

RANCANG BANGUN SISTEM KLASIFIKASI DAERAH RAWAN BANJIR DI KOTA LANGSA MEGGUNAKAN *GIS* DAN *MACHINE LEARNING*

SKRIPSI

Diajukan Sebagai Salah Satu Syarat Untuk Menyelesaikan
Pendidikan Jenjang Sarjana Terapan
Pada Politeknik Negeri Lhokseumawe



Oleh:

M. AKBAR ZULFIKAR

NIM : 2022573010093
Program Studi : Teknik Informatika
Jurusan : Teknologi Informasi dan Komputer

**KEMENTERIAN PENDIDIKAN TINGGI, SAINS, DAN TEKNOLOGI
POLITEKNIK NEGERI LHOKSEUMAWE
2026**

PENGESAHAN PEMBIMBING

Skripsi yang berjudul Rancang Bangun Sistem Klasifikasi Daerah Rawan Banjir di Kota Langsa menggunakan *GIS* dan *Machine Learning*, disusun oleh M. Akbar Zulfikar, NIM 2022573010093, Program Studi Teknik Informatika, Jurusan Teknologi Informasi dan Komputer Politeknik Negeri Lhokseumawe, telah memenuhi syarat untuk dipertanggungjawabkan dihadapan dewan penguji.

Buketrata, 15 Juli 2026

Pembimbing I

Pembimbing II

Zulfan Khairil Simbolon, S.T., M.Eng.

NIP. 19690902 199303 1 004

Musta'inul Abdi, S.S.T., M.Kom.

NIP. 19911030 201903 1 015

Mengetahui :

Ketua Jurusan

Teknologi Informasi dan Komputer,

Ketua Program Studi

Teknik Informatika,

Salahuddin, S.T., M.Sc.

NIP. 19740424 200212 1 001

M. Khadafi, S.T., M.T.

NIP. 19750718 200212 1 004

PENGESAHAN PENGUJI

Skripsi yang berjudul Rancang Bangun Sistem Klasifikasi Daerah Rawan Banjir di Kota Langsa menggunakan *GIS* dan *Machine Learning*, disusun oleh M. Akbar Zulfikar, NIM 2022573010093, Program Studi Teknik Informatika, Jurusan Teknologi Informasi dan Komputer Politeknik Negeri Lhokseumawe, telah dipertanggungjawabkan dihadapan dewan penguji dan dinyatakan lulus pada tanggal 20 Juli 2026.

Komisi Sidang,

Zulfan Khairil Simbolon, S.T., M.Eng.

NIP. 196909021993031004

.....
(Ketua Sidang)

Musta'inul Abdi, S.S.T., M.Kom.

NIP. 199110302019031015

.....
(Sekertaris Sidang)

Dr. Rahmad Hidayat, S.Kom., M.Cs.

NIP. 198304202012121003

.....
(Penguji I)

Muhammad Rizka, S.S.T., M.Kom.

NIP. 198810092015041001

.....
(Penguji II)

Muhammad Reza Zulman, S.S.T., M.Sc.

NIP. 199205012022031005

.....
(Penguji III)

Mengetahui,

Ketua Jurusan
Teknologi Informasi dan Komputer,

Ketua Program Studi
Teknik Informatika,

Salahuddin, S.T., M.Sc.

NIP. 19740424 200212 1 001

M. Khadafi, S.T., M.T.

NIP. 19750718 200212 1 004

HALAMAN PERNYATAAN

Dengan ini saya menyatakan bahwa dalam Skripsi ini tidak terdapat karya yang pernah diajukan untuk mendapatkan gelar kesarjanaan di suatu Perguruan Tinggi, dan sepanjang pengetahuan saya juga tidak terdapat karya atau pendapat yang pernah ditulis orang lain, kecuali yang secara tertulis diacu dalam naskah dan disebut dalam daftar pustaka.

Lhokseumawe, 15 Juli 2026

M. Akbar Zulfikar

NIM. 2022573010093

KATA PENGANTAR

Segala puji beserta syukur senantiasa penulis panjatkan kepada Allah SWT yang telah memberikan rahmat dan petunjuk-Nya kepada penulis sehingga dapat menyelesaikan skripsi yang berjudul *"Rancang Bangun Sistem Klasifikasi Daerah Rawan Banjir Di Kota Langsa Menggunakan GIS Dan Machine Learning"*. Shalawat beserta salam kepada baginda Rasulullah Muhammad SAW, keluarga, dan para sahabat yang telah berjasa dalam memperjuangkan islam dan ilmu pengetahuan. Skripsi ini disusun sebagai salah satu syarat untuk menyelesaikan pendidikan Sarjana Terapan Program Studi Teknik Informatika, Jurusan Teknologi Informasi dan Komputer, Politeknik Negeri Lhokseumawe.

Dalam penyusunan skripsi ini, penulis banyak mendapatkan dukungan, perhatian, dorongan, bimbingan, dan berbagai bantuan dari banyak pihak, terutama para dosen pembimbing. Dengan demikian, segala hormat dan kerendahan hati, penulis menyampaikan rasa terima kasih yang tidak terhingga terutama kepada:

1. Ucapan teristimewa kepada kedua orang tua, yaitu Ayahanda Zulfikar dan Ibunda Mawar Afrida, yang selalu memberikan doa, dukungan, dan materi serta memberikan semangat dan kasih sayang sehingga penulis dapat berdiri tegar dan menyelesaikan skripsi ini. Teruntuk adik tersayang M. Naufal Kamil Zulfikar, Siti Keisya Kamila, dan M. Ikhsan Kamil Zulfikar.
2. Bapak Zulfan Khairil Simbolon, S.T., M.Eng. dan Bapak Musta'inul Abdi, S.S.T., M.Kom., selaku Pembimbing I dan II, yang telah membimbing penulis, memberi petunjuk, memberi saran-saran dan arahan serta masukan dari awal masa pengajuan judul sampai berhasil menyelesaikan skripsi.

3. Bapak Mahdi, S.T., M.Cs., selaku Koordinator Skripsi, atas segala perhatian, arahan, dan dukungan yang telah membantu kelancaran penulis dalam menyelesaikan skripsi ini. Para dosen dan tenaga pengajar Program Studi Teknik Informatika yang telah memberikan arahan dan bimbingan selama proses perkuliahan.
4. Bapak Salahuddin, S.T., M.Cs., selaku Ketua Jurusan Teknologi Informasi dan Komputer, Bapak Fachri Yanuar Rudi F, S.S.T., M.T., selaku Sekretaris Jurusan Teknologi Informasi dan Komputer, dan Bapak M. Khadafi, S.T., M.T., selaku Ketua Program Studi Teknik Informatika, atas segala bimbingan dan perhatian selama masa perkuliahan.
5. Bapak Ir. Rizal Syahyadi, ST, M.Eng.Sc IPM.ASEAN Eng., APEC Eng., selaku Direktur Politeknik Negeri Lhokseumawe.
6. Bapak Dr. Rahmad Hidayat, S.Kom., M.Cs., Bapak Muhammad Rizka, S.S.T., M.Kom. dan Bapak Muhammad Reza Zulman, S.S.T., M.Sc. , selaku penguji yang telah bersedia memberikan arahan dan masukan dalam pengerjaan skripsi ini.
7. Ucapan terima kasih penulis sampaikan kepada Akbar Bimantara, Rendy Aditya Dalimunthe, Rahmat Isma Hidayat, Agung Ramadhan Setiawan, Muhammad Rizki, Muhammad Abil, dan Teman-teman Kost Jackpro yang senantiasa memberi dukungan, menemani, serta berjuang bersama selama masa perkuliahan. Terima kasih juga kepada seluruh teman-teman Angkatan 2022 Program Studi Teknik Informatika yang telah menjadi

bagian dari perjalanan penuh cerita dan perjuangan, serta kepada DPM dan KomIT atas pengalaman dan kesempatan belajar yang berharga.

8. Ucapan terima kasih juga penulis sampaikan kepada Manchester United, klub sepak bola kesayangan penulis, yang secara tidak langsung mengajarkan arti kesabaran dan pentingnya terus berproses meskipun kerap dihina dan diremehkan. Sebagaimana lirik *"Glory Glory Man United"* yang tetap dinyanyikan para pendukungnya tanpa memandang hasil pertandingan, penulis belajar bahwa dukungan dan keyakinan terhadap sebuah proses tidak seharusnya bergantung pada hasil sesaat. Kritik yang datang di tengah proses tersebut turut diingatkan lewat kutipan Eric Cantona, *"When the seagulls follow the trawler, it's because they think sardines will be thrown into the sea."* — bahwa kritik yang dilontarkan tanpa memahami situasi sebenarnya tidak perlu dijadikan alasan untuk berhenti. *"Once Red Always Red"* — sebuah keyakinan yang tetap dipegang teguh apa pun hasil yang didapat, menjadi pengingat bahwa loyalitas dan proses yang konsisten pada akhirnya lebih bermakna daripada hasil instan semata, sebuah nilai yang turut jadi pengingat pada diri penulis selama menyelesaikan skripsi ini.
9. Terakhir, penulis ingin mengucapkan terima kasih yang sebesar-besarnya kepada diri sendiri, karena telah bertahan dan menolak untuk menyerah dalam menyelesaikan skripsi ini. Perjalanan menyusun sistem ini tidak selalu mudah mulai dari data yang perlu ditelusuri dan diperbaiki berulang kali, kode program yang harus dicocokkan ulang dengan *notebook* aslinya,

hingga struktur bab yang dirombak beberapa kali mengikuti arahan dosen pembimbing. Namun, setiap kali menemukan sesuatu yang keliru dan memperbaikinya sampai benar-benar sesuai, itu menjadi bukti bahwa penulis tidak berhenti pada jawaban yang terlihat "cukup baik", melainkan terus mencari jawaban yang dapat dipertanggungjawabkan. Kesungguhan tersebut adalah fondasi yang layak dibawa ke langkah-langkah berikutnya, jauh melampaui skripsi ini semata.

Penulis menyadari masih banyak kekurangan dalam penulisan ini dan berharap skripsi ini bermanfaat bagi semua pihak, khususnya bagi Pemerintah Kota Langsa dalam upaya mitigasi bencana banjir, serta amal baik yang diberikan kepada penulis dibalas oleh Allah SWT. Aamiin.

Lhokseumawe, 15 Juli 2026.
Penulis,

M. Akbar Zulfikar
NIM. 2022573010093

DAFTAR ISI

PENGESAHAN PEMBIMBING	i
PENGESAHAN PENGUJI	ii
HALAMAN PERNYATAAN.....	iii
KATA PENGANTAR.....	iv
DAFTAR ISI.....	viii
DAFTAR GAMBAR.....	xii
DAFTAR TABEL	xv
Abstrak	xix
<i>Abstract</i>	xx
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang Masalah.....	1
1.2 Rumusan Masalah	5
1.3 Tujuan Penelitian	6
1.4 Batasan Masalah.....	7
1.5 Manfaat Penelitian	9
1.6 Sistematika Penulisan	10
BAB II TINJAUAN PUSTAKA.....	13
2.1 <i>State of the Art</i>	13
2.2 Tinjauan Teoritis	18
2.2.1 Banjir.....	18
2.2.2 Daerah Rawan Banjir	18
2.2.3 Badan Informasi Geospasial (BIG).....	19
2.2.4 <i>Sistem Informasi Geografis (GIS)</i>	20
2.2.5 <i>WebGIS</i>	20
2.2.6 Data Spasial.....	21
2.2.7 <i>Machine Learning</i>	22
2.2.8 <i>Random Forest</i>	22
2.2.9 Variabel dan Parameter Penyebab Banjir	24
2.2.10 Klasifikasi Daerah Rawan Banjir.....	25
2.2.11 Integrasi <i>GIS</i> dan <i>Machine Learning</i>	25
2.2.12 <i>Confusion Matrix</i>	26

2.2.13	<i>Cohen's Kappa</i>	26
2.2.14	<i>Matthews Correlation Coefficient (MCC)</i>	28
BAB III METODOLOGI PENELITIAN		30
3.1	Alur Penelitian	30
3.2	Analisis Kebutuhan Sistem	32
3.2.1	Analisis Kebutuhan Fungsional	32
3.2.2	Analisis Kebutuhan Non-Fungsional	33
3.3	Rancangan Sistem	34
3.3.1	Arsitektur Sistem.....	34
3.3.2	<i>Use Case Diagram</i>	37
3.3.3	<i>Activity Diagram</i>	40
3.3.4	<i>Wireframe</i> Antarmuka Sistem.....	48
3.4	Data dan Pengumpulan Data	51
3.4.1	Metode Pengumpulan Data.....	Error! Bookmark not defined.
3.4.2	Jenis dan Sumber Data	53
3.4.3	Pengambilan Data Spasial <i>GIS</i>	54
3.4.4	<i>Preprocessing Data</i> Spasial	55
3.4.5	Penggabungan Data.....	65
3.4.6	Pembentukan Dataset	67
3.5	Perancangan Metode	69
3.5.1	Metodologi Pengembangan Sistem.....	Error! Bookmark not defined.
3.5.2	Model Klasifikasi A dan Model Klasifikasi B	69
3.5.3	Algoritma Model Klasifikasi <i>Random Forest</i>	72
3.5.4	Optimasi Hiperparameter <i>GridSearchCV</i>	77
3.5.5	Metode Evaluasi Model	Error! Bookmark not defined.
3.6	Teknik Pengujian	81
3.6.1	Evaluasi Menggunakan <i>Confusion Matrix</i>	Error! Bookmark not defined.
3.6.2	Pengujian <i>Blackbox</i>	83
3.6.3	Pengujian <i>Whitebox</i>	85
3.6.4	Pengujian Performa Model	Error! Bookmark not defined.
BAB IV HASIL DAN PEMBAHASAN		86

4.1	Hasil Implementasi Sistem <i>WebGIS</i>	86
4.1.1	Hasil Halaman <i>Dashboard</i>	86
4.1.2	Hasil Halaman Peta Kerawanan	87
4.1.3	Hasil Halaman Statistik Kerawanan	88
4.1.4	Hasil Halaman Evaluasi Model	90
4.1.5	Hasil Halaman Kelola Data <i>GIS</i>	95
4.2	Hasil Pengolahan dan Pengumpulan Data Spasial	99
4.2.1	Peta <i>Digital Elevation Model (DEM)</i>	99
4.2.2	Peta Kemiringan Lereng (<i>Slope</i>)	100
4.2.3	Peta <i>Topographic Wetness Index (TWI)</i>	101
4.2.4	Peta <i>Plan Curvature</i>	102
4.2.5	Peta <i>Height Above Nearest Drainage (HAND)</i>	104
4.2.6	Peta Jarak Terhadap Sungai	105
4.2.7	Peta Jarak Terhadap Jalan	106
4.2.8	Peta Penggunaan Tutupan Lahan (<i>LULC</i>)	108
4.2.9	Peta Jenis Tanah	109
4.2.10	Peta Curah Hujan Rata-rata Tahunan	111
4.3	Hasil Pembentukan Dataset	112
4.3.1	Statistik Deskriptif Fitur	112
4.3.2	Distribusi Label Dataset Model A	114
4.3.3	Distribusi Label Dataset Model B	116
4.3.4	Perbandingan Karakteristik Kedua <i>Dataset</i>	117
4.4	Implementasi Algoritma <i>Random Forest</i>	118
4.4.1	Implementasi Model A (66Desa/Kelurahan)	118
4.4.2	Implementasi Model B (1.500 Titik Sampel)	127
4.4.3	Perbandingan Implementasi Model A dan Model B	135
4.5	Hasil Evaluasi Model A (66desa/kelurahan)	136
4.5.1	Hasil Evaluasi Klasifikasi Biner	136
4.5.2	Hasil Evaluasi Klasifikasi 3 Kelas	140
4.5.3	<i>Feature Importance</i>	144
4.5.4	<i>Matriks Pembanding</i> per Desa	146
4.5.5	Ringkasan Evaluasi Model A	148

4.6	Hasil Evaluasi Model B (1.500 Titik Sampel).....	149
4.6.1	Hasil <i>GridSearchCV</i>	150
4.6.2	Perbandingan Model <i>Baseline</i> dan Model <i>Teroptimasi</i>	151
4.6.3	Evaluasi pada Data Uji.....	151
4.6.4	<i>Feature Importance</i>	154
4.6.5	Ringkasan Evaluasi Model B	156
4.7	Perbandingan Hasil Klasifikasi dengan KRB Kota Langsa.....	157
4.7.1	Data KRB Kota Langsa.....	158
4.7.2	Perbandingan dengan Hasil Model A	160
4.7.3	Perbandingan dengan Hasil Model B.....	161
4.7.4	Analisis Perbedaan Hasil Berdasarkan Unit Analisis dan Konsistensi dengan KRB	162
4.8	Hasil Pengujian Sistem	165
4.8.1	Hasil Pengujian <i>Blackbox</i>	166
4.8.2	Hasil Pengujian <i>Whitebox</i>	181
BAB V	PENUTUP.....	191
5.1	Simpulan	191
5.2	Saran.....	193
	JADWAL KEGIATAN PENELITIAN.....	195
	RENCANA ANGGARAN PENELITIAN	196
	DAFTAR PUSTAKA	197

DAFTAR GAMBAR

Gambar 3.1 Alur Penelitian	30
Gambar 3.2 Arsitektur Sistem	35
Gambar 3.3 Use-Case Diagram	37
Gambar 3. 4 Acitivity Diagram Login	41
Gambar 3.5 Activity Diagram Halaman Dashboard	42
Gambar 3.6 Activity Diagram kelola data GIS	43
Gambar 3.7 Activity Diagram Visualisasi Peta daerah Rawan Banjir	44
Gambar 3.8 Activity Diagram Visualisasi Statistik daerah Rawan Banjir	45
Gambar 3.9 Activity Diagram Cari daerah Rawan Banjir	46
Gambar 3.10 Activity Diagram menampilkan Evaluasi Model	47
Gambar 3.11 Wireframe Halaman	48
Gambar 3.12 Wireframe Halaman Visualisasi Peta Daerah Rawan Banjir	49
Gambar 3. 13 Wireframe Halaman Visualisai Statistik Derah Rwan Banjir	50
Gambar 3.14 Wireframe Halaman Evaluasi Model	51
Gambar 3.15 Flowchart Pengambilan Data Spasial GIS	54
Gambar 3.16 Flowchart Preprocessing Data	55
Gambar 3.17 Flowchart proses Penyamaan Sistem Kordinat	56
Gambar 3.18 Flowchart proses Clipping Data	57
Gambar 3. 19 Flowchart proses Resampling Data	57
Gambar 3.20 Flowchart Proses Penyamaan Format Data	58
Gambar 3.21 Flowchart Proses Derivasi DEM	59
Gambar 3. 22 Flowchart Proses Reklasifikasi Variabel Penggunaan Lahan	60

Gambar 3.23 Flowchart Reklasifikasi Jenis Tanah, Curah Hujan.....	62
Gambar 3. 24 Flowchart Pembuatan Proximity Raster	63
Gambar 3.25 Flowchart Proses Verifikasi Visual Data.....	64
Gambar 3.26 Flowchart Proses Penggabungan Data	65
Gambar 3.27 Flowchart <i>proses pembentukan dataset</i>	68
Gambar 3.28 Metodologi Pengembangan Sistem. Error! Bookmark not defined.	
Gambar 3.29 Proses Model Klasifikasi Algoritma Random Forest	75
Gambar 4.1 Halaman Dashboard.....	86
Gambar 4.2 Halaman Peta Kerawanan.....	87
Gambar 4.3 Halaman Statistik Model A	88
Gambar 4.4 Halaman Statistik Model B.....	89
Gambar 4.5 Halaman Metrik Evaluasi Model A.....	91
Gambar 4.6 Confusion Matrix, Hiperparameter, dan Matriks Pembandingan Model A.....	92
Gambar 4.7 Halaman Feature Importance Model A	93
Gambar 4.9 Confusion Matrix, Hiperparameter Model B	94
Gambar 4.10 Halaman Feature Importance Model B.....	95
Gambar 4.11 Halaman Tab Data Titik Sampel & Data Desa.....	96
Gambar 4.12 Halaman Tab Klasifikasi Manual	97
Gambar 4.13 Halaman Tab Kelola Pengguna	98
Gambar 4.14 Peta Digital Elevation Model (DEM) Kota Langsa.....	99
Gambar 4.15 Peta Kemiringan Lereng (Slope) Kota Langsa.....	100
Gambar 4.16 Peta Topographic Wetness Index (TWI) Kota Langsa.....	101

Gambar 4.17 Peta Plan Curvature Kota Langsa	103
Gambar 4.18 Peta Height Above Nearest Drainage (HAND) Kota Langsa	104
Gambar 4.19 Peta Jarak Terhadap Sungai.....	105
Gambar 4.20 Peta Jarak Terhadap Jalan.....	107
Gambar 4.21 Peta Penggunaan Tutupan Lahan (LULC) Kota Langsa	108
Gambar 4.22 Peta Jenis Tanah Kota Langsa	110
Gambar 4.23 Peta Curah Hujan Kota Langsa	111
Gambar 4.24 Distribusi Label Dataset Model A	114
Gambar 4.25 Diagram distribusi label Model B.....	116
Gambar 4.26 Confusion Matrix Model A Klasifikasi Biner (n=14)	137
Gambar 4.27 Confusion Matrix Model A Klasifikasi 3 Kelas (n=20)	141
Gambar 4.28 Feature Importance Model A Klasifikasi Biner.....	144
Gambar 4.29 Feature Importance Model A Klasifikasi 3 Kelas	145
Gambar 4.30 Confusion Matrix Model B (n=300).....	152
Gambar 4.31 Kurva ROC Model B	154
Gambar 4.32 Feature Importance Model B	155

DAFTAR TABEL

Tabel 2.1 <i>State of the Arts</i>	14
Tabel 3.1 Tahapan Alur Penelitian.....	30
Tabel 3.2 Kebutuhan Fungsional Sistem.....	32
Tabel 3.3 Spesifikasi Perangkat Keras	33
Tabel 3.4 Spesifikasi Perangkat Lunak	34
Tabel 3.5 Layer Arsitektur Sistem	35
Tabel 3.6 Deskripsi Aktor	38
Tabel 3.7 Deskripsi Use Case.....	38
Tabel 3.8 Tahapan Metodologi Pengembangan Sistem.....	Error! Bookmark not defined.
Tabel 3.9 Parameter Data spasial sebagai Variabel Masukan Model	72
Tabel 3.10 Ruang Pencarian Hiperparameter <i>GridSearchCV</i> Model A.....	78
Tabel 3.11 Ruang Pencarian Hiperparameter <i>GridSearchCV</i> Model B.....	79
Tabel 3.12 Wilayah Administrasi Kota Langsa	52
Tabel 3.13 Metode Pengumpulan Data	53
Tabel 3.14 Jenis dan Sumber Data	53
Tabel 3.15 Skor Reklasifikasi Penggunaan Lahan (LULC).....	61
Tabel 3.16 Skenario Pengujian Fungsional (<i>Blackbox</i>)	83
Tabel 3.17 Skenario Pengujian <i>Whitebox</i>	85
Tabel 4.1 Hasil Klasifikasi Model A per Kecamatan.....	89
Tabel 4.2 Hasil Klasifikasi Model B per Kecamatan	90
Tabel 4.3 Statistik Deskriptif 10 Variabel Fitur	113

Tabel 4.4 Distribusi Label Binary Dataset Model A per Kecamatan.....	115
Tabel 4.5 Perbandingan Karakteristik Dataset Model A dan Model B.....	117
Tabel 4.6 Hiperparameter Terbaik Model A	123
Tabel 4.7 Ruang Pencarian dan Hiperparameter Terbaik Model B	130
Tabel 4.8 Perbandingan Model Baseline dan Model setelah GridsearchCV	132
Tabel 4.9 Perbandingan Implementasi Model A dan Model B	135
Tabel 4.10 Confusion Matrix Model A Biner pada Data Uji	138
Tabel 4.11 Hiperparameter <i>GridSearchCV</i> Terbaik Model A Biner	138
Tabel 4.12 Hasil Evaluasi Repeated CV Model A Klasifikasi Biner.....	140
Tabel 4.13 Confusion Matrix Model A Klasifikasi 3 Kelas (n=20).....	142
Tabel 4.14 Hiperparameter <i>GridSearchCV</i> Terbaik Model A 3 Kelas	143
Tabel 4.15 Hasil Evaluasi Repeated CV Model A Klasifikasi 3 Kelas.....	143
Tabel 4.16 Feature Importance Model A Biner dan 3 Kelas.....	145
Tabel 4.17 <i>Matriks Pembanding</i> Model A per Desa (n=66)	147
Tabel 4.18 Metrik Evaluasi <i>Matriks Pembanding</i> Model A per Desa	147
Tabel 4.19 Ringkasan Seluruh Hasil Evaluasi Model A	149
Tabel 4.20 Hiperparameter Terbaik Model B	150
Tabel 4.21 Perbandingan Baseline Model dan <i>GridSearchCV</i> pada Model B....	151
Tabel 4.22 Confusion Matrix Model B pada Data Uji (n=300)	152
Tabel 4.23 Hasil Evaluasi Model B pada Data Uji	153
Tabel 4.24 Feature Importance Model B.....	155
Tabel 4.25 Ringkasan Evaluasi Model B	156

Tabel 4.26 Bahaya dan Risiko Banjir per Kecamatan (KRB Kota Langsa 2024)	159
Tabel 4. 27 Perbandingan Hasil Model A dengan KRB per Kecamatan	160
Tabel 4.28 Perbandingan Hasil Model B dengan KRB per Kecamatan	161
Tabel 4.29 Perbedaan Hasil Model A vs Model B per Kecamatan	162
Tabel 4.30 Pengujian <i>Blackbox</i> Halaman Register	167
Tabel 4.31 Pengujian <i>Blackbox</i> halaman Login	168
Tabel 4.32 Pengujian <i>Blackbox</i> Halaman Dashboard	170
Tabel 4.33 Pengujian <i>Blackbox</i> Halaman Pengelolaan Data <i>GIS</i>	171
Tabel 4.34 Pengujian <i>Blackbox</i> Halaman Visualisasi Peta	172
Tabel 4.35 Pengujian <i>Blackbox</i> Halaman Visualisasi Statistik	173
Tabel 4.36 Pengujian <i>Blackbox</i> Halaman Pencarian Lokasi	174
Tabel 4.37 Pengujian <i>Blackbox</i> Halaman Evaluasi Performa Model	175
Tabel 4.38 Pengujian <i>Blackbox</i> Halaman Klasifikasi Manual	176
Tabel 4.39 Pengujian <i>Whitebox</i> Preprocessing Data	181
Tabel 4.40 Flowgraph dan Kompleksitas <i>Preprocessing</i> Data	182
Tabel 4.41 Jalur Independen dan Hasil Pengujian <i>Preprocessing</i> Data	182
Tabel 4.42 Pengujian <i>Whitebox</i> Proses Penggabungan Data	183
Tabel 4.43 Flowgraph dan Kompleksitas Penggabungan Data	184
Tabel 4.44 Jalur Independen dan Hasil Pengujian Penggabungan Data	184
Tabel 4.45 Pengujian <i>Whitebox</i> Proses Pembentukan Dataset	185
Tabel 4.46 Flowgraph dan Kompleksitas Pembentukan Dataset	186
Tabel 4.47 Jalur Independen dan Hasil Pengujian Pembentukan Dataset	187

Tabel 4.48	Pengujian <i>Whitebox</i> Proses Endpoint Model Random Forest.....	188
Tabel 4.49	Flowgraph dan Kompleksitas Endpoints Model <i>Random Forest</i>	189
Tabel 4.50	Jalur Independen dan Hasil Pengujian Model <i>Random Forest</i>	189

Abstrak

Kota Langsa merupakan salah satu wilayah di Provinsi Aceh yang rutin mengalami kejadian banjir, namun belum tersedia sistem klasifikasi daerah rawan banjir berbasis perangkat lunak yang teruji pada tingkat desa/kelurahan. Penelitian ini merancang dan membangun sistem klasifikasi daerah rawan banjir dengan mengintegrasikan *Sistem Informasi Geografis (GIS)* dan algoritma *Random Forest* berdasarkan 10 variabel geospasial yang bersumber dari Badan Informasi Geospasial (BIG), *ESA WorldCover*, *FAO DSMW*, dan *CHIRPS*. Sistem dibangun dengan dua unit analisis, yaitu Model A pada 66 desa/kelurahan dan Model B pada 1.500 titik sampel, dan diimplementasikan sebagai *WebGIS* berbasis *Next.js*, *FastAPI*, dan *Supabase PostgreSQL*. Model A melalui *Repeated Cross-Validation* menghasilkan akurasi $77,73\% \pm 8,41\%$, sedangkan *Matriks Pembandingan* terhadap seluruh 66 desa menghasilkan akurasi 92,42% dan *Cohen's Kappa* 0,7791. Model B melalui evaluasi pada 300 data uji menghasilkan akurasi 84,33%, *F1-Score* 0,8399, *AUC-ROC* 0,8528, *Cohen's Kappa* 0,4022, dan *Matthews Correlation Coefficient* 0,4031. Pengujian *Blackbox* terhadap sembilan segmen sistem menghasilkan 24 dari 26 skenario Berhasil, dan pengujian *Whitebox* menggunakan *Basis Path Testing* terhadap empat proses inti menghasilkan 16 jalur independen yang seluruhnya terverifikasi melalui *unit test*. Sistem menghasilkan klasifikasi 52 dari 66 desa/kelurahan sebagai Rawan pada Model A dan 259 dari 1.500 titik sampel sebagai Rawan pada Model B, yang disajikan secara spasial melalui peta interaktif sehingga dapat diakses dan dimanfaatkan oleh masyarakat maupun pemangku kebijakan dalam upaya mitigasi bencana banjir.

Kata Kunci: Klasifikasi Daerah Rawan Banjir, *Sistem Informasi Geografis*, *Random Forest*, *WebGIS*, Kota Langsa

Abstract

Langsa City is one of the regions in Aceh Province that regularly experiences flooding, yet no tested software-based flood-prone area classification system is currently available at the village level. This research designs and builds a flood-prone area classification system by integrating a Geographic Information System (GIS) with the Random Forest algorithm based on 10 geospatial variables sourced from the Geospatial Information Agency (BIG), ESA WorldCover, FAO DSMW, and CHIRPS. The system was built using two units of analysis, namely Model A at the village level (66 villages) and Model B at the sample point level (1,500 points), and was implemented as a WebGIS based on Next.js, FastAPI, and Supabase PostgreSQL. Model A, evaluated through Repeated Cross-Validation, achieved an accuracy of $77.73\% \pm 8.41\%$, while the Comparative Matrix against all 66 villages produced an accuracy of 92.42% and a Cohen's Kappa of 0.7791. Model B, evaluated on 300 test data points, achieved an accuracy of 84.33%, an F1-Score of 0.8399, an AUC-ROC of 0.8528, a Cohen's Kappa of 0.4022, and a Matthews Correlation Coefficient of 0.4031. Blackbox testing on nine system segments produced 24 of 26 successful scenarios, while Whitebox testing using Basis Path Testing on four core processes produced 16 independent paths, all verified through unit testing. The system classified 52 of 66 villages as flood-prone under Model A and 259 of 1,500 sample points as flood-prone under Model B, both presented spatially through an interactive map so that the results can be accessed and utilized by the public and policymakers in flood disaster mitigation efforts.

Keywords: *Flood-Prone Area Classification, Geographic Information System, Random Forest, WebGIS, Langsa City*

BAB I

PENDAHULUAN

1.1 Latar Belakang Masalah

Banjir merupakan salah satu bencana hidrometeorologi yang paling sering terjadi di berbagai wilayah dunia dan menimbulkan dampak signifikan terhadap aspek sosial, ekonomi, dan lingkungan. Perubahan iklim global yang ditandai dengan meningkatnya intensitas curah hujan serta perubahan tata guna lahan telah memperbesar potensi terjadinya banjir di berbagai kawasan, sehingga menuntut adanya pendekatan pemetaan dan klasifikasi daerah rawan banjir yang akurat, berbasis data, dan mampu mendukung pengambilan keputusan dalam upaya mitigasi bencana [1][2]. Di Indonesia, banjir menjadi bencana yang paling dominan dan terjadi hampir setiap tahun, terutama pada wilayah perkotaan dan dataran rendah.

Berdasarkan Data Informasi Bencana Indonesia (DIBI) yang dikelola oleh Badan Nasional Penanggulangan Bencana (BNPB), banjir tercatat sebagai jenis bencana dengan frekuensi kejadian tertinggi di Indonesia dengan lebih dari 1.000 kejadian per tahun yang menyebabkan ribuan korban dan kerugian material yang tidak sedikit [3]. Tingginya curah hujan, buruknya sistem drainase, serta pertumbuhan kawasan permukiman di sekitar daerah aliran sungai menyebabkan risiko banjir semakin meningkat. Namun demikian, upaya penanggulangan banjir di banyak daerah masih bersifat reaktif dan belum sepenuhnya didukung oleh sistem klasifikasi kerawanan berbasis analisis spasial dan *Machine Learning* [4][5].

Kota Langsa merupakan salah satu wilayah di Provinsi Aceh yang memiliki tingkat kerawanan banjir yang tinggi. Secara geografis, Kota Langsa berada pada kawasan dataran rendah di pesisir timur Aceh dengan elevasi berkisar antara 0 hingga 105 meter di atas permukaan laut, dilalui oleh Daerah Aliran Sungai (DAS) Krueng Langsa, serta didominasi oleh jenis tanah *Fluvisols* (aluvial pesisir) yang memiliki kapasitas infiltrasi rendah dan muka air tanah yang dangkal. Berdasarkan catatan DIBI BNPB, dalam kurun waktu 2003–2022 Kota Langsa telah mengalami 42 kejadian bencana, di mana banjir menjadi bencana dengan persentase tertinggi sebesar 36% dari total seluruh kejadian bencana dan berdampak pada 28.525 jiwa serta kerusakan 389 unit rumah [6]. Hujan dengan intensitas tinggi di wilayah hulu sungai kerap menyebabkan luapan air yang menggenangi kawasan permukiman, mengganggu aktivitas masyarakat, serta merusak infrastruktur perkotaan.

Kejadian banjir yang paling terkini terjadi pada tanggal 31 Januari 2026 yang menggenangi sebagian besar wilayah permukiman di Kota Langsa. Berdasarkan Kajian Risiko Bencana (KRB) Kota Langsa 2025–2029, banjir dikategorikan sebagai bencana dengan kecenderungan kejadian yang terus meningkat, dengan Kecamatan Langsa Timur memiliki potensi kerugian tertinggi sebesar Rp936,36 miliar, menjadikan Kota Langsa sebagai wilayah yang sangat mendesak untuk diteliti secara ilmiah guna mendukung upaya mitigasi yang terencana [7].

Permasalahan yang dihadapi dalam penanganan banjir di Kota Langsa adalah belum tersedianya sistem klasifikasi daerah rawan banjir yang dikembangkan dalam bentuk perangkat lunak teruji dan dapat diakses secara langsung oleh masyarakat maupun pemangku kebijakan pada tingkat desa/kelurahan. Penelitian

terdahulu di Kota Langsa masih terbatas pada kajian mitigasi dan analisis overlay *GIS* yang disajikan dalam bentuk peta statis [8][9], tanpa dikembangkan menjadi sistem perangkat lunak yang fungsional dan teruji kualitasnya, baik dari sisi kesesuaian fungsi sistem terhadap kebutuhan pengguna maupun struktur kode program di dalamnya. *Geographic Information System (GIS)* telah banyak dimanfaatkan dalam pemetaan kerawanan banjir karena kemampuannya dalam mengelola dan menganalisis data spasial secara terintegrasi, namun hasil kajian tersebut umumnya berhenti pada tahap analisis spasial dan belum diimplementasikan menjadi sistem *WebGIS* yang kelayakannya dapat diverifikasi melalui pengujian perangkat lunak secara sistematis [9].

Dalam metodologi pengkajian bahaya banjir yang ditetapkan BNPB melalui Peraturan Kepala BNPB Nomor 2 Tahun 2012 dan Modul Teknis KRB Banjir, penyusunan peta bahaya banjir dapat dilakukan menggunakan parameter fisik geospasial wilayah sungai yang dikalibrasi dengan data area terdampak banjir yang pernah terjadi. Pendekatan ini menjadi salah satu landasan metodologis penelitian ini dalam menggunakan 10 variabel geospasial fisik dan data ground truth banjir aktual kejadian 31 Januari 2026 sebagai dasar klasifikasi daerah rawan banjir di Kota Langsa pada tingkat desa/kelurahan.

Integrasi *GIS* dengan algoritma *Machine Learning* diperlukan untuk mengatasi keterbatasan analisis *overlay* konvensional dalam menangani hubungan non-linear antar variabel penyebab banjir. Algoritma *Random Forest* dipilih pada penelitian ini karena kemampuannya bekerja dengan kombinasi variabel kontinu dan kategorikal sekaligus, sebagaimana karakteristik 10 variabel geospasial yang

digunakan, serta menghasilkan nilai kontribusi (*feature importance*) tiap variabel yang membantu interpretasi hasil klasifikasi. Kajian terdahulu turut menunjukkan bahwa *Random Forest* secara konsisten mengungguli algoritma *Machine Learning* lain seperti *Naïve Bayes* dan *Support Vector Machine* dalam tugas klasifikasi banjir [10], serta terbukti mampu mengidentifikasi faktor dominan penyebab banjir dengan akurasi klasifikasi yang tinggi pada berbagai wilayah kajian [11][12], sehingga algoritma ini dipandang mendesak untuk diterapkan pada permasalahan klasifikasi daerah rawan banjir di Kota Langsa.

Selain kemampuannya menangani hubungan non-linear dan variabel campuran, *Random Forest* memiliki beberapa keunggulan lain yang menjadikannya sesuai untuk permasalahan klasifikasi daerah rawan banjir pada penelitian ini. Algoritma ini bekerja dengan membangun banyak *decision tree* secara independen menggunakan sampel data yang diambil secara acak (*bootstrap sampling*), kemudian menggabungkan hasil prediksi seluruh pohon melalui mekanisme *majority voting*. Pendekatan ansambel ini membuat *Random Forest* lebih tahan terhadap *overfitting* dibandingkan penggunaan satu *decision tree* tunggal, karena kesalahan yang mungkin terjadi pada sebagian pohon dapat dikompensasi oleh pohon lain dalam kumpulan tersebut. *Random Forest* juga tidak memerlukan normalisasi atau standarisasi nilai variabel sebelum pelatihan, berbeda dengan algoritma berbasis jarak seperti *Support Vector Machine* atau *K-Nearest Neighbor*, sehingga proses pelatihan menjadi lebih sederhana meskipun 10 variabel geospasial yang digunakan memiliki satuan dan rentang nilai yang sangat berbeda (misalnya elevasi dalam satuan meter dan skor kategorikal 1–5). Karakteristik ini

menjadikan *Random Forest* sesuai diterapkan pada kedua unit analisis penelitian ini, termasuk Model A yang hanya memiliki 66 sampel desa/kelurahan, karena pendekatan berbasis ansambel pohon keputusan tetap dapat menghasilkan estimasi yang relatif stabil meskipun ukuran data latih tergolong kecil.

Kebaruan (novelty) penelitian ini terletak pada tiga aspek utama. Pertama, penggunaan data *ground truth* banjir aktual kejadian 31 Januari 2026 yang dikombinasikan dengan nilai *Height Above Nearest Drainage (HAND)* sebagai dasar pembentukan label kerawanan, sebuah pendekatan yang belum pernah diterapkan pada penelitian sejenis di Kota Langsa. Kedua, klasifikasi dilakukan pada unit analisis 66 desa/kelurahan di 5 kecamatan yang lebih detail dibandingkan penelitian terdahulu yang hanya pada tingkat kecamatan [8]. Ketiga, hasil klasifikasi disajikan melalui sistem *WebGIS* interaktif berbasis web yang dapat diakses secara *real-time* oleh masyarakat dan pemangku kebijakan [13].

Oleh karena itu, penelitian ini bertujuan merancang dan membangun sistem klasifikasi daerah rawan banjir di Kota Langsa menggunakan integrasi *GIS* dan algoritma *Random Forest*, serta menghasilkan informasi spasial tingkat kerawanan banjir per desa/kelurahan yang dapat dimanfaatkan oleh pemerintah daerah dan pihak terkait sebagai alat pendukung pengambilan keputusan dalam perencanaan mitigasi bencana banjir secara sistematis dan berbasis bukti.

1.2 Rumusan Masalah

Berdasarkan latar belakang masalah yang telah dijelaskan, maka rumusan masalah dari penelitian ini yaitu :

1. Bagaimana merancang sistem klasifikasi daerah rawan banjir di Kota Langsa pada tingkat desa/kelurahan yang mengintegrasikan *Sistem Informasi Geografis (GIS)* dan algoritma *Machine Learning Random Forest* berdasarkan 10 variabel geospasial yang bersumber dari data resmi Badan Informasi Geospasial (BIG), *ESA WorldCover*, *FAO DSMW*, dan *CHIRPS*
2. Bagaimana membangun sistem klasifikasi daerah rawan banjir di Kota Langsa berdasarkan rancangan yang telah dibuat, sehingga dapat diakses dan digunakan oleh masyarakat maupun pemangku kebijakan melalui sistem *WebGIS*
3. Bagaimana tingkat performa algoritma *Random Forest* dalam mengklasifikasikan daerah rawan banjir per desa/kelurahan di Kota Langsa yang diukur menggunakan metrik akurasi, *F1-Score*, *Cohen's Kappa*, dan *Matthews Correlation Coefficient (MCC)*

1.3 Tujuan Penelitian

Tujuan dari penelitian ini adalah sebagai berikut :

1. Merancang sistem klasifikasi daerah rawan banjir di Kota Langsa pada tingkat desa/kelurahan yang mengintegrasikan *Sistem Informasi Geografis (GIS)* dan algoritma *Machine Learning Random Forest* berdasarkan 10 variabel geospasial yang bersumber dari data resmi Badan Informasi Geospasial (BIG), *ESA WorldCover*, *FAO DSMW*, dan *CHIRPS*.

2. Membangun sistem klasifikasi daerah rawan banjir di Kota Langsa berdasarkan rancangan yang telah dibuat, sehingga dapat diakses dan digunakan oleh masyarakat maupun pemangku kebijakan melalui sistem *WebGIS*.
3. Menghasilkan klasifikasi tingkat kerawanan banjir di Kota Langsa serta Mengukur tingkat performa algoritma *Random Forest* dalam mengklasifikasikan daerah rawan banjir di Kota Langsa menggunakan metrik akurasi, *F1-Score*, *Cohen's Kappa*, dan *Matthews Correlation Coefficient (MCC)*.

1.4 Batasan Masalah

Agar penelitian ini lebih terarah dan tidak meluas dari tujuan penelitian, pembahasan akan dibatasi pada hal-hal berikut :

1. Wilayah penelitian dibatasi pada wilayah administrasi Kota Langsa yang terdiri dari 66 desa/kelurahan di 5 kecamatan, yaitu Kecamatan Langsa Kota, Langsa Baro, Langsa Barat, Langsa Lama, dan Langsa Timur.
2. Data yang digunakan merupakan data spasial sekunder yang mencakup 10 variabel geospasial penyebab banjir, yaitu: *Digital Elevation Model (DEM)*, Kemiringan Lereng (*Slope*), *Topographic Wetness Index (TWI)*, *Plan Curvature*, Jarak terhadap Sungai, Jarak terhadap Jalan, *Height Above Nearest Drainage (HAND)*, Penggunaan Lahan (*LULC*), Jenis Tanah, dan Curah Hujan. Data *DEM*, jaringan sungai, jaringan jalan, dan batas administrasi bersumber dari Badan Informasi Geospasial

(BIG); data *LULC* bersumber dari *ESA WorldCover* 10m tahun 2024; data jenis tanah bersumber dari *FAO Digital Soil Map of the World (DSMW)*; dan data curah hujan bersumber dari *CHIRPS* v2.0 periode 2016–2025. Penelitian difokuskan pada klasifikasi tingkat kerawanan banjir, bukan prediksi waktu kejadian banjir.

3. Data *ground truth* yang digunakan sebagai acuan pembentukan label kerawanan banjir adalah peta area terdampak banjir aktual Kota Langsa pada kejadian 31 Januari 2026. Label biner ditentukan berdasarkan kombinasi dua kondisi: titik sampel berada dalam area terdampak banjir historis dan nilai *HAND* titik tersebut < 1 meter.
4. Pembangunan model klasifikasi menggunakan dua pendekatan: **Model B** berbasis 1.500 titik sampel yang diintegrasikan ke dalam sistem *WebGIS*, dan **Model A** berbasis 66 desa/kelurahan sebagai model pembandingan. Klasifikasi tingkat kerawanan mengacu pada Peraturan Kepala BNPB Nomor 2 Tahun 2012 dengan tiga kelas: Rendah, Sedang, dan Tinggi.
5. Seluruh pengolahan data spasial dilakukan menggunakan perangkat lunak *QGIS* 3.40.14 dengan sistem koordinat EPSG:32647 (*WGS 84 / UTM Zone 47N*) dan resolusi spasial seragam 30 meter.
6. Sistem yang dibangun berupa aplikasi *WebGIS* berbasis *web* menggunakan *framework Next.js* 14, *library* peta *Leaflet.js*, basis data *Supabase/PostgreSQL*, dan *backend FastAPI*. Sistem hanya mencakup fungsi klasifikasi dan visualisasi peta kerawanan banjir, tidak mencakup

prediksi waktu kejadian banjir maupun sistem peringatan dini (*early warning system*).

7. Peta hasil klasifikasi ditampilkan secara interaktif melalui antarmuka *WebGIS* dan tidak dihasilkan sebagai peta tematik statis melalui *overlay* di *QGIS*.

1.5 Manfaat Penelitian

Dalam penelitian ini manfaat yang diharapkan dapat diperoleh adalah sebagai berikut:

1. Memberikan informasi tingkat kerawanan banjir per desa/kelurahan yang dapat diakses secara *online* melalui sistem *WebGIS*, sehingga masyarakat dapat mengetahui tingkat kerawanan wilayah tempat tinggalnya dan meningkatkan kewaspadaan terhadap potensi bencana banjir secara mandiri.
2. Menyediakan alat pendukung pengambilan keputusan berbasis data spasial bagi pemerintah daerah dan Badan Penanggulangan Bencana Daerah (BPBD) Kota Langsa dalam perencanaan mitigasi banjir, penetapan prioritas penanganan wilayah rawan, serta penataan ruang wilayah berdasarkan informasi kerawanan banjir yang terukur secara ilmiah pada skala desa/kelurahan.
3. Memberikan kontribusi ilmiah berupa model klasifikasi daerah rawan banjir berbasis algoritma *Random Forest* yang telah divalidasi

menggunakan data *ground truth* banjir aktual kejadian 31 Januari 2026, dengan metrik evaluasi akurasi 84,33%, *F1-Score* 0,8399, *Cohen's Kappa* 0,4022, dan *MCC* 0,4031 pada Model B (1.500 titik sampel), serta akurasi matriks pembandingan 92,42% dengan *Cohen's Kappa* 0,7791 pada tingkat desa/kelurahan. Hasil penelitian ini dapat menjadi referensi bagi penelitian sejenis di wilayah pesisir Aceh maupun daerah lain dengan karakteristik topografi serupa.

4. Menyediakan kerangka metodologi integrasi *GIS* dan *Machine Learning* untuk klasifikasi kerawanan banjir berbasis data resmi BIG, *ESA WorldCover*, *FAO DSMW*, dan *CHIRPS* yang dapat dikembangkan lebih lanjut dengan menambahkan variabel sosioekonomik, memperluas cakupan wilayah kajian, atau menggunakan data *ground truth* multi-kejadian untuk meningkatkan representativitas label kerawanan.

1.6 Sistematika Penulisan

Sistematika penulisan ini merupakan gambaran menyeluruh mengenai alur pembahasan yang terdapat dalam setiap bab, adapun sistematika penulisan skripsi ini adalah sebagai berikut :

BAB I PENDAHULUAN

Bab ini menguraikan latar belakang permasalahan yang mendasari penelitian, yaitu tingginya tingkat kerawanan banjir di Kota Langsa dan belum tersedianya sistem klasifikasi kerawanan banjir berbasis data ilmiah pada tingkat desa/kelurahan. Selain

itu, bab ini memuat rumusan masalah, tujuan penelitian, batasan masalah, manfaat penelitian, dan sistematika penulisan.

BAB II TINJAUAN PUSTAKA

Bab ini menyajikan kajian penelitian terdahulu yang relevan dalam bentuk tabel *State of the Art*, yang memuat perbandingan metode, kelas output, akurasi, persamaan, dan perbedaan dengan penelitian ini. Selain itu, bab ini menguraikan landasan teori yang menjadi fondasi penelitian, meliputi konsep banjir dan daerah rawan banjir, Badan Informasi Geospasial (BIG), *Sistem Informasi Geografis (GIS)*, algoritma *Random Forest*, variabel dan parameter penyebab banjir, metrik evaluasi model, serta *WebGIS*.

BAB III METODELOGI PENELITIAN

Bab ini menjelaskan metodologi yang digunakan dalam penelitian, yang mencakup jenis dan sumber data spasial yang diperoleh dari BIG, FAO, *ESA WorldCover*, *CHIRPS*, dan data *ground truth* banjir aktual. Bab ini juga memuat metode pengumpulan data, rancangan sistem (*arsitektur*, *use case diagram*, *activity diagram*, dan *wireframe*), alur *preprocessing* data spasial *GIS* di *QGIS 3.40.14*, algoritma model klasifikasi *Random Forest*, serta teknik pengujian sistem.

BAB IV HASIL DAN PEMBAHASAN

Bab ini menyajikan hasil penelitian secara sistematis, dimulai dari hasil pengolahan 10 parameter *GIS* menggunakan *QGIS* yang ditampilkan dalam bentuk peta tematik, hasil *exploratory data analysis* (EDA), hasil pelatihan dan evaluasi model *Random Forest* (Model B — 1.500 titik sampel dan Model A — 66 desa/kelurahan), matriks pembandingan antara prediksi model dan data historis banjir per desa/kelurahan, perbandingan dengan dokumen Kajian Risiko Bencana (KRB) Kota Langsa 2024, serta tampilan dan fungsionalitas sistem *WebGIS* yang dibangun.

BAB V KESIMPULAN DAN SARAN

Bab ini menyajikan kesimpulan yang merupakan jawaban atas rumusan masalah penelitian berdasarkan hasil dan pembahasan yang telah diuraikan pada Bab IV, serta saran yang ditujukan untuk pengembangan penelitian selanjutnya dan pemanfaatan sistem oleh pemangku kebijakan.

BAB II

TINJAUAN PUSTAKA

2.1 *State of the Art*

State of the Art bertujuan untuk mengkaji penelitian-penelitian terdahulu yang relevan dengan topik penelitian guna menunjukkan perkembangan keilmuan dan memperjelas posisi penelitian yang dilakukan. Kajian difokuskan pada penelitian yang menggunakan pendekatan *GIS* dan *Machine Learning* untuk pemetaan atau klasifikasi daerah rawan banjir, baik di Indonesia maupun di tingkat internasional.

Penelitian terdahulu menunjukkan bahwa *GIS* banyak dimanfaatkan dalam pemetaan daerah rawan banjir menggunakan metode *overlay* dan pembobotan parameter fisik lingkungan. Pendekatan tersebut masih bersifat subjektif karena bergantung pada penilaian pakar dalam menentukan bobot parameter. Integrasi *GIS* dengan algoritma *Machine Learning*, khususnya *Random Forest*, hadir sebagai alternatif yang lebih objektif dan mampu menangkap hubungan non-linear antar variabel penyebab banjir.

Meskipun demikian, penelitian terkait klasifikasi daerah rawan banjir berbasis *GIS* dan *Machine Learning* yang dikembangkan dalam bentuk sistem *WebGIS* interaktif dan diterapkan di Kota Langsa pada tingkat desa/kelurahan masih sangat terbatas. Penelitian ini mengisi kesenjangan tersebut dengan membangun sistem klasifikasi berbasis *Random Forest* menggunakan data *ground truth* banjir aktual dan menyajikan hasilnya melalui *WebGIS* yang dapat diakses secara *real-time*.

Adapun ringkasan penelitian terdahulu yang relevan disajikan pada Tabel 2.1 *State of the Arts*.

Tabel 2.1 *State of the Arts*

No	Penulis/Tahun	Judul Artikel	Metode yang Digunakan	Hasil yang Diperoleh	Persamaan	Perbedaan
1.	Andewi et al. (2025) [13]	Integrasi Teknologi Penginderaan Jauh dan <i>Machine Learning</i> Pada <i>WebGIS</i> untuk Pemetaan Potensi Banjir	<i>Random Forest</i> dan <i>GIS</i>	Mengembangkan sistem <i>WebGIS</i> untuk menampilkan potensi banjir secara spasial. Akurasi: 87,5%.	Membangun sistem berbasis <i>GIS</i> dan <i>Random Forest</i> .	Tidak berfokus pada klasifikasi tingkat kerawanan per desa; tidak menggunakan <i>ground truth</i> banjir aktual.
2.	Singha et al. (2024) [11]	Integrating <i>Machine Learning</i> and Geospatial Data Analysis for Comprehensive Flood Hazard Assessment	<i>Random Forest</i> dan <i>GIS</i>	<i>Random Forest</i> mampu mengidentifikasi faktor dominan banjir dan menghasilkan klasifikasi	Mengintegrasikan <i>GIS</i> dan <i>Random Forest</i> untuk pemetaan kerawanan banjir.	Lokasi studi berbeda (India); tidak mengembangkan sistem <i>WebGIS</i> interaktif; tidak ada klasifikasi per desa.

No	Penulis/Tahun	Judul Artikel	Metode yang Digunakan	Hasil yang Diperoleh	Persamaan	Perbedaan
				kerawanan. Akurasi: 92,3%.		
3.	Ningrum et al. (2024) [7]	Strategi Penanganan Banjir Berbasis Mitigasi Bencana Pada Kawasan Rawan Bencana Banjir Di DAS Seulalah Kota Langsa	Analisis Kuantitatif, Superimpose, dan Overlay	Mengidentifikasi wilayah rawan banjir di Kota Langsa berdasarkan analisis spasial. Akurasi tidak dilaporkan.	Lokasi penelitian di Kota Langsa.	Belum menerapkan <i>Machine Learning</i> ; tidak ada <i>WebGIS</i> ; analisis hanya per kecamatan bukan per desa.
4.	Faruq & Amal (2024) [9]	Desain Sistem Prediksi Wilayah Terdampak Banjir dengan <i>Machine Learning</i> Berbasis Data <i>GIS</i>	<i>Random Forest</i> dan <i>GIS</i>	Memberikan prediksi wilayah terdampak banjir berbasis data <i>GIS</i> . Akurasi: 89,7%.	Menggunakan <i>GIS</i> dan <i>Random Forest</i> ; membangun sistem berbasis web.	Fokus pada prediksi wilayah terdampak per kejadian, bukan klasifikasi tingkat kerawanan per desa.

No	Penulis/Tahun	Judul Artikel	Metode yang Digunakan	Hasil yang Diperoleh	Persamaan	Perbedaan
5.	Seprianto et al. (2024) [14]	Pemetaan Daerah Potensi Rawan Banjir Menggunakan Metode Overlay	Overlay <i>GIS</i>	Menghasilkan peta sebaran titik rawan banjir di Kecamatan Andolo. Akurasi tidak dilaporkan.	Memetakan lokasi rawan banjir menggunakan <i>GIS</i> .	Masih menggunakan metode konvensional dengan pembobotan subjektif; belum menggunakan <i>Machine Learning</i> .
6.	Irmawati et al. (2023) [15]	Flood Susceptibility Index Analysis Using Overlay Method and <i>GIS</i> -based	<i>GIS</i> dan Overlay	Menghasilkan klasifikasi daerah dengan tiga indeks kerawanan banjir. Akurasi tidak dilaporkan.	Memberikan informasi klasifikasi daerah rawan banjir menggunakan <i>GIS</i> .	Belum menerapkan <i>Machine Learning</i> ; tidak membangun sistem <i>WebGIS</i> interaktif.
7.	Aritonang et al. (2025) [16]	Comparative Analysis of <i>Random Forest</i> and Naive Bayes for Flood	<i>Random Forest</i> , <i>Naïve Bayes</i>	<i>Random Forest</i> mengungguli	Menggunakan <i>Random Forest</i> untuk	Menggunakan citra SAR Sentinel-1;

No	Penulis/Tahun	Judul Artikel	Metode yang Digunakan	Hasil yang Diperoleh	Persamaan	Perbedaan
		Classification Using Sentinel-1 SAR		<i>Naïve Bayes</i> dalam klasifikasi banjir berbasis citra SAR. Akurasi <i>Random Forest</i> : 91,2%.	klasifikasi banjir.	bukan <i>WebGIS</i> ; tidak ada analisis per desa/kelurahan.
8.	Apriana et al. (2024) [12]	Mapping Flood-Prone Areas Using <i>GIS</i> Through Geo-Artificial Intelligence (Geo-AI) Approach in Bengkulu City	<i>GIS</i> , Geo-AI	Menghasilkan peta daerah rawan banjir berbasis pendekatan Geo-AI di Kota Bengkulu. Akurasi: 88,4%.	Menggunakan <i>GIS</i> dalam memetakan area rawan banjir.	Menggunakan pendekatan Geo-AI, bukan <i>Random Forest</i> ; tidak ada <i>WebGIS</i> per desa.

2.2 Tinjauan Teoritis

Tinjauan teoritis berfungsi sebagai fondasi konseptual yang menjadi rujukan utama dalam merancang serta mengimplementasikan penelitian ini. Bagian ini menguraikan konsep-konsep dasar yang mendasari penelitian beserta rujukan referensinya secara sistematis.

2.2.1 Banjir

Banjir merupakan salah satu bencana hidrometeorologi berupa meluapnya air yang menggenangi suatu wilayah yang biasanya tidak tergenang akibat ketidakmampuan sistem aliran air dalam menampung volume debit air yang melebihi kapasitas tampungnya [6]. Berdasarkan Peraturan Kepala Badan Nasional Penanggulangan Bencana (BNPB) Nomor 2 Tahun 2012 tentang Pedoman Umum Pengkajian Risiko Bencana, banjir dikategorikan sebagai ancaman berulang (*recurrent hazard*) yang perlu dipetakan tingkat bahayanya secara sistematis guna mendukung upaya pengurangan risiko bencana di tingkat daerah (*rujukan peraturan, bukan sitasi jurnal*). Tingginya curah hujan, buruknya sistem drainase, kondisi topografi dataran rendah, serta pertumbuhan kawasan permukiman di sekitar daerah aliran sungai merupakan faktor-faktor utama yang memperparah kejadian banjir di wilayah perkotaan, termasuk di Kota Langsa [6][8].

2.2.2 Daerah Rawan Banjir

Daerah rawan banjir merupakan wilayah yang memiliki tingkat potensi tinggi untuk mengalami banjir berdasarkan karakteristik fisik dan lingkungannya. Tingkat kerawanan banjir suatu wilayah ditentukan oleh kombinasi berbagai faktor seperti kondisi topografi, jenis tanah, penggunaan lahan, curah hujan, dan kedekatan terhadap jaringan sungai [1]. Berdasarkan Peraturan Kepala BNPB

Nomor 2 Tahun 2012, tingkat bahaya banjir diklasifikasikan ke dalam tiga kelas, yaitu Rendah, Sedang, dan Tinggi, yang ditentukan berdasarkan persentase luas wilayah yang terdampak banjir.

2.2.3 Badan Informasi Geospasial (BIG)

Badan Informasi Geospasial (BIG) merupakan lembaga pemerintah nonkementerian yang bertanggung jawab atas penyelenggaraan informasi geospasial di Indonesia berdasarkan Peraturan Presiden Nomor 94 Tahun 2011. BIG berfungsi sebagai otoritas utama yang menyediakan, mengelola, dan mendistribusikan data geospasial dasar yang bersifat resmi dan dapat dipertanggungjawabkan secara hukum. Berdasarkan Peraturan Presiden Nomor 9 Tahun 2016 tentang Percepatan Pelaksanaan Kebijakan Satu Peta, BIG ditetapkan sebagai lembaga yang berwenang menjadi wali data (*data custodian*) bagi seluruh data geospasial dasar di Indonesia, termasuk data batas administrasi, jaringan sungai, jaringan jalan, dan data elevasi [Perpres 9/2016].

Dalam penelitian ini, data yang bersumber dari BIG meliputi DEM Nasional (DEMNAS) dengan resolusi asli 8 meter yang digunakan untuk menghasilkan variabel DEM, *Slope*, *TWI*, *Plan Curvature*, dan *HAND*; data vektor jaringan sungai yang digunakan untuk menghasilkan variabel jarak terhadap sungai; data vektor jaringan jalan yang digunakan untuk menghasilkan variabel jarak terhadap jalan; serta data poligon batas administrasi desa/kelurahan Kota Langsa. Penggunaan data BIG sebagai sumber utama menjamin keabsahan dan standarisasi data geospasial yang digunakan sehingga hasil penelitian dapat dipertanggungjawabkan secara ilmiah.

2.2.4 Sistem Informasi Geografis (GIS)

Sistem Informasi Geografis (GIS) merupakan sistem berbasis komputer yang digunakan untuk mengumpulkan, menyimpan, mengelola, menganalisis, dan menampilkan data yang memiliki referensi geografis [17]. *GIS* memiliki kemampuan untuk mengintegrasikan berbagai jenis data spasial dari sumber yang berbeda sehingga memungkinkan analisis spasial secara terpadu. Dalam penelitian ini, *GIS* digunakan pada dua tahapan utama: pertama, untuk pengolahan data spasial menggunakan *QGIS* 3.40.14 yang mencakup proses proyeksi ulang ke sistem koordinat EPSG:32647 (*WGS 84 / UTM Zone 47N*), pemotongan wilayah (*clipping*), *resampling* ke resolusi 30 meter, ekstraksi nilai parameter ke 1.500 titik sampel, dan penentuan label *ground truth* melalui operasi *intersect* spasial; kedua, sebagai dasar visualisasi hasil klasifikasi dalam bentuk *WebGIS* interaktif berbasis *web* [4][9].

2.2.5 WebGIS

WebGIS merupakan sistem informasi geografis yang dapat diakses melalui antarmuka berbasis *web* menggunakan teknologi internet tanpa memerlukan instalasi perangkat lunak *GIS* khusus di sisi pengguna [13]. *WebGIS* memungkinkan visualisasi, eksplorasi, dan analisis data spasial secara interaktif melalui *browser*, sehingga informasi geografis dapat dimanfaatkan secara lebih luas oleh masyarakat umum maupun pengambil kebijakan. Dalam penelitian ini, sistem *WebGIS* dibangun menggunakan *framework* *Next.js* 14 sebagai *frontend*, *Leaflet.js* sebagai *library* peta interaktif, *Supabase* berbasis *PostgreSQL* sebagai basis data

spasial, dan *FastAPI* sebagai *backend* untuk *serving* prediksi model *Random Forest* secara *real-time* [13].

2.2.6 Data Spasial

Data spasial merupakan data yang merepresentasikan fenomena di permukaan bumi dengan referensi lokasi keruangan (*georeferenced*) [18]. Data spasial pada umumnya terbagi menjadi dua jenis, yaitu data *raster* dan data vektor.

1. Data Raster

Data Raster merupakan jenis data spasial yang merepresentasikan fenomena geografis dalam bentuk susunan sel-sel grid (matriks) atau piksel, di mana setiap piksel menyimpan nilai atribut tertentu. Data raster sangat efektif untuk merepresentasikan fenomena kontinu seperti ketinggian lahan (DEM), kemiringan lereng, curah hujan, dan indeks topografi [18]. Dalam penelitian ini, seluruh 10 variabel geospasial direpresentasikan dalam format raster dengan resolusi 30 meter.

2. Data Vektor

Data Vektor adalah model data spasial yang merepresentasikan fitur geografis sebagai objek geometris berupa titik (*point*), garis (*line*), dan poligon (*polygon*) [17]. Data vektor digunakan dalam penelitian ini untuk merepresentasikan batas administrasi desa/kelurahan, jaringan sungai, dan jaringan jalan yang bersumber dari BIG, serta poligon area terdampak banjir.

2.2.7 *Machine Learning*

Machine Learning merupakan cabang dari kecerdasan buatan (*Artificial Intelligence*) yang memungkinkan sistem komputer untuk mempelajari pola dari data secara otomatis tanpa diprogram secara eksplisit untuk setiap tugas [10]. Dalam konteks pemetaan kerawanan banjir, *Machine Learning* digunakan untuk membangun model prediktif yang mampu mengklasifikasikan tingkat kerawanan suatu wilayah berdasarkan kombinasi variabel geospasial [1]. Keunggulan *Machine Learning* dibandingkan metode konvensional *overlay GIS* terletak pada kemampuannya menangani hubungan non-linear antar variabel dan mengeliminasi subjektivitas dalam penentuan bobot parameter [7][8].

2.2.8 *Random Forest*

Random Forest adalah algoritma *Machine Learning* berbasis *ensemble* yang membangun sejumlah *decision tree* secara acak dari sampel *bootstrap* dan subset fitur, kemudian mengagregasi hasil prediksi setiap pohon melalui mekanisme *majority voting* untuk menghasilkan prediksi akhir [10]. Algoritma ini pertama kali diperkenalkan oleh *Breiman* dan telah banyak digunakan dalam berbagai penelitian klasifikasi spasial karena kemampuannya menangani data berdimensi tinggi, tahan terhadap *overfitting*, memberikan estimasi *feature importance*, serta tidak memerlukan asumsi distribusi data tertentu [1][11]. Dalam penelitian pemetaan kerawanan banjir, *Random Forest* terbukti menghasilkan akurasi yang lebih tinggi dibandingkan *Support Vector Machine (SVM)* maupun *Naïve Bayes* [13]. Pemilihan *Random Forest* pada penelitian ini didasarkan pada karakteristik data yang berdimensi tinggi (10 variabel), distribusi kelas yang tidak seimbang

(*imbalanced*) antara wilayah rawan dan tidak rawan, serta kebutuhan untuk mengidentifikasi variabel yang paling berpengaruh terhadap kerawanan banjir di Kota Langsa. Mekanisme kerja *Random Forest* dalam melakukan pemisahan data pada setiap *node Decision Tree* menggunakan ukuran ketidakmurnian (*impurity*) berupa *Gini Index*. *Gini Index* mengukur seberapa sering elemen yang dipilih secara acak dari himpunan akan salah diklasifikasikan apabila diberi label secara acak sesuai distribusi kelas. Semakin kecil nilai *Gini Index*, semakin murni pemisahan yang dihasilkan. Rumus *Gini Index* adalah sebagai berikut:

$$Gini = 1 - \sum_i p_i^2 : \dots\dots\dots 2.1$$

Dengan:

p_i : Proporsi data pada kelas ke -i

n : jumlah kelas

Setelah seluruh *Decision Tree* menghasilkan prediksi masing-masing, *Random Forest* menentukan hasil klasifikasi akhir melalui mekanisme *majority voting*. Mekanisme ini bekerja dengan menghitung kelas yang paling banyak diprediksi oleh seluruh pohon, kemudian menetapkan sebagai hasil prediksi akhir. Pendekatan ini memastikan bahwa keputusan akhir bersifat kolektif dan tidak bergantung pada satu pohon tunggal, sehingga model lebih stabil dan tahan terhadap *overfitting*. Rumus *majority voting* adalah sebagai berikut :

$$y = mode(y_1, y_2, \dots\dots\dots y_n) : \dots\dots\dots 2.2$$

Dengan :

y : Hasil klasifikasi akhir

y_n : hasil prediksi dari *Decision Tree* ke-n

2.2.9 Variabel dan Parameter Penyebab Banjir

Penentuan tingkat kerawanan banjir dalam penelitian ini didasarkan pada beberapa variabel fisik dan lingkungan yang telah banyak digunakan dalam penelitian terdahulu [8][11]. Variabel-variabel tersebut dipilih karena memiliki pengaruh langsung terhadap proses terjadinya genangan dan luapan air. Seluruh parameter dijadikan sebagai variabel *input* dalam algoritma *Random Forest*, sehingga hubungan antar variabel dapat dianalisis secara simultan dan non-linear, memungkinkan sistem klasifikasi daerah rawan banjir menghasilkan peta kerawanan yang lebih akurat dibandingkan metode konvensional berbasis *overlay* [7].

Seluruh parameter dijadikan sebagai variabel input dalam algoritma *Random Forest*, sehingga hubungan antar variabel dapat dianalisis secara simultan dan non-linear. Pendekatan ini memungkinkan sistem klasifikasi daerah rawan banjir menghasilkan peta kerawanan yang lebih akurat dibandingkan metode konvensional berbasis *overlay*. Parameter yang digunakan meliputi :

1. Ketinggian lahan (*Digital Elevation Model / DEM*)
2. Kemiringan lereng (*slope*)
3. *Topographic Wetness Index (TWI)*
4. Kelengkungan Lereng (*Curvature*)
5. Jarak terhadap Sungai (*Distance to River*)
6. Jarak terhadap Jalan (*Distance to Road*)
7. *Height Above Nearest Drainage (HAND)*
8. Penggunaan lahan (*Land Use / Land Cover*)

9. Jenis Tanah

10. Curah Hujan

2.2.10 Klasifikasi Daerah Rawan Banjir

Klasifikasi daerah rawan banjir merupakan proses pengelompokan wilayah ke dalam kelas tingkat kerawanan tertentu berdasarkan parameter penyebab banjir [11]. Proses ini bertujuan untuk menyederhanakan informasi kompleks mengenai risiko banjir ke dalam kategori yang mudah dipahami oleh pengambil kebijakan dan masyarakat. Berdasarkan Peraturan Kepala BNPB Nomor 2 Tahun 2012, klasifikasi bahaya banjir dilakukan ke dalam tiga kelas: Rendah, Sedang, dan Tinggi (*rujukan peraturan*). Dalam penelitian ini, klasifikasi tiga kelas tersebut diterapkan pada Model A (66 desa/kelurahan), sedangkan Model B (1.500 titik sampel) menggunakan klasifikasi biner (Rawan/Tidak Rawan) karena *ground truth* yang tersedia hanya merepresentasikan satu kejadian banjir.

2.2.11 Integrasi GIS dan Machine Learning

Integrasi *GIS* dan *Machine Learning* memungkinkan pengolahan data spasial dan data atribut secara bersamaan untuk menghasilkan klasifikasi daerah rawan banjir yang lebih akurat dan objektif [9][12]. *GIS* berperan dalam pengumpulan, pengolahan, dan ekstraksi nilai variabel geospasial dari berbagai sumber data, sedangkan *Machine Learning* berperan dalam membangun model prediktif yang mampu mengidentifikasi pola kerawanan dari kombinasi variabel tersebut. Hasil integrasi keduanya kemudian divisualisasikan kembali melalui sistem *WebGIS* sehingga informasi kerawanan dapat dimanfaatkan secara spasial dan interaktif. Pendekatan ini telah terbukti menghasilkan akurasi yang lebih tinggi

dibandingkan metode *GIS* konvensional dalam berbagai penelitian terdahulu [1][9][12].

2.2.12 *Confusion Matrix*

Confusion Matrix merupakan tabel yang digunakan untuk mengevaluasi kinerja model klasifikasi dengan membandingkan hasil prediksi model terhadap data aktual [19]. *Confusion Matrix* terdiri dari empat komponen, yaitu *True Positive (TP)* untuk data Rawan yang diprediksi benar sebagai Rawan, *True Negative (TN)* untuk data Tidak Rawan yang diprediksi benar sebagai Tidak Rawan, *False Positive (FP)* untuk data Tidak Rawan yang salah diprediksi sebagai Rawan, dan *False Negative (FN)* untuk data Rawan yang salah diprediksi sebagai Tidak Rawan. Melalui *Confusion Matrix*, dapat dihitung metrik Akurasi, Presisi, *Recall*, dan *F1-Score* [19]. Untuk rumus metrik-metrik tersebut yaitu :

$$Akurasi = \frac{(TP+TN)}{(TP+TN+FP+FN)} : \dots\dots\dots 2.3$$

$$Presisi = \frac{TP}{(TP+FP)} : \dots\dots\dots 2.4$$

$$Recall = \frac{TP}{(TP+FN)} : \dots\dots\dots 2.5$$

$$F1-Score = 2 \times \frac{(Presisi \times Recall)}{(Presisi + Recall)} : \dots\dots\dots 2.6$$

Confusion matrix membantu mengidentifikasi pola kesalahan model, seperti kecenderungan untuk salah mengklasifikasikan kelas tertentu, dan sangat efektif untuk mengevaluasi model pada dataset yang tidak seimbang.

2.2.13 *Cohen's Kappa*

Cohen's Kappa merupakan metrik yang mengukur tingkat kesepakatan antara hasil prediksi model dengan label aktual, dengan memperhitungkan

kemungkinan kesepakatan yang terjadi secara kebetulan [20]. Nilai *Cohen's Kappa* berkisar antara -1 hingga 1 , di mana nilai 1 menunjukkan kesepakatan sempurna, nilai 0 menunjukkan kesepakatan setara dengan tebakan acak, dan nilai negatif menunjukkan kesepakatan yang lebih buruk daripada acak. Berdasarkan kategorisasi Landis & Koch (1977), nilai *Kappa* diinterpretasikan ke dalam beberapa kategori, mulai dari *Poor* hingga *Almost Perfect* [20]. Nilai *Cohen's Kappa* dihitung menggunakan persamaan:

$$\kappa = (p_o - p_e) / (1 - p_e) \quad 2.7$$

di mana p_o adalah proporsi kesepakatan aktual (*observed agreement*) dan p_e adalah proporsi kesepakatan yang diharapkan secara acak (*expected agreement*). Interpretasi nilai *Cohen's Kappa* mengacu pada Landis & Koch (1977) sebagaimana disajikan pada Tabel 2.1.

Tabel 2.1 Interpretasi Nilai *Cohen's Kappa* (Landis & Koch, 1977)

Nilai Kappa	Interpretasi
$<0,00$	Buruk (<i>Poor</i>)
$0,00-0,20$	Sangat Lemah (<i>Slight</i>)
$0,21-0,40$	Lemah (<i>Fair</i>)
$0,41-0,60$	Sedang (<i>Moderate</i>)
$0,61-0,80$	Kuat (<i>Substansial</i>)
$0,81-1,00$	Hampir Sempurna (<i>Almost Perfect</i>)

Cohen's Kappa dipilih sebagai metrik evaluasi karena distribusi kelas pada model tidak seimbang, sehingga diperlukan metrik yang dapat mengukur

kesepekatan antara prediksi dan label aktual di luar faktor kebeluan, tanpa dipengaruhi oleh dominasi salah satu kelas.

2.2.14 Matthews Correlation Coefficient (MCC)

Matthews Correlation Coefficient (MCC) merupakan metrik evaluasi klasifikasi biner yang memperhitungkan keempat nilai *Confusion Matrix* (TP , TN , FP , FN) secara seimbang, sehingga tetap dapat diandalkan meskipun distribusi kelas tidak seimbang (*imbalanced*) [21]. Nilai *MCC* berkisar antara -1 hingga 1 , di mana nilai 1 menunjukkan prediksi sempurna, 0 menunjukkan prediksi setara acak, dan -1 menunjukkan prediksi yang seluruhnya terbalik. *MCC* dinilai lebih informatif dibandingkan *F1-Score* maupun *Cohen's Kappa* pada kasus *dataset* tidak seimbang, karena satu-satunya metrik yang memperhitungkan keempat sel *Confusion Matrix* sekaligus dalam satu rumus [21]. *MCC* dihitung menggunakan persamaan:

$$MCC = \frac{TP \times TN - FP \times FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}} \quad 2.8$$

Keunggulan *MCC* dibandingkan akurasi dan *F1-Score* terletak pada kemampuannya memberikan nilai yang rendah apabila model hanya bagus memprediksi satu kelas saja (*majority class*), sehingga lebih mencerminkan kinerja model secara menyeluruh [9]. Tabel 2.3 menyajikan interpretasi nilai *MCC*.

Tabel 2.2 Interpretasi Nilai *MCC*

Nilai <i>MCC</i>	Interpretasi
0,90 – 1,00	Sangat Baik
0,70 – 0,89	Baik
0,50 – 0,69	Cukup

Nilai <i>MCC</i>	Interpretasi
0,30 – 0,49	Lemah
0,00 – 0,29	Sangat Lemah
< 0,00	Lebih buruk dari acak

MCC dipilih sebagai salah satu metrik evaluasi untuk peforma Model B yang memiliki ketidakseimbangan distribusi kelas pada data yang tergolong ekstrem. Pada kondisi ketidakseimbangan seperti ini terkadang model hanya memprediksi kelas mayoritas dan tetap menghasilkan akurasi yang tinggi, sehingga *MCC* memperhitungkan empat nilai pada *Confusion Matrix* secara seimbang menjadi metrik yang paling representatif untuk menggambarkan peforma model secara menyeluruh.


Dalam penelitian ini, nilai *MCC* Model B pada *test set* adalah 0,4031 yang termasuk kategori Lemah, konsisten dengan nilai *Cohen's Kappa* 0,4022. Rendahnya nilai *MCC* dan *Kappa* pada Model B disebabkan oleh ketidakseimbangan kelas yang ekstrem (257 titik rawan vs 1.243 titik tidak rawan), bukan karena model tidak mampu membedakan kelas. Hal ini dikonfirmasi oleh nilai akurasi 84,33% dan *F1-Score* 0,8399 yang tergolong baik, serta nilai *AUC-ROC* 0,8528 yang menunjukkan kemampuan diskriminasi model yang memadai.

BAB III

METODOLOGI PENELITIAN

3.1 Alur Penelitian

Alur penelitian ini menjelaskan tahapan-tahapan yang dilakukan dalam penelitian ini secara berurutan, mulai dari identifikasi masalah sampai penarikan kesimpulan. Gambar 3.1 berikut menunjukkan alur penelitian yang dilakukan.



Gambar 3.1 Alur Penelitian

Pada penelitian ini terdapat 11 tahap alur penelitian yang dapat dilihat pada Tabel 3.1.

Tabel 3.1 Tahapan Alur Penelitian

No	Tahapan	Penjelasan
1	Identifikasi Masalah	Permasalahan kerawanan banjir di Kota Langsa diidentifikasi, yaitu belum adanya sistem klasifikasi daerah rawan banjir berbasis data pada tingkat desa/kelurahan.
2	Studi Literatur	Dilakukan studi literatur terhadap penelitian-penelitian terdahulu yang membahas klasifikasi daerah rawan banjir menggunakan <i>GIS</i> dan <i>Machine Learning</i> , sebagai dasar penentuan pendekatan yang digunakan pada penelitian ini.
3	Pengumpulan Data	Data spasial dikumpulkan dari <i>BIG</i> , <i>ESA WorldCover</i> , <i>FAO DSMW</i> , dan <i>CHIRPS</i> , ditambah data <i>ground truth</i> banjir aktual dari kejadian banjir

No	Tahapan	Penjelasan
		31 Januari 2026. Data-data ini menjadi dasar untuk membentuk 10 variabel geospasial yang dipakai dalam penelitian.
4	<i>Preprocessing</i> Data Spasial	Data mentah yang sudah dikumpulkan diolah menggunakan <i>QGIS</i> 3.40.14, mulai dari penyamaan sistem koordinat ke EPSG:32647, <i>clipping</i> ke wilayah Kota Langsa, <i>resampling</i> ke resolusi 30m, sampai perhitungan variabel turunan <i>DEM</i> seperti <i>slope</i> , <i>TWI</i> , <i>curvature</i> , dan <i>HAND</i> .
5	Penggabungan Data dan Pembentukan <i>Dataset</i>	Seluruh variabel yang sudah diolah digabungkan menjadi dua <i>dataset</i> , yaitu dataset 66 desa/kelurahan (Model A) melalui <i>Zonal Statistics</i> dan dataset 1.500 titik sampel (Model B) melalui <i>Sample Raster Values</i> . Kedua <i>dataset</i> ini kemudian dibagi menjadi data latih dan data uji.
6	Perancangan Sistem	Dirancang arsitektur sistem, <i>use case diagram</i> , <i>activity diagram</i> , dan <i>wireframe</i> antarmuka, sebagai acuan sebelum sistem dibangun.
7	Pelatihan dan Evaluasi Model <i>Random Forest</i>	Model dilatih pada kedua <i>dataset</i> menggunakan <i>GridSearchCV</i> untuk mencari kombinasi <i>hyperparameter</i> terbaik, kemudian performanya dievaluasi menggunakan metrik akurasi, <i>F1-Score</i> , <i>Cohen's Kappa</i> , dan <i>MCC</i> .
8	Implementasi Sistem <i>WebGIS</i>	Sistem dibangun berdasarkan rancangan yang sudah dibuat, menggunakan <i>Next.js</i> untuk <i>frontend</i> , <i>FastAPI</i> untuk <i>backend</i> , dan <i>Supabase PostgreSQL</i> sebagai basis data, sehingga hasil klasifikasi model dapat diakses melalui peta interaktif.
9	Pengujian Sistem	Sistem yang sudah dibangun diuji menggunakan dua metode, yaitu <i>Blackbox</i> untuk menguji fungsi-fungsi pada sistem, dan <i>Whitebox</i> untuk menguji kode program pada proses-proses inti sistem.
10	Hasil dan Analisis	Hasil klasifikasi kedua model dianalisis lebih lanjut, meliputi perbandingan hasil antara Model A dan Model B per kecamatan, perbandingan dengan dokumen Kajian Risiko Bencana (KRB) Kota Langsa, dan analisis penyebab perbedaan hasil antar kedua model berdasarkan unit analisis yang digunakan.

No	Tahapan	Penjelasan
11	Penarikan Kesimpulan	Kesimpulan ditarik berdasarkan hasil dan analisis pada tahap sebelumnya, kemudian disusun juga saran untuk pengembangan penelitian selanjutnya.

3.2 Analisis Kebutuhan Sistem

Analisis kebutuhan sistem merupakan fondasi utama dalam pengembangan perangkat lunak yang berfungsi untuk memastikan bahwa solusi yang dirancang benar-benar menjawab persoalan pengguna dan memenuhi standar teknis yang diperlukan. Kebutuhan fungsional menggambarkan layanan dan fitur yang harus disediakan oleh sistem, seperti autentikasi pengguna, pengolahan data, serta proses interaksi pada sistem. Kebutuhan non-fungsional berfokus pada aspek seperti alat atau bahan, skalabilitas, dan kemudahan pemeliharaan pada sistem.

3.2.1 Analisis Kebutuhan Fungsional

Kebutuhan fungsional adalah kebutuhan yang meliputi seluruh entitas dalam suatu sistem serta proses-proses yang dijalankan oleh entitas tersebut. Tabel 3.2 merangkum kebutuhan fungsional yang diidentifikasi pada penelitian ini.

Tabel 3.2 Kebutuhan Fungsional Sistem

ID	Aktor	Kebutuhan Fungsional
KF-01	<i>Admin</i>	Sistem dapat melakukan autentikasi <i>Admin</i> menggunakan <i>email</i> dan <i>password</i> melalui <i>Supabase Auth</i>
KF-02	<i>Admin, User</i>	Sistem dapat menampilkan halaman <i>Dashboard</i> berisi ringkasan statistik kerawanan banjir
KF-03	<i>Admin</i>	Sistem dapat menampilkan, menelusuri, dan mengelola data spasial (1.500 titik sampel dan 66 desa) melalui halaman Kelola Data <i>GIS</i>

ID	Aktor	Kebutuhan Fungsional
KF-04	<i>Admin, User</i>	Sistem dapat menampilkan peta interaktif hasil klasifikasi kerawanan banjir untuk Model A dan Model B
KF-05	<i>Admin, User</i>	Sistem dapat menampilkan statistik hasil klasifikasi per kecamatan dalam bentuk grafik dan tabel
KF-06	<i>Admin, User</i>	Sistem dapat melakukan pencarian lokasi desa/kelurahan berdasarkan nama
KF-07	<i>Admin</i>	Sistem dapat menampilkan metrik evaluasi performa Model A dan Model B
KF-08	<i>Admin</i>	Sistem dapat melakukan klasifikasi secara manual berdasarkan 10 nilai variabel geospasial yang dimasukkan pengguna

3.2.2 Analisis Kebutuhan Non-Fungsional

Kebutuhan non-fungsional mencakup aspek yang berkaitan dengan perangkat keras (*hardware*) dan perangkat lunak (*software*). Perangkat keras merupakan komponen fisik komputer yang dapat dilihat dan disentuh secara langsung. Sebaliknya, perangkat lunak merujuk pada kumpulan instruksi yang diberikan kepada komputer untuk menjalankan tugas tertentu. Tabel 3.3 menyajikan spesifikasi perangkat keras yang digunakan pada penelitian ini.

Tabel 3.3 Spesifikasi Perangkat Keras

No	Komponen	Spesifikasi
1	Perangkat	ASUS Vivobook
2	<i>Processor</i>	AMD Ryzen 5 5600H with Radeon Graphics
3	RAM	16 GB
4	Penyimpanan	SSD 512 GB
5	<i>Graphics Processing Unit (GPU)</i>	NVIDIA GeForce RTX 3050 Laptop GPU
6	Sistem Operasi	Microsoft Windows 11 Home Single Language 64-bit

No	Komponen	Spesifikasi
7	Koneksi internet	Stabil, diperlukan untuk akses <i>Google Colab</i> , <i>Supabase</i> , dan <i>deployment</i> sistem

Tabel 3.4 berikut menyajikan spesifikasi perangkat lunak yang digunakan pada penelitian ini.

Tabel 3.4 Spesifikasi Perangkat Lunak


No	Perangkat Lunak	Fungsi
1	<i>QGIS 3.40.14</i>	Pengolahan dan analisis data spasial
2	<i>Google Colab</i>	Lingkungan pelatihan model <i>Random Forest</i> berbasis <i>Python</i>
3	<i>Google Antigravity IDE</i>	Editor kode untuk pengembangan <i>frontend</i> dan <i>backend</i>
4	<i>Python 3</i>	Bahasa pemrograman untuk <i>preprocessing</i> data dan pelatihan model
5	<i>Node.js</i>	<i>Runtime environment</i> untuk menjalankan <i>Next.js</i>
6	<i>Next.js 14</i>	<i>Framework frontend</i> sistem <i>WebGIS</i>
7	<i>FastAPI</i>	<i>Framework backend</i> untuk melayani model klasifikasi
8	<i>Supabase PostgreSQL</i>	Basis data sistem

3.3 Rancangan Sistem

Rancangan sistem pada penelitian ini menjelaskan gambaran sistem klasifikasi daerah rawan banjir Kota Langsa yang dibangun, mencakup arsitektur sistem, *use case diagram*, *activity diagram*, dan *wireframe* antarmuka sebagai acuan sebelum sistem diimplementasikan.

3.3.1 Arsitektur Sistem

Gambar 3.2 menunjukkan arsitektur sistem yang terdiri dari empat lapisan (*layer*) yang saling terhubung secara berurutan.



Gambar 3.2 Arsitektur Sistem

Arsitektur sistem terdiri dari 4 *layer* yang saling terhubung secara berurutan, sebagaimana dijelaskan pada Tabel 3.5.

Tabel 3.5 *Layer* Arsitektur Sistem

Layer	Nama	Penjelasan
1	Input Data Spasial	Lapisan pengumpulan 8 jenis data spasial dari instansi resmi pemerintah dan lembaga internasional, yang menjadi dasar pembentukan 10 variabel geospasial masukan model.
2	Pemrosesan Data GIS	Lapisan pengolahan data spasial menggunakan <i>QGIS</i> 3.40.14, meliputi penyamaan sistem koordinat, <i>clipping</i> , <i>resampling</i> , derivasi variabel topografi dari <i>DEM</i> , pembuatan proximity raster, dan reklasifikasi skor, sehingga dihasilkan 10 file raster siap pakai.
3	<i>Machine Learning</i>	Lapisan pelatihan model menggunakan <i>Python</i> dan <i>Scikit-learn</i> pada <i>Google Colab</i> , yang membangun Model A (66 desa/kelurahan) dan Model B (1.500 titik sampel) secara paralel melalui pembagian data latih dan data uji, pelatihan algoritma <i>Random Forest</i> , serta optimasi hyperparameter menggunakan <i>GridSearchCV</i> .

Layer	Nama	Penjelasan
4	Sistem <i>WebGIS</i>	Lapisan aplikasi yang menyajikan hasil klasifikasi kepada pengguna, terdiri dari <i>FastAPI</i> (<i>backend</i> , port 8001, endpoint /predict), <i>Supabase PostgreSQL</i> (basis data: flood_points, desa_klasifikasi, kecamatan_stats), <i>Next.js</i> 14 (<i>frontend</i> , port 3000), dan <i>Leaflet.js</i> (library peta interaktif di atas basemap <i>OpenStreetMap</i>).

Pemilihan teknologi (*techstack*) pada setiap *layer* sistem berdasarkan pada pertimbangan kebutuhan fungsional sistem, kemudahan integrasi antar komponen, dan ketersediaan dukungan ekosistem yang memadai.


Next.js dipilih sebagai *framework frontend* dikarenakan mendukung arsitektur *hybrid rendering* yang memungkinkan menampilkan informasi yang bergantung pada *real-time*. *Next.js* juga memiliki pilihan komponen yang luas seperti *react-leaflet* yang digunakan untuk menampilkan peta pada sistem *WebGIS* yang dibangun.

Leaflet.js dipilih sebagai *library* untuk menampilkan peta pada sistem yang dibangun dikarenakan ringan, *open-source*, dan mendukung penambahan *layer data geospasial* termasuk *GeoJSON* untuk menampilkan 2 layer peta pada model yang dibangun. *Leaflet.js* juga mendukung integrasi basemap *OpenStreetMap* secara gratis.

Supabase PostgreSQL dipilih sebagai *database* karena menyediakan layanan *PostgreSQL* yang dapat diakses secara *real-time* melalui *API* bawaan tanpa perlu membangun infrastruktur *server database* data sendiri seperti menggunakan layanan *hosting*.

3.3.2 Use Case Diagram

Use Case Diagram merupakan diagram yang menggambarkan fungsi-fungsi utama sistem dan interaksi antara aktor dengan sistem yang dibangun. Diagram ini memperjelas batasan peran dan fungsi setiap aktor, serta layanan yang disediakan sistem kepada penggunanya. Gambar 3.3 menunjukkan rancangan *use case diagram* sistem klasifikasi daerah rawan banjir Kota Langsa.



Gambar 3.3 Use-Case Diagram

Sistem melibatkan dua aktor, yaitu *Admin* dan *User*. *Admin* merupakan aktor dengan hak akses penuh yang wajib melakukan *login* melalui *Supabase Auth* untuk dapat mengelola data *GIS* dan memantau evaluasi performa model. *User* merupakan aktor yang mewakili masyarakat umum atau pemangku kebijakan; *login* bersifat opsional bagi *User*, karena baik yang *login* maupun tidak, *User* memiliki

akses yang sama terhadap fitur visualisasi peta, visualisasi statistik, dan pencarian lokasi. Tabel 3.6 merangkum deskripsi kedua aktor tersebut.

Tabel 3.6 Deskripsi Aktor

Nama Aktor	Deskripsi
<i>Admin</i>	<i>Admin</i> merupakan aktor yang memiliki hak akses penuh terhadap seluruh fitur sistem. <i>Admin</i> wajib melakukan <i>login</i> /autentikasi terlebih dahulu untuk dapat mengelola data <i>GIS</i> di basis data <i>Supabase</i> (CRUD pada tabel <i>flood_points</i> , <i>desa_klasifikasi</i> , dan <i>kecamatan_stats</i>), serta memantau hasil evaluasi performa model klasifikasi.
<i>User</i>	<i>User</i> merupakan aktor yang mewakili masyarakat umum atau pemangku kebijakan. <i>Login</i> bersifat opsional bagi <i>User</i> — baik yang sudah <i>login</i> maupun tidak, <i>User</i> memiliki akses yang sama terhadap fitur visualisasi peta kerawanan banjir, visualisasi statistik per kecamatan, dan pencarian lokasi desa/kelurahan.

Sistem memiliki tujuh *use case* utama. *Use case Login/Autentikasi* wajib digunakan *Admin* untuk mengakses fitur pengelolaan data dan evaluasi model, dan bersifat opsional bagi *User*. *Use case Menampilkan Halaman Dashboard*, *Menampilkan Visualisasi Peta*, *Menampilkan Visualisasi Statistik*, dan *Mencari Lokasi Rawan Banjir* dapat diakses oleh *Admin* dan *User*. *Use case Mengelola Data GIS* dan *Menampilkan Evaluasi Performa Model* hanya dapat diakses oleh *Admin* setelah *login*. Tabel 3.7 menjelaskan ketujuh *use case* tersebut secara rinci.

Tabel 3.7 Deskripsi *Use Case*

No	Use Case	Deskripsi
1	Login/Autentikasi	<i>Admin</i> wajib melakukan <i>login</i> menggunakan <i>email</i> dan <i>password</i> melalui <i>Supabase Auth</i> sebelum dapat mengakses fitur pengelolaan data dan evaluasi model. <i>User</i> dapat melakukan <i>login</i> secara opsional; tanpa <i>login</i> , <i>User</i> tetap dapat mengakses fitur publik (visualisasi peta, statistik, dan pencarian).
2	Menampilkan halaman <i>Dashboard</i>	<i>Admin</i> dan <i>User</i> dapat mengakses halaman <i>dashboard</i> sebagai halaman utama sistem yang menampilkan ringkasan statistik kerawanan banjir Kota Langsa, jumlah desa per kelas kerawanan, peta mini interaktif sebagai pratinjau, dan menu navigasi ke seluruh fitur sistem.
3	Mengelola data <i>GIS</i>	<i>Admin</i> dapat melakukan operasi CRUD (<i>Create, Read, Update, Delete</i>) terhadap data spasial pada tabel <i>flood_points</i> , <i>desa_klasifikasi</i> , dan <i>kecamatan_stats</i> di basis data <i>Supabase</i> . Fitur ini hanya dapat diakses setelah <i>Admin login</i> .
4	Menampilkan visualisasi peta daerah rawan banjir	<i>Admin</i> dan <i>User</i> dapat menampilkan peta <i>choropleth</i> interaktif berbasis <i>Leaflet.js</i> yang menunjukkan tingkat kerawanan banjir per desa/kelurahan, dengan interaksi <i>zoom</i> , <i>pan</i> , dan klik pada poligon desa untuk menampilkan <i>popup</i> informasi detail beserta nilai 10 variabel geospasial.
5	Menampilkan visualisasi statistik daerah rawan banjir	<i>Admin</i> dan <i>User</i> dapat menampilkan informasi statistik hasil klasifikasi dalam bentuk grafik batang dan tabel ringkasan yang menunjukkan distribusi jumlah desa/kelurahan berdasarkan kelas kerawanan per kecamatan, diambil secara <i>real-time</i> dari tabel <i>kecamatan_stats</i> .
6	Mencari lokasi rawan banjir	<i>Admin</i> dan <i>User</i> dapat mencari desa/kelurahan tertentu berdasarkan nama melalui kotak pencarian. Sistem melakukan kueri ke tabel <i>desa_klasifikasi</i> dan menampilkan hasil pencarian, kemudian memindahkan tampilan peta ke lokasi yang dicari beserta <i>popup</i> informasi tingkat kerawanan.
7	Menampilkan evaluasi performa model	<i>Admin</i> dapat memantau hasil evaluasi performa kedua model, meliputi metrik akurasi, <i>F1-Score</i> , <i>AUC-ROC</i> , <i>Cohen's Kappa</i> , dan <i>MCC</i> , disertai visualisasi <i>confusion matrix</i> , kurva ROC, grafik

No	Use Case	Deskripsi
		<i>feature importance</i> dari 10 variabel geospasial, serta matriks pembandingan per desa terhadap data historis banjir aktual. Fitur ini hanya dapat diakses oleh <i>Admin</i> setelah <i>login</i> .


3.3.3 Activity Diagram

Activity Diagram merupakan diagram yang menggambarkan alur aktivitas dan urutan proses yang terjadi di dalam sistem dari kondisi awal hingga kondisi akhir setiap proses. Diagram ini memvisualisasikan langkah-langkah yang dilakukan setiap aktor dalam berinteraksi dengan sistem secara terperinci, termasuk titik-titik keputusan yang menentukan alur mana yang akan dijalankan sistem berdasarkan kondisi tertentu.

Ketujuh *activity diagram* pada penelitian ini merepresentasikan tujuh fungsi utama sistem sesuai dengan *use case* yang telah dirancang sebelumnya, yaitu *Login*, Halaman *Dashboard*, Kelola Data *GIS*, Visualisasi Peta Daerah Rawan Banjir, Visualisasi Statistik Daerah Rawan Banjir, Pencarian Lokasi Rawan Banjir, dan Menampilkan Evaluasi Model. Jika *use case diagram* hanya menggambarkan fungsi apa saja yang tersedia bagi tiap aktor secara garis besar, *activity diagram* menguraikan fungsi tersebut menjadi langkah-langkah proses yang lebih rinci dan berurutan. Notasi yang digunakan pada setiap diagram mencakup *initial node* sebagai titik awal proses, serangkaian *action node* yang menggambarkan aktivitas yang dilakukan sistem maupun aktor, *decision node* untuk menggambarkan titik percabangan alur, serta *final node* sebagai titik akhir proses.

1. Activity Diagram halaman Login

Gambar 3.4 menunjukkan alur aktivitas proses autentikasi ke dalam sistem.




Gambar 3. 4 Acitivity Diagram Login

Proses dimulai saat aktor membuka halaman *login* dan memasukkan kredensial berupa *email* dan *password*. Sistem mengirimkan permintaan autentikasi ke *Supabase Auth* untuk diverifikasi. Apabila kredensial valid, sistem menghasilkan *session token* dan mengarahkan aktor ke halaman *dashboard* sesuai peran yang dimiliki, *Admin* mendapat akses penuh, sedangkan *User* mendapat akses yang lebih terbatas dibanding *Admin*. Apabila kredensial tidak valid, sistem menampilkan

pesan kesalahan dan meminta aktor memasukkan ulang kredensialnya. Bagi *User* yang tidak ingin *login*, sistem menyediakan opsi untuk langsung mengakses fitur publik tanpa melalui proses autentikasi.

2. Activity Diagram halaman Dashboard

Gambar 3.5 menunjukkan alur aktivitas ketika aktor mengakses halaman *dashboard*.




Gambar 3.5 Activity Diagram Halaman Dashboard

Proses dimulai saat aktor membuka situs, kemudian sistem menampilkan halaman *dashboard* sebagai halaman utama. Halaman ini menampilkan ringkasan informasi daerah rawan banjir serta menu navigasi menuju fitur lain, seperti visualisasi peta, statistik, pencarian lokasi, dan evaluasi model.

3. Activity Diagram kelola data GIS

Gambar 3.6 menunjukkan alur aktivitas *Admin* dalam mengelola data spasial.




Gambar 3.6 Activity Diagram kelola data GIS

Proses dimulai ketika *Admin* memilih menu Kelola Data GIS, kemudian sistem menampilkan data titik sampel dan data desa yang tersimpan di basis data dalam bentuk tabel yang dapat ditelusuri. *Admin* dapat menelusuri data tersebut, serta menguji model klasifikasi secara manual melalui fitur Prediksi Manual dengan

memasukkan nilai 10 variabel geospasial. Sistem kemudian mengembalikan hasil klasifikasi dari model *Random Forest* yang telah dilatih.

4. *Activity Diagram* Visualisasi Peta daerah Rawan Banjir

Gambar 3.7 menunjukkan alur aktivitas dalam menampilkan hasil klasifikasi dalam bentuk peta.




Gambar 3.7 *Activity Diagram* Visualisasi Peta daerah Rawan Banjir

Proses dimulai ketika aktor memilih menu visualisasi peta, kemudian sistem mengambil data hasil klasifikasi daerah rawan banjir dan menampilkannya dalam bentuk peta tematik berbasis *GIS* yang menunjukkan tingkat kerawanan banjir di wilayah Kota Langsa.

5. *Activity Diagram* Visualisasi Statistik daerah Rawan Banjir

Gambar 3.8 menunjukkan alur aktivitas dalam menyajikan informasi statistik hasil klasifikasi.




Gambar 3.8 *Activity Diagram* Visualisasi Statistik daerah Rawan Banjir

Proses dimulai ketika aktor memilih menu visualisasi statistik, kemudian sistem mengolah data hasil klasifikasi untuk ditampilkan dalam bentuk grafik dan tabel, memberikan gambaran jumlah dan distribusi wilayah berdasarkan tingkat kerawanan banjir per kecamatan.

6. *Activity Diagram* Cari daerah Rawan Banjir

Gambar 3.9 menunjukkan alur aktivitas ketika aktor melakukan pencarian lokasi.




Gambar 3.9 Activity Diagram Cari daerah Rawan Banjir

Proses dimulai saat aktor memasukkan nama desa/kelurahan pada kotak pencarian, kemudian sistem memproses permintaan tersebut dan menampilkan informasi tingkat kerawanan banjir pada lokasi yang dicari berdasarkan hasil klasifikasi yang tersedia.

7. Activity Diagram menampilkan Evaluasi Model

Gambar 3.10 menunjukkan alur aktivitas *Admin* dalam melihat performa model klasifikasi.



Gambar 3.10 Activity Diagram menampilkan Evaluasi Model


Proses dimulai ketika *Admin* memilih menu evaluasi model, kemudian sistem menampilkan hasil evaluasi performa algoritma *Random Forest* dalam bentuk metrik kinerja, *confusion matrix*, dan grafik *feature importance*, untuk mengetahui tingkat keberhasilan model dalam mengklasifikasikan daerah rawan banjir.

3.3.4 Wireframe Antarmuka Sistem

Wireframe antarmuka merupakan representasi visual sistem yang menjadi penghubung antara pengguna dengan fitur-fitur yang tersedia. *Wireframe* dirancang dengan navigasi yang jelas dan tata letak (*layout*) yang mudah dipahami, sehingga pengguna dapat mengakses informasi yang disediakan tanpa memerlukan pelatihan khusus. Pada penelitian ini terdapat 4 halaman yang dirancang *wireframe*-nya, yaitu Halaman *Dashboard*, Visualisasi Peta, Visualisasi Statistik, dan Evaluasi Model.

1. Halaman Dashboard

Gambar 3.11 menunjukkan rancangan tata letak halaman *dashboard*.




Gambar 3.11 *Wireframe* Halaman

Halaman *dashboard* merupakan tampilan awal sistem yang berfungsi sebagai pusat navigasi utama ketika aktor pertama kali mengakses sistem. Tata letak halaman terdiri dari *navbar* di bagian atas yang memuat logo sistem dan menu utama, area kartu statistik (*card*) di tengah yang menampilkan ringkasan jumlah

desa per kelas kerawanan untuk setiap kecamatan secara *real-time*, serta tombol navigasi cepat menuju fitur visualisasi peta, statistik, dan pencarian lokasi. *User* dapat melihat ringkasan informasi umum dan mengakses menu navigasi yang tersedia, sedangkan *Admin* dapat mengakses menu tambahan berupa pengelolaan data *GIS* dan evaluasi performa model yang hanya muncul setelah *login* berhasil.

2. Halaman Visualisasi Peta Daerah Rawan Banjir

Gambar 3.12 menunjukkan rancangan tata letak halaman visualisasi peta.




Gambar 3.12 *Wireframe* Halaman Visualisasi Peta Daerah Rawan Banjir

Halaman ini menampilkan hasil klasifikasi Model A dan Model B melalui tab yang dapat dipilih pengguna. Tata letak halaman terdiri dari *navbar* di bagian atas, area peta utama (*full-width*) yang dirender menggunakan *Leaflet.js* dengan *basemap OpenStreetMap*, panel legenda di sudut kanan bawah, serta kontrol *layer* di sudut kanan atas untuk mengaktifkan atau menonaktifkan *layer* tertentu. Pada tab Model A, peta menampilkan *choropleth* per desa/kelurahan dengan gradasi warna sesuai kelas kerawanan, sedangkan pada tab Model B, peta menampilkan

sebaran 1.500 titik sampel dengan simbol warna sesuai status kerawanan. Pengguna dapat berinteraksi dengan peta melalui *zoom*, *pan*, dan klik pada poligon desa atau titik sampel untuk menampilkan *popup* informasi yang memuat nilai 10 variabel geospasial lokasi tersebut.

3. Halaman visualisasi statistik daerah rawan banjir

Gambar 3.13 menunjukkan rancangan tata letak halaman visualisasi statistik.




Gambar 3. 13 *Wireframe* Halaman Visualisai Statistik Derah Rwan Banjir

Halaman ini menyajikan informasi statistik hasil klasifikasi Model A dan Model B melalui tab yang dapat dipilih pengguna. Tata letak halaman terdiri dari *navbar* di bagian atas, grafik batang (*bar chart*) interaktif di bagian tengah yang menampilkan distribusi kerawanan per kecamatan, serta tabel ringkasan di bagian bawah. Pengguna dapat membandingkan tingkat kerawanan antar kecamatan secara visual, serta mengetahui jumlah dan persentase desa/kelurahan atau titik sampel berdasarkan tingkat kerawanan pada setiap kecamatan.

4. Halaman informasi hasil evaluasi model

Gambar 3.14 menunjukkan rancangan tata letak halaman evaluasi model.



Gambar 3.14 *Wireframe* Halaman Evaluasi Model

Halaman ini hanya dapat diakses oleh *Admin* setelah *login*, dan menampilkan hasil evaluasi kinerja Model A dan Model B melalui tab yang dapat dipilih. Tata letak halaman terdiri dari *navbar* di bagian atas dengan indikator sesi *Admin*, kartu metrik evaluasi di bagian atas yang menampilkan nilai akurasi, *F1-Score*, *Cohen's Kappa*, dan *MCC* (ditambah *AUC-ROC* untuk Model B), visualisasi *confusion matrix* di bagian tengah, grafik *feature importance* dari 10 variabel geospasial di bagian kanan, serta tabel matriks pembandingan per desa pada tab Model A yang membandingkan hasil klasifikasi terhadap data historis banjir aktual.

3.4 Data dan Pengumpulan Data

Penelitian ini dilakukan di Kota Langsa, Provinsi Aceh, yang merupakan salah satu kota di wilayah pesisir timur Aceh. Secara geografis, Kota Langsa

terletak pada koordinat $04^{\circ}24'35,68''$ – $04^{\circ}33'47,03''$ Lintang Utara dan $97^{\circ}53'14,59''$ – $98^{\circ}04'42,16''$ Bujur Timur, dengan batas administrasi sebelah Utara berbatasan dengan Kabupaten Aceh Timur dan Selat Malaka, sebelah Selatan dengan Kabupaten Aceh Timur dan Kabupaten Aceh Tamiang, sebelah Barat dengan Kabupaten Aceh Timur, dan sebelah Timur dengan Kabupaten Aceh Tamiang. Luas wilayah administratif Kota Langsa adalah 23.982,93 ha (239,83 km²). Secara administratif, Kota Langsa terbagi menjadi 5 kecamatan dengan 66 desa/kelurahan yang menjadi unit analisis dalam penelitian ini. Rincian wilayah administrasi Kota Langsa disajikan pada Tabel 3.12.

Kondisi topografi Kota Langsa didominasi oleh dataran rendah dengan elevasi berkisar antara -1,31 meter hingga 104,77 meter di atas permukaan laut. Berdasarkan hasil pengolahan *DEM* Nasional (*DEMNAS*) dari BIG, sebagian besar wilayah Kota Langsa berada pada elevasi 0–10 meter dpl, terutama di Kecamatan Langsa Timur dan Langsa Barat yang berbatasan langsung dengan kawasan pesisir dan muara Krueng Langsa. Kemiringan lereng wilayah ini sangat landai ($0-3^{\circ}$) di kawasan timur dan tengah, dengan kemiringan lebih curam hanya ditemukan di bagian barat daya Kecamatan Langsa Baro yang berbatasan dengan kawasan perbukitan.

Tabel 3.8 Wilayah Administrasi Kota Langsa

No	Kecamatan	Jumlah Desa	Luas Wilayah(km ²)
1	Langsa Barat	13 desa	48,78
2	Langsa Baro	12 desa	61,69
3	Langsa Kota	10 desa	6,11
4	Langsa Lama	15 desa	45,02
5	Langsa Timur	16 desa	78,23
Total Desa :		66 desa	239,83

Metode pengumpulan data pada penelitian ini dilakukan melewati beberapa tahapan yang disajikan pada Tabel 3.13.

Tabel 3.9 Metode Pengumpulan Data

No	Metode	Deskripsi
1	Studi Literatur	Pengumpulan data dilakukan dengan mengkaji jurnal ilmiah, prosiding, dan laporan penelitian yang berkaitan dengan pemetaan dan klasifikasi daerah rawan banjir berbasis <i>GIS</i> dan <i>Machine Learning</i> sebagai dasar teori dan penentuan variabel penelitian.
2	Pengumpulan Data Spasial Sekunder	Pengumpulan data spasial berupa <i>DEM</i> , penggunaan lahan, curah hujan, jenis tanah, dan jaringan sungai yang diperoleh dari instansi resmi dalam bentuk data digital.
3	Observasi dan Verifikasi Data	Observasi dilakukan secara terbatas untuk memastikan kesesuaian data spasial dengan kondisi wilayah penelitian, serta verifikasi atribut dan sistem koordinat data.

3.4.1 Jenis dan Sumber Data


Data yang digunakan pada penelitian ini merupakan data sekunder yang bersumber dari instansi resmi pemerintah dan lembaga internasional. sebagaimana disajikan pada Tabel 3.10.

Tabel 3.10 Jenis dan Sumber Data

No	Jenis Data	Sumber	Format
1	<i>DEM</i> Nasional (DEMNAS)	BIG	<i>Raster</i>
2	Jaringan Sungai	BIG	<i>Vektor</i>
3	Jaringan Jalan	BIG	<i>Vektor</i>
4	Batas Administrasi	BIG	<i>Vektor</i>
5	Tutupan Lahan	<i>ESA WorlCover</i>	<i>Raster</i>
6	Jenis Tanah	<i>FAO DSMW</i>	<i>Vektor</i>
7	Curah Hujan	<i>UCSB CHIRPS</i>	<i>Raster</i>
8	Peta Banjir Historis Langsa 31 Januari 2026	BIG-BNPB	<i>Vektor</i>

3.4.2 Pengambilan Data Spasial GIS

Tahap pengambilan data merupakan tahapan mengumpulkan data-data dari berbagai sumber yang nantinya di gunakan pada penelitian ini. Gambar 3.15 menampilkan alur pengambilan data spasial yang dilakukan pada penelitian ini.




Gambar 3.15 Flowchart Pengambilan Data Spasial GIS

Bedasarkan Gambar 3.15, setelah semua data yang dibutuhkan kemudian diunduh dari sumber yang telah ditentukan dalam format digital seperti *shapefile* untuk data spasial dengan jenis *vector* dan *GeoTIFF* untuk format data spasial dengan jenis *raster*. Data kemudian verifikasi dengan cara pemeriksaan pada tampilan visual dan pada atribut menggunakan *software* QGIS untuk memastikan data yang akan digunakan sesuai sebelum masuk ke tahap *preprocessing*.

3.4.3 *Preprocessing Data Spasial*

Preprocessing data spasial dilakukan untuk mempersiapkan dan menyesuaikan seluruh data dari berbagai sumber agar siap digunakan dalam proese klasifikasi, Gambar 3.16 menggambarkan alur *preprocessing* data spasial pada pannelitian ini.




Gambar 3.16 *Flowchart Preprocessing Data*

Berdasarkan Gambar 3.16, *preprocessing* terdiri dari beberapa tahapan.

Setiap tahapan akan dijelaskan secara lebih rinci pada bagian berikutnya.

1. Proses Penyamaan Sistem Koordinat


Gambar 3.17 menunjukkan alur penyamaan sistem koordinat pada seluruh data spasial yang digunakan. Seluruh data spasial direproyeksi ke sistem koordinat *EPSG:32647 (WGS 84 / UTM Zone 47N)* menggunakan fungsi *Reproject Layer* pada *QGIS*, sehingga seluruh data berada pada sistem koordinat yang seragam sebelum masuk ke tahap selanjutnya.



Gambar 3.17 Flowchart proses Penyamaan Sistem Koordinat

2. Proses Clipping Data


Gambar 3.18 menunjukkan alur proses *clipping* data spasial. Proses diawali dengan mengekstrak batas administrasi Kota Langsa dari peta administrasi Indonesia menggunakan fungsi *Filter by Expression* pada *QGIS*. Batas Kota Langsa yang diperoleh kemudian digunakan sebagai acuan untuk memotong seluruh data spasial melalui fungsi *Clip*, sehingga data yang diproses pada tahap selanjutnya hanya mencakup wilayah Kota Langsa.



Gambar 3.18 Flowchart proses *Clipping Data*

3. Proses *Resampling Data*


Gambar 3.19 menunjukkan alur proses *resampling* data spasial. Seluruh data *raster* diseragamkan ke resolusi 30×30 meter menggunakan fungsi *Warp (Reproject)* dengan metode *Bilinear* pada QGIS, sehingga seluruh data memiliki ukuran piksel yang sama sebelum masuk ke tahap berikutnya.



Gambar 3. 19 Flowchart proses *Resampling Data*

4. Proses Penyesuaian Format Data

Gambar 3.20 menunjukkan alur penyesuaian format data spasial. Data vektor dikonversi ke format *shapefile* menggunakan fungsi *Save As* pada QGIS, sedangkan data *raster* dikonversi ke format GeoTIFF menggunakan fungsi *Translate (Convert Format)*, sehingga seluruh data memiliki format standar yang seragam untuk tahap pengolahan selanjutnya.




Gambar 3.20 Flowchart Proses Penyamaan Format Data

5. Flowchart proses Derivasi DEM

a. Slope

Gambar 3.23 menunjukkan alur derivasi lima variabel topografi dari data DEM.




Gambar 3.21 *Flowchart* Proses Derivasi DEM

Dari satu sumber data DEMNAS, diturunkan lima variabel sekaligus menggunakan *QGIS*. Elevasi diekstraksi langsung sebagai representasi ketinggian permukaan. *Slope* dihitung dalam satuan derajat menggunakan fungsi *Slope* pada *QGIS*. *TWI* dihitung menggunakan algoritma *SAGA Wetness Index* nilai *TWI* yang tinggi menunjukkan potensi akumulasi air yang besar. *Plan curvature* mengukur kelengkungan horizontal permukaan, dengan nilai positif menunjukkan zona konvergensi aliran dan nilai negatif menunjukkan zona divergensi. *HAND* mengukur ketinggian vertikal suatu titik terhadap saluran drainase terdekat; selain menjadi variabel prediktor, *HAND* juga menjadi kriteria pembentukan label *ground*

truth, di mana titik dengan nilai *HAND* kurang dari 1 meter yang berada di area terdampak banjir 31 Januari 2026 dikategorikan sebagai titik rawan banjir.

6. *Flowchart* proses reklasifikasi data penggunaan lahan



Gambar 3. 22 *Flowchart* Proses Reklasifikasi Variabel Penggunaan Lahan


Data penggunaan lahan bersumber dari *ESA WorldCover* 2021 dengan resolusi asli 10 meter, yang telah di-*resample* ke 30 meter dan di-*clip* ke batas Kota

Langsa. Setiap kelas tutupan lahan diberikan skor kerentanan banjir secara ordinal pada skala 1–5, karena skor ordinal mencerminkan urutan tingkat impermeabilitas permukaan sehingga lebih sesuai untuk model *Random Forest* dibandingkan *one-hot encoding*. Pada penelitian ini terdapat 5 kelas penggunaan lahan yang direklasifikasi, sebagaimana dirangkum pada Tabel 3.15.

Tabel 3.11 Skor Reklasifikasi Penggunaan Lahan (*LULC*)

Kelas <i>ESA WorldCover</i>	Kode	Skor
<i>Tree Cover</i> (Tutupan Pohon)	10	1
<i>Cropland</i> (Lahan Pertanian)	40	3
<i>Built-up</i> (Lahan Terbangun)	50	4
<i>Permanent Water Bodies</i>	80	5
<i>Mangroves</i>	95	5

7. Flowchart Proses Reklasifikasi Skor Jenis Tanah dan Curah Hujan




Gambar 3.23 Flowchart Reklasifikasi Jenis Tanah, Curah Hujan

Data jenis tanah bersumber dari *FAO DSMW* yang mencakup dua unit tanah di Kota Langsa. Fluvisols mendapat skor 5 karena merupakan tanah aluvial pesisir dengan kapasitas infiltrasi rendah, sedangkan Acrisols mendapat skor 3 karena merupakan tanah merah podsolik dengan kapasitas infiltrasi yang lebih baik. Data curah hujan bersumber dari *CHIRPS v2.0* yang diproses melalui penggabungan 120 *file raster* bulanan periode 2016–2025, kemudian direklasifikasi ke skor 1–5 dengan rentang: kurang dari 1.000 mm = skor 1, 1.000–1.500 mm = skor 2, 1.500–2.000 mm = skor 3, 2.000–2.500 mm = skor 4, dan lebih dari 2.500 mm = skor 5.

Nilai curah hujan rata-rata di Kota Langsa sebesar 2.211–2.503 mm/tahun menghasilkan skor dominan 4 di seluruh wilayah kota.

8. Flowchart pembuatan Proximity Raster Jarak Sungai dan Jarak Jalan

Gambar 3.26 menunjukkan alur pembuatan *proximity raster* untuk variabel jarak.




Gambar 3. 24 Flowchart Pembuatan Proximity Raster

Proximity raster dibuat untuk dua variabel jarak, yaitu jarak terhadap jaringan sungai dan jarak terhadap jaringan jalan. Metode ini dipilih dibandingkan *Multiple Ring Buffer* karena menghasilkan nilai jarak kontinu dalam satuan meter untuk setiap piksel 30 meter, sehingga lebih kaya informasi untuk model *Machine Learning* dibandingkan nilai kategoris diskrit dari *Multiple Ring Buffer*. Fungsi

Proximity (Raster Distance) pada *QGIS* menghitung jarak *Euclidean* dari setiap piksel ke objek vektor terdekat, menghasilkan dua *file* GeoTIFF resolusi 30 meter.

9. *Flowchart* verifikasi visual data

Gambar 3.27 menunjukkan tahap verifikasi akhir hasil *preprocessing* data spasial.




Gambar 3.25 *Flowchart* Proses Verifikasi Visual Data

Tahap ini memastikan seluruh data telah memenuhi kebutuhan analisis melalui keputusan Ya atau Tidak. Jika data belum sesuai, proses kembali ke tahap

preprocessing untuk diperbaiki; jika sudah sesuai, data dinyatakan siap dan dilanjutkan ke tahap pembentukan *dataset*.

3.4.4 Penggabungan Data

Penggabungan data dilakukan setelah seluruh 10 variabel geospasial menyelesaikan tahap *preprocessing*, dengan tujuan mengekstraksi nilai setiap parameter *raster* ke unit analisis yang digunakan, sehingga setiap unit memiliki atribut lengkap dari 10 variabel yang siap digunakan dalam proses klasifikasi. Penggabungan data pada penelitian ini menghasilkan dua *dataset* yang berbeda sesuai dengan dua model yang dibangun. Gambar 3.28 menggambarkan alur proses penggabungan data.



Gambar 3.26 Flowchart Proses Penggabungan Data

Proses dimulai dengan *input* 10 *file raster* hasil *preprocessing* yang telah memiliki sistem koordinat EPSG:32647, resolusi 30 meter, dan cakupan wilayah Kota Langsa yang seragam, dilanjutkan dengan pengecekan kesesuaian resolusi dan *grid* agar seluruh data dapat diekstraksi pada lokasi yang sama.

Untuk Model A, ekstraksi nilai dilakukan menggunakan operasi *Zonal Statistics* pada *QGIS* terhadap 66 poligon desa/kelurahan Kota Langsa, menggunakan statistik *mean* untuk variabel kontinu (*DEM*, *Slope*, *TWI*, *Curvature*, Jarak Sungai, Jarak Jalan, *HAND*) dan statistik *majority* untuk variabel kategorikal (*LULC* Skor, Jenis Tanah, Curah Hujan), menghasilkan *file* DATASET_66_DESA.csv dengan 66 baris dan 10 kolom fitur. Untuk Model B, ekstraksi nilai dilakukan menggunakan operasi *Sample Raster Values* pada *QGIS* 3.40.14 terhadap 1.500 titik sampel yang telah disiapkan, di mana setiap titik menerima nilai dari 10 *raster* parameter sekaligus dalam satu proses, menghasilkan *file* DATASET_1500_TITIK.csv dengan 1.500 baris dan 10 kolom fitur.

Perbedaan metode ekstraksi nilai antara Model A (*Zonal Statistics*) dan Model B (*Sample Raster Values*) menyebabkan nilai variabel yang sama dapat berbeda secara numerik meskipun bersumber dari raster yang identik. Hal ini merupakan konsekuensi dari perbedaan teknik analisis kedua model dan bukan merupakan inkonsistensi data.

Pada Model A, nilai setiap variabel merupakan nilai agregat yang mewakili seluruh poligon desa, contoh nilai elevasi (*DEM*) suatu desa adalah rata-rata dari seluruh piksel *raster* yang berada didalam batas desa tersebut. Desa dengan wilayah


luas yang mencakup area dataran rendah sekaligus perbukitan akan memiliki nilai *DEM* rata-rata yang berada di antara keduanya.

Pada Model B nilai pada setiap variabel merupakan nilai pasti (*exact value*) pada koordinat titik sampel tersebut, diambil langsung dari piksel *raster* pada data spasial. Titik yang berada di kawasan dataran rendah dan titik yang berada pada kawasan dataran tinggi pada desa yang sama akan memiliki nilai elevasi (*DEM*) yang berbeda. Hal ini menyebabkan rentang nilai pada model B lebih bervariasi dibandingkan Model A yang mengambil nilai rata-rata (*mean*) dari piksel *raster* suatu wilayah di data spasial.

Perbedaan ini nantinya akan berpengaruh pada *feature importance* yang dihasilkan setelah kedua model dibangun, dan akan merepresentasikan kemampuan diskriminasi pada 10 variabel yang berbeda dari setiap model.

3.4.5 Pembentukan Dataset

Pembentukan *dataset* merupakan tahap lanjutan setelah seluruh data spasial melalui *preprocessing* dan penggabungan data. Pada tahap ini, kedua *dataset* hasil penggabungan (66 desa untuk Model A dan 1.500 titik untuk Model B) dibagi menjadi data latih (*training data*) dan data uji (*testing data*) menggunakan teknik *stratified split*, sehingga proporsi kelas Rawan dan Tidak Rawan tetap seimbang baik pada data latih maupun data uji. Gambar 3.29 menggambarkan alur proses pembentukan *dataset*.



Gambar 3.27 Flowchart proses pembentukan dataset

Untuk Model A, pembagian data dilakukan pada dua skema klasifikasi. Pada skema biner, 66 desa dibagi menjadi 52 data latih dan 14 data uji. Pada skema 3 kelas (Tidak Rawan, Rawan, Sangat Rawan), 66 desa dibagi menjadi 46 data latih dan 20 data uji, dengan pencarian nilai *random state* yang disesuaikan agar ketiga kelas tetap muncul pada data uji, mengingat jumlah sampel pada skema ini tergolong kecil. Untuk Model B, 1.500 titik sampel dibagi menjadi 1.200 data latih dan 300 data uji dengan rasio 80:20. Pada kedua model, parameter `class_weight='balanced'` diterapkan saat pelatihan untuk mengatasi ketidakseimbangan jumlah sampel antar kelas Rawan dan Tidak Rawan.

Data latih digunakan untuk melatih algoritma *Random Forest* agar dapat mempelajari pola hubungan antar variabel penyebab banjir, sedangkan data uji digunakan untuk mengevaluasi kemampuan model dalam mengklasifikasikan data yang belum pernah dipelajari sebelumnya.

3.5 Perancangan Metode

Perancangan metode pada penelitian ini menjelaskan pendekatan pengembangan sistem yang dipilih beserta algoritma klasifikasi yang diterapkan pada kedua model yang dibangun.

3.5.1 Model Klasifikasi A dan Model Klasifikasi B

Penelitian ini membangun dua model klasifikasi dengan unit analisis dan skema klasifikasi yang berbeda, untuk memberikan perbandingan sekaligus melihat pengaruh tingkat perincian data terhadap hasil klasifikasi kerawanan banjir.

Pemilihan dua unit analisis yang berbeda pada penelitian dikarenakan pada dua pendekatan yang sering digunakan dalam penelitian klasifikasi daerah rawan banjir. Pendekatan dengan basis unit administratif seperti per desa atau kelurahan yang digunakan oleh pihak yang memiliki otoritas seperti BNPB. Pendekatan berbasis titik sampel yang memungkinkan representasi kondisi fisik yang lebih detail karena nilai variabel diambil langsung dari titik tersebut.

1. Model Klasifikasi A

Model A menggunakan unit analisis 66 desa/kelurahan Kota Langsa, dengan nilai variabel diperoleh melalui agregasi *Zonal Statistics* pada tiap poligon desa. Model A dibangun dalam dua varian skema klasifikasi. Varian pertama adalah

klasifikasi biner (Tidak Rawan/Rawan), berdasarkan persentase luas area terdampak banjir per desa. Varian kedua adalah klasifikasi 3 kelas (Tidak Rawan/Rawan/Sangat Rawan), mengacu pada Peraturan Kepala BNPB Nomor 2 Tahun 2012 yang mengklasifikasikan bahaya banjir ke dalam tiga tingkatan. Kedua varian ini dibangun untuk melihat apakah pembagian tingkat kerawanan yang lebih rinci dapat memberikan informasi yang lebih bermanfaat dibandingkan klasifikasi Rawan/Tidak Rawan saja, mengingat unit analisis desa memungkinkan variasi nilai persentase area terdampak yang cukup beragam untuk dipecah menjadi beberapa kategori.

Penentuan ambang batas $pct_banjir \geq 30\%$ sebagai kriteria label Rawan mengacu pada klasifikasi bahaya banjir dalam Peraturan Kepala BNPB Nomor 2 Tahun 2012, yang membagi kelas bahaya berdasarkan persentase luas wilayah terdampak. Ambang batas 30% dipilih sebagai titik pemisah yang memastikan desa-desa dengan porsi area terdampak yang nyata terklasifikasi sebagai Rawan, konsisten dengan spirit klasifikasi berbasis luas terdampak yang ditetapkan BNPB.

2. Model Klasifikasi B

Model B menggunakan unit analisis 1.500 titik sampel yang tersebar merata di seluruh wilayah Kota Langsa, dengan nilai variabel diperoleh langsung pada koordinat tiap titik melalui *Sample Raster Values*. Berbeda dengan Model A, Model B hanya dibangun dengan satu skema klasifikasi biner (Tidak Rawan/Rawan). Hal ini karena label *ground truth* Model B ditentukan dari kombinasi dua kondisi biner (titik berada di dalam area terdampak banjir aktual dan nilai *HAND* kurang dari 1 meter), Penggunaan ambang batas *HAND* kurang dari 1 meter sebagai salah satu

kriteria label Rawan didasarkan pada karakteristik fisik variabel HAND itu sendiri titik dengan nilai HAND sangat rendah berada sangat dekat dengan permukaan saluran drainase secara vertikal, sehingga memiliki kerentanan tinggi terhadap genangan ketika debit sungai meningkat. Kombinasi dua kriteria ($HAND < 1$ meter dan berada dalam area terdampak banjir aktual kejadian 31 Januari 2026) diterapkan untuk memastikan label Rawan hanya diberikan pada titik yang memenuhi syarat fisik sekaligus terbukti secara empiris pernah terdampak, sehingga mengurangi risiko pemberian label berdasarkan satu kejadian yang tidak representatif pada skala titik yang sangat detail.

Secara keseluruhan, penelitian ini membangun tiga model klasifikasi Model A biner, Model A 3 kelas, dan Model B dengan kombinasi unit analisis (desa/kelurahan dan titik sampel) serta skema klasifikasi (biner dan 3 kelas) yang berbeda. Pembangunan ketiga model ini dimaksudkan agar diperoleh perbandingan performa algoritma *Random Forest* yang dapat diukur secara objektif pada berbagai konfigurasi unit analisis dan skema klasifikasi, sehingga dapat diketahui pengaruh tingkat perincian data (desa dibandingkan titik) maupun jumlah kelas target (biner dibandingkan 3 kelas) terhadap kemampuan model dalam mengklasifikasikan daerah rawan banjir. Model B selanjutnya diintegrasikan ke dalam sistem *WebGIS*, mengingat jumlah sampelnya yang lebih besar (1.500 titik) memberikan resolusi spasial yang lebih detail dibandingkan Model A.

Meskipun Model A dan Model B berbeda pada unit analisis dan metode ekstraksi nilai, keduanya menggunakan 10 parameter geospasial yang sama sebagai

variabel masukan. Tabel 3.13 merangkum kesepuluh parameter tersebut beserta peran masing-masing dalam proses klasifikasi.

Tabel 3.12 Parameter Data spasial sebagai Variabel Masukan Model

No	Parameter	Tipe Data	Peran dalam Klasifikasi
1	<i>DEM</i> (Elevasi)	Kontinu	Semakin rendah elevasi, semakin besar potensi genangan air
2	<i>Slope</i> (Kemiringan Lereng)	Kontinu	Lereng landai memperlambat aliran permukaan sehingga air lebih mudah tergenang
3	<i>TWI</i>	Kontinu	Nilai tinggi menunjukkan potensi akumulasi air akibat <i>catchment area</i> besar dan lereng landai
4	<i>Plan Curvature</i>	Kontinu	Nilai positif (permukaan cekung) menunjukkan zona konvergensi aliran air
5	<i>HAND</i>	Kontinu	Semakin rendah nilai, semakin dekat suatu titik terhadap saluran drainase secara vertikal
6	Jarak Terhadap Sungai	Kontinu	Semakin dekat ke sungai, semakin besar risiko banjir luapan
7	Jarak Terhadap Jalan	Kontinu	Merepresentasikan tingkat urbanisasi dan impermeabilitas permukaan di sekitarnya
8	<i>LULC</i> (Penggunaan Lahan)	Ordinal (skor 1–5)	Lahan terbangun memiliki kapasitas infiltrasi rendah sehingga skor kerentanannya lebih tinggi
9	Jenis Tanah	Ordinal (skor 1–5)	Jenis tanah dengan kapasitas infiltrasi rendah (seperti <i>Fluvisols</i>) memiliki skor kerentanan lebih tinggi
10	Curah Hujan	Ordinal (skor 1–5)	Curah hujan tinggi menjadi pemicu utama terjadinya limpasan permukaan

Berdasarkan Tabel 3.13, kesepuluh variabel dapat dikelompokkan berdasarkan karakteristik yang direpresentasikannya dan alasan pemilihannya dalam konteks klasifikasi daerah rawan banjir di Kota Langsa.

1. Kelompok Variabel Topografi

Lima variabel pertama seluruhnya diturunkan dari data DEM dan merepresentasikan kondisi topografi wilayah yang secara langsung menentukan pola aliran dan akumulasi air permukaan. DEM dipilih karena elevasi merupakan faktor paling mendasar dalam menentukan potensi genangan wilayah dataran rendah Kota Langsa yang berada pada elevasi 0–10 meter di atas permukaan laut secara inheren lebih rentan terhadap genangan dibandingkan wilayah perbukitan di bagian barat kota. *Slope* dipilih karena kemiringan lereng menentukan kecepatan aliran permukaan lereng landai memperpanjang waktu tinggal air di permukaan sehingga meningkatkan potensi genangan. TWI dipilih karena menggabungkan informasi *catchment area* dan kemiringan dalam satu indeks, sehingga mampu mengidentifikasi lokasi-lokasi yang secara topografi cenderung menjadi titik akumulasi air. *Plan Curvature* dipilih karena menggambarkan bentuk permukaan secara horizontal permukaan cekung (nilai positif) mengonvergensi aliran air dari berbagai arah menuju satu titik. HAND dipilih karena mengukur ketinggian suatu titik di atas saluran drainase terdekat secara vertikal, sehingga langsung merepresentasikan seberapa dekat suatu lokasi dengan potensi luapan sungai — variabel ini juga digunakan sebagai salah satu kriteria pembentukan label *ground truth* pada Model B.

2. Kelompok Variabel Jarak

Jarak terhadap sungai dipilih karena luapan sungai merupakan mekanisme utama terjadinya banjir di Kota Langsa, khususnya luapan Krueng Langsa yang


melintas di tengah kota, sehingga kedekatan suatu wilayah dengan jaringan sungai secara langsung meningkatkan paparan terhadap risiko banjir. Jarak terhadap jalan dipilih bukan semata-mata sebagai faktor risiko fisik, melainkan sebagai proksi tingkat urbanisasi dan impermeabilitas permukaan kawasan yang berada sangat dekat dengan jaringan jalan umumnya merupakan kawasan terbangun padat dengan tutupan permukaan keras yang mengurangi kapasitas infiltrasi tanah dan mempercepat limpasan permukaan.

3. Kelompok Variabel Karakteristik Permukaan

Ketiga variabel ini direklasifikasi ke dalam skor ordinal 1–5 sebelum digunakan sebagai masukan model. LULC dipilih karena jenis tutupan lahan menentukan kapasitas infiltrasi permukaan lahan terbangun dan perkerasan memiliki kapasitas infiltrasi sangat rendah sehingga hampir seluruh curah hujan menjadi limpasan permukaan. Jenis tanah dipilih karena karakteristik fisik tanah, khususnya tekstur dan porositas, menentukan kecepatan air meresap ke dalam tanah tanah *Fluvisols* (*aluvial* pesisir) yang mendominasi Kota Langsa memiliki kapasitas infiltrasi rendah dan muka air tanah yang dangkal sehingga diberi skor kerentanan lebih tinggi. Curah hujan dipilih sebagai variabel pemicu utama banjir meskipun dalam penelitian ini seluruh wilayah Kota Langsa memiliki nilai skor yang seragam akibat resolusi data *CHIRPS* yang kasar ($\pm 5,5$ km per piksel) variabel ini tetap dipertahankan untuk menjaga kelengkapan metodologis dan memungkinkan model diterapkan pada wilayah dengan variasi curah hujan lebih beragam di masa mendatang.

3.5.2 Algoritma Model Klasifikasi *Random Forest*

Random Forest bekerja dengan membangun sejumlah *decision tree* secara acak berdasarkan data latih, di mana setiap *decision tree* melakukan klasifikasi berdasarkan kombinasi nilai 10 variabel geospasial. Hasil akhir klasifikasi ditentukan melalui mekanisme *majority voting* dari seluruh pohon, sehingga diperoleh kelas kerawanan banjir untuk setiap unit analisis. Gambar 3.16 menunjukkan alur kerja algoritma *Random Forest* yang diterapkan pada penelitian ini.



Gambar 3.28 Proses Model Klasifikasi Algoritma *Random Forest*

Algoritma ini diterapkan pada Model A dan Model B dengan skema klasifikasi yang berbeda. Model A menggunakan 66 desa/kelurahan sebagai unit

analisis dan dilatih pada dua skema, yaitu klasifikasi biner (Rawan/Tidak Rawan) dan klasifikasi 3 kelas (Tidak Rawan/Rawan/Sangat Rawan) mengacu pada Peraturan Kepala BNPB Nomor 2 Tahun 2012. Model B menggunakan 1.500 titik sampel sebagai unit analisis dengan klasifikasi biner, karena *ground truth* yang tersedia hanya merepresentasikan satu kejadian banjir. Kedua model menerapkan *class_weight='balanced'* pada tahap pelatihan untuk mengatasi ketidakseimbangan jumlah sampel antar kelas.

1. Pembentukan *Decision Tree*

Setiap *decision tree* dibentuk dari sampel data yang diambil secara acak (*bootstrap sampling*), sehingga setiap pohon memiliki struktur yang berbeda satu sama lain. Pendekatan ini bertujuan meningkatkan keragaman antar pohon dan mengurangi risiko *overfitting* pada model.

2. Pemilihan Atribut dan Pemisahan Data

Pada setiap *node* dalam *decision tree*, dilakukan pemilihan atribut terbaik untuk memisahkan data berdasarkan ukuran ketidakmurnian (*impurity*) menggunakan *Gini Index*, di mana atribut dengan nilai *Gini Index* terkecil dipilih sebagai pemisah karena menghasilkan pemisahan data yang paling baik. Pada setiap *node*, *Random Forest* hanya mempertimbangkan subset acak dari 10 variabel untuk menjaga keberagaman antar pohon. *Gini Index* dihitung berdasarkan proporsi setiap kelas pada suatu node, di mana nilai *Gini Index* mendekati 0 menunjukkan node tersebut semakin murni (didominasi satu kelas), sedangkan nilai mendekati 1 menunjukkan campuran kelas yang lebih merata.

3.5.3 Optimasi Hiperparameter *GridSearchCV*

Untuk mendapatkan performa klasifikasi terbaik, kombinasi hiperparameter model *Random Forest* dicari menggunakan *GridSearchCV*, yaitu metode yang mencoba seluruh kombinasi nilai hiperparameter yang telah ditentukan sebelumnya, kemudian memilih kombinasi dengan performa validasi terbaik berdasarkan metrik *F1-Score*. Lima hiperparameter dipilih untuk dioptimasi pada penelitian ini, dengan alasan sebagai berikut.

n_estimators (jumlah pohon dalam *forest*) diuji pada nilai 100, 200, dan 300, karena jumlah pohon yang lebih banyak umumnya menghasilkan prediksi yang lebih stabil melalui *majority voting*, namun juga meningkatkan waktu komputasi, sehingga perlu dicari titik yang memberikan performa terbaik tanpa penambahan pohon yang tidak perlu. *max_depth* (kedalaman maksimum tiap pohon) diuji pada nilai *None* (tanpa batas), 10, dan 20, untuk mengontrol kompleksitas tiap pohon kedalaman tanpa batas berisiko menyebabkan pohon terlalu menyesuaikan diri dengan data latih (*overfitting*), terutama pada Model A yang berukuran kecil, sedangkan kedalaman terbatas memaksa pohon berhenti tumbuh lebih awal. *min_samples_split* (jumlah minimum sampel untuk memisahkan suatu *node*) diuji pada nilai 2, 5, dan 10, dan *min_samples_leaf* (jumlah minimum sampel pada *node* daun) diuji pada nilai 1, 2, dan 4, karena kedua parameter ini mengontrol seberapa detail suatu pohon dapat memisahkan data nilai yang lebih tinggi membuat pohon berhenti memisahkan data pada kelompok yang masih tergolong kecil, sehingga mengurangi risiko pohon mempelajari pola yang sebenarnya hanya kebetulan (*noise*) pada data latih.

Tabel 3.14 menyajikan ruang pencarian hiperparameter yang direncanakan untuk Model A.

Tabel 3.13 Ruang Pencarian Hiperparameter *GridSearchCV* Model A

Hiperparameter	Model A Biner	Model A 3 Kelas
<i>n_estimators</i>	100, 200, 300	100, 200, 300
<i>max_depth</i>	<i>None</i> , 10, 20	<i>None</i> , 10, 20
<i>min_samples_split</i>	2, 5, 10	2, 5, 10
<i>min_samples_leaf</i>	1, 2, 4	1, 2, 4
<i>class_weight</i>	<i>balanced</i>	<i>balanced</i>
Total kombinasi	81	81
<i>Cross-validation</i>	k=3	k=3
Total proses <i>fitting</i>	243	243

Seperti pada Tabel 3.10 berbeda dengan keempat hiperparameter di atas, *class_weight* tidak diikutkan ke dalam ruang pencarian, melainkan ditetapkan tetap pada nilai *balanced* untuk seluruh varian model. Penetapan ini dilakukan karena baik dataset Model A (77,3% Rawan berbanding 22,7% Tidak Rawan) maupun dataset Model B (16,5% Rawan berbanding 83,5% Tidak Rawan) memiliki distribusi kelas yang tidak seimbang, sehingga tanpa penyesuaian bobot, model berisiko cenderung memprediksi kelas mayoritas saja. Nilai *balanced* membuat scikit-learn secara otomatis memberi bobot pada tiap kelas berbanding terbalik dengan frekuensi kemunculannya, tanpa perlu diuji sebagai beberapa alternatif nilai karena penyeimbangan bobot ini memang diperlukan pada seluruh varian model, bukan sesuatu yang bersifat opsional untuk dibandingkan.

Untuk Model A, dengan ukuran *dataset* yang kecil (66 sampel untuk kedua varian), pencarian hiperparameter menggunakan *Stratified K-Fold Cross-Validation* dengan $k=3$, agar setiap *fold* tetap memiliki representasi sampel yang cukup dari tiap kelas. Kombinasi 81 nilai hiperparameter dengan 3 *fold* menghasilkan total 243 proses *fitting* untuk masing-masing varian, sehingga keseluruhan pencarian pada Model A berjumlah 486 proses *fitting*.

Tabel 3.11 berikut menyajikan ruang pencarian hiperparameter yang direncanakan untuk Model B.

Tabel 3.14 Ruang Pencarian Hiperparameter *GridSearchCV* Model B

Hiperparameter	Model B
<i>n_estimators</i>	100, 200, 300
<i>max_depth</i>	<i>None</i> , 10, 20
<i>min_samples_split</i>	2, 5, 10
<i>min_samples_leaf</i>	1, 2, 4
<i>class_weight</i>	<i>balanced</i>
Total kombinasi	81
<i>Cross-validation</i>	$k=5$
Total proses <i>fitting</i>	405

Untuk Model B, dengan ukuran *dataset* yang jauh lebih besar (1.500 sampel), pencarian hiperparameter menggunakan *Stratified K-Fold Cross-Validation* dengan $k=5$, karena jumlah sampel yang besar memungkinkan pembagian ke lebih banyak *fold* tanpa membuat tiap *fold* kekurangan sampel per kelas, sehingga validasi yang diperoleh lebih menyeluruh. Kombinasi 81 nilai hiperparameter dengan 5 *fold* menghasilkan total 405 proses *fitting*.

3.5.4 Skema Validasi

Skema validasi pada penelitian ini merupakan strategi pembagian data yang digunakan mengukur kemampuan generalisasi model terhadap data yang belum dipelajari selama pelatihan. Pemilihan skema validasi disesuaikan dengan ukuran *dataset* masing-masing model, dikarenakan skema yang digunakan untuk *dataset* besar belum tentu menghasilkan estimasi performa yang optimal pada *dataset* kecil.

1. Skema Validasi Model A

Model A memiliki ukuran sampel yang sangat kecil ($n=66$). Pendekatan *Single Train-Test Split* dengan proporsi 80:20 menghasilkan data uji sebesar 14 sampel untuk skema biner dan 20 sampel untuk skema 3 kelas. Pada ukuran sekecil ini, satu prediksi salah setara dengan penurunan akurasi sebesar 7,14% pada data uji biner, sehingga hasil *Single Split* sangat bergantung pada keberuntungan pembagian data dan tidak dapat dijadikan representasi performa generalisasi yang sesungguhnya.

Oleh karena itu, skema validasi yang direncanakan untuk Model A adalah *Repeated Stratified K-Fold Cross-Validation*, yaitu *Stratified K-Fold* yang diulang beberapa kali dengan pembagian *fold* yang berbeda pada setiap pengulangan. Konfigurasi yang direncanakan adalah 3 *fold* diulang sebanyak 10 kali, menghasilkan total 30 evaluasi independen per varian model (biner dan 3 kelas). Strategi ini memastikan estimasi performa tidak bergantung pada satu konfigurasi pembagian data tertentu. Evaluasi *Single Split* tetap dilakukan sebagai pelengkap untuk melihat pola kesalahan model pada satu partisi data tertentu, namun tidak dijadikan acuan utama pelaporan performa.

2. Skema Validasi Model B

Model B memiliki ukuran sampel yang jauh lebih besar (1.500 titik). Pendekatan *Single Train-Test Split* dengan proporsi 80:20 menghasilkan data uji sebesar 300 titik cukup besar untuk merepresentasikan performa generalisasi model secara andal. Oleh karena itu, skema validasi utama yang direncanakan untuk Model B adalah evaluasi langsung pada 300 data uji tersebut. *Stratified K-Fold Cross-Validation* $k=5$ digunakan sebagai konfirmasi konsistensi performa antar *fold*, bukan sebagai skema utama.

3.6 Teknik Pengujian

Teknik pengujian dilakukan untuk memastikan bahwa sistem klasifikasi daerah rawan banjir yang dibangun dapat berjalan sesuai dengan rancangan serta menghasilkan model klasifikasi yang akurat dan andal. Pengujian dilakukan dari sisi fungsional sistem, alur proses internal, kinerja model klasifikasi, serta validasi hasil prediksi terhadap data historis aktual. Teknik pengujian yang digunakan meliputi evaluasi menggunakan *Confusion Matrix*, pengujian *Blackbox*, pengujian *Whitebox*, dan pengujian performa model.

3.6.1 Matriks Peforma

Evaluasi peforma kedua model diukur dengan menggunakan enam metrik yang dihitung dari *Confusion Matrix*, yaitu Akurasi, Presisi, *Recall*, *F1-Score*, serta *Cohen's Kappa*, dan *Matthews Corelation Coefficient (MCC)*. Pemilihan keenam metrik ini tidak diterapkan seragam di kedua Model, melainkan disesuaikan dengan jumlah data dan karakteristik dari masing-masing *dataset*.

Pemilihan *Cohen's Kappa* dan MCC sebagai metrik tambahan di luar Akurasi dan *F1-Score* didasarkan pada ketidakseimbangan distribusi kelas yang dimiliki kedua model. Model A memiliki distribusi 77,3% Rawan berbanding 22,7% Tidak Rawan, sedangkan Model B memiliki ketidakseimbangan yang jauh lebih ekstrem yaitu 16,5% Rawan berbanding 83,5% Tidak Rawan. Pada kondisi *imbalanced* seperti ini, model yang hanya memprediksi kelas mayoritas secara konsisten pun dapat menghasilkan Akurasi yang tinggi meskipun tidak mampu mengenali kelas minoritas sama sekali, sehingga Akurasi saja tidak cukup untuk menggambarkan performa model secara menyeluruh.

1. Matriks Peforma Model A

Untuk Model A, metrik yang dilaporkan sebagai hasil utama adalah Akurasi, *F1-Score*, dan AUC-ROC dari *Repeated CV*, serta Akurasi dan *Cohen's Kappa* dari Matriks Pembanding. Nilai *Cohen's Kappa* diprioritaskan untuk Model A karena memberikan gambaran seberapa jauh kesepakatan antara prediksi model dengan label aktual melampaui tingkat kebetulan semata, yang relevan pada ukuran data uji yang sangat kecil.

2. Matriks Peforma Model B

Untuk Model B, keenam metrik dilaporkan seluruhnya Akurasi, Presisi, *Recall*, *F1-Score*, *Cohen's Kappa*, dan MCC karena ukuran data uji yang lebih besar ($n=300$) memungkinkan estimasi yang lebih andal untuk setiap metrik. MCC diprioritaskan sebagai metrik tambahan untuk Model B karena merupakan satu-satunya metrik yang memperhitungkan keempat nilai *Confusion Matrix* (TP, TN,

FP, FN) secara seimbang dalam satu nilai tunggal, sehingga paling tepat untuk menggambarkan performa pada ketidakseimbangan distribusi kelas yang ekstrem (1:5).

3.6.2 Pengujian *Blackbox*

Pengujian *Blackbox* berfokus pada pengujian fungsional sistem tanpa memperhatikan struktur internal atau logika program, dilakukan dengan memberikan *input* pada sistem dan membandingkan *output* yang dihasilkan dengan hasil yang diharapkan. Pengujian ini dilakukan terhadap sembilan segmen halaman sistem, dengan setiap segmen diuji melalui beberapa skenario yang mencakup kondisi penggunaan normal, kondisi akses khusus, dan penanganan *input* tidak valid. Tabel 3.16 merangkum kesembilan segmen yang direncanakan untuk diuji.

Tabel 3.15 Skenario Pengujian Fungsional (*Blackbox*)

No	Segmen	Skenario Pengujian	<i>Output</i> yang Diharapkan
1	Autentikasi <i>Login</i>	Mengakses sistem menggunakan kredensial dengan berbagai kondisi (valid, tidak valid, kosong, berbeda peran)	Sistem melakukan autentikasi sesuai kredensial dan mengarahkan pengguna sesuai peran yang dimiliki
2	Autentikasi Register	Mendaftarkan akun baru dengan berbagai kondisi data (valid, tidak valid, sudah terdaftar)	Sistem membuat akun baru untuk data valid, dan menampilkan validasi untuk data tidak valid
3	Halaman <i>Dashboard</i>	Mengakses halaman <i>dashboard</i> dan menavigasi ke fitur lain	Halaman <i>dashboard</i> tampil dengan ringkasan informasi kerawanan banjir, navigasi berfungsi

No	Segmen	Skenario Pengujian	<i>Output yang Diharapkan</i>
4	Pengelolaan Data <i>GIS</i>	Mengakses halaman Kelola Data <i>GIS</i> dengan dan tanpa <i>login Admin</i>	Data spasial ditampilkan bagi <i>Admin</i> yang telah <i>login</i> , akses ditolak tanpa <i>login</i>
5	Visualisasi Peta	Menampilkan peta kerawanan Model A dan Model B, berinteraksi dengan <i>popup</i> informasi	Peta menampilkan sebaran kerawanan sesuai model yang dipilih beserta informasi parameter
6	Visualisasi Statistik	Menampilkan statistik kerawanan Model A dan Model B per kecamatan	Grafik dan tabel distribusi kerawanan per kecamatan tampil sesuai model yang dipilih
7	Pencarian Lokasi	Mencari lokasi dengan kata kunci sesuai, tidak terdaftar, dan kolom kosong	Sistem menampilkan hasil pencarian yang sesuai atau notifikasi yang relevan
8	Evaluasi Performa Model	Mengakses halaman evaluasi Model A dan Model B dengan dan tanpa <i>login Admin</i>	Metrik evaluasi dan visualisasi performa tampil bagi <i>Admin</i> yang telah <i>login</i>
9	Prediksi Lokasi Baru	Memasukkan 10 parameter spasial dengan nilai valid, kosong, dan format tidak valid	Sistem mengembalikan hasil klasifikasi untuk <i>input</i> valid, serta validasi untuk <i>input</i> tidak valid

Kesembilan segmen pada Tabel 3.16 disusun sebagai rencana pengujian yang menjadi acuan dan target hasil pengujian sistem pada tahap implementasi, dengan rincian skenario dan hasil aktual setiap segmen disajikan secara lengkap pada Bab Hasil dan Pembahasan.

3.6.3 Pengujian *Whitebox*

Pengujian struktural pada penelitian ini menggunakan metode *Basis Path Testing*, yaitu menelusuri kode program untuk membentuk graf alir (*flow graph*), menghitung *cyclomatic complexity*, dan menyusun jalur independen sebagai dasar rancangan data uji. Pengujian ini bertujuan memastikan bahwa alur logika pada proses-proses inti sistem tereksekusi dengan benar tanpa kesalahan logika. Tabel 3.17 merangkum empat proses yang direncanakan untuk diuji.

Tabel 3.16 Skenarion Pengujian *Whitebox*

No	Proses	Fokus Pengujian
1	<i>Preprocessing Data</i>	Alur logika penanganan nilai kosong pada variabel kontinu, mencakup perulangan dan kondisi pengecekan nilai
2	Penggabungan Data	Alur logika validasi ketersediaan seluruh variabel geospasial sebelum data digabungkan
3	Pembentukan <i>Dataset</i>	Alur logika pencarian <i>random state</i> yang menjamin representasi seluruh kelas pada data uji
4	Model <i>Random Forest</i>	Alur logika <i>endpoint</i> yang memanggil model untuk menghasilkan klasifikasi beserta probabilitasnya

Setiap proses pada Tabel 3.10 akan ditelusuri kode programnya untuk menentukan titik keputusan, menghitung *cyclomatic complexity*, dan menyusun data uji pada setiap jalur independen yang teridentifikasi, dengan hasil selengkapnya disajikan pada Bab Hasil dan Pembahasan.

BAB IV


HASIL DAN PEMBAHASAN

4.1 Hasil Implementasi Sistem *WebGIS*

Sistem *WebGIS* Klasifikasi Rawan Banjir Kota Langsa merupakan wujud implementasi praktis dari Model A dan Model B yang telah dilatih pada sub-bab sebelumnya. Sistem ini dibangun dengan dua peran pengguna yaitu *admin* yang memiliki akses penuh termasuk pengelolaan data dan pengujian model, serta *user* yang memiliki akses terbatas pada halaman-halaman informasi publik.

4.1.1 Hasil Halaman *Dashboard*

Halaman *Dashboard* merupakan halaman awal yang dapat diakses oleh *admin* maupun *user*, menampilkan ringkasan hasil klasifikasi kerawanan banjir Kota Langsa secara umum dengan Model A sebagai tampilan bawaan. Gambar 4.1 berikut menampilkan tampilan halaman *Dashboard*.




Gambar 4.1 Halaman *Dashboard*

Berdasarkan Gambar 4.1, halaman ini menampilkan status model aktif yaitu *Random Forest*, serta tiga kartu ringkasan meliputi total desa terpantau (66 desa di

5 kecamatan), 52 desa hasil klasifikasi Rawan, dan 14 desa Tidak Rawan. Bagian bawah halaman menampilkan tabel ringkasan hasil klasifikasi per kecamatan yang dapat ditukar antara Model A dan Model B melalui tombol pilihan, dengan kedua tampilan menyajikan hasil klasifikasi model secara konsisten.

4.1.2 Hasil Halaman Peta Kerawanan

Halaman Peta Kerawanan menampilkan visualisasi spasial hasil klasifikasi kedua model dalam satu kanvas peta menggunakan *Leaflet.js*. Gambar 4.2 berikut menampilkan tampilan halaman Peta Kerawanan.



Gambar 4.2 Halaman Peta Kerawanan

Berdasarkan Gambar 4.2, peta menampilkan dua *layer* yang dapat diaktifkan atau dinonaktifkan secara independen melalui panel legenda. *Layer* pertama berupa *choropleth* batas 66 desa Model A yang diwarnai berdasarkan hasil klasifikasi *prediksi_binary*; setiap desa pada peta dapat diklik untuk menampilkan info status Prediksi Model A, Prediksi 3 Kelas (Tidak Rawan/Rawan/Sangat Rawan), serta persentase area terdampak aktual sebagai informasi pembandingan.

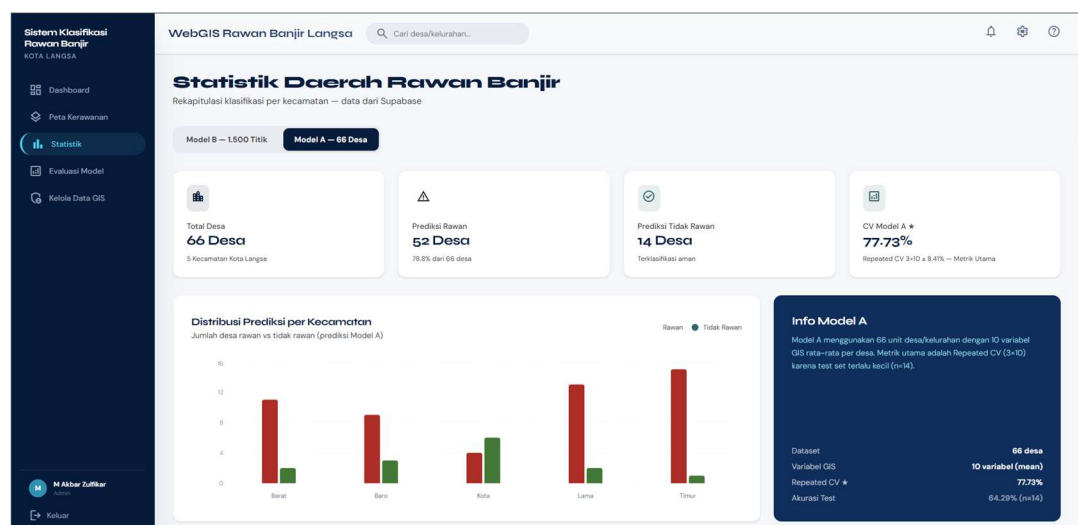
historis. *Layer* kedua berupa 1.500 titik sampel Model B yang diwarnai merah untuk 259 titik hasil klasifikasi Rawan dan hijau untuk 1.241 titik Tidak Rawan, masing-masing dilengkapi *popup* berisi nilai 10 variabel *GIS* pada titik tersebut.

4.1.3 Hasil Halaman Statistik Kerawanan

Halaman Statistik menyajikan rekapitulasi hasil klasifikasi kedua model dalam bentuk kartu ringkasan, grafik batang, dan tabel rinci per kecamatan.

1. Halaman Statistik Model A

Pada gambar 4.3 berikut menampilkan halaman Statistik pada tampilan Model A.



Gambar 4.3 Halaman Statistik Model A

Berdasarkan Gambar 4.3, kartu ringkasan menampilkan total 66 desa, 52 desa hasil klasifikasi Rawan (78,8%), dan 14 desa Tidak Rawan, disertai *Repeated Cross-Validation* $77,73\% \pm 8,41\%$ sebagai metrik utama. Tabel 4.1 berikut merangkum rincian klasifikasi per kecamatan.


Tabel 4.1 Hasil Klasifikasi Model A per Kecamatan

Kecamatan	Total Desa	Rawan	Tidak Rawan	Persentase
Langsa Timur	16	15	1	93,75%
Langsa Lama	15	13	2	86,67%
Langsa Barat	13	11	2	84,62%
Langsa Baro	12	9	3	75,00%
Langsa Kota	10	4	6	40,00%

Berdasarkan Tabel 4.1, Kecamatan Langsa Timur memiliki persentase desa Rawan tertinggi menurut hasil klasifikasi model.

2. Halaman Statistik Model B

Pada gambar 4.4 berikut menampilkan halaman Statistik pada tampilan Model B.

**Gambar 4.4** Halaman Statistik Model B

Berdasarkan Gambar 4.4, kartu ringkasan menampilkan total 1.500 titik sampel, 259 titik hasil klasifikasi Rawan (17,3%), 1.241 titik Tidak Rawan (82,7%),

dan akurasi model 84,33% dengan *Cross-Validation* $82,93\% \pm 0,93\%$. Tabel 4.2 berikut merangkum distribusi titik per kecamatan.

Tabel 4.2 Hasil Klasifikasi Model B per Kecamatan

Kecamatan	Total Titik	Titik Rawan	Persentase
Langsa Kota	47	15	31,91%
Langsa Barat	340	83	24,41%
Langsa Timur	473	110	23,26%
Langsa Lama	224	24	10,71%
Langsa Baro	416	27	6,49%

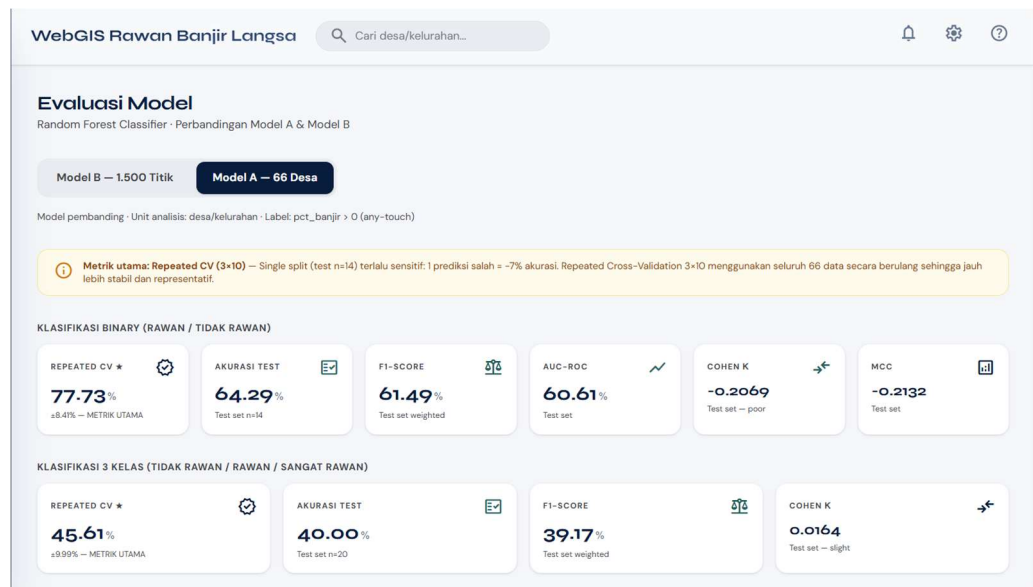
Berdasarkan Tabel 4.2, Kecamatan Langsa Kota memiliki persentase titik Rawan tertinggi menurut hasil klasifikasi Model B, berbeda dari urutan pada Model A.

4.1.4 Hasil Halaman Evaluasi Model

Halaman Evaluasi Model merupakan halaman yang hanya dapat diakses oleh *admin*, menampilkan metrik evaluasi performa kedua model beserta kontribusi setiap variabel dalam proses klasifikasi.


1. Hasil Halaman Evaluasi Model A

Gambar 4.5 berikut menampilkan bagian metrik pada halaman Evaluasi Model tampilan Model A.



Gambar 4.5 Halaman Metrik Evaluasi Model A


Berdasarkan Gambar 4.5, metrik menampilkan hasil klasifikasi biner (*Repeated CV* 77,73% ± 8,41%, *Akurasi test* 64,29%, *F1-Score* 61,49%, *AUC-ROC* 60,61%, *Cohen's Kappa* -0,2069, *MCC* -0,2132) dan klasifikasi 3 kelas (*Repeated CV* 45,61% ± 9,99%, *Akurasi test* 40,00%, *F1-Score* 39,17%, *Cohen's Kappa* 0,0164). Kemudian Gambar 4.6 menampilkan bagian *confusion matrix*, hiperparameter, dan *Matriks Pembanding* per Desa pada halaman yang sama.



Gambar 4.6 *Confusion Matrix, Hiperparameter, dan Matriks Pembanding Model*

A

Berdasarkan Gambar 4.6, *confusion matrix* pada 14 data uji menunjukkan $TN=0$, $FP=3$, $FN=2$, $TP=9$ dengan Presisi Rawan 75,0% dan *Recall* 81,8%. *Matriks Pembanding* per Desa pada seluruh 66 desa menunjukkan $TN=12$, $FP=3$, $FN=2$, $TP=49$ dengan Akurasi 92,42% dan *Cohen's Kappa* 0,7791 kategori *Substantial*. Panel hiperparameter menampilkan konfigurasi $n_estimators=100$, $max_depth=None$, $min_samples_split=5$, $min_samples_leaf=1$, dan $class_weight=balanced$. Kemudian Gambar 4.27 menampilkan bagian *Feature Importance* pada halaman yang sama.




Gambar 4.7 Halaman *Feature Importance* Model A

Berdasarkan Gambar 4.7, urutan kontribusi variabel yang ditampilkan yaitu Jarak Jalan (31,56%), *DEM* (17,22%), *Plan Curvature* (11,22%), *HAND* (10,52%), Jarak Sungai (9,86%), *Slope* (9,65%), *TWI* (8,28%), *LULC* Skor (1,39%), Jenis Tanah (0,31%), dan Curah Hujan (0,00%).


2. Hasil Halaman Evaluasi Model B

Gambar 4.8 berikut menampilkan bagian kartu metrik pada halaman Evaluasi Model tampilan Model B.




Gambar 4.8 Halaman Metrik Evaluasi Model B

Berdasarkan Gambar 4.8, kartu metrik menampilkan Akurasi 84,33%, *F1-Score* 83,99%, *AUC-ROC* 85,28%, *CV Accuracy* $82,93\% \pm 0,93\%$, *Cohen's Kappa* 0,4022 kategori *Moderate*, dan *MCC* 0,4031. Kemudian Gambar 4.9 menampilkan bagian *confusion matrix* dan hiperparameter pada halaman yang sama.



Gambar 4.8 *Confusion Matrix, Hiperparameter Model B*

Berdasarkan Gambar 4.9, *confusion matrix* pada 300 data uji menunjukkan $TN=230$, $FP=21$, $FN=26$, $TP=23$ dengan Presisi Rawan 52,3% dan *Recall* 46,9%. Panel hiperparameter menampilkan konfigurasi $n_estimators=200$, $max_depth=None$, $min_samples_split=10$, $min_samples_leaf=2$, dan $class_weight=balanced$. Kemudian Gambar 4.10 menampilkan bagian *Feature Importance* pada halaman yang sama.



Gambar 4.9 Halaman *Feature Importance Model B*

Berdasarkan Gambar 4.10, urutan kontribusi variabel yang ditampilkan yaitu *DEM* (25,99%), *Jarak Jalan* (16,55%), *Slope* (11,23%), *HAND* (10,96%), *TWI* (9,14%), *Jarak Sungai* (7,75%), *Plan Curvature* (6,91%), *LULC Skor* (6,71%), *Jenis Tanah* (4,76%), dan *Curah Hujan* (0,00%).

4.1.5 Hasil Halaman Kelola Data *GIS*

Halaman Kelola Data *GIS* merupakan panel *admin* untuk memantau hasil klasifikasi dan menguji model klasifikasi secara manual.

1. Data Desa

Tab Data Desa dan Titik Sampel menampilkan seluruh data mentah 1.500 titik dan 66 desa dalam bentuk tabel yang dapat ditelusuri, termasuk nilai 10 variabel *GIS* dan hasil klasifikasi masing-masing.

Sistem Klasifikasi Rawan Banjir KOTA LANGSA

WebGIS Rawan Banjir Langsa

Kelola Data GIS
Panel admin — manajemen data spasial dan monitoring sistem

Titik Sampel: 1,500 | Desa Terpantau: 66 | Kecamatan: 5 | FastAPI (port 8001) Online

Overview | Data Titik Sampel | **Data Desa** | Prediksi Manual | Kelola Pengguna

Tabel desa_klasifikasi (66 baris)

DESA	KECAMATAN	% TERDAMPAK	LABEL BINARY	LABEL 3 KELAS	LULC
Kuala Langsa	Langsa Barat	8.2%	Rawan	Rendah	Mangrove
Lhok Banie	Langsa Barat	71.0%	Rawan	Tinggi	Trees
Matang Seulimeng	Langsa Barat	19.6%	Rawan	Sedang	Built-up
PB. Beuramo	Langsa Barat	18.5%	Rawan	Sedang	Built-up
PB. Teungoh	Langsa Barat	20.0%	Rawan	Sedang	Trees
Serambi Indah	Langsa Barat	0.0%	Aman	Rendah	Built-up

Sistem Klasifikasi Rawan Banjir KOTA LANGSA

WebGIS Rawan Banjir Langsa

Kelola Data GIS
Panel admin — manajemen data spasial dan monitoring sistem

Titik Sampel: 1,500 | Desa Terpantau: 66 | Kecamatan: 5 | FastAPI (port 8001) Online

Overview | **Data Titik Sampel** | Data Desa | Prediksi Manual | Kelola Pengguna

Tabel flood_points (1,500 baris)

ID	ELEVASI (M)	SLOPE (°)	TWI	HAND (M)	LULC	STATUS	PROBABILITAS
1	3.1	1.46	4.281	0.26	Hutan/Mangrove	Rawan	51.1%
2	0.8	0.38	7.461	0.21	Hutan/Mangrove	Tidak Rawan	3.3%
3	7.0	1.70	21.607	2.23	Hutan/Mangrove	Tidak Rawan	31.3%
4	0.7	0.54	6.510	0.11	Air/Genangan/Lahan Terbuka	Tidak Rawan	39.8%
5	27.5	3.46	7.937	0.79	Hutan/Mangrove	Tidak Rawan	2.4%
6	109.3	10.95	21.972	18.22	Hutan/Mangrove	Tidak Rawan	0.0%
7	-0.1	0.52	6.452	0.11	Air/Genangan/Lahan Terbuka	Rawan	84.8%

Gambar 4.10 Halaman Tab Data Titik Sampel & Data Desa

Berdasarkan Gambar 4.11, *admin* dapat memantau data spasial yang tersimpan di basis data *Supabase* dalam bentuk tabel, meliputi 1.500 baris data titik sampel pada tabel *flood_points* beserta nilai 10 variabel geospasialnya, dan 66 baris data klasifikasi per desa/kelurahan pada tabel *desa_klasifikasi*. Karena *Supabase* membatasi maksimum 1.000 baris per *request*, pengambilan data *flood_points* pada halaman ini dilakukan dalam dua *batch* menggunakan *.range(0,999)* dan *.range(1000,1499)*.

2. Prediksi Manual

Gambar 4.12 menampilkan tampilan halaman Kelola Data *GIS* pada tab Prediksi Manual.

The screenshot shows the 'Prediksi Manual' tab in the 'Sistem Klasifikasi Rawan Banjir Kota Langsa' web application. The interface includes a sidebar with navigation options: Dashboard, Peta Kerawanan, Statistik, Evaluasi Model, and Kelola Data GIS (selected). The main content area is titled 'WebGIS Rawan Banjir Langsa' and features a search bar and navigation tabs: Overview, Data Titik Sampel, Data Desa, Prediksi Manual (selected), and Kelola Pengguna. The 'Prediksi Manual' section contains an 'Input Variabel GIS (Model v4 - 10 Fitur)' form with the following values: DEM (Elevasi) (m) = 5, Slope (°) = 2.5, TWI = 12, Plan Curvature = 0.001, Jarak Sungai (m) = 300, Jarak Jalan (m) = 150, HAND (m) = 1.5, LULC Skor (Tutupan Lahan) = Skor 4 - Semak / Permukiman, Jenis Tanah (Soil Skor) = Skor 5 - Fluvisols (Aluvial), and Curah Hujan (ch_skor) 4 - homogen di seluruh Kota Langsa (2500-3000 mm/thn). A 'Prediksi Kerawanan' button is at the bottom of the input section. The 'Hasil Prediksi' section shows the result: 'Tidak Rawan' (Not Vulnerable), 'Hasil klasifikasi model RF v4', 'Probabilitas Rawan' 26.8%, and 'Probabilitas Aman' 73.2%. The model details are 'Model E v4 - Random Forest - n_estimators=200 - max_depth=None'.

Gambar 4.11 Halaman Tab Klasifikasi Manual


Berdasarkan Gambar 4.12, *admin* dapat memasukkan nilai 10 variabel *GIS* secara manual untuk memanggil model klasifikasi secara langsung melalui *FastAPI*. Sebagai contoh, masukan dengan *DEM* 5 m, *slope* 2,5°, *TWI* 12, *curvature* 0,001, jarak sungai 300 m, jarak jalan 150 m, *HAND* 1,5 m, skor *LULC* 4 (Semak/Permukiman), skor tanah 5 (Fluvisols), dan skor curah hujan 4 menghasilkan klasifikasi Tidak Rawan dengan probabilitas Rawan 26,8% dan probabilitas Aman 73,2%.

Istilah "prediksi" pada nama tab dan tombol ini mengikuti penamaan metode bawaan *library scikit-learn*, yaitu *.predict()*, yang dipanggil untuk mengambil keputusan dari model yang telah dilatih baik pada tugas klasifikasi maupun regresi. Penamaan tersebut tidak dimaksudkan sebagai klaim kemampuan meramalkan kejadian banjir pada lokasi atau kondisi yang berada di luar cakupan

data pelatihan. Sistem yang dirancang sebagai sistem klasifikasi yang mengelompokkan lokasi berdasarkan kondisi historis yang telah terjadi di Kota Langsa, sehingga fitur ini lebih tepat dipahami sebagai bukti bahwa model klasifikasi versi terbaru ($n_estimators=200$) telah terintegrasi dan dapat dipanggil melalui *FastAPI*, bukan sebagai alat peramalan kerawanan banjir untuk wilayah yang kondisinya berbeda dari data latih.

3. Kelola Pengguna

Gambar 4.13 menampilkan tab Kelola Pengguna pada halaman Kelola Data *GIS* yang hanya bisa diakses oleh Admin.



Gambar 4.12 Halaman Tab Kelola Pengguna


Berdasarkan Gambar 4.13, *admin* dapat memantau seluruh akun terdaftar beserta perannya dan membuat akun *admin* baru, dengan pembatasan bahwa hanya *admin* yang dapat membuat akun *admin* baru.

4.2 Hasil Pengolahan dan Pengumpulan Data Spasial

Pengolahan data *GIS* merupakan tahapan fundamental dalam penelitian ini yang bertujuan menghasilkan 10 layer parameter geospasial sebagai variabel masukan model *Random Forest*. Seluruh proses pengolahan dilakukan menggunakan perangkat lunak *QGIS* 3.40.14 dengan sistem koordinat EPSG:32647 (WGS 84 / UTM Zone 47N) dan resolusi raster seragam 30 meter $\times$ 30 meter. Penyeragaman sistem koordinat, resolusi, dan cakupan wilayah dilakukan untuk memastikan konsistensi spasial antar layer sehingga proses ekstraksi nilai parameter ke titik sampel dan desa/kelurahan dapat dilakukan secara akurat.

4.2.1 Peta *Digital Elevation Model (DEM)*

Gambar 4.14 menyajikan distribusi ketinggian wilayah Kota Langsa yang diperoleh dari data *DEM* Nasional (*DEMNAS*) Badan Informasi Geospasial (*BIG*).




Gambar 4.13 Peta *Digital Elevation Model (DEM)* Kota Langsa

Nilai elevasi di Kota Langsa berkisar antara $-5,98$ meter hingga $154,04$ meter di atas permukaan laut, dengan rata-rata keseluruhan sebesar $9,97$ mdpl. Nilai

elevasi negatif pada beberapa piksel di wilayah pesisir dan muara sungai mengindikasikan lokasi yang secara topografi berada di bawah permukaan laut rata-rata, yang menjadikannya rentan terhadap genangan dan banjir rob. Berdasarkan analisis rata-rata elevasi per kecamatan, Kecamatan Langsa Baro memiliki elevasi rata-rata tertinggi sebesar 21,38 mdpl dengan nilai maksimum mencapai 154,04 mdpl, mencerminkan karakter topografi berbukit di bagian barat yang berbatasan dengan kawasan pegunungan.

4.2.2 Peta Kemiringan Lereng (*Slope*)

Gambar 4.15 menampilkan distribusi kemiringan lereng (*slope*) wilayah Kota Langsa yang dihitung menggunakan fungsi *Slope* pada *QGIS* 3.40.14.




Gambar 4.14 Peta Kemiringan Lereng (*Slope*) Kota Langsa

Kecamatan Langsa Baro memiliki kemiringan rata-rata tertinggi ($3,09^\circ$) dengan nilai ekstrem hingga $39,40^\circ$ pada beberapa desa di kawasan perbukitan

bagian barat, yang menyebabkan aliran air bergerak lebih cepat menuju lembah dan dataran rendah di timur. Kecamatan Langsa Lama ($2,73^\circ$) dan Langsa Timur ($2,53^\circ$) berada di rentang menengah dengan variasi kemiringan yang cukup beragam. Dominasi kemiringan datar di hampir seluruh wilayah kota, khususnya di Langsa Barat, Langsa Kota, dan Langsa Timur menjadi salah satu faktor fisik yang memperbesar risiko genangan banjir, karena air dari wilayah hulu yang lebih curam akan terakumulasi di dataran rendah tanpa mampu mengalir dengan cepat ke laut.

4.2.3 Peta *Topographic Wetness Index (TWI)*

Gambar 4.16 menyajikan distribusi *TWI* yang dihitung menggunakan algoritma *SAGA Wetness Index* pada *QGIS*.




Gambar 4.15 Peta *Topographic Wetness Index (TWI)* Kota Langsa

Nilai *TWI* di Kota Langsa berkisar antara $-9,03$ hingga $29,27$, dengan rata-rata keseluruhan sebesar $11,34$. Secara umum, nilai *TWI* yang tinggi

mengindikasikan bahwa suatu lokasi memiliki *catchment area* yang besar sekaligus kemiringan yang rendah, sehingga air cenderung terakumulasi dan tanah lebih mudah mencapai kondisi jenuh (*saturated*). Pola spasial *TWI* menunjukkan nilai tinggi yang terkonsentrasi di sepanjang aliran Krueng Langsa dan anak-anak sungainya, serta pada cekungan-cekungan dataran rendah di bagian utara dan timur kota. Kecamatan Langsa Lama memiliki rata-rata *TWI* tertinggi (12,62) meskipun secara ketinggian tidak yang terendah, mengindikasikan bahwa jaringan drainase yang padat di kecamatan tersebut menciptakan banyak zona akumulasi aliran. Kecamatan Langsa Baro juga memiliki rata-rata *TWI* yang tinggi (12,45) karena limpasan dari kawasan perbukitan terkonsentrasi pada lembah-lembah sempit. Sebaliknya, Kecamatan Langsa Barat memiliki rata-rata *TWI* terendah (9,75) meskipun berada di elevasi paling rendah, kemungkinan karena sebagian besar wilayahnya berupa kawasan mangrove dan pesisir yang memiliki pola drainase berbeda dari daratan. Nilai *TWI* berkorelasi dengan kejadian banjir historis, di mana lokasi-lokasi dengan $TWI > 15$ hampir seluruhnya tercatat dalam peta terdampak banjir 31 Januari 2026 yang digunakan sebagai *ground truth* penelitian ini.

4.2.4 Peta *Plan Curvature*

Gambar 4.17 menampilkan distribusi *plan curvature* yang mengukur kelengkungan horizontal permukaan tanah di Kota Langsa.




Gambar 4.16 Peta *Plan Curvature* Kota Langsa

Nilai *plan curvature* di Kota Langsa berkisar antara $-0,108$ hingga $0,114$, dengan dominasi nilai mendekati nol yang mencerminkan permukaan yang relatif datar dan seragam. Nilai positif menunjukkan permukaan cekung (*concave*) yaitu zona di mana aliran dari berbagai arah bertemu dan berpotensi mengakumulasi genangan, sedangkan nilai negatif menunjukkan permukaan cembung (*convex*) yang memencarkan aliran ke berbagai arah. Variasi *plan curvature* yang paling beragam terlihat di Kecamatan Langsa Baro, di mana topografi berbukit menciptakan lembah-lembah cekung yang berfungsi sebagai kanal alami pengumpul aliran. Di wilayah dataran rendah seperti Kecamatan Langsa Timur dan Langsa Barat, nilai *plan curvature* yang mendekati nol menunjukkan medan yang hampir seragam tanpa konsentrasi aliran yang dominan, namun justru hal ini menyebabkan air tersebar merata di seluruh permukaan dan sulit mengalir secara terarah ke saluran drainase. Kombinasi nilai *curvature* mendekati nol dengan

elevasi rendah dan *slope* yang sangat datar di kedua kecamatan tersebut menciptakan kondisi yang kondusif bagi terjadinya genangan banjir yang meluas.

4.2.5 Peta *Height Above Nearest Drainage (HAND)*

Gambar 4.18 menyajikan distribusi *HAND* yang mengukur ketinggian vertikal setiap piksel relatif terhadap saluran drainase terdekatnya.




Gambar 4.17 Peta *Height Above Nearest Drainage (HAND)* Kota Langsa

Nilai *HAND* di Kota Langsa berkisar antara $-0,000024$ meter hingga $14,89$ meter. Berbeda dengan elevasi absolut (*DEM*), *HAND* memberikan informasi yang lebih relevan secara hidrologis karena mengukur seberapa jauh suatu lokasi secara vertikal dari jaringan drainase yang paling dekat, semakin kecil nilai *HAND*, semakin besar kemungkinan lokasi tersebut tergenang ketika debit saluran drainase meluap. Sebagian besar wilayah Kota Langsa memiliki nilai *HAND* yang rendah, terutama di sepanjang sempadan Krueng Langsa, kanal-kanal irigasi, dan kawasan pesisir di Kecamatan Langsa Barat dan Langsa Timur. Wilayah dengan $HAND < 1$

meter yang digunakan sebagai salah satu kriteria penetapan label *ground truth* rawan banjir dalam penelitian ini mendominasi bagian utara dan timur kota. Hal ini konsisten dengan catatan historis kejadian banjir BNPB DIBI dan peta terdampak banjir 31 Januari 2026 yang menunjukkan konsentrasi genangan terbesar di Kecamatan Langsa Timur dan Langsa Barat. Sebaliknya, wilayah perbukitan di bagian barat Kecamatan Langsa Baro memiliki nilai *HAND* yang lebih tinggi (>5 meter) meskipun dilintasi jaringan sungai kecil, karena lereng yang curam menciptakan perbedaan ketinggian vertikal yang besar antara permukaan tanah dan dasar saluran.

4.2.6 Peta Jarak Terhadap Sungai

Gambar 4.19 menyajikan distribusi jarak terhadap jaringan sungai yang dihasilkan melalui metode *Proximity Raster (Raster Distance)* dari data vektor jaringan sungai *BIG*.




Gambar 4.18 Peta Jarak Terhadap Sungai

Nilai jarak terhadap sungai di Kota Langsa berkisar antara 0 meter (tepat di atas sungai) hingga 1.462,63 meter, dengan rata-rata keseluruhan sebesar 267,08 meter. Penggunaan metode *Proximity Raster* menghasilkan nilai jarak kontinu yang lebih informatif dibandingkan metode *Multiple Ring Buffer* yang hanya menghasilkan nilai kategoris, sehingga model *Random Forest* dapat menangkap gradasi risiko yang lebih halus berdasarkan jarak ke sungai. Analisis per kecamatan menunjukkan kontras yang mencolok. Kecamatan Langsa Lama memiliki rata-rata jarak sungai terendah (147,73 meter) dengan nilai maksimum hanya 787,46 meter, yang mengindikasikan kepadatan jaringan sungai dan anak sungai yang tinggi di kecamatan tersebut. Kecamatan Langsa Timur (166,42 meter) dan Langsa Baro (180,03 meter) juga berada pada jarak sungai rata-rata yang rendah. Kecamatan Langsa Kota memiliki rata-rata jarak sungai tertinggi (570,91 meter) karena merupakan kawasan terbangun padat di mana sebagian besar saluran air alami telah dialihkan ke sistem drainase buatan. Kedekatan dengan sungai secara langsung berpengaruh terhadap risiko banjir luapan (*riverine flooding*), di mana wilayah dalam radius 200 meter dari sungai utama merupakan zona dengan risiko paling tinggi berdasarkan analisis *ground truth* penelitian ini.

4.2.7 Peta Jarak Terhadap Jalan

Gambar 4.20 menyajikan distribusi jarak terhadap jaringan jalan yang dihasilkan menggunakan metode *Proximity Raster* dari data vektor jaringan jalan *BIG*.




Gambar 4.19 Peta Jarak Terhadap Jalan

Nilai jarak terhadap jalan di Kota Langsa berkisar antara 0 meter hingga 3.581,08 meter, dengan rata-rata keseluruhan sebesar 149,21 meter. Dalam konteks klasifikasi kerawanan banjir, jarak terhadap jalan digunakan sebagai proksi tingkat urbanisasi dan impermeabilitas permukaan — wilayah yang berdekatan dengan jaringan jalan cenderung memiliki perkerasan aspal atau beton yang mengurangi kapasitas infiltrasi tanah dan meningkatkan volume limpasan permukaan. Kecamatan Langsa Kota memiliki rata-rata jarak jalan terendah (31,07 meter) dengan nilai maksimum hanya 474,34 meter, mencerminkan kepadatan infrastruktur jalan yang tinggi sebagai kawasan pusat kota. Kecamatan Langsa Lama (59,65 meter) dan Langsa Baro (105,25 meter) berada pada level menengah, sementara Kecamatan Langsa Timur memiliki variasi yang sangat besar (0 hingga 3.581,08 meter), menggambarkan pola pembangunan yang tidak merata antara bagian yang sudah terbangun di dekat pusat kota dengan bagian terpencil di selatan.

Kecamatan Langsa Barat memiliki rata-rata jarak jalan tertinggi (444,49 meter) karena sebagian besar wilayahnya berupa kawasan mangrove dan pesisir yang belum terbangun. Parameter jarak jalan menjadi variabel dengan *feature importance* tertinggi kedua dalam model *Random Forest* (0,1545), menunjukkan bahwa pola infrastruktur jalan berkorelasi kuat dengan distribusi spasial kejadian banjir di Kota Langsa — kemungkinan karena kawasan berinfrastruktur jalan yang padat juga merupakan kawasan permukiman padat yang lebih terdokumentasi dalam laporan banjir historis.

4.2.8 Peta Penggunaan Tutupan Lahan (*LULC*)

Gambar 4.21 menggambarkan distribusi penggunaan lahan Kota Langsa berdasarkan data *ESA WorldCover* 2021 yang telah direklasifikasi ke skor kerentanan banjir.




Gambar 4.20 Peta Penggunaan Tutupan Lahan (*LULC*) Kota Langsa

Dari analisis agregasi *majority* per desa, ditemukan lima kelas tutupan lahan yang ada di Kota Langsa, yaitu *Tree Cover* (kode 10, skor 1), *Cropland* (kode 40,

skor 3), *Built-up* (kode 50, skor 4), *Permanent Water Bodies* (kode 80, skor 5), dan *Mangroves* (kode 95, skor 5). Secara keseluruhan dari 66 desa, *Built-up* mendominasi dengan 24 desa (36%), diikuti *Tree Cover* 23 desa (35%), *Mangroves* 8 desa (12%), *Cropland* 7 desa (11%), dan *Water Bodies* 4 desa (6%). Distribusi per kecamatan menunjukkan pola yang kontras. Kecamatan Langsa Kota paling homogen dengan 90% desanya (9 dari 10 desa) berdominasi lahan terbangun (*Built-up*, skor 4), mengkonfirmasi statusnya sebagai kawasan pusat kota dengan impermeabilitas permukaan tertinggi. Kecamatan Langsa Barat memiliki keragaman paling tinggi: 38% desanya (5 dari 13) didominasi mangrove (skor 5), 31% *Built-up* (skor 4), 15% *Tree Cover*, dan 15% *Water Bodies*, menggambarkan karakter kawasan transisi pesisir-urban yang kompleks. Kecamatan Langsa Lama justru didominasi *Tree Cover* (67% atau 10 dari 15 desa, skor 1) yang mengindikasikan tutupan vegetasi lebat dengan kapasitas infiltrasi tinggi, menjadikannya kecamatan dengan kerentanan *LULC* terendah. Kecamatan Langsa Timur memiliki komposisi beragam dengan *Cropland* sebagai dominan (44%), diikuti *Tree Cover* (38%), *Water Bodies* (12%), dan *Mangroves* (6%), mencerminkan karakter kawasan semi-pertanian di pinggiran kota yang berbatasan dengan pesisir.

4.2.9 Peta Jenis Tanah

Gambar 4.22 menunjukkan distribusi jenis tanah Kota Langsa berdasarkan data *Digital Soil Map of the World (DSMW) FAO* yang telah direklasifikasi ke skor kerentanan banjir.




Gambar 4.21 Peta Jenis Tanah Kota Langsa

Berbeda dengan parameter lain yang memiliki variasi nilai kontinu, parameter jenis tanah di Kota Langsa hanya terdiri dari dua unit tanah, yaitu *Fluvisols* (kode Jd, skor 5) dan *Acrisols* (kode Ao, skor 3). Meskipun terlihat sederhana, informasi jenis tanah ini memiliki implikasi hidrologis yang besar karena berkaitan langsung dengan kapasitas infiltrasi dan permeabilitas permukaan. *Fluvisols* merupakan tanah aluvial yang terbentuk dari endapan material sedimen yang dibawa oleh aliran sungai dan proses deposisi pesisir. Karakteristik utama *Fluvisols* adalah tekstur yang umumnya berlumpur hingga lempung dengan porositas rendah, mengakibatkan kapasitas infiltrasi yang buruk sehingga sebagian besar air hujan menjadi limpasan permukaan. *Fluvisols* mendominasi wilayah dataran rendah di bagian utara, timur, dan tengah Kota Langsa — tepat di kawasan yang paling sering mengalami banjir. *Acrisols* merupakan tanah merah podsolik yang lebih tua dan lebih terlindi, umumnya ditemukan di kawasan perbukitan di

bagian barat Kecamatan Langsa Baro. Meskipun kapasitas infiltrasi *Acrisols* lebih baik dibandingkan *Fluvisols*, nilai skor 3 tetap diberikan karena permeabilitasnya masih tergolong sedang. Kaitan antara dominasi *Fluvisols* di dataran rendah dengan distribusi titik rawan banjir pada *dataset* Model B cukup kuat — dari 247 titik berlabel rawan banjir, mayoritas berada di atas lapisan *Fluvisols*, menunjukkan peran jenis tanah sebagai salah satu faktor penguat risiko banjir.

4.2.10 Peta Curah Hujan Rata-rata Tahunan

Gambar 4.23 menampilkan distribusi curah hujan rata-rata tahunan Kota Langsa yang diperoleh dari data *CHIRPS* v2.0 melalui agregasi 120 *file raster* bulanan periode 2016–2025.



Gambar 4.22 Peta Curah Hujan Kota Langsa

Nilai curah hujan rata-rata di Kota Langsa berkisar antara 2.211 mm hingga 2.503 mm per tahun, seluruhnya berada dalam rentang 2.500–3.000 mm/tahun untuk kategori skor 4 (Tinggi). Distribusi curah hujan yang relatif homogen ini

disebabkan oleh resolusi data *CHIRPS* yang kasar ($\pm 5,5$ km per piksel) sehingga variasi curah hujan skala lokal antar desa dalam satu kota tidak dapat tertangkap. Konsekuensinya, variabel curah hujan (*ch_skor*) memiliki nilai yang hampir seragam di seluruh 1.500 titik sampel, sehingga tidak memberikan kontribusi diferensiasi dalam proses klasifikasi. Hal ini tercermin dari nilai *feature importance* sebesar 0,0000 yang menempatkan curah hujan di posisi terakhir dari 10 variabel. Meskipun demikian, variabel ini tetap dipertahankan dalam model dengan dua pertimbangan: pertama, untuk menjaga kelengkapan metodologis sesuai dengan kerangka parameter kerawanan banjir yang ditetapkan dalam Peraturan Kepala BNPB Nomor 2 Tahun 2012; kedua, untuk memastikan bahwa model dapat diaplikasikan pada wilayah dengan variasi curah hujan yang lebih beragam di masa mendatang tanpa perlu mengubah arsitektur fitur.

4.3 Hasil Pembentukan Dataset

Tahap pembentukan *dataset* menghasilkan dua *dataset* terstruktur yang masing-masing digunakan untuk melatih dan menguji Model A (66 desa/kelurahan) dan Model B (1.500 titik sampel). Setiap *dataset* memuat 10 kolom fitur dan 1 kolom label kerawanan banjir yang ditetapkan berdasarkan kriteria *ground truth* yang berbeda untuk setiap model. Pada sub-bab ini disajikan karakteristik statistik setiap fitur, distribusi label, serta pembagian data latih dan data uji.

4.3.1 Statistik Deskriptif Fitur

Tabel 4.3 menyajikan statistik deskriptif 10 variabel fitur yang digunakan pada *dataset* Model A.

Tabel 4.3 Statistik Deskriptif 10 Variabel Fitur


Variabel	Min	Maks	Rata-rata	Std. Dev
Elevasi/DEM (m)	0,42	78,41	9,97	13,67
<i>Slope</i> (°)	0,80	9,88	2,26	1,60
<i>TWI</i>	8,47	14,54	11,34	1,82
<i>Plan Curvature</i>	-0,014	0,010	-0,001	0,003
<i>HAND</i> (m)	0,42	6,72	1,28	1,08
Jarak Sungai (m)	70,39	1.173,95	267,08	246,04
Jarak Jalan (m)	7,95	1.478,28	149,21	281,09
<i>LULC</i> Skor	1	5	2,52	1,53
Jenis Tanah Skor	3	5	4,58	0,82
Curah Hujan Skor	4	4	4,00	0,00

Beberapa temuan dari statistik deskriptif pada Tabel 4.3 perlu mendapat perhatian khusus. Pertama, variabel elevasi menunjukkan standar deviasi yang tinggi (13,67) dengan rentang nilai yang lebar, mengindikasikan variasi spasial yang besar antar desa, terutama antara desa-desa dataran rendah pesisir dan desa-desa perbukitan di Kecamatan Langsa Baro. Sebaliknya, *plan curvature* justru memiliki nilai yang mendekati nol dengan standar deviasi sangat kecil (0,003), menunjukkan permukaan Kota Langsa yang secara umum relatif datar. Kedua, variabel jarak sungai (std. 246,04 m) dan jarak jalan (std. 281,09 m) memiliki variasi yang besar, mencerminkan perbedaan aksesibilitas dan kepadatan infrastruktur antar desa. Ketiga, variabel curah hujan memiliki standar deviasi 0,00 karena seluruh 66 desa berada dalam rentang curah hujan yang sama (skor 4), sehingga tidak memberikan kontribusi diferensiasi pada proses klasifikasi dan menghasilkan nilai *feature importance* 0,0000 dalam model. Keempat, *LULC* Skor dengan rata-rata 2,52 menunjukkan bahwa secara keseluruhan penggunaan lahan Kota Langsa condong ke kategori kerentanan rendah hingga menengah, dengan

Tree Cover (23 desa, 35%) dan *Built-up* (24 desa, 36%) sebagai dua kelas dominan yang hampir berimbang.

4.3.2 Distribusi Label Dataset Model A

Gambar 4.24 menunjukkan distribusi label kerawanan pada *dataset* Model A.



Gambar 4.23 Distribusi Label Dataset Model A

Dataset Model A dibentuk dari 66 desa/kelurahan Kota Langsa sebagai unit analisis. Label kerawanan per desa ditetapkan berdasarkan persentase luas area terdampak banjir (*pct_banjir*) yang dihitung dari perbandingan luas area terdampak banjir kejadian 31 Januari 2026 terhadap luas total desa. Desa dengan *pct_banjir* $\geq$ 30% dikategorikan Rawan (label 1) dan kurang dari itu dikategorikan Tidak Rawan (label 0), mengacu pada Peraturan Kepala BNPB Nomor 2 Tahun 2012. Dari 66 desa, sebanyak 51 desa (77,3%) berlabel Rawan dan 15 desa (22,7%) berlabel Tidak Rawan. Distribusi label Model A yang justru didominasi kelas Rawan mencerminkan bahwa sebagian besar wilayah Kota Langsa memang terdampak banjir berdasarkan catatan historis, konsisten dengan kondisi geografis kota yang didominasi dataran rendah pesisir.


Tabel 4.4 Distribusi Label *Binary* Dataset Model A per Kecamatan

Kecamatan	Total Desa	Rawan (label=1)	Tidak Rawan (label=0)
Langsa Barat	13	10 (76,9%)	3 (23,1%)
Langsa Baro	12	9 (75,0%)	3 (25,0%)
Langsa Kota	10	4 (40,0%)	6 (60,0%)
Langsa Lama	15	14 (93,3%)	1 (6,7%)
Langsa Timur	16	14 (87,5%)	2 (12,5%)
Total	66	51 (77,3%)	15 (22,7%)

Berdasarkan Tabel 4.4, Kecamatan Langsa Lama dan Langsa Timur memiliki jumlah desa rawan terbanyak yaitu masing-masing 14 dari 15 desa (93,3%) dan 14 dari 16 desa (87,5%), menjadikan keduanya sebagai kecamatan dengan konsentrasi kejadian banjir tertinggi di Kota Langsa berdasarkan data historis. Kecamatan Langsa Barat juga menunjukkan proporsi tinggi dengan 10 dari 13 desa (76,9%) berlabel rawan, konsisten dengan karakter pesisir dan mangrove yang rentan genangan. Kecamatan Langsa Baro memiliki 9 dari 12 desa (75,0%) berlabel rawan meskipun secara topografi memiliki elevasi lebih tinggi — hal ini disebabkan oleh desa-desa di dataran rendah bagian timur kecamatan yang berbatasan langsung dengan wilayah pusat kota. Kecamatan Langsa Kota memiliki proporsi rawan terendah dengan hanya 4 dari 10 desa (40,0%) berlabel rawan, mencerminkan bahwa meskipun merupakan kawasan terbangun padat, sistem drainase perkotaan yang lebih baik mengurangi frekuensi kejadian banjir yang terdokumentasi dibandingkan kecamatan lainnya.

4.3.3 Distribusi Label Dataset Model B

Pada Gambar 4.25 menampilkan distribusi label kerawanan pada *dataset* Model B.



Gambar 4.24 Diagram distribusi label Model B

Dataset Model B dibentuk dari 1.500 titik sampel yang tersebar merata di seluruh wilayah Kota Langsa. Label kerawanan ditetapkan berdasarkan dua kriteria simultan, yaitu titik berada di dalam area terdampak banjir kejadian 31 Januari 2026 dan nilai *HAND* kurang dari 1 meter. Dari 1.500 titik sampel, sebanyak 247 titik (16,5%) berlabel Rawan dan 1.253 titik (83,5%) berlabel Tidak Rawan. Ketidakseimbangan kelas (*class imbalance*) antara kedua kelas ini mencerminkan kondisi nyata di lapangan, di mana tidak seluruh wilayah Kota Langsa merupakan daerah rawan banjir, dengan rasio ketidakseimbangan sekitar 1:5,1. Oleh karena itu, parameter *class_weight='balanced'* diterapkan pada algoritma *Random Forest* untuk memberikan bobot yang lebih tinggi pada kelas minoritas (Rawan) secara otomatis proporsional terhadap frekuensi kemunculannya dalam data latih. *Dataset* kemudian dibagi menggunakan *stratified split* 80:20 menghasilkan 1.200 data latih

(198 Rawan + 1.002 Tidak Rawan) dan 300 data uji (49 Rawan + 251 Tidak Rawan), dengan proporsi kelas yang terjaga pada kedua subset.

4.3.4 Perbandingan Karakteristik Kedua *Dataset*

Tabel 4.5 menyajikan perbandingan karakteristik lengkap antara Dataset Model A dan Dataset Model B.

Tabel 4.5 Perbandingan Karakteristik Dataset Model A dan Model B

Karakteristik	Model A	Model B
Unit analisis	Desa/Kelurahan	Titik Sampel
Jumlah sampel	66	1.500
Jumlah fitur	10	10
Kriteria label	$pct_banjir \geq 30\%$	$HAND < 1m \cap$ area terdampak 31 Jan 2026
Label Rawan	51 (77,3%)	247 (16,5%)
Label Tidak Rawan	15 (22,7%)	1.211 (83,5%)
Data Latih	52 (40R + 12TR)	1.200 (230R + 970TR)
Data Uji	14 (11R + 3TR)	300 (59R + 241TR)
Penanganan <i>imbalance</i>	$class_weight='balanced'$	$class_weight='balanced'$
Metode validasi	CV k=3	CV k=5

Perbedaan mendasar antara kedua *dataset* terletak pada unit analisis dan kriteria pembentukan label. Model A menggunakan pendekatan berbasis administrasi yang lebih sesuai untuk perencanaan wilayah tingkat desa, sedangkan Model B menggunakan pendekatan berbasis titik yang memberikan resolusi spasial lebih detail dengan 1.500 sampel terdistribusi merata. Distribusi label Model A yang didominasi kelas Rawan (77,3% vs 22,7%) berbanding terbalik dengan Model

B yang sangat tidak seimbang (16,5% vs 83,5%) — perbedaan ini wajar karena kriteria label yang berbeda: Model A berbasis agregasi historis per desa yang cenderung menangkap lebih banyak wilayah terdampak karena satu kejadian banjir dapat mempengaruhi sebagian besar luas desa, sedangkan Model B berbasis kondisi fisik titik per titik (*HAND* dan area terdampak). Kedua *dataset* menggunakan 10 fitur yang sama, namun metode ekstraksi nilainya berbeda: Model A menggunakan *Zonal Statistics* (nilai agregat dalam poligon desa) sedangkan Model B menggunakan *Sample Raster Values* (nilai tepat di koordinat titik).

4.4 Implementasi Algoritma *Random Forest*

Implementasi algoritma *Random Forest* dilakukan menggunakan bahasa pemrograman *Python 3* dengan *library scikit-learn* pada lingkungan *Google Colab* yang terhubung dengan *Google Drive* sebagai penyimpanan data. *Library* pendukung yang digunakan meliputi *pandas* dan *numpy* untuk pengolahan data tabular, *matplotlib* dan *seaborn* untuk visualisasi hasil, serta *joblib* untuk penyimpanan model terlatih. Sesuai dengan urutan yang ditetapkan, implementasi dimulai dari *Model A* (66 desa/kelurahan) sebagai model pembanding, kemudian dilanjutkan dengan *Model B* (1.500 titik sampel) sebagai model utama sistem *WebGIS*.

4.4.1 Implementasi Model A (66Desa/Kelurahan)

1. Pembuatan Dataset dan Definisi Fitur

Implementasi dilakukan pada lingkungan *Google Colab* yang terhubung dengan *Google Drive*, sesuai dengan urutan yang telah ditetapkan, yaitu Model A dikerjakan terlebih dahulu sebagai model pembanding sebelum Model B.

Implementasi Model A diawali dengan memuat kembali *dataset* yang telah terbentuk dan dibahas statistik deskriptifnya pada bagian sebelumnya (*dataset_A_v4_processed.csv*, 66 baris dan 17 kolom), kemudian menyiapkannya dalam bentuk matriks fitur X dan dua variabel target y (*label_binary* dan *label_3kelas*) sesuai dengan dua skema klasifikasi yang direncanakan, sehingga siap digunakan oleh *scikit-learn* pada tahap pelatihan berikutnya. Kode 4.1 menunjukkan pemuatan *dataset* Model A tersebut.

Listing 4.1 Definisi Fitur dan Pemuatan *Dataset Model A*

```
df = pd.read_csv(f'{PROC_DIR}/dataset_A_v4_processed.csv')

with open(f'{PROC_DIR}/feature_cols_A_v4.json') as f:
    FEATURE_COLS = json.load(f)

X      = df[FEATURE_COLS]
y_bin  = df['label_binary']
y_3    = df['label_3kelas']

print(f'Shape dataset : {df.shape}')
print(f'Fitur (X)      : {X.shape}')

print(f'\nDistribusi label_binary:')
for k in sorted(y_bin.unique()):
    count = (y_bin==k).sum()
    print(f'    {LABEL_BINARY_NAMES[k]:14s} ({k}): {count} desa
    ({count/len(y_bin)*100:.1f}%)')

print(f'\nDistribusi label_3kelas:')
for k in sorted(y_3.unique()):
    count = (y_3==k).sum()
    print(f'    {LABEL_3KELAS_NAMES[k]:14s} ({k}): {count} desa
    ({count/len(y_3)*100:.1f}%)')
```

Berdasarkan Listing 4.1, *dataset* Model A berbentuk 66 baris dan 17 kolom, dengan 10 kolom di antaranya menjadi fitur (X berbentuk 66×10). Distribusi *label_binary* menunjukkan 51 desa (77,3%) berlabel Rawan dan 15 desa (22,7%) berlabel Tidak Rawan, sedangkan distribusi *label_3kelas* menunjukkan 15 desa (22,7%) Tidak Rawan, 29 desa (43,9%) Rawan, dan 22 desa (33,3%) Sangat Rawan.

2. Pembagian Data

Setelah *dataset* Model A berhasil dimuat dan disiapkan dalam bentuk X dan y pada Listing 4.1, langkah selanjutnya adalah membagi 66 desa tersebut menjadi data latih dan data uji untuk masing-masing dari dua skema klasifikasi yang dimiliki Model A, mengingat kedua skema memerlukan strategi pembagian yang berbeda akibat perbedaan ukuran dan sebaran kelasnya. Pada varian biner, distribusi label yang timpang (51 desa Rawan berbanding 15 desa Tidak Rawan) menuntut pembagian data latih dan data uji yang tetap mempertahankan proporsi kedua kelas tersebut, sedangkan pada varian 3 kelas dengan tiga label (Tidak Rawan, Rawan, dan Sangat Rawan) diperlukan strategi tambahan berupa pencarian nilai `random_state` secara otomatis, karena ukuran dataset yang kecil membuat pembagian acak biasa berisiko tidak menyertakan salah satu kelas pada data uji. Kode 4.2 menunjukkan pembagian data untuk kedua varian Model A tersebut.

Listing 4.2 Pembagian Data Model A

```
X_train_b, X_test_b, y_train_b, y_test_b = train_test_split(
    X, y_bin, test_size=0.2,
    random_state=RANDOM_STATE, stratify=y_bin
)

TEST_SIZE_3KELAS = 0.3
chosen_rs = None

for rs_candidate in range(42, 200):
    _, _, _, y_test_check = train_test_split(
        X, y_3, test_size=TEST_SIZE_3KELAS,
        random_state=rs_candidate, stratify=y_3
    )
    if y_test_check.nunique() == y_3.nunique():
        chosen_rs = rs_candidate
        break

if chosen_rs is None:
    raise ValueError('Tidak ditemukan random_state yang menjamin semua kelas
    hadir')

print(f'Random state terpilih untuk 3 kelas: {chosen_rs}')

X_train_3, X_test_3, y_train_3, y_test_3 = train_test_split(
    X, y_3, test_size=TEST_SIZE_3KELAS,
    random_state=chosen_rs, stratify=y_3
)

print('\n=== Binary ===')
print(f'Train: {len(X_train_b)} | dist:
    {dict(y_train_b.value_counts().sort_index())}')
print(f'Test : {len(X_test_b)} | dist:
    {dict(y_test_b.value_counts().sort_index())}')

print('\n=== 3 Kelas ===')
print(f'Train: {len(X_train_3)} | dist:
    {dict(y_train_3.value_counts().sort_index())}')
print(f'Test : {len(X_test_3)} | dist:
    {dict(y_test_3.value_counts().sort_index())}')
print(f'Jumlah kelas di test set: {y_test_3.nunique()} (harus 3)')
```

Untuk varian biner digunakan *test_size* 20% menghasilkan 52 data latih dan 14 data uji. Untuk varian 3 kelas digunakan *test_size* 30% dengan pencarian *random_state* otomatis pada baris *chosen_rs* = None hingga break, untuk memastikan ketiga kelas terwakili di *test set*, menghasilkan 46 data latih dan 20 data uji. Blok if *chosen_rs* is None: raise ValueError(...) berfungsi sebagai pengaman apabila tidak ada satu pun kandidat *random_state* pada rentang 42–200 yang berhasil menghadirkan ketiga kelas.

3. Optimasi Hiperparameter (*GridSearchCV*)

GridSearchCV Model A menggunakan *Stratified K-Fold* $k=3$ karena ukuran sampel kecil ($n=66$) dengan kelas minoritas hanya 15 desa. Kode 4.3 menunjukkan implementasi *GridSearchCV* untuk kedua varian.

Listing 4.3 *GridSearchCV* Model A

```
param_grid = {
    'n_estimators'      : [100, 200, 300],
    'max_depth'         : [None, 10, 20],
    'min_samples_split' : [2, 5, 10],
    'min_samples_leaf'  : [1, 2, 4],
    'class_weight'      : ['balanced']
}

cv_k3 = StratifiedKFold(n_splits=3, shuffle=True, random_state=RANDOM_STATE)

# Binary
print('GridSearchCV - Binary')
grid_bin = GridSearchCV(
    RandomForestClassifier(random_state=RANDOM_STATE, n_jobs=-1),
    param_grid, cv=cv_k3, scoring='f1_weighted',
    n_jobs=-1, verbose=1
)
grid_bin.fit(X_train_b, y_train_b)

# 3 Kelas
print('\nGridSearchCV - 3 Kelas')
grid_3 = GridSearchCV(
    RandomForestClassifier(random_state=RANDOM_STATE, n_jobs=-1),
    param_grid, cv=cv_k3, scoring='f1_weighted',
    n_jobs=-1, verbose=1
)
grid_3.fit(X_train_3, y_train_3)

print(f'\n=== Best Params Binary ===')
for k, v in grid_bin.best_params_.items():
    print(f'    {k}: {v}')
print(f'Best CV F1: {grid_bin.best_score_:.4f}')

print(f'\n=== Best Params 3 Kelas ===')
for k, v in grid_3.best_params_.items():
    print(f'    {k}: {v}')
print(f'Best CV F1: {grid_3.best_score_:.4f}')
```

Grid pencarian mencakup 81 kombinasi parameter dengan *cross-validation* $k=3$, sehingga total proses *fitting* yang dijalankan adalah 243 kali untuk setiap varian. Hiperparameter terbaik yang diperoleh menghasilkan *Best CV F1-Score* sebesar 0,8133 untuk varian biner dan 0,5823 untuk varian 3 kelas. Tabel 4.6 menyajikan rincian hiperparameter terbaik yang ditemukan untuk kedua varian.

Tabel 4.6 Hiperparameter Terbaik Model A

Hiperparameter	Model A Biner	Model A 3 Kelas
<i>n_estimators</i>	100	200
<i>max_depth</i>	None	None
<i>min_samples_leaf</i>	1	1
<i>min_samples_split</i>	5	2
<i>class_weight</i>	<i>balanced</i>	<i>balanced</i>

4. Metode Evaluasi *Single Split CV*

Setelah kombinasi hiperparameter terbaik diperoleh dari *GridSearchCV* pada Listing 4.3, tahap selanjutnya adalah mengevaluasi performa model *best_bin* dan *best_3* tersebut. Evaluasi pada tahap ini menggunakan satu kali pembagian data latih dan data uji (*single split*) yang sama seperti pada Listing 4.2, dengan enam metrik sekaligus, yaitu *Accuracy*, *F1-Score*, *AUC-ROC*, *Cohen's Kappa*, *MCC*, dan *CV Accuracy* $k=3$, untuk kedua varian klasifikasi Model A. Kode 4.4 menunjukkan evaluasi *single split* tersebut sebagai pelengkap sebelum evaluasi utama menggunakan *Repeated Cross-Validation*.

Listing 4.4 Evaluasi *Single Split* Model A

```
best_bin = grid_bin.best_estimator_
best_3 = grid_3.best_estimator_

# === Binary ===
y_pred_b = best_bin.predict(X_test_b)
y_proba_b = best_bin.predict_proba(X_test_b)[:, 1]

acc_b = accuracy_score(y_test_b, y_pred_b)
f1_b = f1_score(y_test_b, y_pred_b, average='weighted')
auc_b = roc_auc_score(y_test_b, y_proba_b)
kappa_b = cohen_kappa_score(y_test_b, y_pred_b)
mcc_b = matthews_corrcoef(y_test_b, y_pred_b)

cv_bin = cross_val_score(best_bin, X, y_bin, cv=cv_k3, scoring='accuracy')

print('=== EVALUASI BINARY (Single Split - Pelengkap) ===')
print(f'Accuracy : {acc_b*100:.2f}%')
print(f'F1-Score : {f1_b:.4f}')
print(f'AUC-ROC : {auc_b:.4f}')
print(f'Cohen Kappa : {kappa_b:.4f}')
print(f'MCC : {mcc_b:.4f}')
print(f'CV k=3 : {cv_bin.mean()*100:.2f}% ± {cv_bin.std()*100:.2f}%')

# === 3 Kelas ===
y_pred_3 = best_3.predict(X_test_3)

acc_3 = accuracy_score(y_test_3, y_pred_3)
f1_3 = f1_score(y_test_3, y_pred_3, average='weighted')
kappa_3 = cohen_kappa_score(y_test_3, y_pred_3)
mcc_3 = matthews_corrcoef(y_test_3, y_pred_3)

cv_3 = cross_val_score(best_3, X, y_3, cv=cv_k3, scoring='accuracy')

print('\n=== EVALUASI 3 KELAS (Single Split - Pelengkap) ===')
print(f'Accuracy : {acc_3*100:.2f}%')
print(f'F1-Score : {f1_3:.4f}')
print(f'Cohen Kappa : {kappa_3:.4f}')
print(f'MCC : {mcc_3:.4f}')
print(f'CV k=3 : {cv_3.mean()*100:.2f}% ± {cv_3.std()*100:.2f}%')
```

Berdasarkan Listing 4.4, evaluasi *single split* varian biner menghasilkan akurasi 64,29%, *F1-Score* 0,6149, *AUC-ROC* 0,6061, *Cohen's Kappa* -0,2069, *MCC* -0,2132, dan CV k=3 sebesar 77,27% ± 9,82%. Evaluasi *single split* varian 3 kelas menghasilkan akurasi 40,00%, *F1-Score* 0,3917, *Cohen's Kappa* 0,0164, dan CV k=3 sebesar 50,00% ± 9,82%. Nilai *Cohen's Kappa* negatif pada varian biner (-0,2069) menunjukkan kesepakatan yang lebih buruk daripada kebetulan semata pada *single split* ini, yang menjadi salah satu alasan utama *Repeated Cross-Validation* dipilih sebagai metrik evaluasi utama, bukan hasil *single split* ini.

5. Metode Evaluasi - *Repeated Cross-Validation*

Karena ukuran sampel kecil ($n=66$), evaluasi utama menggunakan *Repeated Stratified K-Fold* ($3 \text{ folds} \times 10 \text{ repeats} = 30$ evaluasi) sebagaimana ditunjukkan pada Kode 4.5.

Listing 4.5 *Repeated Cross-Validation Model A*

```
rskf = RepeatedStratifiedKFold(
    n_splits=3, n_repeats=10, random_state=RANDOM_STATE
)

# === Binary ===
rcv_acc_b = cross_val_score(best_bin, X, y_bin, cv=rskf,
    scoring='accuracy')
rcv_f1_b = cross_val_score(best_bin, X, y_bin, cv=rskf,
    scoring='f1_weighted')
rcv_auc_b = cross_val_score(best_bin, X, y_bin, cv=rskf, scoring='roc_auc')

print('=== REPEATED CV - BINARY (3 folds x 10 repeats = 30 evaluasi) ===')
print(f'Accuracy : {rcv_acc_b.mean()*100:.2f}% ± {rcv_acc_b.std()*100:.2f}%')
print(f'F1-Score : {rcv_f1_b.mean():.4f} ± {rcv_f1_b.std():.4f}')
print(f'AUC-ROC : {rcv_auc_b.mean():.4f} ± {rcv_auc_b.std():.4f}')

# === 3 Kelas ===
rcv_acc_3 = cross_val_score(best_3, X, y_3, cv=rskf, scoring='accuracy')
rcv_f1_3 = cross_val_score(best_3, X, y_3, cv=rskf, scoring='f1_weighted')

print('\n=== REPEATED CV - 3 KELAS (3 folds x 10 repeats = 30 evaluasi) ===')
print(f'Accuracy : {rcv_acc_3.mean()*100:.2f}% ± {rcv_acc_3.std()*100:.2f}%')
print(f'F1-Score : {rcv_f1_3.mean():.4f} ± {rcv_f1_3.std():.4f}')
```

Berdasarkan Listing 4.5, *Repeated Cross-Validation* varian biner menghasilkan akurasi $77,73\% \pm 8,41\%$, *F1-Score* $0,7541 \pm 0,0763$, dan *AUC-ROC* $0,6749 \pm 0,1139$ dari 30 evaluasi. Varian 3 kelas menghasilkan akurasi $45,61\% \pm 9,99\%$ dan *F1-Score* $0,4476 \pm 0,1022$. Hasil *Repeated CV* yang jauh lebih stabil dan lebih tinggi dibandingkan *single split* pada Listing 4.4 (khususnya varian biner, dari *Kappa* negatif menjadi akurasi $77,73\%$) mengonfirmasi bahwa satu *random_state* tunggal pada *dataset* sekecil ini tidak cukup representatif, sehingga *Repeated CV* dipilih sebagai metrik evaluasi utama.

6. Penyimpanan Model

Setelah kedua varian Model A selesai dievaluasi melalui *Repeated Cross-Validation* pada Listing 4.5, model *best_bin* dan *best_3* beserta seluruh hasilnya perlu disimpan agar dapat digunakan kembali tanpa mengulang proses pelatihan. Kode 4.6 menunjukkan penyimpanan model, parameter, dan hasil Model A tersebut.

Listing 4.6 Penyimpanan Model A

```
# Simpan model
joblib.dump(best_bin, f'{OUT_DIR}/rf_66desa_binary_v4.pkl')
joblib.dump(best_3, f'{OUT_DIR}/rf_66desa_3kelas_v4.pkl')

# Simpan feature cols
with open(f'{OUT_DIR}/rf_66desa_feature_cols_v4.json', 'w') as f:
    json.dump(FEATURE_COLS, f, indent=2)

# Simpan params
params = {

    'binary': grid_bin.best_params_,
    '3kelas': grid_3.best_params_,
    'random_state_3kelas': chosen_rs,
    'test_size_3kelas' : TEST_SIZE_3KELAS,
    'label_names_binary' : LABEL_BINARY_NAMES,
    'label_names_3kelas' : LABEL_3KELAS_NAMES

}

with open(f'{OUT_DIR}/rf_66desa_params_v4.json', 'w') as f:
    json.dump(params, f, indent=2)
```

Model A disimpan dalam dua varian (biner dan 3 kelas) menggunakan format .pkl melalui *joblib*, beserta *file* JSON pendukung yang mencatat daftar fitur, kombinasi hiperparameter terbaik kedua varian, dan nilai *random_state* yang terpilih untuk skema 3 kelas. Seluruh metrik evaluasi dari tahap *single split*, CV $k=3$, dan *Repeated CV* turut disimpan ke *file* JSON terpisah agar dapat diakses kembali tanpa perlu menjalankan ulang seluruh proses pelatihan, dan hasil prediksi

terhadap seluruh 66 desa disimpan sebagai *file* CSV untuk keperluan sistem *WebGIS*.

4.4.2 Implementasi Model B (1.500 Titik Sampel)

1. Pemuatan Dataset dan Definisi Fitur

Dataset Model B dimuat dari *file* `dataset_B_v4_processed.csv` beserta daftar fitur yang tersimpan dari tahap *preprocessing*. Kode 4.7 menunjukkan pemuatan *dataset* Model B.

Listing 4.7 Definisi Fitur dan Pemuatan Dataset Model B

```
df = pd.read_csv(f'{PROC_DIR}/dataset_B_v4_processed.csv')

with open(f'{PROC_DIR}/feature_cols_B_v4.json') as f:
    FEATURE_COLS = json.load(f)

LABEL_COL = 'label'

X = df[FEATURE_COLS]
y = df[LABEL_COL]

print(f'Shape dataset : {df.shape}')
print(f'Fitur (X)      : {X.shape}')
print(f'\nDistribusi label:')
print(y.value_counts())
print(f'\nClass Imbalance Ratio: 1 : {(y==0).sum()/(y==1).sum():.2f}')
```

Berdasarkan Listing 4.7, *dataset* Model B berbentuk 1.500 baris dan 21 kolom, dengan 10 kolom di antaranya menjadi fitur (X berbentuk 1.500×10). Distribusi label menunjukkan 247 titik (16,5%) berlabel Rawan dan 1.253 titik (83,5%) berlabel Tidak Rawan, dengan rasio ketidakseimbangan kelas sebesar 1:5,07. Sama seperti Model A, daftar *FEATURE_COLS* dimuat dari *file* `feature_cols_B_v4.json`, bukan dituliskan ulang sebagai daftar literal.

2. Pembagian Data

Setelah *dataset* Model B berhasil dimuat pada Listing 4.7, langkah selanjutnya adalah membagi 1.500 titik sampel tersebut menjadi dua bagian

sebelum proses pelatihan dimulai, yaitu data yang digunakan untuk melatih model dan data yang disisihkan khusus untuk menguji kemampuan model pada titik yang belum pernah dipelajari. Kode 4.8 menunjukkan pembagian data Model B menjadi data latih dan data uji tersebut.

Listing 4.8 Pembagian Data Model B

```
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2,
    random_state=RANDOM_STATE, stratify=y
)

print(f'Train : {X_train.shape} | dist: {dict(y_train.value_counts())}')
print(f'Test  : {X_test.shape}  | dist: {dict(y_test.value_counts())}')
```

Berdasarkan Listing 4.8, *stratified split* 80:20 menghasilkan 1.200 data latih (1.002 Tidak Rawan + 198 Rawan) dan 300 data uji (251 Tidak Rawan + 49 Rawan), dengan parameter *stratify=y* menjaga proporsi kelas tetap terjaga pada kedua *subset*. Berbeda dengan Model A yang menggunakan strategi pencarian *random_state* adaptif untuk skema 3 kelas, Model B cukup menggunakan *split* standar karena hanya memiliki satu skema klasifikasi (biner) dengan ukuran sampel yang jauh lebih besar.

3. Model Baseline

Setelah data latih dan data uji terbentuk pada Listing 4.8, sebelum masuk ke tahap optimasi hiperparameter yang memakan waktu komputasi lebih lama, dibangun terlebih dahulu model *baseline* menggunakan kombinasi parameter yang sederhana (*n_estimators*=100 dengan parameter lain memakai nilai *default scikit-learn*). Model *baseline* ini berfungsi sebagai titik acuan awal, sehingga peningkatan performa yang diperoleh setelah *GridSearchCV* nantinya dapat diukur dan

dibandingkan secara jelas, bukan sekadar diasumsikan lebih baik. Kode 4.9 menunjukkan pembangunan model *baseline* tersebut.

Listing 4.9 *Model Baseline* untuk Model B

```
baseline = RandomForestClassifier(
    n_estimators=100,
    class_weight='balanced',
    random_state=RANDOM_STATE,
    n_jobs=-1
)
baseline.fit(X_train, y_train)

y_pred_base = baseline.predict(X_test)
y_proba_base = baseline.predict_proba(X_test)[:, 1]

acc_base = accuracy_score(y_test, y_pred_base)
f1_base = f1_score(y_test, y_pred_base, average='weighted')
auc_base = roc_auc_score(y_test, y_proba_base)

cv_k5 = StratifiedKFold(n_splits=5, shuffle=True,
    random_state=RANDOM_STATE)
cv_base = cross_val_score(baseline, X, y, cv=cv_k5, scoring='accuracy')

print('=== MODEL BASELINE ===')
print(f'Accuracy : {acc_base*100:.2f}%')
print(f'F1-Score : {f1_base:.4f}')
print(f'AUC-ROC : {auc_base:.4f}')
print(f'CV k=5 : {cv_base.mean()*100:.2f}% ± {cv_base.std()*100:.2f}%')
```

Berdasarkan Listing 4.9, model *baseline* dengan $n_estimators=100$ dan parameter lain menggunakan nilai *default scikit-learn* menghasilkan akurasi 84,33%, *F1-Score* 0,8084, *AUC-ROC* 0,8267, dan CV k=5 sebesar 84,80% ± 1,72%. Nilai ini menjadi tolok ukur pembandingan sebelum proses optimasi hiperparameter dijalankan.

4. Optimasi Hiperparameter (*GridSearchCV*)

Setelah model *baseline* pada Listing 4.9 menghasilkan angka acuan awal, tahap selanjutnya adalah mencari kombinasi hiperparameter yang lebih baik menggunakan *GridSearchCV*. Berbeda dengan Model A yang menggunakan *Stratified K-Fold* k=3 karena ukuran sampelnya kecil, Model B menggunakan *Stratified K-Fold* k=5, karena ukuran sampel yang jauh lebih besar (1.500 titik)

memungkinkan pembagian ke lebih banyak *fold* tanpa membuat tiap *fold* kekurangan sampel per kelas. Kode 4.10 menunjukkan implementasi *GridSearchCV* Model B tersebut.

Listing 4.10 *GridSearchCV* Model B

```
param_grid = {
    'n_estimators' : [100, 200, 300],
    'max_depth' : [None, 10, 20],
    'min_samples_split': [2, 5, 10],
    'min_samples_leaf' : [1, 2, 4],
    'class_weight' : ['balanced']
}

cv_k5 = StratifiedKFold(
    n_splits=5, shuffle=True, random_state=RANDOM_STATE
)

print('Total kombinasi : 81 × 5 folds = 405 fits')

grid_search = GridSearchCV(
    RandomForestClassifier(
        random_state=RANDOM_STATE, n_jobs=-1
    ),
    param_grid, cv=cv_k5,
    scoring='f1_weighted',
    n_jobs=-1, verbose=1
)
grid_search.fit(X_train, y_train)
```

Grid pencarian mencakup 81 kombinasi parameter dengan *cross-validation* $k=5$, sehingga total proses *fitting* yang dijalankan adalah 405 kali. Tabel 4.7 menyajikan ruang pencarian dan hiperparameter terbaik yang ditemukan untuk Model B.

Tabel 4.7 Ruang Pencarian dan *Hiperparameter* Terbaik Model B

Hiperparameter	Nilai yang Dicoba	Nilai Terbaik
<i>n_estimators</i>	100, 200, 300	200
<i>max_depth</i>	<i>None</i> , 10, 20	<i>None</i>
<i>min_samples_split</i>	2, 5, 10	10
<i>min_samples_leaf</i>	1, 2, 4	2

Hiperparameter	Nilai yang Dicoba	Nilai Terbaik
<i>class_weight</i>	<i>balanced</i>	<i>balanced</i>
<i>Best CV F1-Score</i>		0,8542

Untuk mengetahui sejauh mana proses optimasi hiperparameter memberikan perubahan terhadap performa model, hasil model *baseline* pada Listing 4.9 dibandingkan dengan hasil model setelah *GridSearchCV* pada Tabel 4.7. Tabel 4.6 menyajikan perbandingan tersebut.

5. Evaluasi Model B

Setelah kombinasi hiperparameter terbaik diperoleh dari *GridSearchCV* pada Listing 4.10, model tersebut diambil melalui *grid_search.best_estimator_* dan dievaluasi pada 300 data uji yang telah disisihkan sejak Listing 4.8, menggunakan enam metrik yang sama seperti pada model *baseline*, yaitu *Accuracy*, *F1-Score*, *AUC-ROC*, *Cohen's Kappa*, *MCC*, dan *CV Accuracy* $k=5$, agar dapat dibandingkan secara langsung dan setara dengan hasil model *baseline* pada Listing 4.9. Kode 4.11 menunjukkan evaluasi model teroptimasi pada data uji tersebut, sekaligus perbandingannya terhadap model *baseline*.

Listing 4.11 Evaluasi Model B pada Data Uji

```

best_model = grid_search.best_estimator_
y_pred = best_model.predict(X_test)
y_proba = best_model.predict_proba(X_test)[:, 1]

acc = accuracy_score(y_test, y_pred)
f1 = f1_score(y_test, y_pred, average='weighted')
auc = roc_auc_score(y_test, y_proba)
kappa = cohen_kappa_score(y_test, y_pred)
mcc = matthews_corrcoef(y_test, y_pred)

cv_scores = cross_val_score(best_model, X, y, cv=cv_k5, scoring='accuracy')
cv_mean = cv_scores.mean()
cv_std = cv_scores.std()

print('=== EVALUASI MODEL TEROPTIMASI ===')
print(f'Accuracy      : {acc*100:.2f}%')
print(f'F1-Score       : {f1:.4f}')
print(f'AUC-ROC         : {auc:.4f}')
print(f'Cohen Kappa     : {kappa:.4f}')
print(f'MCC            : {mcc:.4f}')
print(f'CV k=5           : {cv_mean*100:.2f}% ± {cv_std*100:.2f}%')

# Perbandingan Baseline vs Optimasi
print('\n=== PERBANDINGAN BASELINE vs TEROPTIMASI ===')
print(f'{"Metrik":<12s} | {"Baseline":<10s} | {"Optimasi":<10s} | {"Δ":<10s}')
print(f'{"-" * 50}')
print(f'{"Accuracy":<12s} | {acc_base*100:>8.2f}% | {acc*100:>8.2f}% | {(acc-acc_base)*100:+.2f}%')
print(f'{"F1-Score":<12s} | {f1_base:>10.4f} | {f1:>10.4f} | {f1-f1_base:+.4f}')
print(f'{"AUC-ROC":<12s} | {auc_base:>10.4f} | {auc:>10.4f} | {auc-auc_base:+.4f}')
print(f'{"CV k=5":<12s} | {cv_base.mean()*100:>8.2f}% | {cv_mean*100:>8.2f}% | {(cv_mean-cv_base.mean())*100:+.2f}%')

```

Berdasarkan Listing 4.11, model teroptimasi menghasilkan akurasi 84,33%, *F1-Score* 0,8399, *AUC-ROC* 0,8528, *Cohen's Kappa* 0,4022, dan *MCC* 0,4031. Tabel 4.8 merangkum perbandingan hasil model *baseline* dan model teroptimasi dari keluaran kode tersebut.

Tabel 4.8 Perbandingan Model *Baseline* dan Model setelah *GridsearchCV*

Metrik	<i>Baseline</i>	Setelah <i>GridSearchCV</i>
Akurasi	84,33%	84,33%
<i>F1-Score</i>	0,8084	0,8399
<i>AUC-ROC</i>	0,8267	0,8528

Metrik	<i>Baseline</i>	Setelah <i>GridSearchCV</i>
<i>CV Accuracy</i> k=5	84,80% $\pm$ 1,72%	82,93% $\pm$ 0,93%

Berdasarkan Tabel 4.8, proses optimasi hiperparameter tidak mengubah *Accuracy* pada data uji (tetap 84,33%), namun meningkatkan *F1-Score* dan *AUC-ROC*, yang berarti model teroptimasi lebih baik dalam menyeimbangkan *Presisi* dan *Recall* serta lebih baik dalam membedakan kedua kelas. Nilai *CV Accuracy* justru sedikit menurun ($-1,87\%$) namun dengan standar deviasi yang lebih kecil (0,93% dibanding 1,72%), menunjukkan performa model teroptimasi yang lebih stabil dan konsisten antar *fold*, meskipun rata-ratanya sedikit lebih rendah. Pembahasan lebih lanjut mengenai kategori nilai *Cohen's Kappa* dan *MCC* disajikan pada bagian Hasil Evaluasi Model B.

6. Penyimpanan Model

Setelah proses evaluasi pada Listing 4.11 menghasilkan model teroptimasi *best_model* beserta seluruh metrik performanya, tahap selanjutnya adalah menyimpan model tersebut ke *Google Drive* agar dapat digunakan kembali tanpa perlu menjalankan ulang seluruh proses pelatihan, sekaligus sebagai *file* yang nantinya di-*deploy* ke sistem *WebGIS* melalui *endpoint FastAPI*. Kode 4.12 menunjukkan penyimpanan model, parameter, dan hasil Model B tersebut.

Listing 4.12 Penyimpanan Model B

```
# Simpan model
joblib.dump(best_model, f'{OUT_DIR}/rf_1500titik_binary_v4.pkl')

# Feature cols
with open(f'{OUT_DIR}/rf_1500titik_feature_cols_v4.json', 'w') as f:
    json.dump(FEATURE_COLS, f, indent=2)

# Params
with open(f'{OUT_DIR}/rf_1500titik_params_v4.json', 'w') as f:
    json.dump(grid_search.best_params_, f, indent=2)

# Metrics
metrics = {
    'baseline': {
        'accuracy': round(acc_base, 4),
        'f1_score': round(f1_base, 4),
        'auc_roc' : round(auc_base, 4),
        'cv_accuracy_mean': round(cv_base.mean(), 4),
        'cv_accuracy_std' : round(cv_base.std(), 4)
    },
    'optimized': {
        'accuracy': round(acc, 4),
        'f1_score': round(f1, 4),
        'auc_roc' : round(auc, 4),
        'cohen_kappa': round(kappa, 4),
        'mcc'      : round(mcc, 4),
        'cv_accuracy_mean': round(cv_mean, 4),
        'cv_accuracy_std' : round(cv_std, 4),
        'best_cv_f1' : round(grid_search.best_score_, 4)
    },
    'confusion_matrix': {
        'TP': int(tp), 'TN': int(tn),
        'FP': int(fp), 'FN': int(fn)
    }
}

with open(f'{OUT_DIR}/rf_1500titik_metrics_v4.json', 'w') as f:
    json.dump(metrics, f, indent=2)

# Prediksi WebGIS
df_pred.to_csv(f'{OUT_DIR}/rf_1500titik_prediksi_webgis_v4.csv',
index=False)
```

Model B disimpan menggunakan format `.pkl` melalui *joblib*, beserta *file* JSON pendukung yang mencatat daftar fitur, kombinasi hiperparameter terbaik, dan seluruh metrik evaluasi baik *baseline* maupun teroptimasi. Nilai *tp*, *tn*, *fp*, *fn* pada blok `metrics['confusion_matrix']` dihitung pada tahap visualisasi *Confusion Matrix* sebelumnya (belum tercakup dalam Listing 4.7–4.11 di atas). Hasil prediksi terhadap seluruh 1.500 titik disimpan sebagai *file* CSV untuk keperluan sistem *WebGIS*.

4.4.3 Perbandingan Implementasi Model A dan Model B

Tabel 4.9 merangkum perbandingan implementasi teknis kedua model secara menyeluruh.

Tabel 4.9 Perbandingan Implementasi Model A dan Model B

Aspek	Model A	Model B
Nama kolom fitur	dem_mean, slope_mean, dst.	dem, slope, dst.
Kolom label	label_binary / label_3kelas	label
<i>Dataset shape</i>	(66, 17)	(1.500, 21)
Distribusi label	51R (77,3%) / 15TR (22,7%)	247R (16,5%) / 1.253TR (83,5%)
Jumlah kelas target	2 kelas + 3 kelas	2 kelas
Data latih / uji	52 / 14 (biner), 46 / 20 (3 kelas)	1.200 / 300
<i>CV GridSearchCV</i>	k=3, 243 <i>fits</i>	k=5, 405 <i>fits</i>
<i>n_estimators</i> terbaik	100 (biner) / 200 (3 kelas)	200
<i>max_depth</i> terbaik	None	None
<i>min_samples_leaf</i> terbaik	1	2
<i>min_samples_split</i> terbaik	5 (biner) / 2 (3 kelas)	10
Best CV F1	-	0,8542
Metrik evaluasi utama	<i>Repeated CV</i> (3×10)	CV k=5 + <i>test set</i>

Perbedaan paling mendasar antara kedua model terletak pada jumlah kelas target dan unit analisis. Model A memiliki dua varian klasifikasi karena basis labelnya menggunakan persentase luas terdampak per desa yang memiliki gradasi

nilai kontinu sehingga dapat dibagi menjadi beberapa kategori kerawanan. Model B hanya menggunakan klasifikasi biner karena data *ground truth* berupa peta area terdampak banjir 31 Januari 2026 hanya mencatat ada atau tidaknya genangan pada suatu titik tanpa informasi kedalaman inundasi. Perbedaan pendekatan evaluasi juga mencerminkan perbedaan ukuran data — Model A menggunakan *Repeated CV* karena $n=66$ terlalu kecil untuk *single split* yang stabil, sementara Model B dengan $n=1.500$ cukup untuk evaluasi data uji yang representatif.

4.5 Hasil Evaluasi Model A (66desa/kelurahan)


Evaluasi Model A dilakukan terhadap dua varian klasifikasi, yaitu klasifikasi biner (Tidak Rawan/Rawan) dan klasifikasi 3 kelas (Tidak Rawan/Rawan/Sangat Rawan), dengan unit analisis 66 desa/kelurahan Kota Langsa. Mengingat ukuran sampel yang sangat kecil ($n=66$), metode evaluasi utama yang digunakan adalah *Repeated Stratified K-Fold Cross-Validation* ($3 \text{ folds} \times 10 \text{ repeats} = 30 \text{ evaluasi}$), sedangkan evaluasi *single train-test split* disajikan sebagai pelengkap. Selain kedua metode tersebut, dilakukan juga evaluasi menggunakan *Matriks Pembandingan* per Desa, yaitu membandingkan prediksi model terhadap seluruh 66 desa dengan label historis aktual, untuk memberikan gambaran konsistensi model terhadap kondisi lapangan secara keseluruhan.

4.5.1 Hasil Evaluasi Klasifikasi Biner

Klasifikasi biner membagi 66 desa ke dalam dua kelas, yaitu Tidak Rawan (label 0) dan Rawan (label 1). Pembagian data menggunakan *stratified split* 80:20 menghasilkan 52 data latih (40 Rawan + 12 Tidak Rawan) dan 14 data uji (11 Rawan + 3 Tidak Rawan).

1. Hasil Evaluasi *Confusion Matrix*

Gambar 4.26 menampilkan *confusion matrix* hasil prediksi model biner pada 14 data uji.



Gambar 4.25 *Confusion Matrix* Model A Klasifikasi Biner (n=14)

Berdasarkan *confusion matrix* pada Gambar 4.26, rincian prediksi model disajikan pada Tabel 4.10.

Tabel 4.10 *Confusion Matrix* Model A Biner pada Data Uji

	Prediksi Tidak Rawan	Prediksi Rawan
Tidak Rawan	TN = 0	FP = 3
Rawan	FN = 2	TP = 9

Dari 14 data uji, model berhasil memprediksi 9 dari 11 desa Rawan dengan benar (TP=9), namun tidak berhasil mengidentifikasi satu pun desa Tidak Rawan dengan benar (TN=0 — seluruh 3 desa Tidak Rawan diprediksi sebagai Rawan). Kondisi ini mencerminkan bahwa model cenderung bias ke kelas mayoritas (Rawan) yang mendominasi 77,3% dari total *dataset*. Nilai *accuracy* pada *single split* sebesar 64,29% dengan *Cohen's Kappa* -0,2069 mencerminkan ketidakstabilan evaluasi pada ukuran data uji yang sangat kecil (14 sampel), di mana satu prediksi salah setara dengan penurunan akurasi 7,14%. Oleh karena itu, hasil *single split* ini tidak dapat dijadikan representasi performa generalisasi model yang sesungguhnya.

2. Hasil *GridSearchCV*

Proses optimasi hiperparameter menggunakan *GridSearchCV* dengan *Stratified K-Fold* $k=3$ dan 243 kombinasi *fitting* menghasilkan hiperparameter terbaik untuk model biner. Tabel 4.11 menyajikan hiperparameter terbaik yang ditemukan beserta nilai *Best CV F1-Score* yang dicapai selama proses pencarian.

Tabel 4.11 Hiperparameter *GridSearchCV* Terbaik Model A Biner

Hiperparameter	Nilai Terbaik
<i>n_estimators</i>	100
<i>max_depth</i>	<i>None</i>

Hiperparameter	Nilai Terbaik
<i>min_samples_leaf</i>	1
<i>min_samples_split</i>	5
<i>class_weight</i>	<i>balanced</i>
<i>Best CV F1-Score</i>	0,8133

Berdasarkan Tabel 4.11, kombinasi *n_estimators*=100 dengan *max_depth*=None berarti setiap pohon tumbuh sepenuhnya tanpa pembatasan kedalaman, sementara *min_samples_leaf*=1 dan *min_samples_split*=5 menjadi satu-satunya bentuk regularisasi yang membatasi ukuran pohon minimal pada tahap pemisahan simpul. Kombinasi ini menghasilkan *Best CV F1-Score* sebesar 0,8133 selama proses pencarian, meskipun nilai ini dievaluasi pada data latih (52 desa) melalui *cross-validation*, bukan pada data uji yang sebelumnya dibahas pada bagian *Confusion Matrix*.

3. Hasil *Repeated Cross-Validation*

Untuk mendapatkan estimasi performa yang lebih stabil dan representatif, digunakan *Repeated Stratified K-Fold Cross-Validation* dengan 3 *folds* yang diulang sebanyak 10 kali. Tabel 4.12 merangkum perbandingan seluruh metode evaluasi yang digunakan untuk klasifikasi biner.

Tabel 4.12 Hasil Evaluasi *Repeated CV* Model A Klasifikasi Biner

Metode Evaluasi	<i>Accuracy</i>	<i>F1-Score</i>	<i>AUC-ROC</i>
<i>Single Split</i> (n=14)	64,29%	0,6149	0,6061
CV k=3	77,27% $\pm$ 9,82%	—	—
<i>Repeated CV</i> 3 $\times$ 10	77,73% $\pm$ 8,41%	0,7541 $\pm$ 0,0763	0,6749 $\pm$ 0,1139


Berdasarkan Tabel 4.12, *Repeated CV* menghasilkan *accuracy* rata-rata **77,73% $\pm$ 8,41%** dengan *F1-Score* 0,7541 $\pm$ 0,0763 dan *AUC-ROC* 0,6749 $\pm$ 0,1139 dari 30 iterasi evaluasi. Konsistensi antara CV k=3 (77,27%) dan *Repeated CV* (77,73%) mengkonfirmasi bahwa estimasi performa ini tidak bergantung pada satu konfigurasi *fold* tertentu. Nilai *AUC-ROC* sebesar 0,6749 menunjukkan model memiliki kemampuan diskriminasi yang lebih baik dari prediksi acak (0,5).

4.5.2 Hasil Evaluasi Klasifikasi 3 Kelas

Selain skema klasifikasi biner Model A juga dilatih menggunakan skema klasifikasi 3 kelas untuk melihat apakah pembagian tingkat kerawanan yang lebih rinci dapat memberikan gambaran yang lebih informatif dibandingkan klasifikasi Rawan/Tidak Rawan saja. Klasifikasi 3 kelas membagi 66 desa berdasarkan persentase luas terdampak banjir ke dalam tiga kategori, yaitu Tidak Rawan (label 1, 15 desa), Rawan (label 2, 29 desa), dan Sangat Rawan (label 3, 22 desa), mengacu pada Peraturan Kepala BNPB Nomor 2 Tahun 2012. Berbeda dengan skema biner yang menggunakan *test_size* 20%, skema 3 kelas menggunakan *test_size* 30% dengan pencarian *random_state* adaptif (sebagaimana ditunjukkan pada Listing 4.2), menghasilkan 46 data latih dan 20 data uji, agar ketiga kelas tetap terwakili pada data uji meskipun ukuran sampel per kelas cukup kecil.

1. Hasil Evaluasi *Confusion Matrix*

Gambar 4.27 menampilkan *confusion matrix* hasil prediksi model 3 kelas pada 20 data uji.



Gambar 4.26 *Confusion Matrix* Model A Klasifikasi 3 Kelas (n=20)

Karena skema 3 kelas melibatkan sembilan kombinasi hasil prediksi, rincian nilai pada Gambar 4.27 disajikan kembali dalam bentuk tabel numerik. Tabel 4.13 merangkum rincian *confusion matrix* tersebut.

Tabel 4.13 *Confusion Matrix* Model A Klasifikasi 3 Kelas (n=20)

	Prediksi Tidak Rawan	Prediksi Rawan	Prediksi Sangat Rawan
Aktual Tidak Rawan	1	2	1
Aktual Rawan	0	5	4
Aktual Sangat Rawan	1	4	2

Berdasarkan Tabel 4.13, dari 20 data uji, model memprediksi dengan benar sebanyak 8 data (1 Tidak Rawan, 5 Rawan, dan 2 Sangat Rawan), setara dengan akurasi 40,00%. Kelas Rawan aktual diklasifikasikan Sangat Rawan sebanyak 4 kali dan kelas Sangat Rawan aktual diklasifikasikan Rawan sebanyak 4 kali, menunjukkan model paling sering keliru pada dua kelas yang berdekatan tingkat kerawanannya, bukan pada kelas yang berjauhan (Tidak Rawan tertukar Sangat Rawan hanya terjadi 1 kali). *F1-Score* sebesar 0,3917 yang jauh di bawah skema biner (0,6149 pada *single split*) turut mengonfirmasi kesulitan model dalam menyeimbangkan *Presisi* dan *Recall* pada ketiga kelas secara bersamaan. Nilai *Cohen's Kappa* sebesar 0,0164 mendekati nol dan masuk kategori *Slight* menunjukkan tingkat kesepakatan antara prediksi model dan label aktual yang hanya sedikit lebih baik dibandingkan tebakan acak semata.

2. Hasil *GridSearchCV*

Sama seperti skema biner, optimasi hiperparameter untuk skema 3 kelas menggunakan *GridSearchCV* dengan *Stratified K-Fold* $k=3$. Tabel 4.14 menyajikan hiperparameter terbaik yang ditemukan untuk skema 3 kelas.

Tabel 4.14 Hiperparameter *GridSearchCV* Terbaik Model A 3 Kelas

<i>Hiperparameter</i>	<i>Nilai Terbaik</i>
<i>n_estimators</i>	200
<i>max_depth</i>	<i>None</i>
<i>min_samples_leaf</i>	1
<i>min_samples_split</i>	2
<i>class_weight</i>	<i>balanced</i>
<i>Best CV F1-Score</i>	0,5823

Berdasarkan Tabel 4.14, *Best CV F1-Score* sebesar 0,5823 pada skema 3 kelas jauh lebih rendah dibandingkan skema biner (0,8133 pada Tabel 4.9), mengindikasikan bahwa proses pemisahan tiga kelas sekaligus jauh lebih menantang bagi model dibandingkan dua kelas, sejalan dengan berkurangnya jumlah sampel latih per kategori.

3. Hasil Repeated Cross-Validation

Pada Tabel 4.15 merangkum perbandingan seluruh metode evaluasi yang digunakan untuk klasifikasi 3 kelas.

Tabel 4.15 Hasil Evaluasi *Repeated CV* Model A Klasifikasi 3 Kelas


Metode Evaluasi	<i>Accuracy</i>	<i>F1-Score</i>	<i>Cohen's Kappa</i>
<i>Single Split</i> (n=20)	40,00%	0,3917	0,0164
<i>CV k=3</i>	50,00% ± 9,82%	—	—
<i>Repeated CV 3×10</i>	45,61% ± 9,99%	0,4476 ± 0,1022	—

Berdasarkan Tabel 4.15, *Repeated CV* menghasilkan *accuracy* rata-rata 45,61% ± 9,99% dari 30 iterasi evaluasi, jauh lebih rendah dibandingkan skema biner (77,73%). Nilai *Cohen's Kappa* pada *single split* sebesar 0,0164 (mendekati 0, kategori *Slight*) menunjukkan tingkat kesepakatan yang rendah antara prediksi dan label aktual. Penurunan performa pada skema 3 kelas ini konsisten dengan

berkurangnya jumlah sampel latih per kelas dibandingkan skema biner (rata-rata 15 desa per kelas dibandingkan 33 desa per kelas pada biner), sehingga model memiliki lebih sedikit contoh untuk mempelajari pola tiap kategori.


4.5.3 *Feature Importance*

Analisis *feature importance* dilakukan terhadap kedua varian model untuk mengidentifikasi kontribusi masing-masing variabel terhadap keputusan klasifikasi. Gambar 4.28 menampilkan diagram *feature importance* Model A untuk varian biner.



Gambar 4.27 *Feature Importance* Model A Klasifikasi Biner

Gambar 4.28 berikut menampilkan diagram *feature importance* Model A untuk varian 3 kelas.



Gambar 4.28 *Feature Importance* Model A Klasifikasi 3 Kelas

Diagram batang pada Gambar 4.28 dan 4.29 memberikan gambaran visual mengenai variabel mana yang paling berpengaruh pada masing-masing varian, namun karena kedua diagram tersebut ditampilkan secara terpisah, perbandingan nilai kontribusi setiap variabel antara varian biner dan 3 kelas akan lebih mudah dilakukan apabila disajikan berdampingan dalam satu tabel. Selain itu, bentuk tabel juga memungkinkan pembacaan nilai *feature importance* hingga empat angka desimal secara tepat, yang sulit diperoleh hanya dari membaca panjang batang pada diagram. Tabel 4.16 merangkum nilai *feature importance* seluruh 10 variabel untuk kedua varian berdasarkan Gambar 4.28 dan 4.29

Tabel 4.16 *Feature Importance* Model A Biner dan 3 Kelas

Peringkat (Biner)	Variabel	Biner	3 Kelas
1	Jarak Jalan	0,3156	0,2291
2	DEM (Elevasi)	0,1722	0,1345
3	<i>Curvature</i>	0,1122	0,0992
4	HAND	0,1052	0,1165

Peringkat (Biner)	Variabel	Biner	3 Kelas
5	Jarak Sungai	0,0986	0,1422
6	<i>Slope</i>	0,0965	0,1161
7	TWI	0,0828	0,1236
8	LULC Skor	0,0139	0,0310
9	Jenis Tanah Skor	0,0031	0,0076
10	Curah Hujan Skor	0,0000	0,0000

Berdasarkan Tabel 4.16, jarak jalan merupakan variabel dengan kontribusi tertinggi pada kedua varian (0,3156 untuk biner dan 0,2291 untuk 3 kelas), diikuti oleh DEM pada posisi kedua untuk varian biner. Dominasi jarak jalan pada Model A berbeda dengan Model B yang menempatkan DEM sebagai variabel terpenting. Perbedaan ini wajar karena Model A menggunakan agregasi *Zonal Statistics* per desa sehingga variabel jarak jalan yang merepresentasikan tingkat urbanisasi dan kepadatan infrastruktur lebih berkorelasi dengan pola kerawanan historis di level desa. Pada varian 3 kelas, distribusi *feature importance* lebih merata dibandingkan varian biner, dengan jarak sungai dan TWI meningkat signifikan karena kedua variabel tersebut relevan untuk membedakan gradasi tingkat kerawanan yang lebih halus. Curah hujan skor memiliki *feature importance* 0,0000 pada kedua varian karena seluruh desa Kota Langsa memiliki nilai skor yang seragam sehingga tidak memberikan kontribusi diferensiasi apapun.

4.5.4 Matriks Pembandingan per Desa

Setelah performa Model A dievaluasi melalui *Repeated Cross-Validation* pada kedua varian klasifikasi, dilakukan pula evaluasi tambahan berupa *Matriks Pembandingan* per Desa. Berbeda dengan *Repeated CV* yang hanya mengevaluasi

pada porsi data uji secara bergantian, Matriks Pembanding menjalankan model biner terbaik terhadap seluruh 66 desa dan membandingkan hasilnya dengan label historis aktual, untuk memberikan gambaran seberapa konsisten prediksi model dengan kondisi kerawanan banjir yang tercatat di seluruh wilayah Kota Langsa, bukan hanya pada 14 desa yang sempat menjadi data uji. Tabel 4.17 menyajikan hasil perbandingan prediksi model terhadap 66 desa secara keseluruhan.

Tabel 4.17 Matriks Pembanding Model A per Desa (n=66)

	Prediksi Tidak Rawan	Prediksi Rawan	Total Aktual
Aktual Tidak Rawan	TN = 12	FP = 3	15
Aktual Rawan	FN = 2	TP = 49	51
Total Prediksi	14	52	66

Berdasarkan Tabel 4.17, dari 66 desa, model berhasil memprediksi dengan benar 49 desa Rawan (TP=49) dan 12 desa Tidak Rawan (TN=12), sehingga total prediksi benar adalah 61 dari 66 desa. Terdapat 3 desa Tidak Rawan aktual diklasifikasikan Rawan (FP) dan 2 desa Rawan aktual diklasifikasikan Tidak Rawan (FN). Tabel 4.18 merangkum metrik evaluasi dari hasil matriks pembanding ini.

Tabel 4.18 Metrik Evaluasi *Matriks Pembanding* Model A per Desa

Metrik	Nilai
Akurasi per Desa	92,42%
<i>Cohen's Kappa</i>	0,7791
Kategori <i>Kappa</i>	<i>Substantial</i>
TP	49 desa

Metrik	Nilai
TN	12 desa
FP	3 desa
FN	2 desa

Berdasarkan Tabel 4.18, akurasi matriks pembanding sebesar 92,42% dengan *Cohen's Kappa* 0,7791 yang masuk kategori *Substantial* menunjukkan tingkat kesepakatan yang tinggi antara prediksi model dengan data historis aktual, jauh lebih tinggi dibandingkan hasil *single split* pada 14 data uji (akurasi 64,29%, *Cohen's Kappa* -0,2069). Perbedaan ini terjadi karena Matriks Pembanding menjalankan model pada 66 desa sekaligus (termasuk 52 desa yang sudah dipelajari model saat pelatihan), sehingga tidak dapat disamakan dengan evaluasi generalisasi murni seperti *Repeated CV*, namun tetap memberikan bukti bahwa model konsisten dengan kondisi kerawanan banjir di seluruh wilayah kota. Jumlah *False Negative* yang hanya 2 desa mengindikasikan model sangat jarang melewati desa yang sebenarnya rawan kondisi yang penting dalam konteks mitigasi bencana, karena desa Rawan aktual diklasifikasikan Tidak Rawan berisiko tidak mendapatkan penanganan preventif yang diperlukan.

4.5.5 Ringkasan Evaluasi Model A

Ringkasan evaluasi model merangkum keseluruhan hasil evaluasi Model A yang telah dibahas, yang mencakup kedua varian klasifikasi yaitu klasifikasi biner dan 3 kelas serta hasil dari akurasi perbandingan dengan matriks pembanding per desa. Tabel 4.19 berikut merangkum seluruh hasil evaluasi Model A dari keempat metode yang digunakan.

Tabel 4.19 Ringkasan Seluruh Hasil Evaluasi Model A

Metrik	Biner	3 Kelas
Distribusi label	51R (77,3%) / 15TR (22,7%)	15TR (22,7%) / 29R (43,9%) / 22SR (33,3%)
Data latih / uji	52 / 14	46 / 20
<i>Best n_estimators</i>	100	200
<i>Best CV F1 (GridSearchCV)</i>	0,8133	0,5823
<i>Repeated CV Accuracy</i>	77,73% $\pm$ 8,41%	45,61% $\pm$ 9,99%
<i>Repeated CV F1-Score</i>	0,7541 $\pm$ 0,0763	0,4476 $\pm$ 0,1022
<i>Repeated CV AUC-ROC</i>	0,6749 $\pm$ 0,1139	—
Akurasi Matriks <i>Pembanding</i> (n=66)	92,42%	—
<i>Cohen's Kappa Matriks Pembanding</i>	0,7791 (<i>Substantial</i>)	—

Berdasarkan Tabel 4.19, secara keseluruhan Model A biner menghasilkan performa yang lebih baik dan lebih stabil dibandingkan varian 3 kelas. Hasil matriks pembanding per desa yang mencapai 92,42% dengan *Kappa Substantial* menjadi bukti kuat bahwa model mampu mengklasifikasikan seluruh wilayah Kota Langsa secara konsisten dengan data historis banjir yang tercatat. Oleh karena itu, Model A biner digunakan sebagai dasar evaluasi utama dalam perbandingan dengan Model B dan KRB Kota Langsa pada.

4.6 Hasil Evaluasi Model B (1.500 Titik Sampel)

Evaluasi Model B dilakukan terhadap klasifikasi biner (Tidak Rawan/Rawan) pada 1.500 titik sampel yang tersebar di seluruh wilayah Kota Langsa. Model B merupakan model utama yang diintegrasikan ke dalam sistem *WebGIS* untuk

melayani prediksi klasifikasi kerawanan banjir berbasis titik koordinat. Berbeda dengan Model A yang menggunakan *Repeated CV* sebagai metrik utama, Model B memiliki ukuran *test set* yang cukup besar (300 sampel) sehingga evaluasi pada *test set* dapat dijadikan representasi performa generalisasi yang reliabel.

4.6.1 Hasil *GridSearchCV*

Pada Tabel 4.20 berikut menyajikan hiperparameter terbaik yang ditemukan beserta nilai *Best CV F1-Score*.

Tabel 4.20 Hiperparameter Terbaik Model B

Hiperparameter	Nilai Terbaik
<i>n_estimators</i>	200
<i>max_depth</i>	None
<i>min_samples_leaf</i>	2
<i>min_samples_split</i>	10
<i>class_weight</i>	<i>balanced</i>
<i>Best CV F1-Score</i>	0,8542

Berdasarkan Tabel 4.20, nilai *min_samples_split*=10 dan *min_samples_leaf*=2 berfungsi sebagai regularisasi yang mencegah *overfitting* tanpa perlu membatasi kedalaman pohon. *Best CV F1-Score* sebesar 0,8542 lebih tinggi dibandingkan Model A biner (0,8133) yang mencerminkan keunggulan Model B akibat dataset yang jauh lebih besar.

4.6.2 Perbandingan Model *Baseline* dan Model *Teroptimasi*

Sebelum *GridSearchCV* dijalankan, dibangun model *baseline* menggunakan parameter *default* sebagai tolok ukur awal. Tabel 4.21 berikut menyajikan perbandingan performa model *baseline* dengan model teroptimasi.


Tabel 4.21 Perbandingan *Baseline* Model dan *GridSearchCV* pada Model B

Metrik	<i>Baseline</i>	<i>Teroptimasi</i>	Perubahan
Akurasi	84,33%	84,33%	—
<i>F1-Score</i>	0,8084	0,8399	+0,0315
<i>AUC-ROC</i>	0,8267	0,8528	+0,0261
CV Std k=5	1,72%	0,93%	Lebih stabil

Berdasarkan Tabel 4.21, peningkatan paling signifikan setelah optimasi terlihat pada *F1-Score* (+0,0315) dan *AUC-ROC* (+0,0261). Standar deviasi CV yang mengecil (1,72% → 0,93%) menunjukkan model teroptimasi lebih konsisten antar *fold*.

4.6.3 Evaluasi pada Data Uji

Evaluasi model teroptimasi dilakukan terhadap 300 data uji. Gambar 4.30 berikut menampilkan *confusion matrix* hasil prediksi Model B pada 300 data uji.



Gambar 4.29 *Confusion Matrix* Model B (n=300)

Berdasarkan *confusion matrix* pada Gambar 4.30, rincian prediksi model disajikan pada Tabel 4.22 berikut.

Tabel 4.22 *Confusion Matrix* Model B pada Data Uji (n=300)


	Prediksi Tidak Rawan	Prediksi Rawan
Aktual Tidak Rawan	TN = 230	FP = 21
Aktual Rawan	FN = 26	TP = 23

Berdasarkan Tabel 4.22, dari 300 data uji model berhasil memprediksi 230 titik Tidak Rawan (TN=230) dan 23 titik Rawan (TP=23) dengan benar. Terdapat 21 *False Positive* dan 26 *False Negative*. Tabel 4.23 berikut merangkum seluruh metrik evaluasi Model B pada data uji beserta hasil *Cross-Validation* k=5.

Tabel 4.23 Hasil Evaluasi Model B pada Data Uji

Metrik	Nilai	Keterangan
Akurasi	84,33%	
<i>F1-Score</i>	0,8399	<i>Weighted</i>
<i>AUC-ROC</i>	0,8528	
<i>Cohen's Kappa</i>	0,4022	<i>Moderate</i>
<i>MCC</i>	0,4031	
<i>CV Accuracy k=5</i>	82,93% $\pm$ 0,93%	

Berdasarkan Tabel 4.23, Model B menghasilkan akurasi **84,33%** dengan *Cohen's Kappa* **0,4022** kategori *Moderate* yang mengkonfirmasi kesepakatan antara prediksi model dengan label aktual jauh melampaui tingkat kebetulan semata. *MCC* sebesar **0,4031** memperkuat bahwa model memberikan prediksi yang seimbang pada kedua kelas meskipun terdapat ketidakseimbangan distribusi (16,5% vs 83,5%). Perbedaan antara akurasi *test set* (84,33%) dan CV k=5 (82,93%) yang hanya 1,4% mengindikasikan tidak terjadi *overfitting* yang signifikan. Gambar 4.31 berikut menampilkan kurva ROC Model B yang menggambarkan kemampuan diskriminasi model pada berbagai nilai *threshold*.




Gambar 4.30 Kurva ROC Model B

Berdasarkan Gambar 4.31, *AUC-ROC* sebesar **0,8528** menunjukkan kemampuan diskriminasi model yang baik dalam memisahkan kelas Rawan dan Tidak Rawan, di mana nilai ini mendekati 1,0 yang merepresentasikan *classifier* yang sempurna.

4.6.4 Feature Importance

Analisis *feature importance* dilakukan untuk mengidentifikasi kontribusi masing-masing variabel terhadap keputusan klasifikasi Model B. Gambar 4.32 berikut menampilkan diagram *feature importance* Model B.



Gambar 4.31 *Feature Importance Model B*

Berdasarkan Gambar 4.32, rincian nilai *feature importance* seluruh 10 variabel disajikan pada Tabel 4.24 berikut.

Tabel 4.24 *Feature Importance Model B*

Peringkat	Variabel	<i>Importance</i>
1	DEM (Elevasi)	0,2599
2	Jarak Jalan	0,1655
3	<i>Slope</i>	0,1123
4	HAND	0,1096
5	TWI	0,0914
6	Jarak Sungai	0,0775
7	<i>Curvature</i>	0,0691
8	LULC Skor	0,0671
9	Jenis Tanah Skor	0,0476
10	Curah Hujan Skor	0,0000

Berdasarkan Tabel 4.24, DEM merupakan variabel dengan kontribusi tertinggi (0,2599), diikuti jarak jalan (0,1655) dan *slope* (0,1123). Dominasi DEM berbeda dengan Model A yang menempatkan jarak jalan sebagai variabel terpenting — perbedaan ini terjadi karena Model B menggunakan nilai tepat pada koordinat titik (*Sample Raster Values*) sehingga variasi elevasi antar titik lebih tinggi dan lebih diskriminatif dibandingkan nilai rata-rata per desa. HAND menempati posisi keempat (0,1096) yang konsisten dengan perannya sebagai salah satu kriteria pembentukan label *ground truth*. Curah hujan skor memiliki *feature importance* **0,0000** karena seluruh wilayah Kota Langsa memiliki nilai skor yang seragam sehingga tidak memberikan kontribusi diferensiasi apapun dalam proses klasifikasi.

4.6.5 Ringkasan Evaluasi Model B

Tabel 4.25 berikut merangkum seluruh hasil evaluasi Model B secara komprehensif.

Tabel 4.25 Ringkasan Evaluasi Model B

Aspek	Nilai
Distribusi label	247R (16,5%) / 1.253TR (83,5%)
<i>Best n_estimators</i>	200
<i>Best CV F1 (GridSearchCV)</i>	0,8542
Akurasi	84,33%
<i>F1-Score</i>	0,8399
<i>AUC-ROC</i>	0,8528
<i>Cohen's Kappa</i>	0,4022 (Moderate)

Aspek	Nilai
<i>MCC</i>	0,4031
<i>CV Accuracy k=5</i>	82,93% $\pm$ 0,93%
<i>TP / TN / FP / FN</i>	23 / 230 / 21 / 26
Variabel terpenting	DEM (0,2599), Jarak Jalan (0,1655)

Berdasarkan Tabel 4.25, Model B berhasil mencapai performa yang baik dan konsisten dengan akurasi 84,33%, *Cohen's Kappa* 0,4022 (*Moderate*), dan standar deviasi CV yang sangat kecil ($\pm 0,93\%$). Dominasi DEM dan jarak jalan sebagai dua variabel terpenting mencerminkan bahwa karakteristik topografi dan infrastruktur wilayah merupakan penentu utama kerawanan banjir di Kota Langsa pada level titik sampel.

4.7 Perbandingan Hasil Klasifikasi dengan KRB Kota Langsa

Perbandingan dilakukan antara hasil klasifikasi model dengan Kajian Risiko Bencana (KRB) Kota Langsa Tahun 2024–2029 yang diterbitkan oleh BNPB. KRB merupakan dokumen resmi pemerintah yang menjadi acuan perencanaan penanggulangan bencana di tingkat daerah. Perbandingan ini bertujuan untuk menilai sejauh mana hasil klasifikasi model yang berbasis *Machine Learning* dan data geospasial konsisten dengan penilaian resmi yang mempertimbangkan bahaya, kerentanan, dan kapasitas secara bersamaan. Perbandingan dilakukan pada tingkat kecamatan karena KRB menyajikan data pada tingkat resolusi tersebut.

4.7.1 Data KRB Kota Langsa

Sebelum membandingkan hasil model dengan KRB, perlu dipahami bahwa KRB membedakan dua konsep yang berbeda, yaitu kelas bahaya dan kelas risiko. Kedua kelas ini dihasilkan dari proses analisis yang berbeda dan merepresentasikan aspek yang berbeda pula dari ancaman bencana.

Kelas Bahaya (*Hazard Class*) merupakan penilaian terhadap potensi fisik suatu wilayah untuk terdampak banjir berdasarkan karakteristik alam seperti topografi, morfologi sungai, ketinggian genangan, dan luas area yang berpotensi tergenang. Kelas bahaya bersifat murni fisik — tidak mempertimbangkan apakah ada manusia, bangunan, atau aset yang berada di area tersebut. Sebuah wilayah hutan yang terpencil dapat memiliki kelas bahaya TINGGI jika secara fisik sering tergenang, namun kelas risikonya bisa sangat rendah karena tidak ada manusia yang terdampak.

Kelas Risiko (*Risk Class*) merupakan penilaian yang mempertimbangkan interaksi tiga komponen sekaligus, yaitu bahaya, kerentanan, dan kapasitas. Kerentanan mencakup potensi penduduk terpapar, kerugian ekonomi, dan kerusakan lingkungan. Kapasitas mencakup kemampuan masyarakat dan pemerintah dalam menghadapi, merespons, dan memulihkan diri dari bencana. Kelas risiko diperoleh dari kombinasi ketiga komponen tersebut, sehingga suatu wilayah dengan bahaya besar dapat memperoleh kelas risiko yang lebih rendah apabila kerentanannya kecil atau kapasitasnya memadai, dan sebaliknya. Sebagai contoh, Kecamatan Langsa Timur memiliki kelas bahaya TINGGI namun kelas risiko SEDANG, karena kapasitas masyarakat Langsa Timur dalam menghadapi

banjir dinilai cukup, sehingga risiko akhirnya termoderasi. Sebaliknya, Kecamatan Langsa Baro mendapat kelas risiko TINGGI meskipun luas bahayanya lebih kecil dari Langsa Timur, karena kepadatan penduduk dan kerentanan sosial-ekonominya lebih besar.

Penelitian ini menggunakan variabel geospasial fisik, sehingga hasil klasifikasi model paling setara untuk dibandingkan dengan kelas bahaya KRB, bukan kelas risiko. Perbandingan dengan kelas risiko tetap disajikan sebagai informasi tambahan, dengan memahami bahwa perbedaan yang muncul antara model dan kelas risiko KRB bersumber dari komponen kerentanan dan kapasitas sosial yang tidak dimodelkan dalam penelitian ini. Tabel 4.26 menyajikan data bahaya dan risiko banjir per kecamatan dari KRB Kota Langsa Tahun 2024

Tabel 4.26 Bahaya dan Risiko Banjir per Kecamatan (KRB Kota Langsa 2024)

Kecamatan	Total Luas (Ha)	Luas Bahaya Tinggi (Ha)	Kelas Bahaya	Kelas Risiko
Langsa Barat	4.629,40	1.044,66	TINGGI	SEDANG
Langsa Baro	1.879,37	514,37	TINGGI	TINGGI
Langsa Kota	503,45	39,81	SEDANG	SEDANG
Langsa Lama	1.112,11	287,33	TINGGI	SEDANG
Langsa Timur	6.452,14	2.168,84	TINGGI	SEDANG
Kota Langsa	14.576,48	4.055,01	TINGGI	TINGGI

Berdasarkan Tabel 4.26, KRB mencatat bahwa empat dari lima kecamatan di Kota Langsa memiliki kelas bahaya TINGGI. Kecamatan Langsa Timur memiliki luas bahaya tinggi terbesar (2.168,84 ha), diikuti Langsa Barat (1.044,66 ha) dan Langsa Baro (514,37 ha). Pada dimensi risiko, hanya Kecamatan Langsa Baro yang masuk kelas risiko TINGGI meskipun Langsa Timur memiliki luas

bahaya terbesar, seluruh kecamatan di Kota Langsa memiliki kapasitas menghadapi banjir yang dinilai SEDANG sehingga risiko akhirnya termoderasi, sedangkan Langsa Baro mendapat risiko TINGGI akibat kerentanan penduduk terpapar yang lebih besar.

4.7.2 Perbandingan dengan Hasil Model A

Model A menghasilkan klasifikasi kerawanan banjir pada tingkat desa yang dapat dikonversi ke tingkat kecamatan untuk keperluan perbandingan. Tabel 4.27 berikut menyajikan perbandingan antara proporsi desa rawan per kecamatan dari Model A dengan kelas bahaya dan risiko dari KRB.

Tabel 4. 27 Perbandingan Hasil Model A dengan KRB per Kecamatan

Kecamatan	Total Desa	Desa Rawan (Model A)	Proporsi	KRB Bahaya	KRB Risiko
Langsa Lama	15	14	93,3%	TINGGI	SEDANG
Langsa Timur	16	14	87,5%	TINGGI	SEDANG
Langsa Barat	13	10	76,9%	TINGGI	SEDANG
Langsa Baro	12	9	75,0%	TINGGI	TINGGI
Langsa Kota	10	4	40,0%	SEDANG	SEDANG

Berdasarkan Tabel 4.27, terdapat konsistensi yang kuat antara hasil Model A dengan KRB pada dua kecamatan yang paling kontras. Kecamatan Langsa Kota memiliki proporsi desa rawan terendah (40,0%) dan secara bersamaan merupakan satu-satunya kecamatan dengan kelas bahaya SEDANG pada KRB — konsistensi ini mengkonfirmasi bahwa karakteristik topografi perkotaan Langsa Kota yang relatif lebih tinggi memang memiliki potensi banjir lebih rendah. Di sisi lain, Kecamatan Langsa Timur dan Langsa Lama secara konsisten menunjukkan proporsi desa rawan tertinggi pada Model A (87,5% dan 93,3%) sekaligus memiliki kelas bahaya TINGGI pada KRB. Perbedaan yang perlu dicermati terjadi pada

dimensi risiko KRB di mana Langsa Baro mendapat kelas risiko TINGGI sementara Model A menempatkan Langsa Baro dengan proporsi rawan 75,0% — setara dengan Langsa Barat yang hanya mendapat risiko SEDANG. Perbedaan ini dapat dijelaskan oleh metodologi KRB yang memasukkan faktor kerentanan sosial-ekonomi dan kepadatan penduduk dalam perhitungan risiko, di mana Kecamatan Langsa Baro memiliki kepadatan penduduk terpapar lebih tinggi dibandingkan Langsa Barat sehingga risiko akhirnya lebih besar meskipun luas bahayanya lebih kecil.

4.7.3 Perbandingan dengan Hasil Model B

Model B menghasilkan klasifikasi berbasis titik sampel yang memberikan gambaran distribusi spasial kerawanan yang lebih detail dibandingkan Model A. Untuk keperluan perbandingan yang setara dengan Model A, distribusi titik rawan Model B dihitung menggunakan label *ground truth* yang sama (bukan hasil prediksi model) dan dikelompokkan per kecamatan melalui *spatial join* terhadap batas administrasi desa. Tabel 4.28 berikut menyajikan perbandingan distribusi titik rawan Model B dengan KRB per kecamatan.

Tabel 4.28 Perbandingan Hasil Model B dengan KRB per Kecamatan

Kecamatan	Total Titik	Titik Rawan (GT)	Proporsi	KRB Bahaya	KRB Risiko
Langsa Kota	47	14	29,79% (Tertinggi)	SEDANG	SEDANG
Langsa Barat	340	81	23,82%	TINGGI	SEDANG
Langsa Timur	473	98	20,72%	TINGGI	SEDANG

Kecamatan	Total Titik	Titik Rawan (GT)	Proporsi	KRB Bahaya	KRB Risiko
Langsa Lama	224	28	12,50%	TINGGI	SEDANG
Langsa Baro	416	26	6,25% (Terendah)	TINGGI	TINGGI

Berdasarkan Tabel 4.28, distribusi titik rawan Model B menunjukkan pola yang sangat berbeda dengan distribusi desa rawan Model A. Kecamatan Langsa Kota justru memiliki proporsi titik rawan tertinggi (29,79%) pada Model B, berbanding terbalik dengan Model A yang menempatkan Langsa Kota pada proporsi terendah (40,0%). Sebaliknya, Langsa Lama dan Langsa Baro yang mendominasi proporsi desa rawan tertinggi pada Model A (93,3% dan 75,0%) justru menempati posisi terendah pada Model B (12,50% dan 6,25%). Perbedaan pola ini akan dibahas lebih lanjut pada sub-bab berikutnya.

4.7.4 Analisis Perbedaan Hasil Berdasarkan Unit Analisis dan Konsistensi dengan KRB

Hasil perbandingan pada bagian sebelumnya menunjukkan temuan yang menarik, yaitu Model A dan Model B menghasilkan pola spasial yang saling bertolak belakang meskipun keduanya menggunakan data historis kejadian banjir yang sama sebagai acuan dasar. Tabel 4.29 merangkum perbandingan langsung kedua model untuk memperjelas kontras tersebut.

Tabel 4.29 Perbedaan Hasil Model A vs Model B per Kecamatan

Kecamatan	Model A (% Desa Rawan)	Ranking A	Model B (% Titik Rawan)	Ranking B	KRB Bahaya
Langsa Lama	93,33%	#1 Tertinggi	12,50%	#4	TINGGI
Langsa Timur	87,50%	#2	20,72%	#2	TINGGI

Kecamatan	Model A (% Desa Rawan)	Ranking A	Model B (% Titik Rawan)	Ranking B	KRB Bahaya
Langsa Barat	76,92%	#3	23,82%	#2	TINGGI
Langsa Baro	75,00%	#4	6,25%	#5 Terendah	TINGGI
Langsa Kota	40,00%	#5 Terendah	29,79%	#1 Tertinggi	SEDANG

Berdasarkan Tabel 4.29, Kecamatan Langsa Lama dan Langsa Kota mengalami pembalikan *ranking* yang paling ekstrem antara kedua model. Fenomena ini merupakan contoh nyata dari *Modifiable Areal Unit Problem* (MAUP) dalam analisis spasial, yaitu kondisi di mana hasil analisis dapat berubah secara besar ketika unit pengamatannya berubah dari poligon desa menjadi titik koordinat, meskipun data banjir yang menjadi acuan identik.

Perbedaan pola ini terjadi karena kriteria pelabelan kedua model memang dirancang berbeda sesuai dengan unit analisis masing-masing. Kriteria Model A bersifat "*any-touch*" pada level desa, sebuah desa diberi label Rawan apabila terdapat irisan sekecil apapun antara batas desa dengan area banjir historis. Desa dengan luas wilayah besar namun hanya tersentuh banjir pada sebagian kecil wilayahnya akan tetap tercatat Rawan secara keseluruhan, meskipun mayoritas wilayah desa tersebut berada pada elevasi aman. Kriteria Model B jauh lebih ketat karena mensyaratkan dua kondisi sekaligus pada level titik, yaitu berada di dalam area banjir dan memiliki nilai HAND di bawah 1 meter.

Perbedaan kriteria ini bukan merupakan inkonsistensi metodologis, melainkan penyesuaian yang disengaja terhadap karakteristik masing-masing unit analisis. Model A mengikuti pendekatan administratif yang sejalan dengan metodologi resmi BNPB, yang memang dirancang berbasis persentase luas wilayah

desa/kecamatan sehingga kriteria irisan sederhana sudah memadai dan valid digunakan. Model B beroperasi pada unit titik diskret yang tidak memiliki acuan metodologi administratif setara, sehingga memerlukan kriteria tambahan yang lebih ketat secara fisik. Pertimbangan lain yang mendasari perbedaan ini adalah bahwa peta banjir historis hanya merekam satu kejadian tunggal pada 31 Januari 2026, bukan keseluruhan potensi genangan suatu wilayah secara permanen. Pada level desa, agregasi atas luasan yang besar secara alami meredam variasi acak dari satu kejadian tunggal tersebut, sehingga kriteria irisan sederhana tetap representatif. Pada level titik yang jauh lebih detail, ketiadaan efek peredaman ini membuat label menjadi sangat sensitif terhadap kebetulan jangkauan satu kejadian banjir maupun ketelitian batas poligon hasil digitasi, sehingga penambahan kriteria HAND diperlukan untuk memastikan titik yang dilabeli Rawan memang secara fisik berada pada elevasi rendah yang konsisten dengan prinsip kerawanan struktural, bukan sekadar kebetulan terdampak pada satu kejadian.

Kasus Kecamatan Langsa Lama menjadi ilustrasi yang tepat untuk menjelaskan fenomena ini. Sebanyak 14 dari 15 desa di kecamatan ini tercatat Rawan pada Model A karena masing-masing desa memiliki setidaknya sebagian kecil wilayah yang pernah tergenang. Namun ketika dianalisis pada level titik yang lebih detail, hanya 12,50% dari 224 titik sampel di kecamatan tersebut yang benar-benar memenuhi kriteria ketat HAND di bawah 1 meter sekaligus berada dalam area banjir, mengindikasikan bahwa sebagian besar wilayah desa di Langsa Lama sebenarnya berada pada elevasi yang relatif aman meskipun pernah mengalami genangan di titik-titik tertentu. Pola serupa namun berkebalikan terjadi pada

Kecamatan Langsa Kota, di mana kawasan perkotaan yang padat dan didominasi permukaan impermeabel menghasilkan proporsi titik dengan HAND rendah yang lebih tinggi secara relatif, meskipun jumlah desa yang tercatat pernah terdampak banjir tergolong paling sedikit.

Dibandingkan dengan KRB Kota Langsa, kedua model menunjukkan tingkat konsistensi yang berbeda. Model A lebih konsisten dengan klasifikasi bahaya KRB pada empat dari lima kecamatan, sedangkan Model B menunjukkan pola yang lebih unik dengan Langsa Kota sebagai pengecualian utama. Perbedaan ini wajar mengingat KRB menggunakan unit analisis luas wilayah yang mendekati pendekatan Model A, sementara Model B menggunakan unit analisis titik diskret dengan kriteria topografi yang lebih ketat. Kedua model memiliki peran yang berbeda sesuai unit analisisnya masing-masing — Model A menghasilkan klasifikasi kerawanan per desa yang sesuai untuk perencanaan wilayah tingkat administratif, sementara Model B menghasilkan klasifikasi per titik koordinat yang digunakan langsung oleh sistem *WebGIS* untuk menentukan status rawan suatu lokasi.

4.8 Hasil Pengujian Sistem

Pengujian sistem dilakukan mengacu pada rencana pengujian *Blackbox* dan *Whitebox* yang telah disusun sebelumnya, mencakup sembilan segmen fungsional untuk pengujian *Blackbox* dan empat proses inti untuk pengujian *Whitebox*.

4.8.1 Hasil Pengujian *Blackbox*

Pengujian *Blackbox* berfokus pada pengujian fungsional sistem dari sudut pandang pengguna, tanpa memperhatikan struktur kode program di baliknya. Pengujian dilakukan dengan memberikan input tertentu ke sistem, kemudian membandingkan *output* yang dihasilkan dengan hasil yang diharapkan berdasarkan kebutuhan fungsional yang telah dirancang. Pengujian ini dilakukan terhadap sembilan segmen halaman sistem, yaitu Autentikasi *Login*, Autentikasi *Register*, *Dashboard*, Pengelolaan Data *GIS*, Visualisasi Peta, Visualisasi Statistik, Pencarian Lokasi, Evaluasi Performa Model, dan Prediksi Lokasi Baru, dengan halaman Autentikasi diuji dalam dua segmen terpisah (*Login* dan *Register*) sehingga secara keseluruhan terdapat sembilan segmen pengujian. Setiap segmen diuji dengan beberapa skenario yang mencakup kondisi penggunaan normal, kondisi akses khusus, dan penanganan *input* tidak valid, untuk memastikan kedelapan kebutuhan fungsional dan kebutuhan non-fungsional terkait keamanan serta keandalan sistem terpenuhi secara menyeluruh. Pendekatan pengujian ini dipilih karena sesuai untuk memvalidasi bahwa sistem *WebGIS* yang dibangun benar-benar berfungsi sebagaimana yang dialami langsung oleh pengguna akhir baik *Admin* maupun *User* tanpa perlu meninjau bagaimana setiap fungsi tersebut diimplementasikan secara internal, sehingga hasil pengujian ini dapat merepresentasikan pengalaman penggunaan sistem secara nyata di lapangan, sebagaimana disajikan pada Tabel 4.30 hingga Tabel 4.38 berikut.

1. Pengujian *Blackbox* halaman *Register***Tabel 4.30** Pengujian *Blackbox* Halaman *Register*

No	Test Case	Pre-condition	Test Steps	Test Data	Expected Result	Post-condition	Actual Result	Status
1	Registrasi dengan data valid	Halaman <i>Register</i> terbuka	Mengisi nama, email, dan password sesuai ketentuan, menekan tombol Daftar	(Nama : Naufal) (Email : naufal@email.com) (Password : Abay0011)	Akun berhasil dibuat, sistem menampilkan notifikasi sukses	Akun baru tersimpan di sistem	Sistem berhasil mengarahkan pengguna baru ke halaman dashboard	berhasil
2	Registrasi dengan format email tidak valid	Halaman <i>Register</i> terbuka	Mengisi form registrasi dengan email tanpa format yang valid, menekan tombol Daftar	(Nama : Naufal) (Email : Naufal.id) (Password : Abay0011)	Sistem menampilkan notifikasi "Email tidak valid"	Akun tidak dibuat	Sistem menampilkan notifikasi Email tidak valid dan akun gagal dibuat	berhasil
3	Registrasi dengan password kurang dari 6 karakter	Halaman <i>Register</i> terbuka	Mengisi form registrasi dengan password kurang dari 6 karakter, menekan tombol Daftar	(Nama : Naufal) (Email : naufal@email.ocm) (Password : Abay01)	Sistem menampilkan notifikasi "Password minimal 6 karakter"	Akun tidak dibuat	Sistem menampilkan notifikasi Password tidak memenuhi ketentuan dan akun gagal dibuat	berhasil

No	Test Case	Pre-condition	Test Steps	Test Data	Expected Result	Post-condition	Actual Result	Status
4	Registrasi dengan email yang sudah terdaftar	Email yang akan digunakan sudah terdaftar di sistem	Mengisi form registrasi menggunakan email yang sudah pernah didaftarkan, menekan tombol Daftar	Email yang sudah terdaftar	Sistem menampilkan notifikasi bahwa email sudah digunakan	Akun tidak dibuat, akun lama tidak berubah	Sistem menampilkan informasi <i>User already registered</i>	Berhasil

2. Pengujian *Blackbox* halaman *Login*

Tabel 4.31 Pengujian *Blackbox* halaman *Login*

No	Test Case	Pre-condition	Test Steps	Test Data	Expected Result	Post-condition	Actual Result	Status
1	<i>Login</i> dengan kredensial valid	Admin memiliki akun terdaftar, berada di halaman <i>login</i>	Mengisi email dan password yang valid, menekan tombol <i>Login</i>	Email dan password admin yang valid	Sistem memverifikasi kredensial melalui <i>Supabase Auth</i> dan mengarahkan ke halaman <i>Dashboard</i> dengan akses penuh	Admin berhasil masuk, sesi aktif	Admin berhasil <i>login</i> dan diarahkan ke <i>Dashboard</i> dengan akses penuh ke seluruh fitur (Kelola Data <i>GIS</i> , Evaluasi Model, dst.)	Berhasil

No	Test Case	Pre-condition	Test Steps	Test Data	Expected Result	Post-condition	Actual Result	Status
2	Login sebagai User (bukan Admin)	Akun dengan <i>role</i> "user" telah terdaftar (melalui <i>Register</i>)	Mengisi email dan password akun ber- <i>role</i> "user", menekan tombol <i>Login</i>	Email dan password akun ber- <i>role</i> "user"	Sistem berhasil melakukan autentikasi, namun akun ber- <i>role</i> "user" tidak mendapat akses ke menu khusus admin (Kelola Data GIS, Evaluasi Model, Kelola Pengguna)	Pengguna login dengan akses terbatas sesuai <i>role</i> "user"	User berhasil login dan diarahkan ke <i>Dashboard</i> dengan akses User biasa	Berhasil
3	Login dengan password salah	Admin memiliki akun terdaftar, berada di halaman <i>login</i>	Mengisi email terdaftar dengan password yang salah, menekan tombol <i>Login</i>	Email terdaftar + password salah	Sistem menampilkan notifikasi kredensial tidak valid, tidak mengarahkan ke <i>Dashboard</i>	Pengguna tetap berada di halaman <i>login</i>	Sistem menampilkan pesan Email atau password salah dan tetap berada di halaman login	Berhasil
4	Login dengan email tidak terdaftar	Berada di halaman <i>login</i>	Mengisi email yang tidak terdaftar, mengisi	Email tidak terdaftar	Sistem menampilkan notifikasi email/password tidak valid	Pengguna tetap berada di halaman <i>login</i>	Sistem menampilkan pesan Email atau password salah dan tetap	berhasil

No	Test Case	Pre-condition	Test Steps	Test Data	Expected Result	Post-condition	Actual Result	Status
			password bebas, menekan tombol <i>Login</i>				berada di halaman login	

3. Hasil Pengujian *Blackbox* Halaman *Dashboard*

Tabel 4.32 Pengujian *Blackbox* Halaman *Dashboard*

No	Test Case	Pre-condition	Test Steps	Test Data	Expected Result	Post-condition	Actual Result	Status
1	Akses halaman <i>Dashboard</i> tanpa login	Tidak terdapat sesi pengguna aktif	Membuka URL utama sistem melalui browser	URL sistem	Menampilkan ringkasan jumlah desa Rawan/Tidak Rawan dan status kedua model tanpa memerlukan login	Pengguna dapat melihat ringkasan dan mengakses menu navigasi publik	Halaman menampilkan ringkasan 66 desa dengan 52 desa Rawan dan status kedua model sesuai rancangan	Berhasil
2	Navigasi dari <i>Dashboard</i> ke halaman lain	Pengguna berada di halaman <i>Dashboard</i>	Menekan salah satu menu navigasi	Klik menu "Peta Kerawanan"	Sistem mengarahkan pengguna ke halaman Peta Kerawanan	Halaman Peta Kerawanan tampil	Sistem mengarahkan <i>Admin/User</i> ke halaman Peta Kerwanan dan	Berhasil

No	Test Case	Pre-condition	Test Steps	Test Data	Expected Result	Post-condition	Actual Result	Status
			(Peta Kerawanan)				Peta Kerawan tampil	

4. Hasil Pengujian *Blackbox* Halaman Pengelolaan Data *GIS*

Tabel 4.33 Pengujian *Blackbox* Halaman Pengelolaan Data *GIS*

No	Test Case	Pre-condition	Test Steps	Test Data	Expected Result		Post-condition	Actual Result	Status
1	Akses halaman Kelola Data <i>GIS</i> sebagai Admin	Admin telah login	Login dengan kredensial admin, memilih menu Kelola Data <i>GIS</i>	Email dan password admin	Data 1.500 titik sampel dan 66 desa ditampilkan dalam tabel yang dapat ditelusuri		Admin dapat menelusuri/mencari data mentah pada tabel	Data 1.500 titik dan 66 desa berhasil ditampilkan dalam tabel yang dapat ditelusuri	Berhasil
2	Akses halaman Kelola Data <i>GIS</i> tanpa login	Tidak terdapat sesi pengguna aktif	Membuka URL halaman Kelola Data <i>GIS</i> secara langsung melalui browser	URL halaman admin	Sistem menolak akses dan mengarahkan pengguna ke halaman <i>login</i>		Pengguna tidak dapat melihat data <i>GIS</i>	Sistem mengarahkan kembali pengguna ke halaman login dan pengguna tidak dapat mengakses halaman	Berhasil

No	Test Case	Pre-condition	Test Steps	Test Data	Expected Result		Post-condition	Actual Result	Status
								kelola data GIS	

5. Hasil Pengujian *Blackbox* Halaman Visualisasi Peta

Tabel 4.34 Pengujian *Blackbox* Halaman Visualisasi Peta

No	Test Case	Pre-condition	Test Steps	Test Data	Expected Result	Post-condition	Actual Result	Status
1	Menampilkan peta titik kerawanan Model B	Data klasifikasi Model B tersimpan di basis data	Memilih menu Peta Kerawanan, tab Model B	—	Peta menampilkan titik kerawanan dengan simbol warna merah (Rawan) dan hijau (Tidak Rawan)	Pengguna dapat melihat sebaran titik pada peta	Peta menampilkan 259 titik merah (Rawan) dan 1.241 titik hijau (Tidak Rawan)	Berhasil
2	Menampilkan peta <i>choropleth</i> Model A	Data klasifikasi Model A tersimpan di basis data	Memilih tab Model A pada halaman Peta Kerawanan	—	Peta menampilkan <i>choropleth</i> 66 desa sesuai kelas kerawanan	Pengguna dapat melihat sebaran kerawanan per desa	Peta menampilkan <i>choropleth</i> 66 desa sesuai hasil klasifikasi	Berhasil

No	Test Case	Pre-condition	Test Steps	Test Data	Expected Result	Post-condition	Actual Result	Status
3	Menampilkan <i>popup</i> informasi parameter	Peta telah dimuat dengan data titik/desa	Menekan salah satu titik atau poligon desa pada peta	Klik pada 1 titik/desa	Sistem menampilkan <i>popup</i> berisi nilai parameter lokasi tersebut	<i>Popup</i> informasi tertutup saat area lain ditekan	<i>Popup</i> parameter tampil sesuai lokasi yang ditekan	Berhasil

6. Hasil Pengujian *Blackbox* Halaman Visualisasi Statistik

Tabel 4.35 Pengujian *Blackbox* Halaman Visualisasi Statistik

No	Test Case	Pre-condition	Test Steps	Test Data	Expected Result	Post-condition	Actual Result	Status
1	Menampilkan statistik Model A per kecamatan	Data klasifikasi Model A tersimpan di basis data	Memilih menu Statistik, tab Model A	—	Grafik dan tabel distribusi kerawanan 66 desa per kecamatan tampil	Pengguna dapat melihat rekapitulasi per kecamatan	Grafik dan tabel distribusi per kecamatan tampil sesuai hasil klasifikasi Model A	Berhasil
2	Menampilkan statistik Model B per kecamatan	Data klasifikasi Model B tersimpan di basis data	Memilih tab Model B pada halaman yang sama	—	Grafik dan tabel distribusi 1.500 titik per kecamatan tampil	Pengguna dapat melihat rekapitulasi per kecamatan	Grafik dan tabel distribusi per kecamatan tampil sesuai hasil klasifikasi Model B	Berhasil

7. Hasil Pengujian *Blackbox* Halaman Pencarian Lokasi**Tabel 4.36** Pengujian *Blackbox* Halaman Pencarian Lokasi

No	Test Case	Pre-condition	Test Steps	Test Data	Expected Result	Post-condition	Actual Result	Status
1	Mencari lokasi dengan kata kunci sebagian	Sistem memiliki data 66 nama desa/kelurahan	Mengetik sebagian nama desa pada kolom pencarian	"Meutia"	Sistem menampilkan desa yang sesuai beserta status kerawanannya	Peta berpindah ke lokasi hasil pencarian	Pencarian "Meutia" mengembalikan hasil "Meutia, Langsa Kota" berstatus Tidak Rawan (Aman)	Berhasil
2	Mencari lokasi dengan nama tidak terdaftar	Sistem memiliki data 66 nama desa/kelurahan	Mengetik nama yang tidak ada dalam data desa Kota Langsa	"Medan Johor"	Sistem menampilkan notifikasi lokasi tidak ditemukan	Peta tidak berpindah lokasi	Pencarian tidak mengembalikan hasil apa pun, data lokasi tidak terdeteksi	Berhasil
3	Mencari lokasi dengan kolom kosong	Sistem memiliki data 66 nama desa/kelurahan	Menekan tombol cari tanpa mengisi kolom pencarian	— (kosong)	Sistem menampilkan validasi bahwa kolom pencarian harus diisi	Tidak ada perubahan pada peta	Pencarian tidak mengembalikan hasil apa pun, data lokasi tidak terdeteksi	Berhasil

8. Hasil Pengujian *Blackbox* Halaman Evaluasi Performa Model**Tabel 4.37** Pengujian *Blackbox* Halaman Evaluasi Performa Model

No	Test Case	Pre-condition	Test Steps	Test Data	Expected Result	Post-condition	Actual Result	Status
1	Menampilkan evaluasi Model A sebagai Admin	Admin telah login	Login sebagai admin, memilih menu Evaluasi Model, tab Model A	Email dan password admin	Halaman menampilkan Akurasi, <i>F1-Score</i> , <i>Cohen's Kappa</i> , <i>MCC</i> , dan <i>Feature Importance</i> Model A	Admin dapat melihat rincian performa Model A	Halaman menampilkan seluruh metrik dan <i>Feature Importance</i> Model A sesuai rancangan	Berhasil
2	Menampilkan evaluasi Model B sebagai Admin	Admin telah login	Memilih tab Model B pada halaman yang sama	—	Halaman menampilkan Akurasi, <i>F1-Score</i> , <i>AUC-ROC</i> , <i>Cohen's Kappa</i> , <i>MCC</i> , dan <i>Feature Importance</i> Model B	Admin dapat melihat rincian performa Model B	Halaman menampilkan seluruh metrik dan <i>Feature Importance</i> Model B sesuai rancangan	Berhasil
3	Akses halaman Evaluasi Model tanpa login	Tidak terdapat sesi pengguna aktif	Membuka URL halaman Evaluasi Model	URL halaman evaluasi	Sistem menolak akses dan mengarahkan ke halaman <i>login</i>	Pengguna tidak dapat melihat metrik evaluasi	Sistem kembali mengarahkan user ke halaman login dan halaman	Berhasil

No	Test Case	Pre-condition	Test Steps	Test Data	Expected Result	Post-condition	Actual Result	Status
			secara langsung				metrik gagal dibuka	

9. Hasil Pengujian *Blackbox* Halaman Klasifikasi Manual

Tabel 4.38 Pengujian *Blackbox* Halaman Klasifikasi Manual

No	Test Case	Pre-condition	Test Steps	Test Data	Expected Result	Post-condition	Actual Result	Status
1	Input 10 parameter dengan nilai valid	Admin telah login, model ter-deploy pada <i>FastAPI</i>	Login sebagai admin, memilih tab Prediksi Manual, mengisi 10 nilai parameter, menekan tombol prediksi	DEM 5m, slope 2,5°, TWI 12, curvature 0,001, jarak sungai 300m, jarak jalan 150m, HAND 1,5m, skor LULC 4, skor	Sistem mengembalikan klasifikasi Rawan/Tidak Rawan beserta probabilitasnya	Hasil klasifikasi ditampilkan kepada admin	Sistem mengembalikan klasifikasi Tidak Rawan dengan probabilitas Rawan 26,8% dan Aman 73,2%	Berhasil

No	Test Case	Pre-condition	Test Steps	Test Data	Expected Result	Post-condition	Actual Result	Status
				tanah 5, skor curah hujan 4				
2	Input dengan salah satu parameter dikosongkan	Admin telah login	Mengosongkan salah satu kolom (misal DEM), menekan tombol prediksi	9 parameter terisi, kolom DEM kosong	Sistem menampilkan validasi bahwa seluruh kolom wajib diisi	Klasifikasi tetap diproses	Sistem mengembalikan klasifikasi Tidak Rawan dengan probabilitas Rawan 22,1% dan Aman 77,9%	Gagal
3	Input dengan format nilai tidak valid	Admin telah login	Mengisi kolom numerik dengan karakter huruf	DEM = "abc"	Sistem menampilkan pesan format nilai tidak valid	Input DEM tidak bisa menginput Huruf hanya Angka (<i>float</i>)	Sistem Tidak mengembalikan hasil apapun	<i>Gagal</i>

Berdasarkan kesembilan tabel di atas, dari 26 skenario pengujian yang dilaksanakan, 24 skenario (92,3%) dinyatakan Berhasil dan 2 skenario (7,7%) dinyatakan Gagal. Seluruh fungsi utama sistem autentikasi, navigasi antar halaman, penampilan data spasial pada peta dan statistik, pencarian lokasi, serta penampilan metrik evaluasi model berjalan sesuai rancangan pada seluruh kondisi yang diuji, termasuk kondisi akses tanpa *login* dan perbedaan hak akses antara peran Admin dan *User*. Kedua skenario Gagal ditemukan pada segmen Prediksi Lokasi Baru, khususnya pada penanganan *input* tidak valid. Rincian pembahasan tiap segmen dijelaskan sebagai berikut.

Pada segmen Autentikasi *Login*, keempat skenario dinyatakan Berhasil, memenuhi KF-01. Sistem mampu membedakan kredensial valid dan tidak valid dengan tepat melalui mekanisme autentikasi *Supabase Auth*, serta menerapkan validasi kolom wajib diisi pada sisi *frontend* sebelum permintaan *login* dikirim. Pengujian pada akun ber-*role User* menjadi temuan penting tersendiri, karena membuktikan bahwa sistem menerapkan pemisahan hak akses berbasis peran (*role-based access control*) secara benar setelah proses autentikasi *User* berhasil *login* namun tetap tidak memperoleh akses ke menu khusus Admin.

Pada segmen Autentikasi *Register*, keempat skenario dinyatakan Berhasil. Ketiga validasi yang diuji, format *email*, panjang minimum *password*, dan duplikasi *email* merupakan lapisan pertahanan pertama terhadap data tidak konsisten sebelum masuk ke basis data *Supabase*, dan keberhasilannya menunjukkan bahwa lapisan validasi tidak hanya bergantung pada batasan bawaan *Supabase Auth*, tetapi juga diterapkan secara eksplisit pada logika aplikasi.

Pada segmen Halaman *Dashboard*, kedua skenario dinyatakan Berhasil, memenuhi KF-02. Keberhasilan akses tanpa *login* mengonfirmasi bahwa rancangan *Dashboard* sebagai titik masuk publik benar-benar diimplementasikan, dan seluruh menu navigasi berhasil mengarahkan pengguna ke halaman tujuan yang sesuai tanpa kesalahan *routing*.

Pada segmen Pengelolaan Data *GIS*, kedua skenario dinyatakan Berhasil, memenuhi KF-03 dan KNF-02. Keberhasilan menampilkan 1.500 titik dan 66 desa menunjukkan sistem berhasil menangani volume data yang besar, termasuk mengatasi pembatasan 1.000 baris per permintaan pada *Supabase*. Keberhasilan penolakan akses tanpa *login* membuktikan pembatasan akses diterapkan pada tingkat pemrosesan permintaan, bukan hanya menyembunyikan menu pada antarmuka.

Pada segmen Visualisasi Peta, ketiga skenario dinyatakan Berhasil, memenuhi KF-04. Keberhasilan menampilkan dua *layer* sekaligus (titik Model B dan *choropleth* Model A) tanpa saling mengganggu menunjukkan *Leaflet.js* mampu menangani penggabungan data spasial dari dua unit analisis berbeda secara bersamaan.

Pada segmen Visualisasi Statistik, kedua skenario dinyatakan Berhasil, memenuhi KF-05. Keberhasilan pada kedua tampilan membuktikan mekanisme pengambilan data *real-time* dari tabel kecamatan_stats berfungsi konsisten terlepas dari model yang dipilih pengguna.

Pada segmen Pencarian Lokasi, ketiga skenario dinyatakan Berhasil, memenuhi KF-06. Pencarian dengan kata kunci sebagian berhasil menemukan hasil yang sesuai, sedangkan dua skenario lainnya (nama tidak terdaftar dan kolom kosong) sama-sama tidak mengembalikan hasil apa pun tanpa notifikasi eksplisit — hasil ini dinyatakan sesuai karena memang tidak ada data yang cocok untuk ditampilkan.

Pada segmen Evaluasi Performa Model, ketiga skenario dinyatakan Berhasil, memenuhi KF-07 dan KNF-02. Seluruh metrik dan *Feature Importance* yang tampil sesuai rancangan menunjukkan data hasil pelatihan model berhasil diteruskan secara utuh hingga ke lapisan presentasi *WebGIS*, dan penolakan akses tanpa *login* konsisten dengan hasil pada segmen Pengelolaan Data *GIS*.

Pada segmen Klasifikasi Manual, hanya skenario pertama (*input valid*) yang Berhasil, sedangkan dua skenario lainnya Gagal. Sistem tidak menampilkan validasi kolom wajib diisi ketika salah satu parameter dikosongkan — tetap memproses dan mengembalikan klasifikasi Tidak Rawan dengan probabilitas 22,1% — dan tidak menampilkan pesan format nilai tidak valid ketika kolom numerik diisi karakter huruf. Kedua kegagalan ini terjadi khusus pada fitur yang berinteraksi langsung dengan model *Random Forest* melalui *endpoint API* /predict, mengindikasikan validasi *input* pada lapisan *backend* belum diterapkan seketat validasi pada lapisan antarmuka, sehingga KNF-05 belum sepenuhnya terpenuhi pada fitur ini. Akar penyebab teknis kedua kegagalan ini turut dikonfirmasi melalui pengujian *Whitebox* pada bagian berikutnya.

4.8.2 Hasil Pengujian *Whitebox*

Pengujian *Whitebox* pada penelitian ini menggunakan metode *Basis Path Testing*, yaitu menelusuri kode program pada setiap proses inti untuk menentukan graf alir (*flow graph*), menghitung *cyclomatic complexity*, dan menyusun jalur independen sebagai dasar rancangan data uji.

1. Hasil Pengujian *Whitebox Preprocessing Data*

Tabel 4.39 berikut menyajikan kode program penanganan nilai kosong pada variabel kontinu beserta penomoran *node*-nya.

Tabel 4.39 Pengujian *Whitebox Preprocessing Data*

Line	Kode Program	Node
1	KONTINU = ['dem', 'slope', 'twi', 'curv', 'hand', 'river', 'road', 'c h_mean']	1
2	fillna_info = {}	2
3	for col in KONTINU:	3
4	if col in df.columns and df[col].isnull().sum() > 0:	4
5	val = round(df[col].median(), 2)	5
6	df[col] = df[col].fillna(val)	6
7	fillna_info[col] = {'method': 'median', 'value': val}	7
8	print('Selesai')	8

Berdasarkan Tabel 4.39, node 3 (perulangan) dan node 4 (kondisi) merupakan titik keputusan pada fungsi ini. Tabel 4.40 berikut menyajikan *Flowgraph* beserta hasil perhitungan kompleksitas dan status pengujian jalur independennya.

Tabel 4.40 *Flowgraph dan Kompleksitas Preprocessing Data*

<i>Flowgraph</i>	Kompleksitas	Keterangan
<pre> graph TD 1((1)) --> 2((2)) 2 --> 3((3)) 3 -- Ya --> 4((4)) 4 -- Tidak --> 3 3 -- Tidak --> 8((8)) 4 -- Ya --> 5((5)) 5 --> 6((6)) 6 --> 7((7)) 7 --> 8 </pre>	$V(G) = E - N + 2$ $V(G) = 9 - 8 + 2 = 3$ Path 1 = 1,2,3,4,5,6,7,3,8 Path 2 = 1,2,3,4,3,8 Path 3 = 1,2,3,8	Lulus (✓) Lulus (✓) Lulus (✓)

Tabel 4.41 berikut menyajikan data uji dan hasil pengujian untuk masing-masing jalur independen tersebut.

Tabel 4.41 Jalur Independen dan Hasil Pengujian *Preprocessing Data*

Jalur	<i>Independent Path</i>	Data Uji	<i>Expected Result</i>	<i>Actual Result</i>	<i>Status</i>
1	1-2-3-4-5-6-7-3-8	Kolom dem (2 nilai kosong)	Nilai kosong diisi median dem	2 nilai kosong pada dem terisi median 3,79	Berhasil
2	1-2-3-4-3-8	Kolom curv (tidak ada nilai kosong)	Kolom dilewati tanpa perubahan nilai	Kolom curv tidak mengalami perubahan nilai	Berhasil
3	1-2-3-8	Daftar KONTINU dikondisikan kosong	Perulangan tidak dieksekusi, langsung	Perulangan tidak berjalan, program langsung	Berhasil

Jalur	<i>Independent Path</i>	Data Uji	<i>Expected Result</i>	<i>Actual Result</i>	Status
		(skenario batas)	ke akhir proses	mencetak "Selesai"	

Berdasarkan Tabel 4.41, ketiga jalur independen berhasil diverifikasi sesuai hasil yang diharapkan, sehingga proses *preprocessing* penanganan nilai kosong dinyatakan bebas dari kesalahan logika.

2. Hasil Pengujian *Whitebox* Proses Penggabungan Data

Tabel 4.42 berikut menyajikan kode program validasi ketersediaan 10 fitur final beserta penomoran node-nya.

Tabel 4.42 Pengujian *Whitebox* Proses Penggabungan Data

Line	Kode Program	Node
1	FEATURE_COLS = ['dem', 'slope', 'twi', 'curv', 'hand', 'river', 'road', 'lulc_skor', 'soil_skor', 'ch_skor']	1
2	LABEL_COL = 'label'	2
3	missing = [f for f in FEATURE_COLS if f not in df.columns]	3
4	print(f'Total fitur : {len(FEATURE_COLS)}')	4
5	for i, f in enumerate(FEATURE_COLS, 1):	5
6	print(f' {i:2d}. {f}')	6
7	if missing:	7
8	print(f' Fitur tidak ada: {missing}')	8
9	print('Seluruh 10 fitur tersedia')	9

Berdasarkan Tabel 4.42, node 5 (perulangan) dan node 7 (kondisi) merupakan titik keputusan pada fungsi ini. Tabel 4.43 berikut menyajikan graf alir beserta hasil perhitungan kompleksitas dan pengujian jalur independennya.

Tabel 4.43 *Flowgraph* dan Kompleksitas Penggabungan Data

<i>Flowgraph</i>	Kompleksitas	Keterangan
<pre> graph TD 1((1)) --> 2((2)) 2 --> 3((3)) 3 --> 4((4)) 4 --> 5((5)) 5 -- Ya --> 5 5 -- Tidak --> 6((6)) 6 --> 7((7)) 7 -- Ya --> 8((8)) 7 -- Tidak --> 9((9)) </pre>	$V(G) = E - N + 2$ $V(G) = 10 - 9 + 2 = 3$ Path 1 = 1,2,3,4,5,6,5,7,9 Path 2 = 1,2,3,4,5,6,5,7,8 Path 3 = 1,2,3,4,5,7,9	Lulus (✓) Lulus (✓) Lulus (✓)

Tabel 4.44 berikut menyajikan data uji dan hasil pengujian untuk masing-masing jalur independen tersebut.

Tabel 4.44 Jalur Independen dan Hasil Pengujian Penggabungan Data

Jalur	<i>Independent Path</i>	Data Uji	<i>Expected Result</i>	<i>Actual Result</i>	<i>Status</i>
1	1-2-3-4-5-6-5-7-9	Dataframe memiliki seluruh 10 kolom fitur	Validasi lolos, tidak ada fitur hilang	valid=True, missing=[]	Berhasil
2	1-2-3-4-5-6-5-7-8	Dataframe tidak memiliki kolom soil_skor	Validasi gagal, soil_skor dilaporkan hilang	valid=False, missing=['soil_skor']	Berhasil

Jalur	<i>Independent Path</i>	Data Uji	<i>Expected Result</i>	<i>Actual Result</i>	<i>Status</i>
3	1-2-3-4-5-7-9	FEATUR E_COLS dikondisikan kosong (skenario batas)	Perulangan dilewatkan nol kali, validasi tetap lolos	valid=True, missing=[] (perulangan tidak dieksekusi)	Berhasil

Berdasarkan Tabel 4.44, ketiga jalur independen berhasil diverifikasi sesuai hasil yang diharapkan, sehingga proses validasi fitur final dinyatakan bebas dari kesalahan logika.

3. Hasil Pengujian *Whitebox* Proses Pembentukan Dataset

Tabel 4.45 berikut menyajikan kode program pencarian `random_state` adaptif untuk pembagian data 3 kelas beserta penomoran node-nya.

Tabel 4.45 Pengujian *Whitebox* Proses Pembentukan Dataset

Line	Kode Program	Node
1	<code>TEST_SIZE_3KELAS = 0.3</code>	1
2	<code>chosen_rs = None</code>	2
3	<code>for rs_candidate in range(42, 200):</code>	3
4	<code>y_test_check = train_test_split(X, y_3, test_size=TEST_SIZE_3KELAS, random_state=rs_candidate, stratify=y_3)</code>	4
5	<code>if y_test_check.nunique() == y_3.nunique():</code>	5
6	<code>chosen_rs = rs_candidate</code>	6
7	<code>break</code>	7
8	<code>if chosen_rs is None:</code>	8
9	<code>raise ValueError('Tidak ditemukan random_state yang menjamin semua kelas hadir')</code>	9
10	<code>print(f'Random state terpilih: {chosen_rs}')</code>	10

Berdasarkan Tabel 4.45, node 3 (perulangan), node 5, dan node 8 merupakan titik keputusan pada fungsi ini. Tabel 4.46 berikut menyajikan graf alir beserta hasil perhitungan kompleksitas dan status pengujian jalur independennya.

Tabel 4.46 *Flowgraph* dan Kompleksitas Pembentukan Dataset

<i>Flowgraph</i>	Kompleksitas	Keterangan
<pre> graph TD 1((1)) --> 2((2)) 2 --> 3((3)) 3 -- Ya --> 3 3 -- Tidak --> 4((4)) 4 --> 5((5)) 5 -- Ya --> 3 5 -- Tidak --> 6((6)) 6 --> 7((7)) 7 --> 8((8)) 8 -- Ya --> 9((9)) 8 -- Tidak --> 10((10)) </pre>	$V(G) = E - N + 2$ $V(G) = 13 - 11 + 2 = 4$ Path 1 = 1,2,3,4,5,6,7,8,10 Path 2 = 1,2,3,4,5,3,4,5,6,7,8,10 Path 3 = 1,2,3,4,5,3,...,3,8,9 Path 4 = 1,2,3,8,9	Lulus (✓) Lulus (✓) Lulus (✓) Lulus (✓)

Tabel 4.47 berikut menyajikan data uji dan hasil pengujian untuk masing-masing jalur independen tersebut.

Tabel 4.47 Jalur Independen dan Hasil Pengujian Pembentukan Dataset

Jalur	<i>Independent Path</i>	Data Uji	<i>Expected Result</i>	<i>Actual Result</i>	<i>Status</i>
1	1-2-3-4-5-6-7-8-10	Kandidat random_state pertama langsung menghasilkan 3 kelas	chosen_rs = kandidat pertama (42)	chosen_rs=42	Berhasil
2	1-2-3-4-5-3-4-5-6-7-8-10	Kandidat pertama gagal, kandidat kedua berhasil (3 kelas)	chosen_rs = kandidat kedua (43)	chosen_rs=43, train_test_split terpanggil 2 kali	Berhasil
3	1-2-3-4-5-3-...-3-8-9	Seluruh kandidat pada rentang gagal (selalu 2 kelas)	<i>ValueError</i> terangkat	<i>ValueError</i> terangkat sesuai jumlah kandidat pada rentang	Berhasil
4	1-2-3-8-9	Rentang kandidat kosong sejak awal	<i>ValueError</i> terangkat tanpa iterasi	<i>ValueError</i> terangkat, train_test_split tidak terpanggil	Berhasil

Berdasarkan Tabel 4.47, keempat jalur independen berhasil diverifikasi sesuai hasil yang diharapkan, sehingga proses pembentukan dataset dinyatakan bebas dari kesalahan logika.

4. Pengujian Proses Model *Random Forest* (Endpoint POST /predict)

Tabel 4.48 berikut menyajikan kode program *endpoint* /predict beserta penomoran node-nya.

Tabel 4.48 Pengujian *Whitebox* Proses Endpoint Model Random Forest

Line	Kode Program	Node
1	@app.post("/predict", response_model=PredictOutput) def predict(data: PredictInput):	1
2	if model is None:	2
3	raise <i>HTTPException</i> (status_code=503, detail="Model belum dimuat.")	3
4	input_dict = data.model_dump()	4
5	X = np.array([[input_dict[col] for col in feature_cols]])	5
6	pred = int(model.predict(X)[0])	6
7	proba = model.predict_proba(X)[0]	7
8	idx_rawan = list(model.classes_).index(1) if 1 in model.classes_ else 1	8
9	idx_aman = list(model.classes_).index(0) if 0 in model.classes_ else 0	9
10	return PredictOutput(prediksi=pred, status_rawan="Rawan" if pred==1 else "Tidak Rawan", ...)	10

Berdasarkan Tabel 4.48, fungsi ini memiliki 5 titik keputusan: satu kondisi if eksplisit pada Node 2, satu iterasi implisit pada list comprehension penyusun X di Node 5, dan tiga ekspresi kondisional (ternary) pada Node 8, 9, dan 10. Tabel 4.49 berikut menyajikan graf alir beserta hasil perhitungan kompleksitas dan status pengujian jalur independennya.

Tabel 4.48 *Flowgraph* dan Kompleksitas *Endpoints* Model *Random Forest*

<i>Flowgraph</i>	Kompleksitas	Keterangan
	$V(G) = P + 1$ (dikonfirmasi tool <i>radon</i>) $V(G) = 5 + 1 = 6$ Path 1 = 1,2,3 (model belum dimuat) Path 2 = 1,2,4,5,6,7,8,9,10 (pred=0) Path 3 = cabang pred=1 di Node 10 Path 4 = cabang else di Node 8 Path 5 = cabang else di Node 9 Path 6 = cabang batas di Node 5	Lulus (✓) Lulus (✓) Lulus (✓) Lulus (✓) Lulus (✓) Lulus (✓)

Tabel 4.50 berikut menyajikan data uji dan hasil pengujian untuk masing-masing jalur independen tersebut.

Tabel 4.49 Jalur Independen dan Hasil Pengujian Model *Random Forest*

Jalur	<i>Independent Path</i>	Data Uji	<i>Expected Result</i>	<i>Actual Result</i>	<i>Status</i>
1	1-2-3	model belum dimuat (None)	Sistem menampilkan error 503 "Model belum dimuat"	<i>HTTPException</i> terangkat dengan status_code=503	Berhasil
2	1-2-4-5-6-7-8-9-10 (pred=0)	10 variabel geospasial, model mengklasifikasikan kelas 0	Sistem mengembalikan status "Tidak Rawan"	<i>Status</i> "Tidak Rawan" dikembalikan sesuai pred	Berhasil
3	Cabang pred=1 di Node 10	Data sama, model mengklasifikasikan kelas 1	Sistem mengembalikan status "Rawan"	<i>Status</i> "Rawan" dikembalikan sesuai pred	Berhasil

Jalur	<i>Independent Path</i>	Data Uji	<i>Expected Result</i>	<i>Actual Result</i>	<i>Status</i>
4	Cabang else di Node 8	model.classes_ tidak memuat kelas 1 (skenario batas)	idx_rawan menggunakan nilai default 1	idx_rawan=1, namun proba hanya 1 kolom sehingga memicu <i>IndexError</i>	Berhasil
5	Cabang else di Node 9	model.classes_ tidak memuat kelas 0 (skenario batas)	idx_aman menggunakan nilai default 0	idx_aman=0, namun karena idx_rawan juga 0, kedua probabilitas sama	Berhasil
6	Cabang batas di Node 5	feature_cols dikondisikan kosong	Sistem menampilkan galat jumlah fitur tidak sesuai	model.predict() menaikkan <i>ValueError</i> sebelum mencapai return	Berhasil

Berdasarkan Tabel 4.50, jalur 1 sampai 3 mengonfirmasi *endpoint* berjalan sesuai rancangan pada kondisi penggunaan normal. Jalur 4 dan 5 merupakan pengujian kondisi batas yang tidak terjadi pada model final yang di-*deploy* (karena model.classes_ model biner tersebut selalu memuat kedua kelas [0, 1]), namun pengujian ini mengungkap bahwa mekanisme default value pada Node 8 dan 9 tidak sepenuhnya menangani kasus model dengan satu kelas. Jalur 6 mengonfirmasi bahwa *endpoint* tidak melakukan validasi eksplisit terhadap jumlah variabel sebelum memanggil model.predict(), sehingga kesalahan konfigurasi pada feature_cols akan menghasilkan galat dari pustaka *scikit-learn*, bukan pesan galat yang dirancang khusus oleh sistem.

BAB V

PENUTUP

5.1 Simpulan

Berdasarkan hasil penelitian yang telah dilakukan, dapat ditarik kesimpulan sebagai berikut.

Sistem klasifikasi daerah rawan banjir di Kota Langsa telah berhasil dirancang dengan mengintegrasikan *Sistem Informasi Geografis (GIS)* dan algoritma *Random Forest* berdasarkan 10 variabel geospasial yang bersumber dari Badan Informasi Geospasial (BIG), *ESA WorldCover*, *FAO DSMW*, dan *CHIRPS*. Rancangan sistem mencakup arsitektur empat lapisan (input data spasial, pemrosesan data *GIS*, *Machine Learning*, dan sistem *WebGIS*), *use case* dan *activity diagram* untuk dua aktor (Admin dan *User*), serta perancangan metode yang meliputi penerapan algoritma *Random Forest* pada tiga model klasifikasi (Model A biner, Model A 3 kelas, dan Model B) untuk memperoleh perbandingan performa yang terukur, optimasi hiperparameter menggunakan *GridSearchCV*, dan metode evaluasi menggunakan *Repeated Cross-Validation* serta *Matriks Pembandingan*.

Berdasarkan rancangan tersebut, sistem berhasil dibangun dan diimplementasikan sebagai *WebGIS* berbasis *Next.js*, *FastAPI*, dan *Supabase PostgreSQL*. Pengujian *Blackbox* terhadap sembilan segmen sistem menghasilkan 24 dari 26 skenario Berhasil, dan pengujian *Whitebox* menggunakan *Basis Path Testing* terhadap empat proses inti menghasilkan 16 jalur independen yang

seluruhnya terverifikasi melalui *unit test*, membuktikan bahwa sistem yang dibangun berfungsi sesuai dengan rancangan yang telah dibuat.

Sistem menghasilkan klasifikasi tingkat kerawanan banjir untuk kedua unit analisis, dengan Model A mengklasifikasikan 52 dari 66 desa/kelurahan (78,8%) sebagai Rawan dan Model B mengklasifikasikan 259 dari 1.500 titik sampel (17,3%) sebagai Rawan. Performa algoritma *Random Forest*, yang diukur menggunakan metrik akurasi, *F1-Score*, *Cohen's Kappa*, dan *Matthews Correlation Coefficient (MCC)*, menunjukkan bahwa Model A melalui *Repeated Cross-Validation* menghasilkan estimasi akurasi $77,73\% \pm 8,41\%$, sedangkan *Matriks Pemanding* terhadap keseluruhan 66 desa menghasilkan akurasi 92,42% dengan *Cohen's Kappa* 0,7791 (kategori *Substantial*). Model B melalui evaluasi pada 300 data uji menghasilkan akurasi 84,33%, *F1-Score* 0,8399, *AUC-ROC* 0,8528, *Cohen's Kappa* 0,4022 (kategori *Moderate*), dan *MCC* 0,4031. Selisih antara estimasi *Repeated Cross-Validation* Model A (77,73%) dan hasil *Matriks Pemanding* (92,42%) menunjukkan bahwa meskipun performa generalisasi Model A pada desa yang belum pernah dipelajari berada pada tingkat yang moderat, klasifikasi yang dihasilkan model tetap konsisten dengan data historis banjir aktual pada tingkat yang tinggi ketika diterapkan pada keseluruhan populasi 66 desa. Hal ini mengindikasikan bahwa algoritma *Random Forest*, meskipun dilatih pada jumlah sampel yang terbatas, mampu mempelajari pola hubungan antar variabel geospasial penyebab banjir dengan cukup baik sehingga hasil klasifikasinya sejalan dengan kondisi kerawanan banjir yang sesungguhnya terjadi di Kota Langsa.

5.2 Saran

Berdasarkan hasil penelitian dan keterbatasan yang ditemukan, peneliti mengajukan beberapa saran untuk pengembangan penelitian selanjutnya sebagai berikut:

1. Penelitian selanjutnya disarankan untuk menambahkan variabel kerentanan sosial-ekonomi, seperti kepadatan penduduk, jumlah fasilitas umum dan infrastruktur vital, serta tingkat kesiapsiagaan masyarakat, sebagai pelengkap 10 variabel fisik-spasial yang digunakan pada penelitian ini. Penambahan tersebut diperlukan karena perbandingan hasil klasifikasi model dengan dokumen Kajian Risiko Bencana (KRB) Kota Langsa pada Sub-bab 4.7 menunjukkan perbedaan peringkat kerawanan antar kecamatan, yang disebabkan oleh dokumen KRB memperhitungkan komponen kerentanan dan kapasitas selain bahaya fisik, sedangkan model pada penelitian ini hanya menggunakan variabel fisik-spasial.
2. Penelitian selanjutnya disarankan untuk mengkaji teknik penyeimbangan data tambahan seperti *Synthetic Minority Oversampling Technique (SMOTE)*, penyesuaian ambang batas (*threshold*) probabilitas klasifikasi selain nilai 0,5, atau perbandingan dengan algoritma klasifikasi lain seperti *Gradient Boosting* dan *XGBoost*, dengan tujuan meningkatkan *Recall* kelas Rawan pada Model B yang pada penelitian ini tercatat sebesar 46,94% pada data uji (n=300), tanpa menurunkan akurasi keseluruhan sebesar 84,33% yang telah dicapai.
3. Sistem *WebGIS* yang dibangun pada penelitian ini disarankan untuk dikembangkan menjadi alat bantu pengambilan keputusan bagi Pemerintah

Kota Langsa, khususnya Badan Penanggulangan Bencana Daerah (BPBD) Kota Langsa, melalui penambahan mekanisme pembaruan data historis banjir secara berkala serta pembaruan data curah hujan secara berkala, sehingga hasil klasifikasi yang ditampilkan pada sistem dapat terus disesuaikan dengan kondisi lapangan terbaru.

4. Sistem peramalan kerawanan banjir dengan cakupan wilayah yang lebih luas dapat dikembangkan apabila: (a) cakupan wilayah kajian diperluas ke beberapa kota/kabupaten dengan karakteristik topografi dan curah hujan yang berbeda, dan (b) data historis yang digunakan sebagai *ground truth* mencakup beberapa kejadian banjir pada musim yang berbeda, tidak hanya satu kejadian sebagaimana pada penelitian ini (banjir 31 Januari 2026). Hal tersebut diperlukan karena algoritma *Random Forest* tidak melakukan ekstrapolasi terhadap nilai di luar rentang data latih, sebagaimana ditunjukkan oleh nilai *feature importance* variabel curah hujan (*ch_skor*) sebesar 0,0000 akibat homogenitas nilai curah hujan pada wilayah kajian, *ground truth* yang hanya bersumber dari satu kejadian banjir, dan *Recall* kelas Rawan pada data uji Model B sebesar 46,94% sebagaimana disebutkan pada kesimpulan.

Keempat saran tersebut diharapkan dapat menjadi acuan bagi pengembangan penelitian lanjutan yang berkaitan dengan klasifikasi daerah rawan banjir berbasis *GIS* dan *Machine Learning*, baik dari aspek data, metodologi, pengembangan sistem, maupun pemanfaatannya oleh pemangku kebijakan.

RENCANA ANGGARAN PENELITIAN

No	Uraian	Volume	Satuan	Harga Satuan (Rp)	Jumlah
1	Kertas A4	2	Rim	Rp. 55.000	Rp. 110.000
2	Cetak Buku	2	Buku	Rp. 30.000	Rp. 60.000
3	Transportasi	3	Bulan	Rp. 200.000	Rp. 600.000
4	Print Proposal	5	Rangkap	Rp. 20.000	Rp. 100.000
Total					Rp. 870.000

DAFTAR PUSTAKA

- [1] O. Rahmati *et al.*, “Multi-hazard exposure mapping using machine learning techniques: A case study from Iran,” *Remote Sens. (Basel)*, vol. 11, no. 16, 2019, doi: 10.3390/rs11161943.
- [2] K. Khosravi, A. M. Melesse, H. Shahabi, A. Shirzadi, K. Chapi, and H. Hong, “Flood susceptibility mapping at Ningdu catchment, China using bivariate and data mining techniques,” in *Extreme Hydrology and Climate Variability: Monitoring, Modelling, Adaptation and Mitigation*, Elsevier, 2019, pp. 419–434. doi: 10.1016/B978-0-12-815998-9.00033-6.
- [3] B. Nasional and P. Bencana, “B N P B INDEKS RISIKO BENCANA INDONESIA”.
- [4] B. Irawan, S. Syafrudin, and M. A. Budihardjo, “Prosiding Seminar Nasional Sains dan Teknologi Seri 02 Fakultas Sains dan Teknologi,” *Universitas Terbuka*, vol. 1, no. 2, 2024.
- [5] H. A. H. Al-Najjar and B. Pradhan, “Spatial landslide susceptibility assessment using machine learning techniques assisted by additional data created with generative adversarial networks,” *Geoscience Frontiers*, vol. 12, no. 2, pp. 625–637, Mar. 2021, doi: 10.1016/j.gsf.2020.09.002.
- [6] “KAJIAN RISIKO BENCANA KOTA LANGSA,” 2025.
- [7] K. DI Rawan Bencana Banjir Daerah Aliran Sungai Seulalah Kota Langsa, A. Sekar Ningrum, K. Br Ginting, and D. Tanggal, “STRATEGI PENANGANAN BANJIR BERBASIS MITIGASI BENCANA PADA.” [Online]. Available: <http://jurnal.unsil.ac.id/index.php/geosee/index>
- [8] K. Darmawan and A. Suprayogi, “ANALISIS TINGKAT KERAWANAN BANJIR DI KABUPATEN SAMPANG MENGGUNAKAN METODE OVERLAY DENGAN SCORING BERBASIS SISTEM INFORMASI GEOGRAFIS,” 2017.
- [9] A. Faruq and A. Syaiful Amal, “Desain Sistem Prediksi Wilayah Terdampak Banjir dengan *Machine Learning* berbasis Data *Sistem Informasi Geografis*,” *Seminar Keinsinyuran*, 2024.
- [10] M. Bagas, A. Darmawan, F. Dewanta, and S. Astuti, “Analisis Perbandingan Algoritma Decision Tree, *Random Forest*, dan Naïve Bayes untuk Prediksi Banjir di Desa Dayeuhkolot Comparative Analysis of Decision Tree, *Random Forest*, and Naïve Bayes Algorithm for Flood Prediction at Dayeuhkolot Village,” *TELKA*, vol. 9, no. 1, pp. 52–61, 2023.
- [11] C. Singha, V. K. Rana, Q. B. Pham, D. C. Nguyen, and E. Łupikasza, “Integrating machine learning and geospatial data analysis for

- comprehensive flood hazard assessment,” *Environmental Science and Pollution Research*, vol. 31, no. 35, pp. 48497–48522, Jul. 2024, doi: 10.1007/s11356-024-34286-7.
- [12] A. Apriana, A. R. Al Ansory, T. Agustina, I. Amalia, and R. Refrizon, “Mapping Flood-Prone Areas Using *GIS* Through as Geo-Artificial Intelligence (Geo-Ai) Approach in Bengkulu City,” *Journal of Technomaterial Physics*, vol. 6, no. 1, pp. 56–61, Feb. 2024, doi: 10.32734/jotp.v6i1.16006.
- [13] P. Ony Andewi, K. Agus Seputra, K. Yota Ernanda Aryanto, L. Joni Erawati Dewi, and F. Teknik dan Kejuruan, “INTEGRASI TEKNOLOGI PENGINDERAAN JAUH DAN MACHINE LEARNING PADA WEB *GIS* UNTUK PEMETAAN POTENSI BANJIR,” *Jurnal Pendidikan Teknologi dan Kejuruan*, vol. 22, no. 1, 2025.
- [14] M. Seprianto, M. Anggo, L. Harudu, and S. Aldiansyah, “Pemetaan Daerah Potensi Rawan Banjir Menggunakan Metode Overlay,” vol. 9, no. 4, 2024.
- [15] V. Irmawati, O. Cahyono, Mujiyo, S. Maro’ah, N. M. Istiqomah, and M. R. Romadhon, “Flood Susceptibility Index Analysis Using Overlay Method and *GIS*-based,” *JST (Jurnal Sains dan Teknologi)*, vol. 12, no. 2, Oct. 2023, doi: 10.23887/jstundiksha.v12i2.52737.
- [16] C. S. Rotua Aritonang, A. S. Handayani, S. Suroso, W. Caesarendra, and A. Asriyadi, “Comparative Analysis Of *Random Forest* and Naive Bayes for Flood Classification Using Sentinel-1 SAR,” *bit-Tech*, vol. 8, no. 2, pp. 1304–1314, Dec. 2025, doi: 10.32877/bt.v8i2.2852.
- [17] U. F. Kurniawati *et al.*, “Pengolahan Data Berbasis *Sistem Informasi Geografis* (SIG) Untuk Kebutuhan Penyusunan Profil di Kecamatan Sukolilo,” *Jurnal Pengabdian kepada Masyarakat-LPPM ITS*.
- [18] M. Wahyuni Pertanahan and S. Tinggi Pertanahan Nasional, “PEMANFAATAN DATA SPASIAL DALAM PEMETAAN TEMATIK DI PADUKUHAN PROMASAN KABUPATEN KULONPROGO,” doi: 10.47002/jpm.v4i1.912.
- [19] M. Grandini, E. Bagli, and G. Visani, “Metrics for Multi-Class Classification: an Overview,” Aug. 2020, [Online]. Available: <http://arxiv.org/abs/2008.05756>
- [20] R. Delgado and X. A. Tibau, “Why *Cohen’s Kappa* should be avoided as performance measure in classification,” *PLoS One*, vol. 14, no. 9, Sep. 2019, doi: 10.1371/journal.pone.0222916.

- [21] D. Chicco and G. Jurman, “The Matthews correlation coefficient (*MCC*) should replace the ROC AUC as the standard metric for assessing binary classification,” *BioData Min.*, vol. 16, no. 1, Dec. 2023, doi: 10.1186/s13040-023-00322-4.