

**KLASIFIKASI PENYAKIT DAUN KELAPA SAWIT
MENGUNAKAN ARSITEKTUR *RESNET-50* DENGAN
PENDEKATAN *TRANSFER LEARNING* (STUDI KASUS PADA
PERKEBUNAN PANGKALAN SUSU)**

SKRIPSI

Diajukan Sebagai Salah Satu Syarat untuk Menyelesaikan
Pendidikan Jenjang Sarjana Terapan Pada
Politeknik Negeri Lhokseumawe



Oleh :

AGUNG RAMADHAN SETIAWAN

NIM : 2022573010081
Program Studi : Teknik Informatika
Jurusan : Teknologi Informasi dan Komputer

**KEMENTERIAN PENDIDIKAN TINGGI, SAINS, DAN
TEKNOLOGI POLITEKNIK NEGERI LHOKSEUMAWE**

2025

PENGESAHAN PEMBIMBING

Skripsi yang berjudul *Klasifikasi Penyakit Daun Kelapa Sawit Menggunakan Arsitektur ResNet-50 dengan Pendekatan Transfer Learning (Studi Kasus Pada Perkebunan Pangkalan Susu)*, disusun oleh Agung Ramadhan Setiawan, NIM 2022573010081, Program Studi Teknik Informatika, Jurusan Teknologi Informasi dan Komputer Politeknik Negeri Lhokseumawe, telah memenuhi syarat untuk dipertanggungjawabkan dihadapan dewan penguji.

Pembimbing I,

Buket Rata, 18 Juni 2026
Pembimbing II,

Dr. Rahmad Hidayat, S.Kom., M.Cs.
NIP. 198304202012121003

Mahdi, S.T., M.Cs.
NIP. 197008021993031001

Mengetahui,

Ketua Jurusan Teknologi Informasi
dan Komputer,

Ketua Program Studi
Teknik Informatika,

Salahuddin, S.T., M.Cs.
NIP. 197404242002121001

M. Khadafi, S.T., M.T.
NIP. 197507182002121004

PENGESAHAN PENGUJI

Skripsi yang berjudul *Klasifikasi Penyakit Daun Kelapa Sawit Menggunakan Arsitektur ResNet-50 dengan Pendekatan Transfer Learning (Studi Kasus Pada Perkebunan Pangkalan Susu)*, disusun oleh Agung Ramadhan Setiawan, NIM 2022573010081, Program Studi Teknik Informatika, Jurusan Teknologi Informasi dan Komputer Pada Politeknik Negeri Lhokseumawe, telah dipertanggungjawabkan didepan dewan penguji dan dinyatakan lulus pada tanggal 00 Juni 2026.

Komisi Sidang,

Nama Ketua Sidang

NIP.

(Ketua Sidang)

Nama Sekretaris Sidang

NIP.

(Sekretaris Sidang)

Azhar, S.T., M.T.

NIP.

(Penguji 1)

Huzaeni, SST., M.IT.

NIP.

(Penguji 2)

Hendrawaty, S.T., M.T.

NIP.

(Penguji 3)

Mengetahui,

Ketua Jurusan

Teknologi Informasi dan Komputer,

Ketua Program Studi

Teknik Informatika,

Salahuddin, S.T., M.Cs.

NIP. 197404242002121001

M. Khadafi, S.T., M.T.

NIP. 197507182002121004

HALAMAN PERNYATAAN

Dengan ini saya menyatakan bahwa dalam Skripsi ini tidak terdapat karya yang pernah diajukan untuk mendapatkan gelar kesarjanaan di suatu Perguruan Tinggi, dan sepanjang pengetahuan saya juga tidak terdapat karya atau pendapat yang pernah ditulis orang lain, kecuali yang secara tertulis diacu dalam naskah dan disebut dalam daftar pustaka.

Lhokseumawe, 18 Juni 2026

A handwritten signature in black ink, consisting of stylized, flowing letters that appear to read 'Agung Ramadhan Setiawan'.

Agung Ramadhan Setiawan
NIM. 2022573010081

KATA PENGANTAR

Segala puji beserta syukur senantiasa penulis panjatkan kepada Allah SWT yang telah memberikan rahmat dan petunjuk-Nya kepada penulis sehingga dapat menyelesaikan skripsi yang berjudul “*Klasifikasi Penyakit Daun Kelapa Sawit Menggunakan Arsitektur ResNet-50 dengan Pendekatan Transfer Learning (Studi Kasus Pada Perkebunan Pangkalan Susu)*”. Shalawat beserta salam kepada baginda Rasulullah Muhammad SAW, keluarga, dan para sahabat yang telah berjasa dalam memperjuangkan islam dan ilmu pengetahuan. Skripsi ini disusun sebagai salah satu syarat untuk menyelesaikan pendidikan Sarjana Terapan Program Studi Teknik Informatika Jurusan Teknologi Informasi dan Komputer Politeknik Negeri Lhokseumawe.

Dalam Penyusunan skripsi ini penulis banyak mendapatkan dukungan, perhatian, dorongan, bimbingan dan berbagai bantuan dari banyak pihak terutama para dosen pembimbing. Dengan demikian, segala hormat dan kerendahan hati penulis ini menyampaikan rasa terima kasih yang tidak terhingga terutama kepada:

1. Ucapan teristimewa kepada kedua orang tua yaitu Ayahanda Agus Setiawan dan Ibunda Sri Ramayani yang selalu memberikan doa, dukungan dan materi serta memberikan semangat dan kasih sayang sehingga penulis dapat berdiri tegar dan menyelesaikan skripsi ini. Teruntuk adik kakak tersayang Arie Fontana Setiawan dan M. Aditya Setiawan.
2. Bapak Dr. Rahmad Hidayat, S.Kom., M.Cs. dan Bapak Mahdi, S.T., M.Cs., selaku pembimbing I dan II yang telah membimbing penulis, memberi petunjuk, memberi saran-saran dan arahan serta masukan dari awal masa pengajuan judul sampai berhasil menyelesaikan Skripsi.
3. Bapak Mahdi , S.T., M.Cs., selaku Koordinator Skripsi, atas segala perhatian, arahan, dan dukungan yang telah membantu kelancaran penulis dalam menyelesaikan skripsi ini. Para dosen dan tenaga pengajar Program Studi Teknik Informatika yang telah memberikan arahan dan bimbingan selama proses perkuliahan.

4. Bapak Salahuddin, S.T., M.Cs. selaku Ketua Jurusan Teknologi Informasi dan Komputer, Bapak Fachri Yanuar Rudi F, S.S.T., M.T. selaku Sekretaris Jurusan Teknologi Informasi dan Komputer, dan Bapak M. Khadafi, S.T., M.T. selaku Ketua Program Studi Teknik Informatika atas segala bimbingan dan perhatian selama masa perkuliahan.
5. Bapak Ir. Rizal Syahyadi, ST, M.Eng.Sc IPM.ASEAN Eng., APEC Eng., selaku Direktur Politeknik Negeri Lhokseumawe.
6. Bapak Azhar, S.T., M.T., Bapak Huzaeni, SST., M.IT. dan Ibu Hendrawaty, S.T., M.T. selaku penguji yang telah bersedia memberikan arahan dan masukan dalam pengerjaan Skripsi ini.
7. Ucapan terimakasih penulis sampaikan kepada Kawan-Kawan terdekat Muhammad Rizki, Muhammad Fadhila, Reyhan Putra Syahmi, Dimas Kurniawan, Putri Alvioli dan Member Kurohana yang senantiasa memberi dukungan, menemani, serta berjuang bersama, seperti kata Uzumaki Naruto *"Teman itu adalah orang yang menyelamatkan dari neraka yang bernama kesepian."*. Terima kasih juga kepada seluruh teman-teman Angkatan 2022 Program Studi Teknik Informatika yang telah menjadi bagian dari perjalanan penuh cerita dan perjuangan. Kepada (GenBI) atas pengalaman berharga yang membuka banyak kesempatan, (Himatik) yang telah memberikan ruang untuk belajar, berproses, dan kenangan yang sangat berarti dan (KOMIT) yang memberikan pengalaman dalam ilmu bidang IT.
8. Terakhir yang tidak kalah penting, saya ingin mengucapkan terima kasih yang sebesar-besarnya kepada diri saya sendiri, karena sudah bertahan, berproses, dan menolak untuk menyerah dalam menyelesaikan skripsi ini. Dalam perjalanan menyusun sistem klasifikasi ini, ada kalanya *error code* bermunculan tanpa henti, jalan terasa buntu, hingga mengharuskan perombakan topik penelitian. Namun, alih-alih meratapinya, terima kasih karena memilih untuk bangkit dan melihatnya sebagai bagian dari proses belajar.

Seperti kata Jiraiya: *"Kegagalan juga menyenangkan, hidup dengan kepercayaan bahwa cobaan itu berguna untuk menempa diri sendiri."*

Segala kegagalan saat menyusun logika, mencari solusi *bug*, hingga merombak ulang draf nyatanya telah menempa mental dan kemampuanmu menjadi jauh lebih tangguh. Terima kasih juga atas setiap waktu dan tenaga yang dikorbankan, mulai dari turun langsung ke Perkebunan Pangkalan Susu untuk mengumpulkan data, hingga malam-malam panjang yang dihabiskan untuk melatih model dan menyelesaikan revisi. Mengingat kembali apa yang dikatakan

Naruto Uzumaki: *"Aku tidak peduli akan jadi apa aku di masa depan. Apakah aku akan berhasil ataupun gagal. Tapi yang pasti, apa yang aku lakukan sekarang akan membentukku di masa depan."* Segala lelah, ketekunan, dan kerja keras yang kamu tuangkan dalam penelitian ini adalah fondasi berharga yang sedang kamu bangun untuk dirimu sendiri kelak.

Penulis menyadari masih banyak kekurangan dalam penulisan ini dan berharap skripsi ini bermanfaat bagi semua pihak serta amal baik yang diberikan kepada penulis dibalas oleh Allah SWT. Aamiin.

Lhokseumawe, 18 Juni 2026.

Penulis,

Agung Ramadhan Setiawan

NIM. 2022573010081

RINGKASAN

Penelitian ini bertujuan mengembangkan sistem klasifikasi penyakit daun kelapa sawit berbasis citra menggunakan pendekatan *deep learning* untuk mengatasi kendala identifikasi manual yang memakan waktu dan kurang konsisten. Penelitian ini menerapkan *Convolutional Neural Network* (CNN) dengan arsitektur *ResNet-50* melalui pendekatan *transfer learning* untuk mengklasifikasikan lima kondisi daun yaitu *Healthy*, *Dryness*, *Fungal Disease*, *Magnesium Deficiency*, dan *Scale Insect*, dengan studi kasus pada Perkebunan Pangkalan Susu. Evaluasi model menggunakan tiga skenario dataset yaitu *primer* foto yang diambil langsung di Perkebunan Pangkalan Susu, *sekunder* yang bersumber dari kaggle, dan *multi modal* gabungan keduanya. Tahapan penelitian mencakup pengumpulan data, pra-pemrosesan, augmentasi, pelatihan, *fine tuning*, evaluasi performa, serta implementasi ke dalam aplikasi berbasis web. Hasil pengujian menunjukkan akurasi model pada dataset *sekunder* sebesar 82,66%, dataset *primer* 96,60%, dan dataset *multi-modal* 89,87%. Meskipun akurasi dataset *primer* tertinggi, model *multi-modal* menunjukkan kemampuan generalisasi yang lebih stabil dalam mengenali variasi karakteristik citra dari berbagai sumber. Kesimpulannya, penggabungan dataset terbukti meningkatkan kemampuan model dalam mengidentifikasi penyakit daun kelapa sawit secara otomatis dan lebih adaptif terhadap kondisi nyata di lapangan.

Kata Kunci: *CNN*, *ResNet-50*, *Transfer Learning*, Penyakit Daun Kelapa Sawit.

ABSTRACT

This study aims to develop an image-based classification system for oil palm leaf diseases using a deep learning approach to overcome the constraints of manual identification, which is time-consuming and less consistent. This research implements a Convolutional Neural Network (CNN) with the ResNet-50 architecture through a transfer learning approach to classify five leaf conditions Healthy, Dryness, Fungal Disease, Magnesium Deficiency, and Scale Insect, with a case study at the Pangkalan Susu Plantation. Model evaluation was conducted using three dataset scenarios: a primary dataset consisting of photos taken directly at the Pangkalan Susu Plantation, a secondary dataset sourced from Kaggle, and a multi-modal dataset combining both. The research stages encompass data collection, preprocessing, augmentation, training, fine-tuning, performance evaluation, and implementation into a web-based application. The test results indicate that the model's accuracy on the secondary dataset is 82.66%, the primary dataset is 96.60%, and the multi-modal dataset is 89.87%. Although the primary dataset achieved the highest accuracy, the multi-modal model demonstrates a more stable generalization capability in recognizing variations in image characteristics from diverse sources. In conclusion, the integration of datasets is proven to enhance the model's capability to automatically and adaptively identify oil palm leaf diseases under real field conditions.

Keywords: CNN, ResNet-50, Transfer Learning, Oil Palm Leaf Disease.

DAFTAR ISI

	Halaman
PENGESAHAN PEMBIMBING	i
PENGESAHAN PENGUJI	ii
HALAMAN PERNYATAAN.....	iii
KATA PENGANTAR.....	iv
RINGKASAN	vii
ABSTRACT	viii
DAFTAR ISI.....	ix
DAFTAR GAMBAR	xii
DAFTAR TABEL	xiii
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	4
1.3 Tujuan Penelitian.....	5
1.4 Batasan Masalah.....	5
1.5 Manfaat Penelitian	6
1.6 Sistematika Penulisan.....	7
BAB II TINJAUAN PUSTAKA	8
2.1 <i>State Of The Art</i>	8
2.2 Penyakit Daun Kelapa Sawit.....	11
2.3 <i>Deep Learning</i>	13
2.4 <i>Convolutional Neural Network (CNN)</i>	14
2.5 <i>Arsitektur ResNet-50 (Residual Neural Network)</i>	15
2.6 <i>Transfer Learning</i>	18
2.7 <i>Confusion Matrix</i>	18
2.8 <i>Black box Testing</i>	20
2.9 <i>White Box Testing</i>	21
BAB III METODOLOGI PENELITIAN	22
3.1 Alur Penelitian.....	22
3.2 Analisa Kebutuhan Fungsional	23
3.3 Analisa Kebutuhan Non Fungsional	24
3.4 Rancangan Sistem	27

3.4.1 Ilustrasi Sistem	27
3.4.2 <i>Use Case Diagram</i>	29
3.4.3 <i>Activity Diagram</i>	33
3.4.4 Perancangan Database.....	38
3.4.5 Rancangan Antarmuka Pengguna (<i>User Interface</i>).....	41
3.5 Pengumpulan Data	45
3.6 <i>Preprocessing</i> (Pra-pemrosesan).....	48
3.6.1 Pengecekan dan Konversi Format Citra.....	49
3.6.2 <i>Resizing</i> (Pengubahan Ukuran).....	49
3.6.3 Normalisasi Piksel dan <i>Standard ImageNet</i>	50
3.6.4 <i>Image Augmentation</i> (Augmentasi Citra)	50
3.7 <i>Model Development</i>	53
3.7.1 <i>ResNet-50</i>	53
3.7.2 <i>Model Training</i>	55
3.7.3 <i>Fine Tunning</i>	56
3.8 Tahap Evaluasi	57
3.8.1 <i>Testing</i> (Pengujian).....	57
3.8.2 Evaluasi dengan <i>Confusion Matrix</i>	58
3.8.3 Analisis Hasil	59
3.9 Perancangan Pengujian	59
BAB IV HASIL DAN PEMBAHASAN	61
4.1 Implementasi Sistem Klasifikasi Penyakit Daun Kelapa Sawit.....	62
4.1.1 Implementasi Halaman Beranda	62
4.1.2 Halaman Klasifikasi	63
4.1.3 Halaman Ensiklopedia	65
4.1.4 Halaman Login dan Register.....	65
4.1.5 Halaman Profil	67
4.1.6 Halaman Riwayat.....	67
4.1.7 Halaman Dashboard	68
4.2 Implementasi Pengumpulan Dataset	70
4.2.1 Dataset <i>Primer</i>	70
4.2.2 Dataset <i>Sekunder</i>	71
4.2.3 Dataset <i>Multi Modal</i>	72
4.3 <i>Preprocessing Data</i>	73

4.3.1 Pengecekan dan Konversi Format.....	73
4.3.2 <i>Resize</i> (Mengubah Ukuran Gambar).....	74
4.3.3 <i>Split Data</i>	75
4.3.4 Augmentasi Data	76
4.3.5 <i>Rescale</i> (Normalisasi Nilai Piksel).....	77
4.4 Implementasi Rancangan Arsitektur <i>ResNet-50</i>	78
4.4.1 Konfigurasi <i>Transfer Learning</i>	78
4.4.2 Proses Pelatihan Model	80
4.5 Perbandingan Model Berdasarkan Skenario Dataset	82
4.5.1 Perbandingan Akurasi Keseluruhan	82
4.5.2 Perbandingan Model dengan Penelitian Lain	83
4.6 Hasil Pengujian Arsitektur <i>ResNet-50</i>	85
4.6.1 <i>Confusion Matrix</i>	85
4.6.2 Metriks Evaluasi.....	88
4.6.3 Hasil Pengujian <i>BlackBox</i>	91
4.7 Hasil Pengujian <i>WhiteBox</i>	99
BAB V SIMPULAN DAN SARAN	116
5.1 Simpulan	116
5.2 Saran.....	117
DAFTAR PUSTAKA.....	118

DAFTAR GAMBAR

Gambar 2.1 <i>Dryness</i> . [15]	11
Gambar 2.2 <i>Fungal Disease</i> [15]	12
Gambar 2.3 <i>Magnesium Deficiency</i> [15]	12
Gambar 2.4 <i>Scale Insect</i> [15]	13
Gambar 2.5 Standard CNN Arsitektur [25].....	15
Gambar 2. 6 <i>Identity Block</i> ResNet [29]	16
Gambar 3. 1 Alur Penelitian.....	22
Gambar 3. 2 Ilustrasi Sistem	28
Gambar 3. 3 <i>Use Case Diagram</i> User.....	30
Gambar 3. 4 <i>Use Case Diagram</i> Admin	32
Gambar 3. 5 <i>Activity Diagram</i> Klasifikasi Daun	34
Gambar 3. 6 <i>Activity</i> Login dan Register	36
Gambar 3. 7 Rancangan Halaman Login	41
Gambar 3. 8 Rancangan Halaman Registrasi.....	42
Gambar 3. 9 Rancangan Halaman Profile.....	42
Gambar 3. 10 Rancangan Halaman Riwayat	43
Gambar 3. 11 Rancangan Halaman Admin	43
Gambar 3. 12 Rancangan Halaman Beranda	44
Gambar 3. 13 Rancangan Halaman Klasifikasi	44
Gambar 3. 14 Rancangan Halaman Ensiklopedia.....	45
Gambar 3. 15 <i>Flowchart Preprocessing</i>	48
Gambar 3. 16 <i>Grayscale Convert to RGB</i>	49
Gambar 3. 17 <i>Resize</i> Gambar.....	49
Gambar 3. 18 <i>Flowchart</i> Augmentasi	51
Gambar 3. 19 Hasil Augmentasi	52
Gambar 3. 20 <i>Workflow Tranfer Learning</i>	53
Gambar 4. 1 Implentasi Halaman Beranda	63
Gambar 4. 2 Implementasi Halaman Klasifikasi	64
Gambar 4. 3 Halaman Ensiklopedia.....	65
Gambar 4. 4 Form Login dan Registrasi.....	66
Gambar 4. 5 Halaman Profil	67
Gambar 4. 6 Halaman History	68
Gambar 4. 7 Halaman Dashboard Admin	69
Gambar 4. 8 Gambar Daun <i>Primer</i>	71
Gambar 4. 9 Gambar Daun <i>Sekunder</i>	72
Gambar 4. 10 <i>Confusion Matrix Primer</i>	86
Gambar 4. 11 <i>Confusion Matrix Sekunder</i>	87
Gambar 4. 12 <i>Confusion Matrix Multi Modal</i>	88

DAFTAR TABEL

Tabel 2. 1 <i>State Of The Art</i>	8
Tabel 3. 1 <i>Software</i> yang digunakan	25
Tabel 3. 2 Penggunaan <i>Sowtware</i>	26
Tabel 3. 3 <i>Use Case Diagram</i> User.....	31
Tabel 3. 4 Use Case Admin.....	32
Tabel 3. 5 Tabel Users	38
Tabel 3. 6 Tabel History	39
Tabel 3. 7 Tabel Diseases	40
Tabel 3. 8 Jumlah Dataset	46
Tabel 3. 9 <i>Data Splitting</i>	46
Tabel 3. 10 Distribusi Data <i>Training</i>	47
Tabel 3. 11 Contoh Citra Daun Sawit.....	47
Tabel 3. 12 Tabel Normalisasi.....	50
Tabel 4. 1 Dataset <i>Primer</i>	70
Tabel 4. 2 Dataset <i>Sekunder</i>	71
Tabel 4. 3 <i>Multi Modal</i>	73
Tabel 4. 4 Konversi	74
Tabel 4. 5 <i>Resize</i>	75
Tabel 4. 6 <i>Split Data</i>	75
Tabel 4. 7 Rotasi.....	76
Tabel 4. 8 Code Normalisasi Standar Imagenet	77
Tabel 4. 9 Arsitektur Model <i>ResNet-50</i>	78
Tabel 4. 10 Arsitektur Model <i>ResNet-50</i>	79
Tabel 4. 11 <i>Hyperparameter</i> Pelatihan Model	81
Tabel 4. 12 <i>Hyperparameter</i> Pelatihan Model	81
Tabel 4. 13 Perbandingan Antar Model.....	82
Tabel 4. 14 Perbandingan Penelitian	83
Tabel 4. 15 Hasil Evaluasi Per Kelas (<i>Primer</i>)	89
Tabel 4. 16 Hasil Evaluasi Metrik Per Kelas (<i>Sekunder</i>).....	89
Tabel 4. 17 Hasil Evaluasi Metrik Per Kelas (<i>Multi Modal</i>).....	90
Tabel 4. 18 Pengujian <i>Blackbox</i> Autentikasi.....	92
Tabel 4. 19 Pengujian <i>Blackbox</i> Halaman Utama.....	94
Tabel 4. 20 Pengujian <i>Blackbox</i> Halaman Klasifikasi	95
Tabel 4. 21 Pengujian <i>Blackbox</i> Ensiklopedia	97
Tabel 4. 22 Pengujian <i>Blackbox</i> Halaman Riwayat, Profil, dan Dashboard	98
Tabel 4. 23 <i>Whitebox Preprocessing</i>	100
Tabel 4. 24 <i>Test Case Scenario Preprocessing</i>	100
Tabel 4. 25 <i>Whitebox Split Data</i>	101
Tabel 4. 26 <i>Test Case Scenario Split Data</i>	102
Tabel 4. 27 <i>Whitebox</i> Augmentasi.....	103
Tabel 4. 28 <i>Test Case Scenario Augmentasi</i>	104
Tabel 4. 29 <i>Whitebox ResNet-50</i>	105
Tabel 4. 30 <i>Test Case Scenario ResNet-50</i>	106
Tabel 4. 31 <i>White Box</i> Proses Login	108

Tabel 4. 32 <i>White Box</i> Proses Login	108
Tabel 4. 33 <i>White Box Endpoint Inferensi /predict</i>	111
Tabel 4. 34 <i>White Box Endpoint Inferensi /predict</i>	111
4. 35 <i>White Box</i> Validasi Unggah Gambar	114
Tabel 4. 36 <i>White Box</i> Validasi Unggah Gambar	114

BAB I

PENDAHULUAN

1.1 Latar Belakang

Kelapa sawit merupakan komoditas perkebunan unggulan yang memegang peranan penting dalam perekonomian Indonesia sebagai salah satu penghasil devisa negara terbesar, sebesar USD 22,86 miliar dengan volume ekspor sebesar 32,36 juta ton pada tahun 2024, jika dibandingkan dengan tahun 2023 neraca volume perdagangan mengalami penurunan sebesar 15,39%, begitu juga neraca nilai perdagangan kelapa sawit mengalami penurunan sebesar 10,76%, surplus nilai neraca perdagangan kelapa sawit tahun 2024 mencapai USD 22,85 miliar menurut penelitian [1]. Berdasarkan Surat Keputusan Menteri Pertanian Bernomor 833/KPTS/SR. 020/M/12/2019, luas lahan kelapa sawit di Indonesia mencapai 16.38 juta hektar yang tersebar di 25 provinsi. Perkebunan kelapa sawit yang dikelola oleh rakyat mencakup 6.2 juta hektar. Perkebunan kelapa sawit juga merupakan tulang punggung ekonomi bagi 16.2 juta penduduk Indonesia yang bekerja secara langsung maupun tidak langsung di sektor perkebunan kelapa sawit berdasarkan pada penelitian [2]. Meskipun demikian, merawat pohon sawit bukanlah hal yang mudah. Tingginya tingkat produksi kelapa sawit sangat dipengaruhi oleh kondisi kesehatan tanaman, khususnya pada bagian daun yang berperan langsung dalam proses fotosintesis. Penyakit daun kelapa sawit seperti *dryness*, *fungus disease*, *magnesium deficiency*, dan *scale insect* sering kali menimbulkan kerusakan visual pada daun yang berujung pada terganggunya proses fotosintesis dan pertumbuhan tanaman. Jika tidak terdeteksi secara dini, penyakit

tersebut dapat menyebar luas dan menyebabkan kerugian ekonomi yang signifikan bagi pengelola perkebunan [3].

Biasanya proses identifikasi penyakit daun kelapa sawit masih banyak dilakukan secara manual melalui pengamatan visual oleh tenaga ahli atau petugas lapangan. Metode konvensional ini memiliki beberapa keterbatasan, antara lain ketergantungan pada pengalaman pengamat, potensi subjektivitas dalam penilaian, keterbatasan jumlah tenaga ahli, serta waktu identifikasi yang relatif lama [4]. Selain itu, kondisi lingkungan di lapangan seperti pencahayaan yang tidak seragam, variasi sudut pandang, dan luasnya area perkebunan turut menyulitkan proses pemantauan kesehatan tanaman secara menyeluruh dan konsisten. Situasi ini menunjukkan perlunya solusi berbasis teknologi yang mampu membantu proses identifikasi penyakit secara lebih cepat, objektif, dan terukur [5].

Perkembangan teknologi *Artificial Intelligence* (AI), khususnya pada bidang *Computer Vision* dan *Deep Learning*, membuka peluang besar dalam otomatisasi proses identifikasi penyakit tanaman melalui analisis citra digital [6]. Salah satu pendekatan yang banyak digunakan dalam pengolahan citra adalah *Convolutional Neural Network* (CNN), yang terbukti memiliki kemampuan unggul dalam mengekstraksi fitur visual dan mengenali pola kompleks pada gambar. CNN mampu mempelajari karakteristik visual seperti tekstur, warna, dan bentuk yang menjadi indikator penting dalam membedakan kondisi daun sehat dan daun yang terinfeksi penyakit [7].

Namun pelatihan model CNN dari awal (*training from scratch*) umumnya memerlukan dataset dalam jumlah besar dan waktu komputasi yang tinggi. Dalam

konteks penelitian akademik maupun implementasi di lapangan, ketersediaan dataset berlabel dalam jumlah besar sering menjadi kendala [8]. Untuk mengatasi hal tersebut, pendekatan *Transfer Learning* menjadi solusi yang relevan. Dengan memanfaatkan pengetahuan dari model yang telah dilatih sebelumnya (*pre-trained model*), proses pelatihan menjadi lebih cepat dan mampu mencapai akurasi yang optimal meskipun diterapkan pada domain yang berbeda, seperti pada klasifikasi kondisi jalan maupun diagnosa medis [9]. Pendekatan ini memungkinkan model untuk beradaptasi dengan dataset baru secara lebih efisien, termasuk pada kasus klasifikasi penyakit daun kelapa sawit.

Model ResNet (*Residual Network*) merupakan salah satu arsitektur CNN yang banyak digunakan dalam transfer learning karena kemampuannya mengatasi permasalahan *vanishing gradient* pada jaringan yang dalam. Dengan struktur *residual block*, *ResNet-50* mampu mempertahankan performa tinggi seiring bertambahnya kedalaman jaringan. Hal ini menjadikan *ResNet-50* sebagai kandidat yang kuat untuk diterapkan pada klasifikasi penyakit daun kelapa sawit yang memiliki variasi visual antar kelas yang cukup kompleks [10]. Penelitian sebelumnya telah membuktikan bahwa model ResNet mampu mengenali gejala penyakit pada daun padi dengan akurasi tinggi mencapai 91,52% saat menggunakan ResNet-101 sedangkan ketika menggunakan InceptionResNet akurasi mencapai 92.68% [11].

Selain aspek metode, kualitas dan keragaman dataset juga menjadi faktor krusial dalam pengembangan model klasifikasi citra. Dataset yang hanya bersumber dari lingkungan terkontrol sering kali menghasilkan model yang kurang

robust saat diterapkan di kondisi nyata. Oleh sebab itu, penelitian ini memanfaatkan kombinasi dataset publik dari Kaggle dan dataset citra yang dikumpulkan langsung dari perkebunan di wilayah Pangkalan Susu. Penggabungan dua sumber data ini bertujuan untuk memperkaya variasi data, mencakup perbedaan kondisi pencahayaan, latar belakang, sudut pengambilan gambar, serta tingkat keparahan penyakit, sehingga model yang dihasilkan memiliki kemampuan generalisasi yang lebih baik terhadap kondisi lapangan sebenarnya [12].

Penelitian ini diharapkan dapat menghasilkan model yang akurat dan efisien dalam mengidentifikasi jenis penyakit daun kelapa sawit secara otomatis. Dengan adanya sistem klasifikasi berbasis *Deep Learning*, proses pemantauan kesehatan tanaman dapat dilakukan secara lebih cepat dan konsisten, sehingga mendukung pengambilan keputusan yang tepat dalam pengelolaan perkebunan.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah dalam penelitian ini adalah sebagai berikut :

1. Bagaimana menangani tantangan keterbatasan jumlah dataset berlabel dan *background noise* pada citra daun agar model dapat mengenali fitur penyakit dengan akurat?
2. Bagaimana mengimplementasikan metode *Convolutional Neural Network* dengan pendekatan *transfer learning* menggunakan model *ResNet-50* untuk klasifikasi penyakit daun kelapa sawit?

3. Bagaimana pengaruh penggunaan kombinasi dataset *primer* dan dataset *sekunder* terhadap performa dan kemampuan generalisasi model klasifikasi?

1.3 Tujuan Penelitian

Adapun tujuan yang ingin dicapai dalam penelitian Tugas Akhir ini adalah :

1. Melakukan Augmentasi pada data agar meningkatkan jumlah dataset yang dimiliki serta meningkatkan akurasi dalam klasifikasi.
2. Mengimplementasikan metode CNN dengan pendekatan *transfer learning* menggunakan model *ResNet-50* untuk klasifikasi penyakit daun kelapa sawit.
3. Menganalisis performa model klasifikasi berdasarkan hasil pengujian menggunakan dataset *primer* dari perkebunan Pangkalan Susu dan data *sekunder* dari kaggle.

1.4 Batasan Masalah

Agar penelitian ini tidak keluar dari bahasan serta mencapai tujuan yang diharapkan, maka penulis membatasi permasalahan penelitian pada beberapa poin yaitu :

1. Objek penelitian berfokus pada citra daun kelapa sawit yang diperoleh dari Kaggle dan observasi langsung pada Perkebunan sawit di Pangkalan Susu.
2. Penelitian hanya berfokus pada klasifikasi lima jenis kondisi daun, yaitu *Healthy*, *Dryness*, *Fungal Disease*, *Magnesium Deficiency*, dan *Scale Insect*.

3. Arsitektur yang digunakan adalah *ResNet-50* dengan pendekatan *Transfer Learning*.
4. Evaluasi model dilakukan menggunakan *confusion matrix* yang terdiri dari metrik akurasi, precision, recall, F1-score.
5. Penelitian tidak mencakup implementasi sistem dalam bentuk aplikasi *mobile* atau sistem *real-time* di lapangan, hanya dalam bentuk website.

1.5 Manfaat Penelitian

Penelitian ini diharapkan dapat membantu petani lokal dalam menangani penyakit daun sawit pada Perkebunan Pangkalan Susu untuk mengurangi kerugian hasil panen yang lebih besar serta meningkatkan pemahaman penulis dalam mengimplementasikan *Deep Learning*. Dengan mengetahui secara pasti jenis penyakit apa yang terjangkit pada daun sawit, dapat membantu pengendalian seperti penyemprotan fungisida atau pestisida agar dilakukan secara terarah. Hal ini mengurangi penggunaan bahan kimia berlebih, mencegah pencemaran lingkungan, dan menekan biaya produksi operasional Perkebunan. Hasil penelitian ini juga akan menunjukkan seberapa efektif teknik augmentasi dalam meningkatkan generalisasi model pada dataset yang kecil dan tidak seimbang, yang merupakan tantangan umum dalam *computer vision* di bidang pertanian.

1.6 Sistematika Penulisan

Sistematika penulisan skripsi ini bertujuan untuk memberikan Gambaran secara garis besar mengenai penelitian yang akan dilakukan. Adapun sistematika penulisannya sebagai berikut.

BAB I : PENDAHULUAN

Bab ini berisi latar belakang masalah, rumusan masalah, Batasan masalah, tujuan penelitian, manfaat penelitian, dan sistematika penulisan.

BAB II : TINJAUAN PUSTAKA

Bab ini berisi *state of the art* dan semua teori pendukung dalam melakukan penelitian mengenai sistem klasifikasi penyakit daun.

BAB III : METODELOGI PENELITIAN

Bab ini berisi metodologi penelitian yang menjelaskan tentang tahapan-tahapan dalam menjelaskan penelitian, yaitu rancangan sistem, pengumpulan data, metode dan teknik pengujian.

BAB IV : HASIL DAN PEMBAHASAN

Bab ini menjelaskan tentang hasil implementasi *user interface*, Implementasi metode, pengumpulan data, dan pengujian pada sistem klasifikasi penyakit daun kelapa sawit.

BAB V : PENUTUP

Bab ini merupakan bab yang membahas simpulan yang menjawab rumusan dan tujuan dari penelitian serta masukan dan saran untuk penelitian selanjutnya.

BAB II

TINJAUAN PUSTAKA

2.1 *State Of The Art*

State of the Art memberikan gambaran mengenai perkembangan terkini dalam pemanfaatan *Deep Learning* untuk deteksi penyakit tanaman serta digunakan untuk mengidentifikasi celah penelitian (*research gap*) yang dapat dikembangkan lebih lanjut. Belum banyak penelitian yang secara khusus mengoptimalkan arsitektur ResNet dengan teknik *fine-tuning* untuk mengklasifikasikan lima kategori daun yaitu sehat dan penyakit daun secara spesifik Daun *Healthy*, *Dryness*, *Fungal Disease*, *Magnesium Deficiency*, dan *Scale Insect* pada kondisi lingkungan nyata seperti di Perkebunan Pangkalan Susu. Oleh karena itu, integrasi pendekatan *Transfer Learning* ResNet dengan penggunaan dataset lokal yang representatif menjadi dasar kebaruan (*novelty*) dalam penelitian ini untuk menghasilkan model yang lebih adaptif dan akurat bagi kebutuhan praktis di lapangan. Detail dari jurnal penelitian terdahulu dapat dilihat pada Tabel 2.1.

Tabel 2. 1 *State Of The Art*

No	<i>State Of The Art</i>
1	Penulis/Tahun : Mandiri T, Dharmawan B, Ibn F, Untoro M (2025) [3] Judul Artikel : Identifikasi Penyakit Pada Daun Kelapa Sawit Dengan Pendekatan CNN AlexNet Metode Yang Digunakan : CNN Arsitektur AlexNet Dataset : citra daun kelapa sawit dengan 5 kelas penyakit yaitu bercak daun, daun berputar, daun berkerut, daun menguning, dan daun menggulung Hasil Yang Diperoleh : Akurasi latihan 97% dan akurasi validasi 80%. Persamaan : Objek penelitian pada daun kelapa sawit dan menggunakan CNN.

	Perbedaan : Menggunakan arsitektur AlexNet; Dataset bersifat lokal Lampung.
2	Penulis/Tahun : Ong J, Ong P, Lee W (2022) [4] Judul Artikel : Image-based Oil Palm Leaf Disease Detection using Convolutional Neural Network Metode Yang Digunakan : CNN Alexnet dan SVM Alexnet Dataset : 2000 Gambar penyakit daun kelapa sawit dengan 4 kelas yaitu daun sehat, bercak mata, busuk daun, dan bercak daun. Hasil Yang Diperoleh : AlexNet-CNN menghasilkan akurasi dari 93% - 99% sedangkan AlexNet-SVM menghasilkan akurasi 90%-99% Persamaan : Fokus pada deteksi penyakit daun kelapa sawit berbasis citra. Perbedaan : Tidak menggunakan pendekatan <i>Transfer Learning</i> dari model spesifik seperti ResNet.
3	Penulis/Tahun : Barburiceanu S, Meza S, Orza B, Malutan R, Terebes R (2021) Judul Artikel : Convolutional Neural Networks for Texture Feature Extraction. Applications to Leaf Disease Classification [7] Metode Yang Digunakan : <i>Pre-trained</i> AlexNet, VggNet, dan ResNet Dataset : Berbagai macam daun sehat tanaman dengan total 14997 gambar. Hasil Yang Diperoleh : Model pra-latih efektif mengekstraksi fitur tekstur untuk deteksi penyakit tanaman. Persamaan : Menggunakan <i>pre-trained model</i> dan fokus pada klasifikasi penyakit daun. Perbedaan : Objek penelitian adalah berbagai spesies tanaman umum (bukan spesifik kelapa sawit)
4	Penulis/Tahun : Ashiqul Islam M, Nymur Rahman Shuvo M, Shamshojaman M, Hasan S, Shahadat Hossain M, Khatun T (2021) [11] Judul Artikel : An Automated Convolutional Neural Network Based Approach for Paddy Leaf Disease Detection Metode Yang Digunakan : ResNet-101 dan Inception-ResNet-V2 Dataset : 4 Kelas daun penyakit padi yaitu bercak daun, hawar daun, jamur daun, dan daun sehat berjumlah 984. Hasil Yang Diperoleh : ResNet-101 mencapai akurasi 92,68% dan lebih stabil dibanding VGG-19. Persamaan : Penggunaan arsitektur berbasis <i>Residual Network</i> (ResNet).

	Perbedaan : Objek penelitian adalah tanaman padi; jumlah kelas dan jenis penyakit berbeda.
5	Penulis/Tahun : Ahmed M, Ahmed A (2023) [10] Judul Artikel : Palm tree disease detection and classification using residual network and transfer learning Metode Yang Digunakan : <i>Residual Network & Transfer Learning</i> Inception ResNet Dataset : 3 kelas dataset kurma yaitu bercak coklat, sehat dan bersisik putih dengan total gambar 2631 gambar. Hasil Yang Diperoleh : Mencapai akurasi tertinggi sebesar 99,62%. Persamaan : Menggunakan pendekatan <i>Transfer Learning</i> dan arsitektur <i>Residual Network</i>. Perbedaan : Fokus pada pohon kurma (<i>Date Palm</i>); Kategori penyakit tidak mencakup <i>Scale Insect</i>.
6	Penulis/Tahun : Haw Y, Lai K, Chuah J, Bejo S, Husin N, Hum Y, Yee P, Tee C, Ye X, Wu X (2023) [5] Judul Artikel : Classification of basal stem rot using deep learning: a review of digital data collection Metode Yang Digunakan : Review Deep Learning Methods Dataset : dataset dalam mendeteksi bibit kelapa sawit BSR yang terinfeksi Hasil Yang Diperoleh : Menggunakan CNN saja hanya dapat akurasi 60%, namun ketika melakukan augmentasi data mendapat akurasi 84% Persamaan : Membahas klasifikasi penyakit pada kelapa sawit menggunakan <i>Deep Learning</i>. Perbedaan : Berupa jurnal tinjauan (<i>Review</i>) yang fokus spesifik pada penyakit busuk pangkal batang (BSR).

2.2 Penyakit Daun Kelapa Sawit

Kelapa sawit (*Elaeis guineensis*) merupakan tanaman perkebunan yang memiliki nilai ekonomi tinggi karena menjadi bahan baku utama produksi minyak sawit. Produktivitas tanaman kelapa sawit sangat bergantung pada kondisi kesehatan tanaman sawit itu sendiri, khususnya daun sebagai organ utama dalam proses fotosintesis. Gangguan pada daun dapat menurunkan kemampuan tanaman dalam menghasilkan energi sehingga berdampak pada penurunan hasil panen. Penyakit daun kelapa sawit umumnya ditandai oleh perubahan warna, tekstur, dan bentuk daun [13]. Beberapa jenis penyakit yang sering ditemukan antara lain:

1. *Dryness*

Ditandai dengan kondisi daun yang mengering, perubahan warna menjadi kecokelatan, serta berkurangnya kelembapan jaringan daun. Kondisi ini dapat disebabkan oleh faktor lingkungan maupun gangguan fisiologis tanaman [14]. Gambar penyakit *Dryness* dapat dilihat pada Gambar 2.1



Gambar 2.1 *Dryness*. [15]

2. *Fungal Disease/Bercak Daun*

Penyakit akibat infeksi jamur yang biasanya memunculkan bercak-bercak pada daun dengan pola tertentu. Infeksi jamur dapat menyebar dengan

cepat apabila tidak ditangani sejak dini [16]. *Fungal Disease* dapat dilihat pada Gambar 2.2.



Gambar 2.2 *Fungal Disease* [15]

3. *Magnesium Deficiency*

Merupakan gangguan nutrisi yang menyebabkan perubahan warna daun menjadi kekuningan, terutama pada bagian tepi daun. Kekurangan magnesium mengganggu pembentukan klorofil sehingga menurunkan efektivitas fotosintesis [17]. Gambar 2.3 adalah gambar *Magnesium Deficiency*.



Gambar 2.3 *Magnesium Deficiency* [15]

4. *Scale Insect*

Disebabkan oleh hama kutu perisai yang menempel pada permukaan daun dan mengisap cairan tanaman. Serangan hama ini dapat menyebabkan daun menguning dan pertumbuhan tanaman terganggu [18]. Gambar *Scale Insect* dapat dilihat pada Gambar 2.4.



Gambar 2.4 *Scale Insect* [15]


2.3 *Deep Learning*

Deep learning merupakan bagian dari *machine learning* yang menggunakan *Deep Neural Networks* untuk menyelesaikan permasalahan pada *domain machine learning*. *Deep learning* menirukan cara berpikir manusia. *Deep learning* merupakan metode yang memanfaatkan *Artificial Neural Networks* yang berlapis lapis (*multi layer*). *Artificial Neural Networks* ini dibuat mirip dengan otak manusia, di mana neuron-neuron terkoneksi satu sama lain sehingga membentuk sebuah jaringan neuron yang sangat rumit. *Deep learning* atau *deep structured learning* atau *hierarchial learning* atau *deep neural* merupakan metode pembelajaran yang memanfaatkan *multiple non-linear transformation* [19].

2.4 *Convolutional Neural Network (CNN)*

Convolutional Neural Network merupakan salah satu arsitektur *Deep Learning* yang dirancang khusus untuk mengolah data berbentuk citra. CNN terinspirasi dari mekanisme kerja sistem penglihatan manusia, di mana neuron merespons rangsangan visual pada area tertentu. Dalam CNN, proses utama dilakukan melalui operasi konvolusi yang menggunakan filter atau kernel untuk mengekstraksi fitur dari citra input. Filter tersebut bergerak di seluruh bagian citra untuk mendeteksi pola-pola penting seperti tepi, tekstur, dan bentuk. Melalui proses pelatihan, CNN secara otomatis mempelajari filter yang paling relevan untuk membedakan antar kelas data, sehingga tidak memerlukan ekstraksi fitur manual seperti pada metode tradisional [20].

Secara umum, CNN terdiri dari beberapa lapisan utama, yaitu *convolutional layer*, *activation function*, *pooling layer*, dan *fully connected layer*. *Convolutional layer* berperan dalam mengekstraksi fitur, kemudian fungsi aktivasi seperti ReLU (*Rectified Linear Unit*) digunakan untuk memperkenalkan non-linearitas agar model mampu mempelajari pola kompleks. *Pooling layer* berfungsi mengurangi dimensi fitur sekaligus mempertahankan informasi penting, sehingga membantu mengurangi beban komputasi dan risiko *overfitting*. Pada bagian akhir, *fully connected layer* digunakan untuk proses klasifikasi berdasarkan fitur yang telah dipelajari. Kombinasi lapisan-lapisan ini membuat CNN sangat efektif dalam tugas klasifikasi citra, termasuk dalam identifikasi penyakit daun tanaman berdasarkan karakteristik visualnya [21]. Tahapan perlayer dapat dilihat pada Gambar 2.1.




Gambar 2.5 Standard CNN Arsitektur [21]

2.5 Arsitektur *ResNet-50 (Residual Neural Network)*

Residual Neural Network adalah arsitektur jaringan saraf yang memungkinkan pelatihan jaringan yang sangat dalam, biasanya terdiri dari puluhan atau ratusan lapisan. Hal ini berbeda dengan pendekatan tradisional yang melatih jaringan lebih dangkal dengan lapisan yang lebih sedikit. Manfaat dari jaringan yang lebih dalam telah diketahui secara luas, jaringan tersebut dapat mempelajari fitur pada tingkat abstraksi yang semakin tinggi, yang mengarah pada performa yang lebih baik di berbagai tugas. Namun, melatih jaringan yang sangat dalam di masa lalu sulit dilakukan karena masalah gradien yang menghilang (*vanishing gradient problem*), di mana gradien sinyal kesalahan cenderung menjadi sangat kecil saat dipropagasikan mundur melalui jaringan. Arsitektur ResNet dirancang untuk mengatasi masalah ini dengan menggunakan *skip connections* antar lapisan yang memungkinkan gradien mengalir lebih mudah melalui jaringan [22].

Dalam penelitian terdahulu, para peneliti menyarankan berbagai konfigurasi ResNet dengan jumlah lapisan yang bervariasi, seperti ResNet-18, ResNet-34,

ResNet-50, dan *ResNet-152*. Setiap lapisan dalam *ResNet* terdiri dari beberapa bingkai atau blok penyusun. Dalam implementasinya, blok identitas (*identity blocks*) dan blok konvensional (*convolutional blocks*) digabungkan untuk menghasilkan struktur *ResNet* yang telah ditingkatkan [23]. Untuk gambar *identity block* *ResNet* dapat dilihat pada Gambar 2.6



Gambar 2. 6 *Identity Block* *ResNet* [24]

ResNet-50 adalah variasi dari arsitektur *ResNet* yang memiliki 50 lapisan dalam. Arsitektur ini dirancang untuk mengatasi masalah *vanishing gradient* pada jaringan saraf yang sangat dalam dengan memperkenalkan konsep skip connections atau shortcut connections. Jaringan ini telah dilatih sebelumnya menggunakan lebih dari satu juta gambar dari basis data ImageNet [25].

1. Tahapan Arsitektur *ResNet-50*

Secara umum, *ResNet-50* terdiri dari urutan blok konvolusi yang diakhiri dengan *average pooling* dan lapisan *softmax* untuk klasifikasi.

Berdasarkan dokumen, tahapan utamanya adalah:

- a. Lapisan Input: Menerima gambar (biasanya berukuran 224 x 224 piksel).

- b. Tahap Konvolusi Awal (Conv1): Terdiri dari lapisan konvolusi dengan 64 filter berukuran 7 x 7 dan stride 2, diikuti oleh max pooling 3 x 3.
- c. Blok Residual (Conv2_x hingga Conv5_x):
 - a) Conv2_x: Terdiri dari 3 blok residual, masing-masing dengan filter 1 x 1, 64; 3 x 3, 64; dan 1 x 1, 256.
 - b) Conv3_x: Terdiri dari 4 blok residual.
 - c) Conv4_x: Terdiri dari 6 blok residual.
 - d) Conv5_x: Terdiri dari 3 blok residual.
- d. Lapisan Output: Menggunakan *Average Pooling* diikuti oleh lapisan *Fully Connected* (FC) dan fungsi aktivasi *Softmax* untuk menghasilkan probabilitas klasifikasi.

2. Persamaan pada *ResNet-50*

Prinsip utama ResNet didasarkan pada pemetaan residual. Jika x adalah input ke blok tersebut, maka alih-alih mencoba mempelajari pemetaan langsung $H(x)$, jaringan mempelajari fungsi residual $F(x)$.

- a. Pemetaan Residual :

$$H(x) = F(x) + x \quad (2.1)$$

Di mana $F(x)$ adalah pemetaan residual yang dipelajari oleh lapisan-lapisan di dalam blok, dan x ditambahkan melalui *shortcut connection*.

- b. Blok Konvolusi (Matriks Filter) :

$$\begin{array}{rcl} 1 & \times & 1.64 \\ 3 & \times & 3.64 \times 3 \\ 1 & \times & 1.256 \end{array} \quad (2.2)$$

Persamaan ini menunjukkan penggunaan filter berukuran 1×1 dan 3×3 dengan jumlah filter tertentu yang diulang sebanyak 3 kali dalam satu tahap [25].

2.6 *Transfer Learning*

Transfer learning merupakan suatu metode pembelajaran di mana sebuah model mempelajari suatu permasalahan tertentu yang kemudian berfungsi sebagai titik awal untuk tugas lainnya. Pendekatan ini dinilai tepat untuk menangani permasalahan di mana telah tersedia prosedur yang relevan dengan isu utama, serta ketika tugas terkait tersebut memerlukan data dalam jumlah yang besar. *Transfer learning* menerapkan teknik ekstraksi fitur dari model yang telah dilatih sebelumnya (*pre-trained model*), hal ini meminimalkan kebutuhan bagi pengembang untuk memulai pelatihan model dari awal. Model *transfer learning* biasanya dilatih menggunakan dataset berskala besar (misalnya, ImageNet), dan parameter terkait yang diperoleh dari model tersebut dapat diintegrasikan dengan jaringan saraf kustom (*custom neural network*) untuk berbagai aplikasi terkait lainnya [26]

2.7 *Confusion Matrix*

Tugas klasifikasi terdiri dari memprediksi kelas, seperti adanya penyakit atau tidak adanya penyakit. Untuk tugas klasifikasi biner, matriks kebingungan (*confusion matrix*) memfasilitasi penghitungan metrik performa diskriminasi yang umum. Diskriminasi menunjukkan kemampuan model untuk membedakan antara nilai positif dan negatif (misalnya, pasien dengan dan tanpa penyakit) [27].

Confusion matrix merepresentasikan kebenaran absolut (*ground truth*) sebagai baris dan prediksi klasifikasi sebagai kolom seperti pada Gambar 2.7.

Nilai-nilai ini digunakan untuk menurunkan metrik sensitivitas (*recall*), spesifisitas, nilai prediksi positif (*precision*), nilai prediksi negatif, dan akurasi. Penting untuk dicatat bahwa akurasi dapat menjadi metrik yang menyesatkan untuk dataset yang tidak seimbang (*imbalanced dataset*) pada dataset dengan hanya 1% kasus positif, model yang selalu memprediksi negatif akan tetap memiliki akurasi 99% [27]. Berikut beberapa rumus yang akan digunakan untuk melakukan evaluasi:

1. Accuracy : Rasio prediksi benar terhadap total data.

$$\frac{TP + TN}{(TP + TN + FP + FN)} \quad (2.3)$$

2. Precision : Tingkat keakuratan antara data yang diminta dengan hasil prediksi.

$$\frac{TP}{(TP + FP)} \quad (2.4)$$

3. Recall : Tingkat keberhasilan model dalam menemukan kembali informasi.

$$\frac{TP}{(TP + FN)} \quad (2.5)$$

4. F1-Score : Rata-rata harmonik dari *precision* dan *recall*, yang berguna untuk mengevaluasi model pada dataset yang tidak seimbang (*imbalanced*) [28].

$$2 \times \frac{Recall \times Precision}{Recall + Precision} \quad (2.6)$$

		Predicted		
		Positive	Negative	
Ground Truth	Positive	True Positive (TP)	False Negative (FN) [Type II Error]	Sensitivity (Recall) $\frac{TP}{(TP + FN)}$
	Negative	False Positive (FP) [Type I Error]	True Negative (TN)	Specificity $\frac{TN}{(TN + FP)}$
		Precision (PPV) $\frac{TP}{(TP + FP)}$	NPV $\frac{TN}{(TN + FN)}$	Accuracy $\frac{TP + TN}{(TP + TN + FP + FN)}$

Gambar 2.7 Confusion Matrix [27]

2.8 Black box Testing

Black box testing merupakan metode pengujian perangkat lunak yang fokus pada fungsionalitas sistem tanpa memperhatikan struktur internal atau kode program. Metode ini bertujuan untuk mengevaluasi apakah output sistem sesuai dengan spesifikasi berdasarkan input tertentu, dengan menguji fungsi secara eksternal dari sudut pandang pengguna. Salah satu keunggulan metode ini adalah tidak perlunya pemahaman mendalam terhadap struktur kode, sehingga pengujian dapat dilakukan secara objektif hanya berdasarkan antarmuka sistem yang tersedia. Salah satu teknik yang umum digunakan dalam black box testing adalah equivalence partitioning, yaitu teknik yang membagi domain input ke dalam beberapa kelas data yang saling eksklusif. [29]

2.9 *White Box Testing*


White box testing merupakan salah satu metode pengujian perangkat lunak yang memfokuskan pada pengujian struktur internal program. Tidak seperti black box yang hanya menguji dari sisi fungsi, metode ini mengevaluasi logika dan alur kontrol dalam kode program untuk memastikan setiap baris program dan cabang logika telah diuji. Pendekatan ini digunakan untuk mendeteksi kesalahan yang tidak terdeteksi oleh pengujian fungsional dan memberikan jaminan bahwa alur eksekusi sesuai dengan perancangan yang telah ditetapkan. [30]

BAB III

METODOLOGI PENELITIAN

3.1 Alur Penelitian

Penelitian ini menggunakan metode eksperimental dengan pendekatan kuantitatif untuk mengembangkan sistem klasifikasi penyakit daun kelapa sawit menggunakan Arsitektur *ResNet-50* dengan pendekatan *transfer learning*. Gambar 3.1 menunjukkan alur penelitian secara keseluruhan.



Gambar 3. 1 Alur Penelitian

Penelitian dimulai dengan identifikasi masalah terkait kebutuhan sistem untuk klasifikasi penyakit daun kelapa sawit. Data dikumpulkan dari dua sumber yaitu dataset publik Kaggle dan pengambilan langsung di Perkebunan Pangkalan Susu. Dataset dibagi menjadi *training set* (70%), *validation set* (15%), dan *testing set* (15%). Citra melalui tahap *preprocessing* berupa *resize* dan *normalisasi*, kemudian

data training mengalami augmentasi untuk meningkatkan variasi. Model CNN dengan arsitektur *ResNet-50* dilatih menggunakan *transfer learning*, diikuti dengan *fine-tuning* untuk optimasi. Model dievaluasi menggunakan *data testing* dengan metrik *accuracy*, *precision*, *recall*, dan *F1-score*.

3.2 Analisa Kebutuhan Fungsional

Kebutuhan fungsional merupakan kebutuhan yang menjelaskan semua entitas yang terlibat dalam sistem, serta fungsi atau proses yang dilakukan oleh masing-masing entitas. Sistem klasifikasi penyakit daun kelapa sawit yang dirancang hanya memiliki dua pengguna, yaitu User dan Admin. Berikut adalah kebutuhan fungsional pada sistem ini.

1. Admin

Admin adalah role yang bertugas untuk mengelola aplikasi sistem klasifikasi penyakit daun sawit. Fungsionalitas yang dapat dilakukan oleh admin meliputi:

- a. *Login* ke dalam sistem.
- b. Mengakses halaman beranda
- c. Mengakses halaman profil
- d. Manajemen User.
- e. Melihat total klasifikasi.
- f. Dapat melihat grafik tren klasifikasi pada sistem.
- g. Dapat melihat ringkasan klasifikasi berdasarkan penyakit.
- h. Melihat semua Riwayat klasifikasi dari semua user.
- i. Menghapus data yang tidak valid.

- j. Mengedit halaman ensiklopedia tanpa harus mengubah code.

2. User

User adalah role yang ada pada sistem klasifikasi penyakit daun kelapa sawit yang bisa menggunakan fungsi dari sistem yang dibuat yaitu klasifikasi penyakit daun sawit. Fungsionalitas yang dapat dilakukan user yaitu :

- a. Dapat masuk ke halaman beranda.
- b. Dapat masuk ke halaman klasifikasi.
- c. Dapat menginput foto daun sawit.
- d. Melakukan klasifikasi.
- e. Mendapatkan hasil.
- f. Melihat halaman profil.
- g. Melihat Riwayat scan milik pribadi.
- h. Melihat info penyakit.

3.3 Analisa Kebutuhan Non Fungsional

Kebutuhan nonfungsional merupakan sebuah kebutuhan yang terdiri dari perangkat lunak (*software*) dan perangkat keras (*hardware*). *Software* merupakan perangkat lunak yang mengacu pada serangkaian instruksi yang diberikan kepada komputer untuk menyelesaikan tugas tertentu. *Hardware* merupakan sebuah perangkat yang mengacu pada komponen fisik komputer yang dapat dilihat dan disentuh langsung oleh tangan. Kebutuhan nonfungsional ini penting untuk memastikan sistem dapat berjalan secara optimal sesuai rancangan. Selain itu, spesifikasi perangkat lunak dan perangkat keras yang sesuai juga mendukung

kelancaran proses pengolahan data serta melakukan *training* data yang akurat. Adapun kebutuhan nonfungsional dari sistem klasifikasi penyakit daun kelapa sawit menggunakan arsitektur *ResNet-50* pada Perkebunan pangkalan susu yang digunakan pada penelitian ini dan sistem klasifikasi ini adalah sebagai berikut:

1. Kebutuhan Perangkat Lunak/*Software*

Tabel 3.1 mencantumkan spesifikasi perangkat lunak yang digunakan dalam proses pengembangan sistem klasifikasi penyakit daun kelapa sawit. Perangkat lunak ini meliputi tools pemrograman, *framework* pendukung, serta sistem operasi yang digunakan dalam pembangunan dan pengujian website, baik pada sisi *backend* maupun *frontend*.

Tabel 3. 1 *Software* yang digunakan

No	Nama <i>Software</i>	Spesifikasi/Fungsi
1	Visual Studio Code 1.97.2	Sebagai Text Editor yang ringan dan kaya fitur untuk pengembangan kode sumber
2	Reactjs 18	Library JavaScript untuk membangun antarmuka pengguna (<i>frontend</i>) sistem yang interaktif.
3	TypeScript 5	Bahasa pemrograman berbasis JavaScript dengan fitur <i>static typing</i> untuk meminimalisir kesalahan kode.
4	HTML 5	Bahasa markup standar untuk menyusun struktur halaman web sistem klasifikasi.
6	Python 3.10.6	Bahasa pemrograman utama untuk mengimplementasikan algoritma CNN dan proses <i>deep learning</i> .
7	FastAPI	<i>framework</i> Python yang digunakan untuk membangun <i>backend</i> Rest API sistem.
8	Google Chrome	Version 135.0.7049.96, digunakan untuk mengakses halaman sistem
9	Vite 5	Framework Front End

10	React Router v6	Routing antar halaman (/, /scan, /auth, /dashboard, /history, /profile, /ensiklopedia
11	Tailwind CSS v3	<i>Utility-first styling</i> dengan design tokens HSL di index.css
13	PostgreSQL	Database utama
14	Supabase Auth	Autentikasi email/password + Google OAuth + reset password
15	Figma	Untuk membuat rancangan desain

2. Kebutuhan Perangkat Keras

Tabel 3.2 mencantumkan secara rinci spesifikasi perangkat keras (*Hardware*), mencakup seluruh komponen penting yang digunakan untuk membuat sistem klasifikasi penyakit daun kelapa sawit dan pengerjaan penulisan skripsi serta alat untuk pengambilan atau memotret gambar untuk dataset yang akan dibutuhkan dalam membangun aplikasi website sistem klasifikasi penyakit daun kelapa sawit.

Tabel 3. 2 Penggunaan *Sowtware*

No	Nama <i>Software</i>	Spesifikasi/Fungsi
1	<i>Processor</i>	Ryzen 7 5000 Series (8 Core) untuk menangani komputasi data dan <i>preprocessing</i> citra.
2	RAM	16 GB untuk mendukung proses pelatihan model <i>deep learning</i> agar berjalan stabil.
3	GPU	AMD Radeon Graphics untuk mendukung akselerasi grafis pada sistem.
4	<i>Storage</i>	512 GB SSD untuk penyimpanan dataset citra dan file proyek tugas akhir.
5	Kamera	Menggunakan beberapa kamera yaitu Iphone 13, Samsung A55, dan Realme 8i. untuk mengambil gambar daun sawit.


3.4 Rancangan Sistem

Perancangan sistem merupakan tahap awal dari perancangan perangkat lunak yang akan dibuat. Perancangan bertujuan untuk memberi gambaran mengenai alur proses dari perangkat lunak tersebut.

Perancangan sistem antara user dan aplikasi menggunakan *Unified Modeling Language* (UML). Pada perancangan UML ini terdapat dua perancangan yaitu *use case diagram* dan *activity diagram*. Perancangan ini dilakukan agar hubungan antara pengguna dan sistem dapat digambarkan secara jelas. Dengan adanya rancangan ini, pengembangan sistem dapat mengikuti alur yang terstruktur. Selain itu, rancangan yang baik akan meminimalisir terjadinya kesalahan pada tahap implementasi.

3.4.1 Ilustrasi Sistem

Ilustrasi sistem pada diagram di atas menggambarkan alur utama dari sebuah aplikasi berbasis web deteksi penyakit daun sawit yang dirancang untuk membantu petani atau pengguna umum website deteksi penyakit daun sawit dalam mendeteksi penyakit pada daun tanaman sawit, khususnya yang bervariasi sawit yang berada di Perkebunan Pangkalan Susu. Diagram ini disusun dalam bentuk konteks sistem (*context diagram*), yang menunjukkan hubungan antara aktor eksternal dengan sistem klasifikasi penyakit daun sawit, serta bagaimana data dan proses berpindah yang terjadi di dalam sistem klasifikasi penyakit daun sawit saat digunakan.



Gambar 3. 2 Ilustrasi Sistem

Gambar 3.2 menjelaskan bagaimana proses kerja pada sistem klasifikasi penyakit daun sawit. Pertama dimulai dari pengguna Website atau user melakukan input berupa citra daun sawit melalui tampilan web pada halaman klasifikasi. Inputan harus dalam bentuk JPG atau PNG dengan maks ukuran 10MB. Setelah gambar diinput, sistem akan memproses inputan tersebut dengan cara mengirimkan gambar ke model ResNet yang sudah dibuat dan dihubungkan dengan sistem website menggunakan FastAPI. Model yang sudah dihubungkan adalah model CNN dengan pendekatan *Transfer Learning* menggunakan arsitektur *ResNet-50*. Model ini yang akan melakukan klasifikasi pada gambar yang diinput oleh user untuk menentukan masuk ke kelas apa daun sesuai dengan dataset yang sudah dilatih sebelumnya.

Setelah model melakukan klasifikasi, hasil diagnosis akan dikirimkan Kembali ke aplikasi klasifikasi penyakit daun sawit pada halaman klasifikasi,

lengkap dengan saran penyembuhan sesuai dengan penyakit yang didiagnosis. Untuk hasil diagnosis yang dikirimkan ke pengguna akan disimpan kedalam database, yang akan berfungsi sebagai data history. Data ini bisa digunakan untuk menjadi dataset baru untuk pengembangan model kedepannya.

3.4.2 Use Case Diagram

Use case diagram menggambarkan interaksi antara aktor dengan sistem dari sudut pandang pengguna. Pada sistem ini terdapat dua aktor utama, yaitu User (pengguna biasa) dan Admin (administrator). Admin merupakan perluasan dari User sehingga memiliki seluruh hak akses User ditambah hak akses eksklusif untuk pengelolaan sistem.


1. Deskripsi Aktor

Sistem ini melibatkan dua aktor dengan peran dan hak akses yang berbeda, sebagaimana dijelaskan pada uraian berikut.

- a. User: Aktor utama yang merupakan petani atau petugas lapangan yang menggunakan sistem untuk klasifikasi penyakit daun kelapa sawit. User dapat melakukan pendaftaran akun, login, mengunggah foto daun untuk dianalisis, melihat hasil prediksi, mengakses riwayat klasifikasi pribadi, dan membaca informasi ensiklopedia penyakit.
- b. Admin: Aktor dengan hak akses penuh terhadap sistem. Admin mewarisi seluruh kemampuan User dan memiliki tambahan kemampuan untuk memantau statistik sistem, mengelola akun pengguna, memantau seluruh riwayat klasifikasi, serta memperbarui konten informasi penyakit pada ensiklopedia.

2. Use Case Diagram User

Use Case Diagram user ini menjelaskan apa saja yang bisa dilakukan oleh user pada website klasifikasi penyakit daun kelapa sawit. *Use Case Diagram* dapat dilihat pada Gambar 3.3.



Gambar 3. 3 Use Case Diagram User


Terdapat sebelas *use case* yang dapat dilakukan oleh aktor User. *Use case* tersebut dikelompokkan ke dalam tiga kategori fungsional, yaitu autentikasi, klasifikasi daun, dan informasi penyakit. Penjelasan lengkap setiap *use case* disajikan pada Tabel 3.3 berikut.

Tabel 3. 3 *Use Case Diagram* User

No	Use Case	Relasi	Deskripsi
1	Daftar Akun / <i>register</i>	-	Pengguna membuat akun baru dengan mengisi form username nama lengkap, email, dan password.
2	<i>Login</i>	-	Pengguna masuk ke sistem menggunakan email dan password yang telah terdaftar.
3	<i>Logout</i>	-	Pengguna mengakhiri sesi aktif. Sistem menghapus JWT token dari browser.
4	Upload Foto Daun	include: Preprocessing Citra	Pengguna mengunggah foto daun kelapa sawit dari galeri atau kamera. Sistem memvalidasi format file (JPG/PNG) dan ukuran maksimal (10MB).
5	Preprocessing Citra	include: Inferensi <i>ResNet-50</i>	Sistem secara otomatis melakukan praproses gambar meliputi konversi format ke RGB, resize ke 224x224 piksel, dan normalisasi nilai piksel sebelum dimasukkan ke model.
6	Inferensi <i>ResNet-50</i>	include: Simpan ke Riwayat	Model <i>ResNet-50</i> memproses gambar yang telah diproses dan menghasilkan probabilitas untuk lima kelas kondisi daun kelapa sawit.
7	Lihat Hasil Prediksi	extend: Lihat Riwayat Klasifikasi	Sistem menampilkan kelas penyakit yang terdeteksi.
8	Simpan ke Riwayat	-	Hasil klasifikasi disimpan otomatis ke tabel scan_history di Supabase.
9	Lihat Riwayat Klasifikasi	-	Pengguna dapat mengakses daftar seluruh riwayat klasifikasi pribadi.
10	Lihat Ensiklopedia	-	Pengguna mengakses halaman ensiklopedia
11	Lihat Detail Penyakit	-	Pengguna dapat melihat informasi lengkap satu kondisi penyakit.

3. Use Case Admin

Use Case Diagram admin ini menjelaskan apa saja yang bisa dilakukan oleh admin pada website klasifikasi penyakit daun kelapa sawit. *Use Case Diagram* dapat dilihat pada Gambar 3.4.



Gambar 3. 4 *Use Case Diagram* Admin

Selain mewarisi seluruh *use case* User, aktor Admin memiliki tujuh *use case* tambahan yang bersifat eksklusif untuk pengelolaan dan pemantauan sistem. Deskripsi setiap *use case* admin disajikan pada Tabel 3.4 berikut.

Tabel 3. 4 Use Case Admin

No	Use Case	Relasi	Deskripsi
1	Login sebagai Admin	-	Setelah autentikasi berhasil, sistem mengarahkan ke halaman dashboard admin di route /admin.
2	Lihat Statistik Klasifikasi	include: Grafik Distribusi, include: Tren Harian	memantau statistik penggunaan sistem secara keseluruhan, termasuk total klasifikasi, distribusi penyakit yang terdeteksi dalam bentuk pie chart, dan tren penggunaan harian dalam bentuk line chart.


3	Lihat Daftar Pengguna	-	Admin dapat melihat tabel seluruh pengguna terdaftar.
4	Nonaktifkan Akun	-	Admin dapat menonaktifkan akun pengguna. Pengguna yang dinonaktifkan tidak dapat login hingga akunnya diaktifkan kembali.
5	Lihat Semua Riwayat Klasifikasi	-	Admin dapat mengakses dan memantau seluruh riwayat klasifikasi dari semua pengguna.
6	Hapus Data Klasifikasi	-	Admin dapat menghapus record riwayat klasifikasi yang dianggap tidak valid.
7	Edit Info Penyakit	-	Admin dapat memperbarui konten informasi penyakit pada tabel diseases

3.4.3 Activity Diagram

Activity diagram menggambarkan alur aktivitas dan logika proses dalam sistem secara sekuensial. Diagram ini menjelaskan urutan langkah-langkah yang terjadi dari sudut pandang sistem ketika aktor melakukan suatu aksi tertentu. Pada penelitian ini terdapat dua *activity diagram* utama yang mewakili proses inti sistem.

1. Proses Klasifikasi Daun

Gambar 3.5 menggambarkan alur kerja paling utama dalam sistem ini, yaitu proses dari pengguna mengunggah foto daun hingga hasil prediksi ditampilkan dan tersimpan ke riwayat. Diagram ini menggunakan *swimlane* empat kolom yang merepresentasikan partisipan Aktor, *Frontend*, *FaskAPI*, dan *Database/Storage*.



Gambar 3. 5 Activity Diagram Klasifikasi Daun


Alur aktivitas klasifikasi daun berlangsung sebagai berikut.

- Pengguna memilih foto daun kelapa sawit dari galeri perangkat atau mengambil foto langsung menggunakan kamera.
- Frontend* melakukan validasi terhadap file yang dipilih. Validasi mencakup pemeriksaan format file (JPG/PNG) serta ukuran file (maks 10MB). Apabila validasi gagal, sistem menampilkan pesan kesalahan dan pengguna diminta memilih file ulang.

- c. Jika file valid, *frontend* menampilkan *preview* gambar kepada pengguna. Pengguna kemudian mengklik tombol 'Analisa' untuk memulai proses prediksi.
- d. *Frontend* menampilkan indikator loading dan mengirimkan gambar ke FastAPI melalui permintaan HTTP POST ke *endpoint /predict*.
- e. FastAPI menerima gambar dan melakukan *preprocessing*, meliputi konversi ke format RGB, *resize* ke dimensi 224x224 piksel, dan normalisasi menggunakan statistik dataset *ImageNet*.
- f. Gambar yang telah diproses dimasukkan ke dalam model *ResNet-50* untuk dilakukan inferensi. Model menghasilkan vektor probabilitas untuk lima kelas kondisi daun.
- g. Apabila proses inferensi berhasil, FastAPI mengembalikan hasil dalam format JSON berisi kelas prediksi, *confidence score*, dan distribusi probabilitas seluruh kelas. Apabila terjadi kegagalan, API mengembalikan kode *error 500* dan *frontend* menampilkan pesan kesalahan.
- h. *Frontend* meneruskan hasil prediksi ke *Supabase Storage* untuk menyimpan file gambar, kemudian menyimpan *record* lengkap ke tabel *scan_history* di database.
- i. Sistem menampilkan hasil prediksi kepada pengguna, mencakup nama kelas penyakit yang terdeteksi, tingkat *confidence*, *diagram probabilitas* semua kelas, dan rekomendasi penanganan sesuai penyakit yang terdeteksi.

2. Proses Login dan Register

Gambar 3.6 menggambarkan alur autentikasi pengguna dengan menggunakan swimlane tiga kolom yang merepresentasikan partisipan Aktor, *Frontend*, dan *Supabase Auth*.



Gambar 3. 6 Activity Login dan Register

Alur aktivitas *register* berlangsung sebagai berikut.

- a. Pengguna membuka halaman login dan memilih opsi untuk membuat akun baru.
- b. Pengguna mengisi formulir registrasi berupa nama lengkap, alamat email, dan password.
- c. Frontend memvalidasi kelengkapan dan format data yang dimasukkan. Apabila terdapat kesalahan, sistem menampilkan pesan *error* dan pengguna diminta memperbaiki *input*.
- d. Apabila data valid, frontend memanggil fungsi *supabase.auth.signUp()* dengan kredensial yang dimasukkan.
- e. *Supabase Auth* membuat akun baru dan secara otomatis menyimpan data pengguna ke tabel *users* dengan role 'user' dan status *is_active* bernilai *true*.
- f. Sistem menampilkan pesan sukses dan mengarahkan pengguna ke halaman login.

Alur aktivitas login berlangsung sebagai berikut.

- a. Pengguna mengisi email dan password pada formulir login.
- b. Frontend memanggil fungsi *signInWithPassword()* yang mengirimkan kredensial ke *Supabase Auth* untuk divalidasi.
- c. *Supabase Auth* memverifikasi email dan password terhadap data yang tersimpan dalam tabel *users*.
- d. Apabila kredensial tidak valid, sistem menampilkan pesan kesalahan dan pengguna diminta memasukkan ulang data login.

- e. Apabila login berhasil, sistem menyimpan JWT token pada *session browser* dan membaca nilai kolom *role* dari data pengguna.
- f. Apabila *role* pengguna adalah 'admin', sistem mengarahkan ke halaman *dashboard* admin pada *route* admin. Apabila *role* adalah 'user', sistem mengarahkan ke halaman beranda pada *route*.

3.4.4 Perancangan Database

Perancangan basis data pada sistem ini menggunakan model relasional dengan PostgreSQL sebagai sistem manajemen basis data. Basis data dirancang untuk menyimpan seluruh data yang dibutuhkan oleh sistem, mencakup data pengguna, riwayat hasil klasifikasi, dan informasi konten penyakit.

1. Tabel Users

Tabel users menyimpan data akun seluruh pengguna yang terdaftar dalam sistem, baik pengguna biasa maupun administrator. Tabel ini terintegrasi dengan layanan Supabase Auth sehingga proses autentikasi dikelola secara otomatis. Struktur tabel users ditunjukkan pada Tabel 3.5.

Tabel 3. 5 Tabel Users

Kolom	Tipe Data	Keterangan
id	uuid	Identifikasi unik pengguna, dibuat otomatis oleh Supabase Auth
email	varchar	Alamat email pengguna, digunakan sebagai kredensial login
full_name	varchar	Nama lengkap pengguna
role	varchar	Peran pengguna dalam sistem: 'user' untuk pengguna biasa, 'admin' untuk administrator
is_active	boolean	Status aktif akun.
created_at	timestamp	Waktu pembuatan akun, diisi otomatis oleh sistem
Updated_at	timestamp	Waktu Ketika ada perubahan, diisi otomatis oleh sistem

2. Tabel History

Tabel scan_history merupakan tabel pusat yang mencatat setiap aktivitas scan yang dilakukan oleh pengguna. Tabel ini memiliki relasi dengan tabel users melalui foreign key user_id dan dengan tabel diseases melalui foreign key disease_id. Kolom all_probabilities bertipe JSON dipilih untuk menyimpan distribusi probabilitas seluruh kelas sekaligus dalam satu kolom, sehingga menghindari kebutuhan tabel tambahan. Struktur tabel scan_history ditunjukkan pada Tabel 3.6.

Tabel 3. 6 Tabel History

Kolom	Tipe Data	Keterangan
id	uuid	Identifikasi unik untuk setiap record riwayat klasifikasi
user_id	uuid	Referensi ke kolom id pada tabel users. Menunjukkan pengguna yang melakukan klasifikasi
disease_key	uuid	Referensi ke kolom id pada tabel diseases. Menunjukkan kelas penyakit yang terdeteksi
confidence	float	Nilai keyakinan (confidence) prediksi dalam rentang 0 hingga 1
all_probabilities	json	Objek JSON berisi distribusi probabilitas untuk kelima kelas kondisi daun
image_url	text	URL gambar daun yang diunggah, disimpan di Supabase Storage
scanned_at	timestamp	Waktu pelaksanaan klasifikasi, diisi otomatis oleh sistem

3. Tabel Diseases

Tabel diseases menyimpan informasi konten ensiklopedia untuk setiap kelas penyakit yang dapat diidentifikasi oleh sistem. Tabel ini memungkinkan admin untuk memperbarui info penyakit tanpa harus mengubah kode. Struktur tabel diseases ditunjukkan pada Tabel 3.7.

Tabel 3. 7 Tabel Diseases

Kolom	Tipe Data	Keterangan
id	uuid	Identifikasi unik untuk setiap kelas penyakit
Name_id	varchar	Nama lengkap kondisi daun, contoh: Magnesium Deficiency
severity	varchar	Tingkat keparahan: none (sehat), low (ringan), medium (sedang), high (berat)
description	text	Deskripsi umum kondisi daun
treatment	text	Langkah-langkah penanganan dan pengobatan
prevention	text	Cara-cara pencegahan agar kondisi tidak terjadi
Image_url	Text	Alamat gambar penyakit
Created_at	timestamp	Waktu terakhir dibuat.
updated_at	timestamp	Waktu terakhir konten diperbarui oleh administrator

4. Relasi Antar Tabel

Terdapat dua relasi antar tabel dalam basis data sistem ini yang membentuk integritas referensial sebagai berikut.

- Relasi antara tabel `users` dan `scan_history` bersifat *one-to-many*, artinya satu pengguna dapat memiliki banyak riwayat klasifikasi, namun setiap riwayat klasifikasi hanya dimiliki oleh satu pengguna. Relasi ini diimplementasikan melalui *foreign key* `user_id` pada tabel `scan_history` yang mereferensi kolom `id` pada tabel `users`.
- Relasi antara tabel `diseases` dan `scan_history` bersifat *one-to-many*, artinya satu jenis penyakit dapat muncul pada banyak riwayat klasifikasi yang berbeda, namun setiap riwayat klasifikasi hanya memiliki satu kelas penyakit yang terdeteksi. Relasi ini diimplementasikan melalui *foreign key* `disease_id` pada tabel `scan_history`.

3.4.5 Rancangan Antarmuka Pengguna (*User Interface*)

Perancangan antarmuka pengguna dilakukan untuk memberikan gambaran tampilan sistem yang akan digunakan oleh pengguna. Desain UI dirancang sederhana, mudah dipahami, serta fokus pada fungsi utama sistem yaitu input gambar daun dan klasifikasi penyakit daun menggunakan algoritma CNN dengan pendekatan *Transfer Learning* menggunakan arsitektur *ResNet-50*. Adapun user interface sebagai berikut:

1. Rancangan Halaman Login

Halaman login berfungsi selayaknya halaman login pada umumnya, yaitu halaman untuk para user masuk ke akun mereka untuk dapat mengakses data para user sendiri dan fitur fitur tambahan yang bisa diakses saat login.

Rancangan halaman login dapat dilihat pada Gambar 3.7

Gambar 3. 7 Rancangan Halaman Login

2. Rancangan Halaman Register

Halaman register ini berfungsi untuk para user mendaftarkan akun mereka jika belum memiliki akun untuk login, nanti sistem akan mengirimkan

verifikasi melalui email user yang melakukan registrasi. Tampilan halaman registrasi dapat dilihat pada Gambar 3.8

Gambar 3. 8 Rancangan Halaman Registrasi

3. Rancangan Halaman Profil

Halaman profil memiliki fungsi untuk menampilkan detail mengenai data dari masing masing akun milik pengguna, mulai dari total klasifikasi dan kapan terakhir kali melakukan klasifikasi. Rancangan halaman profil dapat dilihat pada Gambar 3.9


Gambar 3. 9 Rancangan Halaman Profile

4. Rancangan Halaman Riwayat

Halaman Riwayat memiliki fungsi untuk menampilkan detail dari klasifikasi yang dilakukan oleh user dari awal hingga yang terbaru.

Pengguna hanya bisa melihat Riwayat dari pengguna itu sendiri.


Rancangan halaman Riwayat dapat dilihat pada Gambar 3.10.



Gambar 3. 10 Rancangan Halaman Riwayat

5. Rancangan Halaman Dashboard Admin

Halaman dashboard merupakan halaman yang hanya bisa diakses oleh pengguna dengan role admin, dan halaman ini memiliki fungsi selayaknya halaman dashboard pada umumnya. Rancangan halaman dashboard dapat dilihat pada Gambar 3.11.




Gambar 3. 11 Rancangan Halaman Admin

6. Rancangan Halaman Beranda

Halaman beranda atau bisa dibilang halaman utama dari website ini tidak memiliki fungsi spesifik, halaman ini hanya memberikan informasi


mengenai apa saja yang ada pada website ini. Rancangan halaman dapat dilihat pada Gambar 3.12.



Gambar 3. 12 Rancangan Halaman Beranda

7. Perancangan Halaman Klasifikasi


Halaman klasifikasi merupakan halaman dengan fungsi utama dari website ini yaitu halaman untuk melakukan input dan menerima hasil dari klasifikasi penyakit daun sawit yang ingin dideteksi oleh user. Rancangan dapat dilihat pada Gambar 3.13



Gambar 3. 13 Rancangan Halaman Klasifikasi

8. Perancangan Halaman Ensiklopedia

Halaman Ensiklopedia merupakan halaman yang berisikan informasi mengenai penyakit dan cara menangani penyakit tersebut. Rancangan dapat dilihat pada Gambar 3.14



Gambar 3. 14 Rancangan Halaman Ensiklopedia

3.5 Pengumpulan Data

Citra yang dikumpulkan mencakup lima kategori utama penyakit daun kelapa sawit, yaitu daun sehat, daun kering, daun menguning, kutu putih dan bercak daun seperti yang dapat dilihat pada Tabel 3.8. Setiap citra gambar dirancang untuk merepresentasikan variasi kondisi penyakit yang dapat dilihat dari daun sawit. Dataset penelitian terdiri dari kombinasi dua sumber utama, yaitu dataset publik yang diperoleh dari platform Kaggle sebagai data *sekunder* dan dataset citra daun kelapa sawit yang dikumpulkan secara langsung dari perkebunan di wilayah Pangkalan Susu, Sumatera Utara sebagai data *primer*.

Tabel 3. 8 Jumlah Dataset

No	Jenis Daun	Jumlah Data
1	Daun Sehat/ <i>Healthy</i>	500
2	Daun Kering/ <i>Dryness</i>	500
3	Bercak Daun/ <i>Fungal Diseases</i>	500
4	Daun Menguning/ <i>Magnesium Deficiency</i>	500
5	Kutu Perisai/ <i>Scale Insect</i>	500
Total Data		2500

Selanjutnya peneliti membagi menjadi tiga data yaitu data *training*, data *validation* dan data *testing*. Setiap kelas dalam dataset diupayakan memiliki distribusi yang seimbang (*balanced*) untuk menghindari *bias* dalam proses pelatihan model. Apabila terdapat ketidakseimbangan kelas (*class imbalance*), teknik *oversampling* atau *class weighting* akan diterapkan untuk mengatasi permasalahan tersebut. Pembagian dataset dilakukan secara acak dengan metode *stratified splitting* untuk memastikan distribusi kelas yang proporsional pada setiap subset. Total dataset dibagi ke dalam tiga subset dengan proporsi yang dapat dilihat pada Tabel 3.9.

Tabel 3. 9 Data Splitting

Subset	Proporsi	Fungsi
<i>Training Set</i>	70%	Pelatihan model
<i>Validation Set</i>	15%	Validasi dan tuning
<i>Testing Set</i>	15%	Evaluasi akhir model

Dari keseluruhan total data 2500 gambar daun sawit yang berformat .JPG yang telah dikumpulkan selanjutnya data gambar tersebut akan dibagi menjadi 70% untuk data *training*, 15% untuk data *validation* dan 15% untuk data *testing*. Data *training* digunakan dalam proses *learning* untuk klasifikasi penyakit daun kelapa sawit sedangkan data *testing* digunakan untuk menguji algoritma yang telah dilatih


dan divalidasi sebelumnya. Untuk melihat jumlah secara keseluruhan lebih detailnya distribusi data *training*, *validation* dan *testing* untuk membangun model *ResNet-50* berdasarkan penyakit daun kelapa sawit dapat dilihat pada Tabel 3.10.

Tabel 3. 10 Distribusi Data *Training*

No	Jenis Daun	<i>Traning</i>	<i>Validation</i>	<i>Testing</i>
1	Daun Sehat/ <i>Healthy</i>	350	75	75
2	Daun Kering/ <i>Dryness</i>	350	75	75
3	Bercak Daun/ <i>Fungal Diseases</i>	350	75	75
4	Menguning/ <i>MagnesiumDeficiency</i>	350	75	75
5	Kutu Perisai/ <i>Scale Insect</i>	350	75	75
Total Data		1750	375	375


Pengumpulan data dari lapangan dilakukan menggunakan kamera digital dengan format HEIC dan JPG. Pengambilan citra dilakukan pada berbagai kondisi pencahayaan alami (pagi, siang, dan sore) dan sudut pengambilan yang bervariasi untuk meningkatkan keragaman dataset. Sampel dataset daun sehat dan 4 penyakit daun kelapa sawit dapat dilihat pada Tabel 3.11.

Tabel 3. 11 Contoh Citra Daun Sawit

No	Image	Class
1		Healthy/Sehat
2		Dryness/Kering
3		Fungal Disease/ Bercak Bercak
4		<i>Magnesium Deficiency</i> / Menguning
5		<i>Scale Insect</i> / Kutu Putih

3.6 Preprocessing (Pra-pemrosesan)


Pra-pemrosesan merupakan tahapan transformasi awal terhadap citra mentah untuk menghasilkan format data yang sesuai dengan spesifikasi input arsitektur *ResNet-50*. Alur *preprocessing* dapat dilihat pada Gambar 3.15.



Gambar 3. 15 Flowchart Preprocessing

3.6.1 Pengecekan dan Konversi Format Citra

Tahap pertama adalah pengecekan format citra input. Sistem akan memeriksa apakah citra memiliki format kanal warna yang sesuai (RGB). Jika citra masih dalam format RGBA atau *grayscale*, maka dilakukan konversi otomatis ke format RGB standar dengan tiga channel warna (*Red, Green, Blue*). Contoh gambar dapat dilihat pada Gambar 3.16.



Gambar 3. 16 *Grayscale Convert to RGB*

3.6.2 *Resizing* (Pengubahan Ukuran)

Seluruh citra dalam dataset di-*resize* ke dimensi standar 224×224 piksel, yang merupakan ukuran input default untuk arsitektur *ResNet-50*. Proses *resizing* dilakukan menggunakan teknik *interpolasi bilinear* untuk mempertahankan kualitas visual citra dan menghindari *distorsi* yang berlebihan. Pengubahan ukuran ini diperlukan karena citra yang dikumpulkan dari berbagai sumber memiliki resolusi dan rasio aspek yang bervariasi. Contoh hasil dari melakukan *resize* dapat dilihat pada Gambar 3.17.



Gambar 3. 17 *Resize Gambar*

Citra asli berukuran 265×176 diubah menjadi $224 \times 224 \times 3$ menggunakan *interpolasi bilinear*, yaitu perhitungan nilai piksel baru berdasarkan kombinasi berbobot dari empat piksel tetangga terdekat. Metode ini menghasilkan perubahan skala yang halus dan menjaga stabilitas visual sebelum diproses oleh *ResNet-50*.

3.6.3 Normalisasi Piksel dan *Standard ImageNet*

Nilai intensitas piksel pada citra yang awalnya berada dalam rentang $[0, 255]$ dinormalisasi ke dalam rentang $[0, 1]$ dengan membagi setiap nilai piksel dengan 255. Normalisasi bertujuan untuk menstabilkan proses pelatihan dan mempercepat konvergensi dengan mengurangi skala nilai input. Selain itu, normalisasi juga dilakukan mengikuti statistik dataset *ImageNet* dengan mengurangi nilai mean dan membagi dengan standar deviasi dari setiap kanal warna (RGB) sesuai dengan konfigurasi pre-trained *ResNet-50* yaitu Mean: $[0.485, 0.456, 0.406]$ dan Standard Deviation: $[0.229, 0.224, 0.225]$. Contoh perubahan nilai intensitas satu piksel setelah proses normalisasi dapat dilihat pada Tabel 3.12.


Tabel 3. 12 Tabel Normalisasi

No	Tahap	R	G	B
1	Nilai awal (0–255)	180	140	90
2	Setelah $\div 255$	0.706	0.549	0.353
3	Setelah normalisasi ImageNet	0.97	0.41	-0.24

3.6.4 *Image Augmentation* (Augmentasi Citra)

Data augmentation diterapkan pada data latih dengan melakukan rotasi, translasi, pencerminan horizontal, zoom, penyesuaian kecerahan, dan penyesuaian kontras secara acak. Setiap teknik augmentasi diterapkan secara independen untuk meningkatkan keragaman data dan mengurangi risiko *overfitting*. Tahapan dan hasil

augmentasi yang diterapkan dalam penelitian ini dapat dilihat pada Gambar 3.18 dan Gambar 3.19. Augmentasi data hanya diterapkan pada data latih (*training set*), sedangkan data validasi dan data uji tidak mengalami augmentasi untuk memastikan evaluasi yang objektif terhadap model pada kondisi citra yang realistis.



Gambar 3. 18 *Flowchart* Augmentasi



Gambar 3. 19 Hasil Augmentasi


Gambar 3.18 memperlihatkan tahapan gambar daun sawit yang sedang akan melewati beberapa tahap dalam augmentasi yaitu:

1. Rotasi (*Rotation*) pada citra dilakukan secara acak dalam rentang ± 20 derajat untuk mensimulasikan variasi sudut pengambilan gambar di lapangan.
2. Translasi (*Translation*) dilakukan dengan pergeseran horizontal dan vertikal secara acak hingga 10% dari dimensi citra untuk mengakomodasi variasi posisi objek dalam frame.
3. *Flipping* (Pencerminan) dilakukan dengan pencerminan horizontal (*horizontal flip*) diterapkan dengan probabilitas 50% untuk meningkatkan variasi orientasi daun.
4. *Zoom* (Perbesaran) dilakukan dengan perbesaran atau pengecilan citra secara acak dalam rentang 80%-120% dari ukuran asli untuk mensimulasikan variasi jarak pengambilan gambar.
5. *Brightness Adjustment* (Penyesuaian Kecerahan) dilakukan dengan memodifikasi tingkat kecerahan citra dalam rentang $\pm 20\%$ untuk mengakomodasi variasi kondisi pencahayaan alami.

6. *Contrast Adjustment* (Penyesuaian Kontras) dilakukan dengan menyesuaikan kontras citra secara acak untuk meningkatkan ketahanan model terhadap variasi kualitas citra.

3.7 Model Development

Bagian *Model Development* merupakan tahapan inti dari penelitian ini di mana model *Convolutional Neural Network* (CNN) dengan arsitektur *ResNet-50* dikembangkan menggunakan pendekatan *transfer learning*. Tahapan ini terdiri dari tiga sub-proses utama yang saling berkaitan seperti yang terlihat pada Gambar 3.20.



Gambar 3. 20 *Workflow Tranfer Learning*

3.7.1 ResNet-50

Tahap pertama adalah implementasi *transfer learning* menggunakan arsitektur *ResNet-50* yang telah di-*pretrain* pada dataset ImageNet. *ResNet-50* dipilih karena memiliki keunggulan dalam mengatasi masalah vanishing gradient melalui mekanisme *residual connection* (*skip connection*), sehingga memungkinkan pelatihan jaringan yang lebih dalam dengan performa yang tetap

optimal. Tahapan *Transfer Learning* terdiri dari beberapa komponen utama yang bekerja secara hierarkis untuk mengekstraksi fitur dari citra input. Tahapan yang dilakukan adalah:

1. Memuat Model *Pre-trained*

Model *ResNet-50* yang telah dilatih pada dataset ImageNet dimuat beserta seluruh bobot (*weights*) yang telah dipelajari. Dataset ImageNet terdiri dari jutaan citra dengan ribuan kategori, sehingga model telah memiliki kemampuan dasar dalam mengenali berbagai pola visual seperti tepi (*edges*), tekstur, bentuk, dan fitur kompleks lainnya.

2. *Freeze Convolutional Layers*

Seluruh lapisan konvolusi dari Stage 1 hingga Stage 4 pada *ResNet-50* dibekukan (*freeze*), artinya bobot pada lapisan-lapisan tersebut tidak akan diperbarui selama proses pelatihan awal. Langkah ini dilakukan karena fitur-fitur dasar yang telah dipelajari dari ImageNet (seperti deteksi tepi, tekstur, dan pola warna) bersifat general dan dapat digunakan untuk berbagai domain citra, termasuk citra daun kelapa sawit.

3. Modifikasi Lapisan *Classifier*

Lapisan *fully connected* (FC layer) pada bagian akhir model yang awalnya dirancang untuk mengklasifikasikan 1000 kelas ImageNet diganti dengan arsitektur classifier baru yang disesuaikan untuk 5 kelas penyakit daun kelapa sawit. Arsitektur classifier baru terdiri dari:

- a. *Global Average Pooling*: mengubah feature maps menjadi vektor 1D
- b. *Dense Layer 256 neuron* dengan aktivasi ReLU: untuk transformasi fitur

- c. *Dropout layer* dengan rate 0.5: untuk regularisasi dan mencegah *overfitting*
- d. *Output layer 5 neuron* dengan aktivasi Softmax: menghasilkan probabilitas untuk 5 kelas penyakit (*Healthy, Dryness, Fungal Disease, Magnesium Deficiency, Scale Insect*)

3.7.2 Model Training

Setelah arsitektur model siap, dilakukan proses pelatihan untuk mengoptimalkan bobot pada lapisan classifier yang baru ditambahkan. Proses training dilakukan dengan konfigurasi seperti *Optimizer, loss function, batch size* dan *epochs*, monitoring dan *callback*.

1. *Optimizer*

Menggunakan Adam (Adaptive Moment Estimation) optimizer dengan learning rate awal 0.001. Adam dipilih karena kemampuannya dalam menyesuaikan learning rate secara adaptif untuk setiap parameter, menggabungkan keunggulan momentum dan RMSprop, sehingga mempercepat konvergensi dan menghasilkan performa yang stabil

2. *Loss Function*

Categorical Cross-Entropy digunakan sebagai fungsi loss yang sesuai untuk masalah klasifikasi multi kelas dengan output berupa distribusi probabilitas dari fungsi Softmax. Loss function ini mengukur perbedaan antara distribusi probabilitas prediksi model dengan distribusi sebenarnya (one-hot encoded label).

3. *Batch Size* dan *Epochs*

Data training diproses dalam batch berukuran 32 sampel per iterasi. Pelatihan dilakukan secara iteratif dalam epoch (satu epoch = satu kali model melihat seluruh data training), dengan jumlah maksimum epoch yang ditentukan. Pada setiap epoch, model menghitung loss, melakukan backpropagation untuk menghitung gradien, dan memperbarui bobot menggunakan optimizer.

4. Monitoring dan *Callbacks*

Selama training, beberapa callback diimplementasikan:

- a. *ModelCheckpoint*: menyimpan model dengan validation accuracy terbaik
- b. *EarlyStopping*: menghentikan training jika tidak ada peningkatan performa dalam 15 epoch berturut-turut.
- c. *ReduceLROnPlateau*: mengurangi learning rate jika validation loss mengalami plateau

3.7.3 *Fine Tunning*

Fine tuning merupakan tahap optimasi lanjutan yang dilakukan setelah proses pelatihan awal untuk meningkatkan performa model agar lebih sesuai dengan karakteristik dataset penyakit daun kelapa sawit. Pada tahap ini, beberapa lapisan konvolusi terakhir pada arsitektur *ResNet-50* dibuka kembali (*unfreeze*) sehingga bobotnya dapat diperbarui selama proses pelatihan. Proses *fine tuning* dilakukan dengan menggunakan nilai *learning rate* yang lebih kecil dibandingkan pelatihan awal, yaitu sebesar 0.0001, guna menjaga stabilitas pembaruan bobot dan mempertahankan pengetahuan dasar yang telah dipelajari dari dataset ImageNet. Selanjutnya, model dilatih kembali menggunakan konfigurasi *fine tuning* yang telah

ditetapkan hingga diperoleh performa yang optimal. Hasil dari tahap pengembangan model ini adalah model *ResNet-50* yang telah teroptimasi dan mampu mengklasifikasikan empat jenis penyakit daun kelapa sawit secara efektif.

3.8 Tahap Evaluasi

Bagian evaluasi merupakan tahapan akhir yang bertujuan untuk mengukur performa model yang telah dikembangkan menggunakan data pengujian yang tidak digunakan selama proses pelatihan dan validasi. Evaluasi dilakukan untuk menilai kemampuan generalisasi model terhadap data baru secara objektif. Tahapan evaluasi terdiri atas tiga sub-proses utama.

3.8.1 *Testing* (Pengujian)

Tahap *testing* dilakukan untuk menguji kemampuan model dalam memprediksi kelas penyakit menggunakan data uji yang tidak digunakan selama proses pelatihan. Model dengan performa terbaik berdasarkan nilai akurasi validasi tertinggi dimuat kembali dan digunakan pada tahap pengujian. Data uji diproses melalui tahapan *preprocessing* yang sama dengan data pelatihan, meliputi perubahan ukuran citra menjadi 224×224 piksel dan normalisasi menggunakan nilai *mean* dan *standard deviation* ImageNet. Pada tahap ini tidak diterapkan *data augmentation* agar evaluasi mencerminkan kondisi citra yang sebenarnya. Model kemudian menghasilkan prediksi kelas untuk setiap citra data uji melalui proses *forward propagation*. Hasil keluaran berupa probabilitas untuk setiap kelas, dan kelas dengan probabilitas tertinggi ditetapkan sebagai hasil prediksi. Seluruh hasil prediksi dibandingkan dengan label aktual dan digunakan sebagai dasar perhitungan metrik evaluasi performa model.

3.8.2 Evaluasi dengan *Confusion Matrix*

Tahap evaluasi dilakukan dengan menghitung beberapa metrik evaluasi standar untuk mengukur performa model secara kuantitatif. Metrik yang digunakan meliputi *confusion matrix*, *accuracy*, *precision*, *recall*, dan *F1 score*. *Confusion matrix* digunakan untuk membandingkan hasil prediksi model dengan label aktual pada setiap kelas penyakit, sehingga memberikan gambaran distribusi prediksi yang benar maupun kesalahan klasifikasi. Berdasarkan *confusion matrix*, diperoleh nilai *true positive*, *false positive*, *false negative*, dan *true negative* yang menjadi dasar perhitungan metrik evaluasi lainnya.

Accuracy digunakan untuk mengukur proporsi prediksi yang benar terhadap seluruh data uji menggunakan persamaan (2.3). Selain itu, *precision* dan *recall* digunakan untuk mengevaluasi ketepatan dan kemampuan model dalam mendeteksi setiap kelas penyakit dengan persamaan (2.4) dan persamaan (2.5). Untuk menyeimbangkan kedua metrik tersebut, digunakan *F1-score* dengan persamaan (2.6) yang merupakan rata-rata harmonik dari *precision* dan *recall*. Seluruh metrik evaluasi dihitung untuk masing-masing kelas penyakit (*per-class evaluation*). Selanjutnya, dilakukan agregasi metrik menggunakan pendekatan *macro average* dan *weighted average* untuk memperoleh gambaran performa model secara keseluruhan, khususnya pada kondisi distribusi data yang tidak seimbang.

3.8.3 Analisis Hasil

Tahap akhir evaluasi dilakukan untuk menganalisis hasil pengujian model guna menilai performa serta kemampuan generalisasi model yang dikembangkan. Analisis dilakukan berdasarkan nilai metrik evaluasi dan pola kesalahan klasifikasi pada data pengujian, termasuk perbandingan performa pada setiap kelas penyakit. Selain itu, *confusion matrix* digunakan untuk mengidentifikasi kesalahan prediksi antar kelas. Hasil evaluasi disajikan dalam bentuk visualisasi guna mempermudah interpretasi, serta menjadi dasar dalam penarikan kesimpulan dan identifikasi potensi pengembangan model selanjutnya.

3.9 Perancangan Pengujian

Pengujian yang dilakukan dalam sistem ini bertujuan untuk mengevaluasi kinerja dari aplikasi klasifikasi penyakit daun kelapa sawit, yang meliputi pengujian antarmuka (*interface*), pengujian algoritma, dan pengujian akurasi model.

Pengujian antarmuka (*interface*) dilakukan dengan metode *black box testing*. Pengujian ini hanya berfokus pada keluaran dari sistem berdasarkan input yang diberikan, tanpa mengetahui proses *internal sistem*. Pengujian ini memastikan bahwa setiap fungsi pada aplikasi web, seperti unggah gambar, tampilan hasil klasifikasi, dan navigasi antarmuka, dapat berjalan sesuai dengan yang diharapkan.

Pengujian algoritma dilakukan dengan metode *white box testing*. Pada penelitian ini, *white box* digunakan untuk mengevaluasi alur logika dan struktur kode dari Arsitektur *ResNet-50* yang digunakan dalam klasifikasi penyakit daun kelapa sawit. Pengujian ini memastikan bahwa proses pelatihan model, pemrosesan citra, dan inferensi berjalan dengan benar dan efisien.

Pengujian akurasi model dilakukan untuk mengukur seberapa baik model *ResNet-50* dengan pendekatan *Transfer Learning* dalam mengklasifikasikan citra daun kelapa sawit dengan 5 kelas: daun sehat, bercak daun, daun menguning, daun kering dan kutu putih. Pengujian akurasi ini melibatkan metrik evaluasi seperti *confusion matrix*, *precision*, *recall*, dan *accuracy score* yang diperoleh dari data pengujian (*testing data*).

BAB IV

HASIL DAN PEMBAHASAN

Bab ini menguraikan hasil implementasi sistem klasifikasi penyakit daun kelapa sawit yang dikembangkan menggunakan Arsitektur *ResNet-50* dengan pendekatan *transfer learning*. Pembahasan mencakup implementasi sistem berbasis web, pengumpulan dan pengolahan data, implementasi model, perbandingan performa tiga skenario dataset, hasil evaluasi model terbaik menggunakan *confusion matrix*, serta hasil pengujian fungsional *blackbox* dan *whitebox*.

Implementasi sistem klasifikasi penyakit daun kelapa sawit menggunakan arsitektur *ResNet-50* dengan pendekatan *transfer learning* telah berhasil diwujudkan dalam bentuk aplikasi berbasis web. Sistem ini dibangun menggunakan *ReactJS* 18 dan *TypeScript* pada sisi *frontend*, serta *FastAPI* (Python) pada sisi backend untuk melayani inferensi model *deep learning*. Antarmuka pengguna dirancang responsif menggunakan *Tailwind CSS*. Manajemen autentikasi dan basis data memanfaatkan layanan Supabase yang menyediakan PostgreSQL, Supabase Auth, dan Supabase Storage.

Sistem yang dibangun terdiri dari tujuh halaman yang dapat diakses oleh dua jenis pengguna, yaitu User biasa dan Admin. Proses klasifikasi dilakukan secara *real-time* melalui pengiriman citra ke *endpoint* FastAPI yang kemudian diproses oleh model *ResNet-50* yang telah dilatih. Hasil prediksi dikembalikan dalam format JSON berisi kelas penyakit, tingkat kepercayaan (*confidence*), distribusi probabilitas seluruh kelas, serta rekomendasi penanganan

4.1 Implementasi Sistem Klasifikasi Penyakit Daun Kelapa Sawit


Hasil dari implementasi mencakup berbagai halaman antarmuka pengguna seperti halaman klasifikasi dan hasil deteksi, serta fitur-fitur pendukung lainnya. Selain itu, sistem ini juga telah diintegrasikan dengan model *ResNet-50* yang telah dilatih untuk mengenali lima kelas, yaitu daun sehat, daun kering, bercak daun, daun menguning dan kutu putih.

Implementasi ini bertujuan untuk memudahkan pengguna, khususnya petani atau pengelola Perkebunan sawit pada wilayah Pangkalan Susu, dalam mengidentifikasi penyakit daun secara otomatis melalui platform berbasis web yang *responsif* dan mudah digunakan untuk mendeteksi daun kelapa sawit mereka yang kemungkinan memiliki penyakit yang telah ditentukan oleh sistem klasifikasi penyakit daun pada kelapa sawit untuk mendapatkan hasil yang sangat memuaskan dan mudah dipahami oleh para pengguna yang akan menjadi bagian dari implementasi mudah dimengerti dan enak dilihat oleh para pengguna yang menggunakan website klasifikasi penyakit daun kelapa sawit.

4.1.1 Implementasi Halaman Beranda

Halaman beranda merupakan halaman pertama yang ditemui oleh pengguna saat mengakses sistem. Halaman ini dirancang untuk memberikan kesan profesional sekaligus informatif mengenai fungsi utama aplikasi Nyakwit. Bagian *hero* menampilkan ilustrasi daun kelapa sawit beserta *tagline* utama dan tombol ajakan bertindak berupa tombol "Scan Daun Sekarang" yang mengarahkan pengguna ke halaman klasifikasi. Terdapat pula statistik ringkas yang menampilkan

jumlah kelas penyakit, jumlah data latih, dan arsitektur yang digunakan. Halaman Beranda dapat dilihat pada Gambar 4.1.




Gambar 4. 1 Implentasi Halaman Beranda

4.1.2 Halaman Klasifikasi


Halaman ini merupakan inti dari sistem ini. Pengguna dapat mengunggah foto daun kelapa sawit melalui dua cara memilih dari galeri perangkat atau mengambil foto langsung menggunakan kamera. Sistem mendukung format JPG dan PNG dengan ukuran maksimal 10 MB. Setelah gambar dipilih, pratinjau (*preview*) ditampilkan bersama tombol "Analisa Sekarang" untuk memulai proses klasifikasi.

Pada saat proses klasifikasi berlangsung, *overlay* animasi *loading* ditampilkan di atas gambar dengan indikator *spinner* dan ikon daun yang berdenyut. Proses ini melibatkan pengiriman gambar ke *endpoint/predict* pada FastAPI *backend* menggunakan HTTP POST dengan *body* berupa *FormData*. Setelah respon diterima, sistem menampilkan hasil secara terstruktur yang mencakup nama penyakit yang terdeteksi, *badge* tingkat keparahan (*none/low/medium/high*), *confidence score* dalam persen, diagram batang distribusi probabilitas untuk kelima kelas, rekomendasi penanganan, dan tips pencegahan.

Halaman ini juga dilengkapi dengan indikator status koneksi *backend* (ApiStatusBadge) yang secara otomatis melakukan *health check* ke *endpoint* /. Jika *backend* tidak dapat dijangkau, sistem menampilkan pesan peringatan beserta instruksi cara menjalankan server. Fitur ini memastikan pengguna mendapat informasi yang jelas mengenai status sistem sebelum melakukan scan. Gambar 4.2 memperlihatkan halaman klasifikasi.



(a)




(b)

Gambar 4. 2 Implementasi Halaman Klasifikasi

4.1.3 Halaman Ensiklopedia

Gambar 4.3 menampilkan Halaman ensiklopedia yang berfungsi menyajikan informasi lengkap mengenai lima kondisi daun kelapa sawit yang dapat diidentifikasi oleh sistem. Setiap kondisi ditampilkan dalam bentuk kartu artikel yang memuat gambar representatif, *badge* tingkat keparahan, nama kondisi, *tagline*, serta empat bagian informasi seperti gejala, penyebab, penanganan, dan pencegahan. Navigasi cepat disediakan di bagian atas halaman berupa tombol *anchor link* ke setiap kondisi penyakit.



Gambar 4. 3 Halaman Ensiklopedia

4.1.4 Halaman Login dan Register

Gambar 4.4 menampilkan Halaman autentikasi yang menggunakan *layout* dua kolom pada layar lebar, kolom kiri menampilkan ilustrasi dan deskripsi manfaat memiliki akun, sedangkan kolom kanan menampilkan formulir login atau register. Pengguna dapat beralih antara mode login dan register menggunakan *toggle button* yang responsif. Sistem mendukung dua metode autentikasi yaitu login dengan email dan password, registrasi akun baru dengan verifikasi email.

Validasi formulir diimplementasikan menggunakan *library Zod* yang memastikan format email yang valid, panjang password minimal delapan karakter, dan kelengkapan nama pengguna saat registrasi. Fitur lupa password juga tersedia dimana sistem akan mengirimkan tautan reset ke email pengguna. Seluruh proses autentikasi dikelola oleh Supabase Auth yang menyediakan keamanan berbasis JWT token. Setelah login berhasil, pengguna diarahkan ke halaman yang sesuai berdasarkan perannya masing masing, admin diarahkan ke halaman dashboard, sedangkan user biasa diarahkan ke halaman riwayat.

(a)


(b)

Gambar 4. 4 Form Login dan Registrasi

4.1.5 Halaman Profil

Halaman profil menampilkan ringkasan informasi akun dan aktivitas scan pengguna. *Layout* menggunakan grid dua kolom pada layar lebar, kolom kiri menampilkan avatar, nama, email, badge peran (User atau Admin), dan tanggal bergabung, sedangkan kolom kanan menampilkan tiga kartu statistik (total scan, penyakit terbanyak, tanggal scan terakhir) beserta tabel riwayat lima scan terakhir.

Avatar pengguna menggunakan komponen Avatar dengan fallback berupa inisial nama jika gambar profil tidak tersedia. Data profil diambil dari tabel users di Supabase yang secara otomatis diisi saat pengguna pertama kali mendaftar melalui trigger database. Tampilan halaman profil dapat dilihat pada Gambar 4.5.




Gambar 4. 5 Halaman Profil

4.1.6 Halaman Riwayat

Gambar 4.6 adalah Halaman Riwayat yang menampilkan seluruh hasil klasifikasi yang pernah dilakukan oleh pengguna yang sedang login. Data diambil dari tabel scan_history di Supabase dengan filter berdasarkan user_id pengguna

aktif, diurutkan berdasarkan waktu terbaru. Bagian atas halaman menampilkan tiga kartu statistik ringkas yaitu total scan yang pernah dilakukan, kelas penyakit yang paling sering terdeteksi, dan tanggal scan terakhir.

Tampilan tabel adaptif berdasarkan ukuran layar, jika pada perangkat mobile ditampilkan sebagai daftar kartu berisi gambar *thumbnail*, nama penyakit, waktu, dan *confidence*, sedangkan pada layar desktop ditampilkan sebagai tabel lengkap dengan kolom tanggal, gambar, prediksi penyakit, dan *confidence score*. Jika pengguna belum pernah melakukan scan, ditampilkan pesan kosong beserta tombol ajakan untuk memulai scan pertama. Akses ke halaman ini memerlukan autentikasi, pengguna yang belum login akan melihat pesan login required.



Riwayat scan kamu
Semua hasil scan penyakit daun yang pernah kamu lakukan tersimpan di sini.

🕒 Total: **23**

📷 Terbanyak: **Scale Insect**

📅 Terakhir: **06 Mei 2026**

Tanggal	Gambar	Prediksi	Confidence
06 Mei 2026, 16:41		Scale Insect	99%
06 Mei 2026, 16:41		Dryness	51%
06 Mei 2026, 16:41		Dryness	62%
06 Mei 2026, 16:40		Healthy	100%

Gambar 4. 6 Halaman History


4.1.7 Halaman Dashboard

Halaman dashboard admin hanya dapat diakses oleh pengguna dengan peran admin. Sistem memverifikasi peran pengguna dengan mengquery tabel `user_roles` di Supabase, jika peran bukan admin, pengguna diarahkan ke halaman riwayat.

Dashboard menampilkan empat kartu statistik yaitu total pengguna terdaftar, total scan dari seluruh pengguna, kelas penyakit yang paling banyak terdeteksi di seluruh sistem, dan waktu scan terakhir dari seluruh pengguna.

Bagian bawah dashboard menampilkan tabel riwayat scan seluruh pengguna beserta informasi nama pengguna, gambar daun, kelas penyakit terdeteksi, dan nilai *confidence*. Tampilan adaptif serupa dengan halaman riwayat user biasa, namun mencakup seluruh data tanpa filter berdasarkan user. Fitur ini memungkinkan admin untuk memantau penggunaan sistem secara menyeluruh dan mengidentifikasi tren penyakit yang dominan. Terdapat sistem untuk mengelola user, mengedit info penyakit dan melihat statistik dari hasil klasifikasi seperti pada

Gambar 4.7



Gambar 4. 7 Halaman Dashboard Admin

4.2 Implementasi Pengumpulan Dataset

Dataset yang digunakan dalam penelitian ini berasal dari dua sumber utama, yaitu dataset *sekunder* yang diperoleh dari platform Kaggle dan dataset *primer* yang dikumpulkan secara langsung di perkebunan kelapa sawit wilayah Pangkalan Susu, Sumatera Utara. Untuk mengetahui pengaruh sumber data terhadap performa model klasifikasi, penelitian ini membentuk tiga skenario dataset yang berbeda, yaitu dataset *primer*, dataset *sekunder*, dan dataset *multi modal*. Seluruh citra digunakan untuk mengklasifikasikan lima kelas kondisi daun kelapa sawit, yaitu *Healthy* (Sehat), *Dryness* (Kekeringan), *Fungal Disease* (Bercak), *Magnesium Deficiency* (Kuning), dan *Scale Insect* (Kutu Perisai).

4.2.1 Dataset *Primer*

Dataset primer merupakan dataset yang diperoleh melalui pengambilan citra secara langsung di perkebunan kelapa sawit Pangkalan Susu, Sumatera Utara. Proses akuisisi citra dilakukan menggunakan beberapa perangkat smartphone, yaitu iPhone 13, Samsung A55, dan Realme 8i. Pengambilan gambar dilakukan pada berbagai kondisi pencahayaan alami dan sudut pengambilan yang berbeda untuk meningkatkan variasi data serta merepresentasikan kondisi nyata di lapangan.

Tabel 4. 1 Dataset *Primer*

No	Kelas	Citra
1	<i>Healthy</i>	452
2	<i>Dryness</i>	430
3	<i>Fungal Disease</i>	453
4	<i>Magnesium Deficiency</i>	441
5	<i>Scale Insect</i>	358
Total		2134

Tabel 4.1 memperlihatkan jumlah citra pada dataset *primer* sebanyak 2134 citra yang terdiri atas 452 citra daun *healthy*, 430 citra *dryness*, 453 citra *fungal disease*, 441 citra *magnesium deficiency*, dan 358 citra *scale insect*. Jumlah data yang relatif besar pada setiap kelas diharapkan dapat membantu model dalam mempelajari karakteristik penyakit daun kelapa sawit secara lebih baik. Contoh citra daun sawit dataset *primer* dapat dilihat pada Gambar 4.8.



Gambar 4. 8 Gambar Daun *Primer*

4.2.2 Dataset *Sekunder*

Dataset *sekunder* merupakan dataset publik yang diperoleh dari platform Kaggle. Dataset ini telah tersedia dalam bentuk citra digital yang dikelompokkan ke dalam lima kelas kondisi daun kelapa sawit. Citra pada dataset *sekunder* umumnya memiliki kualitas yang lebih terkontrol namun, dataset *sekunder* ini tidak sesuai ekspektasi jumlah data sedikit dan kualitas gambar buruk.

Tabel 4. 2 Dataset *Sekunder*

No	Kelas	Citra
1	<i>Healthy</i>	48
2	<i>Drynees</i>	70
3	<i>Fungal Disease</i>	47
4	<i>Magnesium Deficiency</i>	59
5	<i>Scale Insect</i>	142
Total		366

Tabel 4.2 memperlihatkan jumlah citra pada dataset sekunder sebanyak 366 citra yang terdiri atas 48 citra daun *healthy*, 70 citra *dryness*, 47 citra *fungal disease*, 59 citra *magnesium deficiency*, dan 142 citra *scale insect*. Jumlah citra yang lebih sedikit dan distribusi kelas yang tidak seimbang menjadi salah satu tantangan dalam proses pelatihan model pada skenario ini. Contoh citra pada dataset *sekunder* dapat dilihat pada Gambar 4.9 dibawah.



Gambar 4. 9 Gambar Daun *Sekunder*

4.2.3 Dataset *Multi Modal*

Dataset multi modal merupakan hasil penggabungan dataset *primer* dan dataset *sekunder*. Pada penelitian ini, istilah multi modal digunakan untuk menggambarkan kombinasi data citra yang berasal dari dua sumber berbeda, yaitu citra hasil pengambilan langsung di perkebunan kelapa sawit Pangkalan Susu dan citra yang diperoleh dari platform Kaggle.

Penggabungan kedua sumber data dilakukan dengan tujuan meningkatkan keragaman dataset sehingga model dapat mempelajari fitur yang lebih beragam dan memiliki kemampuan generalisasi yang lebih baik terhadap data baru. Selain itu, kombinasi data dari lingkungan terkontrol dan lingkungan nyata diharapkan dapat meningkatkan ketahanan model terhadap variasi kondisi citra yang sering ditemui pada implementasi di lapangan.

Tabel 4. 3 *Multi Modal*

No	Kelas	Citra
1	<i>Healthy</i>	500
2	<i>Drynees</i>	500
3	<i>Fungal Disease</i>	500
4	<i>Magnesium Deficiency</i>	500
5	<i>Scale Insect</i>	500
Total		2500

Pada Tabel 4.3 menampilkan jumlah citra setiap kelas diseragamkan menjadi 500 citra sehingga total dataset yang digunakan sebanyak 2.500 citra. Komposisi tersebut terdiri atas 500 citra *healthy*, 500 citra *dryness*, 500 citra *fungal disease*, 500 citra *magnesium deficiency*, dan 500 citra *scale insect*.

4.3 *Preprocessing Data*

Gambar yang digunakan sebagai dataset harus melalui tahapan *preprocessing* untuk meningkatkan kualitas dan kesiapan data sebelum digunakan pada pelatihan model *ResNet-50*. Proses ini bertujuan untuk mengoptimalkan kinerja model dalam mengenali pola visual yang relevan, terutama pada data gambar daun kelapa sawit yang diambil langsung dari lapangan dan memiliki pencahayaan yang beragam.

4.3.1 Pengecekan dan Konversi Format

Sebelum dilakukan augmentasi, seluruh citra melalui tahapan pra-pemrosesan yang terdiri dari tiga langkah utama. Langkah pertama adalah pengecekan dan konversi format: seluruh citra diperiksa dan dikonversi ke format RGB tiga kanal apabila ditemukan citra dalam format RGBA (empat kanal) atau *grayscale* (satu kanal).

Tabel 4. 4 Konversi

```
def convert_to_rgb(path):
    "Konversi gambar ke RGB apapun format aslinya."
    img = Image.open(path)
    mode = img.mode

    if mode == "RGB":
        return img, "RGB asli"
    elif mode == "RGBA":
        bg = Image.new("RGB", img.size, (255,255,255))
        bg.paste(img, mask=img.split()[3])
        return bg, "RGBA → RGB"
    else:
        return img.convert("RGB"), f"{mode} → RGB"

print("Udah di konversi.")
```

Kode pada Tabel 4.4 mendefinisikan fungsi `convert_to_rgb` yang bertugas membuka gambar dari path tertentu lalu memastikan hasilnya dalam format RGB. Pertama, gambar dibuka dengan `Image.open(path)` dan mode warnanya dicek melalui `img.mode`. Jika mode sudah "RGB", gambar dikembalikan apa adanya dengan keterangan "RGB asli". Jika mode "RGBA", artinya ada channel transparansi, maka dibuat background putih baru berformat RGB, lalu gambar ditempel di atasnya menggunakan alpha mask sehingga transparansi diubah menjadi warna putih, kemudian dikembalikan dengan keterangan "RGBA → RGB". Untuk mode lain seperti grayscale, gambar dikonversi ke RGB menggunakan `.convert("RGB")` dan dikembalikan bersama teks penjelasan mode asal. Di luar fungsi, terdapat perintah `print("Udah di konversi.")` yang hanya menampilkan pesan ke terminal tanpa memanggil fungsi.

4.3.2 *Resize* (Mengubah Ukuran Gambar)

Langkah kedua adalah *resize* dimana seluruh citra diubah ukurannya menjadi 224 x 224 piksel menggunakan interpolasi bilinear, sesuai dengan dimensi input standar arsitektur *ResNet-50* yang dilatih pada dataset ImageNet.

Tabel 4. 5 *Resize*

```
def resize_224(img):
    "Resize gambar ke 224×224 dengan interpolasi BILINEAR."
    return img.resize(TARGET_SIZE, Image.BILINEAR)
print("Fungsi resize siap")
```

Code pada Tabel 4.5 menjelaskan Fungsi `resize_224` digunakan untuk mengubah ukuran gambar menjadi 224×224 piksel dengan interpolasi BILINEAR agar hasilnya halus. Baris pertama mendefinisikan fungsi dengan parameter `img`, lalu docstring menjelaskan tujuannya. Di dalam fungsi, `img.resize(TARGET_SIZE, Image.BILINEAR)` melakukan proses resize sesuai ukuran (224, 224) yang disimpan di variabel `TARGET_SIZE`. Terakhir, `print("Fungsi resize siap")` menampilkan pesan bahwa fungsi sudah tersedia.

4.3.3 *Split Data*

Sebelum augmentasi, dataset dibagi menggunakan metode *stratified splitting* untuk memastikan distribusi kelas yang proporsional pada setiap subset. Pembagian dilakukan dengan proporsi 70% untuk data latih, 15% untuk data validasi, dan 15% untuk data uji.

Tabel 4. 6 *Split Data*

```
train_files, sisa_files = train_test_split(
    list_file,
    test_size=(val_ratio + test_ratio),
    random_state=SEED,
    shuffle=True
)

val_files, test_files = train_test_split(
    sisa_files,
    test_size=(test_ratio / (val_ratio + test_ratio)),
    random_state=SEED,
    shuffle=True
)
```


Code pada Tabel 4.7 merupakan fungsi `augment_rotation` merotasi gambar secara acak hingga ± 20 derajat. Pertama, dipilih sudut acak dengan `random.uniform`, lalu dihitung pusat gambar dari tinggi dan lebar. Matriks rotasi dibuat dengan `cv2.getRotationMatrix2D`, dan akhirnya `cv2.warpAffine` menerapkan rotasi menggunakan interpolasi linear agar halus, sementara area kosong di tepi diisi dengan pantulan piksel terdekat.

4.3.5 Rescale (Normalisasi Nilai Piksel)

Langkah kelima adalah normalisasi piksel dimana nilai intensitas piksel yang awalnya berada dalam rentang $[0, 255]$ dinormalisasi ke rentang $[0, 1]$ dengan membagi setiap nilai dengan 255. Selanjutnya dilakukan standarisasi menggunakan statistik dataset ImageNet, yaitu dikurangi nilai mean $[0.485, 0.456, 0.406]$ dan dibagi dengan standar deviasi $[0.229, 0.224, 0.225]$ untuk masing-masing kanal R, G, dan B. Normalisasi ini penting untuk memastikan konsistensi distribusi data input dengan kondisi saat model *ResNet-50* dilatih pada ImageNet.

Tabel 4. 8 Code Normalisasi Standar Imagenet

```
IMAGENET_MEAN = [0.485, 0.456, 0.406]
IMAGENET_STD  = [0.229, 0.224, 0.225]
transforms.Normalize(mean=IMAGENET_MEAN, std=IMAGENET_STD)
```

Tabel 4.8 berisi code yang menetapkan nilai rata-rata (`IMAGENET_MEAN`) dan standar deviasi (`IMAGENET_STD`) tiap channel RGB dari dataset ImageNet, lalu `transforms.Normalize` memanfaatkan nilai tersebut untuk menormalkan piksel gambar sehingga input sesuai dengan distribusi data yang digunakan saat melatih model.

4.4 Implementasi Rancangan Arsitektur *ResNet-50*

Model klasifikasi dikembangkan menggunakan arsitektur *ResNet-50* dengan pendekatan *transfer learning*. Implementasi dilakukan menggunakan *framework* PyTorch dengan *library* TorchVision yang menyediakan model *ResNet-50* yang telah dilatih pada dataset *ImageNet* (ImageNet-1K, 1,28 juta gambar, 1000 kelas).

4.4.1 Konfigurasi *Transfer Learning*

Implementasi arsitektur model *ResNet-50* dalam penelitian ini terdiri dari dua tahap utama. Tahap pertama adalah memuat bobot pretrained dari *ImageNet* dan membekukan (*freeze*) seluruh lapisan konvolusi dari Stage 1 hingga Stage 4. Tahap ini bertujuan untuk mempertahankan fitur-fitur umum yang telah dipelajari dari dataset ImageNet, seperti deteksi tepi, tekstur, dan pola warna yang bersifat general dan relevan untuk domain klasifikasi citra daun.

Tahap kedua adalah modifikasi lapisan *fully connected* pada bagian akhir model. Lapisan FC original *ResNet-50* yang dirancang untuk 1000 kelas diganti dengan *classifier head* baru yang terdiri dari tahapan konfigurasi yang dapat dilihat pada tabel 4.9.

Tabel 4. 9 Arsitektur Model *ResNet-50*

No	Komponen	Konfigurasi	Keterangan
1	<i>Base Model</i>	<i>ResNet-50 (pretrained ImageNet)</i>	<i>Backbone</i> untuk ekstraksi fitur
2	<i>Freeze Layer</i>	Stage 1 – Stage 4 (dibekukan)	Bobot tidak diperbarui fase awal
3	<i>Dense Layer</i>	256 <i>neuron</i> + ReLU	Transformasi fitur abstrak
4	<i>Dropout</i>	<i>Rate</i> = 0.5	<i>Regularisasi</i> , cegah <i>overfitting</i>
5	<i>Output Layer</i>	5 <i>neuron</i> + <i>Softmax</i>	Klasifikasi 5 kelas penyakit

Bagian ini menjelaskan secara detail bagaimana arsitektur dasar *ResNet-50* diadaptasi ke dalam sistem klasifikasi penyakit daun kelapa sawit melalui metode penyesuaian lapisan (*layer modification*).

Tabel 4. 10 Arsitektur Model *ResNet-50*

```
import torch.nn as nn
from torchvision import models

def build_model(num_classes=NUM_CLASSES, dropout=DROPOUT_RATE):
    model=models.resnet50(weights=models.
        ResNet50_Weights.IMAGENET1K_V1)

    for param in model.parameters():
        param.requires_grad = False

    in_features = model.fc.in_features
    model.fc = nn.Sequential(
        nn.Linear(in_features, 256),
        nn.ReLU(),
        nn.Dropout(p=dropout),
        nn.Linear(256, num_classes)
    )
    return model
```

Code dari Tabel 4.10 berfungsi untuk membangun arsitektur *transfer learning* berbasis *ResNet-50*, di mana tahap awal dilakukan dengan memuat arsitektur model yang telah memiliki bobot *pretrained* dari ImageNet dan membekukan seluruh parameter konvolusi aslinya (`requires_grad = False`) agar fitur umum yang telah dipelajari tidak mengalami perubahan selama pelatihan awal. Selanjutnya, lapisan *fully connected* bawaan (`model.fc`) yang awalnya dirancang untuk 1000 kelas dipotong dan diganti dengan struktur *classifier head* baru secara sekuensial; mencakup lapisan linier pertama dengan 256 *neuron*, fungsi aktivasi ReLU untuk pemrosesan fitur *non-linier*, lapisan *dropout* sebagai teknik regularisasi untuk mencegah *overfitting*, serta diakhiri dengan lapisan *linier output* yang dimensinya disesuaikan secara dinamis dengan jumlah kelas target (`num_classes`) untuk menghasilkan nilai skor keputusan klasifikasi.

4.4.2 Proses Pelatihan Model

Pelatihan model dilakukan dalam dua fase. Fase pertama adalah *feature extraction*, di mana hanya lapisan classifier head yang dilatih sementara seluruh layer konvolusi dibekukan. Fase ini menggunakan *learning rate* awal sebesar 0.001 dengan *optimizer Adam*. *Loss function* yang digunakan adalah *Categorical Cross-Entropy* yang sesuai untuk klasifikasi multi-kelas. *Batch size* ditetapkan sebesar 32 sampel per iterasi.

Fase kedua adalah *fine-tuning*, yang dilakukan setelah fase *feature extraction* menunjukkan konvergensi. Pada fase ini, beberapa lapisan konvolusi terakhir (Stage 4) dibuka kembali (*unfreeze*) sehingga bobotnya dapat diperbarui. *Learning rate* diturunkan secara signifikan menjadi 0.0001 untuk mencegah perubahan bobot yang terlalu besar dan menjaga stabilitas pelatihan. *Fine-tuning* memungkinkan model menyesuaikan fitur-fitur tingkat tinggi yang lebih spesifik terhadap karakteristik visual daun kelapa sawit.

Mekanisme *Early Stopping* diterapkan untuk mencegah *overfitting*, dengan batas *patience* sebesar 15 epoch. Apabila tidak terjadi peningkatan pada *validation loss* selama 15 epoch berturut-turut, pelatihan dihentikan secara otomatis dan model dengan performa validasi terbaik dimuat kembali. Selain itu, *Learning Rate Reduction on Plateau* diterapkan dengan faktor pengurangan 0.1 apabila *validation loss stagnan*, untuk membantu model keluar dari *local minima*. *Hyperparameter* dapat dilihat pada tabel 4,11.

Tabel 4. 11 *Hyperparameter* Pelatihan Model

No	Hyperparameter	Fase 1 (Feature Extraction)	Fase 2 (Fine-tuning)
1	<i>Learning Rate</i>	0.001	0.0001
2	<i>Optimizer</i>	Adam	Adam
3	<i>Loss Function</i>	Categorical Cross-Entropy	Categorical Cross-Entropy
4	<i>Batch Size</i>	32	32
5	<i>Max Epoch</i>	30 epoch	20 epoch
6	<i>Early Stopping Patience</i>	15 epoch	15 epoch
7	<i>LR Reduction Factor</i>	0.1	0.1
8	<i>Layer Frozen</i>	Stage 1–4 (semua)	Stage 1–3 (stage 4 dibuka)

Sebelum memulai proses pelatihan model, dilakukan inisialisasi terhadap parameter direktori, representasi kelas target, serta *hyperparameter* yang mengatur jalannya eksperimen. Pengaturan parameter global ini bertujuan untuk memastikan konsistensi data dari tahap *loading* hingga evaluasi.

Tabel 4. 12 *Hyperparameter* Pelatihan Model

IMG_SIZE	= 224
BATCH_SIZE	= 32
LR_PHASE1	= 1e-3
EPOCHS_P1	= 30
LR_PHASE2	= 1e-4
EPOCHS_P2	= 20
UNFREEZE_LAYERS	= 2
EARLY_STOP_PATIENCE	= 15
REDUCE_LR_PATIENCE	= 5
DROPOUT_RATE	= 0.5

Kode konfigurasi Tabel 4.12 mendefinisikan parameter utama untuk pelatihan model *transfer learning* dua fase dalam mengklasifikasikan lima kondisi daun kelapa sawit (*CLASSES*), dengan ukuran gambar input yang diseragamkan menjadi 224 x 224 piksel (IMG_SIZE) dan diproses dalam kelompok kecil berisi 32 sampel

per iterasi (BATCH_SIZE). Pelatihan dirancang secara adaptif: Fase 1 berjalan selama 30 *epoch* (EPOCHS_P1) dengan *learning rate* lebih besar yaitu 0.001 (LR_PHASE1) untuk melatih lapisan pengklasifikasi baru (*classifier head*), sedangkan Fase 2 berjalan selama 20 *epoch* (EPOCHS_P2) dengan *learning rate* lebih kecil sebesar 0.0001 (LR_PHASE2) untuk melakukan penyesuaian halus (*fine-tuning*) pada lapisan konvolusi teratas. Selain itu, diterapkan nilai *dropout rate* sebesar 0.5 (DROPOUT_RATE) sebagai teknik regularisasi untuk mencegah terjadinya *overfitting* dengan cara menonaktifkan 50% neuron secara acak selama proses pelatihan.

4.5 Perbandingan Model Berdasarkan Skenario Dataset

Untuk mengevaluasi pengaruh sumber data terhadap performa model, dilakukan pelatihan dan pengujian *ResNet-50* secara terpisah pada tiga skenario: dataset Sekunder, dataset Primer, dan dataset *Multi Modal*. Seluruh skenario menggunakan arsitektur dan *hyperparameter* yang identik sehingga perbedaan performa dapat dikaitkan langsung dengan pengaruh komposisi data.

4.5.1 Perbandingan Akurasi Keseluruhan

Berikut adalah perbandingan akurasi keseluruhan dari 3 dataset penelitian ini yang dapat dilihat pada tabel 4.13.

Tabel 4. 13 Perbandingan Antar Model

No	Skenario Dataset	Akurasi	Precision	Recall	F1-Score
1	Dataset <i>Primer</i>	96.60%	96.67%	96.59%	96.62%
2	Dataset <i>Sekunder</i>	82.66%	82.89%	82.66%	82.45%
3	Dataset <i>Multi Modal</i> (<i>Sekunder+Primer</i>)	89.87%	89.90%	89.86%	89.82%

Berdasarkan Tabel 4.13, hasil perbandingan ketiga skenario menunjukkan bahwa model yang dilatih dengan dataset *Multi Modal (Sekunder + Primer)* menghasilkan performa terbaik dalam menebak penyakit gambar. Model yang dilatih hanya dengan dataset *Primer* memperoleh akurasi lebih tinggi dibandingkan dua skenario lainnya, namun dalam menebak penyakit daun masih sering mengalami kekeliruan. Hal ini disebabkan oleh sudut pandang foto daun yang di ambil perhelai saja, sehingga model tidak memiliki cukup variasi data untuk mempelajari fitur diskriminatif secara optimal. Model yang dilatih dengan dataset *Sekunder* memperoleh akurasi yang paling rendah dikarenakan jumlah data sangat sedikit, dan masih sering salah dalam menebak penyakit gambar. Model dataset *Multi Modal* lebih baik dalam menebak penyakit pada daun sawit, dikarenakan banyak variasi gambar misal dari sudut pandang pengambilan gambar *Sekunder* mengambil satu batang daun sedangkan *Primer* mengambil perhelai daun.

4.5.2 Perbandingan Model dengan Penelitian Lain

Untuk menilai posisi performa model yang dikembangkan, dilakukan perbandingan dengan beberapa penelitian terdahulu yang menggunakan metode serupa dalam domain klasifikasi penyakit daun tanaman. Perbandingan difokuskan pada aspek metode yang digunakan, jumlah kelas, dan akurasi yang diperoleh.

Tabel 4. 14 Perbandingan Penelitian

No	Penelitian	Metode	Kelas	Akurasi
1	Mandiri et al. (2025)	CNN AlexNet	5	80% (validasi)
2	Ong et al. (2022)	AlexNet-CNN & AlexNet-SVM	4	93%–99%

3	Ashiqul Islam et al. (2021)	ResNet-101 + InceptionResNetV2	4	92.68%
4	Ahmed & Ahmed (2023)	ResNet + Transfer Learning Inception ResNet	3	99.62%
5	Penelitian Ini – Dataset <i>Sekunder</i>	<i>ResNet-50</i> + Transfer Learning	5	82.66%
6	Penelitian Ini – Dataset Primer	<i>ResNet-50</i> + Transfer Learning	5	96.60%
7	Penelitian Ini – Multi Modal	<i>ResNet-50</i> + Transfer Learning	5	89.87%

Berdasarkan tabel 4.14, dapat dilihat bahwa penelitian ini mengklasifikasikan lima kelas kondisi daun kelapa sawit menggunakan arsitektur *ResNet-50* dengan pendekatan transfer learning. Dibandingkan dengan penelitian Mandiri et al. (2025) yang menggunakan AlexNet untuk lima kelas dan memperoleh akurasi validasi 80%, penelitian ini menggunakan arsitektur yang lebih dalam (50 layer) dengan mekanisme residual connection yang terbukti lebih efektif dalam ekstraksi fitur kompleks. Penelitian Ahmed dan Ahmed (2023) menggunakan arsitektur Inception ResNet untuk tiga kelas pohon kurma dan mencapai akurasi 99.62%, namun jumlah kelas yang lebih sedikit dan domain yang berbeda membuat perbandingan langsung tidak sepenuhnya representatif.

Kebaruan penelitian ini terletak pada kombinasi dataset *Sekunder* dengan data *Primer* yang dikumpulkan langsung dari perkebunan Pangkalan Susu untuk lima kelas penyakit daun kelapa sawit yang relevan secara lokal. Pendekatan ini diharapkan menghasilkan model yang lebih adaptif terhadap kondisi lapangan nyata di perkebunan Indonesia.

4.6 Hasil Pengujian Arsitektur *ResNet-50*


Evaluasi performa model dilakukan menggunakan *data testing* sebanyak 375 gambar (75 gambar per kelas) yang tidak digunakan selama proses pelatihan maupun validasi. Evaluasi menggunakan metrik akurasi, *precision*, *recall*, *F1-score*, dan *confusion matrix* untuk menilai kemampuan model secara komprehensif pada setiap kelas penyakit.

4.6.1 *Confusion Matrix*

Confusion matrix menggambarkan distribusi hasil prediksi model dibandingkan dengan label aktual untuk setiap kelas. Baris pada confusion matrix mewakili kelas aktual (*ground truth*), sedangkan kolom mewakili kelas yang diprediksi oleh model. Nilai diagonal utama menunjukkan prediksi yang benar (*True Positive*), sedangkan nilai di luar diagonal menunjukkan kesalahan klasifikasi. Berikut *Confusion Matrix* berdasarkan 3 skenario:

a. *Confusion Matrix* dataset *Primer*


Berdasarkan Gambar 4.10, menunjukkan performa yang sangat *robust* dengan mengklasifikasikan secara tepat 313 dari total 324 sampel uji, sehingga menghasilkan nilai akurasi sebesar 96,60%. Model mencapai performa optimal pada kelas *Healthy* dengan tingkat akurasi 100% tanpa mengalami misklasifikasi pada seluruh sampel aktual, diikuti oleh akurasi tinggi pada kelas *Fungal Disease* (65 dari 68 data), *Dryness* (63 dari 65 data), dan *Scale Insect* (54 dari 56 data). Tingkat kesalahan minor tertinggi ditemukan pada kelas *Magnesium Deficiency* dengan 4 dari 67 sampel aktual salah diprediksi ke kelas lain.



Gambar 4. 10 *Confusion Matrix Primer*

b. *Confusion Matrix* dataset sekunder


Berdasarkan Gambar 4.11, menunjukkan performa yang cukup baik dengan mengklasifikasikan secara tepat 310 dari total 375 sampel uji pada dataset seimbang (75 sampel per kelas), sehingga menghasilkan nilai akurasi global sebesar 82,67%. Model konsisten mencapai performa optimal mutlak pada kelas *Healthy* dengan akurasi 100% (75 sampel benar), disusul oleh kelas *Fungal Disease* yang menunjukkan akurasi tinggi sebesar 93,33% (70 dari 75 data). Kendati demikian, matriks ini memperlihatkan peningkatan misklasifikasi yang cukup signifikan pada variasi kelas non-sehat, tingkat kesalahan paling menonjol terjadi pada kelas *Scale Insect* di mana 10 sampel salah diprediksi sebagai *Magnesium Deficiency*, serta kelas *Dryness* yang sering terselisih sebagai *Scale Insect* (9 sampel) dan *Fungal Disease* (8 sampel).



Gambar 4. 11 *Confusion Matrix Sekunder*

c. *Confusion Matrix* skenario multi modal

Berdasarkan Gambar 4.12, menunjukkan peningkatan performa yang baik dengan keberhasilan memprediksi secara tepat 337 dari total 375 sampel uji pada dataset seimbang (75 sampel per kelas), yang menghasilkan nilai akurasi global (*overall accuracy*) sebesar 89,87%. Model mempertahankan reliabilitas mutlak pada kelas *Healthy* dengan tingkat akurasi mencapai 100% (75 sampel tepat), serta mencatatkan akurasi tinggi yang konsisten pada kelas *Dryness* dan *Fungal Disease* dengan masing-masing mengidentifikasi 69 dari 75 data secara valid (92,00%). Sebaliknya, performa terendah dan tingkat misklasifikasi relatif lebih tinggi terdeteksi pada kelas *Magnesium Deficiency* (61 dari 75 data) dan *Scale Insect* (63 dari 75 data), di mana terjadi dispersi kesalahan yang dominan ke arah kelas *Dryness* dan sesamanya.



Gambar 4. 12 *Confusion Matrix Multi Modal*

4.6.2 Metriks Evaluasi

Metrik evaluasi adalah alat ukur yang digunakan untuk mengetahui seberapa bagus dan akurat performa model *machine learning* setelah diuji. Dalam kasus klasifikasi citra, metrik ini dipakai buat melihat kemampuan model dalam mengenali pola visual secara tepat berdasarkan kecocokan antara hasil tebakan sistem dengan data aslinya (*ground truth*). Indikator seperti *precision*, *recall*, dan *f1-score* di sini berfungsi memberikan penilaian yang detail dan objektif, untuk mengetahui di mana letak kelebihan dan kekurangan model yang dibuat.

a. Metriks Evaluasi Dataset *Primer*

Metriks evaluasi dataset *Primer* ini merupakan metriks hasil dari pelatihan dataset *primer* yang hasilnya dapat dilihat pada Tabel 4.16.

Tabel 4. 15 Hasil Evaluasi Per Kelas (*Primer*)

No	Kelas	Precision	Recall	F1-Score	Support
1	<i>Healthy</i>	97.14%	100%	98.55%	75
2	<i>Dryness</i>	98.44%	96.92%	97.67%	75
3	<i>Fungal Disease</i>	95.59%	95.59%	95.59%	75
4	<i>Magnesium Deficiency</i>	94.03%	94.03%	94.03%	75
5	<i>Scale Insect</i>	98.18%	96.43%	97.30%	75
Rata-rata		96.61%	96.60%	96.60%	375

Berdasarkan Tabel 4.15, model yang dilatih menggunakan dataset *primer* menunjukkan performa yang sangat baik pada seluruh kelas. Nilai *precision*, *recall*, dan *F1-score* masing-masing kelas berada di atas 94%, dengan kelas *Healthy* memperoleh *recall* sebesar 100% dan *F1-score* sebesar 98,55%. Rata-rata *weighted precision*, *recall*, dan *F1-score* mencapai sekitar 96,6%, menunjukkan bahwa model mampu mengenali kondisi daun sawit dengan tingkat akurasi yang sangat tinggi ketika menggunakan data yang diperoleh langsung dari lapangan.

b. Metriks Evaluasi Dataset *Sekunder*

Metriks evaluasi pada dataset *Sekunder* dapat dilihat pada Tabel 4.17.

Tabel 4. 16 Hasil Evaluasi Metrik Per Kelas (*Sekunder*)

No	Kelas	Precision	Recall	F1-Score	Support
1	Healthy	100%	100%	100%	75
2	Dryness	78.79%	69.33%	73.76%	75
3	Fungal Disease	76.92%	93.33%	84.34%	75
4	Magnesium Deficiency	75.95%	80.00%	77.92%	75
5	Scale Insect	82.81%	70.67%	76.26%	75
Rata-rata		82.89%	82.66%	82.45%	375

Berdasarkan Tabel 4.16, performa model pada dataset *sekunder* mengalami penurunan dibandingkan dataset *primer*. Kelas *Healthy* masih berhasil dikenali secara sempurna dengan nilai *precision*, *recall*, dan *F1-score* sebesar 100%. Namun, kelas lainnya menunjukkan nilai yang lebih rendah, terutama pada kelas *Dryness* dan *Scale Insect*. Secara keseluruhan, rata-rata *weighted precision*, *recall*, dan *F1-score* berada pada kisaran 82%, yang mengindikasikan bahwa variasi data dari sumber *sekunder* memberikan tantangan yang lebih besar bagi model dalam melakukan klasifikasi.

c. Metriks evaluasi dataset *Multi Modal*

Hasil metriks evaluasi per kelas pada dataset *Multi Modal* (*Sekunder* dan *Primer*) dapat dilihat pada Tabel 4.18.

Tabel 4. 17 Hasil Evaluasi Metrik Per Kelas (*Multi Modal*)

No	Kelas	Precision	Recall	F1-Score	Support
1	Healthy	98.68%	100%	99.34%	75
2	Dryness	85.19%	92.00%	88.46%	75
3	Fungal Disease	93.24%	92.00%	92.62%	75
4	Magnesium Deficiency	88.41%	81.33%	84.72%	75
5	Scale Insect	84.00%	84.00%	84.00%	75
Rata-rata		95.99%	89.86%	89.82%	375

Berdasarkan Tabel 4.17, penggunaan dataset *multi modal* yang menggabungkan data *primer* dan *sekunder* mampu meningkatkan performa model dibandingkan penggunaan dataset *sekunder* saja. Kelas *Healthy* kembali memperoleh hasil yang sangat tinggi dengan *F1-score* sebesar 99,34%, sementara sebagian besar kelas lainnya juga

menunjukkan peningkatan nilai *precision*, *recall*, dan *F1-score*. Secara keseluruhan, model memperoleh *weighted precision* sebesar 95,99%, *recall* sebesar 89,86%, dan *F1-score* sebesar 89,82%. Hasil ini menunjukkan bahwa penggabungan kedua sumber data mampu meningkatkan kemampuan generalisasi model dalam mengenali berbagai kondisi daun kelapa sawit.

4.6.3 Hasil Pengujian *BlackBox*

Pengujian *blackbox* dilakukan untuk memverifikasi bahwa seluruh fungsionalitas sistem berjalan sesuai dengan spesifikasi yang telah dirancang. Pengujian berfokus pada keluaran sistem berdasarkan input yang diberikan tanpa memperhatikan detail implementasi internal. Metode pengujian yang digunakan adalah *equivalence partitioning* dan *boundary value analysis*.

1. Hasil Pengujian *Blackbox* AutentikasiTabel 4. 18 Pengujian *Blackbox* Autentikasi

No	Test Case	Pre-condition	Test Steps	Test Data	Expected Result	Post-condition	Actual Result	Status
1	Registrasi akun baru dengan email valid	Halaman registrasi terbuka	Isi nama, email, dan password kemudian klik tombol Daftar	Nama, email, password ≥ 8 karakter	Akun berhasil dibuat, notifikasi sukses ditampilkan, konfirmasi email	Data akun tersimpan pada sistem	Sesuai	PASS
2	Registrasi dengan email tidak valid	Halaman registrasi terbuka	Isi form registrasi menggunakan email tanpa format yang valid kemudian klik Daftar	Email tanpa karakter "@"	Notifikasi error "Email tidak valid" ditampilkan	Akun tidak dibuat	Sesuai	PASS
3	Registrasi dengan password kurang dari 8 karakter	Halaman registrasi terbuka	Isi form registrasi dengan password kurang dari 8 karakter kemudian klik Daftar	Password 5 karakter	Notifikasi error "Password minimal 8 karakter" ditampilkan	Akun tidak dibuat	Sesuai	PASS

4	Login dengan kredensial yang benar	Akun telah terdaftar pada sistem	Masukkan email dan password yang valid kemudian klik Login	Email dan password terdaftar	Notifikasi sukses ditampilkan dan pengguna diarahkan ke halaman riwayat	Sesi pengguna aktif	Sesuai	PASS
5	Login dengan kredensial yang salah	Halaman login terbuka	Masukkan email atau password yang salah kemudian klik Login	Email atau password salah	Notifikasi error ditampilkan dan pengguna tetap berada di halaman login	Sesi pengguna tidak dibuat	Sesuai	PASS
6	Login menggunakan Google OAuth	Halaman login terbuka	Klik tombol "Lanjutkan dengan Google"	Akun Google	Pengguna diarahkan ke halaman autentikasi Google dan kembali ke halaman riwayat setelah berhasil login	Sesi pengguna aktif	Sistem gagal terhubung ke layanan autentikasi Google	FAIL
7	Lupa password	Halaman login terbuka	Klik "Lupa password?", masukkan email terdaftar, lalu kirim	Email valid	Notifikasi "Link reset password sudah dikirim" ditampilkan	Email reset password terkirim	Sesuai	PASS

			permintaan reset					
8	Logout akun	Pengguna dalam kondisi login	Klik tombol Logout	Klik tombol Logout	Sesi pengguna berakhir dan tampilan berubah ke status belum login	Pengguna keluar dari sistem	Sesuai	PASS

2. Hasil Pengujian *Blackbox* Halaman Utama

Tabel 4. 19 Pengujian *Blackbox* Halaman Utama

No	Test Case	Pre-condition	Test Steps	Test Data	Expected Result	Post-condition	Actual Result	Status
1	Akses halaman beranda	Aplikasi berjalan	Buka URL "https://nyak-wit.vercel.app/"	URL "https://nyak-wit.vercel.app/"	Menampilkan hero section, daftar penyakit, dan informasi sistem	Halaman utama tampil	Sesuai	PASS
2	Navigasi ke halaman klasifikasi	Halaman utama terbuka	Klik tombol "Analisa Daun Sekarang"	Klik tombol	Berpindah ke halaman klasifikasi	Halaman klasifikasi tampil	Sesuai	PASS
3	Navigasi ke ensiklopedia	Halaman utama terbuka	Klik tombol "Lihat Ensiklopedia"	Klik tombol	Berpindah ke halaman ensiklopedia	Halaman ensiklopedia tampil	Sesuai	PASS

4	Responsivitas mobile	Website dapat diakses	Ubah viewport menjadi mobile	375×667 px	Layout menyesuaikan layar	Tampilan responsif	Sesuai	PASS
---	----------------------	-----------------------	------------------------------	------------	---------------------------	--------------------	--------	------

3. Hasil Pengujian *Blackbox* Halaman Klasifikasi

Tabel 4. 20 Pengujian *Blackbox* Halaman Klasifikasi

No	Test Case	Pre-condition	Test Steps	Test Data	Expected Result	Post-condition	Actual Result	Status
1	Upload gambar JPG valid	Halaman klasifikasi terbuka	Unggah file gambar JPG	magnesiumjpg, 12 KB	Preview tampil dan tombol Analisa aktif	Gambar siap dianalisi	Sesuai	PASS
2	Upload gambar PNG valid	Halaman klasifikasi terbuka	Unggah file gambar PNG	bercakpng, 1 MB	Preview tampil dan tombol Analisa aktif	Gambar siap dianalisis	Sesuai	PASS
3	Upload file bukan gambar	Halaman klasifikasi terbuka	Unggah file selain gambar	PKM.pdf	Muncul toast error: "File harus berupa gambar (JPG/PNG)"	File tidak diproses	Sesuai	PASS
4	Upload gambar melebihi batas ukuran	Halaman klasifikasi terbuka	Unggah file gambar berukuran lebih dari 10 MB	Bercak20.jpg, 20 MB	Muncul toast error: "Ukuran maksimal 10 MB"	File tidak diproses	Sesuai	PASS

5	Upload gambar dengan metode drag and drop	Halaman klasifikasi terbuka	Seret dan lepaskan file gambar ke zona upload	daunsehat.jpg	Gambar diproses sama seperti upload biasa	Preview gambar ditampilkan	Sesuai	PASS
6	Prediksi daun sehat	Gambar berhasil diunggah	Klik tombol Analisa pada gambar daun sehat	Daunsehat.jpg	Sistem menampilkan hasil Healthy, confidence, distribusi probabilitas, dan rekomendasi	Hasil analisis ditampilkan	Sesuai	PASS
7	Prediksi daun berpenyakit	Gambar berhasil diunggah	Klik tombol Analisa pada gambar daun Scale Insect	Bercakpng.png	Sistem menampilkan hasil Penyakit Jamur 84%, tingkat keparahan (Berat), dan rekomendasi Semprotkan fungisida	Hasil analisis ditampilkan	Sesuai	PASS
8	Backend tidak aktif	Backend dalam kondisi tidak berjalan	Lakukan prediksi gambar	Gambar daun valid	Muncul pesan error gagal terhubung ke server	Tidak ada hasil prediksi	Sesuai	PASS

9	Reset hasil scan	Hasil prediksi sudah ditampilkan	Klik tombol Scan Lagi	Klik tombol Scan Lagi	Preview dan hasil prediksi dihapus, kembali ke zona upload	Form scan kembali ke kondisi awal	Sesuai	PASS
10	Upload Citra dari kamera laptop	Halaman klasifikasi dibuka	Klik tombol ambil foto	Kamera Laptop	Kamera terbuka dan mengambil gambar langsung	Kamera terbuka	Tidak Sesuai	FAIL
11	Upload Citra dari kamera HP	Halaman klasifikasi dibuka	Klik tombol ambil foto	Kamera HP	Kamera terbuka dan mengambil gambar langsung	Kamera terbuka	Sesuai	PASS

4. Hasil Pengujian *Blackbox* Halaman Ensiklopedia

Tabel 4. 21 Pengujian *Blackbox* Ensiklopedia

No	Test Case	Pre-condition	Test Steps	Test Data	Expected Result	Post-condition	Actual Result	Status
1	Akses halaman ensiklopedia	Aplikasi berjalan dan halaman dapat diakses	Klik menu "Ensiklopedia" pada navigasi	Menu Ensiklopedia	Lima kondisi daun ditampilkan lengkap dengan gambar dan deskripsi	Informasi penyakit daun dapat diakses pengguna	Sesuai	PASS
2	Navigasi cepat ke kelas penyakit tertentu	Halaman ensiklopedia terbuka	Klik salah satu chip kelas penyakit, misalnya "Jamur"	Chip kelas "Jamur"	Halaman melakukan scroll otomatis ke bagian detail kelas yang dipilih	Detail kelas penyakit yang dipilih ditampilkan	Sesuai	PASS

5. Hasil Pengujian Blackbox Halaman Riwayat, Profil, dan Dashboard

Tabel 4. 22 Pengujian *Blackbox* Halaman Riwayat, Profil, dan Dashboard

No	Test Case	Pre-condition	Test Steps	Test Data	Expected Result	Post-condition	Actual Result	Status
1	Akses halaman riwayat tanpa login	Tidak terdapat sesi pengguna aktif	Akses langsung halaman /history melalui browser	URL /history	Menampilkan pesan "Login diperlukan" dan tombol menuju halaman login	Pengguna tidak dapat mengakses data riwayat	Sesuai	PASS
2	Akses halaman riwayat dengan login	Pengguna telah login dan memiliki data riwayat scan	Buka halaman /history	Akun pengguna dengan data riwayat scan	Tabel atau daftar riwayat scan milik pengguna ditampilkan	Data riwayat dapat dilihat pengguna	Sesuai	PASS
3	Akses halaman profil	Pengguna telah login	Buka halaman profil	Akun pengguna aktif	Nama, email, total scan, dan riwayat terbaru ditampilkan	Informasi profil pengguna dapat dilihat	Sesuai	PASS
4	Akses dashboard admin oleh user biasa	Pengguna login dengan role "user"	Akses halaman /dashboard	Akun dengan role user	Sistem mengarahkan pengguna ke halaman /history	Dashboard admin tidak dapat diakses	Sesuai	PASS
5	Akses dashboard oleh admin	Pengguna login dengan role "admin"	Akses halaman /dashboard	Akun dengan role admin	Statistik seluruh pengguna dan riwayat klasifikasi ditampilkan	Dashboard admin dapat diakses	Sesuai	PASS

4.7 Hasil Pengujian *WhiteBox*

Pengujian *whitebox* dilakukan dengan menganalisis alur logika dan struktur kode pada proses inti sistem, yaitu praproses citra, arsitektur model *ResNet-50*, dan proses inferensi (*endpoint/predict*). Setiap proses digambarkan dalam bentuk *flowgraph* untuk menentukan jalur (*path*) pengujian, kemudian dibuat skenario *test case* untuk memverifikasi bahwa setiap jalur berjalan sesuai dengan yang diharapkan.

- a. Tabel *Code* Beserta Alurnya: Menyediakan rincian kode program dan penjelasan alur kerja dari setiap bagian yang diuji.
- b. Tabel *Test Case Scenario*: Menyediakan skenario pengujian untuk setiap bagian kode guna memastikan bahwa proses berjalan sesuai dengan yang diharapkan.
- c. Pengujian *Whitebox Preprocessing*
- d. Pengujian *Whitebox Split Data*
- e. Pengujian *Whitebox Augmentasi*
- f. Pengujian *Whitebox Model ResNet-50*

Berikut hasil *whitebox* diantaranya:

1. Pengujian *Whitebox Preprocessing*

Preprocessing merupakan tahapan awal yang dilakukan untuk menyiapkan citra daun kelapa sawit sebelum digunakan pada proses pelatihan model *ResNet-50*. Tahapan ini bertujuan untuk menyeragamkan ukuran citra, melakukan normalisasi nilai piksel, serta meningkatkan variasi data melalui augmentasi. Pengujian *white box* dilakukan untuk memastikan seluruh proses *preprocessing* berjalan sesuai dengan kebutuhan input model. Rincian kode pengujian *white box preprocessing* dapat dilihat pada Tabel 4.23.

Tabel 4. 23 *Whitebox Preprocessing*

Potongan Kode	Alur
Start	1
<pre> INPUT_DIR = "0.valid_primer" OUTPUT_DIR = "1.pre_primer" TARGET_SIZE = (224,224) CLASSES = ["Healthy", "Dryness", "Fungal_Disease", "Magnesium_Deficiency", "Scale_Insect"] </pre>	2
<pre> def convert_to_rgb(path): img = Image.open(path) return img.convert("RGB") </pre>	3
<pre> def resize_224(img): return img.resize(TARGET_SIZE, Image.BILINEAR) </pre>	4
<pre> for cls in CLASSES: folder = Path(INPUT_DIR) / cls </pre>	5
<pre> files = [f for f in folder.iterdir() if f.suffix.lower() in VALID_EXT] </pre>	6
<pre> img = Image.open(f).convert("RGB") </pre>	7
<pre> img = img.resize(TARGET_SIZE, Image.BILINEAR) </pre>	8
<pre> img.save(str(save_folder / f"{f.stem}.jpg"), "JPEG", quality=95) </pre>	9
End	10

Selanjutnya Pengujian *Whitebox Test Case Scenario Preprocessing* dapat dilihat pada tabel 4.24.

Tabel 4. 24 *Test Case Scenario Preprocessing*

Path	Alur	Test Case Scenario	Hasil Pengujian
1	1-2-3-4-5-6-7-8-9-10	1. Start. 2. Sistem menentukan direktori dataset, ukuran citra 224×224 piksel, dan kelas penyakit daun kelapa sawit. 3. Sistem menjalankan fungsi <code>convert_to_rgb()</code> untuk memastikan seluruh citra berada pada format RGB. 4. Sistem menjalankan fungsi <code>resize_224()</code> untuk menyeragamkan ukuran citra menjadi 224×224 piksel. 5. Sistem membaca folder masing-masing kelas penyakit.	Benar (✓) Salah ()

		6. Sistem memvalidasi file yang memiliki ekstensi gambar yang didukung. 7. Sistem membuka dan mengonversi citra ke format RGB. 8. Sistem melakukan resize citra menggunakan metode interpolasi bilinear. 9. Sistem menyimpan citra hasil preprocessing ke folder output dalam format JPEG dengan kualitas 95%. 10. End.	
--	--	---	--

Berdasarkan hasil pengujian *whitebox* Tabel 4.23, seluruh tahapan *preprocessing* berhasil dijalankan sesuai dengan alur yang dirancang. Sistem mampu membaca citra dari setiap kelas, melakukan konversi warna ke format RGB, menyeragamkan ukuran citra menjadi 224×224 piksel sesuai kebutuhan input *ResNet-50*, serta menyimpan hasil *preprocessing* dalam format JPEG tanpa mengalami kesalahan proses. Dengan demikian, data yang dihasilkan telah memenuhi kebutuhan untuk tahapan pembagian dataset dan pelatihan model.

2. Pengujian *Whitebox Split Data*

Tabel 4. 25 *Whitebox Split Data*

Potongan Kode	Alur
Start	1
<pre>SEED = 42 DATA_ASLI_DIR = '1.pre_primer' OUTPUT_SPLIT_DIR = '2.split_primer' CLASSES = ['Healthy', 'Dryness', 'Fungal_Disease', 'Magnesium_Deficiency', 'Scale_Insect']</pre>	2
<pre>def split_dataset_asli(src_dir, dest_dir, val_ratio=0.15, test_ratio=0.15):</pre>	3
<pre>for subset in ['train', 'val', 'test']: for cls in CLASSES: os.makedirs(os.path.join(dest_dir, subset, cls), exist_ok=True)</pre>	4
<pre>list_file = sorted([f for f in os.listdir(folder_kelas) if f.lower().endswith(ekstensi_didukung)])</pre>	5
<pre>train_files, sisa_files = train_test_split(</pre>	6

<code>list_file, test_size=(val_ratio + test_ratio), random_state=SEED, huffle=True)</code>	
<code>val_files, test_files = train_test_split(sisa_files, test_size=(test_ratio / (val_ratio + test_ratio)), random_state=SEED, shuffle=True)</code>	7
<code>for subset, files in [('train', train_files), ('val', val_files), ('test', test_files)]: for f in files:\n shutil.copy2(...)</code>	8
<code>df = pd.DataFrame(report) print(df.to_string(index=False))</code>	9
End	10

Selanjutnya Pengujian *Whitebox Test Case Scenario Split Data* dapat dilihat pada tabel 4.26.

Tabel 4. 26 *Test Case Scenario Split Data*

Path	Alur	Test Case Scenario	Hasil Pengujian
1	1-2-3-4-5-6-7-8-9-10	1. Start. 2. Sistem menentukan direktori dataset hasil preprocessing, direktori output split dataset, nilai random seed, serta daftar kelas penyakit daun kelapa sawit. 3. Sistem menjalankan fungsi <code>split_dataset_asli()</code> untuk membagi dataset menjadi data training, validation, dan testing. 4. Sistem membuat struktur folder train, val, dan test untuk setiap kelas penyakit. 5. Sistem membaca seluruh file citra yang tersedia pada masing-masing kelas. 6. Sistem melakukan pembagian pertama menggunakan <code>train_test_split()</code> untuk memisahkan data training sebesar 70% dan sisa data sebesar 30%. 7. Sistem melakukan pembagian kedua untuk memisahkan data validation sebesar 15% dan data testing sebesar 15%.	Benar (✓) Salah ()

		8. Sistem menyalin file citra ke direktori train, validation, dan testing sesuai hasil pembagian. 9. Sistem membuat laporan distribusi jumlah data pada setiap subset dan kelas penyakit. 10. End.	
--	--	--	--

Berdasarkan hasil pengujian *whitebox* pada Tabel 4.25, seluruh tahapan pembagian data berhasil dijalankan sesuai dengan rancangan sistem. Dataset hasil preprocessing dapat dibagi secara otomatis menjadi data *training* sebesar 70%, data *validation* sebesar 15%, dan data testing sebesar 15% menggunakan fungsi `train_test_split()` dengan nilai random seed yang tetap. Proses ini memastikan distribusi data pada setiap kelas dilakukan secara acak namun konsisten sehingga dapat mendukung proses pelatihan dan evaluasi model *ResNet-50* secara optimal.

3. Pengujian *Whitebox* Augmentasi

Tabel 4. 27 *Whitebox* Augmentasi

Potongan Kode	Alur
Start	1
<pre>INPUT_DIR = 'd_split_b/train' OUTPUT_DIR = 'd_aug_cb' AUGMENT_MULTIPLIER = 3 IMG_SIZE = (224,224)</pre>	2
<pre>def augment_rotation(image, max_angle=20):</pre>	3
<pre>def augment_translation(image, max_shift=0.10):</pre>	4
<pre>def augment_flipping(image, prob=0.5):</pre>	5
<pre>def augment_zoom(image, zoom_range=(0.80,1.20)):</pre>	6
<pre>def augment_brightness(image, adj=0.20):</pre>	7
<pre>def augment_contrast(image, adj=0.30):</pre>	8
<pre>AUG_FUNCTIONS = [augment_rotation, augment_translation, augment_flipping, augment_zoom, augment_brightness,</pre>	9

augment_contrast]	
def apply_all_augmentations(image): result = image.copy() for fn in AUG_FUNCTIONS: result = fn(result) return result	10
for aug_idx in range(AUGMENT_MULTIPLIER): aug_img = apply_all_augmentations(image) cv2.imwrite(...)	11
End	12

Selanjutnya Pengujian *Whitebox Test Case Scenario* Augmentasi dapat dilihat pada tabel 4.28.

Tabel 4. 28 *Test Case Scenario Augmentasi*

Path	Alur	Test Case Scenario	Hasil Pengujian
1	1-2-3-4-5-6-7-8-9-10-11-12	1. Start. 2. Sistem menentukan direktori input, output, ukuran citra, dan jumlah augmentasi yang akan dibuat. 3. Sistem menerapkan augmentasi rotasi secara acak hingga $\pm 20^\circ$. 4. Sistem menerapkan translasi horizontal dan vertikal hingga $\pm 10\%$ dari ukuran citra. 5. Sistem menerapkan horizontal flip dengan probabilitas tertentu. 6. Sistem menerapkan zoom dengan rentang 80%–120%. 7. Sistem melakukan penyesuaian brightness sebesar $\pm 20\%$. 8. Sistem melakukan penyesuaian contrast sebesar $\pm 30\%$. 9. Sistem menggabungkan seluruh teknik augmentasi ke dalam daftar fungsi augmentasi. 10. Sistem menjalankan seluruh fungsi augmentasi secara berurutan pada citra masukan.	Benar (✓) Salah ()

		11. Sistem menghasilkan dan menyimpan citra hasil augmentasi sebanyak tiga kali untuk setiap citra asli. 12. End.	
--	--	--	--

Berdasarkan hasil pengujian *whitebox* pada Tabel 4.27, seluruh teknik augmentasi yang dirancang berhasil dijalankan sesuai alur sistem. Teknik yang digunakan meliputi rotasi, translasi, horizontal flip, zoom, penyesuaian brightness, dan penyesuaian contrast. Setiap citra pelatihan menghasilkan tiga citra augmentasi tambahan melalui kombinasi seluruh teknik tersebut. Hasil pengujian menunjukkan bahwa proses augmentasi mampu meningkatkan variasi dataset pelatihan tanpa mengubah label kelas, sehingga membantu model *ResNet-50* dalam mempelajari karakteristik penyakit daun kelapa sawit secara lebih robust dan meningkatkan kemampuan generalisasi model pada data yang belum pernah dilihat sebelumnya.

4. Pengujian *Whitebox ResNet-50*

Tabel 4. 29 *Whitebox ResNet-50*

Potongan Kode	Alur
Start	1
<pre>train_transform = transforms.Compose([transforms.Resize((224,224)), transforms.ToTensor(), transforms.Normalize(mean= IMAGENET_MEAN,std=IMAGENET_STD)])</pre>	2
<pre>train_dataset = datasets.ImageFolder(...) train_loader = DataLoader(...)</pre>	3
<pre>model = models.resnet50(weights=ResNet50_Weights.IMAGENET1K_V1)</pre>	4
<pre>for param in model.parameters(): param.requires_grad = False</pre>	5
<pre>model.fc = nn.Sequential(nn.Linear(in_features,256), nn.ReLU(), nn.Dropout(0.5),</pre>	6

<code>nn.Linear(256,num_classes)</code> <code>)</code>	
<code>criterion = nn.CrossEntropyLoss(...)</code> <code>optimizer_p1 = optim.Adam(...)</code>	7
<code>for epoch in range(EPOCHS_P1):</code> <code> train_one_epoch(...)</code> <code> validate(...)</code>	8
<code>layers_to_unfreeze = ['layer4','layer3']</code>	9
<code>optimizer_p2 = optim.Adam(...)</code>	10
<code>for epoch in range(EPOCHS_P2):</code> <code> train_one_epoch(...)</code> <code> validate(...)</code>	11
<code>accuracy_score(...)</code> <code>precision_score(...)</code> <code>recall_score(...)</code> <code>f1_score(...)</code>	12
<code>End</code>	13

Selanjutnya Pengujian *Whitebox Test Case Scenario* Augmentasi dapat dilihat pada tabel 4.30.

Tabel 4. 30 *Test Case Scenario ResNet-50*

Path	Alur	Test Case Scenario	Hasil Pengujian
1	1-2-3-4-5-6-7-8-9-10-11-12-13	1. Start. 2. Sistem melakukan transformasi citra berupa resize 224×224 piksel dan normalisasi menggunakan statistik ImageNet. 3. Sistem memuat dataset training, validation, dan testing menggunakan DataLoader. 4. Sistem memuat model ResNet-50 pretrained dari ImageNet. 5. Sistem membekukan seluruh convolutional layer pada ResNet-50 untuk proses transfer learning tahap pertama. 6. Sistem mengganti fully connected layer dengan classifier baru yang terdiri dari Dense Layer, ReLU, Dropout, dan Output Layer sebanyak 5 kelas.	Benar (✓) Salah ()

		7. Sistem menginisialisasi fungsi loss CrossEntropyLoss dan optimizer Adam. 8. Sistem melakukan pelatihan classifier head pada Phase 1 menggunakan data training dan validation. 9. Sistem membuka kembali layer3 dan layer4 ResNet-50 untuk proses fine tuning. 10. Sistem menginisialisasi optimizer fine tuning dengan learning rate yang lebih kecil. 11. Sistem melakukan pelatihan ulang pada Phase 2 untuk menyesuaikan bobot model terhadap dataset daun kelapa sawit. 12. Sistem melakukan evaluasi menggunakan metrik Accuracy, Precision, Recall, dan F1-Score. 13. End.	
--	--	---	--

Berdasarkan hasil pengujian *whitebox* pada Tabel 4.29, seluruh tahapan pelatihan model *ResNet-50* berhasil dijalankan sesuai dengan rancangan sistem. Proses dimulai dengan pemuatan model pretrained *ResNet-50* yang telah dilatih pada dataset *ImageNet*, kemudian dilakukan *transfer learning* dengan membekukan seluruh *convolutional layer* dan mengganti *classifier* akhir agar sesuai dengan lima kelas penyakit daun kelapa sawit. Selanjutnya dilakukan pelatihan *classifier head* pada *phase* pertama, kemudian dilanjutkan dengan proses *fine tuning* pada layer3 dan layer4 menggunakan *learning rate* yang lebih kecil. Hasil pengujian menunjukkan bahwa proses *training*, *fine tuning*, serta evaluasi model menggunakan metrik *Accuracy*, *Precision*, *Recall*, dan *F1-Score* dapat berjalan tanpa kesalahan sehingga model siap digunakan pada sistem klasifikasi penyakit daun kelapa sawit berbasis web.

5. Pengujian *White Box* Proses Login

Pengujian *white box* pada fungsi `handleSubmit()` di halaman `Auth.tsx` untuk mode login bertujuan untuk memastikan alur validasi kredensial dan penanganan respons dari Supabase Auth berjalan sesuai rancangan. Tabel 4.31 menunjukkan alur kode fungsi tersebut pada mode login.

Tabel 4. 31 *White Box* Proses Login

Potongan Kode	Alur
Start	1
<code>const parsed = authSchema.safeParse({ email, password });</code>	2
<code>if (!parsed.success) { toast.error(parsed.error.issues[0]?.message ?? "Data tidak valid."); return; }</code>	3
<code>setLoading(true);</code>	4
<code>const { error } = await supabase.auth.signInWithPassword({ email: parsed.data.email, password: parsed.data.password, });</code>	5
<code>if (error) { toast.error(error.message); } else { toast.success("Login berhasil."); navigate("/history"); }</code>	6
<code>setLoading(false);</code>	7
End	8

Selanjutnya Pengujian *White Box* Proses Login dapat dilihat pada tabel 4.32.

Tabel 4. 32 *White Box* Proses Login

Path	Alur	Test case scenario	Hasil Pengujian
1	1-2-3-4-5-6-7-8	1. Start 2. Sistem memvalidasi input email dan password menggunakan <code>authSchema.safeParse()</code> dengan email "user@nyakwit.com" dan password "sawit2026" (≥ 8 karakter). 3. Hasil parsing bernilai <code>success = true</code> , sehingga kondisi <code>if (!parsed.success)</code> bernilai salah dan tidak menampilkan toast error.	Benar (✓) Salah ()

		4. Sistem mengatur state loading menjadi true (tombol submit menampilkan ikon loading). 5. Sistem memanggil <code>supabase.auth.signInWithPassword()</code> dengan kredensial yang telah divalidasi; kredensial benar sehingga tidak mengembalikan error. 6. Karena variabel error bernilai null/undefined (falsy), blok else dijalankan: menampilkan <code>toast.success("Login berhasil.")</code> dan memanggil <code>navigate("/history")</code>. 7. Sistem mengatur kembali state loading menjadi false. 8. End	
2	1-2-3-8	1. Start 2. Sistem memvalidasi input dengan email kosong ("") dan password "123" (kurang dari 8 karakter). 3. Hasil parsing bernilai <code>success = false</code> (gagal validasi format email dan panjang password), sehingga kondisi <code>if (!parsed.success)</code> bernilai benar. Sistem menampilkan <code>toast.error()</code> dengan pesan dari <code>parsed.error.issues[0].message</code> (misalnya "Email tidak valid") dan fungsi melakukan return. 8. End (state loading tidak diubah, <code>signInWithPassword</code> tidak dipanggil)	Benar (✓) Salah ()
3	1-2-3-4-5-6-7-8	1. Start 2. Sistem memvalidasi input email "user@nyakwit.com" dan password "passwordsalah" (format valid, ≥ 8 karakter). 3. Hasil parsing bernilai <code>success = true</code>, validasi lolos. 4. State loading diatur menjadi true. 5. Sistem memanggil <code>signInWithPassword()</code> dengan kombinasi email/password yang tidak sesuai data terdaftar di Supabase Auth, sehingga mengembalikan objek error berisi pesan kegagalan autentikasi. 6. Karena variabel error bernilai truthy, blok <code>if (error)</code> dijalankan: sistem menampilkan	Benar (✓) Salah ()

		toast.error(error.message) dan tidak memanggil navigate(). 7. State loading diatur kembali menjadi false. 8. End	
--	--	--	--

Berdasarkan Tabel 4.32, fungsi `handleSubmit()` pada mode login memiliki dua struktur percabangan utama, yaitu hasil validasi skema Zod (`authSchema.safeParse`) dan hasil pemanggilan `signInWithPassword()` (ada atau tidaknya error), yang menghasilkan tiga jalur (path) pengujian. Hasil pengujian menunjukkan bahwa ketiga path berjalan dengan benar: input valid dan kredensial benar mengarahkan pengguna ke halaman Riwayat dengan notifikasi sukses (path 1), input tidak valid dihentikan pada tahap validasi skema tanpa memanggil Supabase (path 2), dan input valid namun kredensial salah menampilkan pesan error dari Supabase tanpa melakukan navigasi (path 3). Pada ketiga path, state loading selalu kembali bernilai false setelah proses selesai, sehingga tombol submit tidak terjebak pada kondisi loading permanen.

6. Pengujian *White Box Endpoint Inferensi /predict*

Pengujian *white box* pada endpoint `/predict` bertujuan untuk memastikan seluruh jalur logika pada fungsi `predict()` di `main.py`, mulai dari validasi tipe berkas, pengecekan ketersediaan model, pembacaan dan *preprocessing* gambar, hingga proses inferensi dan penyusunan respons, telah diuji. Tabel 4.9 menunjukkan alur kode endpoint `/predict`.

Tabel 4. 33 *White Box Endpoint Inferensi /predict*

Potongan Kode	Alur
Start	1
if not file.content_type.startswith("image/"): raise HTTPException(400, "File harus berupa gambar (JPG/PNG).")	2
if MODEL is None: raise HTTPException(503, "Model belum dimuat...")	3
contents = await file.read() image = Image.open(io.BytesIO(contents)).convert("RGB") tensor = preprocess(image).unsqueeze(0).to(DEVICE)	4
except Exception as e: raise HTTPException(400, f"Gagal membaca gambar: {e}")	5
with torch.no_grad(): outputs = MODEL(tensor) probs = torch.softmax(outputs, dim=1).squeeze().cpu().numpy()	6
for idx, prob in enumerate(probs): class_name = IDX_TO_CLASS.get(idx, f"class_{idx}") prob_dict[class_name] = float(prob)	7
predicted_key = max(prob_dict, key=prob_dict.get) confidence = prob_dict[predicted_key] meta = CLASS_METADATA.get(predicted_key, {})	8
return PredictionResponse(success=True, predicted=predicted_key, ...)	9
End	10

Selanjutnya Pengujian *White Box Endpoint Inferensi /predict* dapat dilihat pada Tabel 4.34.

Tabel 4. 34 *White Box Endpoint Inferensi /predict*

Path	Alur	Test case scenario	Hasil Pengujian
1	1-2-3-4-5-6- 7-8-9-10	1. Start 2. Sistem memeriksa content_type berkas; jika berupa gambar (image/*), pengujian berlanjut ke langkah berikutnya. 3. Sistem memeriksa apakah variabel MODEL telah berhasil dimuat saat startup; jika MODEL tidak None, proses berlanjut. 4. Sistem membaca byte berkas, mengonversi gambar ke mode RGB, dan menerapkan transformasi preprocessing (resize 224x224, ToTensor, normalisasi ImageNet) sehingga menghasilkan tensor berukuran (1,3,224,224).	Benar (✓) Salah ()

		5. Karena tidak terjadi exception pada langkah 4, blok except dilewati. 6. Tensor dimasukkan ke MODEL dalam mode torch.no_grad(), menghasilkan logits yang kemudian diproses dengan softmax menjadi distribusi probabilitas. 7. Sistem melakukan iterasi terhadap array probabilitas dan memetakan setiap indeks ke nama kelas melalui IDX_TO_CLASS, menghasilkan prob_dict. 8. Sistem menentukan predicted_key (kelas dengan probabilitas tertinggi), confidence, dan metadata kelas (meta) dari CLASS_METADATA. 9. Sistem mengembalikan objek PredictionResponse berisi predicted, predicted_name, confidence, severity, description, treatment, prevention, probabilities, dan device_used. 10. End	
2	1-2-10	1. Start 2. Sistem memeriksa content_type berkas; berkas yang diunggah bukan bertipe image/* (misalnya application/pdf), sehingga sistem langsung melempar HTTPException(400, "File harus berupa gambar (JPG/PNG).") 10. End (response dikembalikan sebagai error 400 sebelum mencapai blok kode lainnya)	Benar (✓) Salah ()
3	1-2-3-10	1. Start 2. content_type berkas valid (image/*), proses berlanjut. 3. Variabel MODEL bernilai None (checkpoint model tidak ditemukan saat startup), sehingga sistem melempar HTTPException(503, "Model belum dimuat. Pastikan file ada di: {MODEL_PATH}") 10. End (response dikembalikan sebagai error 503 sebelum proses inferensi)	Benar (✓) Salah ()
4	1-2-3-4-5-10	1. Start 2. content_type berkas valid (image/*). 3. MODEL telah dimuat (tidak None).	Benar (✓) Salah ()

		4. Sistem mencoba membaca dan memproses gambar, namun berkas yang diunggah rusak/bukan gambar valid sehingga Image.open() melempar exception (misal UnidentifiedImageError). 5. Blok except menangkap exception tersebut dan sistem melempar HTTPException(400, f'Gagal membaca gambar: {str(e)}') 10. End (response dikembalikan sebagai error 400)	
--	--	---	--

Berdasarkan Tabel 4.33, terdapat empat jalur (path) independen pada endpoint /predict yang dihasilkan dari tiga struktur percabangan, yaitu validasi content_type pada langkah 2, pengecekan ketersediaan MODEL pada langkah 3, serta blok try-except pada proses pembacaan gambar di langkah 4-5. Keempat path tersebut mencakup jalur normal (path 1, prediksi berhasil) serta tiga jalur penanganan kesalahan (path 2: berkas bukan gambar, path 3: model belum dimuat, dan path 4: gambar tidak dapat dibaca). Hasil pengujian menunjukkan bahwa keempat path berjalan dengan benar — setiap kondisi error mengembalikan kode status HTTP dan pesan yang sesuai (400 atau 503), sedangkan jalur normal mengembalikan objek PredictionResponse yang lengkap dengan seluruh field yang didefinisikan pada skema.

7. White Box Validasi Unggah Gambar

Pengujian white box pada fungsi handleFile() di halaman Scan.tsx bertujuan untuk memastikan seluruh kondisi validasi berkas yang diunggah pengguna (tipe berkas dan ukuran berkas) berjalan sesuai dengan rancangan sebelum berkas diterima oleh sistem. Tabel 4.35 menunjukkan alur kode fungsi handleFile().

4. 35 *White Box* Validasi Unggah Gambar

Potongan Kode	Alur
Start	1
const handleFile = (f: File null) => { if (!f) return;	2
if (!f.type.startsWith("image/")) { toast.error("File harus berupa gambar (JPG/PNG)"); return; }	3
if (f.size > 10 * 1024 * 1024) { toast.error("Ukuran maksimal 10 MB"); return; }	4
setFile(f); setPreview(URL.createObjectURL(f)); setResult(null); setApiError(null);	5
End	6

Selanjutnya Pengujian *White Box* Validasi Unggah Gambar dapat dilihat pada

Tabel 4.36.

Tabel 4. 36 *White Box* Validasi Unggah Gambar

Path	Alur	Test case scenario	Hasil Pengujian
1	1-2-3-4-5-6	1. Start 2. Fungsi menerima parameter file f yang tidak bernilai null (pengguna memilih berkas), sehingga kondisi if (!f) bernilai salah dan tidak melakukan return dini. 3. Sistem memeriksa f.type.startsWith("image/"); berkas yang dipilih bertipe image/jpeg sehingga kondisi if (!f.type...) bernilai salah dan tidak menampilkan toast error. 4. Sistem memeriksa ukuran berkas f.size; ukuran berkas 2 MB (< 10 MB) sehingga kondisi if (f.size > 10MB) bernilai salah dan tidak menampilkan toast error. 5. Sistem menyimpan berkas ke state file, membuat URL pratinjau melalui URL.createObjectURL(f), serta mengosongkan state result dan apiError dari sesi sebelumnya. 6. End	Benar (✓) Salah ()
2	1-2-6	1. Start 2. Fungsi dipanggil dengan parameter f bernilai null (misalnya event picker dibatalkan tanpa memilih berkas), sehingga	Benar (✓) Salah ()

		kondisi if (!f) bernilai benar dan fungsi langsung melakukan return. 6. End (tidak ada perubahan state)	
3	1-2-3-6	1. Start 2. Parameter f tidak bernilai null. 3. Berkas yang dipilih bertipe application/pdf (bukan image/*), sehingga kondisi if (!f.type.startsWith("image/")) bernilai benar, sistem menampilkan toast.error("File harus berupa gambar (JPG/PNG)") dan fungsi melakukan return. 6. End (state file, preview, result, apiError tidak berubah)	Benar (✓) Salah ()
4	1-2-3-4-6	1. Start 2. Parameter f tidak bernilai null. 3. Berkas bertipe image/png (valid), kondisi pada langkah 3 bernilai salah. 4. Ukuran berkas 12 MB (> 10 MB), sehingga kondisi if (f.size > 10 * 1024 * 1024) bernilai benar, sistem menampilkan toast.error("Ukuran maksimal 10 MB") dan fungsi melakukan return. 6. End (state file, preview, result, apiError tidak berubah)	Benar (✓) Salah ()

Berdasarkan Tabel 4.36, fungsi `handleFile()` memiliki tiga struktur percabangan kondisional (pengecekan null, tipe berkas, dan ukuran berkas) yang menghasilkan empat jalur (path) independen. Hasil pengujian terhadap keempat path menunjukkan bahwa seluruh kondisi validasi berjalan benar: berkas null diabaikan tanpa efek samping (path 2), berkas dengan tipe selain gambar ditolak dengan notifikasi yang sesuai (path 3), berkas berukuran lebih dari 10 MB ditolak dengan notifikasi yang sesuai (path 4), dan berkas gambar yang valid serta berukuran sesuai akan diterima dan ditampilkan pada pratinjau (path 1).

BAB V

SIMPULAN DAN SARAN

5.1 Simpulan

Berdasarkan hasil penelitian yang telah dilakukan, dapat disimpulkan bahwa metode *transfer learning* menggunakan arsitektur *ResNet-50* berhasil diterapkan untuk mengklasifikasikan penyakit daun kelapa sawit ke dalam lima kelas, yaitu *Healthy*, *Dryness*, *Fungal Disease*, *Magnesium Deficiency*, dan *Scale Insect*.

1. Hasil pengujian menunjukkan bahwa model yang dilatih menggunakan dataset *primer* memperoleh akurasi tertinggi sebesar 96,60%, sedangkan model pada dataset *multi modal* memperoleh akurasi 89,87%, dan model pada dataset *sekunder* memperoleh akurasi 82,66%. Meskipun dataset *primer* memberikan hasil akurasi tertinggi, saat menebak penyakit masih terjadi salah yang sangat signifikan, sedangkan dataset *multi modal* lebih baik dalam menebak penyakit meskipun akurasinya jauh dibawah dataset *primer*. Hasil tersebut menunjukkan bahwa *ResNet-50* mampu mempelajari karakteristik visual penyakit daun kelapa sawit dengan baik.
2. Proses preprocessing, pembagian dataset, serta augmentasi data yang meliputi rotasi, translasi, horizontal flip, zoom, brightness, dan contrast berhasil menghasilkan dataset yang siap digunakan dalam proses pelatihan model. Selanjutnya, model *ResNet-50* yang dilatih menggunakan pendekatan *transfer learning* mampu mempelajari karakteristik visual masing-masing kelas penyakit daun kelapa sawit dengan baik.

5.2 Saran

Berdasarkan hasil penelitian yang telah dilakukan, terdapat beberapa saran yang dapat dipertimbangkan untuk pengembangan penelitian selanjutnya.

1. Penelitian selanjutnya disarankan untuk menambah jumlah dan variasi dataset, khususnya pada kelas penyakit yang masih memiliki tingkat kesalahan klasifikasi yang relatif tinggi. Penambahan data dari berbagai kondisi pencahayaan, sudut pengambilan gambar, dan tingkat keparahan penyakit diharapkan dapat meningkatkan performa model.
2. Penelitian berikutnya dapat membandingkan performa *ResNet-50* dengan arsitektur *deep learning* lainnya seperti *EfficientNet*, *MobileNet*, atau *Vision Transformer* untuk mengetahui model yang paling optimal dalam klasifikasi penyakit daun kelapa sawit.
3. Sistem dapat dikembangkan dengan menambahkan fitur deteksi lokasi penyakit pada daun menggunakan metode object detection sehingga informasi yang diberikan kepada pengguna menjadi lebih detail dan informatif.
4. Pengembangan aplikasi berbasis mobile dapat dilakukan agar proses identifikasi penyakit daun kelapa sawit menjadi lebih praktis dan mudah digunakan secara langsung di lingkungan perkebunan.

DAFTAR PUSTAKA

- [1] “ANALISIS KINERJA PERDAGANGAN KOMODITAS KELAPA SAWIT Pusat Data dan Sistem Informasi Pertanian Sekretariat Jenderal Kementerian Pertanian 2025”.
- [2] G. A. W. Satia, E. Firmansyah, and A. Umami, “Perancangan sistem identifikasi penyakit pada daun kelapa sawit (*Elaeis guineensis* Jacq.) dengan algoritma deep learning convolutional neural networks,” *Jurnal Ilmiah Pertanian*, vol. 19, no. 1, pp. 1–10, Mar. 2022, doi: 10.31849/jip.v19i1.9556.
- [3] T. P. Mandiri, B. B. Dharmawan, F. S. Ibn, and M. C. Untoro, “Identifikasi Penyakit Pada Daun Kelapa Sawit Dengan Pendekatan CNN AlexNet,” *Jurnal Informatika: Jurnal Pengembangan IT*, vol. 10, no. 3, pp. 781–788, Jul. 2025, doi: 10.30591/jpit.v10i3.8456.
- [4] J. H. Ong, P. Ong, and W. K. Lee, “Image-based Oil Palm Leaf Disease Detection using Convolutional Neural Network,” *Journal of Information and Communication Technology*, vol. 21, no. 3, pp. 383–410, Jul. 2022, doi: 10.32890/jict2022.21.4.
- [5] Y. H. Haw *et al.*, “Classification of basal stem rot using deep learning: a review of digital data collection and palm disease classification methods,” *PeerJ Comput. Sci.*, vol. 9, 2023, doi: 10.7717/PEERJ-CS.1325.
- [6] W. Shafik, A. Tufail, L. C. De Silva, and R. A. A. H. M. Apong, “A lightweight deep learning model for multi-plant biotic stress classification

- and detection for sustainable agriculture,” *Sci. Rep.*, vol. 15, no. 1, Dec. 2025, doi: 10.1038/s41598-025-90487-1.
- [7] S. Barburiceanu, S. Meza, B. Orza, R. Malutan, and R. Terebes, “Convolutional Neural Networks for Texture Feature Extraction. Applications to Leaf Disease Classification in Precision Agriculture,” *IEEE Access*, vol. 9, pp. 160085–160103, 2021, doi: 10.1109/ACCESS.2021.3131002.
- [8] Q. Zeng, J. Sun, and S. Wang, “DIC-Transformer: interpretation of plant disease classification results using image caption generation technology,” *Front. Plant Sci.*, vol. 14, 2023, doi: 10.3389/fpls.2023.1273029.
- [9] A. A. Alhussan, D. S. Khafaga, E. S. M. El-Kenawy, A. Ibrahim, M. M. Eid, and A. A. Abdelhamid, “Pothole and Plain Road Classification Using Adaptive Mutation Dipper Throated Optimization and Transfer Learning for Self Driving Cars,” *IEEE Access*, vol. 10, pp. 84188–84211, 2022, doi: 10.1109/ACCESS.2022.3196660.
- [10] M. Ahmed and A. Ahmed, “Palm tree disease detection and classification using residual network and transfer learning of inception ResNet,” *PLoS One*, vol. 18, no. 3 March, Mar. 2023, doi: 10.1371/journal.pone.0282250.
- [11] M. A. Islam, N. Rahman Shuvo, M. Shamsoddin, S. Hasan, S. Hossain, and T. Khatun, “An Automated Convolutional Neural Network Based Approach for Paddy Leaf Disease Detection,” *International Journal of Advanced Computer Science and Applications*, vol. 12, no. 1, pp. 280–288, 2021, doi: 10.14569/IJACSA.2021.0120134.

- [12] E. Moupojou *et al.*, “FieldPlant: A Dataset of Field Plant Images for Plant Disease Detection and Classification With Deep Learning,” *IEEE Access*, vol. 11, pp. 35398–35410, 2023, doi: 10.1109/ACCESS.2023.3263042.
- [13] M. Kamireddy, S. K. Behera, and S. Kancherla, “Establishing Critical Leaf Nutrient Concentrations and Identification of Yield Limiting Nutrients for Precise Nutrient Prescriptions of Oil Palm (*Elaeis guineensis* Jacq) Plantations,” *Agriculture (Switzerland)*, vol. 13, no. 2, Feb. 2023, doi: 10.3390/agriculture13020453.
- [14] B. Ikhajiagbe, W. Aituae, and M. C. Ogwu, “MORPHO-PHYSIOLOGICAL ASSESSMENT OF OIL PALM (*Elaeis guineensis* Jacq.) SEEDLINGS EXPOSED TO SIMULATED DROUGHT CONDITIONS,” *J. Oil Palm Res.*, vol. 34, no. 1, pp. 26–34, Mar. 2022, doi: 10.21894/jopr.2021.0018.
- [15] “Klasifikasi Penyakit Daun Sawit.” Accessed: May 10, 2026. [Online]. Available: <https://www.kaggle.com/code/hasbiarahmanefendi/klasifikasi-penyakit-daun-sawit?select=palm-disease-dataset>
- [16] C. S. Wibowo *et al.*, “Molecular basis of resistance to leaf spot disease in oil palm,” *Front. Plant Sci.*, vol. 15, 2024, doi: 10.3389/fpls.2024.1458346.
- [17] X. Ye *et al.*, “Magnesium-deficiency effects on pigments, photosynthesis and photosynthetic electron transport of leaves, and nutrients of leaf blades and veins in citrus sinensis seedlings,” *Plants*, vol. 8, no. 10, Oct. 2019, doi: 10.3390/plants8100389.
- [18] J. P. Egonyu *et al.*, “Global Advances on Insect Pest Management Research in Oil Palm,” Dec. 01, 2022, *MDPI*. doi: 10.3390/su142316288.

- [19] A. Pribadi and A. Kurniawan, “Deteksi Penyakit Sawit Menggunakan Metode Deep Learning,” 2022.
- [20] L. Chen, S. Li, Q. Bai, J. Yang, S. Jiang, and Y. Miao, “Review of image classification algorithms based on convolutional neural networks,” Nov. 01, 2021, *MDPI*. doi: 10.3390/rs13224712.
- [21] A. Zafar *et al.*, “Convolutional Neural Networks: A Comprehensive Evaluation and Benchmarking of Pooling Layer Variants,” *Symmetry (Basel)*., vol. 16, no. 11, Nov. 2024, doi: 10.3390/sym16111516.
- [22] M. Shafiq and Z. Gu, “Deep Residual Learning for Image Recognition: A Survey,” Sep. 01, 2022, *MDPI*. doi: 10.3390/app12188972.
- [23] M. Aggarwal, A. K. Tiwari, M. P. Sarathi, and A. Bijalwan, “An early detection and segmentation of Brain Tumor using Deep Neural Network,” *BMC Med. Inform. Decis. Mak.*, vol. 23, no. 1, Dec. 2023, doi: 10.1186/s12911-023-02174-8.
- [24] B. Mitra Sujatmiko *et al.*, “CONVOLUTION NEURAL NETWORK DENGAN DESAIN JARINGAN RESNET SEBAGAI METODE KLASIFIKASI TUMOR KULIT CONVOLUTION NEURAL NETWORK USING RESNET NETWORK DESIGN AS SKIN TUMOR CLASSIFICATION METHOD,” vol. 11, no. 1, 2022.
- [25] A. Victor Ikechukwu, S. Murali, R. Deepu, and R. C. Shivamurthy, “ResNet-50 vs VGG-19 vs training from scratch: A comparative analysis of the segmentation and classification of Pneumonia from chest X-ray images,”

- Global Transitions Proceedings*, vol. 2, no. 2, pp. 375–381, Nov. 2021, doi: 10.1016/j.gltp.2021.08.027.
- [26] A. W. Salehi *et al.*, “A Study of CNN and Transfer Learning in Medical Imaging: Advantages, Challenges, Future Scope,” Apr. 01, 2023, *MDPI*. doi: 10.3390/su15075930.
- [27] J. H. Cabot and E. G. Ross, “Evaluating prediction model performance,” *Surgery (United States)*, vol. 174, no. 3, pp. 723–726, Sep. 2023, doi: 10.1016/j.surg.2023.05.023.
- [28] K. Carlson, B. P. Battenfield, and Y. Qiang, “Wetland Classification, Attribute Accuracy, and Scale,” *ISPRS Int. J. Geoinf.*, vol. 13, no. 3, Mar. 2024, doi: 10.3390/ijgi13030103.
- [29] B. Hardika *et al.*, “Pengujian Blackbox Testing Website Garuda Farm Menggunakan Teknik Equivalence Partitioning.”
- [30] M. I. Shiddiq, “IMPLEMENTASI WHITE BOX TESTING BERBASIS PATH PADA FORM LOGIN APLIKASI BERBASIS WEB,” vol. 8, no. 1, p. 2022.