

**RANCANG BANGUN APLIKASI PENGUJIAN AKURASI CHATGPT
MENGUNAKAN METODE *CHAIN-OF-THOUGHT* BERBASIS
ALGORITMA *LEVENSHTAIN DISTANCE* PADA DATASET INDOMMLU**

SKRIPSI

Diajukan Sebagai Salah Satu Syarat Untuk Menyelesaikan
Pendidikan Jenjang Sarjana Terapan
Pada Politeknik Negeri Lhokseumawe



Oleh:

ELVIRA GLADYS SAMSUL

NIM : 2022573010010
Program Studi : Teknik Informatika
Jurusan : Teknologi Informasi dan Komputer

**KEMENTERIAN PENDIDIKAN TINGGI, SAINS, DAN TEKNOLOGI
POLITEKNIK NEGERI LHOKSEUMAWE**

2026

PENGESAHAN PEMBIMBING

Skripsi yang berjudul Rancang Bangun Aplikasi Pengujian Akurasi ChatGPT Menggunakan Metode *Chain-of-Thought* Berbasis Algoritma *Levenshtein Distance* pada Dataset IndoMMLU, disusun oleh Elvira Gladys Samsul, NIM 2022573010010, Program Studi Sarjana Terapan Teknik Informatika, Jurusan Teknologi Informasi dan Komputer pada Politeknik Negeri Lhokseumawe, telah disetujui dan memenuhi syarat untuk dipertanggungjawabkan dihadapan dewan penguji.

Buketrata, 20 Juli 2026


Persetujuan Pembimbing,

Pembimbing I,



Muhammad Arhami, S.Si., M.Kom
NIP. 19741029 200003 1 001

Pembimbing II,



Muhammad Rizka, S.S.T., M.Kom
NIP. 19881009 201504 1 001

Mengetahui,

Ketua Jurusan
Teknologi Informasi dan Komputer,

Salahuddin, S.T., M.Cs
NIP. 19740424 200212 1 001

Ketua Program Studi
Teknik Informatika,

M. Khadafi, S.T., M.T
NIP. 19750718 200212 1 004

PENGESAHAN PENGUJI

Skripsi yang berjudul Rancang Bangun Aplikasi Pengujian Akurasi ChatGPT Menggunakan Metode *Chain-of-Thought* Berbasis Algoritma *Levenshtein Distance* pada Dataset IndoMMLU, disusun oleh Elvira Gladys Samsul, NIM 2022573010010, Program Studi Sarjana Terapan Teknik Informatika, Jurusan Teknologi Informasi dan Komputer pada Politeknik Negeri Lhokseumawe, telah dipertanggungjawabkan di depan dewan penguji dan dinyatakan lulus pada tanggal 31 Juli 2026.

TIM Komisi Sidang,

Muhammad Arhami, S.Si., M.Kom	
NIP. 19741029 200003 1 001	(Ketua Sidang)

Muhammad Rizka, S.S.T., M.Kom	
NIP. 19881009 201504 1 001	(Sekretaris Sidang)

Mahdi S.T., M.Cs	
NIP. 1970902 199903 1 001	(Penguji I)

Hendrawaty, S.T., M.T	
NIP. 19700226 199003 1 005	(Penguji II)

Musta'inul Abdi, S.S.T., M.Kom	
NIP. 19911030 201903 1 015	(Penguji III)

Mengesahkan,

Ketua Jurusan
Teknologi Informasi dan Komputer,

Ketua Program Studi
Teknik Informatika,

Salahuddin, S.T., M.Cs
NIP. 19740424 200212 1 001

M. Khadafi, S.T., M.T
NIP. 19750718 200212 1 004

PERNYATAAN KEASLIAN TULISAN

Dengan ini saya menyatakan bahwa dalam Skripsi ini tidak terdapat karya yang pernah diajukan untuk mendapatkan gelar kesarjanaan di suatu Perguruan Tinggi, dan sepanjang pengetahuan saya juga tidak terdapat karya atau pendapat yang pernah ditulis orang lain, kecuali yang secara tertulis diacu dalam naskah dan disebut dalam daftar pustaka.

Buketrata, 31 Juli 2026

Elvira Gladys Samsul
NIM. 2022573010010

ABSTRAK

Perkembangan *Large Language Model* (LLM) seperti *ChatGPT* telah meningkatkan kemampuan dalam memahami bahasa alami dan menyelesaikan berbagai tugas berbasis teks. Kemampuan model dalam memahami bahasa dan konteks budaya lokal masih perlu dievaluasi karena sebagian besar pengembangan dan pengujian dilakukan menggunakan dataset berbahasa Inggris. Penelitian ini bertujuan membangun aplikasi evaluasi otomatis untuk menguji akurasi jawaban *ChatGPT* pada soal *Multiple Choice Question* (MCQ) domain bahasa menggunakan dataset *IndoMMLU*, mengukur tingkat akurasi jawaban GPT-4o mini menggunakan algoritma *Levenshtein Distance*, serta membandingkan efektivitas metode *Chain-of-Thought* (CoT) dan *Non-Chain-of-Thought* (Non-CoT). Penelitian menggunakan metode eksperimen kuantitatif melalui tahapan *preprocessing* dataset *IndoMMLU* yang difokuskan pada sembilan domain bahasa. Aplikasi EvalGPT dikembangkan untuk melakukan pengujian otomatis, menghasilkan jawaban model, dan menghitung nilai *similarity* menggunakan algoritma *Levenshtein Distance*. Pengujian dilakukan melalui empat skenario dengan membandingkan nilai *similarity*, akurasi *exact match*, penggunaan token, dan waktu respons. Hasil penelitian menunjukkan bahwa pengujian per domain menghasilkan nilai *similarity* rata-rata sebesar 65,42% menggunakan metode *Chain-of-Thought* dan 63,81% menggunakan *Non-Chain-of-Thought*, dengan jumlah jawaban benar masing-masing 483 soal dan 454 soal dari total 900 soal. Pengujian gabungan menunjukkan metode *Non-Chain-of-Thought* lebih stabil dengan nilai *similarity* tertinggi sebesar 70,18%, sedangkan *Chain-of-Thought* memperoleh 69,37%. Bahasa Indonesia menghasilkan performa tertinggi dengan nilai *similarity* mencapai 95,92%, sedangkan bahasa daerah lainnya berada pada rentang 55,49% hingga 77,23%. Metode *Chain-of-Thought* membutuhkan token sekitar 5,2 kali lebih besar serta waktu respons empat hingga enam kali lebih lama dibandingkan *Non-Chain-of-Thought*. Hasil penelitian menunjukkan bahwa efektivitas *Chain-of-Thought* tidak selalu meningkatkan performa GPT-4o mini, tetapi dipengaruhi oleh karakteristik domain bahasa dan skala pengujian.

Kata Kunci: *Chain-of-Thought*, ChatGPT, IndoMMLU, *Levenshtein Distance*, *Multiple Choice Question*

ABSTRACT

The development of Large Language Models (LLMs) such as ChatGPT has improved the ability of artificial intelligence systems to understand natural language and solve various text-based tasks. However, the capability of these models in local language and cultural contexts requires further evaluation because most model development and evaluation processes are conducted using English-based datasets. This study aims to design and develop an automated evaluation system to measure the *accuracy* of the GPT-4o mini model on *Multiple Choice Question* (MCQ) tasks in language domains using the IndoMMLU dataset, as well as to analyze the effect of *Chain-of-Thought* (CoT) compared to *Non-Chain-of-Thought* (Non-CoT) approaches. The research applies a quantitative experimental method by preprocessing the IndoMMLU dataset into nine language domains. An evaluation system named EvalGPT was developed to automate testing, generate model responses, and measure answer *similarity* using the *Levenshtein Distance* algorithm. The experiments were conducted through several testing scenarios by comparing Non-CoT and CoT based on *similarity* score, token usage, and response time. The results show that domain-based testing achieved an *average similarity* of 65.42% for CoT and 63.81% for Non-CoT, with 483 and 454 correct answers, respectively. In larger combined-domain tests, Non-CoT produced more stable performance with the highest *similarity* of 70.18%, while CoT achieved 69.37%. Bahasa Indonesia obtained the highest performance with *similarity* reaching 95.92%, whereas other language domains ranged from 55.49% to 77.23%. CoT required approximately 5.2 times more tokens and four to six times longer response time than Non-CoT. These findings indicate that CoT does not consistently improve model performance, as its effectiveness depends on language domain characteristics, model knowledge, and testing scale.

Kata Kunci: *Chain-of-Thought*, ChatGPT, IndoMMLU, *Levenshtein Distance*, *Multiple Choice Question*

KATA PENGANTAR

Segala puji beserta syukur senantiasa penulis panjatkan kepada Allah SWT yang telah memberikan rahmat dan petunjuk-Nya kepada penulis sehingga dapat menyelesaikan skripsi yang berjudul “Rancang Bangun Aplikasi Pengujian Akurasi ChatGPT Menggunakan Metode *Chain-of-Thought* Berbasis Algoritma *Levenshtein Distance* pada Dataset IndoMMLU”. Shalawat beserta salam kepada baginda Rasulullah Muhammad SAW, keluarga, dan para sahabat yang telah berjasa dalam memperjuangkan islam dan ilmu pengetahuan. Skripsi ini disusun sebagai salah satu syarat untuk menyelesaikan pendidikan Sarjana Terapan Program Studi Teknik Informatika Jurusan Teknologi Informasi dan Komputer Politeknik Negeri Lhokseumawe.

Dalam penyusunan skripsi ini, penulis memperoleh banyak dukungan, bimbingan, motivasi, serta bantuan dari berbagai pihak. Dengan segala hormat dan kerendahan hati, penulis menyampaikan ucapan terima kasih yang sebesar-besarnya kepada:

1. Kedua orang tua tercinta, Ayahanda Samsul Bahri dan Ibunda Radiatun, yang senantiasa memberikan kasih sayang, doa, dukungan, pengorbanan, semangat, serta motivasi yang tiada henti kepada penulis. Terima kasih atas segala perjuangan, perhatian, kepercayaan, dan doa yang senantiasa mengiringi setiap langkah penulis sehingga dapat menyelesaikan pendidikan dan skripsi ini.
2. Abang Muhammad Rifaldi Akbar, yang telah memberikan semangat, perhatian, dan dukungan kepada penulis.

3. Bapak Ir. Rizal Syahyadi, ST., M.Eng.Sc., IPM., ASEAN Eng., APEC Eng., selaku Direktur Politeknik Negri Lhokseumawe
4. Bapak Salahuddin, S.T., M.Cs., selaku Ketua Jurusan Teknologi Informasi dan Komputer, Bapak Fachri Yanuar Rudi F, S.S.T., M.T., selaku Sekretaris Jurusan Teknologi Informasi dan Komputer, dan Bapak M. Khadafi, S.T., M.T., selaku Ketua Program Studi Teknik Informatika atas segala bimbingan dan perhatian selama masa perkuliahan.
5. Bapak Muhammad Arhami, S.Si., M.Kom., dan Bapak Muhammad Rizka, S.S.T., M.Kom., selaku pembimbing I dan II yang telah membimbing penulis, memberi petunjuk, memberi saran-saran dan arahan serta masukan dari awal masa pengajuan judul sampai berhasil menyelesaikan Skripsi.
6. Bapak Mahdi, S.T., M.Cs., selaku Koordinator Skripsi Program Studi Teknik Informatika yang telah memberikan arahan dan informasi terkait pelaksanaan skripsi.
7. Bapak Mahdi, S.T., M.Cs., Ibu Hendrawaty, S.T., M.T., dan Bapak Musta'inul Abdi, S.S.T., M.Kom., selaku dosen penguji yang telah memberikan waktu, arahan, kritik, saran, serta masukan yang membangun kepada penulis dalam proses penyempurnaan skripsi ini.
8. Seluruh dosen pengajar Program Studi Sarjana Terapan Teknik Informatika yang telah memberikan ilmu pengetahuan, pengalaman, dan bimbingan selama masa perkuliahan hingga penulis menyelesaikan pendidikan.
9. Seluruh Staf Administrasi pada Jurusan Teknologi Informasi dan Komputer.
10. Dea Auzira Putri, seseorang yang begitu berarti dalam perjalanan hidup

penulis, yang telah hadir sejak kecil dan menjadi saksi dari berbagai cerita, proses, serta perjuangan yang telah penulis lalui. Terima kasih telah menjadi salah satu orang yang selalu ada dalam setiap suka maupun duka, menjadi tempat berbagi cerita, mendengarkan setiap keluh kesah, serta memahami berbagai proses yang penulis jalani. Doa, kehadiran, kepedulian, dan kebersamaan yang telah diberikan selama ini selalu penuh makna dan menjadi bagian berharga yang mengiringi penulis hingga mampu menyelesaikan skripsi ini.

11. Meutia Rahma, yang telah menjadi bagian dari perjalanan penulis sejak masa SMA hingga saat ini. Terima kasih telah menjadi teman yang selalu menemani selama menjalani masa perkuliahan, berbagi cerita, melewati berbagai proses, serta memberikan warna dalam perjalanan pendidikan penulis hingga dapat menyelesaikan skripsi ini.
12. Dinda, Siti, dan Taya, teman seperjuangan selama masa perkuliahan yang telah menemani berbagai cerita dan proses yang penulis lalui selama menjalani pendidikan. Terima kasih atas kebersamaan, bantuan, semangat, serta waktu yang telah dilalui bersama, baik dalam kegiatan perkuliahan maupun momen-momen sederhana yang menjadi bagian dari perjalanan penulis hingga menyelesaikan skripsi ini.
13. Teman-teman seperjuangan Program Studi Teknik Informatika angkatan 2022.
14. Pihak-pihak lain yang tidak dapat disebutkan namanya satu per satu yang telah membantu dan memberikan dukungan kepada penulis dalam penyusunan skripsi ini

15. *Last but not least, I wanna thank me. I wanna thank me for believing in me. I wanna thank me for all doing this hard work. I wanna thank me for having no days off. I wanna thank me for never quitting. I wanna thank me for always being a giver and trying to give more than I receive. I want to thank me for trying to do more right than wrong. I want to thank me for just being me at all times.*

Penulis menyadari bahwa skripsi ini masih memiliki banyak kekurangan. Penulis menerima dan menghargai setiap kritik serta saran yang membangun dari berbagai pihak sebagai bahan perbaikan di masa mendatang. Penulis berharap skripsi ini dapat memberikan manfaat bagi semua pihak. Semoga segala bantuan dan kebaikan yang telah diberikan kepada penulis mendapatkan balasan dari Allah SWT. Aamiin.

Lhokseumawe, 31 Juli 2026
Penulis,

Elvira Gladys Samsul
NIM. 2022573010010

DAFTAR ISI

PENGESAHAN PEMBIMBING	ii
PENGESAHAN PENGUJI.....	iii
PERNYATAAN KEASLIAN TULISAN	iv
ABSTRAK	v
<i>ABSTRACT</i>	vi
KATA PENGANTAR.....	vii
DAFTAR ISI.....	xi
DAFTAR GAMBAR.....	xv
DAFTAR TABEL	xvii
DAFTAR LAMPIRAN	xix
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang Masalah	1
1.2 Rumusan Masalah	4
1.3 Tujuan Penelitian.....	4
1.4 Batasan Penelitian	5
1.5 Manfaat Penelitian.....	6
1.6 Sistematika Penulisan.....	6
BAB II TINJAUAN PUSTAKA.....	9
2.1 <i>State of the Art</i>	9
2.2 Tinjauan Teoritis	17
2.2.1 <i>Large Language Model</i>	17
2.2.2 ChatGPT sebagai Model <i>Pre-trained</i>	18
2.2.3 GPT-4o mini.....	19
2.2.4 <i>Prompting</i> dalam <i>Large Language Model</i>	21
2.2.5 <i>Chain-of-Thought</i> dan <i>Non-Chain-of-Thought Prompting</i> ..	22
2.2.6 <i>Multiple Choice Question</i> (MCQ) dalam Evaluasi LLM.....	24
2.2.7 Dataset IndoMMLU	25
2.2.8 Evaluasi Akurasi Jawaban <i>Large Language Model</i>	26
2.2.9 Algoritma <i>Levenshtein Distance</i>	27

2.2.10 Penerapan <i>Levenshtein Distance</i> dalam Evaluasi Teks.....	30
BAB III METODOLOGI PENELITIAN	32
3.1 Data dan Pengumpulan Data	32
3.2 Analisis Kebutuhan Sistem.....	35
3.2.1 Analisis Kebutuhan Fungsional	35
3.2.2 Analisis Kebutuhan Non-Fungsional	37
3.2.3 Analisis Kebutuhan Antarmuka Pengguna (<i>User Interface</i>)	38
3.3 Perancangan Sistem.....	40
3.3.1 Arsitektur Sistem	41
3.3.2 Pemodelan Sistem <i>Unified Modelling Language</i> (UML)	44
3.3.3 Perancangan Antarmuka Pengguna (<i>User Interface</i>).....	66
3.4 Perancangan Metode Penelitian	84
3.4.1 Perancangan <i>Prompt</i> Pengujian	84
3.4.2 Flowchart Penerapan Metode <i>Chain-of-Thought</i>	86
3.4.3 Flowchart Perhitungan <i>Levenshtein Distance</i>	89
3.4.4 Perhitungan <i>Accuracy</i> Pengujian	92
3.5 Scenarios Pengujian	93
3.5.1 Skenario 1: Pengujian Per Domain Bahasa.....	93
3.5.2 Skenario 2: Pengujian Seluruh Domain dengan 25 Sampel per Domain.....	94
3.5.3 Skenario 3: Pengujian Seluruh Domain dengan 50 Sampel per Domain.....	94
3.5.4 Skenario 4: Pengujian Seluruh Domain dengan 100 Sampel per Domain.....	95
3.6 Perancangan Pengujian Sistem.....	96
3.5.5 Scenario Pengujian Halaman Dataset	96
3.5.6 Scenario Pengujian Halaman Proses Pengujian.....	97
3.5.7 Scenario Pengujian Halaman Hasil Pengujian.....	98
3.5.8 Scenario Pengujian Halaman Visualisasi	98
3.5.9 Scenario Pengujian Halaman Laporan.....	99

BAB IV HASIL DAN PEMBAHASAN.....	100
4.1 Implementasi Aplikasi Pengujian Model GPT-4o Mini	100
4.2 Implementasi <i>Preprocessing</i> Dataset IndoMMLU.....	125
4.2.1 <i>Filtering</i> Dataset IndoMMLU.....	125
4.2.2 Pembentukan Dataset Pengujian.....	127
4.3 Implementasi Mekanisme Pengujian Model GPT-4o Mini.....	130
4.3.1 Implementasi Pembentukan <i>Prompt</i> Pengujian	131
4.3.2 Implementasi Pemanggilan OpenAI API GPT-4o mini.....	133
4.3.3 Implementasi Ekstraksi Jawaban	133
4.3.4 Implementasi Normalisasi Teks	135
4.3.5 Implementasi Perhitungan <i>Levenshtein Distance</i>	136
4.3.6 Implementasi Penyimpanan Data Hasil dan Riwayat Pengujian	139
4.4 Hasil Pengujian Model GPT-4o Mini terhadap Skenario Pengujian..	146
4.4.1 Skenario 1: Pengujian Per Domain Bahasa.....	147
4.4.2 Skenario 2: Pengujian 25 Soal per Domain	150
4.4.3 Skenario 3: Pengujian 50 Soal per Domain	150
4.4.4 Skenario 4: Pengujian 100 Soal per Domain	151
4.5 Pembahasan Hasil Pengujian Model GPT-4o Mini.....	151
4.5.1 Analisis Perbandingan Performa Metode CoT dan Non-CoT	151
4.5.2 Analisis Keberhasilan <i>Chain-of-Thought</i> pada GPT-4o mini	154
4.5.3 Analisis Kegagalan <i>Reasoning Chain-of-Thought</i>	157
4.5.4 Pengaruh Karakteristik Domain Bahasa terhadap Performa Model	161
4.5.5 Analisis Efisiensi Penggunaan Token dan Waktu Respons	164
4.5.6 Analisis Keterbatasan Evaluasi Menggunakan <i>Exact Match</i> dan <i>Levenshtein Distance</i>	165
4.6 Hasil Pengujian <i>Black Box</i>	167

4.6.1 Halaman Dataset	168
4.6.2 Halaman Proses Pengujian.....	169
4.6.3 Halaman Hasil Pengujian.....	171
4.6.4 Halaman Visualisasi	172
4.6.5 Halaman Laporan.....	173
BAB V PENUTUP	175
5.1 Simpulan	175
5.2 Saran	177
DAFTAR PUSTAKA	179
DAFTAR LAMPIRAN	184

DAFTAR GAMBAR

Gambar 2. 1 Perbandingan <i>Standard Prompting</i> , <i>Few-shot CoT</i> , <i>Zero-shot</i> , dan <i>Zero-shot CoT</i>	23
Gambar 3. 1 Alur Metode Penelitian dan Arsitektur Sistem Evaluasi	41
Gambar 3. 2 <i>Use Case Diagram</i> Aplikasi Pengujian Akurasi ChatGPT	45
Gambar 3. 3 <i>Activity Diagram</i> Pengguna Mengunduh Dataset IndoMMLU.....	55
Gambar 3. 4 <i>Activity Diagram</i> Pengguna Mengunduh <i>Template</i> Dataset.....	56
Gambar 3. 5 <i>Activity Diagram</i> Pengguna Mengunggah Dataset.....	57
Gambar 3. 6 <i>Activity Diagram</i> Pengguna Menambah Data Dataset	58
Gambar 3. 7 <i>Activity Diagram</i> Pengguna Menghapus Data Dataset	59
Gambar 3. 8 <i>Activity Diagram</i> Pengguna Menjalankan Pengujian Akurasi	60
Gambar 3. 9 <i>Activity Diagram</i> Pengguna Melihat Hasil Pengujian.....	62
Gambar 3. 10 <i>Activity Diagram</i> Pengguna Melihat Riwayat Pengujian.....	63
Gambar 3. 11 <i>Activity Diagram</i> Pengguna Melihat Visualisasi Hasil.....	64
Gambar 3. 12 <i>Activity Diagram</i> Pengguna Melihat Laporan.....	65
Gambar 3. 13 Desain Halaman Beranda	67
Gambar 3. 14 Halaman Unggah Dataset.....	69
Gambar 3. 15 Desain Halaman Dataset Gagal Diunggah.....	70
Gambar 3. 16 Desain Halaman Dataset Berhasil Diunggah	71
Gambar 3. 17 Desain Modal Tambah Data Dataset.....	72
Gambar 3. 18 Desain Halaman Tambah Data Dataset Berhasil.....	73
Gambar 3. 19 Desain Halaman Hapus Dataset Berhasil.....	74
Gambar 3. 20 Desain Halaman Proses Pengujian.....	75
Gambar 3. 21 Desain Halaman Hasil Pengujian Belum Melakukan Pengujian ...	76
Gambar 3. 22 Desain Halaman Hasil Pengujian Sudah Melakukan Pengujian....	77
Gambar 3. 23 Desain Riwayat Pengujian Belum Tersedia	78
Gambar 3. 24 Desain Riwayat Pengujian Tersedia	79
Gambar 3. 25 Desain Halaman Visualisasi Belum Melakukan Pengujian	80
Gambar 3. 26 Desain Halaman Visualisasi Sudah Melakukan Pengujian	81
Gambar 3. 27 Desain Halaman Laporan Belum Melakukan	82

Gambar 3. 28 Desain Halaman Laporan Sudah Melakukan Pengujian.....	83
Gambar 3. 29 Flowchart Penerapan Metode <i>Chain-of-Thought</i>	87
Gambar 3. 30 Flowchart Perhitungan <i>Levenshtein Distance</i>	89
Gambar 4. 1 Implementasi Halaman Beranda	102
Gambar 4. 2 Implementasi Halaman Unggah Dataset.....	104
Gambar 4. 3 Implementasi Halaman Dataset Gagal Diunggah	105
Gambar 4. 4 Implementasi Halaman Dataset Berhasil Diunggah	107
Gambar 4. 5 Implementasi Modal Tambah Data Dataset	108
Gambar 4. 6 Implementasi Halaman Tambah Data Dataset Berhasil.....	110
Gambar 4. 7 Implementasi Halaman Hapus Dataset Berhasil	111
Gambar 4. 8 Implementasi Implementasi Halaman Proses Pengujian	112
Gambar 4. 9 Implementasi Halaman Hasil Pengujian Belum Melakukan Pengujian	114
Gambar 4. 10 Implementasi Halaman Hasil Pengujian Sudah Melakukan Pengujian	115
Gambar 4. 11 Implementasi Riwayat Pengujian Belum Tersedia.....	117
Gambar 4. 12 Implementasi Riwayat Pengujian Tersedia	118
Gambar 4. 13 Halaman Visualisasi Belum Melakukan Pengujian	119
Gambar 4. 14 Implementasi Halaman Visualisasi Sudah Melakukan Pengujian	121
Gambar 4. 15 Implementasi Halaman Laporan Belum Melakukan.....	123
Gambar 4. 16 Implementasi Halaman Laporan Sudah Melakukan Pengujian ...	124
Gambar 4. 17 Hasil Ekspor Laporan Excel.....	144
Gambar 4. 18 Hasil Ekspor Laporan PDF	145

DAFTAR TABEL

Tabel 2. 1 <i>State of the Art</i>	11
Tabel 3. 1 Struktur Data Dataset Final Penelitian	33
Tabel 3. 2 <i>Use Case Download</i> Dataset IndoMMLU	46
Tabel 3. 3 <i>Use Case Download</i> Template Dataset	47
Tabel 3. 4 <i>Use Case Unggah</i> Dataset	48
Tabel 3. 5 <i>Use Case Tambah</i> Data Dataset	48
Tabel 3. 6 <i>Use Case Hapus</i> Data Dataset.....	49
Tabel 3. 7 <i>Use Case Jalankan</i> Pengujian Akurasi	50
Tabel 3. 8 <i>Use Case Lihat</i> Hasil Pengujian.....	51
Tabel 3. 9 <i>Use Case Lihat</i> Riwayat Pengujian.....	52
Tabel 3. 10 <i>Use Case Lihat</i> Visualisasi Hasil	53
Tabel 3. 11 <i>Use Case Lihat</i> Laporan	53
Tabel 3. 12 Scenario 1: Pengujian Per Domain Bahasa.....	94
Tabel 3. 13 Scenario 2: Pengujian Seluruh Domain dengan 25 Sampel per Domain	94
Tabel 3. 14 Skenario 3: Pengujian Seluruh Domain dengan 50 Sampel per Domain	95
Tabel 3. 15 Skenario 4: Pengujian Seluruh Domain dengan 100 Sampel per Domain	95
Tabel 3. 16 Scenario Pengujian Halaman Dataset	96
Tabel 3. 17 Scenario Pengujian Halaman Proses Pengujian.....	97
Tabel 3. 18 Scenario Pengujian Halaman Hasil Pengujian.....	98
Tabel 3. 19 Scenario Pengujian Halaman Visualisasi	98
Tabel 3. 20 Scenario Pengujian Halaman Laporan	99
Tabel 4. 1 <i>Source code</i> Filtering Dataset Berdasarkan Nilai Atribut Subject	126
Tabel 4. 2 <i>Source code</i> Ekstraksi Jawaban Feferensi dari Pilihan Jawaban	127
Tabel 4. 3 <i>Source code</i> Pengambilan Sejumlah Data Berdasarkan Domain Bahasa	128
Tabel 4. 4 <i>Source code</i> Pembentukan Dataset Pengujian Perdomain	129

Tabel 4. 5 <i>Source code</i> Pembentukan Dataset Gabungan	129
Tabel 4. 6 <i>Source code Template Prompt</i>	131
Tabel 4. 7 <i>Source code</i> Pembentukan <i>Prompt</i>	132
Tabel 4. 8 <i>Source code</i> Pemanggilan OpenAI API GPT-4o mini	133
Tabel 4. 9 <i>Source code</i> Ekstraksi Jawaban	134
Tabel 4. 10 Contoh Ekstraksi Jawaban Model	135
Tabel 4. 11 <i>Source code</i> Normalisasi Teks	135
Tabel 4. 12 <i>Source code</i> Normalisasi Teks	136
Tabel 4. 13 <i>Source code</i> Perhitungan <i>Levenshtein Distance</i>	137
Tabel 4. 14 <i>Source code</i> Perhitungan <i>Similarity</i>	138
Tabel 4. 15 Struktur Data Hasil Pengujian Per Soal	139
Tabel 4. 16 Struktur Metadata Pengujian	141
Tabel 4. 17 Struktur Riwayat Pengujian	142
Tabel 4. 18 Rekapitulasi Hasil Pengujian Per Domain	147
Tabel 4. 19 Rincian Benar Salah per Soal, per Domain	148
Tabel 4. 20 Contoh Detail Hasil Pengujian Bahasa Lampung	149
Tabel 4. 21 Skenario 2 - 25 Soal per Domain	150
Tabel 4. 22 Skenario 3 - 50 Soal per Domain	150
Tabel 4. 23 Skenario 4 - 100 Soal per Domain	151
Tabel 4. 24 Pengujian <i>Black Box</i> Halaman Dataset	168
Tabel 4. 25 Pengujian <i>Black Box</i> Halaman Proses Pengujian	170
Tabel 4. 26 Pengujian <i>Black Box</i> Halaman Hasil Pengujian	171
Tabel 4. 27 Pengujian <i>Black Box</i> Halaman Visualisasi	172
Tabel 4. 28 Pengujian <i>Black Box</i> Halaman Laporan	173

DAFTAR LAMPIRAN

Lampiran 1. Berita Acara Seminar Proposal Skripsi	184
---	-----

BAB I

PENDAHULUAN

1.1 Latar Belakang Masalah

Perkembangan *Large Language Model* (LLM) telah menunjukkan kemajuan yang signifikan dalam bidang pemrosesan bahasa alami, terutama dalam kemampuan memahami konteks, melakukan penalaran, serta menyelesaikan soal akademik berbasis teks dan *Multiple Choice Question* (MCQ) [1], [2]. Model LLM terkini, seperti ChatGPT dan GPT-4, menunjukkan performa tinggi pada berbagai *benchmark* internasional, bahkan pada beberapa tugas penalaran dinyatakan mampu menyamai atau melampaui performa manusia [3], [4], [5]. Capaian tersebut menunjukkan potensi besar LLM sebagai alat bantu dalam konteks akademik dan evaluasi pengetahuan berbasis teks.

Performa tinggi LLM pada berbagai penelitian sebelumnya umumnya didasarkan pada evaluasi menggunakan bahasa Inggris dan dataset global, sehingga belum sepenuhnya merepresentasikan kemampuan model dalam memahami bahasa dan budaya lokal. Kondisi ini mendorong pengembangan IndoMMLU sebagai *benchmark* nasional untuk mengevaluasi kemampuan LLM dalam konteks bahasa Indonesia, pengetahuan akademik, serta aspek budaya lokal [1]. Hasil evaluasi pada IndoMMLU menunjukkan bahwa performa LLM pada soal berbahasa Indonesia masih bervariasi dan cenderung lebih rendah dibandingkan *benchmark* global. Temuan tersebut sejalan dengan penelitian yang menyatakan bahwa karakteristik bahasa dan domain pengetahuan memiliki pengaruh signifikan terhadap performa

LLM, terutama pada bahasa non-Inggris dengan struktur linguistik dan konteks semantik yang berbeda [6], [7] [5].

Permasalahan evaluasi LLM pada domain bahasa Indonesia tidak hanya berkaitan dengan karakteristik dataset, tetapi juga dipengaruhi oleh pendekatan evaluasi dan strategi *prompting* yang digunakan. Evaluasi akurasi jawaban pada berbagai penelitian berbasis *Multiple Choice Question* (MCQ) umumnya dilakukan berdasarkan kecocokan opsi jawaban terhadap jawaban referensi [1], [8], [9]. Pendekatan tersebut mampu mengukur ketepatan pilihan jawaban, tetapi belum mengevaluasi kesesuaian narasi jawaban yang dihasilkan model dengan jawaban referensi. Pendekatan *Chain-of-Thought* (CoT) dinyatakan mampu meningkatkan kualitas penalaran dan akurasi jawaban pada berbagai tugas, seperti penilaian akademik dan evaluasi profesional [3], [4], [10], namun efektivitasnya sangat bergantung pada jenis tugas dan konteks bahasa yang digunakan [7]. Penelitian sebelumnya juga masih banyak mengandalkan analisis manual atau skema kualitatif yang memiliki keterbatasan dari sisi objektivitas dan skalabilitas ketika diterapkan pada *dataset* berskala besar seperti IndoMMLU [11], [12]. Kondisi tersebut mendorong penggunaan metode kuantitatif berbasis kemiripan teks, salah satunya algoritma *Levenshtein Distance*, yang telah banyak diterapkan pada berbagai domain [13], [14], [15], [16], [17], [18]. Meskipun demikian, pemanfaatan algoritma ini dalam evaluasi akurasi jawaban LLM berbahasa Indonesia masih relatif terbatas [19].

Kajian literatur menunjukkan beberapa permasalahan utama yang menjadi dasar penelitian ini, yaitu:

- a. Evaluasi akurasi jawaban ChatGPT pada soal pilihan ganda masih didominasi oleh pencocokan opsi jawaban secara eksak sehingga belum mengevaluasi kesesuaian narasi jawaban yang dihasilkan model dengan jawaban referensi.
- b. Efektivitas pendekatan *Chain-of-Thought* dibandingkan *Non-Chain-of-Thought* pada dataset IndoMMLU belum dievaluasi menggunakan pendekatan berbasis kemiripan teks.
- c. Pemanfaatan algoritma *Levenshtein Distance* dalam evaluasi akurasi jawaban ChatGPT pada domain bahasa masih relatif terbatas.

Penelitian ini mengusulkan rancang bangun aplikasi pengujian akurasi ChatGPT menggunakan dataset IndoMMLU sebagai sumber data utama. Dataset IndoMMLU diproses melalui tahapan *preprocessing* untuk menghasilkan dataset final yang difokuskan pada domain bahasa sehingga proses evaluasi menjadi lebih spesifik dan terkontrol. Dataset final tersebut digunakan untuk membandingkan dua pendekatan *prompting*, yaitu *Non-Chain-of-Thought* dan *Chain-of-Thought*. Evaluasi dilakukan terhadap narasi jawaban akhir yang dihasilkan ChatGPT dengan membandingkannya dengan narasi jawaban referensi menggunakan algoritma *Levenshtein Distance*. Hasil evaluasi tersebut digunakan untuk mengukur tingkat kesesuaian jawaban model berdasarkan kemiripan teks.

1.2 Rumusan Masalah

Rumusan permasalahan dalam penelitian ini adalah:

- a. Bagaimana merancang dan membangun sistem evaluasi otomatis untuk menguji akurasi jawaban ChatGPT pada soal *Multiple Choice Question* (MCQ) domain bahasa menggunakan dataset IndoMMLU?
- b. Bagaimana tingkat akurasi jawaban ChatGPT pada soal MCQ domain bahasa menggunakan dataset IndoMMLU yang telah melalui tahapan *preprocessing* berdasarkan pengukuran kemiripan teks menggunakan algoritma *Levenshtein Distance*?
- c. Bagaimana perbandingan efektivitas pendekatan *Chain-of-Thought* dan *Non-Chain-of-Thought* terhadap akurasi jawaban ChatGPT pada soal MCQ domain bahasa menggunakan dataset IndoMMLU berdasarkan pengukuran kemiripan teks menggunakan algoritma *Levenshtein Distance*?

1.3 Tujuan Penelitian

Tujuan penelitian ini adalah sebagai berikut:

- a. Merancang dan membangun sistem evaluasi otomatis untuk menguji akurasi jawaban ChatGPT pada soal MCQ domain bahasa menggunakan dataset IndoMMLU.
- b. Mengetahui tingkat akurasi jawaban ChatGPT pada soal *Multiple Choice Question* (MCQ) domain bahasa menggunakan dataset IndoMMLU yang telah melalui tahapan *preprocessing* berdasarkan pengukuran kemiripan teks menggunakan algoritma *Levenshtein Distance*.

- c. Mengetahui perbandingan efektivitas pendekatan *Chain-of-Thought* dan *Non-Chain-of-Thought* terhadap akurasi jawaban ChatGPT pada soal MCQ domain bahasa menggunakan dataset IndoMMLU berdasarkan pengukuran kemiripan teks menggunakan algoritma *Levenshtein Distance*.

1.4 Batasan Penelitian

Batasan penelitian ini adalah sebagai berikut:

- a. Dataset yang digunakan dibatasi pada dataset IndoMMLU tahun 2023 yang telah melalui tahapan *preprocessing* dan difokuskan pada soal *Multiple Choice Question* (MCQ) domain bahasa.
- b. Penelitian ini hanya menggunakan ChatGPT dengan model GPT-4o mini sebagai objek evaluasi. Penelitian tidak melakukan perbandingan terhadap *Large Language Model* (LLM) lain maupun model GPT versi lainnya sehingga hasil pengujian hanya merepresentasikan performa GPT-4o mini pada dataset IndoMMLU.
- c. Pendekatan *prompting* yang diterapkan dibatasi pada dua pendekatan, yaitu *Non-Chain-of-Thought* dan *Chain-of-Thought*.
- d. Metode evaluasi akurasi jawaban dibatasi menggunakan algoritma *Levenshtein Distance* untuk mengukur tingkat kemiripan antara narasi jawaban akhir yang dihasilkan model dan narasi jawaban referensi. Evaluasi tidak didasarkan pada kesesuaian pilihan opsi (A, B, C, atau D), tetapi pada tingkat kemiripan teks antara jawaban model dan jawaban referensi.

1.5 Manfaat Penelitian

Manfaat dari penelitian ini diharapkan mampu menyediakan sebuah sistem evaluasi otomatis yang terstruktur untuk menguji akurasi jawaban ChatGPT pada soal *Multiple Choice Question* (MCQ) domain bahasa menggunakan dataset IndoMMLU. Sistem yang dibangun dapat digunakan sebagai alat bantu evaluasi untuk menilai performa ChatGPT secara objektif dan terukur melalui pengukuran kemiripan teks berbasis algoritma *Levenshtein Distance*. Selain itu, sistem ini mendukung reproduktibilitas penelitian karena seluruh proses evaluasi dilakukan secara terintegrasi dalam satu aplikasi, sehingga dapat dimanfaatkan sebagai dasar evaluasi dan pengembangan lanjutan pemanfaatan LLM pada konteks pendidikan berbahasa Indonesia.

1.6 Sistematika Penulisan

Sistematika penulisan ini merupakan kebulatan seluruh materi penyusunan yang diungkapkan secara garis besar dan dibagi menjadi lima bab. Masing-masing bab terdiri dari beberapa sub bab. Adapun susunan sistematikanya adalah sebagai berikut:

BAB I

PENDAHULUAN

Dalam bab ini berisi tentang latar belakang masalah, rumusan masalah, tujuan penulisan, batasan masalah, manfaat penelitian, dan sistematika penulisan.

BAB II**TINJAUAN PUSTAKA**

Dalam bab ini berisi teori-teori yang berhubungan dengan penelitian ini yang menjadi dasar penyelesaian masalah dalam penelitian ini. Teori yang diambil dan dituliskan pada bab ini berupa pengertian dan definisi, serta kutipan-kutipan dari penelitian terdahulu.

BAB III**METODOLOGI PENELITIAN**

Dalam bab ini berisi penjelasan mengenai tahapan penelitian serta perancangan aplikasi pengujian akurasi jawaban ChatGPT menggunakan model GPT-4o mini yang akan dibangun. Perancangan aplikasi meliputi *use case diagram*, *activity diagram*, perancangan *user interface*, serta perancangan metode penelitian yang mencakup pembentukan *prompt* pengujian *Chain-of-Thought* dan *Non-Chain-of-Thought*, penerapan metode *Chain-of-Thought* dan *Non-Chain-of-Thought*, serta perhitungan akurasi menggunakan algoritma *Levenshtein Distance*.

BAB IV**HASIL DAN PEMBAHASAN**

Dalam bab ini berisi hasil dari implementasi aplikasi pengujian akurasi jawaban ChatGPT menggunakan model GPT-4o mini serta pembahasan terhadap sistem yang telah dikembangkan. Pembahasan meliputi implementasi sistem,

pengujian fungsional, hasil evaluasi akurasi, visualisasi hasil, serta perbandingan performa metode *Chain-of-Thought* dan *Non-Chain-of-Thought* berdasarkan perhitungan menggunakan algoritma *Levenshtein Distance*.

BAB V

PENUTUP

Dalam bab ini berisi kesimpulan dari hasil penelitian yang telah dilakukan serta saran yang diharapkan dapat menjadi bahan pertimbangan untuk pengembangan penelitian selanjutnya.

BAB II

TINJAUAN PUSTAKA

2.1 *State of the Art*

State of the Art dalam penelitian ini digunakan untuk mengkaji perkembangan terkini dalam evaluasi *Large Language Model* (LLM), strategi *prompting*, serta metode evaluasi akurasi jawaban berbasis kemiripan teks, sekaligus mengidentifikasi gap penelitian yang masih ada [20].

Penelitian sebelumnya menunjukkan bahwa evaluasi performa LLM, termasuk ChatGPT, pada soal MCQ umumnya masih dilakukan melalui *benchmarking* statis yang berfokus pada hasil akhir, tanpa didukung aplikasi evaluasi otomatis yang terstruktur dan mudah direproduksi [1]. Pemanfaatan dataset lokal seperti IndoMMLU tahun 2023 pada studi sebelumnya juga cenderung bersifat umum tanpa pemfokusan domain tertentu, sehingga analisis performa model pada domain bahasa Indonesia belum dikaji secara mendalam dan sistematis [7]. Pendekatan evaluasi akurasi jawaban LLM masih didominasi oleh pencocokan jawaban eksak atau penilaian manual, yang memiliki keterbatasan dalam menangkap variasi tekstual serta tingkat kemiripan jawaban yang secara semantik masih relevan [11]. Metode evaluasi berbasis kemiripan teks mulai dikaji sebagai alternatif yang lebih fleksibel pada tugas pemrosesan bahasa alami [13], namun penerapannya secara eksplisit pada evaluasi jawaban LLM untuk dataset pendidikan berbahasa Indonesia masih relatif terbatas.

Strategi *prompting* turut menjadi faktor penting yang memengaruhi kualitas jawaban LLM. Pendekatan *Chain-of-Thought* (CoT) dilaporkan mampu

meningkatkan kualitas penalaran dan akurasi jawaban pada berbagai domain, termasuk penilaian otomatis jawaban siswa, evaluasi medis, dan ujian profesional [6], [21]. Penelitian lain menunjukkan potensi peningkatan performa *zero-shot* dan *few-shot* melalui *fine-tuning* berbasis CoT [22]. CoT menunjukkan potensi yang signifikan, tetapi efektivitasnya pada konteks bahasa Indonesia masih terbatas dan belum dievaluasi secara terukur pada dataset IndoMMLU [10]. Penelitian terkait CoT juga cenderung berfokus pada eksperimen model secara terpisah tanpa integrasi ke dalam sistem evaluasi otomatis yang mencakup proses pengolahan data, pengujian model, dan perhitungan akurasi secara *end-to-end* [23].

Metode evaluasi kuantitatif berbasis kemiripan teks seperti algoritma *Levenshtein Distance* telah diterapkan secara luas pada berbagai bidang, termasuk pemrosesan bahasa, *fuzzy matching*, dan analisis perbedaan sekuens [2], [14], [24]. Meskipun efektivitas algoritma ini telah dibuktikan pada berbagai domain, pemanfaatannya sebagai metode evaluasi akurasi jawaban ChatGPT pada dataset pendidikan berbahasa Indonesia masih sangat terbatas dan belum diimplementasikan dalam bentuk aplikasi evaluasi yang terintegrasi.

Tabel 2.1 menyajikan ringkasan penelitian terdahulu yang berkaitan dengan evaluasi LLM, penerapan strategi *Chain-of-Thought*, serta penggunaan algoritma *Levenshtein Distance*. Ringkasan tersebut mencakup penulis, tahun, judul penelitian, metode yang digunakan, hasil utama, serta persamaan dan perbedaan dengan penelitian yang diusulkan untuk memetakan posisi penelitian yang diusulkan dan mengidentifikasi celah penelitian yang belum banyak dikaji.

Tabel 2. 1 *State of the Art*

No	Penulis / Tahun	Judul Artikel	Metode yang Digunakan	Hasil yang Diperoleh	Persamaan	Perbedaan
1	Koto et al., 2023	<i>Large Language Models Only Pass Primary School Exams in Indonesia: A Comprehensive Test on IndoMMLU</i>	Penyusunan <i>benchmark</i> IndoMMLU; evaluasi berbagai LLM (GPT-3.5, BLOOMZ, dll.) menggunakan soal pilihan ganda lintas jenjang pendidikan	GPT-3.5 hanya mampu lulus pada level sekolah dasar; performa menurun signifikan pada jenjang lebih tinggi dan pada soal bahasa serta budaya lokal	Penelitian ini dan studi Koto dkk. sama-sama berfokus pada evaluasi kinerja LLM pada soal pilihan ganda berbahasa Indonesia menggunakan dataset terstruktur untuk mengukur kemampuan pemahaman dan penalaran model.	Koto dkk. menitikberatkan pada pembangunan <i>benchmark</i> lintas jenjang pendidikan, sedangkan penelitian ini mengkaji pengaruh strategi <i>prompting</i> dan menilai akurasi jawaban LLM melalui pendekatan kemiripan teks secara lebih rinci.
2	Ji et al., 2025	<i>Evaluating ChatGPT-4's Performance on Oral and Maxillofacial Queries</i>	Evaluasi ChatGPT-4 pada soal <i>open-ended</i> dan pilihan ganda; perbandingan metode standar dan CoT; validasi oleh pakar medis	Penerapan CoT meningkatkan akurasi MCQ sebesar 3,1% dan memperbaiki struktur serta kelengkapan jawaban <i>open-ended</i>	Kedua penelitian sama-sama menganalisis dampak penggunaan CoT terhadap peningkatan kualitas jawaban LLM pada	Ji dkk. berfokus pada domain medis dengan validasi pakar, sedangkan penelitian ini berada pada domain evaluasi umum LLM dan menggunakan pendekatan evaluasi

No	Penulis / Tahun	Judul Artikel	Metode yang Digunakan	Hasil yang Diperoleh	Persamaan	Perbedaan
					pertanyaan berbasis pengetahuan.	otomatis berbasis kemiripan teks.
3	Zhu et al., 2025	<i>Assessing and Enhancing the Reliability of Chinese Large Language Models in Dental Implantology</i>	Evaluasi lima LLM Tiongkok menggunakan metrik <i>recall</i> dan <i>hallucination rate</i> pada 50 soal MCQ dan 50 soal <i>open-ended</i> ; penerapan CoT dan <i>Long-Text Modeling</i> (LTM); analisis statistik ANOVA dan <i>paired t-test</i>	Qwen 2.5 mencapai <i>recall</i> tertinggi pada MCQ (0.9060); CoT meningkatkan <i>recall</i> sebesar 0.0621 namun berpotensi meningkatkan <i>hallucination</i> ; LTM meningkatkan <i>recall</i> dan menurunkan <i>hallucination</i> secara signifikan	Penelitian Zhu et al. dan penelitian ini sama-sama mengevaluasi kinerja LLM pada soal pilihan ganda serta menganalisis pengaruh CoT terhadap akurasi jawaban.	Zhu et al. menggunakan metrik <i>recall</i> dan <i>hallucination rate</i> pada domain medis serta menerapkan <i>Long-Text Modeling</i> , sedangkan penelitian ini berfokus pada domain bahasa Indonesia dengan evaluasi otomatis berbasis <i>Levenshtein Distance</i> tanpa analisis <i>hallucination</i> .
4	Lee et al., 2024	<i>Applying Large Language Models and Chain-of-Thought for</i>	GPT-3.5 dan GPT-4 dengan <i>zero-shot</i> , <i>few-shot</i> , dan <i>Chain-of-Thought</i> (CoT); evaluasi akurasi penilaian jawaban esai menggunakan rubric	<i>Few-shot learning</i> meningkatkan akurasi sebesar 12,6%; CoT efektif ketika dikombinasikan dengan konteks soal dan rubrik; GPT-4	Kesamaan terletak pada pemanfaatan strategi CoT untuk meningkatkan kualitas keluaran LLM serta evaluasi	Lee dkk. mengarah pada penilaian otomatis jawaban esai menggunakan rubrik, sementara penelitian ini mengevaluasi kesesuaian jawaban LLM terhadap

No	Penulis / Tahun	Judul Artikel	Metode yang Digunakan	Hasil yang Diperoleh	Persamaan	Perbedaan
		<i>Automatic Scoring</i>		unggul dibanding GPT-3.5	jawaban berbasis teks.	jawaban acuan melalui pengukuran kemiripan teks tanpa rubrik penilaian manusia.
5	Ji et al., 2024	<i>Chain-of-Thought Improves Text Generation with Citations in Large Language Models</i>	Penerapan CoT <i>prompting</i> dan <i>Citation Insurance Mechanism</i> (CIM) pada enam LLM <i>open-source</i> menggunakan <i>benchmark</i> ALCE	CoT meningkatkan kualitas jawaban dan sitasi; kombinasi CoT dan CIM menghasilkan performa setara ChatGPT pada tugas generasi teks dengan sitasi	Kedua penelitian sama-sama mengkaji peran CoT dalam mendorong penalaran LLM yang lebih terstruktur dan meningkatkan kualitas keluaran.	Ji dkk. berfokus pada peningkatan kualitas generasi teks dan sitasi pada tugas <i>open-ended</i> , sedangkan penelitian ini menggunakan CoT untuk membandingkan akurasi jawaban ChatGPT pada soal MCQ berbasis kemiripan teks.
6	Chen et al., 2023	<i>When Do You Need Chain-of-Thought Prompting for ChatGPT?</i>	Evaluasi ChatGPT dengan tiga strategi <i>prompting</i> (tanpa instruksi, CoT <i>prompting</i> , dan strategi lain) pada berbagai <i>benchmark reasoning</i> seperti aritmatika dan	CoT secara signifikan meningkatkan akurasi GPT-3, namun pada ChatGPT CoT tidak selalu efektif; ChatGPT sering menghasilkan penalaran bertahap	Kedua penelitian membandingkan pendekatan <i>Chain-of-Thought</i> dan <i>Non-Chain-of-Thought</i> dalam mengevaluasi performa ChatGPT pada berbagai tugas	Chen et al. menguji tugas <i>reasoning</i> umum tanpa evaluasi kesesuaian teks, sedangkan penelitian ini menerapkan perbandingan CoT dan <i>Non-CoT</i> secara spesifik pada soal MCQ IndoMMLU

No	Penulis / Tahun	Judul Artikel	Metode yang Digunakan	Hasil yang Diperoleh	Persamaan	Perbedaan
			<i>commonsense reasoning</i>	secara spontan tanpa instruksi eksplisit		menggunakan pengukuran kemiripan teks.
7	Kim et al., 2023	<i>The COT COLLECTION: Improving Zero-shot and Few-shot Learning via Chain-of-Thought Fine-Tuning</i>	Pembangunan dataset COT COLLECTION berisi 1,84 juta <i>rationale</i> ; <i>fine-tuning</i> Flan-T5 (3B dan 11B) menggunakan CoT; evaluasi <i>zero-shot</i> dan <i>few-shot</i> pada <i>benchmark</i> BBH	<i>Fine-tuning</i> CoT meningkatkan akurasi <i>zero-shot</i> hingga +4,34% dan <i>few-shot</i> hingga +2,37%; model kecil mampu mendekati bahkan melampaui ChatGPT pada beberapa tugas	Penelitian ini dan Kim et al. sama-sama menegaskan peran CoT dalam meningkatkan kualitas penalaran dan akurasi keluaran LLM.	Kim et al. berfokus pada peningkatan kemampuan internal model melalui <i>fine-tuning</i> dan dataset <i>rationale</i> , sedangkan penelitian ini mengevaluasi dampak CoT sebagai strategi <i>prompting</i> tanpa melakukan pelatihan ulang model.
8	Mugaany et al. (2024)	<i>Evaluation of Large Language Model Performance and Reliability for</i>	Evaluasi kinerja ChatGPT (GPT-3.5) dalam menghasilkan sitasi dan DOI pada penulisan akademik, di mana dua peneliti memberikan <i>prompt</i> penulisan	Dari 102 sitasi yang dihasilkan ChatGPT, sebanyak 72,7% sitasi pada domain sains dan 76,6% pada humaniora benar-benar ada. Akurasi DOI pada domain sains sebesar	Sama-sama mengevaluasi performa <i>Large Language Model</i> dan menggunakan <i>Levenshtein Distance</i> sebagai	Penelitian Mugaany dkk. berfokus pada evaluasi sitasi dan referensi akademik berbahasa Inggris, tidak menggunakan format MCQ, tidak melibatkan dataset IndoMMLU, tidak

No	Penulis / Tahun	Judul Artikel	Metode yang Digunakan	Hasil yang Diperoleh	Persamaan	Perbedaan
		<i>Citations and References in Scholarly Writing: Cross-Disciplinary Study</i>	pendahuluan, lalu memverifikasi keberadaan sitasi, akurasi DOI, serta menghitung <i>Levenshtein Distance</i> antara DOI keluaran model dan DOI asli.	32,7%, sedangkan pada humaniora hanya 8,5%. Nilai <i>Levenshtein Distance</i> secara signifikan lebih tinggi pada domain humaniora, menunjukkan tingkat kesalahan string DOI yang lebih besar	ukuran kemiripan teks	membandingkan <i>Chain-of-Thought</i> dan <i>Non-Chain-of-Thought</i> , serta tidak membangun aplikasi evaluasi otomatis
9	Lind-Combs et al., 2023	<i>Comparing Levenshtein Distance and dynamic time warping in predicting listeners' judgments of accent distance</i>	Perbandingan <i>Levenshtein Distance</i> (<i>weighted</i> & <i>unweighted</i>) dan <i>Dynamic Time Warping</i> (DTW) untuk memprediksi persepsi jarak aksen berdasarkan penilaian 52 pendengar	<i>Weighted Levenshtein Distance</i> sedikit lebih unggul dibanding DTW dalam memprediksi persepsi jarak aksen; fonemik lebih dominan dibanding informasi akustik holistik	Kedua penelitian memanfaatkan <i>Levenshtein Distance</i> sebagai metrik objektif untuk merepresentasikan tingkat kemiripan terhadap suatu referensi linguistik.	Lind-Combs dkk. menerapkannya pada transkripsi fonem untuk memodelkan persepsi aksen manusia, sedangkan penelitian ini menggunakannya untuk mengevaluasi kecocokan jawaban ChatGPT pada soal MCQ tanpa melibatkan aspek persepsi atau akustik.

No	Penulis / Tahun	Judul Artikel	Metode yang Digunakan	Hasil yang Diperoleh	Persamaan	Perbedaan
10	Castells-Rufas, 2023	<i>GPU Acceleration of Levenshtein Distance Computation Between Long Strings</i>	Implementasi <i>Wavefront Alignment Algorithm</i> (WFA) berbasis GPU untuk mempercepat perhitungan edit <i>distance</i> pada <i>string</i> sangat panjang	Mencapai performa sangat tinggi hingga ratusan TCUPS untuk <i>string</i> dengan tingkat kemiripan tinggi; jauh melampaui metode sebelumnya	Penelitian ini dan Castells-Rufas sama-sama menempatkan algoritma <i>Levenshtein Distance</i> sebagai inti dalam proses evaluasi kemiripan antar <i>string</i> .	Castells-Rufas berfokus pada optimasi komputasi dan akselerasi GPU, sedangkan penelitian ini menitikberatkan pada pemanfaatan <i>Levenshtein Distance</i> sebagai alat evaluasi kualitas jawaban LLM.

Tabel 2.1 menunjukkan bahwa evaluasi akurasi ChatGPT pada konteks pendidikan berbahasa Indonesia masih memiliki keterbatasan dari sisi pendekatan evaluasi, pemanfaatan dataset lokal, serta integrasi sistem evaluasi otomatis. Penelitian sebelumnya umumnya memisahkan kajian strategi *prompting*, metode evaluasi berbasis kemiripan teks, dan pemanfaatan dataset IndoMMLU, tanpa mengombinasikan ketiga aspek tersebut dalam satu sistem evaluasi yang terstruktur. Kondisi tersebut menegaskan adanya celah penelitian yang melatarbelakangi penelitian ini, yaitu perancangan dan pembangunan aplikasi evaluasi otomatis untuk menguji dan membandingkan akurasi jawaban ChatGPT antara pendekatan *Non-Chain-of-Thought* dan *Chain-of-Thought* pada dataset IndoMMLU domain bahasa menggunakan algoritma *Levenshtein Distance*.

2.2 Tinjauan Teoritis

2.2.1 Large Language Model

Large Language Model (LLM) merupakan model bahasa skala besar dalam bidang *Natural Language Processing* (NLP) yang digunakan untuk memahami dan menghasilkan teks menyerupai bahasa manusia. Model ini mampu mengenali pola bahasa, seperti susunan kata dan makna kalimat, sehingga dapat menghasilkan respons yang sesuai dengan konteks. LLM banyak digunakan dalam berbagai aplikasi, seperti penerjemahan, menjawab pertanyaan, dan pembuatan teks otomatis. LLM umumnya dibangun menggunakan arsitektur *Transformer* yang mampu memproses data teks secara efisien melalui mekanisme *self-attention*, yaitu kemampuan untuk memahami hubungan antar kata dalam satu kalimat. Dibandingkan dengan metode sebelumnya seperti *Recurrent Neural Network*

(RNN), pendekatan ini lebih efektif dalam menangani kalimat panjang dan kompleks, sehingga mampu memahami hubungan kata meskipun jaraknya berjauhan dalam teks [25].

Proses pengembangan LLM dilakukan melalui dua tahap utama, yaitu *pre-training* dan *fine-tuning*. Pada tahap *pre-training*, model dilatih menggunakan data teks dalam jumlah besar untuk mempelajari pola umum bahasa. Setelah itu, pada tahap *fine-tuning*, model disesuaikan untuk tugas tertentu agar dapat memberikan hasil yang lebih spesifik. Dengan proses ini, LLM dapat digunakan dalam berbagai kebutuhan, seperti klasifikasi teks, penerjemahan, dan *question answering*. Seiring perkembangan teknologi, ukuran dan kemampuan LLM terus meningkat sehingga performanya menjadi semakin baik [26].

LLM juga memiliki beberapa keterbatasan. Model ini dapat menghasilkan informasi yang tidak sepenuhnya akurat (*hallucination*) serta berpotensi mengandung bias dari data pelatihan. Selain itu, keterbatasan LLM berupa kebutuhan sumber daya komputasi yang besar serta ketidakjelasan proses pengambilan keputusan membuat pengendalian keluaran model sangat bergantung pada strategi *prompting*. Kondisi tersebut menunjukkan bahwa tingkat akurasi dan keandalan model dapat bervariasi tergantung pada konteks penggunaannya [27].

2.2.2 ChatGPT sebagai Model *Pre-trained*

ChatGPT merupakan model berbasis *Generative Pre-trained Transformer* (GPT) yang dikembangkan oleh OpenAI untuk menghasilkan teks secara percakapan yang alami. Model ini dibangun melalui proses *pre-training* menggunakan data teks dalam jumlah besar, kemudian disempurnakan dengan

pendekatan *Reinforcement Learning from Human Feedback* (RLHF) agar mampu menghasilkan respons yang lebih relevan, aman, dan sesuai dengan preferensi manusia [28].

ChatGPT memiliki kemampuan utama dalam menghasilkan teks yang koheren, kontekstual, dan adaptif terhadap berbagai jenis instruksi. Model ini dapat digunakan dalam berbagai tugas, seperti menjawab pertanyaan, membantu penulisan, serta menyelesaikan permasalahan berbasis teks. Kinerjanya dipengaruhi oleh kualitas dan cakupan data pelatihan, sehingga hasil yang diberikan dapat bervariasi tergantung pada konteks dan kompleksitas input [29].

Pemanfaatan ChatGPT dalam bidang pendidikan menunjukkan potensi yang signifikan, terutama dalam mendukung pemahaman konsep dan pengembangan kemampuan berpikir tingkat tinggi. Meskipun demikian, model ini juga memiliki keterbatasan, seperti potensi menghasilkan informasi yang tidak akurat (*hallucination*), bias pada respons, serta kesulitan dalam memahami istilah yang jarang muncul. Hal ini menunjukkan bahwa kinerja model dapat berbeda-beda tergantung pada konteks penggunaan dan karakteristik input yang diberikan [29].

2.2.3 GPT-4o mini

GPT-4o mini merupakan model bahasa besar (*Large Language Model* atau LLM) yang dikembangkan oleh OpenAI dan diperkenalkan pada 18 Juli 2024 sebagai versi yang lebih ringan dari GPT-4o. Model ini dirancang untuk memberikan keseimbangan antara kemampuan penalaran, kecepatan pemrosesan, dan efisiensi biaya sehingga sesuai digunakan pada aplikasi yang membutuhkan pemanggilan model dalam jumlah besar melalui *Application Programming*

Interface (API). Menurut OpenAI, GPT-4o mini tetap mempertahankan kemampuan memahami instruksi, menghasilkan teks yang koheren, serta mendukung berbagai tugas pemrosesan bahasa alami dengan biaya yang lebih rendah dibandingkan GPT-4o [30].

GPT-4o mini merupakan bagian dari keluarga GPT-4o yang dibangun menggunakan pendekatan omnimodal, yaitu mampu memproses berbagai jenis masukan seperti teks, gambar, audio, dan video dalam satu model terpadu. Pendekatan tersebut memungkinkan peningkatan kemampuan dalam memahami konteks, mengikuti instruksi, serta menyelesaikan tugas penalaran dibandingkan generasi GPT sebelumnya. Evaluasi yang dilakukan OpenAI melalui *GPT-4o System Card* menunjukkan bahwa keluarga GPT-4o memiliki performa yang tinggi pada berbagai benchmark akademik dan tugas penalaran multibahasa [31].

OpenAI juga melaporkan bahwa GPT-4o mini memperoleh skor 82,0% pada benchmark Massive Multitask Language Understanding (MMLU). Hasil tersebut menunjukkan bahwa model ini memiliki kemampuan yang kompetitif dalam memahami pengetahuan umum, menyelesaikan soal akademik, dan mengikuti instruksi. Selain memiliki performa yang baik, GPT-4o mini menawarkan biaya penggunaan API yang lebih rendah sehingga sesuai digunakan pada penelitian yang melibatkan ribuan proses inferensi, seperti evaluasi jawaban terhadap dataset IndoMMLU [30].

Sejumlah penelitian mulai menunjukkan bahwa GPT-4o mini memiliki performa yang baik pada berbagai tugas pemrosesan bahasa alami. Favero dkk. mengembangkan sistem chatbot akademik berbasis *Retrieval-Augmented*

Generation (RAG) dan menemukan bahwa GPT-4o mini menghasilkan jawaban yang lebih akurat dibandingkan model pembanding pada tugas *question answering*, penyusunan materi presentasi, dan pembuatan naskah podcast akademik. Penelitian tersebut menunjukkan bahwa GPT-4o mini mampu menghasilkan respons yang akurat, koheren, dan relevan terhadap konteks dokumen yang diberikan [32].

Penelitian lain yang dilakukan oleh Thelwall mengevaluasi GPT-4o dan GPT-4o mini terhadap lebih dari 107.000 artikel ilmiah untuk menilai kualitas penelitian. Hasil penelitian menunjukkan bahwa GPT-4o memiliki performa sedikit lebih tinggi dibandingkan GPT-4o mini, namun GPT-4o mini tetap memberikan hasil yang kompetitif dengan biaya komputasi yang lebih rendah. Temuan tersebut menunjukkan bahwa GPT-4o mini dapat menjadi alternatif yang efisien untuk berbagai tugas evaluasi berbasis bahasa alami [33].

2.2.4 *Prompting* dalam *Large Language Model*

Prompting merupakan metode interaksi dengan *Large Language Model* (LLM) melalui pemberian instruksi dalam bentuk teks untuk menghasilkan output yang diinginkan. Kualitas respons yang dihasilkan sangat dipengaruhi oleh bagaimana *prompt* disusun. *Prompt* yang jelas, spesifik, dan terarah cenderung menghasilkan jawaban yang lebih akurat dan relevan, sedangkan *prompt* yang ambigu dapat menyebabkan penurunan kualitas output [34].

Secara umum, terdapat dua pendekatan utama dalam *prompting*, yaitu *Non-Chain-of-Thought* dan *Chain-of-Thought*. Pendekatan *Non-Chain-of-Thought* meminta model untuk memberikan jawaban secara langsung tanpa penjelasan tambahan. Sebaliknya, *Chain-of-Thought* mendorong model untuk menghasilkan

penalaran secara bertahap sebelum memberikan jawaban akhir, sehingga membantu model dalam menyelesaikan tugas yang lebih kompleks [35].


Perancangan *prompt* menjadi faktor penting dalam pemanfaatan LLM karena secara langsung memengaruhi performa model dalam berbagai tugas NLP. Strategi *prompting* yang tepat dapat meningkatkan kemampuan model dalam memahami konteks serta menghasilkan respons yang lebih konsisten dan informatif [36]

2.2.5 Chain-of-Thought dan Non-Chain-of-Thought Prompting

Chain-of-Thought (CoT) merupakan teknik prompting yang dirancang untuk mendorong *Large Language Model* (LLM) menghasilkan proses penalaran sebelum memberikan jawaban akhir. Teknik ini memungkinkan model memecahkan suatu permasalahan menjadi beberapa langkah yang saling berkaitan sehingga proses penyelesaian dapat dilakukan secara lebih sistematis. Penelitian Wei *et al.* menunjukkan bahwa pendekatan CoT mampu meningkatkan kemampuan penalaran model pada berbagai tugas, seperti penalaran aritmatika, *commonsense reasoning*, dan *symbolic reasoning*, terutama pada model bahasa berukuran besar [35].

Cara kerja CoT dilakukan dengan menambahkan instruksi pada *prompt* agar model menghasilkan langkah-langkah penalaran sebelum memberikan jawaban. Penerapan CoT dapat dilakukan melalui dua pendekatan, yaitu *Few-shot Chain-of-Thought* dan *Zero-shot Chain-of-Thought*. *Few-shot CoT* memberikan beberapa contoh soal beserta proses penalarannya sebagai panduan bagi model, sedangkan *Zero-shot CoT* tidak menggunakan contoh, tetapi hanya menambahkan instruksi

sederhana, seperti "*Let's think step by step*", sehingga model terdorong menghasilkan penalaran secara bertahap [37] Perbedaan antara *standard prompting*, *Few-shot CoT*, *Zero-shot*, dan *Zero-shot CoT* ditunjukkan pada Gambar 2.1.



Gambar 2. 1 Perbandingan *Standard Prompting*, *Few-shot CoT*, *Zero-shot*, dan *Zero-shot CoT*

Sumber: Kojima et al. (2023)

Gambar 2.1 menunjukkan bahwa pada *standard prompting*, model memberikan jawaban secara langsung tanpa menjelaskan proses berpikir. *Few-shot CoT* menghasilkan jawaban melalui contoh penalaran yang diberikan pada *prompt*. Sementara itu, *Zero-shot CoT* menghasilkan proses penalaran hanya dengan tambahan instruksi tanpa memerlukan contoh sebelumnya. Pendekatan ini terbukti mampu meningkatkan kemampuan penalaran model dibandingkan *standard prompting* pada berbagai tugas logika dan penalaran [37]

Penggunaan CoT memiliki beberapa kelebihan, yaitu mampu meningkatkan kemampuan penalaran model, memperjelas hubungan antar informasi, serta membantu model menyelesaikan permasalahan yang membutuhkan beberapa

tahapan penyelesaian [6], [35]. Meskipun demikian, efektivitas CoT tetap dipengaruhi oleh kualitas *prompt*, jenis tugas yang diberikan, dan kemampuan model dalam menghasilkan penalaran yang konsisten. Kesalahan pada satu tahap penalaran juga dapat memengaruhi jawaban akhir yang dihasilkan [38].

Pendekatan *Non-Chain-of-Thought* merupakan pendekatan prompting yang menghasilkan jawaban secara langsung tanpa menampilkan proses penalaran. Model hanya menerima pertanyaan atau instruksi, kemudian memberikan hasil akhir tanpa menjelaskan langkah-langkah penyelesaiannya. Pendekatan ini menghasilkan respons yang lebih singkat dan efisien, tetapi kurang mampu menangani tugas yang memerlukan penalaran bertahap dibandingkan CoT. Oleh karena itu, Non-CoT sering digunakan sebagai *baseline* untuk membandingkan pengaruh penggunaan *Chain-of-Thought* terhadap kualitas jawaban yang dihasilkan model [35], [37].

2.2.6 Multiple Choice Question (MCQ) dalam Evaluasi LLM

Multiple Choice Question (MCQ) merupakan format evaluasi yang terdiri dari satu pertanyaan dengan beberapa pilihan jawaban, di mana hanya terdapat satu jawaban yang benar. Format ini banyak digunakan dalam sistem evaluasi terstruktur karena memungkinkan penilaian dilakukan secara objektif dan konsisten terhadap kemampuan pemahaman suatu model atau peserta uji [9]. MCQ umumnya tersusun atas pertanyaan utama dan sejumlah opsi jawaban, yang terdiri dari satu jawaban benar dan beberapa opsi pengecoh (*distractor*). Distraktor berfungsi untuk menguji kemampuan dalam membedakan jawaban yang paling sesuai di antara pilihan yang

tersedia. Format ini juga digunakan dalam berbagai benchmark evaluasi model bahasa karena memiliki struktur yang mudah distandarisasi [39].

Penggunaan MCQ dalam evaluasi model bahasa berkaitan dengan kemampuannya dalam mengukur pemahaman berbasis pilihan terbatas (*closed-set evaluation*), di mana model diminta memilih jawaban paling tepat dari opsi yang diberikan. Pendekatan ini banyak digunakan dalam pengujian kemampuan dasar model bahasa pada berbagai domain pengetahuan [8].

2.2.7 Dataset IndoMMLU

Dataset IndoMMLU merupakan dataset yang dikembangkan untuk mengevaluasi kemampuan *Large Language Model* (LLM) dalam memahami bahasa dan pengetahuan pada konteks Indonesia. Pengembangan dataset ini bertujuan untuk menyediakan *benchmark* yang lebih sesuai dengan karakteristik bahasa Indonesia, karena sebagian besar dataset evaluasi sebelumnya masih didominasi oleh bahasa Inggris seperti MMLU, sehingga kurang merepresentasikan kemampuan model dalam konteks lokal [1].

IndoMMLU dirilis pada tahun 2023 terdiri dari sekitar 14.906 soal pilihan ganda yang mencakup 63 domain pengetahuan. Setiap soal disusun dalam format *Multiple Choice Question* (MCQ) dengan satu pertanyaan utama dan beberapa opsi jawaban, di mana hanya terdapat satu jawaban yang benar. Domain yang tercakup meliputi berbagai bidang seperti matematika, sains, sosial, humaniora, serta

pengetahuan umum dengan tingkat kesulitan yang bervariasi untuk menguji kemampuan model secara menyeluruh [1].

Secara umum, IndoMMLU dirancang untuk menguji kemampuan pemahaman dan penalaran model bahasa dalam konteks bahasa Indonesia, bukan hanya sekadar mengenali pola teks. Hal ini menjadikan dataset ini sebagai salah satu benchmark penting dalam evaluasi kemampuan LLM pada bahasa Indonesia yang termasuk dalam kategori low-resource language. Informasi terkait IndoMMLU juga dijelaskan sebagai dataset evaluasi yang digunakan untuk mengukur performa model bahasa pada konteks bahasa Indonesia secara lebih spesifik dan terstruktur. Dataset ini mencakup berbagai bidang pengetahuan yang merepresentasikan materi pendidikan formal, sehingga dapat digunakan untuk mengukur kemampuan model dalam berbagai tingkat kompleksitas soal. Dengan struktur yang berbasis pilihan ganda, IndoMMLU memungkinkan proses evaluasi dilakukan secara konsisten dan terstandarisasi pada berbagai model bahasa [40].

2.2.8 Evaluasi Akurasi Jawaban *Large Language Model*

Evaluasi akurasi jawaban pada *Large Language Model* (LLM) merupakan proses untuk mengukur kesesuaian antara output yang dihasilkan model dan jawaban referensi yang telah ditetapkan. Proses ini digunakan untuk menilai tingkat ketepatan respons model terhadap data acuan pada suatu tugas tertentu [19].

Metode evaluasi berbasis pencocokan langsung (*exact match*) digunakan untuk membandingkan kesamaan teks antara jawaban model dan jawaban referensi secara langsung. Pendekatan ini mudah diterapkan, tetapi memiliki keterbatasan

karena tidak mampu menangani variasi penulisan yang memiliki makna serupa, sehingga perbedaan bentuk teks dapat memengaruhi hasil penilaian [41].

Evaluasi jawaban berbasis teks juga menggunakan pendekatan kemiripan teks (*text similarity*) yang mengukur tingkat kesesuaian antara dua teks berdasarkan struktur, pola kata, maupun representasi linguistik. Pendekatan ini memberikan penilaian yang lebih fleksibel dibandingkan pencocokan eksak karena mempertimbangkan variasi ekspresi bahasa [42].

Pendekatan evaluasi modern pada LLM tidak hanya berfokus pada kesamaan bentuk teks, tetapi juga mempertimbangkan aspek konsistensi dan reliabilitas jawaban model pada berbagai input. Hal ini penting karena model bahasa dapat menghasilkan variasi respons meskipun diberikan pertanyaan yang serupa [19].

2.2.9 Algoritma *Levenshtein Distance*

Levenshtein Distance atau *edit distance* merupakan metode yang digunakan untuk mengukur tingkat perbedaan antara dua buah *string* berdasarkan jumlah minimum operasi edit yang diperlukan agar satu *string* dapat diubah menjadi *string* lainnya. Metode ini banyak dimanfaatkan pada pengolahan teks karena mampu merepresentasikan perbedaan karakter secara terukur dan sistematis [15], [16].

Operasi edit yang diperbolehkan pada algoritma *Levenshtein Distance* terdiri atas tiga jenis, yaitu *insertion* (penyisipan satu karakter), *deletion* (penghapusan satu karakter), dan *substitution* (penggantian satu karakter dengan karakter lain). Setiap operasi edit diberikan biaya sebesar satu, sedangkan karakter

yang identik tidak memerlukan operasi tambahan sehingga biayanya bernilai nol [16].

Perhitungan *Levenshtein Distance* umumnya diselesaikan menggunakan pendekatan *dynamic programming* melalui algoritma *Wagner–Fischer*. Algoritma ini membentuk sebuah matriks dua dimensi berukuran $(m + 1) \times (n + 1)$, dengan m menyatakan panjang *string* sumber s dan n menyatakan panjang *string* target t . Setiap elemen matriks $lev(i, j)$ menyimpan nilai jarak edit minimum antara prefiks sepanjang i karakter dari *string* s dan prefiks sepanjang j karakter dari *string* t . Kompleksitas waktu algoritma ini adalah $O(m \times n)$ [16].

Secara matematis, *Levenshtein Distance* dirumuskan sebagai berikut [17]:

$$lev(i, j) = \begin{cases} i, & \text{jika } j = 0 \\ j, & \text{jika } i = 0 \\ lev(i - 1, j - 1), & \text{jika } s[i] = t[j] \\ 1 + \min \{lev(i - 1, j), lev(i, j - 1), lev(i - 1, j - 1)\}, & \text{jika } s[i] \neq t[j] \end{cases} \quad (2.1)$$

Keterangan:

- a. $lev(i, j)$ menyatakan jarak edit minimum antara prefiks pertama sepanjang i karakter dari *string* s dan prefiks pertama sepanjang j karakter dari *string* t .
- b. Kondisi $lev(i, j) = i$ berlaku ketika *string* target t kosong, sehingga seluruh karakter pada *string* sumber s harus dihapus melalui i operasi *deletion*.
- c. Kondisi $lev(i, j) = j$ berlaku ketika *string* sumber s kosong, sehingga seluruh karakter pada *string* target t harus disisipkan melalui j operasi *insertion*.

- d. Jika $s[i] = t[j]$, tidak diperlukan operasi edit tambahan karena kedua karakter identik.
- e. Jika $s[i] \neq t[j]$, dipilih satu operasi edit dengan biaya minimum dari tiga kemungkinan, yaitu *deletion*, *insertion*, atau *substitution*.

Nilai akhir *Levenshtein Distance* diperoleh dari $lev(m, n)$, dengan $m = len(s)$ dan $n = len(t)$.

Nilai *Levenshtein Distance* bersifat absolut sehingga kurang representatif untuk menyatakan tingkat kemiripan apabila panjang *string* berbeda. Oleh sebab itu, nilai tersebut dinormalisasi agar menghasilkan skor *similarity* dalam rentang 0 sampai 1. Normalisasi dilakukan dengan membagi nilai jarak edit terhadap panjang *string* terpanjang, kemudian mengurangkannya dari satu, sehingga diperoleh rumus sebagai berikut [17]:

$$Similarity(s, t) = 1 - \frac{lev(m, n)}{\max(m, n)} \quad (2.2)$$

Keterangan:

- a. s merupakan *string* pertama (misalnya jawaban sistem).
- b. t merupakan *string* kedua (misalnya jawaban acuan atau *ground truth*).
- c. $lev(m, n)$ adalah nilai *Levenshtein Distance* akhir antara *string* s dan t .
- d. $\max(m, n)$ menyatakan panjang *string* terpanjang yang digunakan sebagai faktor normalisasi.
- e. Nilai *similarity* sebesar 1 menunjukkan kedua *string* identik, sedangkan nilai yang mendekati 0 menunjukkan perbedaan yang semakin besar.

Proses evaluasi pada dataset yang terdiri dari banyak data tidak hanya menghasilkan nilai *similarity* untuk setiap pasangan string, tetapi juga dapat direkap untuk memperoleh gambaran tingkat kemiripan model terhadap keseluruhan data pengujian. Rekapitulasi tersebut dilakukan dengan menghitung rata-rata seluruh nilai *similarity* yang diperoleh. Secara matematis dirumuskan sebagai berikut [38]:

$$Similarity_{avg} = \frac{1}{N} \sum_{i=1}^N similarity_i \quad (2.3)$$

Keterangan:

- a. N merupakan jumlah data pengujian.
- b. $similarity_i$ merupakan nilai *similarity* pada data ke- i

Nilai *Average Similarity* merepresentasikan tingkat kemiripan jawaban model terhadap jawaban referensi secara keseluruhan pada seluruh dataset pengujian.

Algoritma *Levenshtein Distance* beserta bentuk normalisasinya banyak digunakan pada berbagai aplikasi, seperti *spell checking*, *autocorrect*, deteksi plagiarisme, pencocokan teks (*string matching*), serta evaluasi akurasi pada sistem pemrosesan bahasa alami [15], [18].

2.2.10 Penerapan *Levenshtein Distance* dalam Evaluasi Teks

Levenshtein Distance telah diterapkan secara luas dalam berbagai domain pengolahan teks, termasuk analisis kemiripan antara judul dan abstrak publikasi ilmiah yang dihasilkan oleh *Large Language Model* (LLM) dengan versi aslinya [43]. Dalam evaluasi jawaban LLM, algoritma ini relevan karena mampu mengukur kemiripan teks secara kuantitatif melalui jumlah operasi edit minimal (*insertion*,

deletion, substitution) yang diperlukan untuk menyamakan output model dengan teks referensi, sehingga menghasilkan skor jarak yang objektif.

Algoritma ini dipilih dalam penelitian ini karena efisiensi komputasinya yang tinggi dan kesederhanaan implementasinya, yang memungkinkan pemrosesan cepat pada dataset berukuran sedang hingga besar. Namun, karena hanya menangkap perbedaan sintaksis, *Levenshtein Distance* memiliki keterbatasan dalam mendeteksi kesamaan semantik. Oleh karena itu, penggunaannya sebaiknya dikombinasikan dengan metrik berbasis semantik untuk mendapatkan evaluasi yang lebih lengkap dan akurat [19].

BAB III

METODOLOGI PENELITIAN

3.1 Data dan Pengumpulan Data

Penelitian ini menggunakan data sekunder yang bersumber dari dataset IndoMMLU (*Indonesian Massive Multitask Language Understanding*) yang diperkenalkan oleh Koto et al. pada tahun 2023 dalam penelitian berjudul “*Large Language Models Only Pass Primary School Exams in Indonesia: A Comprehensive Test on IndoMMLU*”. Dataset ini dirancang sebagai benchmark untuk mengevaluasi kemampuan *Large Language Model* (LLM) dalam memahami dan menyelesaikan soal berbasis bahasa Indonesia dalam berbagai domain pengetahuan.

Penggunaan IndoMMLU dipilih karena menyediakan soal berbahasa Indonesia yang sesuai dengan fokus penelitian, sehingga dapat digunakan untuk mengevaluasi kemampuan model dalam memahami dan menghasilkan jawaban secara tekstual.

Dataset IndoMMLU tahun 2023 terdiri dari soal berbentuk *Multiple Choice Question* (MCQ) yang mencakup berbagai domain. Namun, dalam penelitian ini data tidak digunakan secara keseluruhan, melainkan difokuskan pada domain bahasa sesuai dengan tujuan penelitian. Oleh karena itu, dilakukan proses seleksi dan pengolahan data (*preprocessing*) untuk menghasilkan dataset final penelitian. Adapun Struktur data yang digunakan dalam penelitian ini ditunjukkan pada Tabel 3.1.

Tabel 3. 1 Struktur Data Dataset Final Penelitian

No	Nama Data	Sumber	Keterangan
1	nomor	IndoMMLU	Penanda urutan soal
2	subject	IndoMMLU	Penanda domain soal, digunakan untuk memfilter domain bahasa
3	soal	IndoMMLU	Teks pertanyaan pilihan ganda
4	jawaban	IndoMMLU	Opsi jawaban pilihan ganda
5	kunci	IndoMMLU	Penanda jawaban benar dalam bentuk A/B/C/D/E
6	Jawaban_benar_teks	Hasil <i>preprocessing</i>	Teks jawaban benar hasil ekstraksi otomatis berdasarkan kolom kunci

Kolom *jawaban_benar_teks* bukan merupakan bagian dari dataset asli IndoMMLU, melainkan dihasilkan melalui tahap *preprocessing* dengan mencocokkan nilai pada kolom *kunci* dengan opsi jawaban yang tersedia. Proses ini dilakukan menggunakan skrip pemrograman pada tahap awal pengolahan data untuk menghasilkan representasi teks dari jawaban benar yang digunakan sebagai referensi dalam proses evaluasi. Setelah dilakukan *preprocessing*, dataset difilter berdasarkan domain bahasa sehingga diperoleh sebanyak 6.712 data. Dari dataset tersebut, sebanyak 900 data digunakan dalam proses pengujian model dengan berbagai skenario pengujian. Data yang digunakan dalam penelitian ini tidak dibagi ke dalam data latih dan data uji, karena model yang digunakan bersifat *pre-trained*, sehingga tidak memerlukan proses pelatihan ulang (*training*) pada dataset penelitian.

Metode pengumpulan data dalam penelitian ini dilakukan melalui tahapan berikut:

a. Studi Literatur

Studi literatur dilakukan untuk mengkaji penelitian terdahulu yang berkaitan dengan evaluasi *Large Language Model* (LLM), teknik *prompting*

seperti *Chain-of-Thought* (CoT), serta metode evaluasi berbasis kesamaan teks, khususnya algoritma *Levenshtein Distance*. Hasil studi ini digunakan sebagai dasar dalam perancangan metode penelitian.

b. Akuisisi Dataset

Dataset IndoMMLU diperoleh dari repositori resmi yang disediakan oleh Koto et al. melalui platform GitHub sebagai bagian dari penelitian berjudul *Large Language Models Only Pass Primary School Exams in Indonesia: A Comprehensive Test on IndoMMLU*. Dataset ini dirilis pada tahun 2023 dengan repositori yang tercatat dipublikasikan pada 8 Oktober 2023 dan digunakan sebagai data utama penelitian karena menyediakan kumpulan soal pilihan ganda berbahasa Indonesia yang dirancang sebagai benchmark evaluasi *Large Language Model* (LLM), sehingga relevan untuk mengukur performa model GPT-40 mini dalam memahami dan menghasilkan jawaban dalam konteks bahasa.

c. *Preprocessing* Dataset

Tahap *preprocessing* dilakukan untuk menyesuaikan dataset dengan kebutuhan penelitian, yang meliputi:

- 1) Pemfilteran data berdasarkan domain bahasa
- 2) Seleksi kolom yang relevan
- 3) Transformasi data, termasuk ekstraksi jawaban benar ke dalam bentuk teks

Hasil dari tahap ini adalah dataset final yang digunakan sebagai input dalam proses evaluasi model.

3.2 Analisis Kebutuhan Sistem

Analisis kebutuhan sistem merupakan tahapan awal dalam pengembangan sistem yang bertujuan untuk mengidentifikasi dan mendefinisikan kebutuhan yang harus dipenuhi oleh sistem agar dapat berjalan sesuai dengan tujuan penelitian. Tahapan ini mencakup identifikasi kebutuhan fungsional dan non-fungsional yang berkaitan dengan proses pengujian akurasi jawaban ChatGPT menggunakan model GPT-4o mini terhadap dataset IndoMMLU menggunakan algoritma *Levenshtein Distance*. Analisis kebutuhan sistem dilakukan untuk memastikan bahwa sistem yang dibangun mampu mendukung proses evaluasi secara otomatis, objektif, dan terstruktur sesuai dengan kebutuhan pengguna.

3.2.1 Analisis Kebutuhan Fungsional

Analisis kebutuhan fungsional dilakukan untuk mengidentifikasi seluruh fungsi yang dapat dilakukan oleh aplikasi pengujian akurasi ChatGPT menggunakan model GPT-4o mini. Analisis ini menjadi dasar dalam perancangan sistem agar fitur yang dikembangkan sesuai dengan kebutuhan pengguna. Aplikasi ini dikembangkan sebagai alat bantu penelitian untuk melakukan evaluasi kemampuan Large Language Model (LLM), khususnya dalam memahami dan menjawab soal berbasis bahasa Indonesia maupun bahasa daerah.

Pengguna sistem merupakan peneliti, mahasiswa, akademisi, atau pihak yang melakukan evaluasi terhadap kemampuan model bahasa dalam memahami berbagai konteks bahasa. Pengguna memanfaatkan sistem untuk melakukan pengujian akurasi ChatGPT menggunakan metode *Non-Chain-of-Thought* (Non-CoT) dan *Chain-of-Thought* (CoT), serta menganalisis hasil evaluasi berdasarkan

nilai *similarity* menggunakan algoritma *Levenshtein Distance*. Sistem tidak menerapkan mekanisme autentikasi sehingga pengguna dapat mengakses fitur aplikasi secara anonim.

a. Pengguna (Anonim)

1. Pengguna dapat mengunduh dataset IndoMMLU sebagai dataset bawaan yang digunakan dalam proses pengujian.
2. Pengguna dapat mengunduh *template* dataset sebagai acuan format data yang dapat digunakan pada proses pengunggahan dataset.
3. Pengguna dapat mengunggah dataset pengujian ke dalam sistem.
4. Pengguna dapat menambahkan data baru ke dalam dataset yang telah diunggah.
5. Pengguna dapat menghapus data pada dataset yang tersedia.
6. Pengguna dapat menjalankan proses pengujian akurasi jawaban ChatGPT menggunakan metode *Non-Chain-of-Thought* dan *Chain-of-Thought*.
7. Pengguna dapat melihat hasil pengujian akurasi dalam bentuk tabel perbandingan yang memuat nomor, soal, jawaban referensi, jawaban Non-CoT, nilai Non-CoT, jawaban CoT, dan nilai CoT.
8. Pengguna dapat melihat riwayat pengujian yang telah dilakukan beserta informasi hasil pengujian yang tersimpan pada sistem.
9. Pengguna dapat melihat visualisasi hasil evaluasi dalam bentuk grafik perbandingan metode *Non-Chain-of-Thought* dan *Chain-of-Thought*.

10. Pengguna dapat melihat laporan hasil evaluasi serta mengunduh laporan dalam format Excel dan PDF.

3.2.2 Analisis Kebutuhan Non-Fungsional

Kebutuhan non-fungsional merupakan kebutuhan pendukung yang berkaitan dengan spesifikasi perangkat keras (*hardware*) dan perangkat lunak (*software*) yang digunakan agar sistem dapat berjalan dengan optimal. Kebutuhan ini tidak berhubungan langsung dengan fungsi utama sistem, namun berperan penting dalam mendukung performa, stabilitas, dan keandalan sistem evaluasi.

- a. Perangkat keras yang digunakan dalam penelitian ini adalah:
 - 1) Laptop *Lenovo V14 G2 ALC*
 - 2) *Processor AMD Ryzen 7 5700U with Radeon Graphics* (1.80 GHz)
 - 3) RAM 8 GB
 - 4) Media penyimpanan SSD 512 GB
- b. Perangkat lunak yang digunakan dalam pengembangan dan pengujian sistem ini adalah:
 - 1) Sistem operasi *Windows 10*
 - 2) *Web browser Google Chrome*
 - 3) *Code editor Visual Studio Code*
 - 4) Bahasa pemrograman PHP dengan framework Laravel digunakan sebagai fullstack dalam membangun antarmuka pengguna, mengelola alur sistem, melakukan *preprocessing* data, menjalankan proses pengujian GPT menggunakan metode *Chain-of-Thought* (CoT) dan *Non-Chain-of-Thought* (Non-CoT), mengimplementasikan algoritma

Levenshtein Distance untuk menghitung tingkat kemiripan jawaban, serta menampilkan hasil pengujian.

- 5) Laravel File Storage digunakan untuk menyimpan dataset, hasil pengujian, dan riwayat pengujian yang dihasilkan sistem.
- 6) OpenAI API Key digunakan sebagai kredensial autentikasi untuk mengakses layanan OpenAI API dalam menjalankan proses pengujian model GPT-4o mini.

3.2.3 Analisis Kebutuhan Antarmuka Pengguna (*User Interface*)

Analisis kebutuhan antarmuka pengguna dilakukan untuk mengidentifikasi kebutuhan tampilan yang digunakan oleh admin dalam berinteraksi dengan sistem evaluasi akurasi ChatGPT. Antarmuka dirancang agar mampu mendukung seluruh proses evaluasi secara jelas, terstruktur, dan mudah digunakan. Berikut merupakan kebutuhan Antarmuka Pengguna pada sistem ini.

a. Karakteristik Antarmuka Sistem.

Sistem dirancang dengan memperhatikan desain antarmuka sebagai berikut:

1. Kesederhanaan: Tampilan sistem dibuat sederhana agar mudah digunakan dalam proses evaluasi
2. Konsistensi: Penggunaan warna, font, dan komponen antarmuka seragam pada setiap halaman
3. Navigasi: Penggunaan menu navigasi untuk mempermudah perpindahan antar halaman dalam sistem

b. Spesifikasi Halaman Antarmuka

Berdasarkan kebutuhan fungsional, berikut adalah rincian halaman antarmuka yang akan dikembangkan:

1. Halaman Utama

Menampilkan informasi umum mengenai sistem serta menyediakan navigasi menuju fitur-fitur yang tersedia pada sistem evaluasi ChatGPT.

2. Halaman Dataset

Menyediakan fitur pengelolaan dataset pengujian yang digunakan untuk proses pengujian. Halaman ini menyediakan fitur pengunduhan dataset IndoMMLU, pengunggahan dataset, penambahan data baru, serta penghapusan data yang tidak diperlukan. Halaman ini juga menyediakan *template* format dataset yang dapat diunduh sebagai acuan dalam penyusunan dataset pengujian. *Template* tersebut memungkinkan pengguna menggunakan dataset lain selain IndoMMLU dengan ketentuan format data yang sesuai dengan standar sistem.

3. Halaman Proses Pengujian

Menyediakan fitur untuk menjalankan proses pengujian akurasi ChatGPT menggunakan metode *Non-Chain-of-Thought* dan *Chain-of-Thought*, serta menampilkan status proses atau progress bar untuk memberikan informasi perkembangan pengujian yang sedang berlangsung.

4. Halaman Hasil Pengujian

Menampilkan hasil pengujian dalam bentuk tabel perbandingan yang berisi nomor, soal, jawaban referensi, jawaban Non-CoT, nilai Non-CoT, jawaban CoT, dan nilai CoT. Halaman ini juga menampilkan nilai rata-rata akurasi dari masing-masing metode yang diuji. Selain itu, halaman ini menyediakan riwayat pengujian yang telah dilakukan sehingga pengguna dapat melihat kembali hasil pengujian sebelumnya beserta detail hasil pengujiannya.

5. Halaman Visualisasi

Menampilkan grafik perbandingan hasil pengujian antara metode *Non-Chain-of-Thought* dan *Chain-of-Thought* untuk mempermudah analisis performa model.

6. Halaman Laporan

Menyediakan tampilan laporan hasil pengujian serta fitur untuk mengunduh hasil laporan dalam bentuk file Excel dan PDF sebagai dokumentasi hasil pengujian.


3.3 Perancangan Sistem

Perancangan sistem merupakan tahap penting dalam penelitian ini yang bertujuan untuk memberikan gambaran mengenai bagaimana aplikasi pengujian akurasi ChatGPT menggunakan model GPT-4o mini akan dibangun dan dioperasikan. Tahap perancangan ini mencakup penyusunan arsitektur sistem, pemodelan menggunakan *Unified Modeling Language* (UML), serta perancangan

user interface. Adapun rincian perancangan sistem dalam penelitian ini dijelaskan sebagai berikut:

3.3.1 Arsitektur Sistem

Arsitektur sistem pada penelitian ini dapat dilihat pada Gambar 3.1 yang menggambarkan struktur dan alur kerja aplikasi pengujian akurasi model GPT-4o mini secara menyeluruh, mulai dari proses pengolahan data, pembentukan *prompt*, pengiriman gabungan *prompt* dan soal ke model melalui OpenAI API, hingga penyajian hasil evaluasi. Arsitektur sistem dirancang untuk mengintegrasikan proses *preprocessing* dataset, pembentukan *prompt* pengujian menggunakan pendekatan *Non-Chain-of-Thought (Non-CoT)* dan *Chain-of-Thought (CoT)*, interaksi dengan model GPT-4o mini, perhitungan tingkat kemiripan jawaban menggunakan algoritma *Levenshtein Distance* serta penyajian hasil pengujian kepada pengguna.



Gambar 3. 1 Alur Metode Penelitian dan Arsitektur Sistem Evaluasi

Gambar 3.1 menunjukkan bahwa sistem terdiri atas dua tahap utama, yaitu tahap *preprocessing* dataset IndoMMLU dan tahap sistem evaluasi akurasi ChatGPT, yang dijelaskan sebagai berikut.

a. Tahap *Preprocessing* Dataset IndoMMLU

Tahap *preprocessing* merupakan bagian awal yang dilakukan untuk menyiapkan data sebelum digunakan dalam proses pengujian. Proses ini dilakukan secara terpisah dari sistem utama menggunakan Laravel Artisan Command yang dirancang khusus untuk mengolah dataset IndoMMLU secara otomatis. Command tersebut dijalankan melalui terminal dengan perintah `php artisan dataset:preprocess`, kemudian sistem akan memanggil layanan *preprocessing* untuk membaca dataset mentah, melakukan proses pengolahan data, serta menghasilkan dataset akhir yang siap digunakan pada proses pengujian. Tahapan *preprocessing* meliputi:

- 1) Filtering domain bahasa, yaitu proses pemilihan soal-soal yang hanya termasuk ke dalam domain bahasa sesuai dengan fokus penelitian.
- 2) Seleksi kolom relevan, sehingga hanya atribut yang dibutuhkan dalam penelitian, seperti pertanyaan, opsi jawaban, dan kunci jawaban, yang digunakan dalam proses evaluasi.
- 3) Ekstraksi jawaban referensi, yaitu proses mencocokkan kunci jawaban dengan opsi jawaban yang tersedia untuk memperoleh teks jawaban yang benar.

- 4) Penyesuaian dan normalisasi format teks, meliputi penyeragaman huruf menjadi *lowercase* serta penghapusan karakter yang tidak diperlukan, guna memastikan keseragaman data dan meminimalkan kesalahan pada tahap perhitungan kemiripan teks.

Hasil dari tahap ini berupa dataset final IndoMMLU yang digunakan sebagai input utama dalam aplikasi pengujian akurasi ChatGPT.

b. Tahap Aplikasi Pengujian Akurasi ChatGPT

Tahap aplikasi pengujian akurasi ChatGPT merupakan bagian inti dalam arsitektur yang berfungsi untuk mengukur tingkat akurasi jawaban yang dihasilkan oleh ChatGPT menggunakan model GPT-4o mini. Dataset final hasil *preprocessing* digunakan sebagai input dalam proses evaluasi.

Tahapan proses evaluasi meliputi:

- 1) Pembentukan *prompt* yang terdiri dari *prompt Non-Chain-of-Thought* (Non-CoT) dan *Chain-of-Thought* (CoT). Format dan struktur *prompt* yang digunakan dalam penelitian ini dapat dilihat pada Subbab 3.4.1 Perancangan *Prompt* Pengujian.
- 2) Pengiriman gabungan *prompt* dan soal ke ChatGPT melalui OpenAI API.
- 3) Sistem menerima jawaban dari ChatGPT sebagai keluaran model.
- 4) Jawaban yang diterima kemudian diekstraksi dan dinormalisasi agar memiliki format teks yang konsisten dengan jawaban referensi.

- 5) Sistem melakukan perhitungan *Levenshtein Distance* untuk mengukur tingkat kemiripan antara jawaban model GPT-4o mini dan jawaban referensi.
- 6) Nilai kemiripan yang diperoleh digunakan sebagai dasar perhitungan akurasi jawaban model GPT-4o mini.
- 7) Seluruh hasil evaluasi kemudian disimpan dalam berkas atau basis data hasil untuk selanjutnya dilakukan analisis dan visualisasi, khususnya dalam membandingkan performa antara *prompt Non-CoT* dan *prompt CoT*.


Pada tahap ini, proses pengujian dilakukan dengan membandingkan kesamaan teks atau narasi jawaban, bukan hanya berdasarkan pilihan opsi. Jawaban referensi tidak dikirimkan ke model, sehingga proses evaluasi tetap objektif dan bebas dari bias.

3.3.2 Pemodelan Sistem *Unified Modelling Language* (UML)

Pemodelan sistem merupakan tahapan dalam perancangan yang digunakan untuk menggambarkan interaksi antara pengguna dan sistem serta alur proses yang terjadi dalam sistem evaluasi akurasi ChatGPT. Pemodelan ini dilakukan menggunakan pendekatan *Unified Modeling Language* (UML) untuk memberikan representasi visual yang jelas dan terstruktur. Pada penelitian ini, pemodelan sistem meliputi pembuatan *use case diagram* dan *activity diagram* yang digunakan untuk mendukung analisis dan perancangan sistem. Melalui pemodelan ini, diharapkan mekanisme kerja sistem dapat dipahami dengan lebih mudah sebelum diimplementasikan.

a. *Use Case Diagram*

Use case diagram merupakan *diagram* yang digunakan untuk menggambarkan interaksi antara aktor dan sistem berdasarkan fungsi-fungsi yang tersedia. *Diagram* ini memberikan gambaran umum mengenai peran pengguna serta batasan fungsi yang dapat diakses dalam aplikasi pengujian akurasi ChatGPT menggunakan model GPT-4o mini. Melalui *use case diagram*, hubungan antara pengguna dan sistem dapat dipahami secara lebih jelas sebelum masuk ke tahap perancangan detail. *Use case diagram* aplikasi pengujian akurasi ChatGPT dapat dilihat pada gambar 3.2.



Gambar 3. 2 *Use Case Diagram* Aplikasi Pengujian Akurasi ChatGPT

Gambar 3.2 menggambarkan *use case diagram* aplikasi pengujian akurasi ChatGPT menggunakan model GPT-4o mini yang dibangun pada penelitian ini. *Diagram* tersebut menunjukkan interaksi antara aktor dengan fungsi-fungsi yang tersedia dalam sistem. Adapun penjelasan mengenai aktor dan *use case* dijelaskan pada bagian berikut.

1) *Use Case Download Dataset IndoMMLU*

Use case download dataset IndoMMLU digunakan untuk menyediakan dataset bawaan yang dapat digunakan pengguna sebagai dataset awal dalam proses pengujian akurasi model GPT-4o mini. Dataset IndoMMLU telah disediakan oleh sistem dan dapat diunduh pengguna untuk digunakan dalam proses pengujian. Rancangan *use case* ini dapat dilihat pada Tabel 3.2.

Tabel 3. 2 *Use Case Download Dataset IndoMMLU*

<i>Use Case</i>	<i>Download Dataset IndoMMLU</i>
Deskripsi	Proses pengunduhan dataset IndoMMLU yang telah disediakan sistem sebagai dataset pengujian
Actor	Pengguna
Precondition	1. Pengguna berada pada halaman dataset 2. Pengguna menekan tombol <i>download</i> dataset indoMMLU
Postcondition	Dataset IndoMMLU berhasil diunduh pengguna

Tabel 3.2 menunjukkan bahwa sistem menyediakan dataset IndoMMLU sebagai dataset bawaan yang dapat digunakan pengguna dalam proses pengujian akurasi model GPT-4o mini.

2) *Use Case Download Template Dataset*

Use case download template dataset digunakan untuk menyediakan format dataset yang dapat dijadikan acuan oleh pengguna dalam menyusun dataset pengujian. *Template* tersebut memungkinkan penggunaan dataset lain selain IndoMMLU selama format data mengikuti ketentuan yang telah ditentukan sistem. Rancangan *use case* ini dapat dilihat pada Tabel 3.3.

Tabel 3. 3 *Use Case Download Template Dataset*

<i>Use Case</i>	<i>Download Template Dataset</i>
Deskripsi	Proses pengunduhan <i>template</i> format dataset sebagai acuan penyusunan dataset pengujian
Actor	Pengguna
Precondition	1. Pengguna berada pada halaman dataset 2. Pengguna menekan tombol <i>download template</i> dataset
Postcondition	<i>Template</i> dataset berhasil diunduh pengguna

Tabel 3.3 menunjukkan bahwa *template* dataset digunakan untuk membantu pengguna menyiapkan dataset dengan struktur yang sesuai agar dapat diproses sistem.

3) *Use Case Unggah Dataset*

Use case unggah dataset digunakan untuk memasukkan dataset pengujian ke dalam sistem. Pengguna dapat mengunggah dataset yang telah disiapkan sesuai dengan format yang telah ditentukan agar dapat digunakan dalam proses pengujian. Rancangan *use case* ini dapat dilihat pada Tabel 3.4.

Tabel 3. 4 *Use Case* Unggah Dataset

<i>Use Case</i>	Unggah Dataset
Deskripsi	Proses memasukkan dataset pengujian ke dalam sistem untuk digunakan dalam proses pengujian akurasi ChatGPT
Actor	Pengguna
Precondition	1. Pengguna berada pada halaman dataset 2. Pengguna memiliki dataset pengujian 3. Pengguna mengunggah dataset pengujian
Postcondition	1. Dataset berhasil diunggah ke dalam sistem 2. Dataset tersedia untuk proses pengujian

Tabel 3.4 menunjukkan bahwa proses unggah dataset dilakukan sebagai tahap awal sebelum proses pengujian akurasi dilakukan.

4) *Use Case* Tambah Data Dataset

Use case tambah data dataset digunakan untuk menambahkan data baru ke dalam dataset pengujian yang telah tersedia. Fitur ini digunakan ketika pengguna ingin menambahkan data tanpa melakukan unggah dataset ulang. Rancangan *use case* ini dapat dilihat pada Tabel 3.5.

Tabel 3. 5 *Use Case* Tambah Data Dataset

<i>Use Case</i>	Tambah Data Dataset
Deskripsi	Proses menambahkan data baru ke dalam dataset pengujian
Actor	Pengguna
Precondition	1. Pengguna berada pada halaman dataset 2. Dataset pengujian telah tersedia 3. Pengguna tambah data baru
Postcondition	Data baru berhasil ditambahkan ke dalam dataset pengujian

Tabel 3.5 menunjukkan bahwa fitur tambah data digunakan untuk memperbarui isi dataset sesuai kebutuhan pengguna.

5) *Use Case* Hapus Data Dataset

Use case hapus data dataset digunakan untuk menghapus data yang tidak diperlukan dari dataset pengujian. Pengguna dapat memilih data tertentu yang ingin dihapus sebelum proses pengujian dilakukan. Rancangan *use case* ini dapat dilihat pada Tabel 3.6.

Tabel 3. 6 *Use Case* Hapus Data Dataset

<i>Use Case</i>	Hapus Data Dataset
Deskripsi	Proses menghapus data yang tidak diperlukan dari dataset pengujian
Actor	Pengguna
Precondition	1. Pengguna berada pada halaman dataset 2. Dataset pengujian telah tersedia 3. Pengguna pilih dan hapus data
Postcondition	Data yang dipilih berhasil dihapus dari dataset pengujian

Tabel 3.6 menunjukkan bahwa fitur hapus data membantu pengguna melakukan pengelolaan dataset sebelum proses pengujian.

6) *Use Case* Jalankan Pengujian Akurasi

Use case jalankan pengujian akurasi merupakan proses utama dalam sistem yang digunakan untuk melakukan pengujian performa model GPT-4o mini menggunakan metode *Chain-of-Thought* (CoT) dan *Non-Chain-of-Thought* (Non-CoT). Proses dimulai ketika pengguna menekan tombol jalankan pengujian setelah dataset pengujian tersedia.

Sistem akan menghasilkan *prompt* pengujian untuk metode CoT dan Non-CoT, kemudian mengirimkan soal kepada ChatGPT melalui API. Jawaban yang diperoleh akan dibandingkan dengan jawaban referensi menggunakan algoritma *Levenshtein Distance* untuk memperoleh nilai

akurasi. Setelah proses pengujian selesai, sistem menyimpan hasil pengujian serta menghasilkan laporan dalam format Excel dan PDF.

Rancangan *use case* ini dapat dilihat pada Tabel 3.7.

Tabel 3. 7 *Use Case* Jalankan Pengujian Akurasi

<i>Use Case</i>	Jalankan Pengujian Akurasi
Deskripsi	Proses pengujian akurasi ChatGPT menggunakan metode CoT dan Non-CoT dengan perhitungan nilai akurasi menggunakan algoritma <i>Levenshtein Distance</i> serta menghasilkan laporan pengujian
Actor	Pengguna
Precondition	1. Dataset pengujian telah tersedia 2. Pengguna berada pada halaman proses pengujian 3. Pengguna menekan tombol jalankan pengujian
Postcondition	1. Sistem menghasilkan <i>prompt</i> pengujian CoT dan Non-CoT 2. Sistem mengirimkan soal ke model GPT-4o mini melalui API 3. Sistem menerima jawaban hasil pengujian 4. Sistem menghitung nilai akurasi menggunakan algoritma <i>Levenshtein Distance</i> 5. Sistem menyimpan hasil pengujian 6. Sistem menampilkan hasil pengujian

Tabel 3.7 menunjukkan bahwa proses pengujian dilakukan secara otomatis mulai dari pembuatan prompt, pengiriman soal ke model GPT-4o mini, perhitungan nilai akurasi, hingga menyimpan hasil pengujian.

7) *Use Case* Lihat Hasil Pengujian

Use case lihat hasil pengujian digunakan untuk menampilkan hasil pengujian yang telah dilakukan oleh sistem. Hasil pengujian disajikan dalam bentuk tabel perbandingan antara metode Non-CoT dan CoT yang berisi soal, jawaban referensi, jawaban hasil pengujian, serta nilai

akurasi masing-masing metode. Rancangan *use case* ini dapat dilihat pada Tabel 3.8.

Tabel 3. 8 *Use Case* Lihat Hasil Pengujian

<i>Use Case</i>	Lihat Hasil Pengujian
Deskripsi	Menampilkan hasil pengujian akurasi ChatGPT dalam bentuk tabel perbandingan dan nilai rata-rata akurasi metode CoT dan Non-CoT
Actor	Pengguna
Precondition	1. Dataset pengujian telah tersedia 2. Pengguna telah menekan tombol jalankan pengujian 3. Proses pengujian telah selesai 4. Hasil pengujian telah tersedia 5. Pengguna berada pada halaman hasil pengujian
Postcondition	1. Sistem mengambil data hasil pengujian 2. Sistem menampilkan nilai rata-rata akurasi metode CoT dan Non-CoT 3. Sistem menampilkan tabel hasil pengujian

Tabel 3.8 menunjukkan bahwa hasil pengujian ditampilkan secara terstruktur agar pengguna dapat mengetahui perbandingan performa ChatGPT berdasarkan metode yang digunakan.

8) *Use Case* Lihat Riwayat Pengujian

Use case lihat riwayat pengujian digunakan untuk menampilkan daftar hasil pengujian yang telah disimpan pada sistem. Riwayat pengujian berisi informasi pengujian yang pernah dilakukan sehingga pengguna dapat melihat kembali hasil pengujian sebelumnya tanpa perlu menjalankan pengujian ulang. Rancangan *use case* ini dapat dilihat pada Tabel 3.9.

Tabel 3. 9 *Use Case* Lihat Riwayat Pengujian

<i>Use Case</i>	Lihat Riwayat Pengujian
Deskripsi	Menampilkan daftar riwayat pengujian yang telah disimpan dan memungkinkan pengguna melihat kembali hasil pengujian yang pernah dilakukan.
Actor	Pengguna
Precondition	1. Pengguna berada pada halaman lihat pengujian 2. Sistem telah menyimpan minimal satu data riwayat pengujian
Postcondition	1. Sistem menampilkan daftar riwayat pengujian 2. Pengguna dapat memilih salah satu riwayat pengujian 3. Sistem memperbarui dan menampilkan data sesuai riwayat pengujian yang dipilih pada seluruh halaman terkait.

Tabel 3.9 menunjukkan bahwa fitur riwayat pengujian digunakan untuk menampilkan daftar hasil pengujian yang telah disimpan pada sistem. Pengguna dapat memilih salah satu riwayat pengujian untuk dilihat kembali. Setelah riwayat pengujian dipilih, sistem akan memperbarui dan menampilkan data yang terkait pada seluruh halaman sistem, seperti dataset, hasil pengujian, visualisasi, dan laporan, sehingga pengguna dapat meninjau kembali hasil pengujian yang telah dilakukan sebelumnya tanpa perlu menjalankan proses pengujian ulang.

9) *Use Case* Lihat Visualisasi Hasil

Use case lihat visualisasi hasil digunakan untuk menampilkan hasil pengujian dalam bentuk grafik perbandingan metode *Chain-of-Thought* dan *Non-Chain-of-Thought*. Visualisasi membantu pengguna memahami perbedaan hasil pengujian berdasarkan nilai akurasi yang diperoleh. Rancangan *use case* ini dapat dilihat pada Tabel 3.10.

Tabel 3. 10 *Use Case* Lihat Visualisasi Hasil

<i>Use Case</i>	Lihat Visualisasi Hasil
Deskripsi	Menampilkan grafik perbandingan hasil pengujian antara metode CoT dan Non-CoT
Actor	Pengguna
Precondition	1. Dataset pengujian telah tersedia 2. Pengguna telah menekan tombol jalankan pengujian 3. Proses pengujian telah selesai 4. Hasil pengujian telah tersedia 5. Pengguna berada pada halaman visualisasi hasil
Postcondition	1. Sistem mengambil data hasil pengujian 2. Sistem menampilkan nilai rata-rata akurasi metode CoT dan Non-CoT 3. Sistem menampilkan grafik perbandingan hasil pengujian

Tabel 3.10 menunjukkan bahwa visualisasi digunakan untuk menyajikan hasil pengujian dalam bentuk grafik agar pengguna lebih mudah memahami perbandingan performa metode CoT dan Non-CoT.

10) *Use Case* Lihat Laporan

Use case lihat laporan digunakan untuk menampilkan laporan hasil pengujian yang telah dihasilkan oleh sistem. Laporan berisi ringkasan hasil pengujian dan tersedia dalam format Excel serta PDF yang dapat diunduh oleh pengguna. Rancangan *use case* ini dapat dilihat pada Tabel 3.11.

Tabel 3. 11 *Use Case* Lihat Laporan

<i>Use Case</i>	Lihat Laporan
Deskripsi	Menampilkan laporan hasil pengujian serta menyediakan fitur unduh laporan dalam format Excel dan PDF
Actor	Pengguna
Precondition	1. Dataset pengujian telah tersedia

<i>Use Case</i>	Lihat Laporan
	2. Pengguna telah menekan tombol jalankan pengujian 3. Proses pengujian telah selesai 4. Hasil pengujian telah tersedia 5. Pengguna berada pada halaman hasil pengujian
Postcondition	1. Sistem menghasilkan laporan hasil pengujian 2. Pengguna dapat melihat laporan 3. Pengguna dapat mengunduh laporan dalam format Excel dan PDF


Tabel 3.11 menunjukkan bahwa fitur laporan digunakan untuk menampilkan dan menyediakan dokumentasi hasil pengujian yang telah dilakukan oleh sistem.

b. *Activity Diagram*

Activity diagram merupakan representasi visual yang digunakan untuk menggambarkan alur aktivitas suatu proses secara berurutan, mulai dari kondisi awal hingga kondisi akhir. *Diagram* ini menunjukkan interaksi antara pengguna dan sistem, termasuk proses, keputusan, serta hasil yang dihasilkan pada setiap tahapan aktivitas.

1) *Activity Diagram* Pengguna Mengunduh Dataset IndoMMLU

Pengunduhan dataset IndoMMLU merupakan tahap awal yang dapat dilakukan pengguna untuk memperoleh dataset evaluasi yang telah tersedia di dalam sistem. *Activity diagram* pengguna dalam mengunduh dataset IndoMMLU dapat dilihat pada Gambar 3.3.




Gambar 3. 3 *Activity Diagram* Pengguna Mengunduh Dataset IndoMMLU

Gambar 3.3 menunjukkan proses pengguna dalam mengunduh dataset IndoMMLU dari sistem. Pengguna membuka halaman dataset dan sistem menampilkan halaman dataset. Pengguna kemudian menekan tombol *download* dataset IndoMMLU, lalu sistem secara otomatis memproses dan *mendownload* dataset IndoMMLU. Setelah proses unduhan selesai, pengguna dapat melihat hasil *download* dataset IndoMMLU yang telah berhasil diunduh ke perangkat pengguna.

2) *Activity Diagram* Pengguna Mengunduh *Template* Dataset

Pengunduhan *template* dataset digunakan untuk membantu pengguna dalam menyiapkan dataset evaluasi sesuai dengan format dan struktur yang ditetapkan oleh sistem. *Activity diagram* pengguna dalam mengunduh *template* dataset dapat dilihat pada Gambar 3.4.




Gambar 3. 4 *Activity Diagram* Pengguna Mengunduh *Template* Dataset

Gambar 3.4 menunjukkan proses pengguna dalam mengunduh *template* dataset dari sistem. Pengguna membuka halaman dataset dan sistem menampilkan halaman dataset. Pengguna kemudian menekan tombol *download template* dataset, lalu sistem secara otomatis memproses dan *mendownload template* dataset. Setelah proses unduhan selesai, pengguna dapat melihat hasil *download template* dataset yang dapat digunakan sebagai acuan dalam menyusun dataset evaluasi.

3) *Activity Diagram* Pengguna Mengunggah Dataset

Pengunggahan dataset merupakan proses yang dilakukan pengguna untuk memasukkan dataset evaluasi ke dalam sistem sebelum proses pengujian akurasi dijalankan. *Activity diagram* pengguna dalam mengunggah dataset dapat dilihat pada 3.5.




Gambar 3. 5 *Activity Diagram* Pengguna Mengunggah Dataset

Gambar 3.5 menunjukkan proses pengguna dalam mengunggah dataset evaluasi ke dalam sistem. Pengguna membuka halaman dataset dan sistem menampilkan halaman dataset. Pengguna kemudian mengunggah dataset ke dalam sistem, lalu sistem melakukan validasi terhadap format dan struktur dataset yang diunggah. Apabila format dan struktur dataset tidak valid, sistem akan menampilkan pesan gagal dan pengguna diminta untuk mengunggah ulang dataset yang sesuai. Jika dataset valid, sistem akan menampilkan dataset yang telah diunggah sehingga pengguna dapat memastikan dataset telah berhasil masuk ke dalam sistem dan siap digunakan dalam proses pengujian.

4) *Activity Diagram* Pengguna Menambah Data Dataset

Penambahan data dataset merupakan proses yang digunakan untuk menambahkan data baru secara manual ke dalam dataset evaluasi yang telah tersedia di dalam sistem. *Activity diagram* pengguna dalam menambah data dataset dapat dilihat pada Gambar 3.6.




Gambar 3. 6 Activity *Diagram* Pengguna Menambah Data Dataset

Gambar 3.6 menunjukkan proses pengguna dalam menambah data baru pada dataset di dalam sistem. Pengguna membuka halaman dataset dan sistem menampilkan halaman dataset. Pengguna kemudian menekan tombol tambah data dan sistem merespons dengan menampilkan modal tambah data. Pengguna memasukkan data baru ke dalam modal tersebut dan sistem menerima data baru yang diinputkan. Setelah proses penyimpanan selesai, sistem menampilkan data baru sehingga pengguna dapat melihat data yang telah berhasil ditambahkan ke dalam dataset evaluasi.

5) Activity *Diagram* Pengguna Menghapus Data Dataset

Penghapusan data dataset merupakan proses yang digunakan untuk menghapus data yang tidak diperlukan dari dataset evaluasi yang

tersimpan di dalam sistem. Activity *diagram* pengguna dalam menghapus data dataset dapat dilihat pada Gambar 3.7.




Gambar 3. 7 Activity Diagram Pengguna Menghapus Data Dataset

Gambar 3.7 menunjukkan proses pengguna dalam menghapus data pada dataset di dalam sistem. Pengguna membuka halaman dataset dan sistem menampilkan halaman dataset. Pengguna memilih data yang akan dihapus dan menekan tombol hapus data, kemudian sistem menampilkan pesan verifikasi untuk mengkonfirmasi tindakan penghapusan. Apabila pengguna mengkonfirmasi ingin menghapus data, sistem akan melakukan proses penghapusan data tersebut. Setelah proses penghapusan selesai, pengguna dapat melihat dataset yang telah diperbarui sesuai dengan hasil penghapusan data.

6) *Activity Diagram* Pengguna Menjalankan Pengujian Akurasi

Proses menjalankan pengujian akurasi merupakan proses utama dalam sistem yang digunakan untuk mengukur performa ChatGPT menggunakan metode *Chain-of-Thought* (CoT) dan *Non-Chain-of-Thought* (Non-CoT). *Activity diagram* pengguna dalam menjalankan pengujian akurasi dapat dilihat pada Gambar 3.8.




Gambar 3. 8 *Activity Diagram* Pengguna Menjalankan Pengujian Akurasi

Gambar 3.8 menunjukkan proses pengguna dalam menjalankan pengujian akurasi pada sistem. Pengguna membuka halaman pengujian dan sistem menampilkan halaman pengujian. Pengguna kemudian menekan tombol jalankan pengujian, lalu sistem mulai memproses dengan membaca dataset dan mengambil satu soal MCQ. Sistem kemudian men-generate *prompt* Non-CoT dan CoT, lalu mengirimkan *prompt* beserta soal ke ChatGPT menggunakan model GPT-4o mini melalui API. Sistem menerima jawaban dari ChatGPT, melakukan normalisasi jawaban, menghitung *Levenshtein Distance*, dan menyimpan nilai akurasi yang diperoleh. Sistem kemudian memeriksa apakah masih terdapat soal yang tersisa. Apabila masih ada soal, sistem mengulang proses dari pengambilan soal berikutnya hingga seluruh soal selesai diproses. Setelah semua soal selesai diproses, sistem men-generate file dengan ekstensi JSON, kemudian menyimpan riwayat pengujian ke dalam file JSON dan menampilkan hasil pengujian sehingga pengguna dapat melihat hasil pengujian akurasi secara keseluruhan.

7) *Activity Diagram* Pengguna Melihat Hasil Pengujian

Melihat hasil pengujian merupakan proses yang digunakan untuk menampilkan hasil pengujian akurasi ChatGPT yang telah dilakukan sebelumnya pada sistem. *Activity diagram* pengguna dalam melihat hasil pengujian dapat dilihat pada Gambar 3.9.



Gambar 3. 9 *Activity Diagram* Pengguna Melihat Hasil Pengujian


Gambar 3.9 menunjukkan proses pengguna dalam melihat hasil pengujian pada sistem. Proses dimulai ketika pengguna membuka halaman hasil pengujian. Sistem kemudian melakukan pengecekan apakah pengujian telah dilakukan sebelumnya. Apabila belum terdapat data hasil pengujian, sistem akan menampilkan halaman hasil pengujian tanpa data sehingga pengguna hanya dapat melihat halaman kosong.

Apabila pengujian telah dilakukan, sistem akan menampilkan halaman hasil pengujian yang berisi data hasil pengujian dalam bentuk tabel. Tabel tersebut memuat informasi hasil pengujian akurasi ChatGPT menggunakan metode *Chain-of-Thought* (CoT) dan *Non-Chain-of-Thought* (Non-CoT) pada dataset IndoMMLU. Setelah data ditampilkan, pengguna dapat melihat dan menganalisis hasil pengujian yang telah dilakukan.

8) *Activity Diagram* Pengguna Melihat Riwayat Pengujian

Melihat riwayat pengujian merupakan proses yang digunakan untuk menampilkan daftar hasil pengujian yang telah disimpan pada sistem

sehingga pengguna dapat melihat kembali hasil pengujian yang pernah dilakukan. *Activity diagram* tersebut dapat dilihat pada Gambar 3.10.




Gambar 3. 10 *Activity Diagram* Pengguna Melihat Riwayat Pengujian

Gambar 3.10 menunjukkan proses pengguna dalam melihat riwayat pengujian pada sistem. Proses dimulai ketika pengguna membuka halaman hasil pengujian. Sistem kemudian memeriksa ketersediaan data riwayat pengujian. Jika belum terdapat riwayat pengujian, sistem akan menampilkan halaman hasil pengujian tanpa data. Sebaliknya, jika data riwayat pengujian tersedia, sistem akan menampilkan daftar riwayat pengujian dalam bentuk tabel. Pengguna dapat memilih salah satu riwayat pengujian untuk dilihat kembali, kemudian sistem akan memperbarui dan menampilkan seluruh data terkait, seperti dataset, hasil pengujian, visualisasi, dan laporan sesuai dengan riwayat pengujian yang dipilih.

9) *Activity Diagram* Pengguna Melihat Visualisasi Hasil

Visualisasi hasil digunakan untuk menampilkan hasil pengujian akurasi dalam bentuk grafik sehingga memudahkan pengguna dalam memahami dan membandingkan hasil pengujian yang diperoleh. *Activity diagram* pengguna dalam melihat visualisasi hasil dapat dilihat pada Gambar 3.11.



Gambar 3. 11 *Activity Diagram* Pengguna Melihat Visualisasi Hasil


Gambar 3.11 menunjukkan proses pengguna dalam melihat visualisasi hasil pengujian pada sistem. Proses dimulai ketika pengguna membuka halaman visualisasi. Sistem kemudian melakukan pengecekan apakah pengujian telah dilakukan sebelumnya. Apabila belum terdapat data hasil pengujian, sistem akan menampilkan halaman visualisasi tanpa data sehingga tidak terdapat grafik yang dapat ditampilkan.

Apabila pengujian telah dilakukan, sistem akan menampilkan halaman visualisasi yang berisi grafik hasil pengujian. Grafik tersebut

menyajikan informasi hasil pengujian akurasi ChatGPT menggunakan metode *Chain-of-Thought* (CoT) dan *Non-Chain-of-Thought* (Non-CoT) sehingga pengguna dapat melihat perbandingan performa kedua metode secara visual. Dengan adanya visualisasi tersebut, pengguna dapat melakukan analisis hasil pengujian dengan lebih mudah dan informatif.

10) *Activity Diagram* Pengguna Melihat Laporan

Laporan evaluasi digunakan untuk menampilkan ringkasan hasil pengujian akurasi serta menyediakan opsi pengunduhan laporan dalam berbagai format yang dapat digunakan pengguna untuk keperluan dokumentasi dan pelaporan. *Activity diagram* pengguna dalam melihat laporan dapat dilihat pada Gambar 3.12.



Gambar 3. 12 *Activity Diagram* Pengguna Melihat Laporan

Gambar 3.12 menunjukkan proses pengguna dalam melihat laporan hasil pengujian pada sistem. Pengguna membuka halaman laporan dan sistem menampilkan halaman laporan sekaligus menampilkan ringkasan hasil pengujian. Pengguna kemudian dihadapkan pada pilihan format unduhan laporan yang tersedia. Apabila pengguna ingin mengunduh laporan dalam format Excel, pengguna menekan tombol unduh Excel dan sistem akan mengunduh file dengan format XLSX sehingga pengguna dapat melihat hasil unduhan dalam format Excel. Apabila pengguna ingin mengunduh laporan dalam format PDF, pengguna menekan tombol unduh PDF dan sistem akan mengunduh file dengan format PDF sehingga pengguna dapat melihat hasil unduhan dalam format PDF.

3.3.3 Perancangan Antarmuka Pengguna (*User Interface*)


Perancangan antarmuka pengguna (*user interface*) dilakukan untuk memberikan gambaran tampilan serta interaksi pengguna dengan sistem dalam proses evaluasi akurasi ChatGPT menggunakan metode *Chain-of-Thought* (CoT) dan *Non-Chain-of-Thought* (Non-CoT). Perancangan ini bertujuan menghasilkan antarmuka yang mudah digunakan, terstruktur, dan sesuai dengan kebutuhan fungsional sistem.

Antarmuka sistem dirancang dengan tata letak yang rapi, navigasi yang mudah dipahami, serta penyajian informasi yang mendukung alur penggunaan sistem mulai dari pengelolaan dataset, proses pengujian, hasil evaluasi, visualisasi,

hingga pembuatan laporan. Adapun rancangan halaman pada aplikasi pengujian akurasi ChatGPT adalah sebagai berikut:

a. Perancangan Halaman Beranda

Halaman beranda dirancang sebagai halaman utama yang ditampilkan setelah pengguna mengakses sistem. Desain halaman beranda dapat dilihat pada Gambar 3.13.



Gambar 3. 13 Desain Halaman Beranda


Gambar 3.13 menunjukkan halaman beranda yang berisi penjelasan singkat mengenai aplikasi EvalGPT untuk menguji akurasi jawaban model GPT-4o mini menggunakan dataset IndoMMLU. Pada halaman ini ditampilkan alur penggunaan sistem yang terdiri dari proses unggah dataset, menjalankan pengujian, melihat hasil pengujian, melihat visualisasi hasil evaluasi, dan mengunduh laporan.

Halaman *beranda* juga menampilkan penjelasan mengenai metode *Chain-of-Thought* (CoT) dan Non-CoT yang digunakan dalam proses pengujian. Metode CoT menghasilkan jawaban melalui tahapan penalaran, sedangkan Non-CoT menghasilkan jawaban secara langsung tanpa proses penalaran bertahap. Pada bagian bawah halaman ditampilkan penjelasan mengenai algoritma *Levenshtein Distance* yang digunakan untuk mengukur tingkat kemiripan antara jawaban ChatGPT dan jawaban referensi berdasarkan operasi penyisipan, penghapusan, dan penggantian karakter.

b. Perancangan Halaman Dataset

1) Perancangan Halaman *Download* Dataset IndoMMLU, *Template* Dataset dan Unggah Dataset

Halaman dataset dirancang untuk mengelola data yang digunakan dalam proses evaluasi. Halaman ini menyediakan fitur untuk mengunduh dataset IndoMMLU, mengunduh *template* CSV, dan mengunggah dataset ke dalam sistem. Desain halaman dataset dapat dilihat pada Gambar 3.14.




Gambar 3. 14 Halaman Unggah Dataset

Gambar 3.14 menunjukkan halaman dataset yang memiliki area unggah file CSV serta tombol Pilih File Dataset dan Upload Dataset untuk menambahkan dataset ke sistem. Pada bagian kanan halaman tersedia tombol IndoMMLU Dataset untuk mengunduh dataset penelitian dan *Template CSV* sebagai panduan format data yang sesuai. Setelah dataset berhasil diunggah, data akan tersimpan pada sistem dan digunakan sebagai sumber data dalam proses pengujian akurasi ChatGPT menggunakan metode Non-CoT dan CoT.

2) Perancangan Halaman Dataset Gagal Diunggah

Halaman dataset gagal diunggah dirancang untuk memberikan informasi kepada pengguna ketika proses unggah dataset tidak berhasil dilakukan karena format file yang tidak sesuai dengan ketentuan sistem. Desain halaman dataset gagal diunggah dapat dilihat pada Gambar 3.15.




Gambar 3. 15 Desain Halaman Dataset Gagal Diunggah

Gambar 3.15 menunjukkan kondisi ketika pengguna telah memilih file dataset dan menekan tombol Upload Dataset, namun sistem mendeteksi bahwa format data tidak sesuai dengan *template* yang telah ditentukan. Sistem kemudian menampilkan notifikasi “Upload Gagal” yang berisi informasi kesalahan format dataset. Pengguna dapat memperbaiki format file sesuai *template* CSV yang tersedia kemudian melakukan proses unggah ulang hingga dataset berhasil ditambahkan ke dalam sistem.

3) Perancangan Halaman Dataset Berhasil Diunggah

Halaman dataset berhasil diunggah dirancang untuk menampilkan informasi bahwa dataset telah berhasil ditambahkan ke dalam sistem dan siap digunakan pada proses evaluasi. Desain halaman dataset berhasil diunggah dapat dilihat pada Gambar 3.16.



Gambar 3. 16 Desain Halaman Dataset Berhasil Diunggah

Gambar 3.16 menunjukkan kondisi setelah pengguna berhasil mengunggah file dataset CSV. Sistem menampilkan notifikasi “Berhasil” sebagai konfirmasi bahwa data telah tersimpan. Dataset yang berhasil diunggah kemudian ditampilkan pada bagian *Preview Dataset* dalam bentuk tabel yang berisi subject, soal, pilihan jawaban, kunci jawaban, dan narasi jawaban. Selain itu, informasi jumlah data yang tersedia juga diperbarui secara otomatis sesuai dataset yang berhasil ditambahkan.

4) Perancangan Modal Tambah Data Dataset

Modal tambah data dataset dirancang untuk memungkinkan pengguna menambahkan data baru secara manual ketika pengguna sudah mengunggah dataset. Desain modal tambah data dataset dapat dilihat pada Gambar 3.17.

The image shows a web application interface for 'EvalGPT'. A modal titled 'Tambah Data Manual' is open, allowing users to add data to an active dataset. The modal includes fields for Subject, Question (Soal), Answer Key (Kunci Jawaban), Answer Choices (Pilihan Jawaban), and Correct Answer Narrative (Narasi Jawaban Benar). There is also a checkbox for automatic saving to the active CSV dataset. The background shows the main dashboard with options like Beranda, Dataset, Proses Pengujian, Hasil Pengujian, Visualisasi, and Laporan. A table of active datasets is visible at the bottom.

No	Subject	Soal	Kunci Jawaban	Pilihan Jawaban	Narasi Jawaban Benar	Aksi
1	Sejarah	Umat Hindu memuja tiga dewa yang disebut Trimurti. Dewa pencipta alam semesta adalah...	A. Brahma B. Wisnu C. Syiwa D. Agni E. Boruna	A	Brahma	[Icon]
2	biologi	Dalam agama Hindu terdapat pengelompokan yang disebut kasta. Para bangsawan dan prajurit termasuk dalam kasta...	A. brahmana B. kesatria C. waisya D. sudra E. paria	B	kesatria	[Icon]


Gambar 3. 17 Desain Modal Tambah Data Dataset

Gambar 3.17 menunjukkan modal penambahan data yang muncul setelah pengguna menekan tombol Tambah Data pada halaman dataset. Pada form tersebut pengguna diminta mengisi beberapa informasi, yaitu subject, soal, pilihan jawaban, kunci jawaban, dan narasi jawaban benar. Setelah seluruh data diisi dengan lengkap, pengguna dapat menekan tombol Simpan Data untuk menyimpan data baru ke dalam dataset aktif.

Apabila pengguna membatalkan proses penambahan data, tombol Batal dapat digunakan untuk menutup modal tanpa menyimpan perubahan.

5) Perancangan Halaman Tambah Data Dataset Berhasil

Halaman tambah data dataset berhasil dirancang untuk menampilkan hasil penambahan data secara manual yang telah berhasil disimpan ke dalam sistem. Desain halaman tambah data dataset berhasil dapat dilihat pada Gambar 3.18.




Gambar 3. 18 Desain Halaman Tambah Data Dataset Berhasil

Gambar 3.18 menunjukkan kondisi setelah pengguna berhasil menambahkan data melalui form tambah data. Sistem menampilkan notifikasi “Berhasil” sebagai informasi bahwa data baru telah

ditambahkan ke dataset aktif. Data yang baru dimasukkan kemudian langsung muncul pada tabel *preview* dataset sehingga pengguna dapat memverifikasi bahwa data telah tersimpan dengan benar. Selain itu, jumlah total data pada dataset juga bertambah secara otomatis.

6) Perancangan Halaman Hapus Dataset Berhasil

Halaman hapus dataset berhasil dirancang untuk memberikan informasi bahwa data yang dipilih telah berhasil dihapus dari dataset aktif. Desain halaman hapus dataset berhasil dapat dilihat pada Gambar 3.19.




Gambar 3. 19 Desain Halaman Hapus Dataset Berhasil

Gambar 3.19 menunjukkan kondisi setelah pengguna menekan tombol hapus pada salah satu data dataset. Sistem akan menghapus data

yang dipilih dan menampilkan notifikasi “Berhasil” sebagai konfirmasi penghapusan. Setelah proses selesai, data yang dihapus tidak lagi ditampilkan pada tabel *preview* dataset dan jumlah total data pada dataset akan berkurang secara otomatis.

c. Perancangan Halaman Proses Pengujian

Halaman proses pengujian dirancang untuk menjalankan pengujian terhadap jawaban ChatGPT menggunakan metode Non-CoT dan CoT secara otomatis. Desain halaman proses evaluasi dapat dilihat pada Gambar 3.20.



Gambar 3. 20 Desain Halaman Proses Pengujian


Gambar 3.20 menampilkan halaman proses pengujian yang berisi tombol “Jalankan Pengujian” untuk memulai proses evaluasi dataset. Pada halaman ini juga ditampilkan informasi mengenai metode *Direct Answer* (Non-CoT), *Step Reasoning* (CoT), serta *Accuracy Test* yang digunakan

sistem dalam proses pengujian. Selain itu, terdapat informasi sistem dan status kesiapan sistem sebelum evaluasi dijalankan.

d. Perancangan Halaman Hasil Pengujian

1) Perancangan Halaman Hasil Pengujian Belum Melakukan Pengujian

Halaman hasil pengujian belum melakukan pengujian dirancang untuk memberikan informasi bahwa proses evaluasi belum pernah dijalankan sehingga hasil pengujian belum tersedia. Desain halaman hasil pengujian dapat dilihat pada Gambar 3.21.




Gambar 3. 21 Desain Halaman Hasil Pengujian Belum Melakukan Pengujian

Gambar 3.21 menunjukkan halaman hasil pengujian ketika belum terdapat data evaluasi. Seluruh nilai statistik seperti total data, total subject, rata-rata akurasi Non-CoT, rata-rata akurasi CoT, peningkatan performa, dan akurasi terbaik masih bernilai nol. Pada bagian utama halaman ditampilkan pesan “Belum Ada Hasil Evaluasi” yang

menginformasikan bahwa pengguna harus mengunggah dataset dan menjalankan proses pengujian terlebih dahulu sebelum hasil evaluasi dapat ditampilkan.

2) Perancangan Halaman Hasil Pengujian Sudah Melakukan Pengujian

Halaman hasil pengujian dirancang untuk menampilkan hasil evaluasi jawaban ChatGPT menggunakan metode Non-CoT dan CoT berdasarkan dataset yang telah diuji. Desain halaman hasil pengujian dapat dilihat pada Gambar 3.22.




Gambar 3. 22 Desain Halaman Hasil Pengujian Sudah Melakukan Pengujian

Gambar 3.22 menunjukkan hasil evaluasi yang telah berhasil dilakukan oleh sistem. Pada bagian atas ditampilkan ringkasan statistik berupa total data, total subject, rata-rata akurasi Non-CoT, rata-rata akurasi CoT, peningkatan performa, dan nilai akurasi terbaik. Di bawahnya terdapat tabel hasil pengujian yang berisi soal, jawaban referensi, jawaban metode Non-CoT, nilai kemiripan Non-CoT, jawaban metode CoT, serta nilai kemiripan CoT yang dihitung menggunakan algoritma *Levenshtein Distance*. Tabel ini membantu pengguna membandingkan performa kedua metode secara rinci.

3) Perancangan Riwayat Pengujian Belum Tersedia

Riwayat pengujian belum tersedia dirancang untuk memberikan informasi bahwa belum terdapat data riwayat pengujian yang tersimpan pada sistem. Tampilan ini ditampilkan ketika pengguna belum pernah menjalankan dan menyimpan hasil pengujian. Desain tampilan riwayat pengujian dapat dilihat pada Gambar 3.23.




Gambar 3. 23 Desain Riwayat Pengujian Belum Tersedia

Gambar 3.23 menunjukkan tampilan riwayat pengujian ketika belum terdapat data riwayat pengujian yang tersimpan pada sistem. Pada bagian riwayat pengujian ditampilkan pesan "Belum Ada Riwayat

Pengujian" yang menginformasikan bahwa pengguna belum memiliki riwayat pengujian yang dapat ditampilkan. Selain itu, tabel riwayat pengujian masih dalam kondisi kosong karena belum terdapat data yang tersimpan pada sistem.

4) Perancangan Riwayat Pengujian Tersedia

Riwayat pengujian tersedia dirancang untuk menampilkan daftar pengujian yang telah disimpan pada sistem sehingga pengguna dapat melihat kembali hasil pengujian yang pernah dilakukan. Desain tampilan riwayat pengujian dapat dilihat pada Gambar 3.24.



The screenshot shows the 'History Pengujian' (Test History) page in the EvalGPT system. The page has a sidebar menu on the left with options: Beranda, Dataset, Proses Pengujian, Hasil Pengujian (selected), Visualisasi, and Laporan. The main content area is titled 'History Pengujian' and includes a subtitle 'Riwayat dataset dan hasil evaluasi sebelumnya.' (Previous dataset and evaluation results). A 'TOTAL PENGUJIAN' (Total Tests) badge shows the number '8'. Below this is a table with the following columns: DATASET, NON-COT, COT, TANGGAL, and AKSI. The table lists five test entries, each with a dataset name, two percentage values (NON-COT and COT), a date, and a 'Lihat' (View) button. At the bottom of the table, it says 'Menampilkan halaman 1 dari 2.' (Showing page 1 of 2) and has pagination controls for '1', '2', and 'Next'.

DATASET	NON-COT	COT	TANGGAL	AKSI
IndoMMLU_20260525_103804.csv	22.38%	21.53%	25 May 2026 10:47	Lihat
IndoMMLU_20260517_165733.csv	22.38%	21.53%	17 May 2026 16:57	Lihat
IndoMMLU_20260517_104835.csv	17.78%	25%	17 May 2026 10:48	Lihat
IndoMMLU_20260517_094403.csv	22.38%	21.53%	17 May 2026 09:44	Lihat
IndoMMLU_20260517_094006.csv	17.78%	25%	17 May 2026 09:40	Lihat

Gambar 3. 24 Desain Riwayat Pengujian Tersedia


Gambar 3.24 menunjukkan tampilan riwayat pengujian ketika data riwayat pengujian telah tersedia. Pada bagian riwayat pengujian ditampilkan tabel yang berisi daftar pengujian yang telah disimpan sebelumnya. Pengguna dapat memilih salah satu riwayat pengujian untuk ditampilkan kembali dengan menekan tombol Lihat pada data yang dipilih. Setelah riwayat pengujian dipilih, sistem akan memperbarui dan menampilkan data terkait, seperti hasil pengujian,

visualisasi, dan laporan sesuai dengan riwayat pengujian yang dipilih sehingga pengguna dapat meninjau kembali hasil pengujian tanpa perlu menjalankan proses pengujian ulang.

e. Perancangan Halaman Visualisasi Hasil Pengujian

1) Perancangan Halaman Visualisasi Belum Melakukan Pengujian

Halaman visualisasi belum melakukan pengujian dirancang untuk memberikan informasi bahwa data evaluasi belum tersedia sehingga grafik perbandingan belum dapat ditampilkan. Desain halaman visualisasi dapat dilihat pada Gambar 3.25.




Gambar 3. 25 Desain Halaman Visualisasi Belum Melakukan Pengujian

Gambar 3.25 menunjukkan kondisi ketika sistem belum memiliki data hasil evaluasi. Statistik pengujian masih bernilai nol dan area visualisasi belum menampilkan grafik. Pengguna diarahkan untuk

menjalankan proses pengujian terlebih dahulu agar sistem dapat menghasilkan visualisasi performa metode Non-CoT dan CoT.

2) Perancangan Halaman Visualisasi Sudah Melakukan Pengujian

Halaman visualisasi dirancang untuk menyajikan hasil evaluasi dalam bentuk grafik sehingga memudahkan pengguna melakukan analisis perbandingan performa metode. Desain halaman visualisasi dapat dilihat pada Gambar 3.26.



Gambar 3. 26 Desain Halaman Visualisasi Sudah Melakukan Pengujian


Gambar 3.26 menunjukkan grafik perbandingan akurasi metode Non-CoT dan CoT berdasarkan setiap subject pada dataset. Selain grafik, sistem juga menampilkan informasi statistik seperti total data, total subject, rata-rata akurasi kedua metode, peningkatan performa, dan

akurasi tertinggi. Melalui visualisasi ini pengguna dapat melihat subject mana yang memperoleh performa terbaik maupun terendah pada masing-masing metode.

f. Perancangan Halaman Laporan Hasil Pengujian

1) Perancangan Halaman Laporan Belum Melakukan Pengujian

Halaman laporan belum melakukan pengujian dirancang untuk memberikan informasi bahwa laporan evaluasi belum dapat dibuat karena belum tersedia data hasil pengujian. Desain halaman laporan dapat dilihat pada Gambar 3.27.




Gambar 3. 27 Desain Halaman Laporan Belum Melakukan Pengujian

Gambar 3.27 menunjukkan kondisi ketika pengguna mengakses halaman laporan tanpa adanya data evaluasi. Sistem menampilkan pesan bahwa laporan belum tersedia dan pengguna harus menjalankan proses pengujian terlebih dahulu sebelum laporan dapat dihasilkan.

2) Perancangan Halaman Laporan Sudah Melakukan Pengujian

Halaman laporan dirancang untuk menyajikan ringkasan hasil evaluasi yang telah dilakukan oleh sistem. Halaman ini memungkinkan pengguna melihat hasil pengujian secara ringkas, mengunduh laporan PDF, serta mengunduh data hasil pengujian dalam format Microsoft Excel. Desain halaman laporan dapat dilihat pada Gambar 3.28.



Gambar 3. 28 Desain Halaman Laporan Sudah Melakukan Pengujian

Gambar 3.28 menunjukkan halaman laporan yang ditampilkan setelah proses pengujian selesai dilakukan. Halaman ini menampilkan ringkasan hasil evaluasi berupa jumlah data, jumlah subject, rata-rata akurasi Non-CoT, rata-rata akurasi CoT, dan peningkatan performa

metode CoT. Selain itu, tersedia fitur *Download* PDF untuk mengunduh laporan ringkasan hasil evaluasi dan *Download* Excel untuk mengunduh data hasil pengujian secara lengkap. Fitur tersebut memudahkan pengguna dalam menyimpan dan mendokumentasikan hasil pengujian yang telah dilakukan.

3.4 Perancangan Metode Penelitian

Bagian ini menjelaskan tahapan perancangan metode dalam aplikasi pengujian akurasi jawaban ChatGPT menggunakan model GPT-4o mini yang dilakukan secara kuantitatif. Tahapan yang dirancang meliputi penerapan metode *Chain-of-Thought* dan *Non-Chain-of-Thought*, serta nilai akurasi jawaban model GPT-4o mini menggunakan algoritma *Levenshtein Distance* untuk mengukur tingkat kemiripan jawaban.

3.4.1 Perancangan *Prompt* Pengujian

Perancangan *prompt* dalam penelitian ini dilakukan untuk membandingkan pengaruh penggunaan metode *Chain-of-Thought* (CoT) dan *Non-Chain-of-Thought* (Non-CoT) terhadap kemampuan ChatGPT dalam menjawab soal pada dataset IndoMMLU. Perancangan *prompt* mengacu pada konsep *Zero-Shot Chain-of-Thought Prompting* yang diperkenalkan oleh Kojima et al. (2022), yaitu penggunaan instruksi sederhana untuk mendorong model menghasilkan langkah penyelesaian secara bertahap sebelum memberikan jawaban akhir.

Prompt CoT dalam penelitian ini mengacu pada konsep *Zero-Shot Chain-of-Thought Prompting* dari Kojima et al. (2022) dengan melakukan penyesuaian

instruksi ke dalam format soal pilihan ganda IndoMMLU. Penyesuaian tersebut dilakukan agar *prompt* sesuai dengan kebutuhan evaluasi, yaitu mengarahkan model untuk memberikan langkah penyelesaian sebelum menghasilkan jawaban akhir. Model yang digunakan dalam penelitian ini adalah ChatGPT melalui OpenAI API dengan model GPT-4o-mini. Pemilihan model tersebut dilakukan karena memiliki kemampuan memahami konteks bahasa serta mendukung proses evaluasi dalam jumlah data yang besar dengan biaya penggunaan API yang lebih efisien.

Terdapat dua rancangan *prompt* yang digunakan dalam proses pengujian, yaitu:

a. *Prompt Non-Chain-of-Thought* (Non-CoT)

Prompt Non-CoT dirancang untuk memperoleh jawaban langsung dari model tanpa memberikan instruksi terkait langkah penyelesaian. *Prompt* ini digunakan sebagai metode pembandingan terhadap metode CoT.

Format *prompt* Non-CoT:

```
Jawablah pertanyaan berikut. Berikan hanya jawaban akhir
teks tanpa opsi (A/B/C/D/E).
```

```
Soal:
{soal}
```

```
Pilihan:
{pilihan jawaban}
```

b. *Prompt Chain-of-Thought* (CoT)

Prompt CoT dirancang dengan memberikan instruksi kepada model untuk melakukan penyelesaian secara bertahap sebelum memberikan jawaban akhir. Respons yang dihasilkan kemudian diproses untuk mengambil bagian jawaban akhir yang akan dibandingkan dengan jawaban referensi menggunakan algoritma *Levenshtein Distance*.

Format *prompt* CoT:

Jawablah pertanyaan berikut dengan berpikir langkah demi langkah untuk menyelesaikan soal ini secara logis.

Soal:
{soal}


Pilihan:
{pilihan jawaban}

Setelah menjelaskan langkah penyelesaiannya, lalu di baris terakhir tulis format eksak: Jawaban akhir: [Teks jawaban tanpa huruf opsi A/B/C/D/E].

Kedua metode tersebut tidak memberikan jawaban referensi dari dataset kepada model agar proses evaluasi tetap objektif. Jawaban akhir yang dihasilkan ChatGPT kemudian dibandingkan dengan jawaban benar pada dataset menggunakan algoritma *Levenshtein Distance* untuk memperoleh nilai kemiripan dan akurasi.

3.4.2 *Flowchart* Penerapan Metode *Chain-of-Thought*

Flowchart penerapan metode *Chain-of-Thought* ditunjukkan pada gambar 3.29. *Flowchart* ini menggambarkan alur implementasi metode *prompting* dalam sistem evaluasi akurasi ChatGPT menggunakan pendekatan *Chain-of-Thought* dan *Non-Chain-of-Thought*.



Gambar 3. 29 *Flowchart* Penerapan Metode *Chain-of-Thought*

Gambar 3.29 menunjukkan proses penerapan metode yang dimulai dari penggunaan dataset IndoMMLU hasil preprocessing sebagai input sistem. Proses evaluasi dilakukan terhadap data soal pada dataset untuk memperoleh jawaban dari ChatGPT menggunakan dua metode *prompting* yang berbeda. Adapun tahapan proses tersebut dijelaskan sebagai berikut:

- a. Input Dataset Hasil *Preprocessing*: Dataset IndoMMLU yang telah melalui tahap preprocessing digunakan sebagai data masukan dalam sistem evaluasi.
- b. Pengambilan Satu Soal: Sistem mengambil satu data soal dari dataset untuk diproses pada tahap evaluasi.

- c. Penentuan Metode *Prompting*: Sistem menentukan metode *prompting* yang akan digunakan, yaitu *prompt* tanpa metode *Chain-of-Thought* (Non-CoT) atau *prompt* dengan metode *Chain-of-Thought* (CoT).
- d. Pembentukan *Prompt*: Berdasarkan metode yang dipilih, sistem membentuk *prompt* evaluasi. Pada metode Non-CoT, *prompt* digunakan untuk menghasilkan jawaban secara langsung, sedangkan pada metode CoT *prompt* disusun dengan instruksi penalaran bertahap sebelum menghasilkan jawaban akhir.
- e. Penggabungan *Prompt* dan Soal: *Prompt* yang telah dibentuk digabungkan dengan soal dari dataset sehingga menghasilkan *prompt* evaluasi yang siap dikirimkan ke model ChatGPT.
- f. Pengiriman *Prompt* ke API ChatGPT: *Prompt* evaluasi dikirimkan ke ChatGPT melalui API untuk memperoleh respons jawaban model.
- g. Penerimaan Jawaban Model: Sistem menerima jawaban yang dihasilkan oleh ChatGPT sebagai output dari proses prompting.
- h. Ekstraksi Jawaban: Sistem melakukan ekstraksi jawaban untuk mengambil inti jawaban akhir dari respons model sebelum digunakan pada proses evaluasi akurasi.
- i. Penyimpanan Jawaban ChatGPT: Jawaban hasil evaluasi disimpan ke dalam *storage* sistem sebagai data hasil pengujian untuk digunakan pada tahap perhitungan akurasi.


Proses tersebut dilakukan secara berulang untuk seluruh data dalam dataset.

Flowchart ini menunjukkan bahwa metode *Chain-of-Thought* digunakan sebagai

variasi strategi *prompting* berbasis penalaran bertahap yang dibandingkan dengan metode *Non-Chain-of-Thought* dalam mengukur pengaruhnya terhadap akurasi jawaban ChatGPT pada dataset evaluasi.

3.4.3 Flowchart Perhitungan Levenshtein Distance

Flowchart perhitungan *Levenshtein Distance* ditunjukkan pada Gambar 3.30. Flowchart ini menggambarkan proses perhitungan tingkat kemiripan antara jawaban referensi dan jawaban yang dihasilkan oleh ChatGPT menggunakan algoritma *Levenshtein Distance*.



Gambar 3. 30 Flowchart Perhitungan *Levenshtein Distance*

Gambar 3.30 menunjukkan proses perhitungan yang dilakukan untuk mengukur tingkat akurasi jawaban model berdasarkan perbandingan teks. Proses ini dilakukan terhadap seluruh data hasil evaluasi yang telah diperoleh dari tahap sebelumnya. Adapun tahapan proses tersebut dijelaskan sebagai berikut:

- a. Input String Sumber dan String Target: Sistem menerima dua buah string sebagai data masukan, yaitu string sumber s berupa jawaban ChatGPT dan string target t berupa jawaban referensi.
- b. Normalisasi Teks: Sistem melakukan *preprocessing* teks dengan mengubah seluruh karakter menjadi huruf kecil (*lowercase*), menghapus tanda baca, dan menghilangkan spasi yang tidak diperlukan agar proses perbandingan lebih konsisten.
- c. Menghitung Panjang String: Sistem menghitung panjang string sumber dan string target menggunakan variabel $m = \text{len}(s)$ dan $n = \text{len}(t)$.
- d. Membuat Matriks *Levenshtein Distance*: Sistem membentuk matriks jarak berukuran $(m + 1) \times (n + 1)$ menggunakan pendekatan *dynamic programming* berdasarkan algoritma *Wagner–Fischer*. Matriks ini digunakan untuk menyimpan nilai edit *distance* pada setiap proses perbandingan karakter.
- e. Inisialisasi Baris dan Kolom Awal: Sistem menginisialisasi nilai awal pada matriks dengan ketentuan $\text{lev}(i, 0) = i$ dan $\text{lev}(0, j) = j$. Nilai tersebut merepresentasikan operasi deletion dan insertion awal.
- f. Menentukan Posisi Awal Perbandingan: Sistem menentukan posisi awal iterasi dengan nilai $i = 1$ dan $j = 1$.

- g. Membandingkan Karakter String: Sistem membandingkan karakter pada posisi $s[i]$ dan $t[j]$ untuk menentukan ada atau tidaknya perbedaan karakter.
- h. Penentuan Nilai Cost: Apabila karakter $s[i]$ dan $t[j]$ sama, maka nilai cost bernilai 0. Sebaliknya, apabila kedua karakter berbeda maka nilai cost bernilai 1.
- i. Perhitungan Operasi Minimum: Sistem menghitung nilai minimum dari tiga kemungkinan operasi edit, yaitu deletion, insertion, dan substitution berdasarkan Persamaan 2.1.
- j. Update Nilai Matriks: Nilai minimum hasil perhitungan disimpan pada matriks $lev(i, j)$ sebagai nilai edit distance sementara.
- k. Pemeriksaan Seluruh Karakter: Sistem memeriksa apakah seluruh karakter pada string telah dihitung. Proses pengisian matriks dilanjutkan hingga seluruh elemen selesai dihitung.
- l. Mengambil Nilai Akhir *Levenshtein Distance*: Sistem mengambil nilai akhir *Levenshtein Distance* pada elemen $lev(m, n)$.
- m. Perhitungan *Similarity*: Sistem melakukan normalisasi nilai *Levenshtein Distance* menjadi nilai *similarity* menggunakan Persamaan 2.2 sehingga diperoleh nilai kemiripan dalam rentang 0 sampai 1. Nilai *similarity* yang mendekati 1 menunjukkan tingkat kemiripan jawaban yang semakin tinggi.
- n. Penyimpanan Nilai *Similarity*: Hasil *similarity* disimpan ke dalam storage sistem sebagai data hasil evaluasi.

Flowchart ini menunjukkan proses perhitungan algoritma *Levenshtein Distance* yang digunakan untuk memperoleh nilai *similarity* antara jawaban model GPT-4o

mini dan jawaban referensi melalui jumlah minimum operasi edit (*insertion*, *deletion*, dan *substitution*). Nilai *similarity* tersebut digunakan sebagai hasil evaluasi tingkat kemiripan jawaban model terhadap jawaban referensi.

3.4.4 Perhitungan *Accuracy* Pengujian

Proses evaluasi menghasilkan nilai *similarity* untuk setiap jawaban yang diperoleh menggunakan algoritma *Levenshtein Distance*. Nilai *similarity* digunakan sebagai dasar penentuan benar atau salahnya jawaban model. Penelitian ini menggunakan dataset berupa soal pilihan ganda. Jawaban dinyatakan benar apabila hasil normalisasi jawaban model identik dengan jawaban referensi sehingga menghasilkan nilai *similarity* sebesar 1 (*exact match*). Nilai *similarity* yang kurang dari 1 menunjukkan adanya perbedaan antara jawaban model dan jawaban referensi sehingga jawaban dinyatakan salah. Nilai *accuracy* diperoleh dari perbandingan jumlah jawaban yang benar terhadap jumlah seluruh data pengujian. Perhitungan tersebut dirumuskan sebagai berikut.

$$Accuracy = \frac{\sum_{i=1}^N Correct_i}{N} \quad (3.1)$$

$$Correct_i = \begin{cases} 1, & Similarity_i = 1 \\ 0, & Similarity_i < 1 \end{cases}$$

Keterangan:

- a. *Accuracy* merupakan nilai akurasi hasil pengujian.
- b. $Correct_i$ bernilai 1 apabila jawaban sama persis dengan jawaban referensi.
- c. $Correct_i$ bernilai 0 apabila terdapat perbedaan karakter sekecil apa pun.
- d. N adalah merupakan jumlah seluruh data pengujian.

Nilai *Average Similarity* juga dihitung untuk memberikan gambaran tingkat kemiripan jawaban model terhadap jawaban referensi pada seluruh data pengujian. Perhitungan dilakukan menggunakan rata-rata seluruh nilai *similarity* yang diperoleh selama proses evaluasi menggunakan persamaan (2.3).

3.5 Scenariao Pengujian

Penelitian ini melakukan pengujian terhadap model GPT-4o mini untuk mengevaluasi akurasi jawaban yang dihasilkan menggunakan pendekatan *Chain-of-Thought* (CoT) dan *Non-Chain-of-Thought* (Non-CoT). Pengujian dilakukan menggunakan dataset IndoMMLU bahasa daerah yang terdiri dari sembilan domain bahasa, yaitu Bahasa Lampung, Bahasa Bali, Bahasa Makassar, Bahasa Banjar, Bahasa Madura, Bahasa Indonesia, Bahasa Dayak Ngaju, Bahasa Sunda, dan Bahasa Jawa. Hasil jawaban yang dihasilkan model kemudian dibandingkan dengan jawaban referensi menggunakan algoritma *Levenshtein Distance* untuk memperoleh nilai akurasi.

Skenario pengujian dirancang untuk menganalisis performa model GPT-4o mini pada masing-masing domain bahasa serta mengamati konsistensi performa model terhadap jumlah data uji yang berbeda.

3.5.1 Skenario 1: Pengujian Per Domain Bahasa

Skenario pertama bertujuan untuk mengetahui tingkat akurasi model GPT-4o mini pada masing-masing domain bahasa. Pengujian dilakukan secara terpisah pada setiap domain menggunakan 100 sampel soal. Setiap sampel diuji menggunakan metode CoT dan Non-CoT, kemudian hasilnya dibandingkan dengan

jawaban referensi menggunakan algoritma *Levenshtein Distance*. Adapun skenario pengujian perdomain bahasa dapat dilihat pada Tabel 3.12.

Tabel 3. 12 Scenario 1: Pengujian Per Domain Bahasa

No	Domain Bahasa	Jumlah Sampel
1	Bahasa Lampung	100
2	Bahasa Bali	100
3	Bahasa Makassar	100
4	Bahasa Banjar	100
5	Bahasa Madura	100
6	Bahasa Indonesia	100
7	Bahasa Dayak Ngaju	100
8	Bahasa Sunda	100
9	Bahasa Jawa	100
Total		900

3.5.2 Skenario 2: Pengujian Seluruh Domain dengan 25 Sampel per Domain

Skenario kedua bertujuan untuk mengevaluasi performa model GPT-4o mini pada dataset gabungan dengan ukuran sampel yang lebih kecil. Pengujian dilakukan dengan menggabungkan seluruh domain bahasa, kemudian mengambil 25 sampel soal dari masing-masing domain sehingga diperoleh total 225 soal. Seluruh soal diuji menggunakan metode CoT dan Non-CoT. Adapun skenario pengujian seluruh domain dengan 25 sampel per domain dapat dilihat pada Tabel 3.13.

Tabel 3. 13 Scenario 2: Pengujian Seluruh Domain dengan 25 Sampel per Domain

Domain yang Digunakan	Jumlah Sampel per Domain	Total Sampel
9 Domain Bahasa	25	225

3.5.3 Skenario 3: Pengujian Seluruh Domain dengan 50 Sampel per Domain

Skenario ketiga bertujuan untuk mengevaluasi performa model GPT-4o mini pada ukuran sampel menengah. Pengujian dilakukan dengan menggabungkan

seluruh domain bahasa, kemudian mengambil 50 sampel soal dari masing-masing domain sehingga diperoleh total 450 soal. Seluruh soal diuji menggunakan metode CoT dan Non-CoT. Adapun skenario pengujian seluruh domain dengan 50 sampel per domain dapat dilihat pada Tabel 3.14.

Tabel 3. 14 Skenario 3: Pengujian Seluruh Domain dengan 50 Sampel per Domain

Domain yang Digunakan	Jumlah Sampel per Domain	Total Sampel
9 Domain Bahasa	50	450

3.5.4 Skenario 4: Pengujian Seluruh Domain dengan 100 Sampel per Domain

Skenario keempat bertujuan untuk mengevaluasi performa model GPT-4o mini pada ukuran sampel yang lebih besar. Pengujian dilakukan dengan menggabungkan seluruh domain bahasa, kemudian mengambil 100 sampel soal dari masing-masing domain sehingga diperoleh total 900 soal. Seluruh soal diuji menggunakan metode CoT dan Non-CoT. Adapun skenario pengujian seluruh domain dengan 10 sampel per domain dapat dilihat pada Tabel 3.15.

Tabel 3. 15 Skenario 4: Pengujian Seluruh Domain dengan 100 Sampel per Domain

Domain yang Digunakan	Jumlah Sampel per Domain	Total Sampel
9 Domain Bahasa	100	900

Hasil dari keempat skenario pengujian tersebut kemudian dibandingkan untuk mengetahui perbedaan akurasi GPT antara metode CoT dan Non-CoT serta untuk menganalisis konsistensi performa model pada berbagai ukuran data uji. Nilai akurasi dihitung menggunakan algoritma *Levenshtein Distance* dengan

membandingkan jawaban yang dihasilkan model GPT-4o mini terhadap jawaban referensi pada dataset.

3.6 Perancangan Pengujian Sistem

Pengujian pada penelitian ini dilakukan menggunakan metode *Black Box Testing*. Pengujian *Black Box* bertujuan untuk menguji fungsi-fungsi pada sistem berdasarkan masukan dan keluaran yang dihasilkan tanpa melihat struktur kode program. Pengujian dilakukan untuk memastikan bahwa seluruh fitur pada aplikasi pengujian performa model GPT-4o mini menggunakan metode *Chain-of-Thought* (CoT) dan Non-CoT, serta perhitungan tingkat kemiripan jawaban menggunakan algoritma *Levenshtein Distance*, dapat berjalan sesuai dengan kebutuhan pengguna dan menghasilkan keluaran yang sesuai dengan rancangan sistem.

3.5.5 Scenario Pengujian Halaman Dataset

Perancangan pengujian halaman dataset bertujuan untuk memastikan bahwa pengguna dapat mengunggah dataset, mengunduh dataset IndoMMLU, mengunduh *template* dataset, menambah data secara manual, serta menghapus data dataset. Adapun scenario pengujian halaman dataset dapat dilihat pada Tabel 3.16.

Tabel 3. 16 Scenario Pengujian Halaman Dataset

No	Pengujian	Test Case	Hasil Yang Diharapkan
1	Membuka halaman dataset	Menekan menu dataset	Halaman dataset berhasil ditampilkan
2	Mengunggah dataset format CSV	Mengunggah file CSV sesuai format	Dataset berhasil diunggah
3	Mengunggah file selain CSV	Mengunggah file PDF atau XLSX	Sistem menampilkan pesan gagal upload

No	Pengujian	Test Case	Hasil Yang Diharapkan
4	Mengunggah dataset dengan format tidak sesuai	Struktur kolom tidak sesuai template	Sistem menampilkan pesan gagal upload
5	Mengunduh dataset IndoMMLU	Menekan tombol Dataset IndoMMLU	Dataset berhasil diunduh
6	Mengunduh <i>template</i> dataset	Menekan tombol <i>Template CSV</i>	<i>Template</i> berhasil diunduh
7	Menambah data dataset	Menekan tombol Tambah Data dan mengisi form	Data berhasil ditambahkan
8	Menghapus data dataset	Menekan tombol hapus pada data	Data berhasil dihapus

3.5.6 Scenario Pengujian Halaman Proses Pengujian

Perancangan pengujian halaman proses pengujian bertujuan untuk memastikan bahwa sistem dapat menjalankan evaluasi akurasi ChatGPT menggunakan metode Non-CoT dan CoT berdasarkan dataset yang telah diunggah. Adapun scenario pengujian halaman proses pengujian dapat dilihat pada Tabel 3.17.

Tabel 3. 17 Scenario Pengujian Halaman Proses Pengujian

No	Pengujian	Test Case	Hasil Yang Diharapkan
1	Membuka halaman proses pengujian	Menekan menu proses pengujian	Halaman proses pengujian berhasil ditampilkan
2	Menjalankan pengujian	Menekan tombol Jalankan Pengujian	Proses evaluasi berhasil dimulai
3	Menampilkan status proses pengujian	Pengujian sedang berlangsung	Status proses pengujian ditampilkan
4	Menampilkan hasil pengujian selesai	Pengujian berhasil diselesaikan	Sistem menampilkan informasi pengujian selesai
5	Menjalankan pengujian tanpa dataset	Dataset belum tersedia	Sistem menampilkan pesan peringatan

3.5.7 Scenario Pengujian Halaman Hasil Pengujian

Perancangan pengujian halaman hasil pengujian bertujuan untuk memastikan bahwa sistem dapat menampilkan hasil evaluasi dan tabel hasil pengujian secara benar. Adapun scenario pengujian halaman hasil pengujian dapat dilihat pada Tabel 3.18.

Tabel 3. 18 Scenario Pengujian Halaman Hasil Pengujian

No	Pengujian	<i>Test Case</i>	Hasil Yang Diharapkan
1	Membuka halaman hasil pengujian	Menekan menu hasil pengujian	Halaman hasil pengujian berhasil ditampilkan
2	Menampilkan ringkasan hasil pengujian	Pengujian selesai dilakukan	Informasi akurasi CoT dan Non-CoT berhasil ditampilkan
3	Menampilkan tabel hasil pengujian	Pengujian selesai dilakukan	Tabel hasil pengujian berhasil ditampilkan
4	Menampilkan tabel riwayat pengujian	Data evaluasi tersimpan tersedia	Tabel riwayat pengujian berhasil ditampilkan
5	Menampilkan hasil evaluasi dari riwayat pengujian	Menekan tombol lihat pada salah satu riwayat	Seluruh halaman hasil pengujian berubah sesuai data yang dipilih
6	Membuka halaman hasil pengujian tanpa data	Belum melakukan pengujian	Sistem menampilkan informasi belum ada hasil evaluasi

3.5.8 Scenario Pengujian Halaman Visualisasi

Perancangan pengujian halaman visualisasi bertujuan untuk memastikan bahwa sistem dapat menampilkan statistik dan grafik hasil evaluasi secara benar. Adapun scenario pengujian halaman visualisasi dapat dilihat pada Tabel 3.19.

Tabel 3. 19 Scenario Pengujian Halaman Visualisasi

No	Pengujian	<i>Test Case</i>	Hasil Yang Diharapkan
1	Membuka halaman visualisasi	Menekan menu visualisasi	Halaman visualisasi berhasil ditampilkan

No	Pengujian	Test Case	Hasil Yang Diharapkan
2	Menampilkan grafik hasil pengujian	Data hasil pengujian tersedia	Grafik perbandingan CoT dan Non-CoT berhasil ditampilkan
3	Menampilkan statistik pengujian	Data hasil pengujian tersedia	Informasi rata-rata akurasi, total data, dan total subject berhasil ditampilkan
4	Membuka halaman visualisasi tanpa data	Belum melakukan pengujian	Sistem menampilkan informasi belum ada data visualisasi

3.5.9 Scenario Pengujian Halaman Laporan

Perancangan pengujian halaman laporan bertujuan untuk memastikan bahwa sistem dapat menampilkan laporan hasil evaluasi serta melakukan export laporan dalam format PDF dan Excel. Adapun scenario pengujian halaman laporan dapat dilihat pada Tabel 3.20.

Tabel 3. 20 Scenario Pengujian Halaman Laporan

No	Pengujian	Test Case	Hasil Yang Diharapkan
1	Membuka halaman laporan	Menekan menu laporan	Halaman laporan berhasil ditampilkan
2	Menampilkan ringkasan laporan	Data hasil pengujian tersedia	Ringkasan hasil evaluasi berhasil ditampilkan
3	Preview laporan PDF	Menekan tombol Preview PDF	Laporan PDF berhasil ditampilkan
4	Mengunduh laporan PDF	Menekan tombol <i>Download</i> PDF	File PDF berhasil diunduh
5	Mengunduh laporan Excel	Menekan tombol <i>Download</i> Excel	File Excel berhasil diunduh
6	Membuka halaman laporan tanpa data	Belum melakukan pengujian	Sistem menampilkan informasi belum ada laporan

BAB IV

HASIL DAN PEMBAHASAN

Bab ini menyajikan hasil implementasi dan pembahasan aplikasi evaluasi akurasi model GPT-4o mini menggunakan dataset IndoMMLU yang telah dirancang dalam Bab III. Implementasi sistem mencakup pembangunan antarmuka aplikasi, *preprocessing* dataset, integrasi API GPT-4o mini dengan pendekatan *Non-Chain-of-Thought* (Non-CoT) dan *Chain-of-Thought* (CoT), serta perhitungan *similarity* jawaban menggunakan algoritma *Levenshtein Distance*. Bab ini juga membahas hasil pengujian model GPT-4o mini berdasarkan skenario pengujian yang telah ditentukan, meliputi perbandingan performa metode CoT dan Non-CoT, analisis nilai *similarity*, penggunaan token, waktu respons, serta pengujian fungsionalitas sistem menggunakan metode *black box*.

4.1 Implementasi Aplikasi Pengujian Model GPT-4o Mini


Implementasi aplikasi merupakan tahapan realisasi dari hasil perancangan sistem yang telah dijelaskan pada Bab III. Seluruh rancangan antarmuka dan fungsionalitas diwujudkan menjadi aplikasi berbasis web menggunakan framework Laravel. Aplikasi yang dikembangkan digunakan untuk melakukan pengujian akurasi jawaban model GPT-4o mini terhadap soal-soal pada dataset IndoMMLU menggunakan dua pendekatan, yaitu *Non-Chain-of-Thought* (Non-CoT) dan *Chain-of-Thought* (CoT). Hasil jawaban yang dihasilkan oleh kedua metode tersebut kemudian dibandingkan dengan jawaban referensi menggunakan algoritma *Levenshtein Distance* untuk menghitung tingkat kemiripan dalam bentuk persentase akurasi. Implementasi yang dibahas meliputi halaman beranda, pengelolaan

dataset, proses pengujian, hasil pengujian, visualisasi hasil evaluasi, serta laporan hasil pengujian. Penjelasan mengenai implementasi setiap halaman aplikasi disajikan pada subbab berikut.

a. Implementasi Halaman Beranda

Halaman beranda merupakan halaman utama yang ditampilkan ketika pengguna pertama kali mengakses aplikasi EvalGPT. Halaman ini berfungsi sebagai media informasi mengenai tujuan aplikasi, gambaran proses pengujian, serta metode yang digunakan dalam melakukan evaluasi akurasi model GPT-4o mini.

Informasi yang ditampilkan mencakup penjelasan singkat mengenai dataset IndoMMLU, metode Non-CoT dan CoT, serta penggunaan algoritma *Levenshtein Distance* dalam proses pengukuran *similarity* jawaban. Halaman beranda juga menyediakan navigasi menuju fitur utama aplikasi sehingga pengguna dapat memahami alur penggunaan sistem sebelum melakukan proses pengujian. Tampilan halaman beranda ditunjukkan pada Gambar 4.1.



Gambar 4. 1 Implementasi Halaman Beranda

Gambar 4.1 menunjukkan implementasi halaman beranda aplikasi EvalGPT yang telah berhasil dibangun. Bagian utama halaman

menampilkan penjelasan singkat mengenai fungsi aplikasi sebagai media untuk menguji tingkat akurasi jawaban model GPT-4o mini menggunakan dataset IndoMMLU. Halaman ini juga memberikan gambaran umum mengenai tahapan penggunaan aplikasi sehingga pengguna dapat memahami proses pengujian sebelum menggunakan seluruh fitur yang tersedia.

Alur penggunaan sistem terdiri atas lima tahapan utama, yaitu mengunggah dataset, menjalankan proses pengujian, melihat hasil pengujian, melihat visualisasi hasil evaluasi, serta mengunduh laporan hasil pengujian. Penyajian alur tersebut membantu pengguna memahami proses kerja aplikasi secara keseluruhan.

Halaman beranda juga menyajikan penjelasan mengenai metode *Chain-of-Thought* (CoT) dan Non-CoT yang digunakan selama proses evaluasi. Metode *Chain-of-Thought* menghasilkan jawaban melalui tahapan penalaran secara bertahap sebelum memberikan jawaban akhir, sedangkan metode Non-CoT menghasilkan jawaban secara langsung tanpa melalui proses penalaran. Perbandingan kedua metode tersebut digunakan untuk mengetahui perbedaan tingkat akurasi jawaban yang dihasilkan oleh model GPT-4o mini.


Bagian bawah halaman menampilkan informasi mengenai algoritma *Levenshtein Distance* yang digunakan untuk menghitung tingkat kemiripan antara jawaban model GPT-4o mini dan jawaban referensi pada dataset IndoMMLU. Perhitungan tingkat kemiripan dilakukan berdasarkan jumlah

operasi penyisipan karakter (*insertion*), penghapusan karakter (*deletion*), dan penggantian karakter (*substitution*). Hasil perhitungan tersebut kemudian dikonversi menjadi persentase akurasi yang digunakan sebagai dasar evaluasi terhadap jawaban yang dihasilkan oleh model GPT-4o mini.

b. Implementasi Halaman Dataset

1) Implementasi Halaman *Download* Dataset IndoMMLU, *Template* Dataset dan Unggah Dataset

Halaman dataset diimplementasikan sebagai media untuk mengelola data yang akan digunakan selama proses pengujian. Halaman ini menyediakan fasilitas untuk mengunduh dataset IndoMMLU, mengunduh *template* dataset dalam format CSV, serta mengunggah dataset ke dalam aplikasi. Tampilan halaman dataset ditunjukkan pada Gambar 4.2.



Gambar 4. 2 Implementasi Halaman Unggah Dataset


Gambar 4.2 menunjukkan implementasi halaman dataset yang telah berhasil dibangun. Bagian kiri halaman tersedia area unggah dataset yang memungkinkan pengguna memilih file dataset berformat CSV

melalui tombol Pilih File Dataset. Setelah file dipilih, pengguna dapat menekan tombol Upload Dataset untuk memulai proses unggah ke dalam aplikasi.

Bagian kanan halaman menyediakan tombol IndoMMLU Dataset yang digunakan untuk mengunduh dataset penelitian sebagai sumber data pengujian. Selain itu, tersedia pula tombol *Template CSV* yang dapat diunduh sebagai panduan penyusunan dataset sesuai dengan format yang telah ditentukan oleh sistem.

2) Implementasi Halaman Dataset Gagal Diunggah

Halaman dataset gagal diunggah diimplementasikan untuk memberikan informasi kepada pengguna apabila proses unggah dataset tidak berhasil dilakukan. Kondisi ini terjadi ketika format dataset tidak sesuai dengan *template* yang telah ditentukan oleh sistem. Tampilan halaman ditunjukkan pada Gambar 4.3.



Gambar 4. 3 Implementasi Halaman Dataset Gagal Diunggah

Gambar 4.3 menunjukkan kondisi ketika pengguna telah memilih file dataset kemudian menekan tombol Upload Dataset, namun sistem mendeteksi adanya ketidaksesuaian format data. Setelah proses validasi dilakukan, aplikasi menampilkan notifikasi "Upload Gagal" yang berisi informasi mengenai kesalahan yang ditemukan pada dataset.

Implementasi validasi tersebut bertujuan untuk mencegah data yang tidak sesuai masuk ke dalam sistem sehingga proses evaluasi dapat berjalan dengan baik. Pengguna dapat memperbaiki format dataset sesuai dengan *template* CSV yang telah disediakan, kemudian melakukan proses unggah kembali hingga dataset berhasil dimuat ke dalam aplikasi.

3) Implementasi Halaman Dataset Berhasil Diunggah

Halaman dataset berhasil diunggah ditampilkan setelah proses unggah dataset selesai dilakukan tanpa mengalami kesalahan. Halaman ini memberikan konfirmasi kepada pengguna bahwa dataset telah berhasil dimuat dan siap digunakan pada proses pengujian. Tampilan halaman ditunjukkan pada Gambar 4.4.

EvalGPT
Sistem Evaluasi GPT

Beranda
Dataset
Proses Pengujian
Hasil Pengujian
Visualisasi
Laporan

Upload Dataset Pengujian ChatGPT

Upload dataset CSV atau tambahkan data secara manual untuk pengujian performa ChatGPT menggunakan metode Chain of Thought (CoT) dan Non-CoT berbasis Levenshtein Distance.

Upload File Dataset CSV
Klik area ini untuk memilih dataset. Pastikan struktur dataset sesuai template.

Download Dataset & Template
Gunakan dataset IndoMMLU untuk pengujian atau download template CSV untuk membuat dataset sendiri sesuai format sistem.

IndoMMLU Dataset
Dataset pengujian bawaan

Template CSV
Format dataset sistem

Dataset Aktif
Dataset_12_9Domain_1005soal_Total900_20260719_105055.csv

Berhasil
Dataset berhasil diupload.

Dataset Preview
Menampilkan 10 data per halaman. Klik ikon hapus untuk menghapus baris.

NO	SUBJECT	SOAL	PILIHAN GANDA	KUNCI	NARASI JAWABAN	AKSI
1	Bahasa Lampung	Anak huruf bicek berbunyi	A. An B. I C. E	C	E	
2	Bahasa Lampung	Tarian yang berasal dari daerah Lampung adalah...	A. Tari Cangget B. Tari Kecak C. Tari Serampang 12	A	Tari Cangget	
3	Bahasa Lampung	Arti dari "Tijan lapah mit sekula"	A. Mereka pergi ke sekolah B. Mereka pergi ke pasar C. Mereka pergi ke rumah kakek	A	Mereka pergi ke sekolah	
4	Bahasa Lampung	Aksara Lampung memiliki jumlah	A. 20 B. 15 C. 25	A	20	
5	Bahasa Lampung	Kemian artinya	A. Paman B. Bibi C. Kakek	B	Bibi	
6	Bahasa Lampung	"Gigi" bahasa lampung nya....	A. Ipon B. Buwok C. Kukut	C	Kukut	
7	Bahasa Lampung	Dalam bahasa lampung kata "Debigi" ialah....	A. Malam B. Sore C. Pagi	C	Pagi	
8	Bahasa Lampung	Asri pergi ke rumah bibi jika di terjemahkan kedalam bahasa lampung adalah	A. Asri lapah mit lamban kemanan B. Asri lapah mit sekula C. Asri lapah mit lamban kemaman	C	Asri lapah mit lamban kemaman	
9	Bahasa Lampung	Naik bahasa lampunya adalah	A. Cakak B. Debah C. Lambung	C	Lambung	
10	Bahasa Lampung	Anak huruf yang terletak dibawah adalah	A. I Dan E B. E Dan An C. An Dan U	C	An Dan U	

Showing 1 to 10 of 900 results

Prev 1 2 ... 90 Next

© 2026 EvalGPT

Gambar 4. 4 Implementasi Halaman Dataset Berhasil Diunggah


Gambar 4.4 menunjukkan implementasi halaman setelah dataset berhasil diunggah ke dalam aplikasi. Sistem menampilkan notifikasi "Berhasil" sebagai informasi bahwa proses unggah telah selesai

dilakukan. Dataset yang berhasil dimuat kemudian langsung ditampilkan pada bagian Preview Dataset dalam bentuk tabel.

Tabel preview menampilkan informasi berupa subject, soal, pilihan jawaban, kunci jawaban, dan narasi jawaban benar sehingga pengguna dapat melakukan pemeriksaan terhadap data yang telah diunggah. Selain itu, jumlah total data pada dataset diperbarui secara otomatis sesuai dengan banyaknya data yang berhasil dimuat ke dalam aplikasi.

4) Implementasi Modal Tambah Data Dataset

Fitur tambah data diimplementasikan untuk memberikan kemudahan kepada pengguna dalam menambahkan data baru secara manual tanpa harus mengunggah ulang keseluruhan dataset. Fitur ini ditampilkan dalam bentuk modal yang muncul ketika pengguna menekan tombol Tambah Data. Tampilan modal ditunjukkan pada Gambar 4.5.



Tambah Data Manual
Data akan disimpan ke CSV dataset aktif

Subject *
Contoh: Bahasa Indonesia, Matematika ...

Kunci Jawaban *
-- Pilih Kunci --

Soal *
Tulis soal di sini ...

Pilihan Jawaban *
Contoh: A. Bandung | B. Jakarta | C. Surabaya | D. Medan
Pisahkan pilihan dengan tanda | (pipe)

Narasi Jawaban Benar *
Contoh: Ibu kota Indonesia adalah Jakarta.
Penjelasan lengkap jawaban yang benar.

🔔 Data akan otomatis ditambahkan ke dataset CSV yang aktif.


Batal + Simpan Data

Gambar 4. 5 Implementasi Modal Tambah Data Dataset

Gambar 4.5 menunjukkan implementasi modal tambah data yang berisi beberapa komponen isian, yaitu subject, soal, pilihan jawaban, kunci jawaban, serta narasi jawaban benar. Seluruh informasi tersebut harus diisi sebelum data dapat disimpan ke dalam dataset aktif. Bagian bawah modal tersedia tombol Simpan Data untuk menyimpan data yang telah diinputkan serta tombol Batal untuk menutup modal tanpa menyimpan perubahan. Implementasi fitur ini memungkinkan pengguna melakukan penambahan data secara langsung sehingga proses pengelolaan dataset menjadi lebih fleksibel.

5) Implementasi Halaman Tambah Data Dataset Berhasil

Halaman tambah data berhasil ditampilkan setelah pengguna berhasil menyimpan data baru ke dalam dataset aktif. Halaman ini memberikan konfirmasi bahwa proses penambahan data telah berhasil dilakukan. Tampilan halaman ditunjukkan pada Gambar 4.6.




Gambar 4. 6 Implementasi Halaman Tambah Data Dataset Berhasil

Gambar 4.6 menunjukkan implementasi halaman setelah proses penambahan data selesai dilakukan. Sistem menampilkan notifikasi "Berhasil" sebagai informasi bahwa data baru telah berhasil disimpan. Data yang baru ditambahkan langsung muncul pada bagian preview dataset sehingga pengguna dapat memastikan bahwa data telah tersimpan dengan benar. Jumlah total data pada dataset juga diperbarui secara otomatis sesuai dengan jumlah data terbaru. Implementasi tersebut membantu pengguna melakukan verifikasi terhadap data yang telah ditambahkan tanpa harus memuat ulang halaman.

6) Implementasi Halaman Hapus Dataset Berhasil

Fitur hapus data diimplementasikan untuk memberikan kemudahan kepada pengguna dalam menghapus data yang tidak diperlukan dari

dataset aktif. Setelah proses penghapusan berhasil dilakukan, aplikasi menampilkan notifikasi sebagai konfirmasi kepada pengguna. Tampilan halaman ditunjukkan pada Gambar 4.7.




Gambar 4. 7 Implementasi Halaman Hapus Dataset Berhasil

Gambar 4.7 menunjukkan implementasi halaman setelah pengguna berhasil menghapus salah satu data pada dataset. Sistem menampilkan notifikasi "Berhasil" sebagai informasi bahwa data telah berhasil dihapus dari dataset aktif. Data yang telah dihapus tidak lagi ditampilkan pada tabel preview dataset dan jumlah total data akan berkurang secara otomatis. Implementasi fitur ini membantu pengguna menjaga kualitas dataset yang digunakan selama proses pengujian sehingga hanya data yang valid yang digunakan pada proses evaluasi model GPT-4o mini.

c. Implementasi Halaman Proses Pengujian

Halaman proses pengujian diimplementasikan sebagai media untuk menjalankan proses pengujian akurasi jawaban model GPT-4o mini menggunakan metode *Non-Chain-of-Thought* (Non-CoT) dan *Chain-of-Thought* (CoT) secara otomatis terhadap dataset yang telah diunggah. Halaman ini pengguna dapat memulai proses pengujian, memantau informasi metode yang digunakan, serta memastikan bahwa aplikasi telah siap melakukan evaluasi. Tampilan halaman proses pengujian ditunjukkan pada Gambar 4.8.



Gambar 4. 8 Implementasi Implementasi Halaman Proses Pengujian

Gambar 4.8 menunjukkan implementasi halaman proses pengujian yang telah berhasil dibangun. Pada bagian utama halaman tersedia tombol Jalankan Pengujian yang digunakan untuk memulai proses pengujian terhadap seluruh data pada dataset aktif. Ketika tombol tersebut ditekan,

aplikasi akan membaca setiap data soal, kemudian mengirimkan pertanyaan kepada model GPT-4o mini menggunakan dua jenis prompt, yaitu *prompt* Non-CoT dan *prompt* CoT.

Selama proses pengujian berlangsung, aplikasi secara otomatis menghasilkan jawaban dari kedua metode tersebut. Jawaban yang diperoleh kemudian dibandingkan dengan jawaban referensi menggunakan algoritma *Levenshtein Distance* untuk memperoleh nilai kemiripan dalam bentuk persentase. Proses tersebut dilakukan secara berulang hingga seluruh data pada dataset selesai dievaluasi. Selain tombol pengujian, halaman ini juga menampilkan informasi mengenai metode yang digunakan selama proses pengujian. Informasi tersebut meliputi Direct Answer (Non-CoT), Step Reasoning (CoT), serta *Accuracy Test* menggunakan algoritma *Levenshtein Distance*. Penyajian informasi tersebut bertujuan untuk memberikan gambaran kepada pengguna mengenai tahapan yang dilakukan oleh aplikasi selama proses evaluasi berlangsung.


Bagian bawah halaman ditampilkan informasi status sistem sebagai indikator bahwa aplikasi telah siap melakukan proses pengujian. Informasi tersebut membantu pengguna memastikan bahwa dataset telah tersedia dan aplikasi dapat menjalankan proses evaluasi tanpa mengalami kendala..

d. Implementasi Halaman Hasil Pengujian

1) Implementasi Halaman Hasil Pengujian Belum Melakukan Pengujian

Halaman hasil pengujian sebelum pengujian dilakukan diimplementasikan untuk memberikan informasi bahwa aplikasi belum

memiliki data hasil evaluasi. Kondisi ini ditampilkan ketika pengguna belum menjalankan proses pengujian terhadap dataset yang tersedia. Tampilan halaman ditunjukkan pada Gambar 4.9.




Gambar 4. 9 Implementasi Halaman Hasil Pengujian Belum Melakukan Pengujian

Gambar 4.9 menunjukkan kondisi awal halaman hasil pengujian ketika belum terdapat data evaluasi yang dihasilkan oleh aplikasi. Seluruh informasi statistik seperti Total Data, Total Subject, Rata-rata Akurasi Non-CoT, Rata-rata Akurasi CoT, Peningkatan Performa, serta Akurasi Terbaik masih bernilai nol karena proses pengujian belum dijalankan. Bagian utama halaman ditampilkan pesan "Belum Ada Hasil Evaluasi" sebagai informasi bahwa aplikasi belum memiliki data yang dapat ditampilkan. Pesan tersebut juga mengarahkan pengguna untuk mengunggah dataset dan menjalankan proses pengujian terlebih dahulu sebelum hasil evaluasi dapat ditampilkan pada halaman ini.

Implementasi halaman ini bertujuan memberikan umpan balik yang jelas kepada pengguna mengenai kondisi aplikasi sehingga pengguna mengetahui bahwa proses evaluasi belum pernah dilakukan.

2) Implementasi Halaman Hasil Pengujian Sudah Melakukan Pengujian

Halaman hasil pengujian diimplementasikan untuk menampilkan seluruh hasil evaluasi yang diperoleh setelah aplikasi menyelesaikan proses pengujian terhadap dataset menggunakan metode Non-CoT dan CoT. Tampilan halaman hasil pengujian ditunjukkan pada Gambar 4.10.



Gambar 4. 10 Implementasi Halaman Hasil Pengujian Sudah Melakukan Pengujian

Gambar 4.10 menunjukkan implementasi halaman hasil pengujian setelah proses evaluasi berhasil diselesaikan. Pada bagian atas halaman ditampilkan ringkasan statistik hasil pengujian yang terdiri atas Total


Data, Total Subject, Rata-rata Akurasi Non-CoT, Rata-rata Akurasi CoT, Peningkatan Performa, serta Akurasi Terbaik. Ringkasan tersebut memberikan gambaran umum mengenai performa model GPT-4o mini pada dataset yang telah diuji. Di bawah ringkasan statistik ditampilkan tabel hasil pengujian yang memuat informasi secara rinci untuk setiap data. Tabel tersebut terdiri atas kolom Soal, Jawaban Referensi, Jawaban Non-CoT, Nilai Kemiripan Non-CoT, Jawaban CoT, dan Nilai Kemiripan CoT. Melalui tabel tersebut pengguna dapat membandingkan jawaban yang dihasilkan oleh kedua metode terhadap jawaban referensi pada setiap soal.

Nilai kemiripan pada masing-masing metode diperoleh menggunakan algoritma *Levenshtein Distance*, yang menghitung tingkat kesamaan antara jawaban model GPT-4o mini dengan jawaban referensi. Nilai tersebut kemudian dikonversi ke dalam bentuk persentase sehingga memudahkan pengguna dalam melakukan interpretasi terhadap hasil evaluasi. Implementasi halaman hasil pengujian tidak hanya menampilkan nilai akhir berupa rata-rata akurasi, tetapi juga menyajikan seluruh hasil evaluasi secara rinci sehingga pengguna dapat melakukan analisis terhadap performa masing-masing metode pada setiap data yang diuji.

3) Implementasi Riwayat Pengujian Belum Tersedia

Halaman riwayat pengujian sebelum tersedia diimplementasikan untuk memberikan informasi bahwa aplikasi belum memiliki data

riwayat pengujian yang tersimpan. Kondisi ini muncul ketika pengguna belum pernah menyimpan hasil pengujian setelah proses evaluasi selesai dilakukan. Tampilan halaman ditunjukkan pada Gambar 4.11.



Gambar 4. 11 Implementasi Riwayat Pengujian Belum Tersedia

Gambar 4.11 menunjukkan kondisi ketika belum terdapat riwayat pengujian yang tersimpan pada aplikasi. Pada bagian riwayat ditampilkan pesan "Belum Ada Riwayat Pengujian" sebagai informasi bahwa pengguna belum memiliki data riwayat yang dapat ditampilkan. Selain pesan tersebut, tabel riwayat pengujian masih dalam keadaan kosong karena belum terdapat hasil pengujian yang disimpan. Implementasi halaman ini memberikan informasi yang jelas mengenai kondisi aplikasi sehingga pengguna mengetahui bahwa riwayat pengujian baru akan tersedia setelah proses evaluasi dilakukan dan hasilnya disimpan.

4) Implementasi Riwayat Pengujian Tersedia

Halaman riwayat pengujian diimplementasikan untuk menampilkan seluruh data hasil pengujian yang telah disimpan oleh pengguna. Fitur ini memudahkan pengguna untuk melihat kembali hasil evaluasi tanpa

perlu menjalankan proses pengujian ulang. Tampilan halaman ditunjukkan pada Gambar 4.12.

DATASET	NON-COT	COT	TANGGAL	STATUS	AKSI
Dataset_12_9Domain_100Soal_Total900_20260716_173332.csv	67.3%	65.51%	16 Jul 2026 17:33	Selesai	Lihat
Dataset_11_9Domain_50Soal_Total450_20260716_163736.csv	70.18%	69.37%	16 Jul 2026 16:40	Selesai	Lihat
Dataset_10_9Domain_25Soal_Total225_20260716_160321.csv	68.6%	68.27%	16 Jul 2026 16:06	Selesai	Lihat
Dataset_9_Bahasa_Jawa_100_20260716_154714.csv	76.18%	77.23%	16 Jul 2026 15:49	Selesai	Lihat
Dataset_8_Bahasa_Sunda_100_20260716_153223.csv	69.7%	73.39%	16 Jul 2026 15:33	Selesai	Lihat

Gambar 4. 12 Implementasi Riwayat Pengujian Tersedia

Gambar 4.12 menunjukkan implementasi halaman riwayat pengujian setelah pengguna berhasil menyimpan hasil evaluasi. Riwayat pengujian ditampilkan dalam bentuk tabel yang berisi daftar seluruh pengujian yang pernah dilakukan beserta informasi pendukung, seperti nama dataset, waktu pengujian, dan aksi yang dapat dilakukan terhadap data tersebut. Setiap data riwayat tersedia tombol Lihat yang digunakan untuk membuka kembali hasil pengujian yang telah dipilih. Setelah tombol tersebut ditekan, aplikasi akan menampilkan kembali seluruh informasi yang berkaitan dengan pengujian tersebut, meliputi hasil evaluasi, visualisasi grafik, serta laporan yang telah dihasilkan sebelumnya.


Implementasi fitur riwayat pengujian memberikan kemudahan kepada pengguna dalam mendokumentasikan hasil evaluasi sehingga

setiap pengujian yang telah dilakukan dapat diakses kembali sewaktu-waktu tanpa harus mengulangi proses pengujian terhadap dataset yang sama.

e. Implementasi Halaman Visualisasi Hasil Pengujian

1) Implementasi Halaman Visualisasi Belum Melakukan Pengujian

Halaman visualisasi sebelum pengujian dilakukan diimplementasikan untuk memberikan informasi bahwa data hasil evaluasi belum tersedia sehingga grafik perbandingan performa metode belum dapat ditampilkan. Kondisi ini muncul ketika pengguna belum menjalankan proses pengujian terhadap dataset yang telah diunggah. Tampilan halaman visualisasi ditunjukkan pada Gambar 4.13.



Gambar 4. 13 Halaman Visualisasi Belum Melakukan Pengujian


Gambar 4.13 menunjukkan kondisi awal halaman visualisasi ketika aplikasi belum memiliki data hasil evaluasi. Seluruh informasi statistik, seperti Total Data, Total Subject, Rata-rata Akurasi Non-CoT, Rata-rata

Akurasi CoT, Peningkatan Performa, serta Akurasi Terbaik, masih bernilai nol. Pada bagian utama halaman belum ditampilkan grafik karena proses pengujian belum dilakukan. Selain itu, aplikasi menampilkan pesan informasi bahwa visualisasi hasil evaluasi belum tersedia. Pesan tersebut mengarahkan pengguna untuk menjalankan proses pengujian terlebih dahulu agar aplikasi dapat menghasilkan grafik berdasarkan hasil evaluasi yang telah diperoleh.

Implementasi halaman ini bertujuan memberikan informasi yang jelas mengenai kondisi aplikasi sehingga pengguna memahami bahwa visualisasi hanya dapat ditampilkan apabila telah tersedia data hasil pengujian.

2) Implementasi Halaman Visualisasi Sudah Melakukan Pengujian

Halaman visualisasi diimplementasikan untuk menyajikan hasil evaluasi dalam bentuk grafik sehingga memudahkan pengguna dalam membandingkan performa metode *Non-Chain-of-Thought* (Non-CoT) dan *Chain-of-Thought* (CoT) pada setiap subject dalam dataset. Tampilan halaman visualisasi ditunjukkan pada Gambar 4.14.



Gambar 4. 14 Implementasi Halaman Visualisasi Sudah Melakukan Pengujian

Gambar 4.14 menunjukkan implementasi halaman visualisasi setelah proses pengujian berhasil diselesaikan. Pada bagian atas halaman ditampilkan ringkasan statistik yang meliputi Total Data, Total Subject, Rata-rata Akurasi Non-CoT, Rata-rata Akurasi CoT, Peningkatan Performa, serta Akurasi Terbaik sebagai gambaran umum hasil evaluasi. Bagian utama halaman menampilkan grafik perbandingan nilai akurasi metode Non-CoT dan CoT pada setiap subject yang terdapat dalam dataset. Grafik tersebut disusun berdasarkan hasil perhitungan algoritma *Levenshtein Distance* yang telah dikonversi ke dalam bentuk persentase sehingga memudahkan pengguna dalam melakukan analisis terhadap performa kedua metode.


Melalui visualisasi tersebut, pengguna dapat dengan mudah mengidentifikasi subject yang memiliki tingkat akurasi tertinggi maupun terendah pada masing-masing metode. Selain itu, perbedaan performa antara metode Non-CoT dan CoT juga dapat diamati secara lebih jelas dibandingkan hanya melihat data dalam bentuk tabel.

Implementasi halaman visualisasi memberikan kemudahan bagi pengguna dalam melakukan interpretasi hasil evaluasi karena informasi disajikan dalam bentuk grafik yang lebih mudah dipahami dibandingkan data numerik secara langsung.

f. Implementasi Halaman Laporan Hasil Pengujian

1) Implementasi Halaman Laporan Belum Melakukan Pengujian

Halaman laporan sebelum pengujian dilakukan diimplementasikan untuk memberikan informasi bahwa laporan hasil evaluasi belum tersedia karena proses pengujian belum dijalankan. Kondisi ini muncul ketika aplikasi belum memiliki data hasil evaluasi yang dapat disusun menjadi laporan. Tampilan halaman laporan ditunjukkan pada Gambar 4.15.




Gambar 4. 15 Implementasi Halaman Laporan Belum Melakukan Pengujian

Gambar 4.15 menunjukkan kondisi ketika pengguna membuka halaman laporan sebelum proses pengujian dilakukan. Pada halaman tersebut aplikasi menampilkan informasi bahwa laporan belum tersedia karena belum terdapat hasil evaluasi yang dapat diolah menjadi dokumen laporan.

Implementasi halaman ini memberikan petunjuk kepada pengguna bahwa proses pengujian harus diselesaikan terlebih dahulu sebelum fitur pembuatan laporan dapat digunakan. Dengan demikian, pengguna dapat memahami urutan penggunaan aplikasi secara lebih jelas.

2) Implementasi Halaman Laporan Sudah Melakukan Pengujian

Halaman laporan diimplementasikan untuk menyajikan ringkasan hasil evaluasi yang telah diperoleh setelah proses pengujian selesai dilakukan. Halaman ini juga menyediakan fasilitas untuk mengunduh laporan dalam format PDF serta hasil pengujian dalam format Microsoft Excel. Tampilan halaman laporan ditunjukkan pada Gambar 4.16.



Gambar 4. 16 Implementasi Halaman Laporan Sudah Melakukan Pengujian

Gambar 4.16 menunjukkan implementasi halaman laporan setelah proses pengujian berhasil diselesaikan. Bagian atas halaman ditampilkan ringkasan hasil evaluasi yang terdiri atas Total Data, Total Subject, Rata-rata Akurasi Non-CoT, Rata-rata Akurasi CoT, Peningkatan Performa, serta Akurasi Terbaik. Informasi tersebut memberikan gambaran umum mengenai hasil evaluasi yang telah dilakukan oleh aplikasi. Di bawah ringkasan hasil evaluasi tersedia dua fitur utama, yaitu *Download PDF* dan *Download Excel*. Tombol *Download PDF* digunakan untuk mengunduh laporan hasil evaluasi dalam bentuk dokumen PDF yang berisi ringkasan statistik, hasil

perbandingan metode, serta informasi pendukung lainnya. Sementara itu, tombol *Download Excel* digunakan untuk mengunduh seluruh data hasil pengujian dalam format Microsoft Excel sehingga pengguna dapat melakukan analisis lebih lanjut menggunakan perangkat lunak pengolahan data.

Implementasi kedua fitur tersebut memberikan kemudahan bagi pengguna dalam menyimpan, mendokumentasikan, serta membagikan hasil evaluasi kepada pihak lain tanpa harus menjalankan proses pengujian kembali. Seluruh informasi yang telah dihasilkan oleh aplikasi dapat diakses kembali melalui dokumen laporan maupun file hasil pengujian yang telah diunduh.

4.2 Implementasi Preprocessing Dataset IndoMMLU

Tahap preprocessing dataset dilakukan sebelum proses pengujian model GPT-4o mini. Tahap ini bertujuan untuk menyiapkan dataset IndoMMLU agar sesuai dengan kebutuhan penelitian, yaitu hanya menggunakan domain bahasa yang menjadi objek pengujian serta membentuk beberapa dataset berdasarkan skenario pengujian yang telah dirancang. Seluruh proses preprocessing diimplementasikan pada kelas `DatasetPreprocessingService`, yang bertanggung jawab melakukan filtering dataset, pembentukan jawaban referensi, serta pembuatan dataset pengujian.

4.2.1 Filtering Dataset IndoMMLU

Tahap pertama pada *preprocessing* dataset adalah melakukan filtering terhadap dataset IndoMMLU. Proses ini bertujuan untuk menyaring data sehingga

hanya soal yang berasal dari domain bahasa yang digunakan dalam penelitian yang diproses lebih lanjut. Domain yang dipilih terdiri atas Bahasa Lampung, Bahasa Bali, Bahasa Makassar, Bahasa Banjar, Bahasa Madura, Bahasa Indonesia, Bahasa Dayak Ngaju, Bahasa Sunda, dan Bahasa Jawa. *Source code* proses filtering dataset ditunjukkan pada Tabel 4.1.

Tabel 4. 1 *Source code* Filtering Dataset Berdasarkan Nilai Atribut Subject

```
protected array $subjectBahasa = [
    'Bahasa Lampung', 'Bahasa Bali', 'Bahasa Makassar', 'Bahasa
    Banjar', 'Bahasa Madura', 'Bahasa Indonesia', 'Bahasa Dayak
    Ngaju',
    'Bahasa Sunda', 'Bahasa Jawa',
];

public function filterBahasa(array $rows):
    array { return array_values(array_filter(
        $rows, fn($row) => in_array($row['subject'] ?? '', $this-
>subjectBahasa, true)
    ));
}
```

Proses filtering diawali dengan mendefinisikan sembilan domain bahasa yang digunakan sebagai acuan penyaringan data. Selanjutnya sistem memeriksa nilai atribut subject pada setiap baris dataset menggunakan fungsi `array_filter()`. Data yang memiliki nilai subject sesuai dengan salah satu domain bahasa tersebut dipertahankan, sedangkan data dari domain lain tidak disertakan pada proses berikutnya. Hasil filtering kemudian dikembalikan menggunakan fungsi `array_values()` sehingga indeks data tersusun kembali secara berurutan. Melalui proses tersebut dihasilkan dataset yang hanya berisi soal dari sembilan domain bahasa dan selanjutnya digunakan sebagai dataset utama pada tahap pembentukan dataset pengujian.

4.2.2 Pembentukan Dataset Pengujian

Proses pembentukan dataset pengujian dilakukan setelah tahap filtering dataset selesai dilaksanakan. Tahap ini bertujuan untuk menyiapkan data yang akan digunakan dalam proses evaluasi GPT-4o mini, meliputi pembentukan jawaban referensi, pengambilan sejumlah soal pada setiap domain bahasa, serta pembuatan beberapa file dataset berdasarkan skenario pengujian yang telah ditentukan.

Tahap pertama dilakukan dengan mengekstrak jawaban referensi dari setiap soal. Jawaban referensi digunakan sebagai pembanding terhadap jawaban yang dihasilkan GPT-4o mini pada saat proses evaluasi. *Source code* proses ekstraksi jawaban referensi ditunjukkan pada Tabel 4.2.

Tabel 4. 2 *Source code* Ekstraksi Jawaban Referensi dari Pilihan Jawaban

```
public function ekstrakJawabanBenar(?string $jawaban, ?string
$kunci): string
{
    if (empty($jawaban) || empty($kunci)) {
        return '';
    }

    $pilihan = preg_split('/\r\n|\r|\n/', $jawaban);
    $kunci = trim($kunci);

    foreach ($pilihan as $item) {
        $item = trim($item);

        if (preg_match('/^' . preg_quote($kunci, '/') . '([\.\.])/i',
$item)) {
            return trim(preg_replace(
                '/'^' . preg_quote($kunci, '/') . '([\.\.])\s*/i',
                '',
                $item
            ));
        }
    }

    return '';
}
```

Proses ekstraksi dilakukan dengan membaca seluruh pilihan jawaban pada setiap soal, kemudian mencocokkannya dengan huruf kunci jawaban. Setelah pilihan yang sesuai ditemukan, sistem menghapus huruf opsi beserta tanda bacanya sehingga hanya menyisakan teks jawaban. Hasil ekstraksi tersebut disimpan sebagai jawaban referensi yang selanjutnya digunakan pada proses perhitungan *similarity*.

Pembentukan dataset dilanjutkan dengan pengambilan sejumlah soal berdasarkan masing-masing domain bahasa. Proses ini bertujuan agar setiap domain memiliki jumlah soal yang sama sesuai dengan skenario pengujian yang telah ditentukan. *Source code* proses pengambilan data ditunjukkan pada Tabel 4.3.

Tabel 4. 3 *Source code* Pengambilan Sejumlah Data Berdasarkan Domain Bahasa

```
protected function ambilPerSubject(array $masterDataset, string
$subject, int $limit): array
{
    $filtered = array_values(array_filter(
        $masterDataset,
        fn($row) => $row['subject'] === $subject
    ));

    return array_slice($filtered, 0, $limit);
}
```

Proses pengambilan data dilakukan dengan menyaring dataset berdasarkan nama domain (subject), kemudian mengambil sejumlah soal sesuai jumlah yang ditentukan menggunakan fungsi `array_slice()`. Melalui proses tersebut, setiap domain menghasilkan jumlah soal yang sama sehingga distribusi data pada seluruh skenario pengujian menjadi seimbang.

Data yang telah dipilih kemudian digunakan untuk membentuk dataset pengujian berdasarkan masing-masing domain bahasa. *Source code* pembentukan dataset per domain ditunjukkan pada Tabel 4.4.

Tabel 4. 4 *Source code* Pembentukan Dataset Pengujian Perdomain

```

public function buatDatasetPerDomain(array $masterDataset, string
$outputFolder): array
{
    $log = [];
    $nomorDataset = 1;

    foreach ($this->subjectBahasa as $domain) {
        $rows = $this->renumber(
            $this->ambilPerSubject($masterDataset, $domain, 100)
        );

        $namaFile = $outputFolder . '/Dataset_' . $nomorDataset .
        '_-'
            . str_replace(' ', '_', $domain) . '_100.csv';

        $this->writeCsv($namaFile, $rows);

        $log[] = "Dataset {$nomorDataset}: {$domain} (" .
        count($rows) . ' data)';
        $nomorDataset++;
    }

    return $log;
}

```

Proses tersebut menghasilkan sembilan file dataset yang masing-masing berisi 100 soal dari satu domain bahasa. Setiap dataset disimpan dalam format CSV dengan nama file yang memuat nomor dataset, nama domain, dan jumlah soal sehingga memudahkan proses identifikasi serta penggunaan pada tahap pengujian.

Pembentukan dataset juga mencakup pembuatan dataset gabungan yang digunakan untuk pengujian berdasarkan jumlah sampel. Dataset ini terdiri atas soal dari seluruh domain bahasa dengan jumlah 25, 50, dan 100 soal untuk setiap domain. *Source code* pembentukan dataset gabungan ditunjukkan pada Tabel 4.5.

Tabel 4. 5 *Source code* Pembentukan Dataset Gabungan

```

public function buatDatasetSample(
    array $masterDataset,
    string $outputFolder,
    int $jumlahSample,
    int $nomorDataset
): string {

```

```

        $gabungan = [];

        foreach ($this->subjectBahasa as $domain) {
            $rows = $this->ambilPerSubject($masterDataset, $domain,
            $jumlahSample);
            array_push($gabungan, ...$rows);
        }

        $gabungan = $this->renumber($gabungan);

        $namaFile = $outputFolder . '/Dataset_' . $nomorDataset .
        '_9Domain_'
        . $jumlahSample . 'Soal_Total' . count($gabungan) . '.csv';

        $this->writeCsv($namaFile, $gabungan);

        return "Dataset {$nomorDataset}: " . count($gabungan) . '
data';
    }

```

Proses pembentukan dataset gabungan dilakukan dengan mengambil sejumlah soal dari setiap domain sesuai parameter yang diberikan, kemudian menggabungkannya menjadi satu dataset. Setelah seluruh data berhasil digabungkan, sistem melakukan penomoran ulang dan menyimpan hasilnya dalam format CSV.

Melalui proses tersebut dihasilkan tiga dataset gabungan, yaitu dataset berisi 225 soal, 450 soal, dan 900 soal. Ketiga dataset tersebut selanjutnya digunakan sebagai data pengujian pada skenario evaluasi GPT-4o mini berdasarkan variasi jumlah sampel.

4.3 Implementasi Mekanisme Pengujian Model GPT-4o Mini

Mekanisme ini bertujuan untuk mengotomatisasi proses evaluasi mulai dari pembentukan *prompt*, pengiriman *prompt* ke OpenAI API, ekstraksi jawaban, normalisasi teks, perhitungan tingkat kemiripan menggunakan algoritma *Levenshtein Distance*, hingga penyimpanan hasil pengujian. Seluruh proses tersebut diimplementasikan agar setiap soal pada dataset dapat dievaluasi secara

sistematis menggunakan metode *Non-Chain-of-Thought* (Non-CoT) maupun *Chain-of-Thought* (CoT).

4.3.1 Implementasi Pembentukan *Prompt* Pengujian

Tahap pertama pada mekanisme pengujian adalah membentuk *prompt* yang akan dikirimkan kepada model GPT-4o mini. *Prompt* berfungsi sebagai instruksi yang mengarahkan model dalam menjawab setiap soal pada dataset pengujian. Penelitian ini menggunakan dua jenis *prompt*, yaitu Non-CoT dan CoT. *Prompt* Non-CoT digunakan untuk meminta model memberikan jawaban akhir secara langsung tanpa penjelasan, sedangkan *prompt* CoT meminta model melakukan proses penalaran terlebih dahulu sebelum menuliskan jawaban akhir. *Source code template prompt* ditunjukkan pada Tabel 4.6.

Tabel 4. 6 *Source code Template Prompt*

```
protected array $templates = [
    'non_cot' => <<<'EOT'
Jawablah pertanyaan berikut. Berikan hanya jawaban akhir teks tanpa
opsi (A/B/C/D/E) .
Soal:
{soal}
Pilihan:
{jawaban}
EOT,

    'cot' => <<<'EOT'
Jawablah pertanyaan berikut dengan berpikir langkah demi langkah untuk
menyelesaikan soal ini secara logis.
Soal:
{soal}
Pilihan:
{jawaban}
Setelah menjelaskan langkah penyelesaiannya, lalu di baris terakhir
tulis format eksak: Jawaban akhir: [Teks jawaban tanpa huruf opsi
A/B/C/D/E] .
EOT,
];
```

Template prompt tersebut disimpan dalam bentuk array sehingga dapat digunakan kembali pada setiap proses pengujian. Perbedaan utama kedua *template* terletak pada instruksi yang diberikan kepada model. *Template* Non-CoT hanya meminta model memberikan jawaban akhir, sedangkan *template* CoT menambahkan instruksi agar model menjelaskan proses penyelesaian terlebih dahulu kemudian menuliskan hasil akhirnya dalam format “Jawaban akhir:”. Format tersebut digunakan agar sistem dapat melakukan ekstraksi jawaban secara konsisten pada proses selanjutnya.

Proses pembentukan *prompt* dilakukan dengan menggabungkan *template* yang telah ditentukan dengan isi soal dan pilihan jawaban yang berasal dari dataset. Proses penggabungan dilakukan dengan mengganti placeholder {soal} dan {jawaban} menggunakan data pada setiap baris dataset. *Source code* proses pembentukan *prompt* ditunjukkan pada Tabel 4.7.

Tabel 4. 7 *Source code* Pembentukan *Prompt*

```
public function build(string $method, string $soal, string
$jawaban): string
{
    if (!isset($this->templates[$method])) {
        throw new \InvalidArgumentException("Method prompt tidak
dikenal: {$method}. Gunakan 'non_cot' atau 'cot'.");
    }

    return strtr($this->templates[$method], [
        '{soal}' => $soal,
        '{jawaban}' => $jawaban,
    ]);
}
```

Proses tersebut menghasilkan *prompt* yang telah berisi soal dan pilihan jawaban sesuai data pada dataset. *Prompt* inilah yang selanjutnya digunakan sebagai masukan pada proses pemanggilan OpenAI API GPT-4o mini.

4.3.2 Implementasi Pemanggilan OpenAI API GPT-4o mini

Proses pengiriman *prompt* ke layanan OpenAI API dilakukan untuk memperoleh jawaban dari model GPT-4o mini. Komunikasi dengan API diimplementasikan menggunakan Laravel HTTP Client sehingga aplikasi dapat mengirimkan request secara langsung ke endpoint OpenAI. *Source code* proses pemanggilan OpenAI API ditunjukkan pada Tabel 4.8.

Tabel 4. 8 *Source code* Pemanggilan OpenAI API GPT-4o mini

```
$response = Http::withToken($this->apiKey)
    ->timeout(config('services.openai.timeout', 120))
    ->post($this->baseUrl, [
        'model' => $this->model,
        'messages' => [
            ['role' => 'user', 'content' => $prompt],
        ],
        'temperature' => $this->temperature,
        'max_tokens' => $this->maxTokens,
    ]);
```

Proses pemanggilan API dilakukan menggunakan metode POST dengan menyertakan API Key sebagai autentikasi. Request yang dikirim memuat model GPT-4o mini, *prompt* yang telah dibentuk sebelumnya, nilai temperature, serta max_tokens sesuai konfigurasi aplikasi. Setelah request berhasil diproses, OpenAI API mengembalikan respons berupa jawaban model beserta informasi penggunaan token yang selanjutnya diproses pada tahap ekstraksi jawaban.

4.3.3 Implementasi Ekstraksi Jawaban

Jawaban yang dihasilkan GPT-4o mini masih berupa teks lengkap sehingga perlu dilakukan proses ekstraksi untuk memperoleh jawaban akhir yang akan dibandingkan dengan jawaban referensi. Proses ekstraksi dilakukan agar format jawaban dari metode Non-CoT maupun CoT menjadi seragam sebelum memasuki

tahap normalisasi. *Source code* proses ekstraksi jawaban ditunjukkan pada Tabel 4.9.

Tabel 4. 9 *Source code* Ekstraksi Jawaban

```
// Jika mode Chain-of-Thought (CoT) aktif
if ($isCot) {

    // Cari bagian "Jawaban Akhir:" menggunakan regex
    if (preg_match_all(
        '/(?:\*\*| )?jawaban\s+akhir\s*:\s*(?:\*\*| )?\s*(.*)/i',
        $text,
        $matches
    ) && !empty($matches[1])) {

        // Ambil hasil "Jawaban Akhir" terakhir yang ditemukan
        $ans = trim(end($matches[1]));

        // Pisahkan menjadi beberapa baris
        $lines = preg_split('/\r\n|\r|\n/', $ans);

        // Gunakan hanya baris pertama sebagai jawaban akhir
        $text = trim($lines[0]);

    } else {

        // Jika tidak ditemukan pola "Jawaban Akhir:",
        // pecah teks menjadi beberapa baris lalu hapus baris kosong
        $lines = array_filter(array_map(
            'trim',
            preg_split('/\r\n|\r|\n/', $text)
        ));

        // Ambil baris terakhir dan hilangkan awalan "Jawaban Akhir:"
        jika masih ada
        $text = trim(
            preg_replace('/^.*jawaban\s+akhir\s*:\s*/i', '',
            end($lines))
        );
    }
}

// Hapus awalan opsi jawaban seperti:
// A. , A) , A - , B. , C), dan sebagainya
$text = preg_replace(
    '/^[a-eA-E](?:\s*[\.\)\-]\s*|\s+)/',
    '',
    $text
);
```

Proses ekstraksi pada metode CoT diawali dengan mencari teks setelah kata “Jawaban akhir:” menggunakan Regular Expression. Apabila format tersebut tidak ditemukan, sistem mengambil baris terakhir dari respons sebagai jawaban akhir. Sistem kemudian menghapus huruf opsi seperti A, B, C, D, atau E apabila masih terdapat pada awal jawaban sehingga hanya menyisakan teks jawaban. Proses tersebut menghasilkan format jawaban yang lebih sederhana dan seragam sehingga dapat digunakan pada tahap perbandingan dengan jawaban referensi. Contoh hasil ekstraksi jawaban dari respons model GPT-4o mini ditunjukkan pada Tabel 4.10.

Tabel 4. 10 Contoh Ekstraksi Jawaban Model

Metode	Respons Model	Hasil Ekstraksi
Non-CoT	“Jakarta”	Jakarta
CoT	“Ibu kota Indonesia adalah Jakarta.\nJawaban akhir: Jakarta”	Jakarta

4.3.4 Implementasi Normalisasi Teks

Proses normalisasi dilakukan terhadap jawaban referensi dan jawaban hasil ekstraksi. Normalisasi bertujuan untuk mengurangi perbedaan penulisan yang tidak memengaruhi makna, seperti penggunaan huruf kapital, tanda baca, maupun spasi berlebih, sehingga tidak memengaruhi hasil perhitungan *similarity*. *Source code* proses normalisasi teks ditunjukkan pada Tabel 4.11.

Tabel 4. 11 *Source code* Normalisasi Teks

```
public function normalize(?string $text): string
{
    if ($text === null || $text === '') {
        return '';
    }

    $text = mb_strtolower($text, 'UTF-8');
```

```

// Hapus tanda baca/symbol, sisakan huruf, angka, dan spasi
(unicode-aware)
$text = preg_replace('/[^\p{L}\p{N}\s]/u', '', $text);

// Rapikan whitespace
$text = preg_replace('/\s+/', ' ', $text);

return trim($text);
}

```

Proses normalisasi diawali dengan mengubah seluruh karakter menjadi huruf kecil menggunakan fungsi `mb_strtolower()`. Sistem menghapus seluruh tanda baca dan simbol sehingga hanya menyisakan huruf, angka, serta spasi, kemudian merapikan spasi menggunakan *Regular Expression* sebelum teks dikembalikan sebagai hasil normalisasi. Proses tersebut menghasilkan perubahan format penulisan tanpa mengubah isi utama dari jawaban. Hasil normalisasi digunakan sebagai masukan pada proses perhitungan *Levenshtein Distance*. Contoh hasil normalisasi teks ditunjukkan pada Tabel 4.12.

Tabel 4. 12 *Source code* Normalisasi Teks

Teks Asli	Teks Ternormalisasi
Tari Cangget	tari cangget
Ibu kota Indonesia adalah Jakarta!	ibu kota indonesia adalah jakarta

4.3.5 Implementasi Perhitungan *Levenshtein Distance*

Proses perhitungan tingkat kemiripan dilakukan antara jawaban GPT-4o mini dengan jawaban referensi menggunakan algoritma *Levenshtein Distance*. Perhitungan dilakukan untuk mengetahui jumlah operasi penyisipan, penghapusan, dan penggantian karakter yang diperlukan untuk mengubah satu teks menjadi teks lainnya. *Source code* proses perhitungan *Levenshtein Distance* ditunjukkan pada Tabel 4.13.

Tabel 4. 13 *Source code* Perhitungan *Levenshtein Distance*

```

public function distance(string $a, string $b): int
{
    // Mengubah string menjadi array karakter agar dapat dibandingkan
    per karakter
    // Menggunakan mb_str_split agar mendukung karakter multibahasa
    $charsA = mb_str_split($a);
    $charsB = mb_str_split($b);

    // Menentukan panjang masing-masing teks
    $n = count($charsA);
    $m = count($charsB);

    // Jika teks pertama kosong, jarak sama dengan jumlah karakter pada
    teks kedua
    if ($n === 0) {
        return $m;
    }

    // Jika teks kedua kosong, jarak sama dengan jumlah karakter pada
    teks pertama
    if ($m === 0) {
        return $n;
    }

    // Membuat tabel dynamic programming untuk menyimpan hasil
    perhitungan jarak
    $dp = [];

    // Inisialisasi baris pertama: mengubah teks pertama menjadi string
    kosong
    // membutuhkan operasi penghapusan sebanyak jumlah karakter
    for ($i = 0; $i <= $n; $i++) {
        $dp[$i][0] = $i;
    }

    // Inisialisasi kolom pertama: mengubah string kosong menjadi teks
    kedua
    // membutuhkan operasi penyisipan sebanyak jumlah karakter
    for ($j = 0; $j <= $m; $j++) {
        $dp[0][$j] = $j;
    }

    // Menghitung jarak minimum menggunakan tiga operasi utama
    Levenshtein Distance:
    // deletion (penghapusan), insertion (penyisipan), dan substitution
    (penggantian)
    for ($i = 1; $i <= $n; $i++) {
        for ($j = 1; $j <= $m; $j++) {

            // Jika karakter pada posisi yang sama bernilai sama,
            // tidak diperlukan operasi pengubahan (cost = 0)
            // Jika berbeda, diperlukan operasi penggantian (cost = 1)

```

```

        $cost = ($charsA[$i - 1] === $charsB[$j - 1]) ? 0 : 1;

        // Menentukan nilai minimum dari tiga kemungkinan operasi:
        // 1. Menghapus karakter pada teks pertama
        // 2. Menambahkan karakter pada teks pertama
        // 3. Mengganti karakter pada teks pertama
        $dp[$i][$j] = min(
            $dp[$i - 1][$j] + 1,          // Deletion
            $dp[$i][$j - 1] + 1,          // Insertion
            $dp[$i - 1][$j - 1] + $cost // Substitution
        );
    }
}

// Nilai terakhir pada tabel menunjukkan jumlah operasi minimum
// untuk mengubah teks pertama menjadi teks kedua
return $dp[$n][$m];
}

```

Perhitungan dilakukan menggunakan pendekatan *dynamic programming* dengan membentuk matriks dua dimensi yang berisi biaya minimum perubahan karakter. Nilai pada sel terakhir matriks merupakan nilai *Levenshtein Distance* yang menunjukkan tingkat perbedaan antara kedua teks. Nilai jarak yang diperoleh selanjutnya dikonversi menjadi nilai *similarity* agar hasil evaluasi lebih mudah diinterpretasikan. *Source code* perhitungan *similarity* ditunjukkan pada Tabel 4.14.

Tabel 4. 14 *Source code* Perhitungan *Similarity*

```

public function similarity(string $a, string $b): float
{
    $maxLen = max(mb_strlen($a), mb_strlen($b));

    if ($maxLen === 0) {
        return 1.0;
    }

    $dist = $this->distance($a, $b);

    return 1.0 - ($dist / $maxLen);
}

```

Perhitungan *similarity* dilakukan dengan membandingkan nilai *Levenshtein Distance* terhadap panjang karakter terpanjang dari kedua teks. Hasil perhitungan berada pada rentang 0 hingga 1, dimana nilai yang semakin mendekati 1

menunjukkan tingkat kemiripan jawaban yang semakin tinggi. Nilai *similarity* tersebut kemudian digunakan untuk menentukan tingkat kesesuaian jawaban GPT-4o mini terhadap jawaban referensi.

4.3.6 Implementasi Penyimpanan Data Hasil dan Riwayat Pengujian

Proses penyimpanan data hasil dan riwayat pengujian dilakukan setelah seluruh proses evaluasi selesai dilaksanakan. Aplikasi menyimpan hasil evaluasi secara otomatis agar dapat ditampilkan kembali pada halaman hasil, visualisasi, maupun laporan. Penyimpanan data dibagi menjadi beberapa bagian, yaitu hasil pengujian per soal, metadata pengujian, riwayat pengujian, serta laporan dalam format Excel dan PDF. Setiap data disimpan dalam format yang berbeda sesuai dengan kebutuhan masing-masing.

a. Struktur Data Hasil Pengujian Persoal

Tahap pertama adalah menyimpan hasil pengujian setiap soal dalam bentuk file JSON. File ini memuat seluruh informasi yang dihasilkan selama proses evaluasi, mulai dari data soal, jawaban referensi, hasil pengujian menggunakan metode Non-CoT maupun CoT, hingga informasi penggunaan token dan waktu respons. Contoh struktur data hasil pengujian per soal ditunjukkan pada Tabel 4.15.

Tabel 4. 15 Struktur Data Hasil Pengujian Per Soal

```
"1": {
  "id": 1,
  "nomor": "1",
  "subject": "Bahasa Bali",
  "level": null,
  "soal": "Dugas Galungane titiang mabakti nganggon udeng
baru. Udeng basa Bali alusne...",
  "jawaban_options": "A. destar\nB. kampuh\nC. wastra",
  "kunci": "A",
```

```

"jawaban_referensi": "destar",
"jawaban_referensi_normalized": "destar",
"non_cot": {
  "prompt": "Jawablah pertanyaan berikut. Berikan
hanya jawaban akhir teks tanpa opsi
(A\\B\\C\\D\\E).\\nSoal:\\nDugas Galungane titiang mabakti
nganggon udeng baru. Udeng basa Bali alusne...\\nPilihan:\\nA.
destar\\nB. kampuh\\nC. wastra",
  "raw_response": "wastra",
  "extracted": "wastra",
  "extracted_normalized": "wastra",
  "similarity": 0.3333333333333337,
  "is_correct": 0,
  "latency": 3.9299228191375732,
  "prompt_tokens": 73,
  "completion_tokens": 2,
  "total_tokens": 75,
  "error": null,
  "_attempt_count": 1
},
"cot": {
  "prompt": "Jawablah pertanyaan berikut dengan
berpikir langkah demi langkah untuk menyelesaikan soal ini
secara logis.\\nSoal:\\nDugas Galungane titiang mabakti nganggon
udeng baru. Udeng basa Bali alusne...\\nPilihan:\\nA. destar\\nB.
kampuh\\nC. wastra\\nSetelah menjelaskan langkah penyelesaiannya,
lalu di baris terakhir tulis format eksak: Jawaban akhir: [Teks
jawaban tanpa huruf opsi A\\B\\C\\D\\E].",
  "raw_response": "Untuk menyelesaikan soal ini, kita
perlu memahami konteks dari kalimat yang diberikan. Kalimat
menyebutkan \"udeng\" dan \"bali alusne\", yang menunjukkan
bahwa kita mencari istilah dalam bahasa Bali yang tepat untuk
menyebut jenis penutup kepala atau udeng yang digunakan dalam
upacara atau acara yang menggunakan bahasa Bali yang
halus.\\n\\nMari kita analisis pilihan yang ada:\\n\\nA. **destar**
- Ini adalah istilah yang sering digunakan untuk menyebut
penutup kepala tradisional Bali, biasanya dipakai dalam
upacara.\\nB. **kampuh** - Ini adalah istilah lain yang juga
merujuk pada penutup kepala, tetapi lebih umum dan tidak selalu
digunakan dalam konteks upacara.\\nC. **wastra** - Ini lebih
merujuk pada kain atau sarung yang dipakai, bukan penutup
kepala.\\n\\nDari analisis di atas, \"destar\" adalah istilah
yang paling sesuai untuk konteks \"udeng baru\" dalam kalimat
tersebut, karena merupakan istilah yang tepat untuk penutup
kepala dalam budaya Bali, terutama dalam konteks yang lebih
formal atau upacara.\\n\\nDengan demikian, langkah terakhir
adalah menyimpulkan jawaban yang paling tepat.\\n\\nJawaban
akhir: destar",
  "extracted": "destar",
  "extracted_normalized": "destar",
  "similarity": 1,
  "is_correct": 1,
  "latency": 3.68060302734375,
  "prompt_tokens": 113,

```

```

        "completion_tokens": 251,
        "total_tokens": 364,
        "error": null,
        "_attempt_count": 1
    }
}

```

Struktur data tersebut menyimpan informasi lengkap untuk setiap soal yang diuji. Informasi yang disimpan meliputi identitas soal, domain bahasa, soal, pilihan jawaban, kunci jawaban, jawaban referensi, hasil normalisasi, serta hasil pengujian menggunakan metode Non-CoT dan CoT. Selain itu, sistem juga menyimpan nilai *similarity*, status benar atau salah, waktu respons (*latency*), penggunaan token, serta jumlah percobaan (*attempt*) sehingga seluruh proses evaluasi dapat ditelusuri kembali apabila diperlukan. Data hasil pengujian tersebut menjadi sumber utama yang digunakan aplikasi untuk menampilkan detail hasil evaluasi pada halaman hasil pengujian.

b. Penyimpanan Metadata (JSON)

Aplikasi juga menghasilkan metadata yang berisi ringkasan pelaksanaan pengujian. Metadata tersebut digunakan untuk menyimpan informasi umum mengenai proses evaluasi sehingga pengguna dapat mengetahui konfigurasi pengujian yang digunakan. Contoh metadata pengujian ditunjukkan pada Tabel 4.16.

Tabel 4. 16 Struktur Metadata Pengujian

```

{
  "model": "gpt-4o-mini",
  "temperature": "0.7",
  "similarity_threshold": 0.8,
  "total_questions": 100,
  "method": "both",
  "date_executed": "2026-07-16 13:58:36",
}

```



```

    "duration_seconds": -678.677517,
    "dry_run": false,
    "token_usage": {
      "non_cot": 7507,
      "cot": 43190,
      "total": 50697
    },
    "average_latency_seconds": {
      "non_cot": 1.4538847255706786,
      "cot": 4.941903536319733
    }
  }
}

```

Metadata tersebut menyimpan informasi mengenai model GPT yang digunakan, nilai *temperature*, jumlah soal yang diuji, metode pengujian, waktu pelaksanaan, durasi proses pengujian, penggunaan token, serta rata-rata waktu respons setiap metode. Informasi tersebut digunakan sebagai ringkasan pelaksanaan pengujian dan ditampilkan kembali pada halaman visualisasi maupun laporan hasil pengujian.

c. Penyimpanan History (JSON)

Setiap proses pengujian yang berhasil diselesaikan juga dicatat sebagai riwayat pengujian. Riwayat ini berfungsi untuk menyimpan informasi singkat mengenai setiap pengujian sehingga pengguna dapat melihat kembali daftar pengujian yang pernah dilakukan tanpa harus membuka seluruh file hasil evaluasi. Contoh struktur data riwayat pengujian ditunjukkan pada Tabel 4.17.

Tabel 4. 17 Struktur Riwayat Pengujian

```

{
  "dataset_file":
  "Dataset_2_Bahasa_Bali_100_20260716_134350.csv",
  "method": "both",
  "status": "selesai",
  "total_soal": 100,
  "avg_non_cot": 55.49,
  "avg_cot": 62.14,

```

```

    "accuracy_non_cot": 42,
    "accuracy_cot": 52,
    "created_at": "2026-07-16 13:47:18",
    "started_at": "2026-07-16 13:47:18",
    "id": 5
  },

```

Data riwayat menyimpan informasi berupa nama dataset yang digunakan, metode pengujian, status proses, jumlah soal, rata-rata *similarity*, jumlah jawaban benar, serta waktu pelaksanaan pengujian. Informasi tersebut ditampilkan pada halaman riwayat sehingga pengguna dapat memilih hasil pengujian yang ingin dilihat kembali.

d. Export Excel

Aplikasi menyediakan fitur ekspor laporan hasil pengujian ke dalam format Microsoft Excel untuk mempermudah pengguna dalam melihat, melakukan analisis, serta mendokumentasikan hasil evaluasi model GPT-4o mini berdasarkan dataset IndoMMLU. File Excel yang dihasilkan berisi rincian hasil pengujian pada setiap soal yang telah diproses. Informasi yang ditampilkan meliputi nomor urut pengujian, domain bahasa, teks soal, jawaban referensi, jawaban model menggunakan pendekatan Non-CoT, nilai *similarity* Non-CoT, penalaran menggunakan metode *Chain-of-Thought* (CoT), jawaban model menggunakan pendekatan CoT, serta nilai *similarity* CoT. Penyusunan data dalam bentuk tabel memungkinkan pengguna membandingkan secara langsung perbedaan hasil jawaban model antara pendekatan Non-CoT dan CoT terhadap jawaban referensi. Contoh hasil ekspor laporan Excel ditunjukkan pada Gambar 4.17

	A	B	C	D	E	F	G	H	I
1	No Subject	Soal		Jawaban Referensi	Jawaban Non-CoT	Nilai Non-CoT	Penalaran CoT	Jawaban CoT	Nilai CoT
2	1 Bahasa Lampung Anak huruf becek berbunyi			E	I	0	Untuk menyelesaikan soal ini, kita perlu menga		0
3	2 Bahasa Lampung Tarian yang berasal dari daerah Lampung adalah			Tari Cangget	Tari Cangget	100	Untuk menyelesaikan soal ini, kita perlu menga Cangget		58.33
4	3 Bahasa Lampung Arti dari "Tiyen lapah mit sekula"			Mereka pergi ke sek	Mereka pergi ke si	100	Untuk menyelesaikan soal ini, kita perlu menga Mereka pergi l		100
5	4 Bahasa Lampung Aksara Lampung memiliki ... jumlah			20 Aksara Lampung n		6.06	Untuk menjawab pertanyaan ini, kita perlu mei	20	100
6	5 Bahasa Lampung Kemian artinya			Bibi	Bibi	100	Langkah 1: Memahami arti kata "kemian". Ker Paman		0
7	6 Bahasa Lampung "Gigi" bahasa lampung nya			Kukut	Ipon	0	Untuk menentukan terjemahan kata "gigi" dala Kukut		100
8	7 Bahasa Lampung Dalam bahasa lampung kata "Debigi" ialah			Pagi	Pagi	100	Untuk menjawab soal ini, kita akan mengkuti li Malam		20
9	8 Bahasa Lampung Asri pergi ke rumah bibi jika di terjemahkan kedalam b			Asri lapah mit lamb	Asri lapah mit lam	90.32	Untuk menerjemahkan kalimat "Asri pergi ke n Asri lapah mit		100
10	9 Bahasa Lampung Naik bahasa lampungnya adalah			Cakak	Debah	20	Untuk menjawab pertanyaan ini, kita perlu mei Debah		20
11	10 Bahasa Lampung Anak huruf yang terletak dibawah adalah			An Dan U	I Dan E	62.5	Untuk menyelesaikan soal ini, kita perlu menga An Dan U		100
12	11 Bahasa Lampung Makanan yang terkenal ciri khas orang lampung adala			Seruit	Seruit	100	Untuk menyelesaikan soal ini, mari kita analisis Seruit		100
13	12 Bahasa Lampung Kabupaten Lampung Utara adalah			Kota Bumi	Kota Bumi	100	Langkah pertama untuk menyelesaikan soal ini Kota Bumi		100
14	13 Bahasa Lampung Kabupaten Lampung Selatan adalah			Kalianda	Kalianda	100	Untuk menjawab pertanyaan tentang Kabupaten Kalianda		100
15	14 Bahasa Lampung Jumlah anak huruf yang dibawah berjumlah			5 Jumlah anak huruf		2.38	Untuk menyelesaikan soal ini, kita perlu memal	3	0
16	15 Bahasa Lampung Kabupaten way kanan adalah			Blambangan Umpu	Blambangan Umpi	100	Untuk menjawab soal ini, kita perlu menganalis Blambangan L		100
17	16 Bahasa Lampung Mahkota yang dipakai oleh orang lampung adalah			Siger	Siger	100	Untuk menjawab pertanyaan mengenai mahko Siger		100
18	17 Bahasa Lampung Kain yang berasal dari Lampung adalah			Kain Tapis	Kain Tapis	100	Untuk menjawab pertanyaan tentang kain yang Kain Tapis		100
19	18 Bahasa Lampung Apak adalah panggilan dalam bahasa			Bapak	Bapak	100	Untuk menyelesaikan soal ini, kita perlu memal Bapak		100

Gambar 4. 17 Hasil Ekspor Laporan Excel

e. Export PDF

Aplikasi menyediakan fitur ekspor laporan hasil pengujian ke dalam format PDF yang digunakan sebagai media dokumentasi dan penyajian ringkasan hasil evaluasi model GPT-4o mini. Berbeda dengan format Excel yang menampilkan hasil pengujian secara rinci pada setiap soal, laporan PDF menyajikan informasi evaluasi dalam bentuk ringkasan yang lebih terstruktur. Contoh hasil ekspor laporan PDF ditunjukkan pada Gambar 4.18.



Gambar 4. 18 Hasil Ekspor Laporan PDF

Laporan PDF yang dihasilkan memuat judul evaluasi, perbandingan metode *Chain-of-Thought* (CoT) dan Non-CoT, ringkasan nilai rata-rata akurasi dari masing-masing metode, rekap hasil pengujian berdasarkan domain bahasa, serta grafik perbandingan performa metode. Selain itu, laporan juga menampilkan bagian kesimpulan yang berisi interpretasi

hasil pengujian berdasarkan nilai rata-rata *similarity* yang diperoleh dari masing-masing metode.

4.4 Hasil Pengujian Model GPT-4o Mini terhadap Skenario Pengujian

Subbab ini menyajikan hasil pengujian performa model GPT-4o mini terhadap dataset IndoMMLU domain bahasa daerah menggunakan aplikasi EvalGPT. Pengujian dilakukan dengan membandingkan dua pendekatan prompting, yaitu *Non-Chain-of-Thought* (Non-CoT) dan *Chain-of-Thought* (CoT), untuk mengetahui perbedaan kemampuan model dalam menjawab soal pilihan ganda berbasis bahasa daerah.

Evaluasi performa dilakukan menggunakan nilai *similarity* dari algoritma *Levenshtein Distance* serta status kesesuaian jawaban berdasarkan exact match terhadap jawaban referensi. Penggunaan exact match diterapkan karena dataset IndoMMLU memiliki format soal pilihan ganda dengan satu jawaban benar, sehingga jawaban model dinyatakan sesuai apabila memiliki kecocokan penuh dengan jawaban acuan. Nilai *similarity* tetap digunakan untuk melihat tingkat kedekatan antara jawaban model dan referensi ketika terdapat perbedaan bentuk penulisan.

Dataset yang digunakan terdiri dari sembilan domain bahasa pada IndoMMLU, yaitu Bahasa Lampung, Bahasa Bali, Bahasa Makassar, Bahasa Banjar, Bahasa Madura, Bahasa Indonesia, Bahasa Dayak Ngaju, Bahasa Sunda, dan Bahasa Jawa. Pengujian dilakukan melalui empat skenario dengan variasi jumlah sampel dan konfigurasi domain untuk mengetahui pengaruh perubahan data terhadap performa model.

Data hasil pengujian diperoleh dari aplikasi EvalGPT yang menyimpan informasi berupa pertanyaan, jawaban referensi, jawaban model, nilai *similarity*, status kesesuaian jawaban, jumlah token, serta waktu respons. Hasil pengujian pada setiap skenario disajikan pada subbab berikutnya, sedangkan analisis mengenai perbedaan performa antara metode Non-CoT dan CoT dibahas lebih lanjut pada Subbab 4.6.

4.4.1 Skenario 1: Pengujian Per Domain Bahasa

Skenario ini bertujuan melihat performa GPT-4o mini pada masing-masing bahasa daerah secara terpisah, tanpa tercampur bahasa lain, sehingga karakteristik tiap domain bisa terlihat lebih murni. Total data yang diuji pada skenario ini berjumlah 900 soal yang terdiri dari sembilan domain bahasa. Hasil pengujian setiap domain ditunjukkan pada Tabel 4.18.

Tabel 4. 18 Rekapitulasi Hasil Pengujian Per Domain

No	Domain	<i>Similarity</i> NC	<i>Similarity</i> CoT	Soal Benar NC	Soal Benar CoT	Metode Unggul
1	Bahasa Lampung	61,60%	66,92%	46/100 (46%)	56/100 (56%)	CoT
2	Bahasa Bali	55,49%	62,14%	38/100 (38%)	49/100 (49%)	CoT
3	Bahasa Makassar	59,88%	59,39%	37/100 (37%)	37/100 (37%)	Setara
4	Bahasa Banjar	62,77%	61,03%	45/100 (45%)	45/100 (45%)	Setara
5	Bahasa Madura	59,36%	55,06%	40/100 (40%)	37/100 (37%)	Non-CoT
6	Bahasa Indonesia	93,86%	95,92%	90/100 (90%)	94/100 (94%)	CoT
7	Bahasa Dayak Ngaju	61,02%	57,88%	33/100 (33%)	33/100 (33%)	Setara
8	Bahasa Sunda	69,70%	73,39%	62/100 (62%)	66/100 (66%)	CoT
9	Bahasa Jawa	76,18%	77,23%	63/100 (63%)	66/100 (66%)	CoT

Tabel 4.18 menunjukkan bahwa Bahasa Indonesia menempati posisi teratas dengan selisih besar dari domain lain, jumlah soal benarnya di atas 90 pada kedua metode, sementara posisi kedua yaitu Bahasa Jawa hanya di kisaran 63 sampai 66

soal. Rentang *similarity* kesembilan domain berkisar antara 55% sampai 96%, cukup lebar untuk ukuran satu model yang sama.

Lima dari sembilan domain menunjukkan *Chain-of-Thought* menghasilkan jumlah soal benar yang lebih tinggi dibanding *Non-Chain-of-Thought*. Tiga domain lainnya, Banjar, Dayak Ngaju, dan Makassar, mencatat hasil yang identik di kedua metode. Bahasa Madura satu-satunya domain di mana *Non-Chain-of-Thought* unggul, 40 berbanding 37 soal.

Setiap soal kemudian diperiksa satu per satu untuk melihat kombinasi hasil kedua metode, apakah sama-sama benar, sama-sama salah, atau hanya salah satu yang benar. Kombinasi hasil kedua metode tersebut dapat dilihat pada Tabel 4.19.

Tabel 4. 19 Rincian Benar Salah per Soal, per Domain

No	Domain	Kedua Metode Benar	Hanya Non-CoT Benar	Hanya CoT Benar	Kedua Metode Salah
1	Bahasa Lampung	36	10	20	34
2	Bahasa Bali	27	11	22	40
3	Bahasa Makassar	24	13	13	50
4	Bahasa Banjar	31	14	14	41
5	Bahasa Madura	20	20	17	43
6	Bahasa Indonesia	88	2	6	4
7	Bahasa Dayak Ngaju	20	13	13	54
8	Bahasa Sunda	54	8	12	26
9	Bahasa Jawa	55	8	11	26

Tabel 4.19 menunjukkan bahwa Angka pada kolom “Kedua Metode Salah” memperlihatkan kesenjangan yang cukup tajam antar domain. Dayak Ngaju dan Makassar mencatat lebih dari separuh soalnya gagal dijawab benar oleh kedua metode sekaligus, sementara Bahasa Indonesia hanya empat soal yang gagal total.

Kolom “Hanya CoT Benar” juga bervariasi, tertinggi pada Bali dan Lampung, menunjukkan dua domain ini paling banyak terbantu saat model diminta bernalar lebih dulu sebelum menjawab. Sebagai gambaran konkret dari pola ini, Tabel 4.20 menampilkan sepuluh soal pertama Bahasa Lampung beserta jawaban kedua metode.

Tabel 4. 20 Contoh Detail Hasil Pengujian Bahasa Lampung

No	Soal	Kunci	Jawaban <i>Non-CoT</i>	Skor NC (%)	Jawaban <i>CoT</i>	Skor <i>CoT</i> (%)
1	Anak huruf bicek berbunyi...	E	I	0	i	0
2	Tarian yang berasal dari daerah Lampung adalah...	Tari Cangget	Tari Cangget	100	Cangget	58
3	Arti dari "Tiyen lapah mit sekula"...	Mereka pergi ke sekolah	Mereka pergi ke sekolah	100	Mereka pergi ke sekolah.	100
4	Aksara Lampung memiliki ... jumlah	20	Aksara Lampung memiliki 20 jumlah.	6	20	100
5	Keminan artinya...	Bibi	Bibi	100	Paman	0
6	"Gigi" bahasa lampung nya...	Kukut	Ipon	0	Kukut	100
7	Dalam bahasa lampung kata "Debigi" ialah...	Pagi	Pagi	100	Malam	20
8	Asri pergi ke rumah bibi jika di terjemahkan...	Asri lapah mit lamban kemaman	Asri lapah mit lamban keminanan	90	Asri lapah mit lamban kemaman	100
9	Naik bahasa lampungnya adalah...	Cakak	Debah	20	Debah	20
10	Anak huruf yang terletak dibawah adalah...	An Dan U	I Dan E	63	An Dan U	100

Sepuluh soal ini mewakili variasi hasil yang muncul di seluruh dataset, sebagian terselamatkan oleh penalaran CoT, sebagian lain justru berubah dari benar jadi salah. Penyebab di balik masing-masing perubahan ini akan diuraikan lebih lanjut pada Subbab 4.6.

4.4.2 Skenario 2: Pengujian 25 Soal per Domain

Skenario kedua dilakukan dengan menggabungkan seluruh domain bahasa menggunakan 25 soal pada setiap domain untuk melihat performa model saat menghadapi campuran bahasa daripada satu domain saja. Jumlah keseluruhan data yang diuji pada skenario ini adalah 225 soal. Hasil pengujian ditampilkan pada Tabel 4.21.

Tabel 4. 21 Skenario 2 - 25 Soal per Domain

Metode	<i>Similarity</i>	Soal Benar	Total Token	Rata-rata <i>Latency</i>
<i>Non-CoT</i>	68,60%	121/225 (53,78%)	16.307	1,77 detik
<i>CoT</i>	68,27%	123/225 (54,67%)	88.819	5,16 detik

Tabel 4.21 menunjukkan bahwa *Similarity* kedua metode hampir sama, hanya terpaut 0,33 poin, dengan Non-CoT sedikit lebih tinggi. Jumlah soal benarnya justru berlawanan arah, CoT unggul dua soal. Selisih token antara kedua metode sudah terlihat jauh sejak skenario kecil ini, CoT memakai lebih dari lima kali lipat token Non-CoT untuk selisih akurasi yang tipis.

4.4.3 Skenario 3: Pengujian 50 Soal per Domain

Skenario ketiga dilakukan dengan meningkatkan jumlah sampel menjadi 50 soal per domain untuk mengetahui apakah pola performa pada Skenario 2 tetap bertahan ketika jumlah data pengujian bertambah. Total data yang diuji pada skenario ini berjumlah 450 soal. Hasil pengujian ditunjukkan pada Tabel 4.22.

Tabel 4. 22 Skenario 3 - 50 Soal per Domain

Metode	<i>Similarity</i>	Soal Benar	Total Token	<i>Latency</i>
<i>Non-CoT</i>	70,18%	247/450 (54,89%)	34.068	1,42 detik
<i>CoT</i>	69,37%	249/450 (55,33%)	180.602	5,00 detik

Tabel 4.22, menunjukkan bahwa pola dari Skenario 2 bertahan, *similarity* Non-CoT tetap lebih tinggi sementara jumlah soal benar tetap lebih banyak pada CoT, kali ini terpaut dua soal. Skenario ini mencatat *similarity* tertinggi di antara seluruh skenario gabungan untuk kedua metode, mengindikasikan komposisi 50 soal pertama tiap domain kebetulan lebih mudah dibanding komposisi pada skenario lain.

4.4.4 Skenario 4: Pengujian 100 Soal per Domain

Skenario keempat dilakukan menggunakan jumlah sampel terbesar, yaitu 100 soal pada setiap domain dengan total 900 soal. Hasil pengujian ditampilkan pada Tabel 4.23.

Tabel 4. 23 Skenario 4 - 100 Soal per Domain

Metode	<i>Similarity</i>	Soal Benar	Total Token	<i>Latency</i>
<i>Non-CoT</i>	67,30%	469/900 (52,11%)	71.908	1,46 detik
<i>CoT</i>	65,55%	456/900 (50,67%)	372.965	5,48 detik

Tabel 4.23 menunjukkan bahwa pola dua skenario sebelumnya tidak bertahan di sini. Non-CoT unggul baik dari sisi *similarity* maupun jumlah soal benar, dengan selisih 13 soal, yang terbesar di antara seluruh skenario gabungan. Volume data yang lebih besar dan lebih beragam justru memperlebar kesenjangan antara kedua metode, bukan mempersempitnya.

4.5 Pembahasan Hasil Pengujian Model GPT-4o Mini

4.5.1 Analisis Perbandingan Performa Metode CoT dan Non-CoT

Rumusan masalah penelitian ini membahas pengaruh penerapan metode *Chain-of-Thought* terhadap kemampuan GPT-4o mini dalam menjawab soal pilihan

ganda pada domain bahasa daerah. Hasil pengujian memperlihatkan bahwa penerapan *Chain-of-Thought* belum memberikan peningkatan performa yang konsisten pada seluruh kondisi pengujian. Metode CoT mampu menghasilkan jumlah jawaban benar yang lebih tinggi pada beberapa skenario, tetapi nilai *similarity* tidak selalu mengalami peningkatan pada kondisi yang sama. Perbedaan tersebut memperlihatkan bahwa efektivitas *Chain-of-Thought* dipengaruhi oleh karakteristik pengujian dan metode evaluasi yang digunakan.

Perbedaan hasil antar skenario berkaitan dengan struktur penyusunan dataset pengujian. Skenario 1 menguji setiap domain bahasa secara terpisah sehingga model hanya berhadapan dengan satu karakteristik bahasa dalam satu rangkaian soal. Kondisi tersebut memungkinkan proses reasoning mempertahankan konteks kosakata dan pola bahasa yang relatif sama. Skenario 2, 3, dan 4 menggabungkan sembilan domain bahasa dalam satu proses evaluasi sehingga model harus melakukan perpindahan konteks pada setiap soal yang berbeda.

Pergantian konteks antarbahasa memberikan tantangan tambahan bagi metode *Chain-of-Thought* karena proses penalaran yang dibangun pada satu soal tidak selalu relevan ketika model menerima soal dengan karakteristik bahasa yang berbeda. Model perlu menyesuaikan kembali pemahaman terhadap kosakata, struktur kalimat, serta konteks budaya dari domain berikutnya. Kondisi tersebut tidak terlalu terlihat pada Non-CoT karena metode ini langsung menghasilkan jawaban tanpa membangun rangkaian reasoning sebelum memberikan respons.

Perbedaan hasil antara nilai *similarity* dan jumlah jawaban benar memperlihatkan bahwa kedua metode evaluasi memiliki karakteristik pengukuran

yang berbeda. *Similarity* menggunakan tingkat kemiripan teks antara jawaban model dan referensi, sedangkan exact match hanya menentukan apakah jawaban sama dengan referensi atau tidak. *Chain-of-Thought* dapat memberikan keuntungan ketika proses reasoning menghasilkan keputusan yang tepat karena jawaban akhir cenderung mengikuti referensi secara langsung. Sebaliknya, ketika reasoning menghasilkan interpretasi yang kurang sesuai, jarak jawaban terhadap referensi dapat menjadi lebih besar sehingga nilai *similarity* mengalami penurunan.

Kemampuan reasoning pada model juga memiliki keterbatasan karena proses tersebut tidak menciptakan pengetahuan baru, melainkan mengolah informasi yang telah tersedia dalam model. Domain dengan representasi pengetahuan yang cukup memungkinkan *Chain-of-Thought* membantu proses evaluasi dan pemilihan jawaban. Kondisi berbeda terjadi pada domain dengan keterbatasan informasi, ketika reasoning dapat berkembang menggunakan asumsi yang tidak sesuai dengan konteks soal.

Pola tersebut terlihat pada beberapa checkpoint yang akan dibahas pada Subbab 4.6.2 dan 4.6.3. Analisis keberhasilan dan kegagalan *Chain-of-Thought* memperlihatkan bahwa peningkatan maupun penurunan performa tidak hanya dipengaruhi oleh keberadaan proses reasoning, tetapi juga oleh kemampuan model dalam memahami konteks bahasa yang diuji.

Secara keseluruhan, *Chain-of-Thought* memberikan keuntungan pada pengujian dengan konteks domain yang lebih terfokus, tetapi belum menunjukkan keunggulan yang konsisten ketika diterapkan pada kombinasi berbagai domain bahasa dalam jumlah soal yang lebih besar. Selain faktor akurasi, penerapan *Chain-*

of-Thought juga memiliki konsekuensi terhadap kebutuhan sumber daya komputasi yang akan dibahas lebih lanjut pada Subbab 4.6.5.

4.5.2 Analisis Keberhasilan *Chain-of-Thought* pada GPT-4o mini

Hasil pengujian memperlihatkan bahwa penerapan *Chain-of-Thought* tidak selalu memberikan peningkatan performa pada seluruh kondisi pengujian. Peningkatan performa lebih terlihat pada pengujian dengan konteks domain yang lebih terfokus, terutama pada beberapa domain bahasa daerah seperti Bahasa Lampung dan Bahasa Bali. Kondisi tersebut menunjukkan bahwa proses penalaran dapat memberikan manfaat ketika model telah memiliki pengetahuan awal yang relevan terhadap materi yang diuji.

Chain-of-Thought pada penelitian ini tidak berperan sebagai mekanisme untuk memperoleh informasi baru, melainkan sebagai proses yang membantu model mengatur informasi yang telah dimiliki sebelum menentukan jawaban akhir. Analisis terhadap checkpoint memperlihatkan tiga pola utama yang menyebabkan reasoning mampu menghasilkan jawaban yang lebih sesuai, yaitu kemampuan mengevaluasi pilihan jawaban, menghubungkan hubungan makna antar kosakata, serta menguraikan struktur kalimat sebelum mengambil keputusan.

a. Eliminasi Pilihan Jawaban Berdasarkan Konteks Soal

Kemampuan melakukan evaluasi terhadap pilihan jawaban terlihat pada soal Bahasa Lampung nomor 6. Soal tersebut meminta arti kata “gigi” dalam bahasa Lampung. Metode Non-CoT menghasilkan jawaban “Ipon” dengan nilai *similarity* sebesar 0%. Kata tersebut tidak sesuai dengan referensi karena “Ipon” memiliki keterkaitan dengan bahasa daerah lain

sehingga model terlihat memilih kosakata berdasarkan kemiripan informasi yang tersedia tanpa melakukan pemeriksaan terhadap konteks bahasa Lampung.

Proses reasoning pada metode CoT memperlihatkan pola pengambilan keputusan yang berbeda. Model tidak langsung menentukan salah satu pilihan, tetapi melakukan pemeriksaan terhadap beberapa kandidat jawaban yang tersedia. Beberapa pilihan dieliminasi karena tidak memiliki hubungan dengan makna kata yang ditanyakan, sedangkan kata “Kukut” dipertahankan karena sesuai dengan arti “gigi” dalam bahasa Lampung. Jawaban akhir yang diberikan sama dengan referensi sehingga memperoleh *similarity* sebesar 100%.

Perbedaan hasil tersebut memperlihatkan bahwa *Chain-of-Thought* membantu model melakukan proses penyaringan informasi sebelum menghasilkan jawaban. Model telah memiliki beberapa representasi kosakata yang berkaitan dengan bahasa daerah, tetapi tanpa proses evaluasi bertahap terdapat kemungkinan model memilih informasi yang memiliki asosiasi kuat walaupun berasal dari konteks bahasa yang berbeda. Reasoning berfungsi sebagai tahap verifikasi yang membantu model menyesuaikan informasi dengan konteks pertanyaan.

b. Pemanfaatan Hubungan Semantik Antar Kosakata

Pola keberhasilan lain terlihat pada soal Bahasa Bali nomor 2 yang membahas istilah pakaian adat. Non-CoT menghasilkan jawaban “kamen”

dengan *similarity* sebesar 20%, sedangkan penerapan CoT menghasilkan jawaban “baju” yang sesuai dengan referensi.

Proses reasoning memperlihatkan bahwa model mencoba memahami hubungan antara beberapa istilah yang terdapat pada soal. Model mengidentifikasi fungsi masing-masing kosakata, yaitu kamen sebagai kain penutup bagian bawah, udeng sebagai penutup kepala, dan baju sebagai pakaian bagian atas. Hubungan antar konsep tersebut digunakan untuk menentukan bahwa istilah “kuaca” memiliki makna yang lebih dekat dengan “baju”.

Hasil tersebut memperlihatkan bahwa *Chain-of-Thought* memberikan keuntungan ketika soal membutuhkan pemahaman hubungan makna antar informasi. Model tidak hanya melakukan pencocokan kata secara langsung, tetapi membangun keterkaitan antar konsep sebelum menghasilkan keputusan akhir. Proses tersebut membuat model lebih mampu memilih jawaban yang sesuai ketika beberapa pilihan memiliki hubungan dengan topik yang sama.

c. Penguraian Struktur Kalimat Sebelum Menentukan Jawaban

Kemampuan reasoning dalam memahami struktur kalimat terlihat pada soal Bahasa Makassar nomor 11. Soal tersebut meminta terjemahan kalimat “Dari mana kamu kemarin?” ke dalam bahasa Makassar. Metode Non-CoT menghasilkan jawaban dengan *similarity* sebesar 61%, sedangkan CoT menghasilkan jawaban “Battu kemaeko subangngi” yang sesuai dengan referensi dengan *similarity* sebesar 100%

Proses penalaran pada soal tersebut memperlihatkan bahwa model melakukan penguraian terhadap bagian-bagian kalimat sebelum menentukan pilihan akhir. Beberapa kosakata seperti “Battu” dan “kemaeko” dianalisis terlebih dahulu untuk melihat keterkaitannya dengan makna kalimat secara keseluruhan. Tahapan tersebut membantu model memahami hubungan antar kata, bukan hanya mencocokkan satu istilah tertentu.

Karakteristik soal terjemahan yang membutuhkan pemahaman antarbagian kalimat membuat proses reasoning menjadi lebih relevan. *Chain-of-Thought* memberikan ruang bagi model untuk mengorganisasi informasi linguistik sebelum menghasilkan jawaban sehingga keputusan yang diambil menjadi lebih terarah.

Ketiga checkpoint tersebut memperlihatkan bahwa keberhasilan *Chain-of-Thought* terjadi ketika model telah memiliki pengetahuan awal yang cukup dan mampu mengolah informasi tersebut secara sistematis. Proses reasoning membantu model melakukan evaluasi, menghubungkan konsep, serta memahami konteks sebelum menghasilkan jawaban. Peningkatan performa yang terjadi bukan disebabkan oleh munculnya pengetahuan baru, melainkan karena informasi yang telah dimiliki model digunakan melalui proses pengambilan keputusan yang lebih terstruktur.

4.5.3 Analisis Kegagalan Reasoning *Chain-of-Thought*

Hasil pengujian juga memperlihatkan kondisi ketika penerapan *Chain-of-Thought* menghasilkan performa yang lebih rendah dibandingkan Non-CoT.

Beberapa checkpoint menunjukkan bahwa jawaban yang telah sesuai pada metode Non-CoT berubah menjadi tidak sesuai setelah model melakukan proses reasoning. Fenomena tersebut memperlihatkan bahwa penambahan tahapan penalaran tidak selalu meningkatkan kualitas jawaban karena hasil akhir tetap dipengaruhi oleh pemahaman awal model terhadap soal.

Analisis terhadap checkpoint memperlihatkan tiga pola kegagalan utama, yaitu kesalahan pemahaman pada tahap awal reasoning, perubahan keputusan akibat proses penalaran berlebihan, serta keterbatasan pengetahuan domain membatasi efektivitas reasoning.

a. Kesalahan Premis pada Tahap Awal Penalaran

Kesalahan pada tahap awal reasoning terlihat pada soal Bahasa Madura nomor 3. Soal tersebut meminta terjemahan kalimat “*Salenglengna bedhengan jareya epasange?*” dengan jawaban referensi “Pagar perreng”. Metode Non-CoT menghasilkan jawaban yang sesuai dengan *similarity* 100%. Penerapan *Chain-of-Thought* menghasilkan jawaban “Pagar beton” dengan *similarity* 61,54%. Proses reasoning memperlihatkan bahwa model memahami pertanyaan tersebut sebagai pembahasan mengenai jenis pagar yang memiliki daya tahan paling tinggi. Model kemudian membandingkan beberapa jenis material pagar dan menyimpulkan bahwa pagar beton merupakan pilihan yang paling sesuai.

Interpretasi tersebut membuat seluruh proses penalaran berjalan menuju kesimpulan yang berbeda dari tujuan soal. Reasoning yang dihasilkan terlihat sistematis, tetapi dibangun dari pemahaman awal yang

tidak sesuai. Kondisi ini memperlihatkan bahwa kualitas penalaran sangat bergantung pada ketepatan pemahaman model terhadap konteks pertanyaan sebelum proses reasoning berlangsung. *Chain-of-Thought* tidak dapat memperbaiki informasi awal yang keliru karena proses tersebut hanya mengembangkan pengetahuan yang telah dipilih oleh model. Ketika premis awal tidak sesuai, reasoning justru dapat memperkuat arah keputusan yang keliru.

b. Perubahan Keputusan Akibat *Overreasoning*

Perubahan keputusan setelah proses reasoning terlihat pada soal Bahasa Makassar nomor 12. Soal tersebut meminta terjemahan kalimat “Saya mau belajar membuat kue”. Metode Non-CoT menghasilkan jawaban yang sesuai dengan referensi yaitu “I nakke erokka appilajar appare kanrejawa” dengan *similarity* 100%. Proses *Chain-of-Thought* membuat model melakukan evaluasi tambahan terhadap seluruh pilihan jawaban. Model sebenarnya telah menemukan pilihan yang sesuai, tetapi kemudian mempertanyakan beberapa bagian kosakata pada pilihan tersebut dan berpindah ke jawaban lain. Hasil akhir yang diperoleh memiliki *similarity* sebesar 65,85%.

Kondisi tersebut memperlihatkan fenomena *overreasoning*, yaitu keadaan ketika proses penalaran yang terlalu panjang menyebabkan model mempertimbangkan informasi tambahan yang tidak diperlukan. Evaluasi yang dilakukan secara berlebihan dapat mengubah keputusan awal yang sebenarnya sudah tepat. Fenomena ini menunjukkan bahwa reasoning tidak

selalu meningkatkan keyakinan model terhadap jawaban benar. Pada beberapa jenis soal yang dapat diselesaikan melalui pengenalan pola atau pengetahuan langsung, proses tambahan justru dapat memperbesar kemungkinan terjadinya perubahan keputusan.

c. Keterbatasan Pengetahuan Domain Membatasi Efektivitas Reasoning

Keterbatasan pemahaman domain terlihat di Bahasa Dayak Ngaju. Hasil pengujian menunjukkan nilai *similarity* Non-CoT sebesar 61,02% dan CoT sebesar 57,88%, dengan jumlah jawaban benar yang sama, yaitu 33 dari 100 soal serta terdapat 54 soal yang menghasilkan jawaban salah pada kedua metode secara bersamaan. Kondisi ini menunjukkan bahwa *Chain-of-Thought* belum mampu memberikan peningkatan performa karena model masih mengalami kesulitan dalam memahami kosakata dan struktur Bahasa Dayak Ngaju.

Hasil tersebut menunjukkan bahwa proses reasoning tidak selalu berdampak positif terhadap akurasi jawaban. *Chain-of-Thought* hanya dapat membantu ketika model memiliki pengetahuan awal yang memadai, sedangkan keterbatasan informasi terhadap domain tertentu dapat menyebabkan hasil penalaran tetap kurang sesuai dengan konteks soal.

Ketiga pola kegagalan tersebut memperlihatkan bahwa efektivitas *Chain-of-Thought* bersifat kontekstual. Reasoning dapat meningkatkan kualitas jawaban ketika model memiliki pengetahuan awal yang cukup dan mampu mengolah informasi yang tersedia secara tepat. Proses yang sama dapat menghasilkan keputusan kurang sesuai ketika model membangun penalaran dari asumsi awal

yang keliru, melakukan evaluasi secara berlebihan, atau menghadapi keterbatasan pengetahuan terhadap domain tertentu.

Temuan ini memperkuat hasil pengujian sebelumnya bahwa *Chain-of-Thought* belum menunjukkan keunggulan yang konsisten dibandingkan Non-CoT pada seluruh skenario. Metode tersebut memberikan manfaat pada kondisi tertentu, terutama ketika model telah memiliki representasi pengetahuan yang relevan terhadap soal yang diberikan. Penerapan *Chain-of-Thought* belum dapat dianggap selalu meningkatkan akurasi karena hasil akhirnya tetap dipengaruhi oleh karakteristik domain, tingkat penguasaan model, dan kompleksitas soal pada dataset IndoMMLU.

4.5.4 Pengaruh Karakteristik Domain Bahasa terhadap Performa Model

Perbedaan karakteristik setiap domain bahasa memberikan pengaruh terhadap efektivitas penerapan *Chain-of-Thought* pada GPT-4o mini. Hasil pengujian memperlihatkan bahwa peningkatan performa tidak hanya dipengaruhi oleh metode prompting yang digunakan, tetapi juga oleh tingkat penguasaan model terhadap informasi linguistik pada masing-masing domain. Domain dengan representasi pengetahuan yang lebih kuat cenderung memperoleh manfaat lebih besar dari proses reasoning, sedangkan domain dengan keterbatasan informasi mengalami peningkatan yang lebih terbatas atau bahkan mengalami penurunan performa.

Bahasa Indonesia memiliki karakteristik berbeda dibandingkan delapan domain bahasa daerah lainnya karena memiliki cakupan penggunaan dan representasi data yang lebih luas dalam proses pelatihan model. Kondisi tersebut

membuat performa dasar Non-CoT telah berada pada tingkat yang relatif tinggi. Penerapan *Chain-of-Thought* hanya memberikan perubahan kecil karena sebagian besar informasi yang dibutuhkan untuk menjawab soal telah dapat diakses model tanpa memerlukan proses penalaran tambahan.

Bahasa Bali memperlihatkan pola peningkatan yang lebih signifikan setelah penerapan *Chain-of-Thought*. Model telah memiliki pemahaman dasar terhadap beberapa kosakata yang muncul pada soal, tetapi masih membutuhkan proses penghubungan informasi untuk menentukan jawaban yang tepat. Reasoning membantu model mengaitkan makna antar istilah sehingga jumlah jawaban benar meningkat dari 38 soal pada Non-CoT menjadi 49 soal pada CoT.

Bahasa Lampung memiliki pola peningkatan yang serupa, tetapi mekanisme keberhasilannya berbeda. Permasalahan utama pada domain ini bukan hanya keterbatasan kosakata, melainkan adanya kemungkinan pencampuran informasi dengan bahasa daerah lain yang memiliki kemiripan bentuk atau konteks. Proses reasoning membantu model melakukan penyaringan terhadap beberapa kemungkinan jawaban sehingga kosakata yang sesuai dengan bahasa Lampung dapat dipertahankan.

Bahasa Makassar memperlihatkan karakteristik yang lebih kompleks. Tingkat penguasaan awal model terhadap domain ini belum cukup kuat untuk menghasilkan peningkatan performa secara konsisten. Beberapa checkpoint memperlihatkan bahwa reasoning mampu membantu model memahami struktur kalimat, tetapi pada kasus lain proses tersebut justru menyebabkan perubahan keputusan ke arah jawaban yang tidak sesuai. Dampak positif dan negatif yang

muncul secara bersamaan membuat pengaruh *Chain-of-Thought* pada hasil agregat menjadi relatif kecil.

Bahasa Dayak Ngaju memperlihatkan keterbatasan pengetahuan model yang paling terlihat. Sebagian besar soal pada domain ini belum dapat dijawab sesuai referensi oleh kedua metode. Proses reasoning pada beberapa kasus menghasilkan penjelasan yang terlihat terstruktur, tetapi tidak memiliki keterkaitan yang cukup dengan konteks bahasa yang diuji. Kondisi tersebut terjadi karena model tidak memiliki representasi kosakata yang memadai sebagai dasar untuk membangun proses penalaran.

Bahasa Madura memperlihatkan pola penurunan performa setelah penerapan *Chain-of-Thought*. Tingkat penguasaan dasar model terhadap domain ini berada pada kondisi yang tidak jauh berbeda dengan beberapa bahasa daerah lainnya, tetapi bentuk kegagalannya memiliki karakteristik berbeda. Reasoning pada domain ini lebih sering menghasilkan interpretasi ulang terhadap maksud soal sehingga model menjawab permasalahan yang berbeda dari pertanyaan asli.

Perbandingan antar domain tersebut memperlihatkan bahwa *Chain-of-Thought* bukan mekanisme yang secara otomatis meningkatkan kemampuan model pada seluruh jenis bahasa. Efektivitas reasoning sangat bergantung pada ketersediaan pengetahuan awal dan kemampuan model dalam mempertahankan konteks pertanyaan. Proses penalaran memberikan manfaat ketika informasi yang dimiliki model cukup untuk dikembangkan, sedangkan keterbatasan pengetahuan dapat menyebabkan reasoning menghasilkan keputusan yang kurang sesuai.

4.5.5 Analisis Efisiensi Penggunaan Token dan Waktu Respons

Peningkatan performa yang diperoleh melalui *Chain-of-Thought* perlu dipertimbangkan bersama peningkatan kebutuhan sumber daya selama proses pengujian. Hasil eksperimen memperlihatkan bahwa penggunaan reasoning memberikan konsekuensi berupa peningkatan jumlah token yang digunakan serta waktu respons yang lebih panjang dibandingkan metode Non-CoT.

Pengujian Skenario 1 menunjukkan bahwa metode CoT menggunakan total 373.641 token untuk 900 soal, sedangkan Non-CoT menggunakan 71.939 token. Perbedaan tersebut menunjukkan bahwa kebutuhan token pada metode CoT mencapai sekitar 5,2 kali lebih besar dibandingkan Non-CoT. Perbedaan serupa juga terlihat pada keseluruhan pengujian, dengan total penggunaan token Non-CoT sebesar 194.222 token dan CoT sebesar 1.016.027 token.

Peningkatan penggunaan token terjadi karena metode CoT menghasilkan tahapan reasoning tambahan sebelum memberikan jawaban akhir. Proses tersebut membuat model menghasilkan keluaran yang lebih panjang sehingga jumlah token yang diproses meningkat secara signifikan. Kondisi yang sama juga terlihat pada waktu respons, ketika latency rata-rata CoT berada pada kisaran 4,55 hingga 6,06 detik per soal, sedangkan Non-CoT berada pada kisaran 1,45 hingga 1,85 detik per soal.

Perbedaan kebutuhan sumber daya tersebut menjadi faktor penting ketika sistem diterapkan pada skala yang lebih besar. Pengujian dengan ratusan soal masih dapat dilakukan dengan tambahan waktu dan biaya yang relatif dapat diterima,

tetapi peningkatan jumlah data hingga ribuan atau puluhan ribu soal akan memperbesar selisih kebutuhan komputasi antara kedua metode.

Efisiensi penggunaan *Chain-of-Thought* juga perlu dilihat dari peningkatan akurasi yang diperoleh. Skenario 2 dan Skenario 3 hanya menghasilkan perbedaan jumlah jawaban benar yang relatif kecil antara CoT dan Non-CoT, sedangkan Skenario 4 memperlihatkan performa CoT yang lebih rendah dibandingkan Non-CoT. Kondisi tersebut memperlihatkan bahwa peningkatan konsumsi token hingga lima kali lipat belum selalu menghasilkan peningkatan akurasi yang sebanding.

Penggunaan *Chain-of-Thought* lebih sesuai diterapkan secara selektif pada kondisi tertentu, terutama pada domain yang memperlihatkan peningkatan setelah proses reasoning dilakukan seperti Bahasa Bali dan Bahasa Lampung. Penerapan reasoning secara menyeluruh pada seluruh dataset menyebabkan peningkatan biaya komputasi tanpa memberikan keuntungan akurasi yang konsisten.

4.5.6 Analisis Keterbatasan Evaluasi Menggunakan *Exact Match* dan *Levenshtein Distance*

Metode evaluasi yang digunakan dalam penelitian ini memiliki keterbatasan dalam mengukur kesesuaian jawaban model, terutama ketika terdapat perbedaan bentuk penulisan antara jawaban model dan referensi. Sistem menggunakan nilai *similarity* dari *Levenshtein Distance* dengan ambang batas 100% untuk menentukan kesesuaian jawaban, sehingga perbedaan karakter tetap memberikan pengaruh terhadap hasil evaluasi meskipun makna kedua jawaban memiliki kesamaan.

Kasus Bahasa Lampung nomor 2 memperlihatkan kondisi tersebut. Jawaban referensi pada dataset adalah "Tari Cangget", sedangkan jawaban yang

diberikan oleh CoT adalah "Cangget". Kedua jawaban memiliki makna yang sama karena merujuk pada jenis tarian yang sama, tetapi perbedaan bentuk teks menyebabkan nilai *similarity* hanya mencapai 58%. Sistem kemudian mengategorikan jawaban tersebut sebagai tidak sesuai.

Kondisi serupa terlihat pada soal Bahasa Indonesia nomor 22 yang meminta pelengkap kalimat “Dika, Telah meminjamiku pensil”. Jawaban referensi yang tersedia adalah “Terima kasih”. Non-CoT menghasilkan jawaban “Dika, Terima kasih. Telah meminjamiku pensil.” yang secara makna masih mengandung jawaban yang benar, tetapi tambahan teks membuat nilai *similarity* turun menjadi 28,57%. Metode CoT yang menghasilkan jawaban lebih ringkas berhasil memperoleh hasil yang sesuai dengan referensi.

Kasus tersebut memperlihatkan bahwa sebagian perbedaan hasil evaluasi tidak selalu berkaitan dengan kemampuan model dalam memahami soal, tetapi dapat dipengaruhi oleh gaya penyampaian jawaban. Model yang memberikan penjelasan tambahan atau menggunakan format kalimat berbeda dapat memperoleh nilai lebih rendah ketika dibandingkan dengan referensi yang hanya berisi jawaban singkat.

Levenshtein Distance tetap memiliki manfaat sebagai metode evaluasi karena memberikan ukuran numerik yang objektif dan dapat diterapkan secara konsisten pada jumlah data yang besar. Penggunaan metode ini memudahkan proses perbandingan antara jawaban model dan referensi tanpa membutuhkan penilaian manual terhadap ribuan jawaban.

Interpretasi terhadap hasil evaluasi perlu mempertimbangkan keterbatasan tersebut. Nilai *similarity* dan kategori kesesuaian yang diperoleh menggambarkan tingkat kedekatan teks antara jawaban model dan referensi, tetapi belum sepenuhnya menggambarkan pemahaman semantik model terhadap pertanyaan. Evaluasi berbasis kombinasi antara pengukuran otomatis dan penilaian manusia dapat memberikan gambaran yang lebih menyeluruh terhadap kemampuan model pada penelitian selanjutnya.

4.6 Hasil Pengujian *Black Box*

Pengujian sistem dilakukan menggunakan metode *Black Box Testing* untuk memastikan setiap fungsi pada aplikasi pengujian performa model GPT-4o mini menggunakan metode *Chain-of-Thought* (CoT) dan Non-CoT serta perhitungan tingkat kemiripan jawaban menggunakan algoritma *Levenshtein Distance* dapat berjalan sesuai dengan kebutuhan sistem. Pengujian dilakukan dengan memberikan masukan terhadap setiap fitur yang tersedia, kemudian hasil keluaran sistem dibandingkan dengan hasil yang diharapkan. Pengujian dinyatakan berhasil apabila keluaran sistem sesuai dengan rancangan yang telah dibuat.

4.6.1 Halaman Dataset

Pengujian halaman dataset dilakukan untuk memastikan fitur pengelolaan dataset dapat berjalan dengan baik, meliputi proses mengunggah dataset, mengunduh dataset IndoMMLU, mengunduh *template* dataset, menambah data secara manual, serta menghapus data dataset. Hasil pengujian halaman dataset dapat dilihat pada Tabel 4.22.

Tabel 4. 24 Pengujian Black Box Halaman Dataset

No	Test Case	Pre-condition	Test Steps	Test Data	Expected Result	Actual Result	Status
1	Membuka halaman dataset	Pengguna berada pada halaman utama aplikasi	Klik menu Dataset	-	Halaman dataset berhasil ditampilkan	Sesuai	PASS
2	Mengunggah dataset format CSV	Halaman dataset terbuka	Klik tombol upload dataset, memilih file CSV, kemudian melakukan upload	Dataset IndoMMLU.csv	Dataset berhasil diunggah dan data ditampilkan pada halaman dataset	Sesuai	PASS
3	Mengunggah file selain CSV	Halaman dataset terbuka	Memilih file selain format CSV kemudian melakukan upload	Dataset.xlsx	Sistem menampilkan pesan gagal upload karena format file tidak sesuai	Sesuai	PASS

4	Mengunggah dataset dengan format tidak sesuai	Halaman dataset terbuka	Mengunggah file CSV dengan struktur kolom yang tidak sesuai template	Dataset_invalid.csv	Sistem menampilkan pesan gagal upload karena format dataset tidak sesuai	Sesuai	PASS
5	Mengunduh dataset IndoMMLU	Halaman dataset terbuka	Klik tombol Dataset IndoMMLU	-	Dataset IndoMMLU berhasil diunduh	Sesuai	PASS
6	Mengunduh <i>template</i> dataset	Halaman dataset terbuka	Klik tombol <i>Template CSV</i>	-	<i>Template</i> dataset berhasil diunduh	Sesuai	PASS
7	Menambah data dataset	Halaman dataset terbuka	Klik tombol Tambah Data, mengisi form, kemudian menyimpan data	Data soal dan jawaban	Data berhasil ditambahkan ke dalam dataset	Sesuai	PASS
8	Menghapus data dataset	Data dataset tersedia	Klik tombol hapus pada salah satu data	Data dataset	Data berhasil dihapus dari dataset	Sesuai	PASS

4.6.2 Halaman Proses Pengujian

Pengujian halaman proses pengujian dilakukan untuk memastikan sistem dapat menjalankan proses evaluasi akurasi model GPT-4o mini menggunakan metode Non-CoT dan CoT berdasarkan dataset yang telah tersedia. Hasil pengujian halaman proses pengujian dapat dilihat pada Tabel 4.23.

Tabel 4. 25 Pengujian Black Box Halaman Proses Pengujian

No	Test Case	Pre-condition	Test Steps	Test Data	Expected Result	Actual Result	Status
1	Membuka halaman proses pengujian	Pengguna berada pada halaman utama aplikasi	Klik menu Proses Pengujian	-	Halaman proses pengujian berhasil ditampilkan	Sesuai	PASS
2	Menjalankan pengujian	Dataset telah tersedia pada sistem	Klik tombol Jalankan Pengujian	Dataset IndoMMLU	Proses evaluasi berhasil dimulai	Sesuai	PASS
3	Menampilkan status proses pengujian	Proses evaluasi sedang berlangsung	Melihat halaman proses pengujian	Dataset pengujian	Status proses pengujian berhasil ditampilkan	Sesuai	PASS
4	Menampilkan hasil pengujian selesai	Proses evaluasi berhasil diselesaikan	Melihat halaman proses pengujian	Data hasil evaluasi	Sistem menampilkan informasi bahwa proses pengujian telah selesai	Sesuai	PASS
5	Menjalankan pengujian tanpa dataset	Dataset belum tersedia	Klik tombol Jalankan Pengujian	-	Sistem menampilkan pesan peringatan bahwa dataset belum tersedia	Sesuai	PASS

4.6.3 Halaman Hasil Pengujian

Pengujian halaman hasil pengujian dilakukan untuk memastikan sistem dapat menampilkan hasil evaluasi, tabel hasil pengujian, serta riwayat pengujian dengan benar. Hasil pengujian halaman hasil pengujian dapat dilihat pada Tabel 4.24.

Tabel 4. 26 Pengujian Black Box Halaman Hasil Pengujian

No	Test Case	Pre-condition	Test Steps	Test Data	Expected Result	Actual Result	Status
1	Membuka halaman hasil pengujian	Pengguna berada pada halaman utama aplikasi	Klik menu Hasil Pengujian	-	Halaman hasil pengujian berhasil ditampilkan	Sesuai	PASS
2	Menampilkan ringkasan hasil pengujian	Proses pengujian telah selesai dilakukan	Membuka halaman hasil pengujian	Data hasil evaluasi	Informasi akurasi CoT dan Non-CoT berhasil ditampilkan	Sesuai	PASS
3	Menampilkan tabel hasil pengujian	Proses pengujian telah selesai dilakukan	Melihat tabel hasil pengujian	Data hasil evaluasi	Tabel hasil pengujian berhasil ditampilkan	Sesuai	PASS
4	Menampilkan tabel riwayat pengujian	Data evaluasi telah tersimpan	Membuka halaman riwayat pengujian	Data evaluasi sebelumnya	Tabel riwayat pengujian berhasil ditampilkan	Sesuai	PASS

No	Test Case	Pre-condition	Test Steps	Test Data	Expected Result	Actual Result	Status
5	Menampilkan hasil evaluasi dari riwayat pengujian	Data riwayat pengujian tersedia	Klik tombol lihat pada salah satu riwayat pengujian	Data evaluasi	Halaman hasil pengujian berubah sesuai data riwayat yang dipilih	Sesuai	PASS
6	Membuka halaman hasil pengujian tanpa data	Belum melakukan pengujian	Membuka halaman hasil pengujian	-	Sistem menampilkan informasi belum terdapat hasil evaluasi	Sesuai	PASS

4.6.4 Halaman Visualisasi

Pengujian halaman visualisasi dilakukan untuk memastikan sistem dapat menampilkan grafik dan statistik hasil evaluasi secara benar berdasarkan data hasil pengujian yang telah dilakukan. Hasil pengujian halaman visualisasi dapat dilihat pada Tabel 4.25.

Tabel 4. 27 Pengujian Black Box Halaman Visualisasi

No	Test Case	Pre-condition	Test Steps	Test Data	Expected Result	Actual Result	Status
1	Membuka halaman visualisasi	Pengguna berada pada halaman utama aplikasi	Klik menu Visualisasi	-	Halaman visualisasi berhasil ditampilkan	Sesuai	PASS

No	Test Case	Pre-condition	Test Steps	Test Data	Expected Result	Actual Result	Status
2	Menampilkan grafik hasil pengujian	Data hasil pengujian tersedia	Membuka halaman visualisasi	Data evaluasi	Grafik perbandingan CoT dan Non-CoT berhasil ditampilkan	Sesuai	PASS
3	Menampilkan statistik pengujian	Data hasil pengujian tersedia	Membuka halaman visualisasi	Data evaluasi	Informasi rata-rata akurasi, total data, dan total subject berhasil ditampilkan	Sesuai	PASS
4	Membuka halaman visualisasi tanpa data	Belum melakukan pengujian	Membuka halaman Visualisasi	-	Sistem menampilkan informasi belum ada data visualisasi	Sesuai	PASS

4.6.5 Halaman Laporan

Pengujian halaman laporan dilakukan untuk memastikan sistem dapat menampilkan laporan hasil evaluasi serta melakukan export laporan dalam format PDF dan Excel. Hasil pengujian halaman laporan dapat dilihat pada Tabel 4.26.

Tabel 4. 28 Pengujian Black Box Halaman Laporan

No	Test Case	Pre-condition	Test Steps	Test Data	Expected Result	Actual Result	Status
1	Membuka halaman laporan	Pengguna berada pada	Klik menu Laporan	-	Halaman laporan berhasil ditampilkan	Sesuai	PASS

No	Test Case	Pre-condition	Test Steps	Test Data	Expected Result	Actual Result	Status
		halaman utama aplikasi					
2	Menampilkan ringkasan laporan	Data hasil pengujian tersedia	Membuka halaman laporan	Data evaluasi	Ringkasan hasil evaluasi berhasil ditampilkan	Sesuai	PASS
3	Preview laporan PDF	Data hasil pengujian tersedia	Klik tombol Preview PDF	Data evaluasi	Laporan PDF berhasil ditampilkan	Sesuai	PASS
4	Mengunduh laporan PDF	Data laporan tersedia	Klik tombol <i>Download</i> PDF	-	File PDF berhasil diunduh	Sesuai	PASS
5	Mengunduh laporan Excel	Data laporan tersedia	Klik tombol <i>Download</i> Excel	-	File Excel berhasil diunduh	Sesuai	PASS
6	Membuka halaman laporan tanpa data	Belum melakukan pengujian	Membuka halaman laporan	-	Sistem menampilkan informasi belum ada laporan	Sesuai	PASS

BAB V

PENUTUP

5.1 Simpulan

Penelitian ini menghasilkan beberapa simpulan perancangan dan implementasi sistem evaluasi otomatis, pengukuran akurasi jawaban ChatGPT menggunakan algoritma *Levenshtein Distance*, serta perbandingan efektivitas metode *Chain-of-Thought* (CoT) dan *Non-Chain-of-Thought* (Non-CoT) pada dataset IndoMMLU domain bahasa sebagai berikut.

- a. Sistem evaluasi otomatis untuk menguji akurasi jawaban *ChatGPT* pada soal *Multiple Choice Question (MCQ)* domain bahasa berhasil dibangun dalam bentuk aplikasi *EvalGPT*. Sistem mampu menjalankan proses evaluasi mulai dari *preprocessing* dataset IndoMMLU, pembentukan *prompt*, pengiriman soal ke model GPT-4o mini melalui *OpenAI API*, ekstraksi jawaban, normalisasi teks, perhitungan nilai *similarity* menggunakan algoritma *Levenshtein Distance*, hingga penyajian hasil pengujian. Hasil *Black Box Testing* menunjukkan seluruh fitur utama sistem berfungsi sesuai dengan rancangan.
- b. Tingkat akurasi jawaban GPT-4o mini terhadap dataset IndoMMLU domain bahasa daerah yang diukur menggunakan algoritma *Levenshtein Distance* menunjukkan variasi antar domain. Bahasa Indonesia menghasilkan performa tertinggi dengan nilai *similarity* sebesar 93,86% hingga 95,92% serta akurasi *exact match* sebesar 90% hingga 94%. Delapan domain bahasa daerah lainnya memperoleh nilai *similarity* pada rentang 55,49% hingga

77,23% dengan akurasi *exact match* sebesar 33% hingga 66%. Hasil tersebut menunjukkan kemampuan GPT-4o mini dalam menjawab soal domain bahasa dipengaruhi oleh karakteristik dan tingkat pemahaman model terhadap masing-masing bahasa. Algoritma *Levenshtein Distance* juga mampu digunakan untuk evaluasi otomatis, meskipun masih memiliki keterbatasan dalam mengenali kesamaan makna apabila terdapat perbedaan bentuk penulisan jawaban.

- c. Perbandingan metode *Chain-of-Thought* dan *Non-Chain-of-Thought* menunjukkan bahwa efektivitas *Chain-of-Thought* dipengaruhi oleh konteks pengujian. Pengujian per domain menggunakan 900 soal menghasilkan performa lebih tinggi melalui metode *Chain-of-Thought* dengan 483 jawaban benar dan nilai *similarity* sebesar 67,66%, sedangkan *Non-Chain-of-Thought* memperoleh 454 jawaban benar dengan nilai *similarity* sebesar 66,65%. Pengujian gabungan dengan jumlah data lebih besar menunjukkan *Non-Chain-of-Thought* menghasilkan nilai *similarity* lebih tinggi di seluruh skenario, sedangkan jumlah jawaban benar *Chain-of-Thought* hanya lebih unggul pada sebagian skenario. Hasil analisis menunjukkan proses *reasoning* membantu model melalui evaluasi pilihan jawaban, hubungan antar kosakata, serta pemahaman struktur kalimat. Proses tersebut juga dapat menurunkan performa ketika model memiliki keterbatasan pengetahuan domain atau membangun asumsi yang tidak sesuai dengan konteks soal. Penggunaan metode *Chain-of-Thought* membutuhkan token sekitar 5,2 kali lebih banyak serta waktu respons

(*latency*) sekitar empat hingga enam kali lebih lama dibandingkan *Non-Chain-of-Thought*, sehingga penerapannya lebih sesuai dilakukan secara selektif sesuai karakteristik pengujian.

5.2 Saran

Beberapa saran yang dapat diajukan untuk pengembangan penelitian selanjutnya adalah sebagai berikut.

- a. Pengujian dapat dilakukan menggunakan model *Large Language Model* (LLM) lain, seperti GPT-4o, Gemini, Claude, atau LLaMA, sehingga efektivitas metode *Chain-of-Thought* dapat dibandingkan pada berbagai model.
- b. Dataset penelitian dapat diperluas dengan menambahkan domain lain dalam IndoMMLU atau menggunakan dataset bahasa daerah lainnya sehingga hasil evaluasi dapat menggambarkan kemampuan model pada cakupan pengetahuan yang lebih luas.
- c. Metode evaluasi dapat dikembangkan dengan mengombinasikan algoritma *Levenshtein Distance* dan metode berbasis *semantic similarity*, seperti *Sentence-BERT* (SBERT), sehingga jawaban yang memiliki makna sama tetapi berbeda bentuk penulisan tetap dapat dikenali sebagai jawaban yang sesuai.
- d. Evaluasi hasil pengujian dapat melibatkan penutur asli atau ahli bahasa daerah untuk memvalidasi hasil evaluasi otomatis, terutama terhadap jawaban yang memiliki makna sama tetapi memperoleh nilai *similarity* rendah akibat perbedaan bentuk penulisan.

- e. Aplikasi EvalGPT dapat dikembangkan dengan menambahkan fitur perbandingan beberapa model LLM, analisis hasil pengujian yang lebih komprehensif, serta penyajian statistik evaluasi yang lebih beragam sehingga dapat mendukung penelitian mengenai evaluasi performa model bahasa secara lebih luas.

DAFTAR PUSTAKA

- [1] F. Koto, N. Aisyah, H. Li, and T. Baldwin, “Large Language Models Only Pass Primary School Exams in Indonesia: A Comprehensive *Test* on IndoMMLU Department Natural Language Processing, MBZUAI,” 1237. [Online]. Available: <https://github.com/>
- [2] J. Beernaerts, E. Debever, M. Lenoir, B. De Baets, and N. Van de Weghe, “A method based on the *Levenshtein Distance* metric for the comparison of multiple movement patterns described by matrix sequences of different length,” *Expert Syst. Appl.*, vol. 115, pp. 373–385, Jan. 2019, doi: 10.1016/j.eswa.2018.07.076.
- [3] A. Maitland, R. Fowkes, and S. Maitland, “Can ChatGPT pass the MRCP (UK) written examinations? Analysis of performance and errors using a clinical decision-reasoning framework,” *BMJ Open*, vol. 14, no. 3, Mar. 2024, doi: 10.1136/bmjopen-2023-080558.
- [4] Y. T. Ting *et al.*, “Performance of ChatGPT incorporated *Chain-of-Thought* method in bilingual nuclear medicine physician board examinations,” *Digit. Health*, vol. 10, Jan. 2024, doi: 10.1177/20552076231224074.
- [5] J. W. A. Strachan *et al.*, “Testing theory of mind in large language models and humans,” *Nat. Hum. Behav.*, vol. 8, no. 7, pp. 1285–1295, Jul. 2024, doi: 10.1038/s41562-024-01882-z.
- [6] G. G. Lee, E. Latif, X. Wu, N. Liu, and X. Zhai, “Applying large language models and *Chain-of-Thought* for automatic scoring,” *Computers and Education: Artificial Intelligence*, vol. 6, Jun. 2024, doi: 10.1016/j.caeai.2024.100213.
- [7] J. Chen, L. Chen, H. Huang, and T. Zhou, “When do you need *Chain-of-Thought* Prompting for ChatGPT?,” Apr. 2023, [Online]. Available: <http://arxiv.org/abs/2304.03262>
- [8] D. Hendrycks *et al.*, “Measuring Massive Multitask Language Understanding,” Jan. 2021, [Online]. Available: <http://arxiv.org/abs/2009.03300>
- [9] W. Li, L. Li, T. Xiang, X. Liu, W. Deng, and N. Garcia, “Can multiple-choice questions really be *useful* in detecting the abilities of LLMs?,” May 2024, [Online]. Available: <http://arxiv.org/abs/2403.17752>

- [10] G. Zhu, X. Zhang, and C. Chen, "Assessing and enhancing the reliability of Chinese large language models in dental implantology," *BMC Oral Health*, vol. 25, no. 1, Dec. 2025, doi: 10.1186/s12903-025-06648-1.
- [11] Z. W. Lim *et al.*, "Benchmarking large language models' performances for myopia care: a comparative analysis of ChatGPT-3.5, ChatGPT-4.0, and Google Bard," 2023. [Online]. Available: www.thelancet.com
- [12] C. W. Tsai, Y. J. Lin, J. U. Hou, S. C. Tsai, P. C. Yeh, and C. H. Kao, "Optimizing patient education for radioactive iodine therapy and the role of ChatGPT incorporating *Chain-of-Thought* technique: ChatGPT questionnaire," *Digit. Health*, vol. 11, Jan. 2025, doi: 10.1177/20552076251357468.
- [13] H. C. Lind-Combs, T. Bent, R. F. Holt, C. G. Clopper, and E. Brown, "Comparing *Levenshtein Distance* and dynamic time warping in predicting listeners' judgments of accent distance," *Speech Commun.*, vol. 155, Nov. 2023, doi: 10.1016/j.specom.2023.102987.
- [14] J. Song, G. Qin, Y. Liang, J. Yan, and M. Sun, "SIDiLDNG: A *similarity*-based intrusion detection system using improved *Levenshtein Distance* and N-gram for CAN," *Comput. Secur.*, vol. 142, Jul. 2024, doi: 10.1016/j.cose.2024.103847.
- [15] B. Berger, M. S. Waterman, and Y. W. Yu, "*Levenshtein Distance*, Sequence Comparison and Biological Database Search," *IEEE Trans. Inf. Theory*, vol. 67, no. 6, pp. 3287–3294, Jun. 2021, doi: 10.1109/TIT.2020.2996543.
- [16] T. Petty, J. Hannig, T. I. Huszar, and H. Iyer, "A New String Edit Distance and Applications," *Algorithms*, vol. 15, no. 7, Jul. 2022, doi: 10.3390/a15070242.
- [17] P. Sanda Mette, E. Arriyanti, S. Lailiyah, S. Widya Cipta Dharma, J. No, and K. Timur, "Penerapan Algoritma *Levenshtein Distance* Untuk Pengecekan Kemiripan Judul Skripsi di STMIK Widya Cipta Dharma," *Jurnal Nasional Komputasi dan Teknologi Informasi (JNKTI)*, vol. 8, no. 3, 2025.
- [18] B. Young, T. Faris, and L. Armogida, "*Levenshtein Distance* as a measure of *accuracy* and precision in forensic PCR-MPS methods," *Forensic Sci. Int. Genet.*, vol. 55, Nov. 2021, doi: 10.1016/j.fsigen.2021.102594.
- [19] J. Mugaanyi, L. Cai, S. Cheng, C. Lu, and J. Huang, "Evaluation of Large Language Model Performance and Reliability for Citations and References

- in Scholarly Writing: Cross-Disciplinary Study,” *J. Med. Internet Res.*, vol. 26, no. 1, Jan. 2024, doi: 10.2196/52935.
- [20] E. S. Barry, J. Merkebu, and L. Varpio, “State-of-the-art literature review methodology: A six-step approach for knowledge synthesis,” *Perspect. Med. Educ.*, vol. 11, no. 5, pp. 281–288, Oct. 2022, doi: 10.1007/s40037-022-00725-9.
 - [21] K. Ji, Z. Wu, J. Han, G. Zhai, and J. Liu, “Evaluating ChatGPT-4’s performance on oral and maxillofacial queries: *Chain-of-Thought* and standard method,” *Frontiers in Oral Health*, vol. 6, 2025, doi: 10.3389/froh.2025.1541976.
 - [22] S. Kim *et al.*, “The COT COLLECTION: Improving Zero-shot and Few-shot Learning of Language Models via *Chain-of-Thought* Fine-Tuning,” 1270. [Online]. Available: <https://github.com/kaistAI/>
 - [23] B. Ji, H. Liu, M. Du, and S.-K. Ng, “*Chain-of-Thought* Improves Text Generation with Citations in Large Language Models,” 2024. [Online]. Available: <https://www.bing.com/new>
 - [24] R. N. Suharto, M. H. Z. Al Faroby, and Y. Setiawan, “Comparative Evaluation of YOLO-based Models for Indonesian License Plate Detection and Recognition with EASY OCR,” in *Procedia Computer Science*, Elsevier B.V., 2025, pp. 943–952. doi: 10.1016/j.procs.2025.09.037.
 - [25] T. Wolf *et al.*, “Transformers: State-of-the-Art Natural Language Processing,” 2020. [Online]. Available: <https://github.com/huggingface/>
 - [26] A. Mohammed and R. Kora, “A Comprehensive Overview and Analysis of Large Language Models: Trends and Challenges,” 2025, *Institute of Electrical and Electronics Engineers Inc.* doi: 10.1109/ACCESS.2025.3573955.
 - [27] A. Håkansson and G. Phillips-Wren, “Generative AI and Large Language Models - Benefits, Drawbacks, Future and Recommendations,” in *Procedia Computer Science*, Elsevier B.V., 2024, pp. 5458–5468. doi: 10.1016/j.procs.2024.09.689.
 - [28] L. Ouyang *et al.*, “Training language models to follow instructions with human feedback,” Mar. 2022, [Online]. Available: <http://arxiv.org/abs/2203.02155>
 - [29] M. Alawida, S. Mejri, A. Mehmood, B. Chikhaoui, and O. Isaac Abiodun, “A Comprehensive Study of ChatGPT: Advancements, Limitations, and Ethical

- Considerations in Natural Language Processing and Cybersecurity,” Aug. 01, 2023, *Multidisciplinary Digital Publishing Institute (MDPI)*. doi: 10.3390/info14080462.
- [30] OpenAI, “GPT-4o mini: Advancing Cost-Efficient Intelligence,” OpenAI. Accessed: Jul. 12, 2026. [Online]. Available: <https://openai.com/index/gpt-4o-mini-advancing-cost-efficient-intelligence/>
 - [31] OpenAI *et al.*, “GPT-4o System Card,” Oct. 2024, [Online]. Available: <http://arxiv.org/abs/2410.21276>
 - [32] N. Favero, F. Salute, and D. Hardt, “Advancing Academic Chatbots: Evaluation of Non Traditional Outputs,” Nov. 2025, [Online]. Available: <http://arxiv.org/abs/2512.00991>
 - [33] M. Thelwall, “In which fields do ChatGPT scores align better than citations with research quality?” [Online]. Available: <https://orcid.org/0000-0001-6065-205X>
 - [34] T. B. Brown *et al.*, “Language Models are Few-Shot Learners,” Jul. 2020, [Online]. Available: <http://arxiv.org/abs/2005.14165>
 - [35] J. Wei *et al.*, “*Chain-of-Thought* Prompting Elicits Reasoning in Large Language Models,” Jan. 2023, [Online]. Available: <http://arxiv.org/abs/2201.11903>
 - [36] L. Reynolds and K. McDonell, “*Prompt* Programming for Large Language Models: Beyond the Few-Shot Paradigm,” Feb. 2021, [Online]. Available: <http://arxiv.org/abs/2102.07350>
 - [37] T. Kojima, S. S. Gu, M. Reid, Y. Matsuo, and Y. Iwasawa, “Large Language Models are Zero-Shot Reasoners,” Jan. 2023, [Online]. Available: <http://arxiv.org/abs/2205.11916>
 - [38] Z. Jia, S. Geng, Y. Zhao, and H. Zhang, “Comprehensive Survey on Prompts Generating via Knowledge-Guided *Chain-of-Thought*,” *International Journal of Crowd Science*, vol. 9, no. 4, pp. 251–261, Nov. 2025, doi: 10.26599/IJCS.2024.9100038.
 - [39] T. Kocmi *et al.*, “Findings of the 2022 Conference on Machine Translation (WMT22),” in *Proceedings of the Seventh Conference on Machine Translation (WMT)*, Stroudsburg, PA, USA: Association for Computational Linguistics, 2022, pp. 1–45. doi: 10.18653/v1/2022.wmt-1.1.

- [40] Takumu, “IndoMMLU: Indonesian Dataset for LLM Evaluation,” AI-SCHOLAR.
- [41] W. Li, L. Li, T. Xiang, X. Liu, W. Deng, and N. Garcia, “Can multiple-choice questions really be *useful* in detecting the abilities of LLMs?,” May 2024, [Online]. Available: <http://arxiv.org/abs/2403.17752>
- [42] S. Xu *et al.*, “Reasoning before Comparison: LLM-Enhanced Semantic *Similarity* Metrics for Domain Specialized Text Analysis,” Feb. 2024, [Online]. Available: <http://arxiv.org/abs/2402.11398>
- [43] P. L. Teh and C. F. Uwasomba, “Impact of Large Language Models on Scholarly Publication Titles and Abstracts: A Comparative Analysis,” *Journal of Social Computing*, vol. 5, no. 2, pp. 105–121, 2024, doi: 10.23919/JSC.2024.0011.

DAFTAR LAMPIRAN

Lampiran 1. Berita Acara Seminar Proposal Skripsi



KEMENTERIAN PENDIDIKAN TINGGI,
SAINS DAN TEKNOLOGI

POLITEKNIK NEGERI LHOKEUMAWE
JURUSAN TEKNOLOGI INFORMASI DAN KOMPUTER

Jalan Banda Aceh-Medan Km. 280,3 Buketrata, Lhokseumawe, 24301 PO.BOX 90
Telepon: (0645) 42670, 42785 Fax: 42785
Laman: www.pnl.ac.id

BERITA ACARA

SEMINAR PROPOSAL SKRIPSI

Pada hari ini Tanggal **Tiga Belas Bulan Dua Tahun Dua Ribu Dua Puluh Enam**, kami yang bertanda tangan dibawah ini, Pembahas dan Pembimbing Skripsi telah melaksanakan seminar proposal Skripsi seorang Mahasiswa/i, Program Studi **Teknik Informatika Jurusan Teknologi Informasi dan Komputer Politeknik Negeri Lhokseumawe** yang tersebut dibawah ini :

Nama : Elvira Gladys Samsul
NIM : 2022573010010
Program Studi : Teknik Informatika
Judul Proposal : Rancang Bangun Aplikasi Pengujian Akurasi ChatGPT
Menggunakan Metode Chain-Of-Thought Berbasis
Algoritma Levenshtein Distance pada Dataset IndoMMLU

Berdasarkan hasil dan catatan dari yang tertampil Bersama berita acara ini serta mengingat sumpah jabatan Tim Pembahas seminar proposal Skripsi, dengan ini proposal Mahasiswa/i tersebut dinyatakan :

DITERIMA / ~~DITOLAK~~

Demikian Berita Acara ini dibuat dengan sebenar-benarnya.

Buketrata, 13 Februari 2026

An. Tim Pembahas
Ketua Seminar,

Muhammad Arhami S.Si., M.Kom
NIP. 19741029 200003 1 001



KEMENTERIAN PENDIDIKAN TINGGI,
SAINS DAN TEKNOLOGI


POLITEKNIK NEGERI LHOKEUMAWE
JURUSAN TEKNOLOGI INFORMASI DAN KOMPUTER

Jalan Banda Aceh-Medan Km. 280,3 Buketrata, Lhokseumawe, 24301 PO.BOX 90
Telepon: (0645) 42670, 42785 Fax: 42785
Laman: www.pnl.ac.id

DAFTAR HADIR

SEMINAR PROPOSAL SKRIPSI

Nama : Elvira Gladys Samsul
NIM : 2022573010010
Program Studi : Teknik Informatika
Pembimbing 1 : Muhammad Arhami, S.Si., M.Kom
Pembimbing 2 : Muhammad Rizka, SST., M.Kom
Judul Proposal : Rancang Bangun Aplikasi Pengujian Akurasi ChatGPT
Menggunakan Metode Chain-Of-Thought Berbasis
Algoritma Levenshtein Distance pada Dataset IndoMMLU

No.	Jabatan	Nama	NIP	Tanda Tangan
1	Ketua Seminar	Muhammad Arhami, S.Si., M.Kom	19741029 200003 1 001	
2	Sekretaris Seminar	Muhammad Rizka, SST., M.Kom	19881009 201504 1 001	
3	Pembahas 1	Mahdi, S.T., M.Cs	19700802 199903 1 001	
4	Pembahas 2	Muhammad Reza Zulman, S.S.T., M.Sc	19920501 202203 1 005	
5	Penyaji	Elvira Gladys Samsul	2022573010010	

Buketrata, 13 Februari 2026
Ketua Program Studi

M. Khadafi, ST., MT
NIP. 197507182002121004



KEMENTERIAN PENDIDIKAN TINGGI,
SAINS, DAN TEKNOLOGI

POLITEKNIK NEGERI LHOKSEUMAWE
JURUSAN TEKNOLOGI INFORMASI DAN KOMPUTER

Jalan Banda Aceh-Medan Km. 280,3 Buketrata, Lhokseumawe, 24301 PO.BOX 90

Telepon: (0645) 42670, 42785 Fax: 42785

Laman: www.pnl.ac.id

FORM PERBAIKAN SEMINAR PROPOSAL
SKRIPSI

Nama : Elvira Gladys Samsul
NIM : 2022573010010
Program Studi : Teknik Informatika
Pembimbing 1 : Muhammad Arhami, S.Si., M.Kom
Pembimbing 2 : Muhammad Rizka, SST., M.Kom
Judul Proposal : Rancang Bangun Aplikasi Pengujian Akurasi ChatGPT
Menggunakan Metode Chain-Of-Thought Berbasis
Algoritma Levenshtein Distance pada Dataset IndoMMLU

DITERIMA / DITOLAK

REVISI

- Saran Pakar Soal Easy
- Pakar Soal Multiple Choice
- di kuis bukan A, B, C
tapi marak jawaban

Buketrata, 13 Februari 2026

Pembahas 1

Mahdi. S.T. M.Cs

NIP. 19700802 199903 1 001



KEMENTERIAN PENDIDIKAN TINGGI,
SAINS, DAN TEKNOLOGI

POLITEKNIK NEGERI LHOKSEUMAWE
JURUSAN TEKNOLOGI INFORMASI DAN KOMPUTER

Jalan Banda Aceh-Medan Km. 280,3 Buketrata, Lhokseumawe, 24301 PO.BOX 90
Telepon: (0645) 42670, 42785 Fax: 42785
Laman: www.pnl.ac.id

FORM PERBAIKAN SEMINAR PROPOSAL
SKRIPSI

Nama : Elvira Gladys Samsul
NIM : 2022573010010
Program Studi : Teknik Informatika
Pembimbing 1 : Muhammad Arhami, S.Si., M.Kom
Pembimbing 2 : Muhammad Rizka, SST., M.Kom
Judul Proposal : Rancang Bangun Aplikasi Pengujian Akurasi ChatGPT
Menggunakan Metode Chain-Of-Thought Berbasis
Algoritma Levenshtein Distance pada Dataset IndoMMLU

DITERIMA / DITOLAK

REVISI

* Perimbangan untuk menggunakan
soal dalam prompt lagi.

Buketrata, 13 Februari 2026

Pembahas 2

Muhammad Reza Zulman, S.S.T., M.Sc
NIP. 19920501 202203 1 005