

PROPOSAL PENELITIAN SKRIPSI

RANCANG BANGUN APLIKASI *POINT OF SALE* DENGAN FITUR PREDIKSI PENJUALAN HARIAN MENGUNAKAN METODE *LONG SHORT-TERM MEMORY* (LSTM)



Disusun oleh:

MUHAMMAD KHOLIS

2022573010098

**TEKNOLOGI INFORMASI KOMPUTER
TEKNIK INFORMATIKA
POLITEKNIK NEGERI LHOKSEUMAWE
TAHUN 2026**

HALAMAN PERSETUJUAN

RANCANG BANGUN APLIKASI POINT OF SALE DENGAN FITUR PREDIKSI PENJUALAN HARIAN MENGGUNAKAN METODE LONG SHORT-TERM MEMORY (LSTM)

Dipersiapkan dan Disusun oleh

MUHAMMAD KHOLIS

2022573010098

Telah disetujui oleh Tim Dosen Pembimbing Penelitian Skripsi
pada tanggal 10 Juni 2026

Mengetahui:
Ketua Prodi Teknik Informatika



M. Khadafi, S.T., M.T
NIP. 197507182002121004

Buketrata, 12 Mei 2026
Ketua Pengusul,



Muhammad Kholis
2022573010098

Menyetujui,
Ketua Jurusan Teknologi Informasi & Komputer



Salahuddin, S.T., M.Cs.
NIP. 197404242002121001

DAFTAR ISI

DAFTAR ISI	i
DAFTAR GAMBAR	ii
DAFTAR TABEL	iii
BAB 1 PENDAHULUAN	1
1.1 Latar Belakang Masalah	1
1.2 Rumusan Masalah	3
1.3 Tujuan Penelitian	3
1.4 Batasan Masalah	4
1.5 Manfaat Penelitian	4
1.6 Sistematika Penulisan	5
BAB 2 TINJAUAN PUSTAKA	7
2.1 <i>State Of The Art</i>	7
2.2 Sistem <i>Point of Sale</i> (POS)	12
2.3 Peramalan Penjualan (<i>Forecasting</i>)	12
2.4 Arsitektur <i>Long Short-Term Memory</i> (LSTM)	13
2.5 <i>Framework</i> Flutter dan Bahasa Dart	14
2.6 Layanan Supabase dan Integrasi <i>Cloud</i>	14
2.7 Isar Database (<i>Local Storage</i>)	15
2.8 Python dan TensorFlow	15
BAB 3 METODOLOGI PENELITIAN	17
3.1 Metode Penelitian	17
3.2 Data dan Pengumpulan Data	18
3.3 Variabel Penelitian	18
3.4 Teknik Analisis Data	19
3.5 Alur Penelitian	20
3.6 Rancangan Sistem	21
3.6. <i>Use Case Diagram</i>	21
3.6. <i>Entity Relationship Diagram</i> (ERD)	24
3.6. Perancangan Wireframe	26
3.6. Rancangan Algoritma <i>Long Short-Term Memory</i> (LSTM)	39
3.7 Teknik Pengujian	41
3.7. Rancangan Pengujian Evaluasi Model Prediksi	41
3.7. Rancangan Analisis Pengujian <i>Black Box</i>	43
3.8 Hasil yang Diharapkan	44

DAFTAR GAMBAR

3.1	Alur Penelitian	20
3.2	<i>Use Case Diagram</i> Sistem POS	22
3.3	<i>Entity Relationship Diagram</i> (ERD) Sistem POS	25
3.4	Wireframe Halaman Registrasi Toko Baru	27
3.5	Wireframe Halaman Login	28
3.6	Wireframe Halaman Pemilihan Toko	29
3.7	Wireframe Halaman Dasbor Owner	30
3.8	Wireframe Halaman POS (Pembayaran)	31
3.9	Wireframe Halaman Riwayat Transaksi	32
3.10	Wireframe Halaman Kelola Produk	33
3.11	Wireframe Halaman Kelola Kategori	34
3.12	Wireframe Halaman Laporan	35
3.13	Wireframe Halaman Pengaturan	36
3.14	Wireframe Halaman Informasi Toko	37
3.15	Wireframe Halaman Struk Digital	38
3.16	Wireframe Halaman Katalog Produk	39
3.17	Alur Kerja Algoritma <i>Long Short-Term Memory</i> (LSTM)	40

DAFTAR TABEL

2.1	<i>State Of The Art</i>	8
3.1	Definisi Aktor	23
3.2	Definisi <i>Use Case</i>	23
3.3	Daftar Tabel Basis Data POS	26
3.4	Skenario Pengujian <i>Black Box</i>	43

BAB I

PENDAHULUAN

1.1 Latar Belakang Masalah

Perkembangan teknologi informasi dan komunikasi telah mendorong terjadinya transformasi digital di berbagai sektor bisnis, termasuk dalam pengelolaan transaksi dan operasional penjualan pada usaha mikro, kecil, dan menengah (UMKM). Pratama dan Handayani [9] mencatat bahwa adopsi teknologi kasir digital di Indonesia masih terbatas, di mana minimnya fitur analitik menjadi penyebab utama UMKM gagal mengantisipasi siklus musiman penjualan. Pemanfaatan sistem *Point of Sale* (POS) berbasis aplikasi menjadi salah satu solusi yang banyak digunakan untuk membantu pelaku usaha dalam mencatat transaksi, mengelola stok barang, serta menyusun laporan penjualan secara lebih terstruktur dan efisien [11].

Pada praktiknya, sebagian besar aplikasi *Point of Sale* yang digunakan oleh UMKM masih bersifat deskriptif, yaitu hanya menampilkan data historis penjualan tanpa adanya kemampuan analisis prediktif. Pelaku usaha umumnya harus melakukan perhitungan dan estimasi penjualan secara manual berdasarkan pengalaman atau intuisi, yang berpotensi menimbulkan kesalahan dalam perencanaan stok, penentuan target penjualan, dan pengelolaan arus kas. Ketidakmampuan sistem dalam memprediksi penjualan harian secara akurat dapat menyebabkan berbagai permasalahan, seperti kelebihan stok (*overstock*), kekurangan persediaan (*stockout*), serta tidak optimalnya strategi penjualan yang diterapkan [2].

Perkembangan teknologi kecerdasan buatan, khususnya dalam bidang *deep learning*, membuka peluang untuk menghadirkan fitur prediksi penjualan yang lebih akurat dan adaptif terhadap pola data historis. Salah satu metode *deep learning* yang banyak digunakan dalam analisis data runtun waktu (*time series*) adalah *Long Short-Term Memory* (LSTM). Abbas dkk. [1] membuktikan bahwa LSTM mengungguli model ARIMA konvensional dalam memprediksi data penjualan ritel harian yang

memiliki tingkat fluktuasi non-linier tinggi, dengan penurunan *error* hingga 15%. Wilson dan Davies [14] menjelaskan bahwa mekanisme *forget gate* pada arsitektur LSTM mampu mempertahankan memori pola penjualan jangka panjang, seperti tren musiman akibat periode Ramadan atau Tahun Baru, yang sering menjadi titik kritis bagi operasional UMKM. Choi dan Lee [3] lebih lanjut menunjukkan bahwa penambahan variabel kontekstual seperti jumlah transaksi harian pada model LSTM multivariate dapat meningkatkan akurasi prediksi secara signifikan.

Tantangan infrastruktur menjadi hambatan nyata bagi UMKM di daerah, khususnya koneksi internet yang tidak stabil. Martinez dan Silva [6] menunjukkan bahwa arsitektur *offline-first* menggunakan basis data lokal *embedded* merupakan solusi efektif untuk menjamin kelancaran operasional sistem pada kondisi jaringan yang tidak andal. Novikov dan Petrov [8] membuktikan bahwa Isar DB unggul sebagai basis data lokal pada aplikasi Flutter berkat kecepatan operasi baca dan tulis yang optimal dibandingkan alternatif seperti Hive dan ObjectBox. Untuk mendukung ekosistem *cloud backend* yang andal, Fischer dan Weber [4] mengevaluasi Supabase sebagai platform *Backend-as-a-Service* (BaaS) *open-source* yang menawarkan fitur *Row Level Security* (RLS) dan *real-time subscription* yang sesuai untuk pengelolaan data transaksi multi-tenant UMKM.

Meskipun riset terdahulu telah membuktikan keunggulan masing-masing komponen secara terpisah, belum ada penelitian yang mengintegrasikan keseluruhan komponen tersebut menjadi satu sistem yang utuh. Kumar dan Sharma [5] menyoroti tantangan latensi ketika modul AI di-*deploy* sebagai layanan terpisah yang dipanggil oleh aplikasi klien kasir. Nguyen dan Tran [7] merekomendasikan pemisahan beban kerja transaksional dengan beban kerja analitik melalui arsitektur *microservices* untuk menjamin sistem kasir tidak mengalami gangguan selama proses pelatihan model. Roberts dan Thomas [10] membahas standarisasi pengiriman data dari aplikasi *mobile* ke server AI berbasis REST API, yang menjadi jembatan integrasi antara sistem POS dan modul prediksi.

Berdasarkan permasalahan tersebut, maka diperlukan suatu penelitian yang

merancang dan membangun aplikasi *Point of Sale* berbasis *mobile* Android dengan arsitektur *offline-first* menggunakan *framework* Flutter dan Isar DB, yang secara bersamaan dilengkapi fitur prediksi penjualan harian berbasis metode LSTM yang dieksekusi di sisi server melalui *REST API*. Penelitian ini diharapkan menghasilkan sebuah sistem POS yang sekaligus berfungsi sebagai *Decision Support System* bagi pelaku UMKM di Lhokseumawe dalam mengambil keputusan manajemen stok dan strategi penjualan secara lebih akurat dan berbasis data.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, maka rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana merancang dan membangun aplikasi *Point of Sale* (POS) dengan fitur prediksi penjualan harian berbasis *mobile* yang dapat digunakan oleh pelaku usaha secara efektif?
2. Bagaimana menerapkan metode *Long Short-Term Memory* (LSTM) pada aplikasi *Point of Sale* untuk memprediksi penjualan harian berdasarkan data transaksi historis?
3. Bagaimana tingkat akurasi hasil prediksi penjualan harian yang dihasilkan oleh metode *Long Short-Term Memory* (LSTM) berdasarkan evaluasi menggunakan metrik kesalahan prediksi?

1.3 Tujuan Penelitian

Berdasarkan rumusan masalah yang telah diuraikan, maka tujuan dalam penelitian ini adalah sebagai berikut:

1. Merancang dan membangun aplikasi *Point of Sale* (POS) berbasis *mobile* yang dilengkapi dengan fitur prediksi penjualan harian sebagai alat bantu pengelolaan dan analisis penjualan.
2. Mengimplementasikan metode *Long Short-Term Memory* (LSTM) pada aplikasi *Point of Sale* untuk memprediksi penjualan harian berdasarkan data

transaksi historis.

3. Memanfaatkan data transaksi penjualan harian, seperti jumlah transaksi, total penjualan, dan jumlah produk terjual, sebagai data latih utama dalam model prediksi penjualan berbasis metode LSTM.
4. Mengevaluasi kinerja dan tingkat akurasi metode *Long Short-Term Memory* (LSTM) dalam menghasilkan prediksi penjualan harian menggunakan metrik evaluasi kesalahan prediksi.

1.4 Batasan Masalah

Untuk menghindari meluasnya materi pembahasan, maka penelitian ini dibatasi pada hal-hal berikut:

1. Aplikasi dikembangkan menggunakan *framework* Flutter dan difokuskan untuk sistem operasi Android, mengingat dominasi pasar Android pada segmen UMKM lokal.
2. Basis data yang digunakan adalah Supabase dengan skema relasional untuk menyimpan data produk, transaksi, dan akun pengguna.
3. Algoritma yang digunakan adalah *Long Short-Term Memory* (LSTM) dengan model *univariate* atau *multivariate* terbatas, dan prediksi dilakukan untuk rentang waktu harian.
4. Data uji bersumber dari data transaksi riil UMKM mitra di Lhokseumawe dengan periode minimal satu tahun atau setidaknya mencakup siklus musiman tahunan.
5. Proses pelatihan model dan prediksi dilakukan di sisi *server/cloud* menggunakan bahasa Python, sedangkan aplikasi *mobile* bertugas mengirim data transaksi dan menerima hasil prediksi melalui *REST API*.

1.5 Manfaat Penelitian

Manfaat yang diharapkan dari penelitian ini adalah sebagai berikut:

1. **Bagi Pelaku UMKM:** Memberikan aplikasi *Point of Sale* (POS) berbasis

mobile yang dapat digunakan untuk pencatatan transaksi penjualan dan pengelolaan stok secara digital, serta menyediakan fitur prediksi penjualan harian berbasis algoritma LSTM sebagai alat bantu dalam pengambilan keputusan *restock* dan pengelolaan persediaan barang.

2. **Bagi Akademisi:** Menjadi referensi dan bahan kajian dalam pengembangan penelitian di bidang sistem informasi dan *machine learning*, khususnya penerapan metode LSTM untuk prediksi penjualan harian pada sistem POS berbasis *mobile* di lingkungan UMKM.
3. **Bagi Peneliti:** Menambah pengetahuan dan pengalaman dalam merancang dan membangun aplikasi POS berbasis *mobile* menggunakan *framework* Flutter serta mengimplementasikan algoritma LSTM untuk menyelesaikan permasalahan prediksi penjualan harian berbasis data transaksi UMKM pada studi kasus nyata.

1.6 Sistematika Penulisan

Sistematika penulisan proposal penelitian skripsi ini disusun untuk memberikan gambaran secara menyeluruh mengenai alur pembahasan yang dilakukan. Sistematika penulisan dibagi menjadi tiga bab utama yang saling berkaitan, dengan rincian sebagai berikut:

BAB I PENDAHULUAN

Bab ini menguraikan gambaran umum penelitian yang meliputi latar belakang masalah, rumusan masalah, tujuan penelitian, batasan masalah, manfaat penelitian, serta sistematika penulisan. Bab ini menjadi dasar dalam memahami alasan dan arah penelitian yang dilakukan.

BAB II TINJAUAN PUSTAKA

Bab ini berisi kajian literatur dan landasan teori yang relevan dengan penelitian. Kajian mencakup perbandingan metode peramalan penjualan dan implementasi sistem POS berbasis *mobile*. Landasan teori menyajikan konsep peramalan, arsitektur LSTM, *framework* Flutter, bahasa Dart, serta layanan Supabase yang

digunakan sebagai infrastruktur sistem.

BAB III METODOLOGI PENELITIAN

Bab ini menjelaskan tahapan metodologi penelitian yang dilakukan, meliputi jenis dan pendekatan penelitian, teknik pengumpulan data, teknik analisis data, alur penelitian, rancangan sistem menggunakan UML, teknik pengujian, serta hasil yang diharapkan.

BAB II

TINJAUAN PUSTAKA

2.1 *State Of The Art*

Penelitian terkait prediksi penjualan dan pengembangan sistem *Point of Sale* berbasis *mobile* telah mengalami perkembangan signifikan seiring meningkatnya pemanfaatan teknologi *deep learning* dan komputasi awan. Abbas dkk. [1] dan Zhang dan Liu [15] membuktikan keunggulan LSTM dibandingkan model statistik konvensional maupun arsitektur *Gated Recurrent Unit* (GRU) dalam menangkap pola non-linier pada data penjualan ritel. Choi dan Lee [3] memperluas pendekatan ini dengan menggunakan model multivariate yang menggabungkan variabel kontekstual seperti frekuensi transaksi harian. Di sisi pengembangan sistem, Setiawan dan Nugroho [11] serta Pratama dan Handayani [9] mengembangkan aplikasi POS berbasis Android untuk UMKM, namun keduanya bersifat murni deskriptif tanpa komponen prediksi analitik.

Meskipun demikian, penelitian yang secara spesifik mengintegrasikan modul prediksi penjualan berbasis LSTM langsung ke dalam sistem POS *mobile* yang beroperasi secara *offline-first* untuk konteks UMKM masih sangat terbatas. Ringkasan penelitian terdahulu tersebut disajikan dalam Tabel 2.1.

Tabel 2.1 *State Of The Art*

No	Penulis, Tahun dan Judul Artikel	Metode yang Digunakan	Hasil yang Diperoleh	Persamaan	Perbedaan
1	Abbas dkk. (2021) [1]. <i>Sales Forecasting Using LSTM Networks in Retail Industry.</i>	LSTM, ARIMA	LSTM mengungguli ARIMA pada data penjualan non-linier dengan penurunan <i>error</i> hingga 15%.	Sama-sama menggunakan LSTM untuk prediksi data penjualan berbasis deret waktu.	Model bersifat <i>standalone</i> tanpa integrasi sistem kasir nyata; penelitian ini mengintegrasikan LSTM ke dalam aplikasi POS.
2	Setiawan & Nugroho (2023) [11]. <i>Development of Cross-Platform POS Application using Flutter for SMEs.</i>	Flutter, Firebase	Aplikasi kasir stabil dan mampu mencatat transaksi secara <i>real-time</i> .	Sama-sama mengembangkan aplikasi POS berbasis Android untuk UMKM.	Aplikasi murni deskriptif tanpa fungsi prediksi analitik; penelitian ini menambahkan modul LSTM terintegrasi.
3	Martinez & Silva (2022) [6]. <i>Architecture Design of Offline-First Mobile Application using Local Embedded Database.</i>	<i>Offline-First</i> , SQLite	Data tersinkronisasi aman tanpa tumpang tindih saat kembali <i>online</i> .	Sama-sama menerapkan arsitektur <i>offline-first</i> pada aplikasi <i>mobile</i> .	Tidak menguji volume data besar dan tidak memiliki komponen AI; penelitian ini mengintegrasikan keduanya.

No	Penulis, Tahun dan Judul Artikel	Metode yang Digunakan	Hasil yang Diperoleh	Persamaan	Perbedaan
4	Zhang & Liu (2022) [15]. <i>Comparative Analysis of LSTM and GRU for Time-Series Sales Forecasting.</i>	LSTM, GRU	LSTM memberikan akurasi lebih stabil pada data tren penjualan multi-tahun.	Sama-sama membandingkan model <i>deep learning</i> untuk prediksi deret waktu penjualan.	Memerlukan daya komputasi tinggi; penelitian ini men- <i>deploy</i> model di server <i>cloud</i> terpisah agar tidak membebani perangkat.
5	Fischer & Weber (2024) [4]. <i>Evaluating Open-Source BaaS Platforms: A Case Study on Supabase and PostgreSQL.</i>	Supabase, PostgreSQL	RLS Supabase memangkas waktu pengembangan <i>backend</i> hingga 40%.	Sama-sama menggunakan Supabase sebagai infrastruktur <i>backend cloud</i> .	Belum diuji untuk performa <i>mobile dynamic sync</i> berskala harian; penelitian ini mengujinya dalam konteks UMKM.
6	Choi & Lee (2022) [3]. <i>Multivariate Time-Series Forecasting for Retail Sales Using LSTM with Economic Indicators.</i>	Multivariate LSTM	Akurasi model naik dengan menambahkan variabel kontekstual seperti hari libur.	Sama-sama menggunakan variabel transaksi harian sebagai input model LSTM.	Bergantung pada data eksternal yang sulit diakses pelaku UMKM kecil; penelitian ini menggunakan data transaksi internal saja.

No	Penulis, Tahun dan Judul Artikel	Metode yang Digunakan	Hasil yang Diperoleh	Persamaan	Perbedaan
7	Novikov & Petrov (2023) [8]. <i>Performance Comparison of Local NoSQL Embedded Databases in Flutter: Hive, ObjectBox, and Isar.</i>	Isar DB, Hive, ObjectBox	Isar DB tercepat dalam operasi <i>batch insert</i> transaksi pada perangkat Android.	Sama-sama menggunakan Isar DB sebagai <i>local storage</i> pada aplikasi Flutter.	Belum diintegrasikan ke arsitektur sinkronisasi <i>cloud</i> ; penelitian ini mengintegrasikan keduanya secara penuh.
8	Brown & Green (2021) [2]. <i>Demand Forecasting for Inventory Management in Small Retail Stores Using Neural Networks.</i>	Neural Networks	Mampu memprediksi <i>demand</i> mingguan dengan MAPE 12%.	Sama-sama menghubungkan prediksi penjualan ke manajemen stok barang.	Rentang prediksi mingguan terlalu luas; penelitian ini berfokus pada prediksi harian yang lebih granular.
9	Guntara (2022). Pengembangan Aplikasi POS <i>Mobile Berbasis Cloud Computing</i> untuk UMKM.	Android, Firebase	Meningkatkan fleksibilitas pemantauan bisnis secara <i>real-time</i> .	Sama-sama mengembangkan aplikasi POS berbasis Android untuk UMKM lokal.	Sangat bergantung koneksi internet tanpa dukungan <i>offline-first</i> dan tanpa modul prediksi penjualan.

No	Penulis, Tahun dan Judul Artikel	Metode yang Digunakan	Hasil yang Diperoleh	Persamaan	Perbedaan
10	Penelitian Ini. Rancang Bangun Aplikasi <i>Point of Sale</i> dengan Fitur Prediksi Penjualan Harian Menggunakan Metode LSTM.	LSTM, Flutter, Supabase, Isar DB	Aplikasi POS <i>mobile offline-first</i> terintegrasi dengan prediksi penjualan harian berbasis LSTM untuk UMKM di Lhokseumawe.	–	–

Berdasarkan kajian terhadap penelitian terdahulu pada Tabel 2.1, dapat disimpulkan bahwa sebagian besar penelitian prediksi penjualan menggunakan LSTM masih bersifat *standalone*, yakni tidak terintegrasi dengan sistem pencatatan transaksi yang aktif digunakan. Sebaliknya, penelitian pengembangan sistem POS *mobile* yang ada belum dilengkapi kemampuan analitik prediktif berbasis *machine learning*. Selain itu, belum ada sistem POS untuk UMKM yang secara bersamaan menerapkan arsitektur *offline-first* sekaligus menyertakan modul prediksi LSTM terintegrasi.

Oleh karena itu, penelitian ini hadir untuk mengisi celah tersebut dengan mengusulkan sistem yang menggabungkan ketiga aspek sekaligus, yaitu: (1) aplikasi POS *mobile* berbasis Flutter dengan kemampuan operasional *offline-first* menggunakan Isar DB dan sinkronisasi otomatis ke Supabase [4],[8]; (2) modul prediksi penjualan harian berbasis LSTM yang dilatih dari data transaksi riil mitra UMKM di Lhokseumawe [1],[3],[14]; dan (3) penyajian hasil prediksi secara langsung kepada pengguna melalui dasbor analitik di dalam aplikasi yang sama [10].

2.2 Sistem *Point of Sale* (POS)

Sistem *Point of Sale* (POS) merupakan kombinasi perangkat keras dan perangkat lunak yang digunakan untuk memproses transaksi penjualan pada titik pembelian. Dalam konteks UMKM, sistem POS berfungsi sebagai alat pencatatan transaksi, pengelolaan stok barang, dan pelaporan keuangan yang menggantikan proses manual berbasis buku catatan. Perkembangan teknologi *mobile* telah mendorong lahirnya aplikasi POS berbasis Android yang lebih fleksibel, murah, dan mudah dioperasikan oleh pelaku usaha kecil tanpa keahlian teknis khusus [9],[11].

Sistem POS modern yang dirancang untuk UMKM memerlukan pendekatan yang berbeda dibandingkan sistem ritel skala besar. Fokus utama harus terletak pada kesederhanaan alur kerja kasir, kecepatan proses transaksi, dan kemampuan beroperasi dalam kondisi konektivitas internet yang tidak stabil. Arsitektur *offline-first* menjadi solusi utama untuk memastikan kelancaran operasional, di mana data transaksi disimpan terlebih dahulu secara lokal dan disinkronkan ke *cloud* secara otomatis ketika koneksi tersedia [6].

2.3 Peramalan Penjualan (*Forecasting*)

Peramalan penjualan merupakan proyeksi teknis dari permintaan pelanggan potensial untuk periode waktu tertentu berdasarkan asumsi-asumsi yang ditetapkan. Menurut Heizer dan Render, peramalan yang akurat sangat krusial dalam manajemen operasi karena mempengaruhi keputusan strategis di bidang pemasaran, keuangan, dan sumber daya manusia. Terdapat empat prinsip utama dalam peramalan: peramalan jarang sekali sempurna, peramalan jangka pendek biasanya lebih akurat daripada jangka panjang, peramalan agregat lebih akurat daripada peramalan item individu, dan pemilihan metode harus disesuaikan dengan pola data (horizontal, tren, musiman, atau siklus).

Metode kuantitatif dalam peramalan mengandalkan model matematika untuk memproyeksikan data masa lalu ke masa depan. Dalam konteks ritel, tantangan

utama adalah menangani variasi musiman, yaitu fluktuasi yang berulang dalam jangka waktu kurang dari satu tahun, seperti lonjakan penjualan menjelang hari raya atau awal bulan. Pendekatan berbasis *deep learning*, khususnya LSTM, terbukti lebih unggul dibandingkan metode statistik konvensional seperti ARIMA dalam menangkap pola jangka panjang pada data penjualan harian yang bersifat nonlinier [1],[15]. Evaluasi akurasi model peramalan umumnya menggunakan kombinasi metrik MAE (*Mean Absolute Error*), RMSE (*Root Mean Square Error*), dan MAPE (*Mean Absolute Percentage Error*) secara bersamaan untuk menghindari bias pembacaan akurasi akibat lonjakan data [12]. Brown dan Green [2] menunjukkan bahwa prediksi berbasis jaringan saraf tiruan dapat mencapai MAPE 12% pada data permintaan ritel kecil, sementara penggunaan pendekatan multivariate dapat meningkatkan presisi tersebut lebih jauh [3].

2.4 Arsitektur Long Short-Term Memory (LSTM)

LSTM adalah jenis khusus dari *Recurrent Neural Network* (RNN) yang memiliki kemampuan untuk mempelajari ketergantungan jangka panjang dalam urutan data [1],[14]. Arsitektur LSTM dirancang untuk mengatasi masalah *vanishing gradient* yang menghambat RNN standar dalam memproses informasi yang terpisah jauh dalam satu urutan [14]. Komponen inti dari unit LSTM adalah *cell state* (keadaan sel) yang bertindak sebagai jalur informasi utama, serta tiga gerbang fungsional:

1. **Forget Gate:** Menggunakan fungsi aktivasi sigmoid untuk menentukan bagian informasi dari status sel sebelumnya yang harus dibuang.
2. **Input Gate:** Memutuskan informasi baru mana yang akan diperbarui ke dalam status sel melalui kombinasi fungsi sigmoid dan tanh.
3. **Output Gate:** Menentukan bagian dari status sel yang akan dikeluarkan sebagai *hidden state* untuk langkah waktu berikutnya.

Persamaan matematis untuk pembaruan status sel C_t dapat dinyatakan sebagai

berikut:

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t \quad 2.1$$

Di mana f_t adalah *output* dari *forget gate*, i_t adalah *output* dari *input gate*, dan $\tilde{C}_t$ adalah kandidat nilai baru yang akan ditambahkan ke dalam status sel.

2.5 Framework Flutter dan Bahasa Dart

Flutter merupakan *framework* pengembangan aplikasi *cross-platform* yang dikembangkan oleh Google dan menggunakan mesin grafis Skia untuk merender antarmuka pengguna secara langsung, menghasilkan performa tinggi mendekati aplikasi *native* [11]. Bahasa pemrograman Dart yang menyertai Flutter mendukung fitur *Just-In-Time* (JIT) untuk pengembangan cepat dan *Ahead-Of-Time* (AOT) untuk rilis produksi yang efisien. Arsitektur *widget* pada Flutter memungkinkan pengembang membangun komponen antarmuka yang modular dan dapat digunakan kembali, sangat cocok untuk aplikasi POS yang memiliki banyak elemen interaktif.

Dalam penelitian ini, Flutter dipilih sebagai *framework* utama pengembangan aplikasi *mobile* karena kemampuannya menghasilkan aplikasi Android berkinerja tinggi dari satu basis kode, serta dukungan ekosistem *package* yang kaya untuk integrasi fitur seperti koneksi Bluetooth, pemindaian barcode, dan komunikasi *REST API* [10],[11].

2.6 Layanan Supabase dan Integrasi Cloud

Supabase merupakan platform *Backend-as-a-Service* (BaaS) *open-source* yang menyediakan lapisan infrastruktur matang di atas basis data PostgreSQL [4]. Supabase mencakup fitur autentikasi pengguna, *real-time subscriptions*, penyimpanan file, dan *Row Level Security* (RLS) yang memungkinkan pengelolaan hak akses data secara granular. Fischer dan Weber [4] membuktikan bahwa penggunaan RLS pada Supabase dapat memangkas waktu pengembangan *backend* hingga 40% sekaligus mengamankan data transaksi multi-tenant. Fitur

real-time subscriptions pada Supabase memungkinkan aplikasi *mobile* menerima pembaruan data secara instan tanpa perlu melakukan *polling* ke server.

Penggunaan Supabase dalam penelitian ini memfasilitasi penyimpanan data transaksi dalam jumlah besar yang nantinya akan ditarik oleh modul Python di server untuk proses pelatihan model AI. Supabase juga menangani autentikasi multi-pengguna (Owner dan Kasir) dengan mekanisme *Role-Based Access Control* (RBAC) yang terimplementasi langsung di lapisan basis data, memastikan privasi data antar-merchant terjaga [13].

2.7 Isar Database (*Local Storage*)

Isar DB adalah basis data *embedded* berkinerja tinggi yang dirancang khusus untuk Flutter dan mendukung operasi baca/tulis secara *asynchronous* tanpa memerlukan koneksi internet. Novikov dan Petrov [8] membuktikan bahwa Isar DB memiliki kecepatan *batch insert* dan pembacaan data sekuensial yang paling optimal dibandingkan basis data lokal lain yang umum digunakan pada Flutter, yakni Hive dan ObjectBox. Isar DB beroperasi langsung di perangkat pengguna menggunakan format penyimpanan *binary* yang dioptimalkan untuk kecepatan tinggi, serta mendukung kueri kompleks dengan antarmuka yang intuitif.

Dalam penelitian ini, Isar DB berperan sebagai penyimpanan lokal utama pada perangkat *mobile* untuk menjamin kelancaran operasional kasir dalam kondisi *offline* [6],[8]. Seluruh transaksi yang dilakukan tanpa koneksi akan disimpan terlebih dahulu di Isar DB, kemudian disinkronkan secara otomatis ke Supabase oleh mesin `SyncNotifier` ketika koneksi internet tersedia kembali.

2.8 Python dan TensorFlow

Python dipilih sebagai bahasa pemrograman untuk pengembangan modul prediksi di sisi server (*server-side*) karena ekosistemnya yang kaya dalam bidang *machine learning* dan analisis data. TensorFlow dengan antarmuka tingkat tinggi Keras digunakan untuk membangun, melatih, dan menyimpan model LSTM

[1],[14]. Proses pelatihan model dilakukan di server menggunakan data transaksi yang ditarik dari Supabase, kemudian model yang telah terlatih di-*deploy* sebagai layanan prediksi yang dapat dipanggil oleh aplikasi *mobile* melalui *REST API* [10], sehingga proses komputasi berat tidak membebani perangkat pengguna. Nguyen dan Tran [7] merekomendasikan pendekatan ini dalam arsitektur *microservices* untuk memastikan sistem kasir tetap stabil meskipun modul AI sedang melakukan proses pelatihan ulang di sisi server.

BAB III

METODOLOGI PENELITIAN

Metodologi penelitian ini menguraikan kerangka kerja pengembangan sistem yang sistematis, mencakup jenis penelitian, teknik pengumpulan dan analisis data, alur penelitian, rancangan sistem, serta rencana pengujian. Seluruh tahapan dirancang untuk membangun aplikasi *Point of Sale (POS) mobile* yang dilengkapi dengan fitur prediksi penjualan harian berbasis algoritma *Long Short-Term Memory (LSTM)*.

3.1 Metode Penelitian

Penelitian ini merupakan jenis penelitian pengembangan (*Research and Development*) dengan pendekatan kuantitatif untuk pengujian model prediksi dan kualitatif untuk analisis kebutuhan pengguna. Model pengembangan yang digunakan adalah *Waterfall*, yang terdiri dari lima tahap utama:

1. **Analisis Kebutuhan:** Mengidentifikasi fitur utama POS (kasir, stok, laporan) berdasarkan observasi dan wawancara dengan mitra UMKM, serta menentukan spesifikasi data yang diperlukan untuk pelatihan model LSTM.
2. **Desain Sistem:** Membuat arsitektur sistem *offline-first*, skema basis data PostgreSQL di Supabase dan Isar DB lokal, serta rancangan antarmuka pengguna (UI/UX) berbasis komponen Shadcn UI.
3. **Implementasi:** Melakukan pengkodean *frontend* menggunakan *framework* Flutter dan bahasa Dart, integrasi *backend* dengan Supabase, serta pengembangan modul AI prediksi penjualan menggunakan Python dan TensorFlow di sisi server (VPS).
4. **Pengujian:** Melakukan uji coba fungsional menggunakan *Black Box Testing* untuk validasi fitur POS dan uji akurasi model LSTM menggunakan data transaksi historis mitra UMKM.
5. **Pemeliharaan:** Melakukan optimasi parameter model berdasarkan umpan

balik penggunaan nyata dan sinkronisasi data berkelanjutan antara aplikasi *mobile* dan server *cloud*.

3.2 Data dan Pengumpulan Data

Data utama yang digunakan dalam penelitian ini adalah data transaksi penjualan harian dari mitra UMKM di Lhokseumawe dengan periode minimal satu tahun. Data mencakup tanggal transaksi, total nilai penjualan harian (nominal rupiah), jumlah transaksi per hari, dan jumlah produk terjual per hari. Data tersebut bersifat kuantitatif dan berbentuk deret waktu (*time series*) yang akan digunakan sebagai masukan model prediksi LSTM.

Data dikumpulkan melalui tiga saluran utama:

1. **Observasi dan Wawancara:** Dilakukan pada pemilik UMKM mitra di Lhokseumawe untuk memahami proses bisnis, alur transaksi harian, dan kendala manajemen stok yang selama ini dihadapi.
2. **Dokumentasi Transaksi:** Mengambil data sejarah penjualan harian (tanggal, produk, jumlah, total) dari catatan manual atau sistem lama milik mitra UMKM sebagai data latih awal model prediksi.
3. **Studi Pustaka:** Mengkaji referensi jurnal ilmiah, buku manajemen operasi (Heizer & Render), serta dokumentasi teknis *framework* Flutter, TensorFlow LSTM, dan layanan Supabase sebagai landasan implementasi.

3.3 Variabel Penelitian

Variabel penelitian yang digunakan dalam proses prediksi penjualan harian pada sistem POS adalah sebagai berikut:

1. **Variabel Input (Fitur):** Data transaksi penjualan harian yang mencakup total nilai transaksi harian (nominal rupiah), jumlah transaksi per hari, dan jumlah produk terjual per hari selama periode minimal satu tahun dari mitra UMKM di Lhokseumawe.
2. **Variabel Output (Target):** Nilai prediksi total penjualan harian untuk hari

berikutnya, yang digunakan sebagai dasar pengambilan keputusan manajemen stok dan strategi promosi usaha.

3. **Variabel Evaluasi:** Kinerja model diukur menggunakan tiga metrik evaluasi, yaitu MAE (*Mean Absolute Error*), RMSE (*Root Mean Square Error*), dan MAPE (*Mean Absolute Percentage Error*).


3.4 Teknik Analisis Data

Data transaksi yang terkumpul melalui aplikasi POS diproses melalui tahapan berikut sebelum digunakan untuk prediksi penjualan:

1. **Pembersihan Data (*Data Cleaning*):** Menghapus data duplikat, mengisi nilai yang kosong menggunakan teknik interpolasi linier, dan menyelaraskan format tanggal agar data deret waktu bersifat kontinu dan konsisten.
2. **Normalisasi:** Mengubah nilai volume penjualan harian ke dalam skala 0 hingga 1 menggunakan *MinMaxScaler* untuk menstabilkan proses pelatihan jaringan saraf tiruan dan mempercepat konvergensi model.
3. **Pembentukan Struktur *Time Series* (*Windowing*):** Mengubah data sekuensial menjadi format input (X) dan label (y) dengan panjang jendela *sliding window* tertentu, misalnya data 14 hari sebelumnya digunakan untuk memprediksi penjualan hari berikutnya.
4. **Pembagian Data (*Time-Based Split*):** Membagi dataset menjadi data latih dan data uji menggunakan metode pemisahan berbasis waktu untuk menjaga urutan temporal dan mencegah kebocoran data.
5. **Pelatihan Model:** Melatih arsitektur LSTM di sisi server menggunakan Adam Optimizer dan fungsi aktivasi ReLU pada lapisan tersembunyi untuk membangun model prediksi penjualan harian.
6. **Denormalisasi:** Mengembalikan nilai prediksi ke satuan aslinya untuk ditampilkan pada antarmuka aplikasi *mobile* secara mudah dipahami pengguna.

3.5 Alur Penelitian

Alur penelitian ini dirancang secara sistematis untuk membangun sistem *Point of Sale* (POS) berbasis *mobile* yang dilengkapi fitur prediksi penjualan harian menggunakan metode LSTM. Sebagaimana diilustrasikan pada Gambar 3.1, tahapan penelitian dibagi menjadi dua fase utama yang saling berkaitan.



Gambar 3.1 Alur Penelitian

Pada **Fase Pengembangan dan Implementasi Sistem POS**, penelitian diawali dengan analisis kebutuhan melalui observasi langsung dan identifikasi permasalahan pada mitra UMKM di Lhokseumawe. Selanjutnya dilakukan perancangan sistem meliputi arsitektur *offline-first*, desain basis data relasional (Supabase PostgreSQL dan Isar DB), serta perancangan *Use Case Diagram*, *Activity Diagram*, ERD, dan antarmuka pengguna. Setelah tahap perancangan, sistem POS dikembangkan menggunakan Flutter sebagai *frontend*, Supabase sebagai basis data *cloud*, Isar DB sebagai basis data lokal, dan Python di VPS untuk pengolahan model AI. Aplikasi yang telah dibangun kemudian diimplementasikan pada mitra UMKM untuk digunakan dalam kegiatan transaksi harian, sehingga menghasilkan data transaksi aktual yang tersimpan secara otomatis.

Pada **Fase Pengembangan Model Prediksi Penjualan**, data transaksi yang


telah terkumpul selanjutnya melalui tahap pra-pemrosesan meliputi pembersihan data, agregasi harian, normalisasi, dan pembentukan data deret waktu (*time series*). Dataset kemudian dibagi menjadi data latih dan data uji. Model LSTM dilatih menggunakan data latih untuk mempelajari pola penjualan jangka pendek maupun jangka panjang. Setelah pelatihan, model diuji dan diintegrasikan kembali ke dalam sistem POS sehingga aplikasi mampu menampilkan hasil prediksi penjualan harian kepada pengguna melalui REST API.

3.6 Rancangan Sistem

Perancangan sistem dalam penelitian ini dilakukan menggunakan *Unified Modeling Language* (UML) untuk memberikan gambaran yang jelas dan terstruktur mengenai alur proses dan interaksi pengguna dengan sistem POS. Pemodelan sistem direpresentasikan melalui *Use Case Diagram*, *Activity Diagram*, serta *Entity Relationship Diagram* (ERD).

3.6.1 *Use Case Diagram*

Sistem POS melibatkan dua aktor utama, yaitu **Owner (Pemilik Toko)** dan **Kasir (Karyawan)**. *Use Case Diagram* menggambarkan fungsi-fungsi yang dapat diakses oleh masing-masing aktor. Rancangan *use case* diilustrasikan pada Gambar 3.2.



Gambar 3.2 *Use Case Diagram* Sistem POS

1. Definisi Aktor

Definisi aktor pada sistem POS diilustrasikan pada Tabel 3.1 berikut:

Tabel 3.1 Definisi Aktor

No.	Aktor	Deskripsi
1	Owner (Pemilik)	Aktor dengan hak akses penuh terhadap seluruh sistem, mencakup pengelolaan produk, laporan keuangan, manajemen staf, pengaturan toko, serta fitur <i>AI Smart Analytics</i> untuk proyeksi penjualan berbasis kecerdasan buatan.
2	Kasir (Karyawan)	Staf operasional harian dengan akses terbatas pada modul POS, pencatatan transaksi, dan ringkasan omzet harian shift berjalan.

2. Definisi Use Case

Definisi *use case* pada sistem POS diilustrasikan pada Tabel 3.2 berikut:

Tabel 3.2 Definisi Use Case


No.	Use Case	Deskripsi
1	Registrasi Toko Baru	Mendaftarkan akun toko baru saat inisialisasi awal sistem (Owner).
2	Login Akun	Autentikasi pengguna menggunakan email dan kata sandi via Supabase Auth.
3	Melakukan <i>Checkout</i>	Memasukkan produk ke keranjang dan memproses transaksi pembayaran.
4	Menerapkan Voucher/Diskon	Memasukkan kode promosi untuk memotong total tagihan transaksi.
5	Mencetak Struk	Mencetak struk transaksi fisik via printer <i>thermal</i> Bluetooth.
6	Mengelola Katalog Produk	Menambah, menyunting, dan menghapus produk/stok barang (Owner).
7	Mengelola Kategori	Mengatur pengelompokan menu katalog produk toko (Owner).
8	Mengaudit Riwayat Stok	Melihat log mutasi stok untuk keperluan audit inventaris (Owner).

9	Melihat <i>Dashboard</i>	Memantau performa keuangan; kasir dibatasi pada data hari berjalan.
10	Melihat AI <i>Smart Analytics</i>	Mengakses proyeksi penjualan berbasis Model LSTM (Owner).
11	Kirim <i>Broadcast</i> Notifikasi	Mengirim pemberitahuan <i>real-time</i> ke semua kasir (Owner).
12	Sinkronisasi Data	Menyinkronkan transaksi <i>offline</i> lokal ke cloud Supabase otomatis.
13	Mengelola Karyawan	Mendaftarkan atau mengubah peran staf kasir (Owner).
14	Mengatur Profil Toko	Mengubah nama toko, alamat, dan logo outlet (Owner).

3.6.2 Entity Relationship Diagram (ERD)

Basis data sistem POS dirancang secara hibrida menggunakan Supabase PostgreSQL untuk penyimpanan *cloud* dan Isar DB untuk penyimpanan lokal di perangkat *mobile*. Skema basis data *cloud* terdiri dari delapan entitas utama yang saling berelasi sebagaimana diilustrasikan pada Gambar 3.3.

Entity Relationship Diagram — Parzello POS



Gambar 3.3 Entity Relationship Diagram (ERD) Sistem POS

Entitas *stores* menjadi entitas induk yang berelasi dengan seluruh entitas lainnya. Entitas *store_members* mengelola hak akses berbasis peran (*Role-Based Access Control/RBAC*) untuk Owner dan Kasir. Katalog produk dikelola melalui entitas *products* dan *categories*, sedangkan data transaksi disimpan pada entitas *transactions* dan *transaction_items*. Riwayat perubahan stok dicatat pada entitas *stock_histories*, sementara entitas *notifications* mendukung sistem notifikasi. Daftar seluruh tabel basis data yang digunakan dirangkum pada Tabel 3.3.

Tabel 3.3 Daftar Tabel Basis Data POS

No.	Nama Tabel	Deskripsi
1	<i>stores</i>	Menyimpan data identitas dan konfigurasi outlet toko merchant.
2	<i>store_members</i>	Mengelola hak akses dan peran staf (Owner/Kasir) pada setiap toko.
3	<i>categories</i>	Menyimpan kategori pengelompokan produk atau menu dagangan.
4	<i>products</i>	Menyimpan katalog produk beserta harga, stok, dan data SKU/barcode.
5	<i>transactions</i>	Menyimpan data nota transaksi penjualan kasir sebagai tabel induk.
6	<i>transaction_items</i>	Menyimpan rincian produk yang dibeli dalam setiap transaksi.
7	<i>stock_histories</i>	Mencatat log audit perubahan stok masuk dan keluar produk.
8	<i>notifications</i>	Menyimpan pesan notifikasi sistem dan <i>broadcast</i> Owner ke staf.

3.6.3 Perancangan Wireframe

Perancangan wireframe dalam penelitian ini mencakup rancangan antarmuka pengguna untuk semua layar utama yang menjadi bagian dari alur operasional aplikasi POS. Wireframe dirancang dengan mempertimbangkan kebutuhan pengguna, aksesibilitas, dan alur kerja yang efisien. Terdapat 13 rancangan layar

yang melayani kebutuhan berbeda sesuai dengan peran pengguna, sebagaimana diuraikan berikut ini.

1. Halaman Registrasi Toko Baru

Halaman pendaftaran akun dan toko baru yang digunakan saat inisialisasi awal sistem oleh Owner, mencakup pengisian data identitas pengguna dan informasi outlet toko.

← ID ▾

Buat Akun

Lengkapi data di bawah ini untuk mendaftar.

Nama Lengkap

Masukkan nama lengkap

Email

Masukkan email

Password

Masukkan password

Konfirmasi Password

Ulangi password

Daftar

ATAU

Lanjutkan dengan Google

Sudah punya akun? **Masuk**

Gambar 3.4 Wireframe Halaman Registrasi Toko Baru

2. Halaman Login

Halaman masuk akun untuk Owner maupun Kasir dengan autentikasi berbasis email dan kata sandi melalui Supabase Auth.

Selamat Datang Kembali

Masukkan email dan password untuk masuk ke dashboard POS.

Email

Masukkan email Anda

Password

Masukkan kata sandi Anda

☐ Ingat saya [Lupa password?](#)

Masuk


ATAU

 Lanjutkan dengan Google

Gambar 3.5 Wireframe Halaman Login

3. Halaman Pemilihan Toko


Memungkinkan pengguna yang telah login untuk memilih toko aktif yang akan dioperasikan, terutama bagi pengguna yang terdaftar di lebih dari satu outlet.



Gambar 3.6 Wireframe Halaman Pemilihan Toko

4. Halaman Dasbor Owner

Ringkasan performa toko yang menampilkan statistik penjualan harian, grafik tren omzet, pintasan fitur penting, dan akses cepat ke modul utama khusus Owner.



Gambar 3.7 Wireframe Halaman Dasbor Owner

5. Halaman POS (Pembayaran)

Layar utama kasir untuk mencari produk, menyusun keranjang pesanan, menerapkan voucher diskon, memilih metode pembayaran, dan memproses transaksi.

< **Pembayaran**

TOTAL TAGIHAN
Rp 25.000

Metode Pembayaran


Tunai


QRIS

Uang Tunai Diterima

Rp 25000

Rp 25 rb Rp 50 rb Rp 100 rb


KEMBALIAN
Rp 0 

Konfirmasi & Simpan Transaksi

Gambar 3.8 Wireframe Halaman POS (Pembayaran)

6. Halaman Riwayat Transaksi

Menampilkan daftar transaksi yang telah dilakukan lengkap dengan fitur pencarian dan filter berdasarkan tanggal, berguna untuk keperluan verifikasi dan audit oleh semua staf toko.



Gambar 3.9 Wireframe Halaman Riwayat Transaksi

7. Halaman Kelola Produk

Memungkinkan Owner untuk menambah, menyunting, dan menghapus produk yang dijual, lengkap dengan harga, stok, SKU/barcode, gambar produk, dan kategori.

← Tambah Produk

Tambah Foto

Maksimal ukuran foto 5MB. Format JPG, PNG.

Nama Produk

Masukkan nama produk

Kategori

Pilih kategori

SKU / Barcode

Contoh: PRD-001

Harga Modal

Rp 0

Harga Jual

Rp 0

Stok Awal


0

Simpan Produk

Gambar 3.10 Wireframe Halaman Kelola Produk

8. Halaman Kelola Kategori


Memungkinkan Owner untuk membuat, mengedit, dan menghapus kategori produk guna mengorganisasi katalog dagangan toko dengan lebih terstruktur.



Gambar 3.11 Wireframe Halaman Kelola Kategori

9. Halaman Laporan


Layar khusus Owner yang menampilkan laporan penjualan, tren bisnis, proyeksi penjualan harian berbasis model LSTM, dan ringkasan performa operasional toko.



Gambar 3.12 Wireframe Halaman Laporan

10. Halaman Pengaturan

Pusat konfigurasi aplikasi dan toko yang dapat diakses oleh semua staf, dengan sejumlah menu yang hanya tersedia bagi Owner seperti pengaturan profil toko dan integrasi pembayaran.



Gambar 3.13 Wireframe Halaman Pengaturan

11. Halaman Informasi Toko

Memungkinkan Owner untuk mengubah nama toko, alamat, logo outlet, dan informasi operasional lainnya yang ditampilkan kepada pelanggan.

Gambar 3.14 Wireframe Halaman Informasi Toko

12. Halaman Struk Digital

Menampilkan pratinjau struk transaksi dalam format digital yang dapat dibagikan kepada pelanggan, mencakup rincian produk, total pembayaran, dan informasi toko.

<
Struk Digital

Parzello Tech
Telp: 085161787501
Terima Kasih Telah Berbelanja

No. Transaksi	#2E17EDFD
Tanggal	10 Jun 2026, 03:00
Metode	Tunai
Burger Daging + Telur 1 x Rp 15.000	Rp 15.000
Burger Sosis + Telur 1 x Rp 10.000	Rp 10.000
Total Belanja	Rp 25.000
Bayar	Rp 25.000
KEMBALIAN	Rp 0

--- SELESAI ---
Powered by Parzello POS


Bagikan

Set Printer

Gambar 3.15 Wireframe Halaman Struk Digital

13. Halaman Katalog Produk


Beranda mode pelanggan yang menampilkan katalog produk toko beserta kategori menu, informasi harga, dan fitur pencarian produk secara mandiri.



Gambar 3.16 Wireframe Halaman Katalog Produk

3.6.4 Rancangan Algoritma *Long Short-Term Memory* (LSTM)

Desain metode LSTM memberikan gambaran mengenai alur kerja algoritma yang digunakan dalam proses prediksi penjualan harian pada sistem POS. Alur kerja algoritma diilustrasikan pada Gambar 3.17.



Gambar 3.17 Alur Kerja Algoritma *Long Short-Term Memory* (LSTM)

Gambar 3.17 menggambarkan alur kerja model LSTM dari input data transaksi harian hingga proses evaluasi model. Adapun langkah-langkah proses algoritma dalam penelitian ini adalah sebagai berikut:

1. Data transaksi penjualan harian diekstrak dari basis data Supabase, kemudian melalui tahap pra-pemrosesan (*preprocessing*) meliputi pembersihan data, penyelarasan format tanggal, dan normalisasi

menggunakan *Min-Max Scaling*.

2. Data disusun dalam bentuk deret waktu melalui proses *windowing (time step)* untuk membentuk pola historis yang digunakan sebagai input model LSTM.
3. Dataset dibagi menjadi data *training* dan *testing* menggunakan metode *time-based split* untuk menjaga urutan temporal data.
4. Model LSTM dibangun dengan arsitektur yang terdiri dari *input layer*, satu atau lebih *hidden layer* LSTM, dan *dense layer* sebagai keluaran prediksi penjualan harian.
5. Model yang telah dilatih diuji menggunakan data *testing* dan dievaluasi dengan metrik MAE (*Mean Absolute Error*), RMSE (*Root Mean Square Error*), dan MAPE (*Mean Absolute Percentage Error*).
6. Apabila hasil evaluasi belum memenuhi kriteria yang diharapkan, dilakukan *hyperparameter tuning* terhadap jumlah *epoch*, *batch size*, jumlah neuron LSTM, dan *learning rate*.
7. Model prediksi yang telah teruji diintegrasikan ke dalam sistem POS melalui REST API sehingga aplikasi *mobile* dapat menampilkan hasil prediksi penjualan harian kepada pengguna.

3.7 Teknik Pengujian

Pengujian sistem pada penelitian ini mencakup dua pendekatan utama untuk memastikan kualitas fungsional aplikasi dan keandalan model prediksi yang diintegrasikan. Pendekatan pengujian tersebut dibagi menjadi pengujian evaluasi model prediksi penjualan dan pengujian fungsionalitas sistem secara keseluruhan menggunakan metode *black box*.

3.7.1 Rancangan Pengujian Evaluasi Model Prediksi

Pengujian model prediksi dilakukan untuk mengukur kinerja dan tingkat akurasi dari algoritma *Long Short-Term Memory* (LSTM) yang dikembangkan. Pengujian ini menggunakan data pengujian (*testing data*) yang diambil dari data

histori transaksi penjualan harian mitra UMKM. Evaluasi akurasi model diukur berdasarkan tingkat kesalahan (*error*) prediksi menggunakan tiga metrik utama, yaitu:

1. **Mean Absolute Error (MAE):** MAE digunakan untuk mengukur rata-rata selisih absolut antara nilai aktual penjualan dengan nilai hasil prediksi. Semakin kecil nilai MAE, maka model prediksi semakin akurat. Formula MAE didefinisikan sebagai berikut:

$$\text{MAE} = \frac{1}{n} \sum_{t=1}^n |Y_t - \hat{Y}_t| \quad 3.1$$

di mana Y_t adalah nilai aktual pada hari ke- t , $\hat{Y}_t$ adalah nilai prediksi pada hari ke- t , dan n adalah jumlah data pengujian.

2. **Root Mean Square Error (RMSE):** RMSE memberikan bobot lebih besar pada kesalahan prediksi yang bernilai besar karena selisihnya dikuadratkan terlebih dahulu sebelum dirata-ratakan dan ditarik akarnya. Formula RMSE didefinisikan sebagai berikut:

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{t=1}^n (Y_t - \hat{Y}_t)^2} \quad 3.2$$

3. **Mean Absolute Percentage Error (MAPE):** MAPE digunakan untuk mengukur persentase kesalahan absolut rata-rata relatif terhadap nilai aktual. Keunggulan MAPE adalah menghasilkan nilai dalam bentuk persentase sehingga mudah diinterpretasikan. Formula MAPE didefinisikan sebagai berikut:

$$\text{MAPE} = \left(\frac{1}{n} \sum_{t=1}^n \left| \frac{Y_t - \hat{Y}_t}{Y_t} \right| \right) \times 100\% \quad 3.3$$

Pengujian evaluasi ini dilakukan dengan membandingkan performa model pada variasi *hyperparameter* (seperti jumlah neuron LSTM, *learning rate*, *batch size*, dan jumlah *epoch*) untuk memperoleh konfigurasi model prediksi yang paling optimal dengan tingkat kesalahan terkecil.

3.7.2 Rancangan Analisis Pengujian *Black Box*

Pengujian fungsional sistem pada penelitian ini menggunakan metode *black box testing*, yaitu metode pengujian perangkat lunak yang berfokus pada validasi fungsional sistem dengan mengamati kesesuaian antara masukan (*input*) dan keluaran (*output*) yang dihasilkan, tanpa memperhatikan struktur internal kode program. Pengujian diterapkan pada fitur-fitur utama sistem untuk memastikan aplikasi berjalan sesuai dengan kebutuhan operasional pengguna.

Rancangan skenario pengujian *black box* untuk fitur-fitur utama sistem POS ini dijabarkan pada Tabel 3.4 berikut:

Tabel 3.4 Skenario Pengujian *Black Box*

No.	Fitur / Fungsi	Skenario Pengujian	Hasil yang Diharapkan
1	Registrasi Toko Baru	Mengisi form registrasi dengan email baru, kata sandi, nama toko, alamat, dan nomor HP.	Akun owner berhasil dibuat, data toko tersimpan di database Supabase Cloud, dan beralih ke halaman utama.
2	Login Akun	Memasukkan email dan kata sandi yang valid/invalid pada layar login.	Jika valid, pengguna masuk ke dasbor. Jika invalid, sistem menampilkan pesan error autentikasi.
3	Kelola Produk	Menambah produk baru dengan nama, harga, stok, foto, dan kategori serta mengubah/menghapus produk.	Data produk baru tersimpan di database lokal Isar DB, terdaftar pada list produk, dan dapat diubah/dihapus.
4	Kelola Kategori	Menambahkan kategori baru, menyunting nama kategori, atau menghapus kategori produk.	Kategori berhasil dibuat, muncul sebagai opsi filter menu, dan terupdate secara real-time.

5	Checkout Transaksi	Memasukkan produk ke keranjang, menerapkan voucher diskon, memilih metode bayar, dan mengonfirmasi nominal bayar.	Transaksi berhasil disimpan di database lokal Isar DB, jumlah stok produk berkurang otomatis, dan dialihkan ke struk sukses.
6	Mencetak Struk	Menghubungkan printer Bluetooth thermal dan menekan tombol cetak struk dari riwayat transaksi.	Printer thermal mencetak struk fisik transaksi secara lengkap (nama produk, total, tanggal, metode bayar).
7	Sinkronisasi Offline	Mematikan koneksi internet (luring), membuat transaksi lokal, lalu mengaktifkan internet kembali (daring).	Transaksi disimpan secara lokal di Isar DB (offline-first), lalu terunggah otomatis ke Supabase Cloud saat internet aktif kembali.
8	Dasbor Laporan	Membuka dasbor laporan penjualan harian, mingguan, dan grafik visualisasi omzet.	Menampilkan statistik ringkasan omzet, total transaksi harian, dan grafik visualisasi garis yang akurat.

3.8 Hasil yang Diharapkan

Hasil yang diharapkan dari penelitian ini meliputi beberapa aspek sebagai berikut:

1. Aplikasi *Point of Sale* (POS) *mobile* yang mampu membantu pelaku UMKM dalam mengelola transaksi penjualan, inventaris produk, dan laporan keuangan secara efisien dengan kemampuan operasional *offline-first*.
2. Implementasi metode LSTM pada sistem yang berjalan dengan baik dan menghasilkan prediksi penjualan harian yang akurat, sehingga dapat digunakan sebagai dasar pengambilan keputusan usaha.
3. Sistem yang mampu menyajikan informasi prediksi dan laporan penjualan

dalam bentuk visualisasi grafik yang mudah dipahami oleh pengguna, khususnya pelaku UMKM.

4. Hasil penelitian ini diharapkan dapat dipublikasikan dalam jurnal ilmiah sebagai kontribusi dalam pengembangan sistem informasi dan penerapan *machine learning* pada UMKM.
5. Penelitian ini menghasilkan laporan tugas akhir sebagai salah satu syarat penyelesaian studi pada Program Studi Teknik Informatika Politeknik Negeri Lhokseumawe.

DAFTAR PUSTAKA

- [1] S. Abbas, M. A. Khan, and A. Tariq, "Sales Forecasting Using Long Short-Term Memory (LSTM) Networks in Retail Industry," *IEEE Access*, vol. 9, pp. 30900–30912, 2021.
- [2] T. Brown and M. Green, "Demand Forecasting for Inventory Management in Small Retail Stores Using Neural Networks," *Journal of Retailing and Consumer Services*, vol. 58, pp. 102–115, 2021.
- [3] H. Choi and J. Lee, "Multivariate Time-Series Forecasting for Retail Sales Using LSTM with Economic Indicators," *International Journal of Forecasting*, vol. 38, no. 3, pp. 890–905, 2022.
- [4] M. Fischer and L. Weber, "Evaluating Open-Source Backend-as-a-Service (BaaS) Platforms: A Case Study on Supabase and PostgreSQL," *International Journal of Computer Science & Information Technology*, vol. 16, no. 1, pp. 45–58, 2024.
- [5] P. Kumar and R. Sharma, "Integrating Predictive Machine Learning Models into Enterprise Resource Planning and Point of Sales Systems," *Journal of Systems and Software*, vol. 195, pp. 111–125, 2023.
- [6] J. Martinez and R. Silva, "Architecture Design of Offline-First Mobile Application using Local Embedded Database and Remote Sync Server," *IEEE Transactions on Software Engineering*, vol. 48, no. 8, pp. 2840–2852, 2022.
- [7] H. Nguyen and V. Tran, "Decoupling Core Transact Systems and Analytical Machine Learning Frameworks inside Microservice Architectures," *Journal of Systems Architecture*, vol. 134, pp. 102–118, 2023.
- [8] A. Novikov and I. Petrov, "Performance Comparison of Local NoSQL Embedded Databases in Flutter Framework: Hive, ObjectBox, and Isar," *Communications in Computer and Information Science*, vol. 1780, pp. 112–126, 2023.
- [9] R. Pratama and S. Handayani, "Digital Transformation of Indonesian SMEs: Implementation of Smart Point of Sales Systems," *Jurnal Sistem Informasi (JSI)*, vol. 21, no. 1, pp. 12–25, 2025.
- [10] D. Roberts and K. Thomas, "Designing Smart Mobile Applications with Server-Side Artificial Intelligence Models via RESTful Web Services," *International Journal of Mobile Computing and Multimedia Communications*, vol. 13, no. 2, pp. 1–18, 2024.
- [11] A. Setiawan and B. T. Nugroho, "Development of Cross-Platform Point of Sale Application using Flutter Framework for Small and Medium Enterprises,"

International Journal of Advanced Computer Science and Applications, vol. 14, no. 5, pp. 320–329, 2023.

- [12] G. Thompson, “A Review of Evaluation Metrics for Time-Series Forecasting in Commercial Retail,” *Journal of Business Forecasting*, vol. 40, no. 2, pp. 75–88, 2021.
- [13] L. White and J. Black, “Privacy-Preserving Machine Learning for Small Business Analytics: Scrubbing Personal Identifiable Information,” *Security and Privacy in Communication Networks*, vol. 512, pp. 200–215, 2025.
- [14] E. Wilson and M. Davies, “Application of LSTM Networks to Solve Long-Term Memory Retention in Highly Seasonal Sales Data,” *Neural Networks*, vol. 148, pp. 45–56, 2022.
- [15] Y. Zhang and X. Liu, “Comparative Analysis of LSTM and GRU for Time-Series Sales Forecasting,” *Applied Soft Computing*, vol. 115, pp. 108–122, 2022.