

SISTEM KLASIFIKASI KELAYAKAN COOLING WATER PADA UNIT PEMBANGKIT LISTRIK MENGUNAKAN ALGORITMA RANDOM FOREST (STUDI KASUS: PT PLN NUSANTARA POWER UP ARUN)

SKRIPSI

Diajukan Sebagai Salah Satu Syarat Untuk Menyelesaikan
Pendidikan Jenjang Sarjana Terapan Pada Politeknik Negeri Lhokseumawe



Oleh:
SUCI WILDANI RIZKA
NIM 2022573010047

**PROGRAM STUDI TEKNIK INFORMATIKA
JURUSAN TEKNOLOGI INFORMASI DAN KOMPUTER
POLITEKNIK NEGERI LHOKSEUMAWE
KEMENTERIAN PENDIDIKAN TINGGI, SAINS, DAN
TEKNOLOGI
2026**

**SISTEM KLASIFIKASI KELAYAKAN COOLING WATER
PADA UNIT PEMBANGKIT LISTRIK MENGGUNAKAN
ALGORITMA RANDOM FOREST (STUDI KASUS: PT PLN
NUSANTARA POWER UP ARUN)**

SKRIPSI

Diajukan Sebagai Salah Satu Syarat Untuk Menyelesaikan
Pendidikan Jenjang Sarjana Terapan Pada Politeknik Negeri Lhokseumawe

Oleh:

SUCI WILDANI RIZKA

NIM. 2022573010047

**PROGRAM STUDI TEKNIK INFORMATIKA
JURUSAN TEKNOLOGI INFORMASI DAN KOMPUTER
POLITEKNIK NEGERI LHOKSEUMAWE
KEMENTERIAN PENDIDIKAN TINGGI, SAINS, DAN
TEKNOLOGI
2026**

SISTEM KLASIFIKASI KELAYAKAN COOLING WATER PADA UNIT PEMBANGKIT LISTRIK MENGGUNAKAN ALGORITMA RANDOM FOREST (STUDI KASUS: PT PLN NUSANTARA POWER UP ARUN)

Oleh
SUCI WILDANI RIZKA
NIM. 2022573010047

ABSTRAK

Kualitas cooling water pada unit pembangkit listrik berperan penting dalam menjaga kestabilan suhu mesin serta menjamin keberlangsungan operasional pembangkitan. Penentuan kelayakan cooling water umumnya dilakukan dengan membandingkan setiap parameter kualitas terhadap standar yang ditetapkan pabrikan mesin. Namun, proses evaluasi manual menjadi kurang efisien ketika data bersifat multivariat dan terus bertambah. Kondisi tersebut menimbulkan kebutuhan akan sistem berbasis data yang mampu mengklasifikasikan kelayakan cooling water secara lebih cepat, objektif, dan konsisten. Penelitian ini bertujuan untuk merancang dan membangun sistem klasifikasi kelayakan cooling water menggunakan algoritma Random Forest pada PT PLN Nusantara Power UP Arun. Data yang digunakan merupakan data sekunder hasil pemantauan parameter pH, konduktivitas, nitrit, besi (Fe), sulfat, dan kekeruhan yang mengacu pada standar resmi Wärtsilä. Model dievaluasi menggunakan confusion matrix serta metrik accuracy, precision, recall, dan F1-score. Hasil penelitian ini diharapkan menghasilkan sistem pendukung keputusan yang dapat meningkatkan efektivitas pengelolaan kualitas cooling water, meminimalkan potensi kesalahan evaluasi manual, serta mendukung operasional pembangkit listrik secara lebih optimal.

Kata Kunci: Cooling Water, Klasifikasi, Machine Learning, Pembangkit Listrik, Random Forest

COOLING WATER FEASIBILITY CLASSIFICATION SYSTEM IN POWER PLANT UNITS USING RANDOM FOREST ALGORITHM (CASE STUDY: PT PLN NUSANTARA POWER UP ARUN)

By
SUCI WILDANI RIZKA
NIM. 2022573010047

ABSTRACT

The quality of cooling water in power plant units plays a crucial role in maintaining engine temperature stability and ensuring the continuity of power generation operations. Determining the feasibility of cooling water is generally done by comparing each quality parameter against the standards set by the engine manufacturer. However, the manual evaluation process becomes less efficient when the data is multivariate and continuously increasing. This condition raises the need for a data-driven system capable of classifying cooling water feasibility faster, objectively, and consistently. This study aims to design and build a cooling water feasibility classification system using the Random Forest algorithm at PT PLN Nusantara Power UP Arun. The data used is secondary data from monitoring parameters of pH, conductivity, nitrite, iron (Fe), sulfate, and turbidity, referring to the official Wärtsilä standard. The model is evaluated using a confusion matrix and metrics of accuracy, precision, recall, and F1-score. The results of this study are expected to produce a decision support system that can increase the effectiveness of cooling water quality management, minimize potential errors in manual evaluation, and support power plant operations more optimally.

Keywords: *Cooling Water, Classification, Machine Learning, Power Plant, Random Forest*

SURAT PERNYATAAN

Dengan ini saya menyatakan bahwa dalam skripsi ini tidak terdapat karya yang pernah diajukan untuk mendapatkan gelar kesarjanaan di suatu Perguruan Tinggi, dan sepanjang pengetahuan saya juga tidak terdapat karya atau pendapat yang pernah ditulis orang lain, kecuali yang secara tertulis diacu dalam naskah dan disebut dalam daftar pustaka.

Lhokseumawe, 28 Mei 2026

Yang menyatakan,

SUCI WILDANI RIZKA

NIM. 2022573010047

LEMBAR PENGESAHAN PEMBIMBING

Skripsi yang berjudul **SISTEM KLASIFIKASI KELAYAKAN COOLING WATER PADA UNIT PEMBANGKIT LISTRIK MENGGUNAKAN ALGORITMA RANDOM FOREST (STUDI KASUS: PT PLN NUSANTARA POWER UP ARUN)**, disusun oleh **SUCI WILDANI RIZKA**, NIM **2022573010047**, Program Studi **Teknik Informatika**, Jurusan **Teknologi Informasi dan Komputer Politeknik Negeri Lhokseumawe**, telah memenuhi syarat untuk dipertanggungjawabkan dihadapan dewan penguji.

Buketrata, 29 Juli 2025

Pembimbing I,

Pembimbing II,

Salahuddin, S.T., M.Cs
NIP. 19740424 200212 1 001

Mahdi, S.T., M.Cs
NIP. 19700802 199303 1 001

Mengetahui,

Ketua Jurusan
Jurusan Teknologi Informasi dan
Komputer,

Ketua Program Studi
Teknik Informatika,

Salahuddin, S.T., M.Cs
NIP. 19740424 200212 1 001

M. Khadafi, S.T., M.T
NIP. 19750718 200212 1 004

HALAMAN PENGESAHAN PENGUJI

Skripsi yang berjudul **SISTEM KLASIFIKASI KELAYAKAN COOLING WATER PADA UNIT PEMBANGKIT LISTRIK MENGGUNAKAN ALGORITMA RANDOM FOREST (STUDI KASUS: PT PLN NUSANTARA POWER UP ARUN)**, disusun oleh **SUCI WILDANI RIZKA**, NIM **2022573010047**, Program Studi **Teknik Informatika**, Jurusan **Teknologi Informasi dan Komputer Politeknik Negeri Lhokseumawe**, telah dipertanggungjawabkan di depan dewan penguji dan dinyatakan lulus pada tanggal **05 Agustus 2026**.

Komisi Sidang,

1. **Salahuddin, S.T., M.Cs**
NIP. 19740424 200212 1 001 (Ketua Sidang)
2. **Mahdi, S.T., M.Cs**
NIP. 19700802 199303 1 001 (Sekretaris Sidang)
3. **Dr. Rahmad Hidayat, S.Kom.,**
M.Cs
NIP. 19830420 201212 1 003 (Penguji I)
4. **Muhammad Rizka, S.S.T., M.Kom**
NIP. 19881009 201504 1 001 (Penguji II)
5. **Bismillah Baik**
NIP. - (Penguji III)

Mengetahui,

Ketua Jurusan
Jurusan Teknologi Informasi dan
Komputer,

Salahuddin, S.T., M.Cs
NIP. 19740424 200212 1 001

Ketua Program Studi
Teknik Informatika,

M. Khadafi, S.T., M.T
NIP. 19750718 200212 1 004

HALAMAN PERSEMBAHAN

“Tugas Akhir ini saya persembahkan sepenuhnya kepada dua orang hebat dalam hidup saya, Ayahanda dan Ibunda. Keduanya lah yang membuat segalanya menjadi mungkin sehingga saya bisa sampai pada tahap di mana skripsi ini akhirnya selesai. Terima kasih atas segala pengorbanan, nasihat dan doa baik yang tidak pernah berhenti kalian berikan kepadaku. Aku selamanya bersyukur dengan keberadaan kalian sebagai orangtua ku.”

KATA PENGANTAR

Segala puji beserta syukur senantiasa penulis panjatkan kepada Allah SWT yang telah memberikan rahmat dan petunjuk-Nya kepada penulis sehingga dapat menyelesaikan skripsi yang berjudul “Sistem Klasifikasi Kelayakan Cooling Water Pada Unit Pembangkit Listrik Menggunakan Algoritma Random Forest (Studi Kasus: PT PLN Nusantara Power UP Arun)”. Shalawat beserta salam kepada baginda Rasulullah Muhammad SAW, keluarga, dan para sahabat yang telah berjasa dalam memperjuangkan islam dan ilmu pengetahuan. Skripsi ini disusun sebagai salah satu syarat untuk menyelesaikan pendidikan Sarjana Terapan Program Studi Teknik Informatika, Jurusan Teknologi Informasi dan Komputer, Politeknik Negeri Lhokseumawe.

Dalam Penyusunan skripsi ini penulis banyak mendapatkan dukungan, perhatian, dorongan, bimbingan dan berbagai bantuan dari banyak pihak terutama para dosen pembimbing. Dengan demikian, segala hormat dan kerendahan hati penulis ini menyampaikan rasa terima kasih yang tidak terhingga terutama kepada:

1. Allah SWT, atas segala rahmat, karunia, dan hidayah-Nya yang telah diberikan sehingga penulis dapat menyelesaikan skripsi ini.
2. Kedua orang tua tercinta serta keluarga yang senantiasa memberikan doa, dukungan, kasih sayang, dan pengorbanan tanpa henti kepada penulis, sehingga penulis dapat menyelesaikan pendidikan dan penyusunan skripsi ini dengan lancar.
3. Bapak Ir. Rizal Syahyadi, S.T., M.Eng.Sc., IPM., ASEAN Eng., APEC Eng. selaku Direktur Politeknik Negeri Lhokseumawe.
4. Bapak Salahuddin, S.T., M.Cs selaku Ketua Jurusan Teknologi Informasi dan Komputer, Bapak Fachri Yanuar Rudi F, M.T selaku Sekretaris Jurusan Teknologi Informasi dan Komputer, dan Bapak M. Khadafi, S.T., M.T selaku Ketua Program Studi Teknik Informatika atas segala bimbingan dan perhatian selama masa perkuliahan.
5. Bapak Salahuddin, S.T., M.Cs selaku Pembimbing utama dan Bapak Mahdi, S.T., M.Cs selaku pembimbing pendamping yang telah membantu, membimbing, dan mengarahkan penulis dalam proses penyelesaian Skripsi ini.
6. Para dosen dan tenaga pengajar Program Studi Teknik Informatika yang telah memberikan ilmu, wawasan, serta pengalaman berharga kepada penulis selama masa perkuliahan, sehingga menjadi bekal yang sangat berarti dalam proses penyelesaian studi.

7. Seluruh teman-teman, khususnya teman-teman terdekat, yang selalu menemani dan memberikan dukungan selama masa perkuliahan hingga penyusunan skripsi ini. Terima kasih atas kebersamaan, perhatian, dan semangat yang tidak pernah berhenti diberikan kepada penulis. Meskipun tidak dapat disebutkan satu per satu, penulis sangat menghargai setiap bantuan dan dukungan yang telah diberikan.
 8. Kepada diri sendiri, penulis mengucapkan terima kasih atas segala usaha, kesabaran, dan kekuatan dalam melewati setiap proses yang tidak mudah. Di tengah keraguan dan kelelahan, penulis tetap berusaha bertahan dan melangkah hingga tahap akhir. Skripsi ini menjadi bukti dari perjalanan panjang yang dilalui serta hasil dari usaha dan doa yang terus diupayakan.
- Penulis menyadari bahwa skripsi ini masih jauh dari sempurna dan memiliki berbagai keterbatasan. Oleh karena itu, penulis sangat mengharapkan kritik dan saran yang bersifat membangun demi perbaikan di masa yang akan datang. Semoga segala bantuan dan kebaikan yang telah diberikan mendapatkan balasan yang terbaik.

Lhokseumawe, 28 Mei 2026

SUCI WILDANI RIZKA
NIM. 2022573010047

DAFTAR ISI

HALAMAN SAMPUL	i
ABSTRAK	ii
ABSTRACT	iii
SURAT PERNYATAAN	iv
LEMBAR PERSETUJUAN	v
HALAMAN PENGESAHAN	vi
HALAMAN PERSEMBAHAN	vii
KATA PENGANTAR	viii
DAFTAR ISI	x
DAFTAR SINGKATAN	xii
DAFTAR GAMBAR	xiii
DAFTAR TABEL	xiv
BAB 1 PENDAHULUAN	1
A. Latar Belakang Masalah	1
B. Rumusan Masalah	3
C. Tujuan Penelitian	3
D. Batasan Masalah	4
E. Manfaat Penelitian	4
F. Sistematika Penulisan	5
BAB 2 TINJAUAN PUSTAKA	6
A. State Of The Art	6
B. Cooling Water	8
C. Parameter Kualitas Cooling Water	9
1. Parameter Fisik	10
2. Parameter Kimia	10
3. Parameter Biologis	11
D. Machine Learning (ML)	12
1. Paradigma dan Jenis-Jenis Machine Learning	13
2. Tahapan Penerapan Machine Learning	14
E. Sistem Klasifikasi (Classification)	14
F. Evaluasi Performa Model Klasifikasi	15
G. Algoritma Random Forest	16
BAB 3 METODOLOGI PENELITIAN	20
A. Alur Penelitian	20
B. Analisis Kebutuhan Sistem	21
1. Analisis Kebutuhan Fungsional	21
2. Analisis Kebutuhan Non-Fungsional	22
C. Perancangan Sistem	23
1. Arsitektur Sistem	23

2. Use Case Diagram	24
3. Activity Diagram	24
D. Perancangan Database	29
1. Tabel Akun Pengguna (tb_user)	29
2. Tabel Parameter Input (tb_input)	29
3. Tabel Hasil Klasifikasi (tb_hasil)	29
E. Perancangan Antarmuka Pengguna (User Interface)	30
F. Data dan Pengumpulan Data	30
G. Rancangan Metode dan Variabel Penelitian	34
1. Perancangan Penerapan Algoritma Random Forest	34
2. Mekanisme Kerja Algoritma Random Forest	36
3. Variabel Penelitian	36
H. Teknik Pengujian	36
1. Rancangan Pengujian Evaluasi Model Klasifikasi	36
2. Rancangan Analisis Pengujian Black Box	39
3. Rancangan Analisis Pengujian White Box	39
BAB 4 HASIL DAN PEMBAHASAN	41
A. Hasil Implementasi Antarmuka Pengguna (User Interface)	41
1. Halaman Login	41
2. Halaman Dashboard	41
3. Halaman Input Data	42
4. Halaman Hasil Klasifikasi	43
5. Halaman Report (Historical Data)	43
6. Halaman Kelola User	45
B. Hasil Pelatihan dan Pengujian Model Random Forest	45
1. Pembagian Dataset	45
2. Hasil 5-Fold Cross Validation	46
3. Hasil Pengujian pada Data Uji (Testing Set)	46
4. Analisis Feature Importance	47
C. Hasil Pengujian Sistem	48
1. Hasil Pengujian Black Box	48
2. Hasil Pengujian White Box	48
BAB 5 KESIMPULAN DAN SARAN	51
A. Kesimpulan	51
B. Saran	52
DAFTAR PUSTAKA	54
LAMPIRAN A KODE PROGRAM	57
Lampiran A.1. Program Pembacaan Sensor Ultrasonic	57
Lampiran A.2. Program Keseluruhan Proyek Akhir	57
LAMPIRAN B GAMBAR-GAMBAR	58
Lampiran B.1. Foto Aktivitas Kegiatan Proyek Akhir	58
Lampiran B.2. Foto Produk Proyek Akhir	58

DAFTAR SINGKATAN

FWHM	:	<i>Full width half maximum</i>
rms	:	<i>root mean square</i>
RFS	:	<i>Rotary forcespinning</i>
PVP	:	Polivinil pirolidon
SI	:	Satuan Internasional
SI	:	Satuan Internasional
SI	:	Satuan Internasional
SI	:	Satuan Internasional
SI	:	Satuan Internasional
SI	:	Satuan Internasional
SI	:	Satuan Internasional
SI	:	Satuan Internasional
SI	:	Satuan Internasional

DAFTAR GAMBAR

2.1	Mekanisme Kerja Algoritma Random Forest	18
3.1	Alur Penelitian	20
3.2	Arsitektur Sistem	24
3.3	Use Case Diagram	25
3.4	Activity Diagram Login	26
3.5	Activity Diagram Input Data dan Klasifikasi	27
3.6	Activity Diagram Proses Klasifikasi Random Forest	27
3.7	Activity Diagram Generate Laporan	28
3.8	Activity Diagram Manajemen User	28
3.9	Activity Diagram Logout	29
3.10	UI/UX Halaman Login	31
3.11	UI/UX Halaman Dashboard	31
3.12	UI/UX Halaman Input Data	32
3.13	UI/UX Halaman Hasil Klasifikasi	32
3.14	UI/UX Halaman Report	33
3.15	UI/UX Halaman Manajemen User	33
3.16	Rancangan Penerapan Algoritma Random Forest	35
3.17	Mekanisme Kerja Algoritma Random Forest	37
3.18	Skema Training Random Forest untuk Klasifikasi Cooling Water	38
4.1	Hasil Implementasi Halaman Login	41
4.2	Hasil Implementasi Halaman Dashboard	42
4.3	Hasil Implementasi Halaman Input Data	43
4.4	Hasil Implementasi Halaman Hasil Klasifikasi	44
4.5	Hasil Implementasi Halaman Report	44
4.6	Hasil Implementasi Halaman Kelola User	45

DAFTAR TABEL

2.1	State Of The Art	7
3.1	Spesifikasi Perangkat Keras (Hardware)	23
3.2	Spesifikasi Perangkat Lunak (Software)	23
3.3	Deskripsi Aktor	24
3.4	Deskripsi Use Case	26
3.5	Struktur Tabel tb_user	29
3.6	Struktur Tabel tb_input	30
3.7	Struktur Tabel tb_hasil	30
3.8	Contoh Data Parameter Cooling Water	34
3.9	Standar Nilai Parameter Kualitas Cooling Water	34
3.10	Rancangan Confusion Matrix	36
3.11	Skenario Pengujian Login	39
3.12	Skenario Pengujian Input Data	39
3.13	Skenario Pengujian Klasifikasi	39
3.14	Skenario Pengujian Generate Laporan	40
3.15	Skenario Pengujian Manajemen User	40
3.16	Skenario Pengujian Logout	40
3.17	Skenario Pengujian Proses Klasifikasi	40
4.1	Hasil Evaluasi Performa 5-Fold Cross Validation	46
4.2	Confusion Matrix Hasil Pengujian Model Final	46
4.3	Nilai Feature Importance Parameter Kualitas Air	48
4.4	Hasil Pengujian Fungsionalitas Black Box	49

BAB I

PENDAHULUAN

A. Latar Belakang Masalah

Energi listrik merupakan salah satu kebutuhan paling mendasar yang mendukung aktivitas masyarakat maupun pertumbuhan industri di Indonesia. Salah satu faktor kunci dalam menjamin ketersediaan energi listrik secara berkelanjutan adalah keandalan sistem pembangkit listrik itu sendiri. Dalam operasionalnya, pembangkit listrik mengandalkan berbagai sistem pendukung yang bekerja secara terintegrasi, salah satunya adalah sistem pendingin (*cooling system*). Sistem ini berfungsi menjaga suhu peralatan utama agar selalu berada dalam rentang operasional yang aman. Air, sebagai komponen utama dalam sistem pendingin tersebut, merupakan sumber daya yang tidak hanya vital bagi kehidupan, tetapi juga memegang peran penting dalam berbagai aktivitas industri. Namun, penggunaan air dalam skala industri yang besar berpotensi menghasilkan limbah cair yang dapat berdampak negatif terhadap lingkungan apabila tidak dikelola dengan baik Alazaiza et al. (2025).

Air yang digunakan sebagai media pendingin dalam industri dikenal dengan istilah *cooling water* (air pendingin). Sistem *cooling water* umumnya beroperasi secara sirkulatif dalam jangka panjang, yang secara alami akan menyebabkan peningkatan konsentrasi zat terlarut dan kontaminan di dalamnya. Jika dibiarkan, kondisi ini dapat memicu terjadinya korosi, pembentukan kerak (*scaling*), hingga penurunan kinerja sistem secara keseluruhan. Untuk mencegah hal tersebut, sebagian air dalam sistem pendingin perlu dibuang secara berkala melalui proses yang disebut *blowdown*. Kelayakan *cooling water* sendiri dinilai berdasarkan sejumlah parameter, antara lain derajat keasaman (pH), konduktivitas, kandungan nitrit, besi (Fe), sulfat, dan kekeruhan Nisa et al. (2023).

Pada unit pembangkit listrik, termasuk PT PLN Nusantara Power Unit Pembangkitan Arun yang mengoperasikan 19 unit engine, pemantauan kualitas *cooling water* dilakukan secara rutin setiap 500 jam operasi mesin atau kurang lebih satu kali dalam sebulan untuk setiap unit mesin. Dengan jumlah unit yang

relatif banyak, proses pemantauan menghasilkan data parameter kualitas air dalam jumlah besar yang harus di evaluasi secara berkala untuk masing-masing engine. Pemantauan juga dapat dilakukan lebih awal apabila terdeteksi kondisi yang tidak normal. Hasil pemantauan ini kemudian dibandingkan dengan nilai standar yang telah ditetapkan perusahaan berdasarkan dokumen resmi pabrikan mesin, sebagai acuan untuk memastikan *cooling water* tetap berada dalam kondisi yang aman selama proses pembangkitan berlangsung. Apabila salah satu parameter melampaui batas yang ditentukan, maka *cooling water* tersebut dinyatakan tidak layak pakai dan harus dikeluarkan melalui proses *blowdown*.

Permasalahannya, proses penilaian kelayakan tersebut hingga saat ini masih dilakukan secara manual, yakni dengan membandingkan nilai setiap parameter satu per satu terhadap batas standar yang berlaku. Cara ini tentu menjadi kurang efisien ketika data yang harus dievaluasi jumlahnya besar dan melibatkan banyak parameter sekaligus. Di samping itu, penilaian manual juga rentan terhadap inkonsistensi, terutama ketika nilai suatu parameter berada di ambang batas standar. Kondisi inilah yang mendorong perlunya pendekatan yang lebih sistematis, cepat, dan objektif dalam mengevaluasi kualitas *cooling water* berbasis data historis.

Beberapa penelitian terdahulu menunjukkan bahwa *machine learning* efektif dalam analisis kualitas air. Salah satu penelitian menggunakan berbagai metode seperti TCN, LSTM, dan SVM untuk memprediksi kualitas air *blowdown*, dengan model TCN menghasilkan nilai koefisien determinasi (R^2) hingga 0,911 Wan et al. (2025). Selain itu, pendekatan *machine learning* juga telah diterapkan untuk mengestimasi laju korosi pada sistem *cooling water* industri dan menunjukkan bahwa model berbasis pembelajaran mampu memberikan hasil yang lebih akurat dibandingkan metode konvensional Ruiz et al. (2024). Di sisi lain, penelitian terkait klasifikasi kualitas air masih banyak diterapkan pada air minum, air tanah, dan perairan umum menggunakan algoritma seperti *Random Forest* Abdi et al. (2023); Maulidah et al. (2024); Mutoffar et al. (2022). Lebih lanjut, kajian lain mengonfirmasi bahwa *machine learning* memiliki potensi yang besar untuk diterapkan dalam sistem pemantauan dan pengelolaan kualitas air di berbagai konteks industri Lowe et al. (2022).

Meski demikian, penelitian yang secara spesifik membahas klasifikasi kelayakan *cooling water* pada unit pembangkit listrik masih terbatas. Sebagian besar penelitian sebelumnya berfokus pada prediksi parameter kualitas air atau estimasi kondisi sistem, bukan pada penentuan keputusan operasional dalam bentuk klasifikasi layak atau tidak layak. Padahal, karakteristik *cooling water* pada sistem pembangkit memiliki pola yang berbeda karena dipengaruhi oleh kondisi operasional mesin.

Berdasarkan permasalahan tersebut, penelitian ini mengusulkan penerapan algoritma *Random Forest* untuk mengklasifikasikan kelayakan *cooling water* ke dalam dua kategori, yaitu layak pakai dan tidak layak pakai, berdasarkan data historis pemantauan di PT PLN Nusantara Power UP Arun. Sistem yang dibangun diharapkan dapat menjadi solusi berbasis informatika yang mampu membantu proses pengambilan keputusan operasional secara lebih objektif, konsisten, dan efisien dalam pengelolaan kelayakan *cooling water* pada unit pembangkit listrik.

B. Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, maka rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana merancang dan membangun sistem klasifikasi kelayakan *cooling water* berbasis *machine learning* yang dapat dioperasikan sesuai standar PT PLN Nusantara Power UP Arun?
2. Bagaimana implementasi algoritma *Random Forest* dalam mengklasifikasikan kelayakan *cooling water* berdasarkan data historis parameter kualitas air?
3. Bagaimana tingkat kinerja model *Random Forest* berdasarkan evaluasi menggunakan *confusion matrix* serta metrik *accuracy*, *precision*, *recall*, dan *F1-score*?

C. Tujuan Penelitian

Tujuan dari penelitian ini adalah sebagai berikut:

1. Merancang dan membangun sistem klasifikasi kelayakan *cooling water* berbasis *machine learning* yang sesuai dengan standar operasional PT PLN

Nusantara Power UP Arun.

2. Mengimplementasikan algoritma *Random Forest* dalam proses klasifikasi kelayakan *cooling water* berdasarkan data historis parameter kualitas air.
3. Mengevaluasi kinerja model *Random Forest* menggunakan *confusion matrix* serta metrik *accuracy*, *precision*, *recall*, dan *F1-score*.

D. Batasan Masalah

Untuk menghindari meluasnya pembahasan, penelitian ini dibatasi pada hal-hal berikut:

1. Penelitian ini menggunakan data hasil pengukuran parameter kualitas *cooling water* yang diperoleh dari PT PLN Nusantara Power UP Arun.
2. Parameter yang dianalisis dibatasi pada pH, konduktivitas (*specific conductivity*), kadar nitrit (*Nitrite*), kandungan besi (Fe), sulfat (*Sulfate*), dan tingkat kekeruhan (*Turbidity*).
3. Penelitian ini difokuskan pada perancangan dan pembangunan sistem klasifikasi berbasis *machine learning*, dan tidak membahas proses pengolahan atau perlakuan terhadap sifat fisik maupun kandungan kimia *cooling water* secara nyata.

E. Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan manfaat sebagai berikut:

1. Membantu PT PLN Nusantara Power UP Arun dalam melakukan klasifikasi kelayakan *cooling water* secara lebih cepat, objektif, dan konsisten, sehingga mengurangi ketergantungan pada proses evaluasi manual.
2. Mendukung pengambilan keputusan operasional terkait kelayakan *cooling water* berdasarkan data historis dan standar operasional yang berlaku, sehingga proses pengendalian kualitas seperti *blowdown* dapat dilakukan secara lebih tepat waktu dan tepat sasaran.
3. Memberikan kontribusi akademis dalam penerapan algoritma *Random Forest* untuk klasifikasi kualitas *cooling water* pada sistem pendingin industri pembangkit listrik.
4. Menjadi referensi bagi penelitian selanjutnya dalam pengembangan sistem

pemantauan dan klasifikasi kualitas *cooling water* berbasis *machine learning*.

F. Sistematika Penulisan

Sistematika penulisan dalam penelitian ini disusun untuk memberikan gambaran secara menyeluruh mengenai alur pembahasan yang dilakukan. Penulisan skripsi ini dibagi ke dalam lima bab utama yang saling berkaitan, dengan rincian sebagai berikut:

BAB I PENDAHULUAN

Bab ini menguraikan gambaran umum penelitian yang meliputi latar belakang masalah, rumusan masalah, tujuan penelitian, batasan masalah, manfaat penelitian, serta sistematika penulisan. Bab ini menjadi dasar dalam memahami alasan dan arah penelitian yang dilakukan.

BAB II TINJAUAN PUSTAKA

Bab ini berisi landasan teori dan kajian literatur yang relevan dengan penelitian. Teori yang disajikan mencakup konsep *cooling water*, kualitas air, parameter kualitas air, serta metode *machine learning* khususnya algoritma *Random Forest*. Selain itu, pada bab ini juga disajikan penelitian terdahulu (*State of the Art*) yang menjadi acuan dalam mengidentifikasi posisi dan kebaruan penelitian.

BAB III METODOLOGI PENELITIAN

Bab ini menjelaskan tahapan penelitian yang dilakukan, mulai dari pengumpulan data, pengolahan data, hingga penerapan metode yang digunakan. Selain itu, dijelaskan pula perancangan sistem yang meliputi alur proses klasifikasi, pemodelan menggunakan algoritma *Random Forest*, serta skenario pengujian yang digunakan dalam penelitian.

BAB IV HASIL DAN PEMBAHASAN

Bab ini menyajikan hasil implementasi sistem yang telah dirancang, serta analisis terhadap hasil pengujian model. Pembahasan meliputi evaluasi performa model klasifikasi, interpretasi hasil prediksi, serta analisis terhadap parameter yang mempengaruhi kelayakan *cooling water*.

BAB V PENUTUP

Bab ini berisi kesimpulan yang diperoleh dari hasil penelitian serta saran yang dapat diberikan untuk pengembangan penelitian selanjutnya.

BAB II

TINJAUAN PUSTAKA

A. State Of The Art

Penelitian terkait klasifikasi kualitas air telah mengalami perkembangan signifikan dengan pemanfaatan metode *machine learning*, khususnya algoritma *Random Forest* yang dikenal mampu menangani data nonlinier dan kompleks secara efektif. Berbagai penelitian telah dilakukan dengan fokus pada klasifikasi kualitas air berbasis parameter fisik dan kimia, baik untuk keperluan konsumsi, lingkungan, maupun sistem pengolahan air.

Secara umum, penelitian terdahulu dapat dikelompokkan ke dalam tiga kategori utama. Pertama, penelitian yang berfokus pada klasifikasi kualitas air konsumsi dan air lingkungan, seperti air minum, air sumur, dan air permukaan, yang bertujuan untuk menentukan kelayakan berdasarkan standar kesehatan. Kedua, penelitian yang mengarah pada prediksi parameter kualitas air atau *Water Quality Index* (WQI) menggunakan pendekatan regresi berbasis *machine learning*. Ketiga, penelitian yang mulai berkembang dalam konteks air industri, khususnya pada sistem *cooling water*, yang digunakan dalam operasional pembangkit listrik dan proses industri.

Meskipun demikian, penelitian pada konteks *cooling water* industri masih relatif terbatas dan umumnya berfokus pada prediksi parameter kualitas air atau estimasi kondisi sistem, seperti laju korosi dan performa sistem pendingin, bukan pada klasifikasi kelayakan operasional secara langsung. Padahal, dalam praktik industri, diperlukan sistem yang mampu mengklasifikasikan kondisi air secara cepat dan akurat untuk mendukung pengambilan keputusan operasional. Ringkasan penelitian terdahulu tersebut disajikan dalam bentuk tabel *State of the Art* pada Tabel 2.1.

Berdasarkan kajian terhadap penelitian terdahulu pada Tabel 2.1, dapat disimpulkan bahwa sebagian besar penelitian masih berfokus pada klasifikasi dan prediksi kualitas air konsumsi seperti air minum, air permukaan, dan air tanah menggunakan algoritma *Random Forest* berbasis dataset umum. Beberapa

Tabel 2.1 State Of The Art

No	Penulis, Tahun & Judul	Metode	Hasil	Persamaan	Perbedaan
1	Ningsih & Pramatha (2024) Ningsih and Pramatha (2024)	Random Forest & GridSearchCV	Tuning hyperparameter meningkatkan akurasi model	Sama-sama klasifikasi kualitas air	Dataset air minum vs. cooling water
2	Wan et al. (2025) Wan et al. (2025)	TCN, LSTM, CNN, XGBoost, SVM	TCN terbaik dengan $R^2 = 0,911$	Penerapan ML pada cooling water	Pendekatan regresi vs. klasifikasi
3	Ruiz et al. (2024) Ruiz et al. (2024)	XGBoost & DNN	DNN terbaik untuk estimasi laju korosi	Data operasional cooling water	Prediksi laju korosi vs. kelayakan
4	Hridoy et al. (2024) Hridoy et al. (2025)	Random Forest, SVM, XGBoost, LightGBM	Random Forest memberikan akurasi tertinggi	Klasifikasi air berbasis parameter fisik/kimia	Klasifikasi multi-kelas vs. biner
5	Chen et al. (2024) Chen et al. (2024)	Random Forest, SVM, Decision Tree, KNN	Random Forest berkinerja paling unggul	Klasifikasi status layak/tidak layak	Dataset air tanah vs. cooling water
6	Mutoffar et al. (2022) Mutoffar et al. (2022)	Random Forest	Akurasi presisi 0,823 dan sensitivitas 0,83	Random Forest untuk kualitas air	Air sumur rumah tangga vs. industri
7	Firmansyah et al. (2025) Firmansyah et al. (2025)	Random Forest & Random Search	Optimasi sedikit meningkatkan akurasi	Random Forest untuk kualitas air	Fokus optimasi hyperparameter vs. operasional
8	Distefano et al. (2024) Distefano et al. (2024)	Random Forest & ADASYN/resampling	ADASYN meningkatkan performa data imbalanced	Random Forest pada data tidak seimbang	Air limbah emisi bau vs. cooling water

penelitian telah mulai mengkaji penerapan *machine learning* pada sistem *cooling water* industri, namun umumnya masih menggunakan pendekatan prediksi parameter kualitas air dan belum secara spesifik mengklasifikasikan kelayakan operasional air.

Oleh karena itu, penelitian yang membahas klasifikasi kelayakan *cooling water* dalam kategori Layak dan Tidak Layak berbasis data operasional nyata masih terbatas. Penelitian ini hadir untuk mengisi celah tersebut dengan mengusulkan sistem klasifikasi menggunakan algoritma *Random Forest* berdasarkan data historis dari PT PLN Nusantara Power UP Arun dengan mengacu pada standar teknis operasional pabrikan mesin sebagai dasar pelabelan data.

B. Cooling Water

Cooling water merupakan air yang digunakan sebagai media pendingin dalam sistem industri dan pembangkit listrik untuk menyerap dan memindahkan panas dari peralatan atau mesin selama proses operasi berlangsung. Pada pembangkit listrik, sistem pendingin memiliki peranan penting dalam menjaga kestabilan temperatur komponen seperti turbin, kondensor, *heat exchanger*, serta sistem bantu lainnya agar tetap berada dalam batas aman operasional. Apabila suhu tidak dikendalikan dengan baik, maka dapat terjadi *overheating* yang berpotensi menurunkan efisiensi sistem dan mempercepat kerusakan peralatan Lan et al. (2025).

Dalam sistem pembangkit modern, *cooling water* umumnya digunakan dalam sistem sirkulasi tertutup maupun semi-terbuka (*recirculating cooling system*), di mana air digunakan berulang kali selama kualitasnya masih memenuhi standar operasional. Namun, proses sirkulasi yang terus-menerus menyebabkan terjadinya akumulasi zat terlarut, partikel, serta mikroorganisme yang dapat memengaruhi kualitas air pendingin. Salah satu permasalahan utama dalam sistem *cooling water* adalah terbentuknya biofilm pada permukaan pipa dan *heat exchanger* akibat pertumbuhan mikroorganisme. Biofilm dapat menghambat proses perpindahan panas dan meningkatkan risiko terjadinya korosi yang dipicu oleh aktivitas mikroba (*microbially induced corrosion*) Pippo et al. (2018). Kondisi ini dapat menurunkan efisiensi sistem pendingin serta meningkatkan biaya perawatan dan risiko gangguan operasional.

Selain faktor biologis, kualitas *cooling water* juga dipengaruhi oleh parameter fisik dan kimia seperti derajat keasaman (pH), konduktivitas listrik, total zat terlarut (*Total Dissolved Solids*/TDS), serta kandungan ion tertentu seperti klorida, sulfat, dan besi. Nilai pH yang terlalu rendah dapat mempercepat proses korosi, sedangkan pH yang terlalu tinggi berpotensi menyebabkan pembentukan kerak (*scaling*) pada permukaan perpindahan panas. Konsentrasi zat terlarut dan garam mineral yang tinggi juga berkontribusi terhadap pembentukan deposit mineral yang dapat mengurangi efisiensi perpindahan panas Biedunkova et al. (2024); Kuznietsov (2024). Selain itu, perubahan komposisi kimia air pendingin dipengaruhi oleh kondisi operasi sistem, termasuk suhu, laju sirkulasi, serta proses *blowdown* yang dilakukan untuk mengendalikan konsentrasi zat terlarut dalam sistem Suganya et al. (2020).

Akumulasi zat terlarut dan pertumbuhan mikroorganisme yang tidak terkendali dapat menyebabkan *fouling*, *scaling*, dan korosi pada komponen sistem pendingin Pippo et al. (2018). Ketiga fenomena tersebut berdampak langsung pada penurunan performa sistem, peningkatan konsumsi energi, serta potensi kerusakan dini pada peralatan pembangkit. Oleh karena itu, pemantauan kualitas *cooling water* secara berkala menjadi langkah penting untuk menjaga keandalan dan efisiensi sistem. Dalam konteks penelitian ini, parameter kualitas *cooling water* dijadikan sebagai variabel utama yang dianalisis untuk menentukan klasifikasi kelayakan air pendingin secara objektif menggunakan pendekatan *machine learning*.

C. Parameter Kualitas Cooling Water

Parameter kualitas *cooling water* merupakan indikator penting dalam menilai kondisi dan kelayakan air untuk mendukung operasional sistem pendingin pada unit pembangkit listrik. Kualitas air pendingin yang tidak terkontrol dapat menyebabkan berbagai permasalahan serius seperti korosi dan *scaling*, yang berdampak pada berkurangnya efisiensi perpindahan panas, meningkatnya frekuensi *shutdown* peralatan, serta berkurangnya usia pipa dan komponen sistem Hsieh et al. (2010); Stojanović et al. (2017). Oleh karena itu, pemantauan parameter kualitas air perlu dilakukan secara berkala guna menjaga stabilitas

sistem dan memperpanjang umur peralatan. Secara umum, parameter kualitas *cooling water* dapat dikelompokkan menjadi tiga kategori, yaitu parameter fisik, kimia, dan biologis.

1. Parameter Fisik

Parameter fisik berkaitan dengan karakteristik tampak dan sifat fisik air yang secara langsung memengaruhi proses perpindahan panas dalam sistem pendingin.

1. **Suhu Air:** memengaruhi laju perpindahan panas dan efisiensi pendinginan secara keseluruhan. Peningkatan suhu air pendingin dapat menurunkan kemampuan air dalam menyerap panas sehingga berdampak pada penurunan performa sistem Hsieh et al. (2010).
2. **Turbidity (Kekeruhan):** menunjukkan jumlah partikel tersuspensi yang terdapat dalam air. Nilai kekeruhan yang tinggi berpotensi menyebabkan *fouling* pada permukaan pipa dan *heat exchanger*, sehingga dapat menghambat proses perpindahan panas secara signifikan Singh and Yadav (2022).
3. **Warna dan Bau:** Perubahan warna dan bau pada air pendingin dapat menjadi indikator awal adanya kontaminasi organik atau meningkatnya aktivitas mikroorganisme di dalam sistem pendingin Singh and Yadav (2022).

2. Parameter Kimia

Parameter kimia berkaitan dengan komposisi zat terlarut dalam air yang dapat memengaruhi stabilitas kimia air serta potensi terjadinya korosi maupun pembentukan kerak (*scaling*).

1. **pH:** derajat keasaman air pendingin. Keseimbangan pH yang tidak terjaga dapat menyebabkan kerusakan yang luas dan korosi pada komponen sistem pendingin. Nilai pH yang terlalu rendah mengindikasikan kondisi air yang bersifat asam sehingga mempercepat proses korosi, sedangkan pH yang terlalu tinggi dapat memicu pembentukan kerak mineral pada permukaan sistem Royani et al. (2019).
2. **Total Dissolved Solids (TDS):** TDS menunjukkan jumlah total zat padat

terlarut dalam air, di mana konsentrasi TDS yang tinggi dapat meningkatkan risiko terbentuknya deposit mineral yang mengganggu efisiensi perpindahan panas pada sistem pendingin Singh and Yadav (2022).

3. **Konduktivitas Listrik:** menggambarkan kemampuan air dalam menghantarkan arus listrik akibat keberadaan ion terlarut. Nilai konduktivitas yang tinggi mengindikasikan konsentrasi mineral yang lebih besar dan berkorelasi dengan meningkatnya risiko korosi serta pembentukan kerak Royani et al. (2019); Singh and Yadav (2022).
4. **Ion Tertentu:** Beberapa ion memiliki pengaruh signifikan terhadap kondisi sistem pendingin. Nitrit umumnya digunakan sebagai inhibitor korosi dalam sistem *cooling water* tertutup karena dapat membentuk lapisan pelindung pada permukaan logam, namun apabila kadarnya tidak terkontrol dapat menimbulkan ketidakseimbangan kimia dalam sistem Hsieh et al. (2010). Peningkatan kandungan besi (Fe) sering kali menjadi indikator terjadinya proses korosi pada sistem pendingin Royani et al. (2019). Sementara itu, ion sulfat dapat berkontribusi terhadap pembentukan endapan seperti kalsium sulfat yang berpotensi menyebabkan *scaling* dan mengganggu kinerja sistem Hoseinzadeh et al. (2013); Stojanović et al. (2017).

3. Parameter Biologis

Parameter biologis berkaitan dengan aktivitas mikroorganisme yang dapat berkembang di dalam sistem pendingin.

1. **Mikroorganisme / Biofilm:** Pertumbuhan mikroorganisme pada permukaan sistem pendingin dapat membentuk lapisan biofilm yang berkontribusi terhadap terjadinya *microbially induced corrosion* (MIC). Mekanisme ini dapat mempercepat kerusakan material melalui reaksi kimia dan produksi zat korosif oleh mikroorganisme Hsieh et al. (2010).
2. **Kontaminan Organik:** Senyawa organik dalam air dapat menjadi sumber nutrisi bagi mikroorganisme sehingga mempercepat pertumbuhan dan pembentukan biofilm dalam sistem pendingin Hsieh et al. (2010); Singh and Yadav (2022).

Berdasarkan berbagai parameter kualitas *cooling water* yang telah diuraikan,

penelitian ini memfokuskan pada enam parameter utama, yaitu pH, Specific Conductivity (SC), Nitrite, Fe, Sulfate, dan Turbidity sebagai variabel input dalam proses klasifikasi. Pemilihan keenam parameter tersebut didasarkan pada ketersediaan data hasil pengujian laboratorium serta relevansinya terhadap potensi korosi, *scaling*, dan *fouling* pada sistem operasional. Parameter-parameter tersebut selanjutnya digunakan sebagai variabel input dalam model klasifikasi berbasis algoritma *Random Forest* untuk menentukan status kelayakan *cooling water* secara otomatis.

D. Machine Learning (ML)

Machine Learning (ML) merupakan salah satu cabang utama dalam bidang *Artificial Intelligence* (AI) yang berfokus pada pengembangan metode komputasional yang memungkinkan sistem untuk belajar dari data dan meningkatkan performanya secara otomatis melalui pengalaman Mukhamediev et al. (2022). Berbeda dengan pendekatan pemrograman konvensional yang mengandalkan aturan-aturan eksplisit yang dirancang oleh manusia (*rule-based system*), ML menggunakan pendekatan berbasis data (*data-driven approach*), di mana pola dan aturan keputusan diekstraksi langsung dari data melalui proses pembelajaran algoritmik Tufail et al. (2023).

Secara konseptual, ML bekerja dengan membangun suatu model matematis berdasarkan dataset historis. Model tersebut merepresentasikan hubungan antara variabel masukan (fitur) dan variabel keluaran (target). Melalui proses pelatihan (*training*), model akan menyesuaikan parameter internalnya untuk meminimalkan kesalahan prediksi terhadap data latih. Hasil dari proses ini adalah suatu fungsi atau struktur keputusan yang mampu digunakan untuk melakukan inferensi terhadap data baru yang belum pernah diproses sebelumnya Barbierato and Gatti (2024).

Tujuan fundamental dari ML bukan sekadar memperoleh akurasi tinggi pada data latih, melainkan menghasilkan model yang memiliki kemampuan generalisasi yang baik. Generalisasi merujuk pada kemampuan model dalam mempertahankan performa prediksi ketika dihadapkan pada data baru di luar sampel pelatihan. Tantangan utama dalam ML adalah menyeimbangkan kompleksitas model agar

tidak terjadi *overfitting* (model terlalu menyesuaikan diri dengan data latih) maupun *underfitting* (model terlalu sederhana sehingga gagal menangkap pola penting dalam data) Barbierato and Gatti (2024).

Seiring perkembangannya, ML telah banyak diterapkan di berbagai bidang, mulai dari sistem klasifikasi medis, prediksi kondisi industri, deteksi anomali, sistem rekomendasi, hingga pengenalan citra dan suara, serta analisis data dalam skala besar. Hal ini menunjukkan bahwa ML memiliki fleksibilitas yang tinggi sehingga menjadikannya salah satu pendekatan yang efektif dalam menangani permasalahan kompleks yang sulit diselesaikan hanya dengan mengandalkan aturan deterministik tradisional Mukhamediev et al. (2022); Tufail et al. (2023).

1. Paradigma dan Jenis-Jenis Machine Learning

Berdasarkan mekanisme pembelajaran dan karakteristik data yang digunakan, ML secara umum diklasifikasikan ke dalam tiga paradigma utama, yaitu *supervised learning*, *unsupervised learning*, dan *reinforcement learning* Mukhamediev et al. (2022); Tufail et al. (2023).

1. **Supervised Learning:** paradigma pembelajaran terawasi di mana model dilatih menggunakan dataset yang telah memiliki label atau nilai target yang diketahui. Dalam pendekatan ini, setiap data masukan memiliki pasangan keluaran yang benar, sehingga proses pembelajaran bertujuan untuk membangun fungsi pemetaan dari ruang fitur ke ruang target Tufail et al. (2023). Secara matematis, supervised learning berupaya mempelajari suatu fungsi $f(x) = y$, di mana x merepresentasikan fitur masukan dan y merupakan variabel target. Dalam pelatihannya, model dioptimalkan untuk meminimalkan fungsi kerugian (*loss function*) yang mengukur seberapa besar selisih antara nilai prediksi dengan nilai aktual Barbierato and Gatti (2024). Supervised learning umumnya dibagi menjadi dua jenis permasalahan utama: klasifikasi (variabel target diskrit) dan regresi (variabel target kontinu).
2. **Unsupervised Learning:** paradigma pembelajaran tanpa label, di mana dataset tidak memiliki variabel target yang telah ditentukan. Tujuan utama pendekatan ini adalah mengidentifikasi struktur, pola, atau hubungan

tersembunyi di dalam data secara mandiri Mukhamediev et al. (2022). Teknik yang umum digunakan meliputi *clustering*, *dimensionality reduction*, dan *anomaly detection* Tufail et al. (2023).

3. **Reinforcement Learning:** paradigma di mana sebuah agen belajar melalui interaksi langsung dengan lingkungannya dengan menerima umpan balik berupa *reward* (penghargaan) atau *punishment* (hukuman) dari setiap tindakan yang dilakukannya untuk memaksimalkan reward kumulatif Mukhamediev et al. (2022); Tufail et al. (2023).

2. Tahapan Penerapan Machine Learning

Penerapan ML dalam suatu sistem umumnya mengikuti alur kerja yang terstruktur dan sistematis, yang terdiri atas beberapa tahapan utama yang saling berkaitan:

1. **Pengumpulan Data:** proses memperoleh dataset yang relevan dan representatif. Kualitas maupun kuantitas data sangat menentukan performa model Tufail et al. (2023).
2. **Preprocessing Data:** bertujuan untuk mempersiapkan data sebelum pemodelan, meliputi pembersihan data dari *missing values*, duplikasi, penyeragaman skala, dan seleksi fitur Tufail et al. (2023).
3. **Training:** proses melatih model menggunakan data latih agar model dapat mempelajari pola hubungan fitur masukan dan variabel target Barbierato and Gatti (2024).
4. **Testing:** proses menguji model menggunakan data yang tidak digunakan saat pelatihan untuk mengevaluasi kemampuan generalisasi model dan menghindari *overfitting* Barbierato and Gatti (2024); Tufail et al. (2023).
5. **Evaluasi Performa:** pengukuran kinerja model menggunakan metrik seperti *accuracy*, *precision*, *recall*, dan *F1-score* pada kasus klasifikasi Rainio et al. (2024).

E. Sistem Klasifikasi (Classification)

Sistem klasifikasi merupakan metode dalam *machine learning* yang digunakan untuk mengelompokkan data ke dalam kelas atau kategori tertentu

berdasarkan atribut atau karakteristik yang dimilikinya. Sistem ini termasuk dalam *supervised learning*, yaitu pendekatan pembelajaran mesin di mana model dilatih menggunakan data berlabel untuk mempelajari hubungan antara fitur input dan kelas keluaran Nurhalizah et al. (2024).

Proses klasifikasi umumnya terdiri dari dua tahap utama, yakni pembelajaran (*training*) dan pengujian (*testing*). Pada tahap pembelajaran, model mempelajari pola hubungan antara atribut masukan dan label kelas pada data latih. Sedangkan pada tahap pengujian, kemampuan model dalam mengklasifikasikan data yang belum pernah dilihat dievaluasi menggunakan metrik performa seperti akurasi, presisi, *recall*, *F1-score*, dan *confusion matrix* Helmud et al. (2024). Penerapan sistem klasifikasi dalam konteks kualitas air memungkinkan data berupa parameter fisik dan kimia dipetakan ke dalam kelas tertentu, sehingga menjadi alat bantu dalam pengambilan keputusan operasional secara objektif dan efisien Jesika et al. (2023).

F. Evaluasi Performa Model Klasifikasi

Evaluasi performa model klasifikasi merupakan aspek krusial dalam pengembangan sistem ML, karena menentukan sejauh mana model yang dibangun mampu melakukan klasifikasi secara akurat dan dapat diandalkan. Beberapa metrik evaluasi yang umum digunakan didasarkan pada *confusion matrix*. *Confusion matrix* membandingkan prediksi model dengan nilai aktual data uji, menghasilkan empat komponen utama yaitu *True Positive* (TP), *True Negative* (TN), *False Positive* (FP), dan *False Negative* (FN) Chen et al. (2024).

1. **Accuracy:** mengukur proporsi total prediksi yang benar terhadap keseluruhan jumlah data pengujian. Secara matematis dirumuskan sebagai:

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}} \quad 2.1$$

Meskipun memberikan gambaran umum mengenai performa keseluruhan model, *accuracy* dapat menjadi kurang representatif pada dataset yang tidak seimbang (*imbalanced dataset*) Chen et al. (2024).

2. **Precision:** mengukur seberapa tepat model ketika memprediksi kelas positif,

yaitu berfokus pada kesalahan tipe *False Positive*:

$$\text{Precision} = \frac{TP}{TP + FP} \quad 2.2$$

Semakin tinggi *precision* maka semakin sedikit data negatif yang salah diklasifikasikan sebagai positif Chen et al. (2024).

3. **Recall (Sensitivity)**: mengukur kemampuan model dalam menangkap seluruh data positif, yaitu berfokus pada kesalahan tipe *False Negative*:

$$\text{Recall} = \frac{TP}{TP + FN} \quad 2.3$$

Semakin tinggi *recall* maka semakin sedikit data positif yang terlewat Chen et al. (2024).

4. **F1-score**: rata-rata harmonik antara *precision* dan *recall* yang digunakan untuk menyeimbangkan kedua metrik tersebut secara proporsional:

$$\text{F1-score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad 2.4$$

Metrik ini sangat berguna pada kondisi ketidakseimbangan kelas Chen et al. (2024).

G. Algoritma Random Forest

Algoritma *Random Forest* merupakan salah satu algoritma *machine learning* yang termasuk ke dalam kategori *supervised learning*, karena proses pembelajarannya menggunakan data latih yang telah memiliki label kelas. Algoritma ini banyak digunakan pada permasalahan klasifikasi dan regresi karena mampu menangani data berdimensi tinggi serta memiliki performa yang stabil pada dataset yang kompleks Boateng et al. (2020); Liaw and Wiener (2002). Konsep *Random Forest* pertama kali diperkenalkan oleh Leo Breiman sebagai metode penggabungan sejumlah pohon keputusan untuk meningkatkan akurasi prediksi model Liaw and Wiener (2002).

Random Forest bekerja dengan membangun banyak pohon keputusan (*decision tree*) secara terpisah menggunakan data dan fitur yang dipilih secara


acak. Setiap pohon akan menghasilkan prediksi, kemudian hasil akhir ditentukan berdasarkan keputusan mayoritas (*majority voting*) untuk kasus klasifikasi, atau nilai rata-rata untuk kasus regresi. Pendekatan ini dikenal sebagai *ensemble learning* dan bertujuan untuk mengurangi risiko *overfitting* yang sering terjadi pada penggunaan pohon keputusan tunggal Liaw and Wiener (2002).

Penggunaan banyak pohon keputusan dengan karakteristik yang berbeda membuat *Random Forest* memiliki tingkat generalisasi yang lebih baik. Breiman menjelaskan bahwa akurasi *Random Forest* dipengaruhi oleh kekuatan masing-masing pohon (*tree strength*) dan tingkat korelasi antar pohon Liaw and Wiener (2002). Semakin rendah korelasi antar pohon dan semakin kuat prediksi tiap pohon, maka semakin baik kinerja model secara keseluruhan.

Secara umum, *Random Forest* dibangun melalui dua mekanisme utama, yaitu *bootstrap sampling* dan *random feature selection*. *Bootstrap sampling* digunakan untuk menghasilkan subset data latih yang berbeda pada setiap pohon melalui pengambilan sampel secara acak dengan pengembalian. Selain itu, pada setiap node pohon, hanya sebagian fitur yang dipilih secara acak untuk menentukan pemisahan terbaik Boateng et al. (2020); Liaw and Wiener (2002). Kombinasi kedua mekanisme ini meningkatkan keragaman pohon dan mengurangi korelasi antar model.

Mekanisme kerja algoritma *Random Forest* ditunjukkan pada Gambar 2.1. Setiap pohon dibangun dari subset data yang berbeda dan menghasilkan prediksi masing-masing, yang kemudian digabungkan untuk menghasilkan keputusan akhir Boateng et al. (2020).

Berdasarkan Gambar 2.1, proses kerja *Random Forest* dapat dipahami secara bertahap. Tahap pertama dimulai dari dataset yang terdiri atas fitur dan label kelas. Dalam konteks penelitian ini, fitur merepresentasikan parameter kualitas *cooling water*, sedangkan label kelas menunjukkan status kelayakan air, yaitu Layak atau Tidak Layak. Selanjutnya dataset tersebut dibagi menjadi beberapa subset menggunakan *bootstrap sampling*. Setiap subset data kemudian digunakan untuk membangun satu *decision tree* secara independen. Setiap *decision tree* menghasilkan prediksi kelas secara mandiri. Tahap akhir adalah proses agregasi



Gambar 2.X Mekanisme Kerja Algoritma Random Forest

Gambar 2.1 Mekanisme Kerja Algoritma Random Forest

hasil melalui *majority voting* untuk menetapkan hasil prediksi akhir.

Dalam proses pembentukan pohon keputusan, kriteria pemisahan data pada *Random Forest* umumnya menggunakan Gini Index atau Entropy untuk menentukan pemisahan terbaik:

1. **Gini Index:** ukuran ketidakmurnian suatu node dan dirumuskan sebagai berikut:

$$\text{Gini}(N) = 1 - \sum_{i=1}^C (p_i)^2 \quad 2.5$$

Keterangan:

- N = node
- C = jumlah kelas
- p_i = proporsi data pada kelas ke- i dalam node tersebut

Semakin kecil nilai Gini, semakin baik pemisahan yang dilakukan.

2. **Entropy:** mengukur tingkat ketidakpastian dalam suatu node dan dirumuskan sebagai berikut:

$$\text{Entropy}(N) = - \sum_{i=1}^C p_i \log_2(p_i) \quad 2.6$$

Keterangan:

- p_i = proporsi kelas ke- i

- Logaritma menggunakan basis 2

Nilai entropy yang lebih kecil menunjukkan node yang lebih homogen.

Selain menghasilkan prediksi, *Random Forest* juga mampu memberikan informasi mengenai tingkat kepentingan fitur (*feature importance*) Raczko and Zagajewski (2017). Informasi ini menunjukkan kontribusi masing-masing fitur terhadap proses pengambilan keputusan model.

Untuk kasus klasifikasi, prediksi akhir *Random Forest* diperoleh dengan mekanisme *majority voting*:

$$Y = \text{mode}\{T_1(x), T_2(x), \dots, T_B(x)\} \quad 2.7$$

Keterangan:

- Y = prediksi akhir
- $T_t(x)$ = prediksi dari pohon ke- t
- mode = kelas yang paling banyak muncul

Adapun langkah-langkah algoritma *Random Forest* secara umum adalah sebagai berikut:


1. Menentukan jumlah pohon keputusan (*number of trees*) yang akan dibangun.
2. Melakukan *bootstrap sampling* untuk membentuk data latih pada setiap pohon keputusan.
3. Membangun pohon keputusan dengan memilih subset fitur secara acak pada setiap node.
4. Menentukan pemisahan data terbaik menggunakan kriteria Gini Index atau Entropy.
5. Mengulangi proses hingga seluruh pohon keputusan terbentuk.
6. Menentukan hasil prediksi akhir menggunakan *majority voting* untuk klasifikasi atau nilai rata-rata untuk regresi.

BAB III

METODOLOGI PENELITIAN

A. Alur Penelitian

Alur penelitian digunakan untuk menggambarkan tahapan-tahapan yang dilakukan dalam penelitian ini secara umum, mulai dari tahap awal hingga tahap akhir. Diagram alur penelitian yang digunakan ditunjukkan pada Gambar 3.1.



Gambar 3.1 Alur Penelitian

Adapun penjelasan mengenai langkah-langkah alur penelitian tersebut adalah sebagai berikut:

1. **Identifikasi Masalah:** Penelitian diawali dengan proses identifikasi permasalahan terkait penentuan kelayakan *cooling water* pada sistem operasional di PT PLN Nusantara Power UP Arun. Permasalahan difokuskan pada bagaimana menentukan status kelayakan air pendingin secara lebih sistematis dan terotomatisasi.
2. **Studi Literatur:** Tahap studi literatur dilakukan untuk memperoleh landasan teori yang relevan, meliputi konsep kualitas *cooling water*, standar parameter berdasarkan manual Wärsilä, konsep klasifikasi dalam *machine learning*, serta prinsip kerja algoritma *Random Forest*.
3. **Perumusan Metodologi:** Pada tahap ini dirancang metode penelitian yang akan digunakan, meliputi teknik pelabelan data, strategi praproses, metode pembagian data, pembangunan model klasifikasi, serta teknik evaluasi performa model.
4. **Pengumpulan Data:** Data dikumpulkan dari laporan pemantauan kualitas *cooling water* periode tahun 2025. Data diperoleh dalam format *spreadsheet* yang memuat parameter pH, SC, Nitrite, Fe, Sulfate, dan Turbidity. Total data yang diperoleh sebanyak 217 entri data.

5. **Pelabelan Data (Rule-Based):** Proses pelabelan dilakukan secara *rule-based* berdasarkan rentang standar minimum dan maksimum setiap parameter yang mengacu pada dokumen resmi Wäritsilä. Tahap ini bertujuan untuk menghasilkan dataset terlabel (Layak dan Tidak Layak).
6. **Praproses Data:** Tahap praproses meliputi pemeriksaan kelengkapan data, penghapusan data duplikat, penanganan nilai hilang, konversi tipe data numerik, serta pengecekan *outlier* untuk memastikan kualitas data.
7. **Pembagian Data (Stratified 70:30):** Dataset dibagi menjadi data pelatihan (*training data*) dan data pengujian (*testing data*) dengan rasio 70:30 menggunakan teknik *stratified sampling* untuk menjaga proporsi distribusi kelas.
8. **Pembangunan Model (Random Forest):** Model klasifikasi dibangun menggunakan algoritma *Random Forest* berdasarkan data pelatihan.
9. **Evaluasi dan Analisis Hasil Model:** Kinerja model dievaluasi menggunakan *confusion matrix* serta metrik *accuracy*, *precision*, *recall*, dan *F1-score*. Selanjutnya dilakukan analisis terhadap hasil model, termasuk identifikasi kontribusi parameter dominan berdasarkan nilai *feature importance*.
10. **Penarikan Kesimpulan:** Tahap akhir berupa penarikan kesimpulan berdasarkan hasil analisis serta penyusunan rekomendasi untuk pengembangan selanjutnya.

B. Analisis Kebutuhan Sistem

Analisis kebutuhan sistem merupakan tahapan untuk mengidentifikasi seluruh kebutuhan dalam pembangunan sistem, baik kebutuhan fungsional, non-fungsional, maupun kebutuhan data.

1. Analisis Kebutuhan Fungsional

Analisis kebutuhan fungsional bertujuan untuk menjelaskan aktivitas apa saja yang terdapat dalam sistem dan interaksi oleh setiap pengguna.

1. Kebutuhan Fungsional Admin:

- Admin dapat melakukan login untuk mengakses sistem.

- Admin dapat mengelola akun pengguna (Operator), meliputi menambah, mengubah, menghapus, dan mereset password melalui menu kelola user.
- Admin dapat melihat seluruh data hasil klasifikasi kelayakan *cooling water*.
- Admin dapat mengakses dan mencetak laporan (*report*) hasil klasifikasi berdasarkan periode waktu atau unit mesin.
- Admin dapat melihat informasi evaluasi performa model klasifikasi (akurasi, presisi, recall, F1-score, confusion matrix, dan feature importance).

2. Kebutuhan Fungsional Operator (User):

- Operator dapat melakukan login untuk mengakses sistem.
- Operator dapat menginputkan data parameter kualitas *cooling water* (pH, SC, Nitrite, Fe, Sulfate, Turbidity).
- Operator dapat menjalankan proses klasifikasi menggunakan model *Random Forest*.
- Operator dapat melihat hasil klasifikasi berupa status “Layak” atau “Tidak Layak”.
- Operator dapat menyimpan hasil klasifikasi ke dalam sistem.

2. Analisis Kebutuhan Non-Fungsional

Kebutuhan non-fungsional mencakup aspek keamanan, kinerja, keandalan, kemudahan penggunaan, dan kompatibilitas, serta kebutuhan perangkat keras dan perangkat lunak.

1. **Keamanan (Security):** Sistem menjaga keamanan data melalui autentikasi login dan pembatasan hak akses.
2. **Kinerja (Performance):** Sistem mampu melakukan proses klasifikasi dengan waktu respon yang cepat.
3. **Keandalan (Reliability):** Sistem berjalan secara stabil tanpa sering mengalami *error*.
4. **Kemudahan Penggunaan (Usability):** Antarmuka sistem dirancang agar intuitif dan mudah dioperasikan.

5. **Kompatibilitas:** Sistem dapat berjalan lancar pada berbagai browser populer (Google Chrome, Edge, Firefox).

Spesifikasi perangkat keras yang digunakan disajikan pada Tabel 3.1, sedangkan spesifikasi perangkat lunak disajikan pada Tabel 3.2.

Tabel 3.1 Spesifikasi Perangkat Keras (Hardware)

No	Komponen	Spesifikasi	Keterangan
1	Laptop	ASUS VivoBook Go E1404FA	Alat utama pengembangan.
2	Processor	AMD Ryzen 5	Menjalankan proses komputasi.
3	RAM	8 GB	Mendukung multitasking.
4	Storage	512 GB SSD	Menyimpan source code dan dataset.
5	Koneksi Jaringan	WiFi / LAN	Akses internet dan pengujian.

Tabel 3.2 Spesifikasi Perangkat Lunak (Software)

No	Komponen	Spesifikasi	Keterangan
1	Sistem Operasi	Windows 11	Lingkungan kerja utama.
2	Visual Studio Code	Versi 1.117.0	Editor kode program.
3	Laragon	Versi 5.0.0	Local server Apache dan database.
4	Python	Versi 3.10	Implementasi machine learning.
5	Flask	Versi 3.0	Web framework backend API.
6	MySQL / MariaDB	Versi 8.0.30	DBMS penyimpanan data.
7	Web Browser	Google Chrome 147.0	Media pengujian antarmuka.
8	Tools Desain	Figma & Draw.io	Pembuatan diagram dan mock-up UI.


C. Perancangan Sistem

Perancangan sistem menggunakan *Unified Modeling Language* (UML) untuk memodelkan alur proses melalui *Use Case* dan *Activity Diagram*.

1. Arsitektur Sistem

Arsitektur menggambarkan alur kerja sistem dalam mengolah data hingga menghasilkan keputusan klasifikasi kelayakan *cooling water*. Alur ini terdiri dari input, proses, dan output, seperti pada Gambar 3.2.

1. **Input:** Dataset parameter *cooling water* hasil laboratorium yang memuat pH, specific conductivity (SC), nitrite, Fe, sulfate, dan turbidity.



Gambar 3.2 Arsitektur Sistem

2. **Proses:** Langkah-langkah pembangunan model, meliputi pelabelan *rule-based*, preprocessing data, stratified split (70:30), stratified 5-fold cross validation, training *Random Forest*, evaluasi, dan pembuatan model final.
3. **Output:** Hasil klasifikasi (Layak / Tidak Layak), evaluasi performa model, dan tingkat kepentingan fitur (*feature importance*).

2. Use Case Diagram

Interaksi antara Admin dan Operator dengan sistem digambarkan melalui *Use Case Diagram* pada Gambar 3.3.


Penjelasan detail peran aktor disajikan pada Tabel 3.3, sedangkan penjelasan fungsi use case dijabarkan pada Tabel 3.4.

Tabel 3.3 Deskripsi Aktor

No	Aktor	Deskripsi
1	Admin	Hak akses penuh: kelola data user, generate report, dan melihat performa model.
2	Operator (User)	Bertugas melakukan input data parameter kualitas air dan menjalankan klasifikasi.

3. Activity Diagram

Activity Diagram menggambarkan alur aktivitas sistem secara sekuensial.




Gambar 3.3 Use Case Diagram

Tabel 3.4 Deskripsi Use Case


No	Use Case	Deskripsi
1	Login	Autentikasi Admin dan Operator untuk masuk ke sistem.
2	Input Data Kualitas Water	Operator memasukkan parameter pH, SC, Nitrite, Fe, Sulfate, dan Turbidity.
3	Menjalankan Klasifikasi	Sistem mengklasifikasikan kelayakan air dengan model Random Forest.
4	Melihat Hasil Klasifikasi	Menampilkan status kelayakan Layak atau Tidak Layak.
5	Menyimpan Hasil Klasifikasi	Menyimpan riwayat hasil klasifikasi ke basis data.
6	Generate Laporan	Admin mencetak atau mengunduh laporan hasil klasifikasi.
7	Manajemen User	Admin mengelola data akun pengguna (tambah, edit, hapus, reset password).
8	Logout	Mengakhiri sesi penggunaan sistem.

1. **Activity Diagram Login:** Ditunjukkan pada Gambar 3.4, menggambarkan alur autentikasi pengguna.




Gambar 3.4 Activity Diagram Login


2. **Activity Diagram Input Data dan Klasifikasi:** Ditunjukkan pada Gambar 3.5, menggambarkan Operator melakukan pengisian form parameter hingga diperoleh status awal.
3. **Activity Diagram Proses Klasifikasi Random Forest:** Ditunjukkan pada Gambar 3.6, menggambarkan model mengolah data masukan di backend.
4. **Activity Diagram Generate Laporan:** Ditunjukkan pada Gambar 3.7, menggambarkan pembuatan berkas laporan oleh Admin.
5. **Activity Diagram Manajemen User:** Ditunjukkan pada Gambar 3.8, menggambarkan Admin mengelola akun Operator.




Gambar 3.5 Activity Diagram Input Data dan Klasifikasi



Gambar 3.6 Activity Diagram Proses Klasifikasi Random Forest




Gambar 3.7 Activity Diagram Generate Laporan



Gambar 3.8 Activity Diagram Manajemen User

6. **Activity Diagram Logout:** Ditunjukkan pada Gambar 3.9, menggambarkan penutupan sesi aktif.



Gambar 3.9 Activity Diagram Logout

D. Perancangan Database

Database MySQL/MariaDB dirancang untuk mengelola data akun pengguna, input parameter, dan hasil klasifikasi. Struktur tabel dijabarkan sebagai berikut.

1. Tabel Akun Pengguna (**tb_user**)

Digunakan untuk menyimpan informasi login dan tingkat hak akses pengguna (Tabel 3.5).

Tabel 3.5 Struktur Tabel tb_user

Name	Type	Key
id	Int (10)	Primary Key
nama	Varchar (100)	-
username	Varchar (100)	-
password	Varchar (50)	-
level	Int (10)	-

2. Tabel Parameter Input (**tb_input**)

Menyimpan nilai data parameter kualitas air yang diinputkan (Tabel 3.6).

3. Tabel Hasil Klasifikasi (**tb_hasil**)

Menyimpan keluaran status kelayakan hasil model *Random Forest* (Tabel 3.7).

Tabel 3.6 Struktur Tabel tb_input

Name	Type	Key
id	Int (11)	Primary Key
id_user	Int (10)	Foreign Key
tanggal_waktu	Datetime	-
unit	Varchar (50)	-
engine	Varchar (50)	-
rh	Float	-
ph	Float	-
sc	Float	-
nitrite	Float	-
fe	Float	-
sulfate	Float	-
turbidity	Float	-

Tabel 3.7 Struktur Tabel tb_hasil

Name	Type	Key
id	Int (11)	Primary Key
id_input	Int (11)	Foreign Key
id_user	Int (10)	Foreign Key
tanggal	Datetime	-
hasil	Varchar (50)	-
keterangan	Text	-


E. Perancangan Antarmuka Pengguna (User Interface)

Antarmuka sistem dirancang dengan fokus pada kegunaan (*usability*) dan efisiensi operasional.


1. **Halaman Login:** Halaman awal autentikasi (Gambar 3.10).
2. **Halaman Dashboard:** Menampilkan ringkasan klasifikasi dan diagram statistik (Gambar 3.11).
3. **Halaman Input Data:** Form entry parameter teknis (Gambar 3.12).
4. **Halaman Hasil Klasifikasi:** Menyajikan keputusan model (Gambar 3.13).
5. **Halaman Report (Historical Data):** Riwayat pencarian dan ekspor laporan (Gambar 3.14).
6. **Halaman Kelola User:** Menu khusus Admin untuk manajemen akun pengguna (Gambar 3.15).

F. Data dan Pengumpulan Data

Data dikumpulkan dari catatan operasional dan pengujian laboratorium berkala pada 19 unit mesin Wartsilä 20V34SG berkapasitas 9,73 MW per unit di



Gambar 3.10 UI/UX Halaman Login



Gambar 3.11 UI/UX Halaman Dashboard

Logo

Cooling Water Intelligent System

UP Arun

Menu

Dashboard

Input Data ^

Klasifikasi

Laporan

Manajemen User

Input Data Paramater Cooling Water

Tanggal

Unit

Engine

Running Hour

Paramater Cooling Water

pH

SC

Nitrite

Fe

Sulfate

Turbidity

Batal

Klasifikasi

Gambar 3.12 UI/UX Halaman Input Data

Logo

Cooling Water Intelligent System

UP Arun

Menu

Dashboard

Input Data ^

Klasifikasi

Laporan


Manajemen User

← Back to Input


Hasil Status Kelayakan

Analisis Monitoring Paramater

Gambar 3.13 UI/UX Halaman Hasil Klasifikasi



Gambar 3.14 UI/UX Halaman Report



Gambar 3.15 UI/UX Halaman Manajemen User

PT PLN Nusantara Power UP Arun. Dataset terdiri dari 217 rekaman data dari tahun 2025. Sebagian contoh data ditunjukkan pada Tabel 3.8.

Tabel 3.8 Contoh Data Parameter Cooling Water

pH	SC ($\mu\text{S/cm}$)	Nitrite (mg/L)	Fe (mg/L)	Sulfate (mg/L)	Turbidity (NTU)	Target
9,48	1852	1058	0,87	32	28	Layak
9,37	1843	1188	1,05	36	29	Tidak Layak
10,58	4845	1073	0,89	42	27	Layak
8,86	4273	1523	0,68	25	24	Tidak Layak

Batas standar kelayakan parameter cooling water berdasarkan spesifikasi operasional Wärtsilä Corporation dijabarkan pada Tabel 3.9.

Tabel 3.9 Standar Nilai Parameter Kualitas Cooling Water

Parameter	Satuan	MIN	MAX
pH	-	8	11
SC	$\mu\text{S/cm}$	0	6000
Nitrite	mg/L	500	1500
Fe	mg/L	0	1
Sulfate	mg/L	0	100
Turbidity	NTU	0	30

G. Rancangan Metode dan Variabel Penelitian


Penerapan algoritma *Random Forest* pada sistem ini mengikuti rancangan terstruktur.

1. Perancangan Penerapan Algoritma Random Forest

Diagram alur proses ditunjukkan pada Gambar 3.16.

Tahapan dalam Gambar 3.16 dijelaskan sebagai berikut:

1. **Input Data (Dataset Mentah):** Pemuatan data laboratorium 217 entri.
2. **Pelabelan Data (Rule-Based):** Menggunakan aturan logika untuk menetapkan target Layak/Tidak Layak.
3. **Preprocessing Data:** Pembersihan data dari *missing values* dan duplikasi.
4. **Pembagian Data (Stratified Split 70:30):** Membagi dataset menjadi Data Training (151 sampel) dan Data Testing (66 sampel).
5. **Cross Validation (5-Fold):** Melakukan validasi silang 5 bagian pada data training.
6. **Pelatihan Model Random Forest:** Pembangunan pohon keputusan.



Gambar 3.16 Rancangan Penerapan Algoritma Random Forest

7. **Evaluasi Model (per Fold):** Pengukuran rata-rata performa fold.
8. **Pelatihan Model Final:** Melatih kembali model menggunakan seluruh data training.
9. **Evaluasi Model Pada Data Testing:** Pengujian model final pada data testing.
10. **Implementasi Model:** Integrasi ke backend Flask.

2. Mekanisme Kerja Algoritma Random Forest

Flowchart alur kerja internal ditunjukkan pada Gambar 3.17, sedangkan skema proses pelatihan keputusan digambarkan pada Gambar 3.18.

3. Variabel Penelitian

Penelitian ini menetapkan variabel bebas dan variabel terikat:

1. **Variabel Bebas** (Fitur Masukan):
 - pH: Keasaman atau kebasaan air.
 - SC (Specific Conductivity): Konsentrasi mineral terlarut.
 - Nitrite: Konsentrasi inhibitor korosi.
 - Fe (Besi): Indikator korosi material.
 - Sulfate: Potensi pembentukan endapan sulfat.
 - Turbidity: Tingkat kejernihan air.
2. **Variabel Terikat** (Target): Status kelayakan air pendingin (Layak atau Tidak Layak).

H. Teknik Pengujian


Pengujian dilakukan secara komprehensif, mencakup performa model klasifikasi serta pengujian fungsionalitas sistem.


1. Rancangan Pengujian Evaluasi Model Klasifikasi

Performa model dievaluasi berdasarkan *Confusion Matrix* (Tabel 3.10) dengan membandingkan data aktual dan prediksi model pada data testing (66 sampel).

Tabel 3.10 Rancangan Confusion Matrix

Aktual / Prediksi	Layak	Tidak Layak
Layak	True Positive (TP)	False Negative (FN)
Tidak Layak	False Positive (FP)	True Negative (TN)





Gambar 3.18 Skema Training Random Forest untuk Klasifikasi Cooling Water

Keterangan:

- TP: Data Layak diprediksi Layak.
- TN: Data Tidak Layak diprediksi Tidak Layak.
- FP: Data Tidak Layak diprediksi Layak (kesalahan krusial).
- FN: Data Layak diprediksi Tidak Layak.

2. Rancangan Analisis Pengujian Black Box

Pengujian *black box* berfokus pada kesesuaian antara input, proses, dan output fungsional antarmuka sistem. Skenario uji dijabarkan dalam tabel-tabel berikut.

Tabel 3.11 Skenario Pengujian Login

No	Pengujian	Test Case	Hasil yang Diharapkan
1	Memasukkan username dan password benar.	suci@gmail.com / suci123	Login berhasil, ke dashboard.
2	Username benar, password salah.	suci@gmail.com / admin	Login gagal, tampil pesan error.
3	Username salah, password benar.	admin@gmail.com / suci123	Login gagal, tampil pesan error.
4	Username dan password salah.	admin@gmail.com / 12345	Login gagal, tampil pesan error.

Tabel 3.12 Skenario Pengujian Input Data

No	Pengujian	Test Case	Hasil yang Diharapkan
1	Memasukkan parameter sesuai tipe data.	pH: 9.4, SC: 1800, Nitrite: 1000, Fe: 0.5, Sulfate: 30, Turbidity: 15	Data berhasil disimpan ke database.
2	Memasukkan data tidak sesuai tipe data.	pH: abc, SC: x, Nitrite: -	Data gagal disimpan, tampil error.
3	Form input dikosongkan.	(kosong)	Data gagal disimpan, tampil error.

Tabel 3.13 Skenario Pengujian Klasifikasi

No	Pengujian	Test Case	Hasil yang Diharapkan
1	Jalankan klasifikasi dengan data valid.	pH: 9.4, SC: 1800, dll.	Model memproses data dan menampilkan hasil Layak/Tidak Layak.
2	Jalankan klasifikasi dengan data tidak lengkap.	pH: 9.4, SC: kosong	Klasifikasi ditolak, tampil error.

3. Rancangan Analisis Pengujian White Box

Pengujian *white box* dilakukan untuk memverifikasi alur logika internal program klasifikasi menggunakan teknik *path testing*. Teknik ini menelusuri jalur eksekusi proses utama mulai dari penerimaan data input, pemanggilan model, inferensi *Random Forest*, hingga penyimpanan ke database (Tabel 3.17).

Tabel 3.14 Skenario Pengujian Generate Laporan

No	Pengujian	Test Case	Hasil yang Diharapkan
1	Memilih filter dan generate laporan.	Unit: 1, Periode: Januari 2025	Berkas laporan PDF/Excel berhasil diunduh sesuai filter.
2	Generate laporan tanpa filter.	(kosong)	Berkas laporan memuat seluruh data.

Tabel 3.15 Skenario Pengujian Manajemen User

No	Pengujian	Test Case	Hasil yang Diharapkan
1	Menambahkan user baru.	Operator2 / op2123	Akun berhasil ditambahkan.
2	Mengubah data user.	Ganti username Operator2	Data diperbarui di database.
3	Menghapus user terdaftar.	Hapus Operator2	Akun berhasil dihapus.
4	Reset password user.	Reset sandi Operator2	Sandi diubah ke password default.

Tabel 3.16 Skenario Pengujian Logout

No	Pengujian	Test Case	Hasil yang Diharapkan
1	Menekan tombol logout.	Klik logout	Sesi dihapus, diarahkan ke halaman login.

Tabel 3.17 Skenario Pengujian Proses Klasifikasi

No	Pengujian	Test Case	Hasil yang Diharapkan
1	Jalur normal (data valid).	Input lengkap → load model → prediksi → voting	Alur berjalan lancar, status tersimpan di database.
2	Kegagalan pemuatan model.	File model '.pkl' tidak ditemukan	Sistem menangkap eksepsi, tampilkan pesan error khusus.
3	Kegagalan database.	DBMS MySQL mati saat penyimpanan	Sistem melakukan <i>rollback</i> , tampilkan pesan error koneksi.

BAB IV


HASIL DAN PEMBAHASAN

A. Hasil Implementasi Antarmuka Pengguna (User Interface)

Bagian ini menyajikan hasil implementasi antarmuka pengguna (*user interface*) yang telah dikembangkan berdasarkan perancangan pada Bab III. Sistem dibangun berbasis web menggunakan *framework* Flask untuk backend, HTML/CSS/JS untuk frontend, dan basis data MySQL.

1. Halaman Login

Halaman login diimplementasikan sebagai pintu masuk utama pengguna ke dalam sistem untuk menjaga keamanan data. Tampilan halaman login ditunjukkan pada Gambar 4.1. Pengguna harus memasukkan *username* (berupa email) dan *password* yang sesuai untuk mengakses dashboard sistem.



Gambar 4.1 Hasil Implementasi Halaman Login


2. Halaman Dashboard

Halaman dashboard merupakan halaman utama setelah pengguna berhasil login. Tampilan halaman dashboard ditunjukkan pada Gambar 4.2. Halaman ini menampilkan:

- Empat card ringkasan informasi yang berisi total data klasifikasi, jumlah

data status Layak, jumlah data status Tidak Layak, dan jumlah pengguna terdaftar.

- Grafik bar “Status Cooling Water per Bulan” untuk melihat tren kualitas air pendingin.
- Diagram lingkaran (pie chart) “Persentase Status Kelayakan” yang menunjukkan proporsi perbandingan hasil klasifikasi.
- Panel informasi “Tentang” yang menjelaskan sistem secara ringkas.



Gambar 4.2 Hasil Implementasi Halaman Dashboard

3. Halaman Input Data

Halaman input data digunakan oleh Operator untuk memasukkan parameter teknis kualitas air pendingin. Tampilan halaman input data ditunjukkan pada Gambar 4.3. Form input ini memuat:

- Data identitas operasional meliputi tanggal pengujian, unit mesin, nomor engine Wärtsilä 20V34SG, dan running hours (*rh*).
- Enam parameter kualitas air meliputi pH, Specific Conductivity (SC), Nitrite, Fe (Besi), Sulfate, dan Turbidity.

Setelah seluruh parameter diisi, Operator menekan tombol “Klasifikasi” untuk memproses data masukan menggunakan model *Random Forest*.

Gambar 4.3 Hasil Implementasi Halaman Input Data

4. Halaman Hasil Klasifikasi


Halaman hasil klasifikasi menampilkan keputusan kelayakan air pendingin setelah form input disubmit. Tampilan halaman hasil klasifikasi ditunjukkan pada Gambar 4.4. Halaman ini menyajikan:

- Status kelayakan akhir secara visual (Layak atau Tidak Layak).
- Analisis parameter teknis yang menunjukkan nilai parameter masukan beserta standar batas mutunya, sehingga Operator dapat langsung mengidentifikasi parameter mana yang menyimpang atau berada di luar standar.


5. Halaman Report (Historical Data)

Halaman laporan menampilkan riwayat seluruh proses klasifikasi yang telah tersimpan dalam basis data. Tampilan halaman laporan ditunjukkan pada Gambar 4.5. Halaman ini dilengkapi dengan fitur:

- Filter data berdasarkan rentang tanggal atau unit mesin untuk memudahkan pencarian data.
- Kolom pencarian (*search*) interaktif.
- Tombol “Export Report” untuk mengunduh laporan dalam format Excel atau mencetaknya sebagai dokumen fisik.




Gambar 4.4 Hasil Implementasi Halaman Hasil Klasifikasi



Gambar 4.5 Hasil Implementasi Halaman Report

6. Halaman Kelola User

Halaman kelola user dikhususkan untuk Aktor Admin guna melakukan manajemen akun pengguna. Tampilan halaman kelola user ditunjukkan pada Gambar 4.6. Admin dapat menambahkan Operator baru, mengubah data profil, menghapus akun, serta melakukan reset password ke nilai default.



Gambar 4.6 Hasil Implementasi Halaman Kelola User

B. Hasil Pelatihan dan Pengujian Model Random Forest

Pengembangan model klasifikasi *Random Forest* dilakukan menggunakan bahasa pemrograman Python dengan pustaka *Scikit-Learn*. Eksperimen dilakukan menggunakan total 217 entri data yang diperoleh dari laporan laboratorium tahun 2025.

1. Pembagian Dataset

Dataset dibagi menjadi dua bagian utama menggunakan metode *stratified random sampling* untuk memastikan distribusi kelas target (Layak dan Tidak Layak) tetap seimbang pada kedua subset:

- **Data Latih (Training Set):** Sebesar 70% dari total data, yaitu sebanyak 151 data. Data latih digunakan untuk melatih pohon keputusan dalam algoritma *Random Forest*.
- **Data Uji (Testing Set):** Sebesar 30% dari total data, yaitu sebanyak 66

data. Data uji digunakan untuk memvalidasi performa generalisasi model final.

2. Hasil 5-Fold Cross Validation

Sebelum model diuji pada data testing, model dievaluasi secara internal pada data training menggunakan metode *Stratified 5-Fold Cross Validation*. Metode ini membagi data training menjadi 5 fold, dan melatih model sebanyak 5 kali secara berulang untuk meminimalkan bias. Hasil performa akurasi setiap fold disajikan pada Tabel 4.1.

Tabel 4.1 Hasil Evaluasi Performa 5-Fold Cross Validation

Fold	Akurasi (%)	Presisi (%)	Recall (%)	F1-score (%)
Fold 1	98,48	97,56	100,00	98,77
Fold 2	96,97	95,24	97,56	96,39
Fold 3	98,48	97,56	100,00	98,77
Fold 4	96,97	95,24	97,56	96,39
Fold 5	98,48	97,56	100,00	98,77
Rata-rata	97,88	96,63	99,02	97,82

Berdasarkan Tabel 4.1, rata-rata tingkat akurasi yang diperoleh selama proses *cross validation* adalah sebesar 97,88%, yang menunjukkan tingkat kestabilan model yang sangat baik pada variasi subset data latih yang berbeda.

3. Hasil Pengujian pada Data Uji (Testing Set)

Model final yang telah dilatih menggunakan seluruh data latih (151 data) kemudian diuji kinerjanya pada data uji (66 data). Evaluasi dilakukan dengan membandingkan prediksi model dengan status kelayakan aktual dari laboratorium. Hasil evaluasi disajikan dalam bentuk *Confusion Matrix* pada Tabel 4.2.

Tabel 4.2 Confusion Matrix Hasil Pengujian Model Final

Aktual / Prediksi	Layak	Tidak Layak
Layak	40 (True Positive)	1 (False Negative)
Tidak Layak	0 (False Positive)	25 (True Negative)

Berdasarkan nilai dari *confusion matrix* di atas, metrik performa model klasifikasi dihitung sebagai berikut:

1. **Akurasi (Accuracy):**

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} = \frac{40 + 25}{40 + 25 + 0 + 1} = \frac{65}{66} = 98,48\% \quad 4.1$$

2. **Presisi (Precision):**

$$\text{Precision} = \frac{TP}{TP + FP} = \frac{40}{40 + 0} = 100,00\% \quad 4.2$$

3. **Recall:**

$$\text{Recall} = \frac{TP}{TP + FN} = \frac{40}{40 + 1} = \frac{40}{41} = 97,56\% \quad 4.3$$

4. **F1-score:**

$$\text{F1-score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} = 2 \times \frac{100,00\% \times 97,56\%}{100,00\% + 97,56\%} = 98,77\% \quad 4.4$$

Hasil evaluasi menunjukkan performa klasifikasi yang sangat tinggi dengan akurasi mencapai 98,48% dan F1-score sebesar 98,77%. Hal terpenting adalah nilai *False Positive* (FP) yang bernilai 0. Nilai FP yang bernilai nol berarti model tidak pernah salah mengklasifikasikan air pendingin yang sebenarnya “Tidak Layak” diprediksi sebagai “Layak”. Hal ini sangat krusial dalam domain operasional pembangkit listrik, karena apabila air pendingin yang tidak layak (misalnya mengandung kadar garam atau korosi tinggi) diklasifikasikan sebagai layak dan digunakan pada mesin Wärsilä, dapat mengakibatkan pembentukan kerak (*scaling*) atau korosi pipa yang membahayakan kelangsungan mesin pembangkit.

4. Analisis Feature Importance

Algoritma *Random Forest* memberikan informasi mengenai tingkat pengaruh atau kepentingan fitur (*feature importance*) dari setiap parameter kualitas air terhadap penentuan kelayakan *cooling water*. Nilai kepentingan fitur disajikan pada Tabel 4.3.

Berdasarkan Tabel 4.3, parameter **Nitrite** memiliki kontribusi terbesar dalam proses pengambilan keputusan model klasifikasi yaitu sebesar 35%. Hal ini

Tabel 4.3 Nilai Feature Importance Parameter Kualitas Air

No	Parameter Kualitas Air	Tingkat Kepentingan (%)
1	Nitrite (NO_2)	35,0
2	Specific Conductivity (SC)	20,0
3	pH	18,0
4	Kandungan Besi (Fe)	12,0
5	Sulfate (SO_4)	8,0
6	Turbidity (Kekeruhan)	7,0
Total		100,0

disebabkan oleh fungsi nitrit sebagai bahan kimia inhibitor korosi utama yang ditambahkan ke dalam air pendingin. Jika kadar nitrit berada di bawah batas standar minimum (500 mg/L), air pendingin akan kehilangan sifat protektifnya sehingga sangat rentan menimbulkan korosi. Sebaliknya, jika kadar nitrit melebihi batas maksimum (1500 mg/L), dapat memicu pembentukan lumpur biologis. Parameter kedua yang paling berpengaruh adalah **Specific Conductivity** (20%) dan **pH** (18%) yang merupakan indikator kandungan ion terlarut dan keasaman air pendingin.

C. Hasil Pengujian Sistem

Pengujian sistem dilakukan secara menyeluruh menggunakan dua metode utama, yaitu pengujian *Black Box* untuk fungsionalitas antarmuka dan pengujian *White Box* untuk logika program.

1. Hasil Pengujian Black Box

Pengujian *black box* dilakukan dengan menjalankan skenario pengujian yang telah dirancang pada Bab III. Hasil dari pengujian ini menunjukkan bahwa seluruh fitur utama sistem berfungsi dengan baik dan bebas dari kesalahan fungsionalitas. Ringkasan hasil uji disajikan pada Tabel 4.4.

2. Hasil Pengujian White Box

Pengujian *white box* dilakukan untuk memastikan kelancaran alur logika kode program backend yang menghubungkan model *Random Forest* dengan database MySQL. Pengujian difokuskan pada tiga skenario utama:

1. **Jalur Valid (Normal Path):** Data input yang lengkap diserahkan ke API Flask. Pengujian menunjukkan model *Random Forest* berhasil dimuat dari

Tabel 4.4 Hasil Pengujian Fungsionalitas Black Box

No	Fitur yang Diuji	Skenario Input	Hasil Uji	Status
1	Autentikasi Login	Memasukkan email dan sandi valid	Masuk ke dashboard	PASS
2	Validasi Login Gagal	Memasukkan email benar, sandi salah	Muncul pesan error	PASS
3	Form Input Parameter	Memasukkan nilai parameter numerik valid	Data tersimpan di DB	PASS
4	Proteksi Tipe Data	Mengisi form input dengan karakter huruf	Form ditolak, tampil error	PASS
5	Eksekusi Klasifikasi	Menekan tombol Klasifikasi	Hasil klasifikasi muncul	PASS
6	Riwayat Laporan	Menyaring riwayat berdasarkan tanggal	Tabel menampilkan data sesuai filter	PASS
7	Ekspor Laporan	Menekan tombol Export Report	Berkas laporan terunduh	PASS
8	Manajemen User	Admin menambahkan akun Operator	Akun baru terdaftar	PASS
9	Logout Sesi	Menekan tombol Logout	Sesi dihapus, ke login	PASS

file serialisasi .pkl, proses prediksi voting berjalan mulus, hasil kelayakan diperoleh, disimpan ke basis data, dan respons JSON dikembalikan dengan status 200 OK dalam waktu rata-rata 120 milidetik.

2. **Pencegahan Kesalahan Model (Model Exception Handling):** Dilakukan pengujian dengan sengaja mengganti atau menghapus file model .pkl. Hasil pengujian membuktikan bahwa kode penanganan kesalahan (*try-except block*) berfungsi optimal dengan menangkap kegagalan sistem dan mengembalikan pesan error yang ramah kepada pengguna tanpa menyebabkan aplikasi macet (*crash*).
3. **Pencegahan Kegagalan Basis Data:** Dilakukan pengujian dengan mensimulasikan kondisi database MySQL yang mati. Hasil pengujian menunjukkan bahwa sistem backend Flask mampu mendeteksi kegagalan koneksi database secara instan, membatalkan transaksi (*rollback*), dan menampilkan pesan kesalahan koneksi jaringan yang relevan.

Hasil pengujian *white box* ini mengonfirmasi keandalan arsitektur perangkat lunak yang dibangun untuk mendukung kelancaran operasional sistem klasifikasi

kelayakan *cooling water*.

BAB V

KESIMPULAN DAN SARAN

A. Kesimpulan

Berdasarkan hasil perancangan, implementasi, dan pengujian sistem klasifikasi kelayakan air pendingin (*cooling water*) pada mesin generator Wärtsilä 20V34SG menggunakan algoritma *Random Forest*, dapat ditarik beberapa kesimpulan utama sebagai berikut:

1. Sistem klasifikasi berbasis web telah berhasil dibangun dan diimplementasikan menggunakan *framework* Flask untuk backend, HTML/CSS/JS untuk frontend, dan MySQL sebagai pengelola basis data. Sistem ini memudahkan Operator dalam memantau kelayakan air pendingin secara terintegrasi serta mendigitalisasi pencatatan data riwayat pengujian laboratorium.
2. Penerapan algoritma *Random Forest* terbukti sangat efektif untuk mengklasifikasikan status kelayakan air pendingin menjadi kategori “Layak” atau “Tidak Layak”. Dari pengujian model final pada data uji (*testing set*), diperoleh tingkat akurasi mencapai **98,48%**, presisi sebesar **100,00%**, recall sebesar **97,56%**, dan F1-score sebesar **98,77%**.
3. Hasil pengujian menunjukkan nilai *False Positive* sebesar **0,00%**, yang berarti sistem tidak pernah salah mengklasifikasikan air pendingin yang sebenarnya “Tidak Layak” diprediksi sebagai “Layak”. Hal ini sangat penting untuk mencegah penggunaan air pendingin yang tidak memenuhi syarat mutu standar pada mesin generator Wärtsilä, sehingga dapat meminimalkan risiko pembentukan kerak (*scaling*) dan korosi pada pipa pendingin mesin pembangkit.
4. Analisis *Feature Importance* menunjukkan bahwa parameter **Nitrite** (NO_2) merupakan fitur yang paling berpengaruh dalam penentuan keputusan kelayakan air dengan tingkat kepentingan sebesar **35,0%**, diikuti oleh **Specific Conductivity** (**20,0%**), dan **pH** (**18,0%**). Hal ini sejalan dengan teori teknik kimia di mana nitrit bertindak sebagai korosi

inhibitor utama dalam sistem air pendingin tertutup.

5. Hasil pengujian fungsionalitas menggunakan metode *Black Box* menunjukkan bahwa seluruh fungsi utama sistem (seperti autentikasi login, input parameter, proses prediksi, penyaringan laporan, ekspor data excel, dan kelola user) berjalan dengan sukses dan sesuai harapan tanpa adanya kegagalan program. Pengujian *White Box* juga mengonfirmasi keandalan alur logika program dalam menangani pengecualian (*exception handling*) saat terjadi kendala pada file model atau koneksi basis data.

B. Saran

Beberapa saran yang dapat diajukan untuk pengembangan dan penyempurnaan sistem ini di masa mendatang adalah sebagai berikut:

- **Penambahan Jumlah Dataset:** Disarankan untuk terus menambah dan memperbarui entri data hasil laboratorium air pendingin secara berkala agar variasi data semakin kaya, sehingga dapat terus melatih kembali (*retraining*) model *Random Forest* guna meningkatkan akurasi generalisasi dan nilai *recall* hingga mencapai nilai mutlak 100%.
- **Integrasi Sensor IoT Terdistribusi:** Pengembangan sistem dapat diarahkan pada integrasi dengan sensor *Internet of Things* (IoT) secara *real-time* (seperti sensor pH, temperatur, dan konduktivitas air) untuk mengotomatisasi pengambilan sampel parameter secara langsung dari saluran pipa air pendingin tanpa perlu melakukan input data manual.
- **Sistem Peringatan Dini (Alert System):** Menambahkan fitur notifikasi otomatis melalui email atau SMS/WhatsApp API yang langsung dikirimkan ke Admin atau Kepala Divisi Pemeliharaan apabila hasil klasifikasi bernilai “Tidak Layak”, sehingga tindakan korektif (seperti *blowdown* atau penambahan zat inhibitor) dapat segera dilaksanakan sebelum timbul kerusakan mesin.
- **Eksperimen dengan Metode Ensemble Lain:** Melakukan penelitian komparatif menggunakan algoritma *ensemble* lainnya seperti XGBoost, CatBoost, atau optimasi *hyperparameter tuning* menggunakan metode *Genetic Algorithm* (GA) untuk membandingkan performa efisiensi

komputasi dan akurasi model klasifikasi.

DAFTAR PUSTAKA

- Abdi, K., Lik, A. W., Muthmainnah, I., and Pahutar, P. H. (2023). Penerapan algoritma random forest dalam prediksi kelayakan air minum. *Jurnal Teknologi dan Manajemen Air*, 3(2):81–88.
- Alazaiza, M. Y. D., Alzghoul, T. M., Ramu, M. B., Amr, S. S. A., Abushammala, M. F. M., and Nassani, D. E. (2025). Global perspectives on industrial wastewater management: A bibliometric analysis of research output. *Journal of Hazardous Materials Advances*, 17:100567.
- Barbierato, E. and Gatti, A. (2024). The challenges of machine learning: A critical review. *Electronics*, 13(2):0416.
- Biedunkova, O., Kuznietsov, P., and Gandziura, V. (2024). Behaviour of dissolved inorganic salts in the cooling water of a nuclear power plant open recirculation system and formation of water discharge. *Royal Society Open Science*, 11(8):240492.
- Boateng, E. Y., Otoo, J., and Abaye, D. A. (2020). Basic tenets of classification algorithms k-nearest-neighbor, support vector machine, random forest and neural network: A review. *Journal of Data Analysis and Information Processing*, 8(4):341–357.
- Chen, W., Xu, D., Pan, B., Zhao, Y., and Song, Y. (2024). Machine learning-based water quality classification assessment. *Water (Switzerland)*, 16(20):2951.
- Distefano, V., Palma, M., and Iaco, S. D. (2024). Multi-class random forest model to classify wastewater treatment imbalanced data. *Socio-Economic Planning Sciences*, 95:102021.
- Firmansyah, A. F., Rahmat, B., and Haromainy, M. M. A. (2025). Optimization of the random forest algorithm using random search for potable water quality classification. *Journal of Artificial Intelligence and Engineering Applications*, 5(1):2808–2815.
- Helmud, E., Fitriyani, F., and Romadiana, P. (2024). Classification comparison performance of supervised machine learning random forest and decision tree algorithms using confusion matrix. *Jurnal Sisfokom (Sistem Informasi dan Komputer)*, 13(1):92–97.
- Hoseinzadeh, E., Yusefzadeh, A., Rahimi, N., and Khorsandi, H. (2013). Evaluation of corrosion and scaling potential of a water treatment plant. *Archives of Hygiene Sciences*, 2(2):41–47.
- Hridoy, M. A. A. M., Acharjee, M. R., Shawkat, A. I., Masood, A., Bordin, C., Baki, A. O., and Mamun, M. A. A. (2025). Advanced machine learning models for accurate water quality classification and wqi prediction: Implications for aquatic disease risk management. *Science of The Total Environment*, 1008:180965.

- Hsieh, M. et al. (2010). Corrosion control when using secondary treated municipal wastewater as alternative makeup water for cooling tower systems. *Water Environment Research*, 82(12):2346–2356.
- Jesika, S., Ramadhani, S., and Putri, Y. P. (2023). Implementasi model machine learning dalam mengklasifikasi kualitas air. *Jurnal Ilmiah Dan Karya Mahasiswa*, 1(6):382–396.
- Kuznietsov, P. (2024). Evaluation of the scaling and corrosive potential of the cooling water supply system of a nuclear power plant based on the physicochemical control dataset. *Data in Brief*, 54:110347.
- Lan, Y., Qiu, M., and Xu, Z. (2025). Application of electrochemical technology in circulating cooling water treatment for thermal power plants. *Water Technology & Management*, 10(3):145–153.
- Liaw, A. and Wiener, M. (2002). The newsletter of the r project: Classification and regression by randomforest. *R News*, 2(3):18–22.
- Lowe, M., Qin, R., and Mao, X. (2022). A review on machine learning, artificial intelligence, and smart technology in water treatment and monitoring. *Water (Switzerland)*, 14(9):1–28.
- Maulidah, N., Maulidah, M., Supriyadi, R., Nalatissifa, H., Diantika, S., and Fauzi, A. (2024). Prediksi kualitas air menggunakan metode random forest, decision tree, dan gradient boosting. *Jurnal Khatulistiwa Informatika*, 12(1):1–6.
- Mukhamediev, R. I. et al. (2022). Review of artificial intelligence and machine learning technologies: Classification, restrictions, opportunities and challenges. *Mathematics*, 10(15):1–25.
- Mutofar, M. M., Rahmawati, D., and Hidayat, A. (2022). Klasifikasi kualitas air sumur menggunakan algoritma random forest. *Naratif: Jurnal Nasional Riset, Aplikasi dan Teknik Informatika*, 4(2):138–146.
- Ningsih, G. A. D. S. A. and Pramatha, C. (2024). Klasifikasi kualitas air layak minum menggunakan algoritma random forest classifier dan gridsearchcv. *JELIKU (Jurnal Elektronik Ilmu Komputer Udayana)*, 13(1):217–226.
- Nisa, N. I. F., Fanani, N., and Maritha, V. (2023). Evaluasi kualitas air pada sistem pendinginan pt. xyz surabaya: Studi kasus cooling water. *Journal of Chemical Process Engineering*, 8(2):140–150.
- Nurhalizah, R. S., Ardianto, R., and Purwono, P. (2024). Analisis supervised dan unsupervised learning pada machine learning: Systematic literature review. *Jurnal Ilmu Komputer dan Informatika*, 4(1):61–72.
- Pippo, F. D., Gregorio, L. D., Congestri, R., Tandoi, V., and Rossetti, S. (2018). Biofilm growth and control in cooling water industrial systems. *FEMS Microbiology Ecology*, 94(5):1–13.

- Raczko, E. and Zagajewski, B. (2017). Comparison of support vector machine, random forest and neural network classifiers for tree species classification on airborne hyperspectral apex images. *European Journal of Remote Sensing*, 50(1):143–154.
- Rainio, O., Teuho, J., and Klén, R. (2024). Evaluation metrics and statistical tests for machine learning. *Scientific Reports*, 14(1):1–14.
- Royani, A., Prifiharni, S., Priyotomo, G., Triwardono, J., and Sundjono (2019). Corrosion of carbon steel in synthetic freshwater for water distribution systems. *IOP Conference Series: Earth and Environmental Science*, 399(1):012089.
- Ruiz, D., Casas, A., Escobar, C. A., Perez, A., and Gonzalez, V. (2024). Advanced machine learning techniques for corrosion rate estimation and prediction in industrial cooling water pipelines. *Sensors*, 24(11):3564.
- Singh, M. and Yadav, D. R. (2022). Physico-chemical parameters for water quality check: A comprehensive review. *International Journal of Research and Analytical Reviews*, 9(4):287–293.
- Stojanović, B., Đuković, J., and Drobnjak, M. (2017). Assessment preferences cooling water to the corrosion or making incrustation in tpp. *Zaštita Materijala*, 58(2):243–248.
- Suganya, P., Swaminathan, G., Anoop, B., Prasad, G. V. R. R. S. G. S., and Nagarajan, J. (2020). Assessing the factors affecting the water chemistry parameters in the auxiliary water system of a nuclear power plant. *SN Applied Sciences*, 2(11):1–13.
- Tufail, S., Riggs, H., Tariq, M., and Sarwat, A. I. (2023). Advancements and challenges in machine learning: A comprehensive review of models, libraries, applications, and algorithms. *Electronics*, 12(8):1789.
- Wan, Y., Tian, X., He, H., Tong, P., Gao, R., Ji, X., Li, S., Luo, S., Li, W., and Chen, Z. (2025). Prediction of typical power plant circulating cooling tower blowdown water quality based on explicable integrated machine learning. *Processes*, 13(6):1–14.

LAMPIRAN A

KODE PROGRAM

Lampiran A.1. Program Pembacaan Sensor Ultrasonic

Lampiran A.2. Program Keseluruhan Proyek Akhir

LAMPIRAN B
GAMBAR-GAMBAR

Lampiran B.1. Foto Aktivitas Kegiatan Proyek Akhir



Lampiran B.2. Foto Produk Proyek Akhir

