

RANCANG BANGUN APLIKASI POINT OF SALE DENGAN FITUR PREDIKSI PENJUALAN HARIAN MENGGUNAKAN METODE LONG SHORT-TERM MEMORY (LSTM)

SKRIPSI

Diajukan Sebagai Salah Satu Syarat Untuk Menyelesaikan
Pendidikan Jenjang Sarjana Terapan Pada Politeknik Negeri Lhokseumawe



Oleh:

MUHAMMAD KHOLIS

NIM : 2022573010098
Program Studi : Teknik Informatika
Jurusan : Teknologi Informasi dan Komputer

**PROGRAM STUDI TEKNIK INFORMATIKA
TEKNOLOGI INFORMASI DAN KOMPUTER
POLITEKNIK NEGERI LHOKSEUMAWE
KEMENTERIAN PENDIDIKAN TINGGI, SAINS, DAN
TEKNOLOGI
2026**

**RANCANG BANGUN APLIKASI POINT OF SALE DENGAN
FITUR PREDIKSI PENJUALAN HARIAN MENGGUNAKAN
METODE LONG SHORT-TERM MEMORY (LSTM)**

SKRIPSI

Diajukan Sebagai Salah Satu Syarat Untuk Menyelesaikan
Pendidikan Jenjang Sarjana Terapan Pada Politeknik Negeri Lhokseumawe

Oleh:

MUHAMMAD KHOLIS

NIM. 2022573010098

**PROGRAM STUDI TEKNIK INFORMATIKA
TEKNOLOGI INFORMASI DAN KOMPUTER
POLITEKNIK NEGERI LHOKSEUMAWE
KEMENTERIAN PENDIDIKAN TINGGI, SAINS, DAN
TEKNOLOGI
2026**

PENGESAHAN PEMBIMBING

Skripsi yang berjudul RANCANG BANGUN APLIKASI POINT OF SALE DENGAN FITUR PREDIKSI PENJUALAN HARIAN MENGGUNAKAN METODE LONG SHORT-TERM MEMORY (LSTM), disusun oleh MUHAMMAD KHOLIS, NIM 2022573010098, Program Studi Teknik Informatika, Jurusan Teknologi Informasi dan Komputer Politeknik Negeri Lhokseumawe, telah memenuhi syarat untuk dipertanggungjawabkan dihadapan dewan penguji.

Pembimbing I,

Buketrata, 28 Mei 2026

Pembimbing II,

**Zulfan Khairil Simbolon, S.T.,
M.Eng.**
NIP. 19690902 199303 1 004

Azhar, S.T., M.T.
NIP. 19640830 199003 1 005

Mengetahui,

Ketua Jurusan
Teknologi Informasi dan Komputer,

Ketua Program Studi
Teknik Informatika,

Salahuddin, S.T., M.Cs
NIP. 19740424 200212 1 001

M. Khadafi, S.T., M.T
NIP. 19750718 200212 1 004

HALAMAN PENGESAHAN PENGUJI

Skripsi yang berjudul **RANCANG BANGUN APLIKASI POINT OF SALE DENGAN FITUR PREDIKSI PENJUALAN HARIAN MENGGUNAKAN METODE LONG SHORT-TERM MEMORY (LSTM)**, disusun oleh **MUHAMMAD KHOLIS**, NIM **2022573010098**, Program Studi **Teknik Informatika, Teknologi Informasi dan Komputer Politeknik Negeri Lhokseumawe**, telah dipertanggungjawabkan di depan dewan penguji dan dinyatakan lulus pada tanggal **28 Mei 2026**.

Komisi Sidang,

1. **Zulfan Khairil Simbolon, S.T., M.Eng.**
NIP. 19690902 199303 1 004 (Ketua Sidang)
2. **Azhar, S.T., M.T.**
NIP. 19640830 199003 1 005 (Sekretaris Sidang)
3. **Dr. Rahmad Hidayat, S.Kom., M.Cs**
NIP. 19830420 201212 1 003 (Penguji I)
4. **Muhammad Rizka, S.S.T., M.Kom**
NIP. 19881009 201504 1 001 (Penguji II)
5. **Bismillah Baik**
NIP. - (Penguji III)

Mengetahui,

Ketua Jurusan
Teknologi Informasi dan Komputer,

Ketua Program Studi
Teknik Informatika,

Salahuddin, S.T., M.Cs
NIP. 19740424 200212 1 001

M. Khadafi, S.T., M.T
NIP. 19750718 200212 1 004

HALAMAN PERNYATAAN

Dengan ini saya menyatakan bahwa dalam skripsi ini tidak terdapat karya yang pernah diajukan untuk mendapatkan gelar kesarjanaan di suatu Perguruan Tinggi, dan sepanjang pengetahuan saya juga tidak terdapat karya atau pendapat yang pernah ditulis orang lain, kecuali yang secara tertulis diacu dalam naskah dan disebut dalam daftar pustaka.

Lhokseumawe, 28 Mei 2026

Yang menyatakan,

MUHAMMAD KHOLIS

NIM. 2022573010098

KATA PENGANTAR

Segala puji beserta syukur senantiasa penulis panjatkan kepada Allah SWT yang telah memberikan rahmat dan petunjuk-Nya kepada penulis sehingga dapat menyelesaikan proposal skripsi yang berjudul “Rancang Bangun Aplikasi Point of Sale dengan Fitur Prediksi Penjualan Harian Menggunakan Metode Long Short-Term Memory (LSTM)”. Shalawat beserta salam kepada baginda Rasulullah Muhammad SAW, keluarga, dan para sahabat yang telah berjasa dalam memperjuangkan islam dan ilmu pengetahuan. Proposal skripsi ini disusun sebagai salah satu syarat untuk menyelesaikan pendidikan Sarjana Terapan Program Studi Teknik Informatika, Jurusan Teknologi Informasi dan Komputer, Politeknik Negeri Lhokseumawe.

Dalam Penyusunan skripsi ini penulis banyak mendapatkan dukungan, perhatian, dorongan, bimbingan dan berbagai bantuan dari banyak pihak terutama para dosen pembimbing. Dengan demikian, segala hormat dan kerendahan hati penulis ini menyampaikan rasa terima kasih yang tidak terhingga terutama kepada:

1. Allah SWT, atas segala rahmat, karunia, dan hidayah-Nya yang telah diberikan sehingga penulis dapat menyelesaikan skripsi ini.
2. Kedua orang tua tercinta serta keluarga yang senantiasa memberikan doa, dukungan, kasih sayang, dan pengorbanan tanpa henti kepada penulis, sehingga penulis dapat menyelesaikan pendidikan dan penyusunan skripsi ini dengan lancar.
3. Bapak Ir. Rizal Syahyadi, S.T., M.Eng.Sc., IPM., ASEAN Eng., APEC Eng. selaku Direktur Politeknik Negeri Lhokseumawe.
4. Bapak Salahuddin, S.T., M.Cs selaku Ketua Jurusan Teknologi Informasi dan Komputer, Bapak Fachri Yanuar Rudi F, M.T selaku Sekretaris Jurusan Teknologi Informasi dan Komputer, dan Bapak M. Khadafi, S.T., M.T selaku Ketua Program Studi Teknik Informatika atas segala bimbingan dan perhatian selama masa perkuliahan.
5. Bapak Zulfan Khairil Simbolon, S.T., M.Eng. selaku Pembimbing utama dan Bapak Azhar, S.T., M.T. selaku pembimbing pendamping yang telah membantu, membimbing, dan mengarahkan penulis dalam proses penyelesaian proposal skripsi ini.
6. Para dosen dan tenaga pengajar Program Studi Teknik Informatika yang telah memberikan ilmu, wawasan, serta pengalaman berharga kepada penulis selama masa perkuliahan, sehingga menjadi bekal yang sangat berarti dalam

proses penyelesaian studi.

7. Seluruh teman-teman, khususnya teman-teman terdekat, yang selalu menemani dan memberikan dukungan selama masa perkuliahan hingga penyusunan skripsi ini. Terima kasih atas kebersamaan, perhatian, dan semangat yang tidak pernah berhenti diberikan kepada penulis. Meskipun tidak dapat disebutkan satu per satu, penulis sangat menghargai setiap bantuan dan dukungan yang telah diberikan.
8. Kepada diri sendiri, penulis mengucapkan terima kasih atas segala usaha, kesabaran, dan kekuatan dalam melewati setiap proses yang tidak mudah. Di tengah keraguan dan kelelahan, penulis tetap berusaha bertahan dan melangkah hingga tahap akhir. Skripsi ini menjadi bukti dari perjalanan panjang yang dilalui serta hasil dari usaha dan doa yang terus diupayakan.

Penulis menyadari bahwa skripsi ini masih jauh dari sempurna dan memiliki berbagai keterbatasan. Oleh karena itu, penulis sangat mengharapkan kritik dan saran yang bersifat membangun demi perbaikan di masa yang akan datang. Semoga segala bantuan dan kebaikan yang telah diberikan mendapatkan balasan yang terbaik.

Lhokseumawe, 28 Mei 2026

MUHAMMAD KHOLIS
NIM. 2022573010098

RANCANG BANGUN APLIKASI POINT OF SALE DENGAN FITUR PREDIKSI PENJUALAN HARIAN MENGGUNAKAN METODE LONG SHORT-TERM MEMORY (LSTM)

Oleh
MUHAMMAD KHOLIS
NIM. 2022573010098

ABSTRAK

Penelitian ini bertujuan merancang dan membangun aplikasi Point of Sale (POS) berbasis mobile yang dilengkapi fitur prediksi penjualan harian menggunakan metode Long Short-Term Memory (LSTM) untuk membantu pelaku UMKM dalam pengambilan keputusan berbasis data. Sistem dikembangkan menggunakan Flutter sebagai frontend dan Python pada sisi server untuk proses pelatihan serta prediksi model. Data yang digunakan berupa transaksi penjualan harian yang diolah sebagai data deret waktu (time series). Kinerja model dievaluasi menggunakan metrik MAE, RMSE, dan MAPE untuk mengukur tingkat akurasi prediksi. Hasil penelitian diharapkan menghasilkan sistem POS yang tidak hanya mencatat transaksi, tetapi juga mampu memberikan informasi prediksi penjualan guna mendukung perencanaan stok dan strategi usaha secara lebih efektif.

Kata Kunci: Point of Sale (POS), Prediksi Penjualan Harian, Long Short-Term Memory (LSTM), Time Series, Machine Learning, UMKM

DESIGN AND DEVELOPMENT OF A POINT OF SALE APPLICATION WITH DAILY SALES PREDICTION FEATURE USING THE LONG SHORT-TERM MEMORY (LSTM) METHOD

By
MUHAMMAD KHOLIS
NIM. 2022573010098

ABSTRACT

This study aims to design and develop a mobile-based Point of Sale (POS) application equipped with a daily sales prediction feature using the Long Short-Term Memory (LSTM) method to assist MSMEs in data-driven decision-making. The system is developed using Flutter as the frontend and Python on the server side for the model training and prediction processes. The data used consists of daily sales transactions processed as time series data. The model performance is evaluated using MAE, RMSE, and MAPE metrics to measure the level of prediction accuracy. The results of the study are expected to produce a POS system that not only records transactions but is also capable of providing sales prediction information to support stock planning and business strategies more effectively.

Keywords: *Point of Sale (POS), Daily Sales Prediction, Long Short-Term Memory (LSTM), Time Series, Machine Learning, MSMEs*

DAFTAR ISI

HALAMAN SAMPUL	i
PENGESAHAN PEMBIMBING	ii
HALAMAN PENGESAHAN	iii
HALAMAN PERNYATAAN	iv
KATA PENGANTAR	v
ABSTRAK	vii
ABSTRACT	viii
DAFTAR ISI	ix
DAFTAR GAMBAR	xi
DAFTAR TABEL	xii
BAB 1 PENDAHULUAN	1
A. Latar Belakang Masalah	1
B. Rumusan Masalah	2
C. Tujuan Penelitian	3
D. Batasan Masalah	3
E. Manfaat Penelitian	4
F. Sistematika Penulisan	4
BAB 2 TINJAUAN PUSTAKA	6
A. State Of The Art	6
B. Tinjauan Teoritis	7
1. Point of Sale (POS)	7
2. Konsep Peramalan (Forecasting)	7
3. Data Deret Waktu (Time Series)	8
4. Machine Learning dalam Prediksi Penjualan	8
5. Recurrent Neural Network (RNN)	9
6. Long Short-Term Memory (LSTM)	9
7. Evaluasi Kinerja Model	12
BAB 3 METODOLOGI PENELITIAN	13
A. Alur Penelitian	13
B. Data dan Pengumpulan Data	14
C. Rancangan Sistem	15
1. Use Case Diagram	15
2. Activity Diagram	18
3. Entity Relationship Diagram (ERD)	19
D. Metode dan Variabel Penelitian	22
1. Metode Penelitian	22
2. Rancangan Algoritma Long Short-Term Memory (LSTM)	23
3. Variabel Penelitian	25

E. Teknik Pengujian	25
F. Hasil yang Diharapkan	25
G. Jadwal Kegiatan Penelitian	26
H. Rencana Anggaran Penelitian	26
BAB 4 HASIL DAN PEMBAHASAN	27
A. Hasil Implementasi Antarmuka Pengguna (User Interface)	27
1. Halaman Login	27
2. Halaman Dashboard	27
3. Halaman Input Data	28
4. Halaman Hasil Klasifikasi	29
5. Halaman Report (Historical Data)	29
6. Halaman Kelola User	30
B. Hasil Pelatihan dan Pengujian Model Random Forest	31
1. Pembagian Dataset	31
2. Hasil 5-Fold Cross Validation	32
3. Hasil Pengujian pada Data Uji (Testing Set)	32
4. Analisis Feature Importance	33
C. Hasil Pengujian Sistem	34
1. Hasil Pengujian Black Box	34
2. Hasil Pengujian White Box	34
BAB 5 KESIMPULAN DAN SARAN	37
A. Kesimpulan	37
B. Saran	38
DAFTAR PUSTAKA	40
LAMPIRAN A KODE PROGRAM	42
Lampiran A.1. Program Pembacaan Sensor Ultrasonic	42
Lampiran A.2. Program Keseluruhan Proyek Akhir	42
LAMPIRAN B GAMBAR-GAMBAR	43
Lampiran B.1. Foto Aktivitas Kegiatan Proyek Akhir	43
Lampiran B.2. Foto Produk Proyek Akhir	43

DAFTAR GAMBAR

3.1	Alur Penelitian	13
3.2	Use Case Diagram	16
3.3	Activity Diagram Alur Kerja Transaksi Kasir	19
3.4	Activity Diagram Sinkronisasi Latar Belakang	20
3.5	Activity Diagram Kalibrasi AI Smart Analytics	20
3.6	Entity Relationship Diagram (ERD)	21
3.7	Rancangan Alur Algoritma LSTM	24
4.1	Hasil Implementasi Halaman Login	27
4.2	Hasil Implementasi Halaman Dashboard	28
4.3	Hasil Implementasi Halaman Input Data	29
4.4	Hasil Implementasi Halaman Hasil Klasifikasi	30
4.5	Hasil Implementasi Halaman Report	30
4.6	Hasil Implementasi Halaman Kelola User	31

DAFTAR TABEL

2.1	State Of The Art.....	6
3.1	Definisi Aktor.....	17
3.2	Definisi Use Case.....	17
3.3	Daftar Tabel Database Parzello POS.....	21
3.4	Jadwal Kegiatan Penelitian.....	26
3.5	Rencana Anggaran Penelitian.....	26
4.1	Hasil Evaluasi Performa 5-Fold Cross Validation.....	32
4.2	Confusion Matrix Hasil Pengujian Model Final.....	32
4.3	Nilai Feature Importance Parameter Kualitas Air.....	34
4.4	Hasil Pengujian Fungsionalitas Black Box.....	35

BAB I

PENDAHULUAN

A. Latar Belakang Masalah

Perkembangan teknologi informasi dan komunikasi telah mendorong terjadinya transformasi digital di berbagai sektor bisnis, termasuk dalam pengelolaan transaksi dan operasional penjualan pada usaha mikro, kecil, dan menengah (UMKM). Pemanfaatan sistem *Point of Sale* (POS) berbasis aplikasi menjadi salah satu solusi yang banyak digunakan untuk membantu pelaku usaha dalam mencatat transaksi, mengelola stok barang, serta menyusun laporan penjualan secara lebih terstruktur dan efisien. Seiring dengan meningkatnya kebutuhan akan pengambilan keputusan yang cepat dan berbasis data, sistem POS tidak lagi hanya berfungsi sebagai alat pencatatan transaksi, tetapi juga dituntut untuk mampu menyediakan informasi analitis yang mendukung strategi bisnis.

Pada praktiknya, sebagian besar aplikasi *Point of Sale* yang digunakan oleh UMKM masih bersifat deskriptif, yaitu hanya menampilkan data historis penjualan tanpa adanya kemampuan analisis prediktif. Pelaku usaha umumnya harus melakukan perhitungan dan estimasi penjualan secara manual berdasarkan pengalaman atau intuisi, yang berpotensi menimbulkan kesalahan dalam perencanaan stok, penentuan target penjualan, dan pengelolaan arus kas. Ketidakmampuan sistem dalam memprediksi penjualan harian secara akurat dapat menyebabkan berbagai permasalahan, seperti kelebihan stok, kekurangan stok, serta tidak optimalnya strategi penjualan yang diterapkan.

Perkembangan teknologi kecerdasan buatan, khususnya dalam bidang *machine learning* dan *deep learning*, membuka peluang untuk menghadirkan fitur prediksi penjualan yang lebih akurat dan adaptif terhadap pola data historis. Salah satu metode *deep learning* yang banyak digunakan dalam analisis data runtun waktu (*time series*) adalah *Long Short-Term Memory* (LSTM). Metode LSTM memiliki keunggulan dalam mempelajari pola jangka pendek dan jangka panjang pada data penjualan harian, sehingga mampu menghasilkan prediksi yang lebih

baik dibandingkan metode statistik konvensional.

Penerapan metode *Long Short-Term Memory* (LSTM) dalam sistem *Point of Sale* diharapkan dapat membantu pelaku usaha dalam memprediksi penjualan harian berdasarkan data transaksi sebelumnya. Dengan adanya fitur prediksi penjualan, sistem POS tidak hanya berperan sebagai alat pencatatan transaksi, tetapi juga sebagai sistem pendukung keputusan yang dapat memberikan gambaran tren penjualan di masa mendatang. Informasi prediksi tersebut dapat dimanfaatkan untuk perencanaan stok barang, pengaturan strategi promosi, serta pengelolaan keuangan usaha secara lebih efektif dan efisien.

Berdasarkan permasalahan tersebut, maka diperlukan suatu penelitian yang merancang dan membangun aplikasi *Point of Sale* dengan fitur prediksi penjualan harian menggunakan metode *Long Short-Term Memory* (LSTM). Penelitian ini diharapkan dapat menghasilkan sebuah aplikasi POS yang mampu memberikan nilai tambah bagi pengguna melalui pemanfaatan teknologi kecerdasan buatan, serta menjadi referensi bagi pengembangan sistem *Point of Sale* berbasis *machine learning* di masa mendatang.

B. Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, maka rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana merancang dan membangun aplikasi *Point of Sale* (POS) dengan fitur prediksi penjualan harian berbasis *mobile* yang dapat digunakan oleh pelaku usaha secara efektif?
2. Bagaimana menerapkan metode *Long Short-Term Memory* (LSTM) pada aplikasi *Point of Sale* untuk memprediksi penjualan harian berdasarkan data transaksi historis?
3. Bagaimana tingkat akurasi hasil prediksi penjualan harian yang dihasilkan oleh metode *Long Short-Term Memory* (LSTM) berdasarkan evaluasi menggunakan metrik kesalahan prediksi?

C. Tujuan Penelitian

Berdasarkan rumusan masalah yang telah diuraikan, maka tujuan dalam penelitian ini adalah sebagai berikut:

1. Merancang dan membangun aplikasi *Point of Sale* (POS) berbasis *mobile* yang dilengkapi dengan fitur prediksi penjualan harian sebagai alat bantu pengelolaan dan analisis penjualan.
2. Mengimplementasikan metode *Long Short-Term Memory* (LSTM) pada aplikasi *Point of Sale* untuk memprediksi penjualan harian berdasarkan data transaksi historis.
3. Memanfaatkan data transaksi penjualan harian, seperti jumlah transaksi, total penjualan, dan jumlah produk terjual, sebagai data latih utama dalam model prediksi penjualan berbasis metode LSTM.
4. Mengevaluasi kinerja dan tingkat akurasi metode *Long Short-Term Memory* (LSTM) dalam menghasilkan prediksi penjualan harian menggunakan metrik evaluasi kesalahan prediksi.

D. Batasan Masalah

Untuk menghindari meluasnya materi pembahasan tugas akhir ini, maka pembahasan akan dibatasi mencakup hal-hal berikut:

1. Aplikasi dikembangkan menggunakan framework Flutter dan difokuskan untuk sistem operasi Android, mengingat dominasi pasar Android pada segmen UMKM lokal.
2. Studi kasus dilakukan pada UMKM skala mikro di wilayah Kota Langsa.
3. Algoritma yang digunakan adalah *Long Short-Term Memory* (LSTM) dengan model *univariate* atau *multivariate* terbatas, dan prediksi dilakukan untuk rentang waktu harian.
4. Sistem mencakup pencatatan penjualan kasir, manajemen stok sederhana, dan laporan penjualan harian. Fitur pembayaran digital (*e-wallet integration*) tidak dibahas secara mendalam pada versi ini.
5. Proses pelatihan model (*training*) dan prediksi dilakukan di sisi *Server/Cloud*

menggunakan bahasa Python, sedangkan aplikasi *mobile* bertugas mengirim data transaksi dan menerima hasil prediksi melalui *REST API*.

E. Manfaat Penelitian

Manfaat yang diharapkan dari penelitian ini adalah sebagai berikut:

1. **Bagi Pelaku UMKM di Kota Langsa:** Memberikan aplikasi *Point of Sale* (POS) berbasis *mobile* yang dapat digunakan untuk pencatatan transaksi penjualan dan pengelolaan stok secara digital, serta menyediakan fitur prediksi penjualan harian berbasis algoritma *Long Short-Term Memory* (LSTM) sebagai alat bantu dalam pengambilan keputusan *restock* dan pengelolaan persediaan barang.
2. **Bagi Akademisi:** Menjadi referensi dan bahan kajian dalam pengembangan penelitian di bidang sistem informasi dan *machine learning*, khususnya penerapan metode *Long Short-Term Memory* (LSTM) untuk prediksi penjualan harian pada sistem *Point of Sale* (POS) berbasis *mobile* di lingkungan UMKM.
3. **Bagi Peneliti:** Menambah pengetahuan dan pengalaman dalam merancang dan membangun aplikasi POS berbasis *mobile* menggunakan framework Flutter serta mengimplementasikan algoritma *Long Short-Term Memory* (LSTM) untuk menyelesaikan permasalahan prediksi penjualan harian berbasis data transaksi UMKM pada studi kasus nyata.

F. Sistematika Penulisan

Sistematika penulisan proposal skripsi ini disusun untuk memberikan gambaran secara menyeluruh mengenai alur pembahasan yang dilakukan. Sistematika penulisan dibagi menjadi tiga bab utama yang saling berkaitan, dengan rincian sebagai berikut:

BAB I PENDAHULUAN

Bab ini menguraikan gambaran umum penelitian yang meliputi latar belakang masalah, rumusan masalah, tujuan penelitian, batasan masalah, manfaat penelitian, serta sistematika penulisan. Bab ini menjadi dasar dalam memahami alasan dan

arah penelitian yang dilakukan.

BAB II TINJAUAN PUSTAKA

Bab ini berisi landasan teori dan kajian literatur yang relevan dengan penelitian. Teori yang disajikan mencakup konsep *Point of Sale* (POS), peramalan (*forecasting*), data deret waktu (*time series*), *machine learning*, konsep *Recurrent Neural Network* (RNN), *Long Short-Term Memory* (LSTM), serta metrik evaluasi kinerja model. Selain itu, bab ini juga menyajikan ringkasan penelitian terdahulu (*State of the Art*) dalam bentuk tabel komparatif.

BAB III METODOLOGI PENELITIAN

Bab ini menjelaskan tahapan metodologi penelitian yang dilakukan, meliputi alur penelitian, pengumpulan data, perancangan sistem menggunakan UML (*use case* dan *activity diagram*), pemodelan menggunakan metode LSTM, rancangan pengujian sistem menggunakan metode *black-box testing*, serta jadwal dan anggaran kegiatan penelitian.

BAB II

TINJAUAN PUSTAKA

A. State Of The Art

Pembuatan penelitian ini menggunakan referensi dari beberapa jurnal yang berkaitan dan berhubungan. Bentuk referensi ditampilkan melalui tabel ringkasan penelitian sebelumnya atau *State of the Art* yang dapat dilihat pada Tabel 2.1 berikut.

Tabel 2.1 State Of The Art

No	Penulis, Tahun & Judul	Metode	Hasil	Persamaan	Perbedaan
1	Darmanto & Barus (2024) Darmanto and Barus (2024)	Random Forest	Model mampu meningkatkan akurasi prediksi serta membantu perusahaan dalam perencanaan stok.	Sama-sama menggunakan data transaksi penjualan sebagai dasar peramalan.	Menggunakan Random Forest untuk klasifikasi/regresi vs. LSTM untuk runtun waktu.
2	Prasetyo <i>et al.</i> (2023) Prasetyo et al. (2023)	LSTM	LSTM mampu menangkap pola tren dan musiman secara lebih baik dibanding regresi linier.	Sama-sama menggunakan metode LSTM untuk peramalan penjualan berbasis data historis.	Hanya fokus pada pengembangan model prediksi vs. integrasi model ke aplikasi POS.
3	Ramadhan <i>et al.</i> (2022) Ramadhan et al. (2022)	LSTM dan GRU	LSTM memiliki performa lebih stabil dalam menghadapi fluktuasi permintaan jangka panjang.	Memanfaatkan pendekatan deep learning untuk memodelkan data deret waktu yang kompleks.	Hanya fokus pada analisis model vs. rancang bangun aplikasi POS terintegrasi.
4	Wijaya & Putri (2022) Wijaya and Putri (2022)	-	Sistem POS berbasis web mengurangi kesalahan manual dan mempercepat pelayanan.	Mengembangkan aplikasi POS untuk membantu pengelolaan transaksi dan laporan.	Belum memiliki fitur prediksi penjualan vs. memiliki fitur prediksi LSTM.

B. Tinjauan Teoritis

1. Point of Sale (POS)

Point of Sale (POS) merupakan sistem informasi yang digunakan untuk memproses dan mencatat transaksi penjualan pada titik terjadinya transaksi antara penjual dan pelanggan Wijaya and Putri (2022). Sistem POS modern telah berkembang dari sekadar mesin kasir elektronik menjadi sistem berbasis komputer atau aplikasi yang terintegrasi dengan basis data dan jaringan internet. Melalui sistem POS, setiap transaksi penjualan akan tercatat secara otomatis dan tersimpan dalam database, sehingga meminimalkan kesalahan pencatatan manual serta meningkatkan kecepatan pelayanan. Selain itu, sistem POS juga umumnya dilengkapi dengan fitur manajemen inventaris yang mampu memperbarui jumlah stok secara otomatis setelah terjadi transaksi, sehingga membantu pelaku usaha dalam mengontrol persediaan barang.

Keunggulan utama sistem POS terletak pada kemampuannya menghasilkan data historis penjualan yang terstruktur dan terdokumentasi dengan baik. Data historis ini menjadi fondasi penting dalam proses analisis bisnis, termasuk analisis tren penjualan, identifikasi produk terlaris, serta peramalan permintaan di masa mendatang. Dengan demikian, sistem POS tidak hanya berperan sebagai alat operasional, tetapi juga sebagai sumber data strategis bagi pengembangan sistem analitik yang lebih canggih.

2. Konsep Peramalan (Forecasting)

Peramalan atau *forecasting* adalah proses estimasi nilai di masa depan berdasarkan pola data historis dan analisis faktor-faktor yang memengaruhinya Prasetyo et al. (2023). Dalam konteks bisnis ritel, peramalan penjualan memiliki peran yang sangat penting karena berkaitan langsung dengan perencanaan stok, pengadaan barang, pengelolaan modal, dan strategi pemasaran. Kesalahan dalam peramalan dapat menyebabkan terjadinya kelebihan stok (*overstock*) yang meningkatkan biaya penyimpanan, maupun kekurangan stok (*stockout*) yang berpotensi mengurangi pendapatan dan kepuasan pelanggan.

Metode peramalan dapat dibedakan menjadi metode kualitatif dan kuantitatif. Metode kuantitatif umumnya memanfaatkan data historis numerik dan teknik statistik seperti *Moving Average*, *Exponential Smoothing*, serta *ARIMA*. Namun, seiring berkembangnya teknologi komputasi, pendekatan berbasis *machine learning* dan *deep learning* mulai banyak digunakan karena mampu memodelkan hubungan non-linear yang kompleks serta menangani data dalam jumlah besar Ramadhan et al. (2022). Pendekatan ini dinilai lebih adaptif terhadap perubahan pola penjualan yang dinamis dibandingkan metode statistik tradisional.

3. Data Deret Waktu (Time Series)

Data deret waktu (*time series*) merupakan data yang dikumpulkan secara berurutan berdasarkan interval waktu tertentu, seperti harian, mingguan, atau bulanan Prasetyo et al. (2023). Data penjualan harian termasuk dalam kategori ini karena memiliki dimensi waktu yang berurutan dan saling bergantung. Karakteristik utama data *time series* meliputi tren jangka panjang, pola musiman yang berulang, fluktuasi siklis yang dipengaruhi kondisi ekonomi, serta komponen acak yang tidak dapat diprediksi secara langsung.

Dalam analisis *time series*, penting untuk memahami bahwa nilai pada suatu waktu tertentu dipengaruhi oleh nilai pada waktu sebelumnya. Oleh karena itu, model yang digunakan dalam peramalan harus mampu menangkap ketergantungan temporal tersebut. Pada kasus penjualan harian, misalnya, jumlah penjualan pada hari ini dapat dipengaruhi oleh pola penjualan pada hari-hari sebelumnya, termasuk faktor musiman seperti akhir pekan atau periode promosi tertentu. Pemahaman terhadap karakteristik ini menjadi dasar dalam pemilihan metode LSTM sebagai model prediksi.

4. Machine Learning dalam Prediksi Penjualan

Machine Learning merupakan cabang dari kecerdasan buatan yang memungkinkan sistem belajar dari data untuk mengenali pola dan menghasilkan prediksi tanpa diprogram secara eksplisit Goodfellow et al. (2016). Dalam prediksi penjualan, pendekatan *supervised learning* digunakan karena tersedia data historis

yang berisi pasangan input dan output yang telah diketahui nilainya. Model akan dilatih menggunakan data tersebut untuk mempelajari pola hubungan antara waktu dan nilai penjualan.

Metode *machine learning* konvensional seperti regresi linier atau *Random Forest* dapat digunakan untuk memprediksi penjualan, namun metode tersebut memiliki keterbatasan dalam menangani data sekuensial yang memiliki ketergantungan jangka panjang. Oleh karena itu, pendekatan berbasis jaringan saraf tiruan, khususnya *Recurrent Neural Network* (RNN), dikembangkan untuk mengatasi keterbatasan tersebut dengan memanfaatkan struktur jaringan yang mampu memproses data berurutan.

5. Recurrent Neural Network (RNN)

Recurrent Neural Network (RNN) merupakan arsitektur jaringan saraf tiruan yang dirancang untuk memproses data sekuensial dengan mempertahankan informasi dari langkah waktu sebelumnya Goodfellow et al. (2016). RNN memiliki mekanisme umpan balik (*feedback loop*) yang memungkinkan output pada waktu sebelumnya menjadi input tambahan pada waktu berikutnya. Struktur ini memungkinkan model memahami konteks temporal dalam data deret waktu.

Meskipun RNN mampu memodelkan data sekuensial, arsitektur ini memiliki kelemahan berupa permasalahan *vanishing gradient*, yaitu kondisi di mana gradien menjadi sangat kecil sehingga jaringan kesulitan mempelajari hubungan jangka panjang. Permasalahan ini menyebabkan performa RNN menurun ketika digunakan untuk memodelkan data dengan dependensi waktu yang panjang, seperti data penjualan harian dalam periode yang cukup lama.

6. Long Short-Term Memory (LSTM)

Long Short-Term Memory (LSTM) merupakan salah satu varian dari *Recurrent Neural Network* (RNN) yang dirancang untuk mengatasi permasalahan *vanishing gradient* pada pemodelan data sekuensial jangka panjang Hochreiter and Schmidhuber (1997). LSTM diperkenalkan oleh Sepp Hochreiter dan Jürgen Schmidhuber pada tahun 1997 sebagai arsitektur jaringan saraf yang mampu

mempertahankan informasi dalam rentang waktu yang lebih panjang dibandingkan RNN konvensional. Keunggulan utama LSTM terletak pada keberadaan mekanisme *gating* (gerbang) yang mengatur aliran informasi masuk, disimpan, dan dikeluarkan dari sel memori (*cell state*). Struktur ini memungkinkan model untuk memilih informasi mana yang relevan untuk dipertahankan atau dilupakan, sehingga sangat efektif dalam berbagai tugas seperti peramalan deret waktu, pengenalan suara, dan pemrosesan bahasa alami Goodfellow et al. (2016).

Secara arsitektural, satu unit LSTM terdiri atas tiga gerbang utama, yaitu *forget gate*, *input gate*, dan *output gate*, serta satu komponen *cell state* yang berfungsi sebagai memori jangka panjang. Pada setiap langkah waktu ke- t , LSTM menerima input x_t , status tersembunyi sebelumnya h_{t-1} , dan status sel sebelumnya C_{t-1} . Proses komputasi dilakukan secara bertahap melalui fungsi aktivasi sigmoid dan tanh untuk mengontrol pembaruan memori. Pendekatan ini memungkinkan LSTM menjaga stabilitas gradien selama proses pelatihan menggunakan algoritma *backpropagation through time* (BPTT). Dengan demikian, LSTM mampu menangkap dependensi temporal yang kompleks dalam data sekuensial.

Secara matematis, mekanisme kerja LSTM dapat dirumuskan sebagai berikut:

1. Forget Gate

Gerbang ini menentukan informasi mana dari status sel sebelumnya yang akan dipertahankan atau dihapus.

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad 2.1$$

Di mana f_t adalah nilai *forget gate* pada waktu ke- t , W_f adalah matriks bobot *forget gate*, b_f adalah bias, dan σ adalah fungsi aktivasi sigmoid.

2. Input Gate

Gerbang ini menentukan informasi baru yang akan disimpan dalam *cell state*.

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad 2.2$$

Kandidat nilai memori baru dihitung dengan:

$$\tilde{C}_t = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c) \quad 2.3$$

Di mana i_t adalah nilai *input gate*, dan $\tilde{C}_t$ adalah kandidat pembaruan memori.

3. Pembaruan Cell State

Pembaruan *cell state* lama menjadi *cell state* baru dihitung dengan mengombinasikan *forget gate* dan *input gate*:

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t \quad 2.4$$

Di mana C_t adalah *cell state* baru, dan C_{t-1} adalah *cell state* sebelumnya.

4. Output Gate

Gerbang ini menentukan status tersembunyi (*hidden state*) berikutnya yang akan ditransmisikan:

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad 2.5$$

Status tersembunyi h_t diperoleh melalui:

$$h_t = o_t * \tanh(C_t) \quad 2.6$$

Di mana o_t adalah nilai *output gate*, dan h_t adalah *hidden state* pada waktu ke- t .

Melalui kombinasi mekanisme gerbang tersebut, LSTM mampu mempertahankan informasi penting dalam jangka panjang sekaligus mengurangi pengaruh informasi yang tidak relevan. Secara empiris, arsitektur ini menunjukkan performa yang unggul dalam berbagai studi komparatif terhadap RNN standar, khususnya pada data dengan pola temporal kompleks dan non-linear Goodfellow et al. (2016).

7. Evaluasi Kinerja Model

Evaluasi kinerja model prediksi bertujuan untuk mengukur tingkat kesalahan antara nilai aktual dan nilai hasil prediksi yang dihasilkan oleh model Prasetyo et al. (2023). Dalam penelitian ini, evaluasi dilakukan menggunakan metrik kuantitatif yang umum digunakan pada data *time series*, yaitu *Mean Absolute Error* (MAE), *Root Mean Squared Error* (RMSE), dan *Mean Absolute Percentage Error* (MAPE).

1. Mean Absolute Error (MAE)

MAE mengukur rata-rata selisih absolut antara nilai aktual dan prediksi.

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad 2.7$$

2. Root Mean Squared Error (RMSE)

RMSE memberikan penalti lebih besar terhadap kesalahan yang signifikan karena menggunakan kuadrat dari selisih tersebut.

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad 2.8$$

3. Mean Absolute Percentage Error (MAPE)

MAPE digunakan untuk mengukur kesalahan dalam bentuk persentase sehingga lebih mudah diinterpretasikan dalam konteks bisnis.

$$\text{MAPE} = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \quad 2.9$$

Proses evaluasi ini penting untuk memastikan bahwa model LSTM yang diintegrasikan dalam aplikasi POS memiliki tingkat akurasi yang memadai dan dapat diandalkan dalam mendukung pengambilan keputusan operasional.


BAB III

METODOLOGI PENELITIAN

A. Alur Penelitian

Alur penelitian ini dirancang secara sistematis untuk membangun sebuah sistem *Point of Sale* (POS) berbasis *mobile* yang dinamakan **Parzello POS Mobile (ZelloPOS)**. Aplikasi ini dilengkapi dengan fitur prediksi penjualan harian menggunakan metode *Long Short-Term Memory* (LSTM) yang terintegrasi. Tahapan penelitian ini merepresentasikan kerangka kerja pengembangan sistem yang dimulai dari tahap analisis kebutuhan, perancangan, implementasi aplikasi, hingga proses pemodelan dan evaluasi sistem secara menyeluruh.

Sebagaimana diilustrasikan pada Gambar 3.1, alur penelitian terbagi menjadi dua fase utama yang saling berkaitan, yaitu Fase Pengembangan dan Implementasi Sistem POS serta Fase Pengembangan Model Prediksi Penjualan.



Gambar 3.1 Alur Penelitian

Pada Fase Pengembangan dan Implementasi Sistem POS, penelitian diawali dengan analisis kebutuhan melalui observasi dan identifikasi permasalahan pada mitra UMKM. Selanjutnya dilakukan perancangan sistem meliputi arsitektur aplikasi, desain basis data, serta perancangan UML dan antarmuka pengguna.

Setelah tahap perancangan selesai, aplikasi Parzello POS Mobile dikembangkan menggunakan Flutter sebagai *frontend*, Isar DB sebagai penyimpanan data lokal (*local storage*) untuk mendukung kemampuan *offline-first*, dan cloud Supabase sebagai *backend* dan basis data utama. Aplikasi yang telah dibangun kemudian diimplementasikan pada mitra UMKM untuk digunakan dalam kegiatan transaksi harian. Dari tahap implementasi ini diperoleh data transaksi penjualan aktual yang tersimpan secara otomatis di dalam basis data lokal Isar DB dan disinkronisasikan secara otomatis ke database cloud Supabase.

Pada Fase Pengembangan Model Prediksi Penjualan, data transaksi yang telah terkumpul selama periode tertentu selanjutnya melalui tahap pra-pemrosesan (*data preparation*), seperti pembersihan data, agregasi harian, normalisasi, serta pembentukan data runtun waktu (*time series*). Dataset kemudian dibagi menjadi data latih dan data uji untuk proses pemodelan. Model LSTM dilatih menggunakan data latih untuk mempelajari pola penjualan jangka pendek maupun jangka panjang. Setelah proses pelatihan selesai, model diuji menggunakan data uji untuk mengukur tingkat akurasi prediksi dengan metrik evaluasi yang sesuai.

Model prediksi yang telah teruji kemudian diintegrasikan kembali ke dalam sistem POS sehingga aplikasi tidak hanya berfungsi sebagai alat pencatatan transaksi *offline-first*, tetapi juga mampu menampilkan hasil prediksi penjualan harian kepada pengguna. Tahap akhir penelitian dilakukan melalui pengujian fungsional sistem menggunakan metode *black box* serta evaluasi performa model untuk memastikan sistem berjalan sesuai dengan kebutuhan dan tujuan penelitian.

B. Data dan Pengumpulan Data

Data diperoleh dari hasil rekapan transaksi penjualan harian UMKM yang diekspor dari aplikasi *Point of Sale* (POS) Parzello POS Mobile yang digunakan pada objek penelitian. Aplikasi POS tersebut digunakan oleh pelaku UMKM skala mikro di wilayah Kota Langsa sebagai media pencatatan transaksi penjualan secara digital. Dataset yang dihasilkan pada sistem POS mencakup informasi tanggal transaksi, jumlah transaksi, total nilai penjualan harian, serta jumlah produk terjual

yang memiliki keterkaitan langsung dengan aktivitas penjualan harian. Data transaksi pada sistem POS dikelola oleh pemilik (*owner*) atau pengelola UMKM, sehingga diperlukan koordinasi dengan pihak UMKM terkait untuk memperoleh data yang sesuai dengan kebutuhan penelitian.

C. Rancangan Sistem


Perancangan sistem dalam penelitian ini dilakukan menggunakan *Unified Modeling Language* (UML) dan *Entity Relationship Diagram* (ERD), yang bertujuan untuk memberikan gambaran dan ilustrasi sistem secara jelas dan terstruktur. Pemodelan sistem ini direpresentasikan melalui perancangan *Use Case Diagram*, *Activity Diagram*, *Entity Relationship Diagram* (ERD), serta *User Interface* guna menggambarkan alur proses, struktur penyimpanan data, dan interaksi pengguna dengan sistem.

1. Use Case Diagram

Rancangan sistem pada aplikasi Parzello POS Mobile melibatkan tiga aktor utama, yaitu Owner (Pemilik Toko), Karyawan/Kasir, dan Pelanggan (Customer). *Use Case Diagram* digunakan untuk menggambarkan fungsi-fungsi yang dapat dilakukan oleh masing-masing aktor dalam sistem *Point of Sale* (POS) yang dilengkapi dengan fitur prediksi penjualan harian. Adapun rancangan *use case* pada penelitian ini diilustrasikan pada Gambar 3.2.

Gambar 3.2 menggambarkan *use case diagram* pada aplikasi Parzello POS Mobile. Penjelasan mengenai peran aktor pada sistem Point of Sale diilustrasikan pada Tabel 3.1 berikut:

Sedangkan penjelasan fungsionalitas dari masing-masing *use case* dijabarkan pada Tabel 3.2 berikut yang disusun menggunakan *longtable* karena melibatkan fungsionalitas sistem yang komprehensif:



Gambar 3.2 Use Case Diagram

Tabel 3.1 Definisi Aktor

No	Aktor	Deskripsi
1	Owner (Pemilik Toko)	Pengguna dengan hak akses tertinggi (<i>super-user</i>) yang mengontrol seluruh konfigurasi toko, manajemen katalog produk, data karyawan, laporan keuangan, audit stok, serta fitur AI Smart Analytics.
2	Karyawan / Kasir	Staf operasional harian toko yang memiliki akses terbatas pada pelayanan transaksi POS, pencetakan struk belanja, pemantauan status meja, penginputan mutasi stok barang, dan melihat ringkasan omzet harian terbatas.
3	Pelanggan (Customer)	Aktor eksternal (diusulkan pada pengembangan masa depan) yang dapat memesan menu mandiri melalui pemindaian QR Code meja restoran dan melakukan pembayaran elektronik.

Tabel 3.2 Definisi Use Case

No	Use Case	Aktor Utama	Deskripsi Singkat
1	UC-01 Registrasi Toko Baru	Owner	Mendaftarkan akun toko baru saat inisialisasi awal sistem.
2	UC-02 Login Akun	Owner, Kasir	Autentikasi pengguna menggunakan email dan kata sandi.
3	UC-03 Melakukan Checkout	Owner, Kasir	Memasukkan pesanan ke keranjang dan memproses transaksi bayar.
4	UC-04 Menerapkan Voucher	Owner, Kasir	Memasukkan kode promosi voucher belanja untuk memotong tagihan.
5	UC-05 Melakukan Split Bill	Owner, Kasir	Memecah pembayaran satu nota belanja menjadi beberapa bill.
6	UC-06 Mencetak Struk Belanja	Owner, Kasir	Mencetak struk transaksi fisik melalui printer thermal Bluetooth.
7	UC-07 Memonitor Status Meja	Owner, Kasir	Memantau keterisian meja kasir secara visual.
8	UC-08 Mengelola Katalog	Owner	Menambah, menyunting, dan menghapus produk atau stok barang.
9	UC-09 Mengelola Kategori	Owner	Mengatur pengelompokan menu katalog produk toko.
10	UC-10 Mengaudit Riwayat Stok	Owner	Melihat log keluar-masuk mutasi barang untuk mencegah fraud.
Berlanjut ke halaman berikutnya			

Tabel 3.2 – Lanjutan dari halaman sebelumnya

No	Use Case	Aktor Utama	Deskripsi Singkat
11	UC-11 Melihat Dashboard	Owner, Kasir	Memantau performa keuangan (Kasir dibatasi khusus hari ini).
12	UC-12 Melihat AI Analytics	Owner	Melihat proyeksi omzet cerdas berbasis Gemini AI atau LSTM.
13	UC-13 Kirim Broadcast Notif	Owner	Mengirim pesan push pemberitahuan real-time ke semua kasir.
14	UC-14 Sinkronisasi Data	Owner, Kasir	Menyinkronkan antrean transaksi offline lokal ke cloud Supabase.
15	UC-15 Mengelola Karyawan	Owner	Mendaftarkan, menangguhkan, atau mengubah peran staf kasir.
16	UC-16 Mengatur Profil Toko	Owner	Mengubah identitas nama toko, alamat, dan logo outlet.

2. Activity Diagram


Activity Diagram merupakan gambaran visual dalam bentuk diagram yang digunakan untuk menggambarkan serangkaian aktivitas atau proses yang terjadi di dalam sistem. Diagram ini memudahkan dalam menjelaskan logika prosedural, proses bisnis, serta alur kerja sistem Parzello POS Mobile yang dilengkapi dengan fitur prediksi penjualan harian. Adapun *Activity Diagram* pada sistem ini dijelaskan sebagai berikut.

1. Activity Diagram Alur Kerja Transaksi Kasir (POS Checkout)

Gambar 3.3 menggambarkan alur kerja kasir atau *owner* dalam memproses transaksi belanja pelanggan di kasir, termasuk opsi penerapan kupon/voucher diskon dan pemisahan tagihan (*split bill*) sebelum data disimpan di penyimpanan lokal Isar DB.

2. Activity Diagram Sinkronisasi Latar Belakang (Offline-First Sync Engine)

Gambar 3.4 menggambarkan logika sinkronisasi data dari *local database* (Isar DB) ke cloud database (Supabase) secara otomatis saat status



Gambar 3.3 Activity Diagram Alur Kerja Transaksi Kasir


konektivitas terdeteksi *online*. Alur data dilakukan berdasarkan ketergantungan relasi tabel (kategori, produk, transaksi, riwayat stok) untuk menjaga konsistensi.

3. Activity Diagram Proses Kalibrasi AI Smart Analytics

Gambar 3.5 menggambarkan alur kerja pemrosesan data historis transaksi lokal, melakukan penapisan data pribadi pelanggan (*PII scrubbing*), mengunggah data teragregasi dan terenkripsi ke *Edge Function*, dan memicu model peramalan penjualan untuk menampilkan visualisasi analitik omzet serta rekomendasi promosi.

3. Entity Relationship Diagram (ERD)


Perancangan basis data dalam penelitian ini dirancang dengan pendekatan hibrida untuk mendukung arsitektur *offline-first*. Skema basis data relasional pada cloud *Supabase PostgreSQL* disinkronisasikan ke dalam penyimpanan lokal perangkat menggunakan *Isar Database* sebagai *local cache*. Hubungan relasional



Gambar 3.5 Activity Diagram Kalibrasi AI Smart Analytics



antar-tabel serta kamus data dirinci untuk menjaga integritas dan performa sistem. Rancangan ERD sistem Parzello POS Mobile diilustrasikan pada Gambar 3.6.



Gambar 3.6 Entity Relationship Diagram (ERD)

Penjelasan mengenai fungsi dan kegunaan dari masing-masing entitas dalam database Parzello POS Mobile diilustrasikan pada Tabel 3.3 berikut:

Tabel 3.3 Daftar Tabel Database Parzello POS

No	Nama Tabel	Fungsi / Deskripsi
1	stores	Menyimpan informasi identitas dasar outlet/toko merchant.
2	store_members	Menyimpan hubungan hak akses anggota staf terhadap toko (RBAC).
3	categories	Kategori pengelompokan produk makanan/barang dagangan.
4	products	Katalog produk barang atau makanan/minuman yang dijual.
5	tables	Tata letak meja operasional restoran (untuk F&B dine-in).
6	vouchers	Kupon promosi diskon transaksi belanja.
7	transactions	Nota transaksi penjualan kasir (induk dari struk).
8	transaction_items	Rincian baris menu/produk yang dibeli dalam transaksi.
9	stock_histories	Kartu log riwayat audit perubahan inventaris produk.
10	notifications	Log notifikasi pusat pesan (in-app dan push alert).

Untuk menjaga konsistensi dan integritas data ketika terjadi penghapusan data, basis data dikonfigurasi dengan aturan relasi sebagai berikut:

1. **ON DELETE CASCADE (Hapus Berantai)**: Diterapkan pada relasi *stores* ke *store_members*, *stores* ke *categories* dan *products*, serta *transactions* ke *transaction_items*. Jika data induk dihapus, seluruh data anak yang terikat akan terhapus secara otomatis.

2. **ON DELETE SET NULL (Setel Kosong):** Diterapkan pada relasi *categories* ke *products*. Jika kategori dihapus, produk yang terikat tidak ikut terhapus, melainkan nilai *category_id* disetel menjadi *NULL* ("Tanpa Kategori").
3. **RESTRICT (Dilarang Hapus):** Diterapkan pada relasi *products* ke *transaction_items*. Produk yang sudah memiliki riwayat penjualan di dalam transaksi dilarang dihapus untuk menjaga kevalidan laporan keuangan historis. Untuk menghapus katalog aktif, kasir menggunakan flag soft delete *is_deleted = true*.

D. Metode dan Variabel Penelitian

1. Metode Penelitian

Penelitian ini menggunakan metode *data mining* dan *machine learning* berbasis algoritma *Long Short-Term Memory* (LSTM) untuk melakukan prediksi penjualan harian pada sistem *Point of Sale* (POS). Metode ini digunakan karena LSTM mampu mempelajari pola data runtun waktu (*time series*) dan menangkap dependensi jangka pendek maupun jangka panjang pada data penjualan. Tahapan metode penelitian yang digunakan terdiri dari beberapa langkah terstruktur sebagai berikut:

1. Business Understanding

Tahap ini bertujuan untuk memahami kebutuhan dan tujuan penelitian dalam konteks prediksi penjualan harian UMKM. Permasalahan yang didefinisikan adalah bagaimana memanfaatkan data transaksi penjualan historis untuk menghasilkan prediksi penjualan harian yang akurat guna membantu pelaku UMKM dalam pengambilan keputusan operasional.

2. Data Understanding

Pada tahap ini dilakukan identifikasi dan pemahaman terhadap data yang digunakan, yaitu data transaksi penjualan harian yang diperoleh dari sistem POS. Data yang dianalisis meliputi tanggal transaksi, jumlah transaksi, total nilai penjualan harian, dan jumlah produk terjual. Data dieksplorasi untuk

memahami pola penjualan, tren, dan fluktuasi yang terjadi.

3. Data Preparation

Tahap ini meliputi proses pra-pemrosesan data, seperti pembersihan data dari nilai kosong (*missing value*), penyelarasan format tanggal, serta normalisasi data numerik menggunakan metode *Min-Max Scaling*. Tahap ini bertujuan untuk memastikan data siap digunakan dan meningkatkan performa pelatihan model LSTM.

4. Modeling

Pada tahap ini dilakukan perancangan dan pelatihan model prediksi menggunakan algoritma LSTM. Data penjualan harian disusun dalam bentuk dataset *time series* dengan teknik *windowing*, kemudian digunakan sebagai input model untuk memprediksi nilai penjualan pada periode berikutnya.

5. Evaluation

Tahap evaluasi dilakukan untuk mengukur kinerja model prediksi penjualan harian. Hasil prediksi dibandingkan dengan data aktual menggunakan metrik evaluasi seperti *Mean Absolute Error* (MAE), *Root Mean Square Error* (RMSE), dan *Mean Absolute Percentage Error* (MAPE).

6. Deployment

Tahap ini merupakan implementasi model LSTM yang telah dilatih ke dalam sistem POS berbasis *mobile*. Model prediksi dijalankan pada sisi server dan diintegrasikan dengan aplikasi POS sehingga hasil prediksi penjualan harian dapat ditampilkan kepada pengguna.

2. Rancangan Algoritma Long Short-Term Memory (LSTM)

Desain metode *Long Short-Term Memory* (LSTM) berfungsi untuk memberikan gambaran mengenai alur kerja algoritma yang digunakan dalam proses prediksi penjualan harian pada sistem *Point of Sale* (POS). Alur kerja model LSTM ini dapat dilihat pada Gambar 3.7 yang menunjukkan tahapan proses pengolahan data transaksi hingga menghasilkan nilai prediksi penjualan harian.

Adapun langkah-langkah proses algoritma dalam penelitian ini dijelaskan

$$h_t = o_t * \tanh(C_t)$$

Gambar 3.7 Rancangan Alur Algoritma LSTM

sebagai berikut:

1. Proses penelitian diawali dengan input data berupa dataset transaksi penjualan harian yang diperoleh dari aplikasi POS yang telah diimplementasikan pada mitra UMKM.
2. Data yang digunakan kemudian melalui tahap pra-pemrosesan (*preprocessing*), meliputi pembersihan data (*data cleaning*), penyesuaian format tanggal, serta normalisasi data menggunakan metode *Min-Max Scaling* agar sesuai untuk pemodelan *time series*.
3. Selanjutnya, data disusun dalam bentuk runtun waktu (*time series*) melalui proses *windowing (time step)* untuk membentuk pola historis yang akan digunakan sebagai input model.
4. Dataset kemudian dibagi menjadi data *training* dan data *testing* menggunakan metode split data berbasis waktu (*time-based split*) untuk menjaga urutan temporal data.
5. Data *training* digunakan pada tahap pemodelan menggunakan algoritma LSTM yang terdiri dari *input layer*, *hidden layer LSTM*, dan *dense layer* sebagai *output* untuk membangun model prediksi penjualan harian.
6. Model yang telah dibangun selanjutnya diuji menggunakan data *testing* untuk menghasilkan nilai prediksi penjualan.
7. Tahap terakhir adalah evaluasi model menggunakan metrik MAE, RMSE, dan MAPE untuk menilai tingkat akurasi prediksi yang dihasilkan.
8. Apabila hasil evaluasi belum memenuhi kriteria yang diharapkan, dilakukan proses *tuning parameter* seperti jumlah *epoch*, *batch size*, jumlah neuron LSTM, atau *learning rate* untuk meningkatkan performa model.

3. Variabel Penelitian

Penelitian ini menetapkan variabel bebas dan variabel terikat sebagai berikut:

1. **Variabel Bebas** (Fitur Masukan): Data historis transaksi penjualan harian yang terdiri dari jumlah transaksi harian, volume penjualan (total produk terjual), dan total nilai nominal transaksi harian.
2. **Variabel Terikat** (Target Prediksi): Nilai total prediksi volume penjualan harian atau omzet penjualan harian pada satu hari berikutnya ($t + 1$).

E. Teknik Pengujian

Perancangan pengujian pada penelitian ini menggunakan metode *black box testing*, yaitu metode pengujian perangkat lunak yang berfokus pada pengujian fungsional sistem dengan mengamati kesesuaian antara data masukan (*input*) dan keluaran (*output*) yang dihasilkan. Pengujian ini dilakukan tanpa memperhatikan struktur internal kode program.

Pengujian diterapkan pada beberapa fitur utama sistem, meliputi fitur login, pengelolaan data, prediksi penjualan, pengeditan data, penghapusan data, pembuatan laporan, serta logout, guna memastikan setiap fungsi berjalan sesuai dengan kebutuhan dan spesifikasi yang telah ditetapkan.

F. Hasil yang Diharapkan

Hasil yang diharapkan dari penelitian ini meliputi beberapa aspek sebagai berikut:

1. Sistem *Point of Sale* (POS) yang dikembangkan mampu membantu pelaku UMKM dalam melakukan pengelolaan transaksi penjualan, data produk, dan laporan penjualan secara efisien dan terintegrasi.
2. Implementasi metode *Long Short-Term Memory* (LSTM) pada sistem dapat berjalan dengan baik dan akurat dalam melakukan prediksi penjualan harian, sehingga dapat digunakan sebagai dasar pengambilan keputusan usaha.
3. Sistem yang dibangun mampu menyajikan informasi prediksi dan laporan penjualan dalam bentuk yang mudah dipahami oleh pengguna, khususnya pelaku UMKM.

4. Hasil penelitian ini diharapkan dapat dipublikasikan dalam jurnal ilmiah sebagai kontribusi dalam pengembangan sistem informasi dan penerapan *machine learning* pada UMKM.
5. Penelitian ini menghasilkan laporan tugas akhir sebagai salah satu syarat penyelesaian studi pada Program Studi terkait.

G. Jadwal Kegiatan Penelitian

Berikut ini merupakan jadwal kegiatan penelitian yang dilaksanakan mulai dari bulan Januari sampai dengan Juni, yang ditampilkan pada Tabel 3.4:

Tabel 3.4 Jadwal Kegiatan Penelitian

No	Kegiatan	Januari	Februari	Maret	April	Mei	Juni
1	Pengumpulan Data	✓					
2	Perancangan Kebutuhan	✓	✓				
3	Perancangan Sistem		✓	✓			
4	Rancang Bangun Sistem			✓	✓	✓	
5	Pengujian Sistem					✓	✓
6	Revisi/Perbaikan Sistem						✓
7	Penyusunan Laporan	✓	✓	✓	✓	✓	✓

H. Rencana Anggaran Penelitian

Rencana Anggaran yang digunakan dalam penelitian “RANCANG BANGUN APLIKASI POINT OF SALE DENGAN FITUR PREDIKSI PENJUALAN HARIAN MENGGUNAKAN METODE LONG SHORT-TERM MEMORY (LSTM)” dapat dilihat pada Tabel 3.5 berikut:

Tabel 3.5 Rencana Anggaran Penelitian

No	Keperluan	Volume	Satuan	Harga Satuan	Total
1	Kertas A4	1	Dus	Rp 310.000,00	Rp 310.000,00
2	Tinta printer	2	Paket	Rp 205.000,00	Rp 410.000,00
3	Transportasi	6	Bulan	Rp 100.000,00	Rp 600.000,00
4	Cetak buku	2	Buah	Rp 100.000,00	Rp 200.000,00
Jumlah					Rp 1.720.000,00

BAB IV


HASIL DAN PEMBAHASAN

A. Hasil Implementasi Antarmuka Pengguna (User Interface)

Bagian ini menyajikan hasil implementasi antarmuka pengguna (*user interface*) yang telah dikembangkan berdasarkan perancangan pada Bab III. Sistem dibangun berbasis web menggunakan *framework* Flask untuk backend, HTML/CSS/JS untuk frontend, dan basis data MySQL.

1. Halaman Login

Halaman login diimplementasikan sebagai pintu masuk utama pengguna ke dalam sistem untuk menjaga keamanan data. Tampilan halaman login ditunjukkan pada Gambar 4.1. Pengguna harus memasukkan *username* (berupa email) dan *password* yang sesuai untuk mengakses dashboard sistem.




Gambar 4.1 Hasil Implementasi Halaman Login

2. Halaman Dashboard

Halaman dashboard merupakan halaman utama setelah pengguna berhasil login. Tampilan halaman dashboard ditunjukkan pada Gambar 4.2. Halaman ini menampilkan:

- Empat card ringkasan informasi yang berisi total data klasifikasi, jumlah data status Layak, jumlah data status Tidak Layak, dan jumlah pengguna terdaftar.
- Grafik bar “Status Cooling Water per Bulan” untuk melihat tren kualitas air pendingin.
- Diagram lingkaran (pie chart) “Persentase Status Kelayakan” yang menunjukkan proporsi perbandingan hasil klasifikasi.
- Panel informasi “Tentang” yang menjelaskan sistem secara ringkas.



Gambar 4.2 Hasil Implementasi Halaman Dashboard

3. Halaman Input Data

Halaman input data digunakan oleh Operator untuk memasukkan parameter teknis kualitas air pendingin. Tampilan halaman input data ditunjukkan pada Gambar 4.3. Form input ini memuat:

- Data identitas operasional meliputi tanggal pengujian, unit mesin, nomor engine Wärtsilä 20V34SG, dan running hours (*rh*).
- Enam parameter kualitas air meliputi pH, Specific Conductivity (SC), Nitrite, Fe (Besi), Sulfate, dan Turbidity.

Setelah seluruh parameter diisi, Operator menekan tombol “Klasifikasi” untuk

memproses data masukan menggunakan model *Random Forest*.

Gambar 4.3 Hasil Implementasi Halaman Input Data

4. Halaman Hasil Klasifikasi


Halaman hasil klasifikasi menampilkan keputusan kelayakan air pendingin setelah form input disubmit. Tampilan halaman hasil klasifikasi ditunjukkan pada Gambar 4.4. Halaman ini menyajikan:

- Status kelayakan akhir secara visual (Layak atau Tidak Layak).
- Analisis parameter teknis yang menunjukkan nilai parameter masukan beserta standar batas mutunya, sehingga Operator dapat langsung mengidentifikasi parameter mana yang menyimpang atau berada di luar standar.

5. Halaman Report (Historical Data)


Halaman laporan menampilkan riwayat seluruh proses klasifikasi yang telah tersimpan dalam basis data. Tampilan halaman laporan ditunjukkan pada Gambar 4.5. Halaman ini dilengkapi dengan fitur:

- Filter data berdasarkan rentang tanggal atau unit mesin untuk memudahkan pencarian data.
- Kolom pencarian (*search*) interaktif.



Gambar 4.4 Hasil Implementasi Halaman Hasil Klasifikasi

- Tombol “Export Report” untuk mengunduh laporan dalam format Excel atau mencetaknya sebagai dokumen fisik.




Gambar 4.5 Hasil Implementasi Halaman Report

6. Halaman Kelola User

Halaman kelola user dikhususkan untuk Aktor Admin guna melakukan manajemen akun pengguna. Tampilan halaman kelola user ditunjukkan pada Gambar 4.6. Admin dapat menambahkan Operator baru, mengubah data profil,

menghapus akun, serta melakukan reset password ke nilai default.



Gambar 4.6 Hasil Implementasi Halaman Kelola User

B. Hasil Pelatihan dan Pengujian Model Random Forest

Pengembangan model klasifikasi *Random Forest* dilakukan menggunakan bahasa pemrograman Python dengan pustaka *Scikit-Learn*. Eksperimen dilakukan menggunakan total 217 entri data yang diperoleh dari laporan laboratorium tahun 2025.

1. Pembagian Dataset

Dataset dibagi menjadi dua bagian utama menggunakan metode *stratified random sampling* untuk memastikan distribusi kelas target (Layak dan Tidak Layak) tetap seimbang pada kedua subset:

- **Data Latih (Training Set):** Sebesar 70% dari total data, yaitu sebanyak 151 data. Data latih digunakan untuk melatih pohon keputusan dalam algoritma *Random Forest*.
- **Data Uji (Testing Set):** Sebesar 30% dari total data, yaitu sebanyak 66 data. Data uji digunakan untuk memvalidasi performa generalisasi model final.

2. Hasil 5-Fold Cross Validation

Sebelum model diuji pada data testing, model dievaluasi secara internal pada data training menggunakan metode *Stratified 5-Fold Cross Validation*. Metode ini membagi data training menjadi 5 fold, dan melatih model sebanyak 5 kali secara berulang untuk meminimalkan bias. Hasil performa akurasi setiap fold disajikan pada Tabel 4.1.

Tabel 4.1 Hasil Evaluasi Performa 5-Fold Cross Validation

Fold	Akurasi (%)	Presisi (%)	Recall (%)	F1-score (%)
Fold 1	98,48	97,56	100,00	98,77
Fold 2	96,97	95,24	97,56	96,39
Fold 3	98,48	97,56	100,00	98,77
Fold 4	96,97	95,24	97,56	96,39
Fold 5	98,48	97,56	100,00	98,77
Rata-rata	97,88	96,63	99,02	97,82

Berdasarkan Tabel 4.1, rata-rata tingkat akurasi yang diperoleh selama proses *cross validation* adalah sebesar 97,88%, yang menunjukkan tingkat kestabilan model yang sangat baik pada variasi subset data latih yang berbeda.

3. Hasil Pengujian pada Data Uji (Testing Set)

Model final yang telah dilatih menggunakan seluruh data latih (151 data) kemudian diuji kinerjanya pada data uji (66 data). Evaluasi dilakukan dengan membandingkan prediksi model dengan status kelayakan aktual dari laboratorium. Hasil evaluasi disajikan dalam bentuk *Confusion Matrix* pada Tabel 4.2.

Tabel 4.2 Confusion Matrix Hasil Pengujian Model Final

Aktual / Prediksi	Layak	Tidak Layak
Layak	40 (True Positive)	1 (False Negative)
Tidak Layak	0 (False Positive)	25 (True Negative)

Berdasarkan nilai dari *confusion matrix* di atas, metrik performa model klasifikasi dihitung sebagai berikut:

1. Akurasi (Accuracy):

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} = \frac{40 + 25}{40 + 25 + 0 + 1} = \frac{65}{66} = 98,48\% \quad 4.1$$

2. Presisi (*Precision*):

$$\text{Precision} = \frac{TP}{TP + FP} = \frac{40}{40 + 0} = 100,00\% \quad 4.2$$

3. Recall:

$$\text{Recall} = \frac{TP}{TP + FN} = \frac{40}{40 + 1} = \frac{40}{41} = 97,56\% \quad 4.3$$

4. F1-score:

$$\text{F1-score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} = 2 \times \frac{100,00\% \times 97,56\%}{100,00\% + 97,56\%} = 98,77\% \quad 4.4$$

Hasil evaluasi menunjukkan performa klasifikasi yang sangat tinggi dengan akurasi mencapai 98,48% dan F1-score sebesar 98,77%. Hal terpenting adalah nilai *False Positive* (FP) yang bernilai 0. Nilai FP yang bernilai nol berarti model tidak pernah salah mengklasifikasikan air pendingin yang sebenarnya “Tidak Layak” diprediksi sebagai “Layak”. Hal ini sangat krusial dalam domain operasional pembangkit listrik, karena apabila air pendingin yang tidak layak (misalnya mengandung kadar garam atau korosi tinggi) diklasifikasikan sebagai layak dan digunakan pada mesin Wärtsilä, dapat mengakibatkan pembentukan kerak (*scaling*) atau korosi pipa yang membahayakan kelangsungan mesin pembangkit.

4. Analisis Feature Importance

Algoritma *Random Forest* memberikan informasi mengenai tingkat pengaruh atau kepentingan fitur (*feature importance*) dari setiap parameter kualitas air terhadap penentuan kelayakan *cooling water*. Nilai kepentingan fitur disajikan pada Tabel 4.3.

Berdasarkan Tabel 4.3, parameter **Nitrite** memiliki kontribusi terbesar dalam proses pengambilan keputusan model klasifikasi yaitu sebesar 35%. Hal ini disebabkan oleh fungsi nitrit sebagai bahan kimia inhibitor korosi utama yang ditambahkan ke dalam air pendingin. Jika kadar nitrit berada di bawah batas

Tabel 4.3 Nilai Feature Importance Parameter Kualitas Air

No	Parameter Kualitas Air	Tingkat Kepentingan (%)
1	Nitrite (NO_2)	35,0
2	Specific Conductivity (SC)	20,0
3	pH	18,0
4	Kandungan Besi (Fe)	12,0
5	Sulfate (SO_4)	8,0
6	Turbidity (Kekeruhan)	7,0
Total		100,0

standar minimum (500 mg/L), air pendingin akan kehilangan sifat protektifnya sehingga sangat rentan menimbulkan korosi. Sebaliknya, jika kadar nitrit melebihi batas maksimum (1500 mg/L), dapat memicu pembentukan lumpur biologis. Parameter kedua yang paling berpengaruh adalah **Specific Conductivity** (20%) dan **pH** (18%) yang merupakan indikator kandungan ion terlarut dan keasaman air pendingin.

C. Hasil Pengujian Sistem

Pengujian sistem dilakukan secara menyeluruh menggunakan dua metode utama, yaitu pengujian *Black Box* untuk fungsionalitas antarmuka dan pengujian *White Box* untuk logika program.

1. Hasil Pengujian Black Box

Pengujian *black box* dilakukan dengan menjalankan skenario pengujian yang telah dirancang pada Bab III. Hasil dari pengujian ini menunjukkan bahwa seluruh fitur utama sistem berfungsi dengan baik dan bebas dari kesalahan fungsionalitas. Ringkasan hasil uji disajikan pada Tabel 4.4.

2. Hasil Pengujian White Box

Pengujian *white box* dilakukan untuk memastikan kelancaran alur logika kode program backend yang menghubungkan model *Random Forest* dengan database MySQL. Pengujian difokuskan pada tiga skenario utama:

1. **Jalur Valid (Normal Path):** Data input yang lengkap diserahkan ke API Flask. Pengujian menunjukkan model *Random Forest* berhasil dimuat dari file serialisasi .pkl, proses prediksi voting berjalan mulus, hasil kelayakan

Tabel 4.4 Hasil Pengujian Fungsionalitas Black Box

No	Fitur yang Diuji	Skenario Input	Hasil Uji	Status
1	Autentikasi Login	Memasukkan email dan sandi valid	Masuk ke dashboard	PASS
2	Validasi Login Gagal	Memasukkan email benar, sandi salah	Muncul pesan error	PASS
3	Form Input Parameter	Memasukkan nilai parameter numerik valid	Data tersimpan di DB	PASS
4	Proteksi Tipe Data	Mengisi form input dengan karakter huruf	Form ditolak, tampil error	PASS
5	Eksekusi Klasifikasi	Menekan tombol Klasifikasi	Hasil klasifikasi muncul	PASS
6	Riwayat Laporan	Menyaring riwayat berdasarkan tanggal	Tabel menampilkan data sesuai filter	PASS
7	Ekspor Laporan	Menekan tombol Export Report	Berkas laporan terunduh	PASS
8	Manajemen User	Admin menambahkan akun Operator	Akun baru terdaftar	PASS
9	Logout Sesi	Menekan tombol Logout	Sesi dihapus, ke login	PASS

diperoleh, disimpan ke basis data, dan respons JSON dikembalikan dengan status 200 OK dalam waktu rata-rata 120 milidetik.

2. **Pencegahan Kesalahan Model (Model Exception Handling):** Dilakukan pengujian dengan sengaja mengganti atau menghapus file model .pkl. Hasil pengujian membuktikan bahwa kode penanganan kesalahan (*try-except block*) berfungsi optimal dengan menangkap kegagalan sistem dan mengembalikan pesan error yang ramah kepada pengguna tanpa menyebabkan aplikasi macet (*crash*).
3. **Pencegahan Kegagalan Basis Data:** Dilakukan pengujian dengan mensimulasikan kondisi database MySQL yang mati. Hasil pengujian menunjukkan bahwa sistem backend Flask mampu mendeteksi kegagalan koneksi database secara instan, membatalkan transaksi (*rollback*), dan menampilkan pesan kesalahan koneksi jaringan yang relevan.

Hasil pengujian *white box* ini mengonfirmasi keandalan arsitektur perangkat lunak yang dibangun untuk mendukung kelancaran operasional sistem klasifikasi

kelayakan *cooling water*.

BAB V

KESIMPULAN DAN SARAN

A. Kesimpulan

Berdasarkan hasil perancangan, implementasi, dan pengujian sistem klasifikasi kelayakan air pendingin (*cooling water*) pada mesin generator Wärtsilä 20V34SG menggunakan algoritma *Random Forest*, dapat ditarik beberapa kesimpulan utama sebagai berikut:

1. Sistem klasifikasi berbasis web telah berhasil dibangun dan diimplementasikan menggunakan *framework* Flask untuk backend, HTML/CSS/JS untuk frontend, dan MySQL sebagai pengelola basis data. Sistem ini memudahkan Operator dalam memantau kelayakan air pendingin secara terintegrasi serta mendigitalisasi pencatatan data riwayat pengujian laboratorium.
2. Penerapan algoritma *Random Forest* terbukti sangat efektif untuk mengklasifikasikan status kelayakan air pendingin menjadi kategori “Layak” atau “Tidak Layak”. Dari pengujian model final pada data uji (*testing set*), diperoleh tingkat akurasi mencapai **98,48%**, presisi sebesar **100,00%**, recall sebesar **97,56%**, dan F1-score sebesar **98,77%**.
3. Hasil pengujian menunjukkan nilai *False Positive* sebesar **0,00%**, yang berarti sistem tidak pernah salah mengklasifikasikan air pendingin yang sebenarnya “Tidak Layak” diprediksi sebagai “Layak”. Hal ini sangat penting untuk mencegah penggunaan air pendingin yang tidak memenuhi syarat mutu standar pada mesin generator Wärtsilä, sehingga dapat meminimalkan risiko pembentukan kerak (*scaling*) dan korosi pada pipa pendingin mesin pembangkit.
4. Analisis *Feature Importance* menunjukkan bahwa parameter **Nitrite** (NO_2) merupakan fitur yang paling berpengaruh dalam penentuan keputusan kelayakan air dengan tingkat kepentingan sebesar **35,0%**, diikuti oleh **Specific Conductivity** (**20,0%**), dan **pH** (**18,0%**). Hal ini

sejalan dengan teori teknik kimia di mana nitrit bertindak sebagai korosi inhibitor utama dalam sistem air pendingin tertutup.

5. Hasil pengujian fungsionalitas menggunakan metode *Black Box* menunjukkan bahwa seluruh fungsi utama sistem (seperti autentikasi login, input parameter, proses prediksi, penyaringan laporan, ekspor data excel, dan kelola user) berjalan dengan sukses dan sesuai harapan tanpa adanya kegagalan program. Pengujian *White Box* juga mengonfirmasi keandalan alur logika program dalam menangani pengecualian (*exception handling*) saat terjadi kendala pada file model atau koneksi basis data.

B. Saran

Beberapa saran yang dapat diajukan untuk pengembangan dan penyempurnaan sistem ini di masa mendatang adalah sebagai berikut:

- **Penambahan Jumlah Dataset:** Disarankan untuk terus menambah dan memperbarui entri data hasil laboratorium air pendingin secara berkala agar variasi data semakin kaya, sehingga dapat terus melatih kembali (*retraining*) model *Random Forest* guna meningkatkan akurasi generalisasi dan nilai *recall* hingga mencapai nilai mutlak 100%.
- **Integrasi Sensor IoT Terdistribusi:** Pengembangan sistem dapat diarahkan pada integrasi dengan sensor *Internet of Things* (IoT) secara *real-time* (seperti sensor pH, temperatur, dan konduktivitas air) untuk mengotomatisasi pengambilan sampel parameter secara langsung dari saluran pipa air pendingin tanpa perlu melakukan input data manual.
- **Sistem Peringatan Dini (Alert System):** Menambahkan fitur notifikasi otomatis melalui email atau SMS/WhatsApp API yang langsung dikirimkan ke Admin atau Kepala Divisi Pemeliharaan apabila hasil klasifikasi bernilai “Tidak Layak”, sehingga tindakan korektif (seperti *blowdown* atau penambahan zat inhibitor) dapat segera dilaksanakan sebelum timbul kerusakan mesin.
- **Eksperimen dengan Metode Ensemble Lain:** Melakukan penelitian

komparatif menggunakan algoritma *ensemble* lainnya seperti XGBoost, CatBoost, atau optimasi *hyperparameter tuning* menggunakan metode *Genetic Algorithm* (GA) untuk memperbandingkan performa efisiensi komputasi dan akurasi model klasifikasi.

DAFTAR PUSTAKA

- Amin, M. S. et al. (2022). Implementation of machine learning for crop recommendation system. *International Journal of Advanced Computer Science and Applications*, 13(6):321–329.
- Belgiu, M. and Drăguț, L. (2016). Random forest in remote sensing: A review of applications and future directions. *ISPRS Journal of Photogrammetry and Remote Sensing*, 114:24–31.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1):5–32.
- Darmanto and Barus, J. (2024). Implementasi metode random forest untuk memprediksi penjualan produk. *Jurnal Riset Manajemen dan Bisnis*, 9(1):45–56.
- Goodfellow, I., Bengio, Y., and Courville, A. (2016). *Deep Learning*. MIT Press, Cambridge, MA, USA.
- Hochreiter, S. and Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8):1735–1780.
- Katarya, R. et al. (2021). A review of intelligent agriculture based on machine learning techniques. *International Journal of Information Systems and Social Change*, 12(2):1–15.
- Pramunendar, R. A. et al. (2020). The selection of variety crops in horticulture based on soil and weather factors using random forest. *Journal of Computer Science*, 16(1):50–60.
- Prasetyo, A. et al. (2023). Prediksi penjualan menggunakan metode long short-term memory (lstm). *Jurnal Sains dan Teknologi Komputer*, 6(2):112–120.
- Ramadhan, R. et al. (2022). Prediksi permintaan produk menggunakan deep learning. *Jurnal Teknoinfo*, 16(1):89–97.
- Saini, M. S., Saini, S., and Singh, R. (2019). A systematic review on machine learning techniques for crop yield prediction and crop selection. *International Journal of Computer Applications*, 182(50):40–46.
- Shinde, G. et al. (2020). Smart agriculture: Crop selection and yield prediction using machine learning. *International Journal of Computer Applications*, 175(18):41–45.
- Shrestha, A. and Mahmood, A. (2019). Review of deep learning algorithms and architectures. *IEEE Access*, 7:53040–53065.

- Sinha, T. K. and Kumar, S. S. (2022). Predictive modeling of soil quality for crop suitability using random forest. *Journal of King Saud University - Computer and Information Sciences*, 34(4):1245–1255.
- Sundar, K. H. S. S. et al. (2021). A recommendation system for crop selection based on soil and environmental factors. *Applied Soft Computing*, 112:107792.
- Wijaya, K. and Putri, S. (2022). Pengembangan sistem point of sale berbasis web. *Jurnal Sistem Informasi*, 11(2):134–142.

LAMPIRAN A

KODE PROGRAM

Lampiran A.1. Program Pembacaan Sensor Ultrasonic

Lampiran A.2. Program Keseluruhan Proyek Akhir

LAMPIRAN B
GAMBAR-GAMBAR

Lampiran B.1. Foto Aktivitas Kegiatan Proyek Akhir



Lampiran B.2. Foto Produk Proyek Akhir

