

**RANCANG BANGUN APLIKASI *POINT OF SALE*
DENGAN FITUR PREDIKSI PENJUALAN HARIAN
MENGUNAKAN METODE *LONG SHORT-TERM MEMORY*
(LSTM)**

SKRIPSI

Diajukan Sebagai Salah Satu Syarat Untuk Menyelesaikan
Pendidikan Jenjang Sarjana Terapan
Pada Politeknik Negeri Lhokseumawe



Oleh:

MUHAMMAD KHOLIS

NIM	: 2022573010098
Program Studi	: Teknik Informatika
Jurusan	: Teknologi Informasi dan Komputer

**KEMENTERIAN PENDIDIKAN TINGGI, SAINS, DAN TEKNOLOGI
POLITEKNIK NEGERI LHOKSEUMAWE
TAHUN 2026**

PENGESAHAN PEMBIMBING

Skripsi yang berjudul “*Rancang Bangun Aplikasi Point of Sale dengan Fitur Prediksi Penjualan Harian Menggunakan Metode Long Short-Term Memory (LSTM)*”, disusun oleh Muhammad Kholis, NIM 2022573010098, Program Studi Teknik Informatika, Jurusan Teknologi Informasi dan Komputer Politeknik Negeri Lhokseumawe, telah memenuhi syarat untuk dipertanggungjawabkan di hadapan dewan penguji.

Pembimbing I

Buket Rata, 16 Juli 2026

Pembimbing II

**Zulfan Khairil Simbolon, S.T.,
M.Eng.**

NIP. 196909021993031004

Azhar, S.T., M.T.

NIP. 196408301990031005

Mengetahui,

Ketua Jurusan
Teknologi Informasi dan
Komputer,

Ketua Program Studi
Teknik Informatika,

Salahuddin, S.T., M.Sc.
NIP. 197404242002121001

M. Khadafi, S.T., M.T
NIP. 197507182002121004

PENGESAHAN PENGUJI

Skripsi yang berjudul “*Rancang Bangun Aplikasi Point of Sale dengan Fitur Prediksi Penjualan Harian Menggunakan Metode Long Short-Term Memory (LSTM)*”, disusun oleh Muhammad Kholis, NIM 2022573010098, Program Studi Teknik Informatika, Jurusan Teknologi Informasi dan Komputer Politeknik Negeri Lhokseumawe, telah dipertanggungjawabkan di hadapan dewan penguji dan dinyatakan lulus pada tanggal 27 Juli 2026.

Komisi Sidang,

Zulfan Khairil Simbolon, S.T., M.Eng. (Ketua Sidang)
NIP. 196909021993031004

Azhar, S.T., M.T. (Sekretaris Sidang)
NIP. 196408301990031005

Musta'inul Abdi, S.S.T., M.Kom. (Penguji I)
NIP. 199110302019031015

Dr. Rahmad Hidayat, S.Kom., M.Cs. (Penguji II)
NIP. 198304202012121003

Radhiyatammardhiyyah, S.S.T., M.Sc. (Penguji III)
NIP. 199208262022032011

Mengetahui,

Ketua Jurusan
Teknologi Informasi dan
Komputer,

Ketua Program Studi
Teknik Informatika,

Salahuddin, S.T., M.Sc.
NIP. 197404242002121001

M. Khadafi, S.T., M.T
NIP. 197507182002121004

HALAMAN PERNYATAAN

Dengan ini saya menyatakan bahwa dalam Skripsi ini tidak terdapat karya yang pernah diajukan untuk mendapatkan gelar kesarjanaan di suatu Perguruan Tinggi, dan sepanjang pengetahuan saya juga tidak terdapat karya atau pendapat yang pernah ditulis orang lain, kecuali yang secara tertulis diacu dalam naskah dan disebut dalam daftar pustaka.

Lhokseumawe, 16 Juli 2026

Muhammad Kholis
NIM. 2022573010098

KATA PENGANTAR

Puji syukur penulis panjatkan kehadiran Allah SWT, karena atas rahmat dan hidayah-Nya, penulis dapat menyelesaikan skripsi ini dengan judul *Rancang Bangun Aplikasi Point of Sale dengan Fitur Prediksi Penjualan Harian Menggunakan Metode Long Short-Term Memory (LSTM)*. Skripsi ini disusun sebagai salah satu syarat untuk memperoleh gelar Sarjana Terapan pada Program Studi Teknik Informatika Politeknik Negeri Lhokseumawe. Penulis menyadari bahwa skripsi ini masih jauh dari sempurna. Oleh karena itu, penulis mengharapkan kritik dan saran yang bersifat membangun dari semua pihak.

Dalam penulisan Skripsi ini penulis dapat melaksanakannya dengan baik berkat dukungan, bimbingan, dan bantuan dari berbagai pihak. Oleh karena itu, penulis ingin mengucapkan terima kasih yang sebesar-besarnya kepada:

1. Allah SWT atas segala rahmat, nikmat, kesehatan, serta kekuatan yang diberikan kepada penulis sehingga dapat menyelesaikan skripsi ini.
2. Keluarga tercinta, terutama Ibunda Jumiati yang selalu memberikan doa, dukungan moral maupun material, serta motivasi kepada penulis selama proses penyelesaian pendidikan.
3. Bapak Dr. Ir. Rizal Syahyadi, S.T., M.Eng.Sc., IPM, ASEAN Eng., APEC Eng., selaku Direktur Politeknik Negeri Lhokseumawe.
4. Bapak Salahuddin, S.T., M.Sc. selaku Ketua Jurusan Teknologi Informasi dan Komputer, Bapak Fachri Yanuar Rudi F, S.S.T., M.T. selaku Sekretaris Jurusan Teknologi Informasi dan Komputer, dan Bapak M. Khadafi, S.T., M.T. selaku Ketua Program Studi Teknik Informatika atas segala bimbingan dan perhatian selama masa perkuliahan.
5. Bapak Zulfan Khairil Simbolon, S.T., M.Eng. selaku Pembimbing Utama dan Bapak Azhar, S.T., M.T. selaku Pembimbing Pendamping yang telah membantu, membimbing, dan mengarahkan penulis dalam proses penyelesaian Skripsi ini.
6. Bapak Musta'inul Abdi, S.S.T., M.Kom., Bapak Dr. Rahmad Hidayat, S.Kom., M.Cs., dan Ibu Radhiyatammardhiyyah, S.S.T., M.Sc. selaku penguji yang telah bersedia memberikan arahan dan masukan dalam pengerjaan Skripsi ini.
7. Seluruh Dosen Pengajar Program Studi Teknik Informatika yang telah memberikan ilmu dan motivasi kepada penulis selama masa perkuliahan.

Penulis menyadari bahwa Skripsi ini masih terdapat kekurangan dan ketidaksempurnaan. Oleh sebab itu, penulis mengharapkan adanya saran dan kritik yang membangun guna dijadikan bahan perbaikan dan pembelajaran untuk ke depannya yang bermanfaat bagi penulis dan rekan-rekan yang membacanya. Semoga bantuan dan kebaikan semua pihak dapat menjadi amal ibadah.

Lhokseumawe, 16 Juli 2026

Muhammad Kholis
NIM. 2022573010098

ABSTRAK

Penelitian ini bertujuan merancang dan membangun aplikasi *Point of Sale* (POS) berbasis *mobile* dengan arsitektur *offline-first* yang dilengkapi fitur prediksi penjualan harian menggunakan metode *Long Short-Term Memory* (LSTM), guna membantu pelaku UMKM, dalam hal ini kantin EatsTEDI Universitas Gadjah Mada sebagai mitra penelitian, dalam pengambilan keputusan operasional berbasis data. Sistem dikembangkan menggunakan *framework* Flutter yang terintegrasi dengan basis data lokal Isar DB dan basis data *cloud* Supabase PostgreSQL, sedangkan modul prediksi dibangun menggunakan Python (TensorFlow dan Flask) yang di-*deploy* sebagai layanan API terpisah. Data yang digunakan berupa 313 hari aktif transaksi penjualan harian yang diolah sebagai data deret waktu (*time series*) dengan pendekatan target *log-return*. Kinerja model LSTM dievaluasi menggunakan metrik MAE, RMSE, sMAPE, dan MASE, serta dibandingkan dengan model pembanding *Naive*, *Mean-7*, dan SARIMA melalui pengujian *multi-seed*. Hasil evaluasi menunjukkan bahwa model LSTM *Hybrid* (MAE rata-rata Rp667.718,00, MASE 1,840) belum mampu mengungguli metode *Naive* (MAE Rp519.841,00, MASE 1,432) akibat keterbatasan volume data historis dan dominasi persistensi jangka pendek pada data penjualan. Eksperimen augmentasi data sintetis menggunakan TimeGAN berhasil menurunkan galat model LSTM multi-langkah secara signifikan, namun tetap belum melampaui *baseline Seasonal-Naive*. Berdasarkan temuan tersebut, layanan API produksi menyajikan metode *Seasonal-Naive* sebagai metode penyaji utama prediksi harian. Pengujian fungsional *Black Box* terhadap 14 skenario dan pengujian *White Box* terhadap fungsi kritis layanan prediksi menunjukkan tingkat keberhasilan 100%, sehingga sistem POS *offline-first* ini terbukti layak dioperasikan secara penuh dalam mendukung operasional UMKM.

Kata Kunci: *Point of Sale* (POS), Prediksi Penjualan Harian, *Long Short-Term Memory* (LSTM), *Offline-First*, TimeGAN, UMKM

ABSTRACT

This study aims to design and develop a mobile-based Point of Sale (POS) application with an offline-first architecture, equipped with a daily sales prediction feature using the Long Short-Term Memory (LSTM) method, to assist MSMEs, in this case the EatsTEDI canteen of Universitas Gadjah Mada as the research partner, in data-driven operational decision-making. The system was developed using the Flutter framework integrated with the local Isar DB database and the Supabase PostgreSQL cloud database, while the prediction module was built using Python (TensorFlow and Flask) deployed as a separate API service. The data used consist of 313 active days of daily sales transactions processed as time-series data using a log-return target approach. The performance of the LSTM model was evaluated using the MAE, RMSE, sMAPE, and MASE metrics, and compared against the Naive, Mean-7, and SARIMA baseline models through multi-seed testing. The evaluation results show that the Hybrid LSTM model (average MAE of IDR 667,718.00 and MASE of 1.840) was unable to outperform the Naive method (MAE of IDR 519,841.00 and MASE of 1.432) due to the limited volume of historical data and the dominance of short-term persistence in the sales data. A synthetic data augmentation experiment using TimeGAN significantly reduced the error of the multi-step LSTM model, yet still did not surpass the Seasonal-Naive baseline. Based on these findings, the production API service presents the Seasonal-Naive method as the primary forecasting method for daily predictions. Black Box functional testing on 14 scenarios and White Box testing on the critical functions of the prediction service showed a 100% success rate, proving that this offline-first POS system is fully viable for supporting MSME operations.

Keywords: *Point of Sale (POS), Daily Sales Prediction, Long Short-Term Memory (LSTM), Offline-First, TimeGAN, MSMEs*

DAFTAR ISI

PENGESAHAN PEMBIMBING	ii
PENGESAHAN PENGUJI	iii
HALAMAN PERNYATAAN.....	iv
KATA PENGANTAR	v
ABSTRAK	vii
ABSTRACT.....	viii
DAFTAR ISI	ix
DAFTAR GAMBAR	xii
DAFTAR TABEL	xiv
BAB I PENDAHULUAN	1
1.1 Latar Belakang Masalah	1
1.2 Rumusan Masalah	6
1.3 Tujuan Penelitian	7
1.4 Batasan Masalah.....	7
1.5 Manfaat Penelitian	9
1.6 Sistematika Penulisan	10
BAB II TINJAUAN PUSTAKA	13
2.1 <i>State of the Art</i>	13
2.2 Tinjauan Teoritis.....	20
2.2.1 <i>Point of Sale (POS)</i>	20
2.2.2 Peramalan Deret Waktu (<i>Time Series Forecasting</i>)	21
2.2.3 <i>Baseline Seasonal-Naive</i>	22
2.2.4 <i>Recurrent Neural Network (RNN)</i>	23
2.2.5 <i>Long Short-Term Memory (LSTM)</i>	24
2.2.6 <i>Generative Adversarial Network (GAN)</i> dan TimeGAN ...	26
2.2.7 Praproses Data	27
2.2.8 Metrik Evaluasi	28
2.2.9 Flutter.....	30
2.2.10 Pengujian <i>Black Box</i>	31
BAB III METODOLOGI PENELITIAN	32
3.1 Data dan Pengumpulan Data.....	32
3.2 Analisis Kebutuhan Sistem	35
3.2.1 Analisis Kebutuhan Fungsional	35
3.2.2 Analisis Kebutuhan Non-Fungsional	37

3.3	Perancangan Sistem	38
3.3.1	Arsitektur Sistem	39
3.3.2	Pemodelan Sistem <i>Unified Modeling Language</i> (UML)	41
3.3.3	Perancangan Antarmuka Pengguna (<i>User Interface</i>)	66
3.4	Perancangan Metode Penelitian	82
3.4.1	Perancangan Alur Penelitian	83
3.4.2	<i>Flowchart</i> Penerapan Metode <i>Long Short-Term Memory</i> ..	84
3.4.3	<i>Flowchart</i> Perhitungan Sel <i>Long Short-Term Memory</i>	88
3.4.4	Perhitungan Metrik Evaluasi Pengujian	90
3.5	Skenario Pengujian Model	92
3.5.1	Skenario 1: Pengujian Model LSTM terhadap <i>Baseline</i>	92
3.5.2	Skenario 2: Pengujian Stabilitas <i>Multi-Seed</i>	93
3.5.3	Skenario 3: Pengujian Augmentasi Data Sintetis TimeGAN	93
3.5.4	Skenario 4: Pengujian Horizon Prakiraan Rekursif	94
3.6	Perancangan Pengujian Sistem	95
3.6.1	Perancangan Pengujian <i>Black Box</i>	95
3.6.2	Perancangan Pengujian <i>White Box</i>	97
3.6.3	Indikator Keberhasilan Penelitian	98
BAB IV	HASIL DAN PEMBAHASAN	99
4.1	Hasil Implementasi Sistem	99
4.1.1	Implementasi Antarmuka Aplikasi Mobile	99
4.1.2	Implementasi Backend dan Basis Data Cloud	115
4.1.3	Implementasi Layanan Prediksi (API)	116
4.2	Hasil Implementasi Praproses Data	120
4.2.1	Deskripsi dan Eksplorasi Awal Dataset EatsTEDI	120
4.2.2	Penyaringan Hari Aktif dan Transformasi Target Log-Return	121
4.2.3	Pembentukan Sequence dan Pembagian Dataset	122
4.3	Hasil Implementasi Mekanisme Prediksi	124
4.3.1	Implementasi Arsitektur Model LSTM	124
4.3.2	Hasil Pelatihan Model	126
4.3.3	Implementasi Augmentasi Data Sintetis TimeGAN	127
4.3.4	Implementasi Prediksi Rekursif Multi-Langkah	129
4.3.5	Implementasi Fungsi Metrik Evaluasi	131
4.4	Hasil Pengujian Model terhadap Skenario Pengujian	133
4.4.1	Skenario 1: Pengujian Model LSTM terhadap Baseline Statistik	133

4.4.2	Skenario 2: Pengujian Stabilitas Model melalui Multi-Seed	135
4.4.3	Skenario 3: Pengujian Augmentasi Data Sintetis TimeGAN	138
4.4.4	Skenario 4: Pengujian Horizon Prakiraan Rekursif	140
4.4.5	Rekapitulasi Hasil Keempat Skenario	141
4.5	Hasil Pengujian Sistem.....	143
4.5.1	Hasil Pengujian Black Box	143
4.5.2	Hasil Pengujian Mekanisme Sinkronisasi Offline-First	145
4.5.3	Hasil Pengujian White Box.....	146
4.6	Pembahasan Hasil Penelitian	148
4.6.1	Analisis Dominasi Persistensi Jangka Pendek pada Data Kantin Institusional	148
4.6.2	Analisis Kegagalan LSTM Mengungguli Baseline: Over- Smoothing pada Data Pendek	148
4.6.3	Analisis Ketidakstabilan Model akibat Keterbatasan Volume Data	149
4.6.4	Analisis Kontribusi dan Batas Efektivitas Augmentasi TimeGAN	150
4.6.5	Analisis Interpretasi Nilai MASE Lebih dari Satu	150
4.6.6	Analisis Keputusan Metode Penyaji pada Layanan Produksi	151
4.6.7	Pembahasan Kelayakan Fungsional dan Kontribusi Arsitektur Offline-First	153
4.6.8	Posisi Temuan terhadap Penelitian Terdahulu	154
4.7	Keterbatasan Sistem dan Penelitian	155
4.7.1	Keterbatasan Sistem POS.....	155
4.7.2	Keterbatasan Penelitian Model Prediksi	156
BAB V	PENUTUP.....	159
5.1	Kesimpulan	159
5.2	Saran	161
DAFTAR PUSTAKA.....		164
LAMPIRAN		167

DAFTAR GAMBAR

3.1	Arsitektur Sistem POS	39
3.2	<i>Use Case Diagram</i> Sistem POS	42
3.3	<i>Activity Diagram</i> Registrasi Toko Baru	52
3.4	<i>Activity Diagram</i> Login Akun	53
3.5	<i>Activity Diagram</i> Mengelola Katalog Produk	54
3.6	<i>Activity Diagram</i> Mengelola Kategori	55
3.7	<i>Activity Diagram</i> Melakukan <i>Checkout</i>	57
3.8	<i>Activity Diagram</i> Mengaudit Riwayat Stok.....	58
3.9	<i>Activity Diagram</i> Melihat <i>Dashboard</i>	59
3.10	<i>Activity Diagram</i> Melihat Prediksi Penjualan Harian	60
3.11	<i>Activity Diagram</i> Melihat Riwayat Analisis	61
3.12	<i>Activity Diagram</i> Sinkronisasi Data.....	62
3.13	<i>Activity Diagram</i> Kirim <i>Broadcast</i> Notifikasi	63
3.14	<i>Activity Diagram</i> Mengelola Karyawan	64
3.15	<i>Activity Diagram</i> Mengatur Profil Toko	66
3.16	Desain Halaman Registrasi Toko Baru.....	68
3.17	Desain Halaman <i>Login</i>	69
3.18	Desain Halaman Pemilihan Toko	70
3.19	Desain Halaman Kelola Katalog Produk	71
3.20	Desain Halaman Kelola Kategori	72
3.21	Desain Halaman Kasir	73
3.22	Desain Halaman Pembayaran	74
3.23	Desain Halaman Riwayat Stok	75
3.24	Desain Halaman Dasbor	76
3.25	Desain Halaman Laporan.....	77
3.26	Desain Halaman Prediksi Penjualan Harian	78
3.27	Desain Halaman Riwayat Analisis	79
3.28	Desain Halaman Manajemen Karyawan	80
3.29	Desain Halaman Profil Toko	81
3.30	Desain Halaman Pengaturan	82
3.31	Alur Penelitian	83
3.32	Alur Kerja Algoritma <i>Long Short-Term Memory</i> (LSTM).....	85
3.33	<i>Flowchart</i> Perhitungan Sel <i>Long Short-Term Memory</i>	88
4.1	Implementasi Halaman Registrasi	100

4.2	Implementasi Halaman <i>Login</i>	101
4.3	Implementasi Halaman Informasi Toko	102
4.4	Implementasi Halaman Pilih Toko	103
4.5	Implementasi Halaman Dasbor Owner	104
4.6	Implementasi Halaman Kelola Produk dan Tambah Produk.....	105
4.7	Implementasi Halaman Kelola Kategori	106
4.8	Implementasi Halaman Kelola Stok dan Ubah Stok Produk.....	107
4.9	Implementasi Halaman Riwayat Stok.....	108
4.10	Implementasi Halaman Kasir (POS) dan Detail Pesanan	109
4.11	Implementasi Halaman Pembayaran	110
4.12	Implementasi Halaman Riwayat Transaksi	111
4.13	Implementasi Halaman Struk Digital	112
4.14	Implementasi Halaman Laporan Analitik.....	113
4.15	Implementasi Halaman <i>Smart Analitik</i>	114
4.16	Implementasi Halaman Riwayat Analisis.....	115
4.17	Kurva Kerugian Pelatihan (<i>Training Loss Curve</i>) Model LSTM	127
4.18	Grafik Pendapatan Aktual vs. Prediksi Model LSTM Hybrid	135
4.19	Boxplot Distribusi MAE Hasil Pengujian <i>Multi-Seed</i>	138

DAFTAR TABEL

2.1	<i>State of the Art</i> Penelitian Terdahulu.....	15
3.1	Struktur Data <i>Dataset</i> Final Penelitian	33
3.2	Spesifikasi Perangkat Keras	37
3.3	Spesifikasi Perangkat Lunak	37
3.4	<i>Use Case</i> Registrasi Toko Baru	43
3.5	<i>Use Case</i> Login Akun	44
3.6	<i>Use Case</i> Mengelola Katalog Produk	44
3.7	<i>Use Case</i> Mengelola Kategori.....	45
3.8	<i>Use Case</i> Melakukan <i>Checkout</i>	46
3.9	<i>Use Case</i> Mengaudit Riwayat Stok	46
3.10	<i>Use Case</i> Melihat <i>Dashboard</i>	47
3.11	<i>Use Case</i> Melihat Prediksi Penjualan Harian.....	47
3.12	<i>Use Case</i> Melihat Riwayat Analisis	48
3.13	<i>Use Case</i> Sinkronisasi Data	49
3.14	<i>Use Case</i> Kirim <i>Broadcast</i> Notifikasi.....	49
3.15	<i>Use Case</i> Mengelola Karyawan	50
3.16	<i>Use Case</i> Mengatur Profil Toko	50
3.17	Skenario 1: Pengujian Model LSTM terhadap <i>Baseline</i>	93
3.18	Skenario 2: Pengujian Stabilitas <i>Multi-Seed</i>	93
3.19	Skenario 3: Pengujian Augmentasi Data Sintetis TimeGAN	94
3.20	Skenario 4: Pengujian Horizon Prakiraan Rekursif	94
3.21	Skenario Pengujian <i>Black Box</i>	95
4.1	Statistik Ringkas Dataset Pendapatan Harian	120
4.2	Pembagian Dataset dan Dimensi Sequence.....	122
4.3	Perbandingan Performa pada Data Uji (<i>One-Step-Ahead</i>)	134
4.4	Statistik Performa LSTM Hybrid pada 10 Seed	137
4.5	Perbandingan Performa Eksperimen Augmentasi TimeGAN (<i>Multi-Step</i> , Horizon 7).....	138
4.6	Galat Prediksi Rekursif per Horizon Prakiraan.....	140
4.7	Rekapitulasi Hasil Pengujian Keempat Skenario.....	142
4.8	Hasil Pengujian <i>Black Box</i>	143
4.9	Hasil Pengujian Mekanisme Sinkronisasi	145
4.10	Hasil Pengujian <i>White Box</i>	147

BAB I

PENDAHULUAN

1.1 Latar Belakang Masalah

Transformasi digital pada sektor ritel dan usaha mikro, kecil, dan menengah (UMKM) telah menjadikan aplikasi *Point of Sale* (POS) sebagai infrastruktur transaksi yang tidak lagi bersifat opsional. Aplikasi POS modern tidak hanya mencatat transaksi penjualan, tetapi juga menghasilkan data transaksional harian yang bersifat deret waktu (*time series*) secara terus-menerus. Namun demikian, sebagian besar aplikasi POS yang beredar, khususnya pada skala usaha kecil seperti kantin institusi, masih memposisikan data tersebut sebatas sebagai arsip pelaporan dan belum memanfaatkannya sebagai basis pengambilan keputusan yang bersifat prediktif. Akibatnya, keputusan operasional seperti penentuan volume produksi harian, pengadaan bahan baku, dan penjadwalan tenaga kerja masih banyak ditentukan berdasarkan intuisi pengelola, yang berisiko menimbulkan kelebihan persediaan (*overstock*) maupun kehabisan persediaan (*stockout*).

Ketidakakuratan estimasi permintaan harian berdampak langsung pada efisiensi biaya dan tingkat layanan. Peramalan penjualan yang akurat berperan penting dalam menyeimbangkan permintaan dan pasokan serta meningkatkan profitabilitas pada sektor ritel [1]. Karakteristik data penjualan harian pada usaha kuliner institusional bersifat kompleks: terdapat musiman mingguan berupa perbedaan volume antara hari kerja dan akhir pekan, pengaruh kalender akademik,

hari libur nasional, serta fluktuasi yang tidak beraturan. Metode statistik konvensional seperti *moving average* dan ARIMA memiliki keterbatasan dalam menangkap pola non-linear dan ketergantungan temporal jangka panjang pada data dengan karakteristik semacam ini.

Untuk mengatasi keterbatasan tersebut, pendekatan *deep learning* berbasis *Recurrent Neural Network* (RNN), khususnya *Long Short-Term Memory* (LSTM), telah menjadi salah satu metode mutakhir dalam peramalan deret waktu penjualan. LSTM memanfaatkan mekanisme gerbang (*gating mechanism*) untuk mempertahankan informasi lintas rentang waktu yang panjang sekaligus mengatasi masalah *vanishing gradient* yang melekat pada RNN tradisional [2]. Sejumlah penelitian terkini menunjukkan keunggulan pendekatan berbasis LSTM. Optimasi *hyperparameter* menggunakan Keras Tuner pada LSTM untuk prediksi penjualan harian *dataset* ritel Walmart menghasilkan peningkatan akurasi yang signifikan dibandingkan metode peramalan tradisional [3]. De Castro Moraes dkk. [4] mengembangkan arsitektur hibrida CNN-LSTM bertumpuk (*stacked*) dan paralel untuk menangani pola musiman yang bervariasi serta korelasi antarproduk pada 500 deret waktu ritel. Sementara itu, Mansur dkk. [1] menunjukkan bahwa model hibrida CNN-LSTM yang diperkaya variabel eksogen berupa hari libur, hari gajian, aksi unjuk rasa, dan kondisi cuaca mampu mencapai MAPE sebesar 4,16%, mengungguli model ANN, CNN, dan LSTM tunggal. Perkembangan ini memperkuat posisi LSTM sebagai metode yang relevan untuk diintegrasikan ke dalam sistem POS.

Kendati demikian, terdapat dua kondisi yang membatasi keterbukaan hasil tersebut untuk direplikasi pada usaha berskala kecil. Pertama, model *deep learning* bersifat *data-hungry*, yaitu performanya sangat bergantung pada ukuran *dataset*, sehingga pelatihan dengan data yang tidak memadai secara nyata membatasi kegunaannya [5]. Beberapa penelitian yang melaporkan akurasi tinggi memang menggunakan data berskala besar, seperti [4] yang memanfaatkan riwayat transaksi lima tahun. Kedua, ketika akurasi tinggi berhasil dicapai pada data berukuran kecil, keberhasilan tersebut umumnya bertumpu pada ketersediaan variabel eksogen yang kaya dan bukan pada panjang deret waktunya semata. Penelitian [1] mencapai MAPE 4,16% hanya dengan enam bulan data harian dari satu gerai, namun dengan tambahan tujuh variabel cuaca dan peristiwa, sementara penulisnya sendiri mencatat adanya indikasi *overfitting* pada kurva *validation loss*. Kondisi ini menyisakan persoalan bagi kasus di mana variabel eksogen semacam itu tidak tersedia. Sebagai jalan keluar, augmentasi data sintetis menggunakan *Time-series Generative Adversarial Network* (TimeGAN) [6] diusulkan untuk memperkaya sampel pelatihan dan terbukti menurunkan RMSE serta MAE pada beberapa domain [7]. Namun literatur juga mencatat bahwa manfaat augmentasi semakin tidak signifikan seiring bertambahnya ukuran data awal [8], sehingga efektivitas TimeGAN pada data penjualan harian berskala kecil masih merupakan pertanyaan terbuka yang layak diuji secara empiris.

Celah kedua bersifat metodologis. Sebagian besar penelitian peramalan penjualan berbasis LSTM membandingkan modelnya dengan sesama model

machine learning, tetapi jarang mengujinya secara ketat terhadap *baseline* heuristik sederhana seperti *seasonal-naive*, padahal pada data dengan musiman mingguan yang kuat *baseline* semacam ini kerap sangat kompetitif. Pengalaman kompetisi peramalan berskala besar menunjukkan bahwa metode sederhana masih menjadi pembanding yang sulit dikalahkan dan karenanya wajib disertakan sebagai kontrol metodologis [9]. Celah ketiga bersifat implementatif: kajian yang ada umumnya berhenti pada tahap eksperimen model dan belum sampai pada penyatuan model ke dalam aplikasi POS yang benar-benar digunakan pengguna akhir, sehingga jarak antara riset akademik dan penerapan praktis di ritel masih lebar [10]. Penelitian ini menempatkan diri tepat pada ketiga celah tersebut, yaitu membangun aplikasi POS yang di dalamnya tertanam fitur prediksi penjualan harian berbasis LSTM, mengevaluasi kontribusi augmentasi TimeGAN, serta menguji model secara jujur terhadap *baseline seasonal-naive*.

Studi kasus penelitian ini menggunakan data transaksi platform EatsTEDI pada Departemen Teknik Elektro dan Informatika (DTEDI), Universitas Gadjah Mada. Data mentah terhimpun dalam rentang 24 Agustus 2024 sampai dengan 20 Juni 2026, mencakup 666 hari kalender atau sekitar 22 bulan operasional. Setelah proses penyaringan, hari aktif pertama dengan transaksi tercatat adalah 26 Agustus 2024, sehingga rentang efektif yang digunakan adalah 26 Agustus 2024 sampai dengan 20 Juni 2026 dan menghasilkan 313 hari dengan transaksi tercatat. Rentang efektif tersebut memuat 475 hari kerja secara kalender, sehingga terdapat sejumlah hari tanpa transaksi yang berasal dari masa libur antarsemester, hari libur

nasional, serta penutupan operasional kantin. Ketimpangan ini bukan merupakan kehilangan data yang bersifat acak, melainkan cerminan langsung dari ritme institusional yang justru menjadi objek pemodelan dalam penelitian ini.

Karakteristik demikian menjadikan *dataset* EatsTEDI representatif untuk persoalan yang diangkat. Secara temporal, rentang 22 bulan mencakup empat semester berturut-turut, yakni semester gasal dan genap tahun akademik 2024/2025 serta semester gasal dan genap tahun akademik 2025/2026. Cakupan dua tahun akademik penuh ini memungkinkan pola musiman berbasis kalender akademik, meliputi periode perkuliahan normal, minggu ujian tengah semester, minggu ujian akhir semester, dan masa libur antarsemester, teramati secara berulang dan bukan hanya sekali, sehingga model memiliki peluang mempelajarinya sebagai pola dan bukan sebagai anomali. Secara struktural, data juga memuat musiman mingguan berupa perbedaan volume transaksi antara hari kerja dan akhir pekan. Namun demikian, dengan hanya 313 titik pengamatan, jumlah sampel pelatihan yang tersedia bagi model LSTM tetap tergolong sangat terbatas apabila dibandingkan dengan penelitian sejenis yang menggunakan ribuan hingga jutaan catatan transaksi [3], [4]. Kondisi inilah yang menempatkan *dataset* EatsTEDI sebagai lingkungan uji yang tepat, yaitu cukup kaya secara pola musiman untuk menjadi persoalan peramalan yang bermakna, namun cukup terbatas secara volume untuk menguji secara jujur apakah kompleksitas LSTM dan augmentasi sintetis TimeGAN benar-benar memberikan nilai tambah dibandingkan pendekatan sederhana pada skala usaha kecil.

Berdasarkan uraian tersebut, penelitian ini merancang dan membangun aplikasi *Point of Sale* dengan fitur prediksi penjualan harian menggunakan metode *Long Short-Term Memory*. Kontribusi penelitian mencakup tiga aspek. Pertama, perancangan arsitektur aplikasi POS yang mengintegrasikan modul prediksi ke dalam alur kerja transaksi harian sehingga hasil peramalan dapat langsung dimanfaatkan pengelola. Kedua, evaluasi empiris pengaruh augmentasi data sintesis TimeGAN terhadap performa LSTM pada *dataset* penjualan berskala kecil. Ketiga, perbandingan model terhadap *baseline seasonal-naive* pada beberapa horizon peramalan sebagai kontrol metodologis, guna menghasilkan rekomendasi yang jujur mengenai kondisi di mana pendekatan *deep learning* layak diterapkan pada konteks usaha kuliner berskala kecil di Indonesia.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana merancang dan membangun aplikasi *Point of Sale* yang mengintegrasikan fitur prediksi penjualan harian ke dalam alur kerja transaksi, sehingga hasil peramalan dapat langsung dimanfaatkan oleh pengelola usaha?
2. Bagaimana menerapkan model *Long Short-Term Memory* untuk memprediksi penjualan harian pada *dataset* EatsTEDI yang berjumlah 313 titik pengamatan, serta bagaimana pengaruh augmentasi data sintesis

Time-series Generative Adversarial Network (TimeGAN) terhadap akurasi model tersebut?

3. Bagaimana tingkat akurasi model *Long Short-Term Memory* dibandingkan terhadap *baseline seasonal-naive* pada beberapa horizon peramalan?

1.3 Tujuan Penelitian

Sejalan dengan rumusan masalah tersebut, penelitian ini bertujuan untuk:

1. Merancang dan membangun aplikasi *Point of Sale* berbasis *mobile* yang mengintegrasikan fitur prediksi penjualan harian ke dalam alur kerja transaksi, serta menguji fungsionalitasnya melalui pengujian sistem.
2. Menerapkan model *Long Short-Term Memory* untuk prediksi penjualan harian pada *dataset* EatsTEDi dan menganalisis pengaruh augmentasi data sintetis TimeGAN terhadap akurasi model pada kondisi data pelatihan yang terbatas.
3. Mengukur tingkat akurasi model *Long Short-Term Memory* terhadap *baseline seasonal-naive* pada beberapa horizon peramalan, guna menghasilkan rekomendasi mengenai kondisi kelayakan penerapan pendekatan *deep learning* pada usaha kuliner berskala kecil.

1.4 Batasan Masalah

Agar penelitian ini terarah dan terukur, ditetapkan batasan sebagai berikut:

1. Sumber dan cakupan data. Data yang digunakan adalah data transaksi

platform EatsTEDI pada Departemen Teknik Elektro dan Informatika (DTEDI), Universitas Gadjah Mada, dengan rentang efektif 26 Agustus 2024 sampai dengan 20 Juni 2026 dan menghasilkan 313 hari dengan transaksi tercatat. Pemodelan dilakukan secara *univariat* dengan variabel target berupa total nilai penjualan harian, tanpa menyertakan variabel eksogen seperti kondisi cuaca, promosi, maupun harga karena tidak tersedia pada *dataset*.

2. Granularitas prediksi. Prediksi dilakukan pada tingkat agregat penjualan harian, bukan pada tingkat *item* atau kategori produk secara individual.
3. Cakupan metode. Metode peramalan yang dikembangkan dibatasi pada arsitektur *Long Short-Term Memory* dengan augmentasi data sintetis TimeGAN, serta dibandingkan terhadap model pembanding berupa *Naive*, *Mean-7*, *Seasonal-Naive*, dan SARIMA. Arsitektur *deep learning* lain seperti *Transformer* dan *Temporal Fusion Transformer*, maupun metode augmentasi lain seperti *jittering* dan *window warping*, tidak menjadi objek pengujian dalam penelitian ini.
4. Metrik evaluasi. Evaluasi performa model menggunakan metrik MAE, RMSE, sMAPE, dan MASE. Metrik MAPE konvensional tidak digunakan karena rentan menghasilkan galat persentase yang tidak representatif pada hari dengan nilai pendapatan sangat rendah.
5. Cakupan aplikasi dan pengujian. Aplikasi POS dikembangkan pada platform Android menggunakan *framework* Flutter, dengan model dilatih secara

luring (*offline*) dan hasil pelatihannya diintegrasikan sebagai layanan prediksi. Pengembangan untuk platform iOS serta mekanisme pelatihan ulang otomatis (*online* atau *incremental learning*) berada di luar cakupan penelitian. Pengujian dibatasi pada pengujian fungsional dan struktural sistem serta pengujian akurasi model, tanpa mencakup pengukuran dampak ekonomi penerapan sistem.

1.5 Manfaat Penelitian

Penelitian ini diharapkan memberikan manfaat pada dua tataran. Secara teoritis, penelitian ini menyediakan bukti empiris mengenai performa model *Long Short-Term Memory* pada data penjualan harian berskala kecil dengan karakteristik deret tidak sinambung, suatu kondisi yang selama ini kurang terwakili dalam literatur karena sebagian besar penelitian menggunakan *dataset* berskala besar dan sinambung, sekaligus menguji efektivitas augmentasi data sintetis TimeGAN sebagai upaya mengatasi keterbatasan jumlah sampel pelatihan. Penelitian ini juga menegaskan pentingnya penyertaan *baseline* heuristik sederhana seperti *seasonal-naive* sebagai kontrol metodologis dalam penelitian peramalan berbasis *deep learning*, sehingga dapat menjadi rujukan bagi kajian selanjutnya yang mengintegrasikan model peramalan ke dalam aplikasi transaksional. Secara praktis, penelitian ini menghasilkan aplikasi *Point of Sale* yang tidak hanya mencatat transaksi tetapi juga menyajikan estimasi penjualan harian sebagai bahan pertimbangan pengelola dalam menentukan volume produksi, pengadaan bahan

baku, dan penjadwalan tenaga kerja; memberikan gambaran mengenai pola permintaan kantin institusional yang terkait dengan ritme kalender akademik; serta menyediakan rujukan teknis bagi pengembang perangkat lunak mengenai arsitektur penyatuan model *machine learning* ke dalam aplikasi *mobile*. Lebih lanjut, hasil perbandingan terhadap *baseline* sederhana diharapkan menjadi rekomendasi berbasis bukti bagi pelaku usaha mikro, kecil, dan menengah mengenai kondisi kelayakan penerapan pendekatan *deep learning* pada skala usaha kecil, sehingga sumber daya pengembangan dapat dialokasikan secara proporsional.

1.6 Sistematika Penulisan

Sistematika penulisan ini merupakan kebulatan seluruh materi penyusunan yang diungkapkan secara garis besar dan dibagi menjadi lima bab. Masing-masing bab terdiri dari beberapa sub bab. Adapun susunan sistematikanya adalah sebagai berikut:

BAB I PENDAHULUAN

Bab ini memuat latar belakang masalah yang menjelaskan urgensi prediksi penjualan harian pada aplikasi *Point of Sale* skala usaha kecil, rumusan masalah, tujuan penelitian, batasan masalah, manfaat penelitian, dan sistematika penulisan.

BAB II TINJAUAN PUSTAKA

Bab ini menyajikan *state of the art* penelitian terdahulu mengenai peramalan penjualan dan sistem *Point of Sale*, serta landasan teori yang meliputi konsep peramalan deret waktu, arsitektur *Long Short-Term Memory*, model pembandingan (*baseline*), metrik evaluasi prediksi, *Generative Adversarial Network* dan TimeGAN, teknologi pengembangan aplikasi, serta metode pemodelan dan pengujian perangkat lunak.

BAB III METODOLOGI PENELITIAN

Bab ini membahas metodologi penelitian yang digunakan, mencakup sumber data dan proses pengumpulan *dataset* EatsTEDI, variabel penelitian, *preprocessing* data, rancangan sistem berupa diagram UML, perancangan antarmuka, rancangan algoritma *Long Short-Term Memory*, serta teknik pengujian dan indikator keberhasilan penelitian.

BAB IV HASIL DAN PEMBAHASAN

Bab ini membahas hasil implementasi sistem secara menyeluruh, mencakup tampilan antarmuka aplikasi *Point of Sale* dan layanan API prediksi, tahapan *preprocessing* data, implementasi dan pelatihan model *Long Short-Term Memory*, eksperimen augmentasi data sintetis TimeGAN, hasil evaluasi model terhadap *baseline seasonal-naive*, serta hasil pengujian fungsional sistem beserta pembahasan temuan dan keterbatasan penelitian.

BAB V PENUTUP

Bab ini menyajikan simpulan dari seluruh proses penelitian berdasarkan hasil yang diperoleh, serta saran untuk pengembangan sistem dan penelitian lanjutan di bidang peramalan penjualan berbasis *deep learning*.

BAB II

TINJAUAN PUSTAKA

2.1 *State of the Art*

Kajian *state of the art* pada subbab ini disusun untuk memetakan posisi penelitian yang dilakukan terhadap penelitian-penelitian terdahulu yang relevan. Penelusuran literatur difokuskan pada empat kelompok kajian yang saling berkaitan.

Kelompok pertama adalah penelitian yang menerapkan *Long Short-Term Memory* dan variannya untuk peramalan penjualan ritel. Kelompok kajian ini menunjukkan kecenderungan yang konsisten, yaitu bahwa arsitektur berbasis LSTM mampu menangkap ketergantungan temporal dan pola musiman pada data penjualan secara lebih baik dibandingkan metode statistik konvensional. Namun demikian, sebagian besar penelitian pada kelompok ini menggunakan *dataset* berskala besar dengan rentang pengamatan bertahun-tahun, sehingga hasilnya belum tentu dapat direplikasi pada skala usaha kecil.

Kelompok kedua adalah penelitian yang mengkaji augmentasi data sintetis, khususnya menggunakan *Time-series Generative Adversarial Network* (TimeGAN), sebagai upaya mengatasi keterbatasan jumlah sampel pelatihan. Kelompok ini memperlihatkan hasil yang belum sepenuhnya konvergen: sebagian penelitian melaporkan penurunan galat yang signifikan, sementara sebagian lain mencatat bahwa manfaat augmentasi menurun seiring bertambahnya ukuran data awal.

Kelompok ketiga adalah penelitian yang menyoroti pentingnya *baseline* sederhana sebagai kontrol metodologis dalam evaluasi model peramalan. Kelompok ini menjadi penting karena beberapa penelitian menunjukkan bahwa metode sederhana masih dapat mengungguli model *deep learning* pada kondisi data tertentu.

Kelompok keempat adalah penelitian yang mengintegrasikan modul peramalan ke dalam aplikasi *Point of Sale*. Kelompok ini masih relatif terbatas jumlahnya, dan sebagian besar penelitian di Indonesia pada kelompok ini menggunakan metode statistik atau *machine learning* konvensional, bukan *deep learning*.

Ringkasan penelitian terdahulu beserta persamaan dan perbedaannya dengan penelitian ini disajikan pada Tabel 2.1.

Tabel 2.1 *State of the Art* Penelitian Terdahulu

No	Penulis / Tahun	Judul Artikel	Metode yang Digunakan	Hasil yang Diperoleh	Persamaan	Perbedaan
1	T. de Castro Moraes, X.-M. Yuan, E. P. Chew (2024) [4]	<i>Hybrid Convolutional Long Short-Term Memory Models for Sales Forecasting in Retail</i>	Hibrida CNN-LSTM bertumpuk (S-CNN-LSTM) dan paralel (P-CNN-LSTM)	MAPE 14,15% (bertumpuk) dan 14,76% (paralel) pada 500 deret waktu ritel selama 5 tahun	Sama-sama menggunakan LSTM untuk peramalan penjualan ritel harian	Menggunakan data berskala besar (5 tahun, 500 deret); penelitian ini hanya 313 titik pengamatan. Tidak menguji augmentasi data maupun integrasi ke aplikasi
2	S. Mansur dkk. (2025) [1]	<i>Sales Forecasting for Retail Stores Using Hybrid Neural Networks and Sales-Affecting Variables</i>	Hibrida CNN-LSTM dengan variabel eksogen (cuaca, hari libur, hari gajian, unjuk rasa)	MAPE 4,16%, mengungguli ANN (19,74%), CNN (13,90%), dan LSTM tunggal (10,39%)	Menggunakan LSTM pada data penjualan harian berskala kecil (6 bulan) dari satu gerai	Keberhasilan bertumpu pada tujuh variabel eksogen yang tidak tersedia pada <i>dataset</i> penelitian ini; penulis mencatat indikasi <i>overfitting</i> . Tidak menguji <i>baseline</i> sederhana

No	Penulis / Tahun	Judul Artikel	Metode yang Digunakan	Hasil yang Diperoleh	Persamaan	Perbedaan
3	M. Mitra dkk. (2024) [3]	<i>Harnessing LSTM Neural Networks and Hyperparameter Optimization for Precise Sales Forecasting in Retail</i>	LSTM dengan optimasi <i>hyperparameter</i> menggunakan Keras Tuner	Peningkatan akurasi signifikan dibanding metode peramalan tradisional pada <i>dataset</i> Walmart	Sama-sama menerapkan LSTM untuk prediksi penjualan harian	Menggunakan <i>dataset</i> hierarkis berskala besar dengan variabel harga, promosi, dan hari besar; tidak mengkaji keterbatasan data maupun augmentasi sintetis
4	P. Yadav, C. R. Barde (2025) [10]	<i>Retail Real-Time Sales Prediction System Using LSTM and XGBoost</i>	LSTM untuk pemodelan deret waktu dikombinasikan dengan XGBoost, terintegrasi dengan sistem POS	Sistem prediksi penjualan waktu nyata yang terhubung dengan POS untuk penyerapan data dinamis	Sama-sama mengintegrasikan model peramalan ke dalam sistem <i>Point of Sale</i>	Menggunakan pendekatan hibrida LSTM-XGBoost berbasis <i>web</i> ; penelitian ini menggunakan LSTM murni pada aplikasi <i>mobile</i> dan menguji augmentasi TimeGAN
5	J. Yoon, D. Jarrett, M. van der Schaar (2019) [6]	<i>Time-series Generative Adversarial Networks</i>	TimeGAN, yaitu GAN dengan pembelajaran swa-penyelaaan berbasis <i>autoencoder</i> untuk deret waktu	Menghasilkan data sintetis yang mempertahankan dinamika temporal data asli secara lebih baik dibanding GAN konvensional	Menggunakan TimeGAN sebagai metode pembangkitan data sintetis	Berfokus pada kualitas pembangkitan data secara umum, bukan pada dampaknya terhadap akurasi peramalan penjualan pada data berskala kecil

No	Penulis / Tahun	Judul Artikel	Metode yang Digunakan	Hasil yang Diperoleh	Persamaan	Perbedaan
6	P. Tang, Z. Li, X. Wang, X. Liu, P. Mou (2025) [7]	<i>Time Series Data Augmentation for Energy Consumption Data Based on Improved TimeGAN</i>	TimeGAN yang ditingkatkan dengan <i>multi-head self-attention</i> , model prediksi hibrida CNN-GRU	Penurunan RMSE dan MAE serta peningkatan R^2 setelah augmentasi data	Sama-sama menerapkan augmentasi TimeGAN untuk mengatasi keterbatasan jumlah data pelatihan	Diterapkan pada domain konsumsi energi manufaktur dengan model CNN-GRU; penelitian ini pada domain penjualan kantin dengan model LSTM
7	A.-A. Semenoglou, E. Spiliotis, V. Assimakopoulos (2023) [8]	<i>Data Augmentation for Univariate Time Series Forecasting with Neural Networks</i>	Perbandingan sistematis beberapa teknik augmentasi data pada peramalan deret waktu univariat	Manfaat augmentasi lebih signifikan pada jaringan yang lebih dalam, namun menurun seiring bertambahnya ukuran data awal	Sama-sama mengkaji efektivitas augmentasi data pada peramalan deret waktu univariat	Bersifat studi perbandingan lintas <i>dataset</i> tanpa membangun aplikasi; tidak menggunakan TimeGAN sebagai metode augmentasi utama
8	S. Makridakis, E. Spiliotis, V. Assimakopoulos (2022) [9]	<i>The M5 Competition: Background, Organization, and Implementation</i>	Kompetisi peramalan berskala besar dengan pembandingan metode statistik, <i>machine learning</i> , dan <i>deep learning</i>	Metode sederhana dan kombinasi statistik tetap menjadi pembandingan yang kompetitif terhadap model kompleks	Menekankan pentingnya <i>baseline</i> sederhana sebagai kontrol metodologis dalam evaluasi peramalan	Berupa kajian kompetisi lintas ribuan deret waktu; penelitian ini menerapkan prinsip tersebut pada satu studi kasus dengan <i>baseline seasonal-naive</i>

No	Penulis / Tahun	Judul Artikel	Metode yang Digunakan	Hasil yang Diperoleh	Persamaan	Perbedaan
9	R. A. Sembiring & Y. Sary (2025), <i>Jurnal Ilmiah Teknik Mesin, Elektro dan Komputer</i> [11]	<i>Analisa dan Implementasi Long Short-Term Memory (LSTM) dalam Kebutuhan Persediaan Barang di PT. Gunung Sari Indonesia</i>	LSTM dengan <i>window size</i> 14, 30, dan 60 hari, dibandingkan dengan <i>Moving Average</i> ; evaluasi MAD, MSE, MAPE	MAPE LSTM 102–106%, sedangkan <i>Moving Average</i> 85–88%; LSTM lebih adaptif pada pola fluktuatif, <i>Moving Average</i> lebih stabil pada pola konsisten	Sama-sama menerapkan LSTM pada data transaksi penjualan Indonesia dan membandingkannya dengan metode sederhana	Pembanding berupa <i>Moving Average</i> , bukan <i>seasonal-naive</i> ; tidak menguji augmentasi data sintetis maupun membangun aplikasi POS
10	U. M. Jannah dkk. (2025), <i>Jurnal Teknologi Informasi dan Multimedia</i> [12]	<i>Analisis Prediksi Penjualan Isi Ulang Air Galon Menggunakan Metode LSTM dan SARIMA</i>	Perbandingan LSTM dengan SARIMA pada data penjualan usaha kecil	Perbandingan akurasi kedua metode pada data penjualan harian usaha berskala kecil	Sama-sama membandingkan LSTM dengan metode pembanding pada konteks usaha kecil di Indonesia	Pembanding berupa SARIMA, bukan <i>baseline</i> heuristik; tidak mengkaji keterbatasan jumlah data maupun integrasi ke aplikasi POS

No	Penulis / Tahun	Judul Artikel	Metode yang Digunakan	Hasil yang Diperoleh	Persamaan	Perbedaan
11	R. Verdiyanto, D. Hartanti, E. Purwanto (2025), <i>Infotek: Jurnal Informatika dan Teknologi</i> [13]	<i>Pengembangan Aplikasi Point of Sales untuk Prediksi Penjualan Harian Usaha Minuman Menggunakan Algoritma Random Forest Regression</i>	<i>Random Forest Regression</i> yang diintegrasikan ke dalam aplikasi <i>Point of Sales</i>	Aplikasi POS dengan fitur prediksi penjualan harian untuk usaha minuman	Sama-sama membangun aplikasi POS dengan fitur prediksi penjualan harian pada konteks usaha kecil Indonesia	Menggunakan <i>Random Forest Regression</i> yang tidak memodelkan ketergantungan temporal secara eksplisit; penelitian ini menggunakan LSTM dan menguji augmentasi TimeGAN

Berdasarkan pemetaan pada Tabel 2.1, dapat diidentifikasi bahwa belum terdapat penelitian yang secara bersamaan melakukan tiga hal berikut: menerapkan LSTM untuk prediksi penjualan harian pada *dataset* berskala kecil dengan karakteristik deret tidak sinambung, menguji kontribusi augmentasi sintetis TimeGAN pada kondisi tersebut, serta mengintegrasikan model hasil pelatihan ke dalam aplikasi *Point of Sale* yang benar-benar digunakan pengguna akhir dan mengevaluasinya terhadap *baseline seasonal-naive*. Ketiga aspek inilah yang menjadi kebaruan penelitian ini.

2.2 Tinjauan Teoritis

2.2.1 *Point of Sale* (POS)

Point of Sale (POS) adalah sistem yang digunakan untuk mencatat, memproses, dan mendokumentasikan transaksi penjualan pada titik terjadinya transaksi. Dalam perkembangannya, aplikasi POS tidak lagi berfungsi semata sebagai mesin kasir digital, melainkan juga sebagai sistem informasi yang mengelola data produk, persediaan, pelanggan, dan pelaporan keuangan. Penerapan aplikasi POS pada usaha mikro, kecil, dan menengah terbukti membantu proses pencatatan transaksi menjadi lebih cepat, akurat, dan terdokumentasi, meskipun tingkat penerimaan penggunaannya masih dipengaruhi oleh persepsi kemudahan dan kemanfaatan sistem [14]. Secara arsitektural, sistem POS umumnya terdiri atas modul autentikasi pengguna, modul manajemen produk, modul transaksi, modul persediaan, dan modul pelaporan [15].

Data transaksi yang dihasilkan aplikasi POS secara berkelanjutan memiliki sifat deret waktu, yakni terurut berdasarkan waktu dan memiliki ketergantungan antarpengamatan [16]. Sifat inilah yang membuka peluang pemanfaatan data POS untuk keperluan peramalan, sehingga sistem tidak hanya bersifat *descriptive* (mencatat apa yang telah terjadi) tetapi juga *predictive* (memperkirakan apa yang akan terjadi), sebagaimana telah diterapkan pada sistem POS ritel yang menyertakan modul prediksi penjualan [10], [13].

2.2.2 Peramalan Deret Waktu (*Time Series Forecasting*)

Deret waktu adalah rangkaian pengamatan suatu variabel yang dicatat secara berurutan dalam interval waktu yang tetap. Peramalan deret waktu bertujuan memperkirakan nilai pengamatan pada periode mendatang berdasarkan pola yang terkandung pada pengamatan historisnya [16]. Secara umum, sebuah deret waktu dapat diuraikan menjadi empat komponen, yaitu tren (*trend*), musiman (*seasonality*), siklus (*cyclical*), dan komponen tak beraturan (*irregular* atau *noise*) [16], [17].

Suatu deret waktu dapat memuat lebih dari satu periode musiman sekaligus, sehingga pemodelannya perlu memperhitungkan setiap periode yang relevan [16]. Pada data penjualan harian kantin institusional, komponen musiman muncul dalam dua tingkatan. Musiman mingguan (periode $m = 7$) tampak dari perbedaan volume transaksi antara hari kerja dan akhir pekan, sedangkan musiman berbasis kalender akademik muncul dari perbedaan antara masa perkuliahan, minggu ujian, dan masa libur antarsemester. Pola musiman berbasis kalender semacam ini juga dilaporkan

berpengaruh nyata terhadap volume penjualan ritel harian [1].

Pendekatan peramalan secara garis besar terbagi menjadi tiga kelompok. *Pertama*, pendekatan statistik klasik seperti *moving average*, *exponential smoothing*, ARIMA, dan SARIMA, yang mengasumsikan hubungan linear antarpengamatan [17]. *Kedua*, pendekatan *machine learning* seperti *Random Forest*, *Support Vector Regression*, dan *Gradient Boosting*, yang memperlakukan peramalan sebagai persoalan regresi dengan fitur temporal yang direkayasa secara manual [13]. *Ketiga*, pendekatan *deep learning* seperti RNN, LSTM, dan GRU, yang mampu mempelajari representasi temporal secara otomatis tanpa rekayasa fitur eksplisit [2], [4]. Perbandingan lintas ketiga kelompok pendekatan tersebut pada kompetisi peramalan berskala besar menunjukkan bahwa tidak ada satu kelompok yang unggul secara mutlak, sehingga pemilihannya bergantung pada karakteristik dan ukuran data yang tersedia [9].

2.2.3 Baseline Seasonal-Naive

Seasonal-naive adalah metode peramalan paling sederhana untuk data bermusiman, yang memperkirakan nilai suatu periode sama dengan nilai pada periode musiman terakhir yang bersesuaian [16]. Secara matematis, prediksi untuk waktu $t + h$ dirumuskan sebagai:

$$\hat{y}_{t+h} = y_{t+h-m\lfloor(h-1)/m\rfloor-m} \quad (2.1)$$

dengan m adalah panjang periode musiman. Untuk data penjualan harian dengan

musiman mingguan, $m = 7$, sehingga prediksi hari Senin depan adalah nilai penjualan hari Senin sebelumnya.

Meskipun sederhana, metode ini memiliki peran metodologis yang penting. Hyndman dan Koehler menegaskan bahwa metode naif berfungsi sebagai penyebut normalisasi dalam pengukuran akurasi peramalan, sehingga akurasi suatu model hanya bermakna apabila dinyatakan secara relatif terhadap metode naif tersebut [18]. Pengalaman kompetisi peramalan berskala besar juga menunjukkan bahwa metode sederhana kerap sulit dikalahkan oleh model kompleks, terutama pada deret waktu yang pendek atau sangat bergejolak [9]. Karena itu, penyertaan *baseline seasonal-naive* dalam penelitian ini berfungsi sebagai kontrol metodologis untuk memastikan bahwa keunggulan model LSTM, apabila ada, benar-benar berasal dari kemampuan pemodelan dan bukan sekadar dari pola musiman yang telah dapat ditangkap oleh heuristik sederhana.

2.2.4 *Recurrent Neural Network (RNN)*

Recurrent Neural Network adalah arsitektur jaringan saraf tiruan yang dirancang untuk memproses data sekuensial dengan cara mempertahankan keadaan tersembunyi (*hidden state*) yang diperbarui pada setiap langkah waktu [2]. Pada langkah waktu t , keadaan tersembunyi dihitung sebagai [2]:

$$h_t = \tanh(W_{xh}x_t + W_{hh}h_{t-1} + b_h) \quad (2.2)$$

dengan x_t sebagai masukan pada waktu t , h_{t-1} sebagai keadaan tersembunyi

sebelumnya, serta W dan b sebagai bobot dan bias yang dipelajari.

Kelemahan utama RNN konvensional adalah masalah *vanishing gradient*, yaitu mengecilnya nilai gradien secara eksponensial ketika dipropagasikan mundur melintasi banyak langkah waktu. Akibatnya, RNN kesulitan mempelajari ketergantungan jangka panjang [2].

2.2.5 Long Short-Term Memory (LSTM)

Long Short-Term Memory diperkenalkan oleh Hochreiter dan Schmidhuber sebagai pengembangan RNN yang mengatasi masalah *vanishing gradient* melalui penambahan sel memori (*cell state*) dan tiga mekanisme gerbang (*gating mechanism*) [2]. Sel memori berfungsi sebagai jalur informasi yang memungkinkan gradien mengalir tanpa mengalami peluruhan berlebih, sedangkan gerbang mengendalikan informasi mana yang dibuang, disimpan, dan dikeluarkan.

a. Gerbang Lupa (*Forget Gate*)

Gerbang lupa menentukan proporsi informasi dari sel memori sebelumnya yang akan dipertahankan [2]:

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (2.3)$$

dengan σ adalah fungsi aktivasi sigmoid yang menghasilkan nilai pada rentang $[0, 1]$. Nilai mendekati 0 berarti informasi dibuang, sedangkan nilai mendekati 1 berarti informasi dipertahankan.

b. Gerbang Masukan (*Input Gate*)

Gerbang masukan menentukan informasi baru yang akan disimpan ke dalam sel memori. Tahap ini terdiri atas dua bagian, yaitu penentuan proporsi pembaruan dan pembentukan kandidat nilai baru [2]:

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (2.4)$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C) \quad (2.5)$$

c. Pembaruan Sel Memori (*Cell State Update*)

Sel memori diperbarui dengan menggabungkan informasi lama yang dipertahankan dan informasi baru yang diterima [2]:

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t \quad (2.6)$$

dengan $\odot$ menyatakan perkalian elemen per elemen (*Hadamard product*).

d. Gerbang Keluaran (*Output Gate*)

Gerbang keluaran menentukan bagian sel memori yang akan diteruskan sebagai keadaan tersembunyi [2]:

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (2.7)$$

$$h_t = o_t \odot \tanh(C_t) \quad (2.8)$$

Melalui mekanisme tersebut, LSTM mampu mempelajari pola berulang

berjangka panjang seperti musiman mingguan pada data penjualan. Sejumlah penelitian membuktikan efektivitasnya pada peramalan penjualan ritel, baik dalam bentuk LSTM tunggal dengan optimasi *hyperparameter* [3] maupun dalam bentuk arsitektur hibrida dengan CNN [1], [4].

2.2.6 *Generative Adversarial Network (GAN) dan TimeGAN*

Generative Adversarial Network (GAN) adalah kerangka pemodelan generatif yang melatih dua jaringan secara bersamaan dalam skema permainan minimaks, yaitu *generator G* yang menghasilkan data sintetis dan *discriminator D* yang membedakan data asli dari data sintetis [19]. Fungsi objektifnya dirumuskan sebagai:

$$\min_G \max_D V(D, G) = \mathbb{E}_{x \sim p_{data}(x)} [\log D(x)] + \mathbb{E}_{z \sim p_z(z)} [\log(1 - D(G(z)))] \quad (2.9)$$

GAN konvensional dirancang untuk data yang tidak memiliki urutan, sehingga kurang mampu mempertahankan dinamika temporal ketika diterapkan pada deret waktu. Untuk mengatasi hal tersebut, Yoon dkk. mengusulkan *Time-series Generative Adversarial Network (TimeGAN)*, yang memadukan kerangka *adversarial* dengan pembelajaran swa-penyeliaan (*self-supervised learning*) berbasis *autoencoder* [6]. Arsitektur TimeGAN terdiri atas empat komponen [6]:

1. ***Embedding function***, memetakan data asli dari ruang fitur ke ruang laten.
2. ***Recovery function***, merekonstruksi data dari ruang laten kembali ke ruang

fitur.

3. **Generator**, menghasilkan barisan laten sintetis dari vektor derau acak.
4. **Discriminator**, membedakan barisan laten asli dari barisan laten sintetis.

Keempat komponen dilatih menggunakan kombinasi tiga fungsi galat, yaitu *reconstruction loss*, *unsupervised adversarial loss*, dan *supervised loss* [6]. Komponen *supervised loss* inilah yang secara khusus memaksa *generator* mempelajari transisi antarlangkah waktu, sehingga dinamika temporal data asli dapat dipertahankan pada data sintetis yang dihasilkan.

Dalam konteks penelitian ini, TimeGAN digunakan sebagai metode augmentasi data untuk memperbanyak sampel pelatihan pada *dataset* yang berjumlah terbatas. Penerapan serupa telah dilaporkan berhasil menurunkan RMSE dan MAE pada domain konsumsi energi [7]. Namun demikian, perlu dicatat bahwa manfaat augmentasi tidak bersifat universal; kajian perbandingan sistematis menunjukkan bahwa keuntungan augmentasi cenderung menurun seiring bertambahnya ukuran data awal maupun berkurangnya kedalaman arsitektur jaringan [8].

2.2.7 Praproses Data

a. Normalisasi

Normalisasi diperlukan agar seluruh nilai masukan berada pada rentang yang seragam, sehingga mempercepat konvergensi pelatihan dan mencegah dominasi fitur bernilai besar. Metode yang umum digunakan pada LSTM adalah *Min-Max*

Scaling [3], [4]:

$$x' = \frac{x - x_{min}}{x_{max} - x_{min}} \quad (2.10)$$

b. Pembentukan Jendela Geser (*Sliding Window*)

Data deret waktu univariat perlu diubah menjadi format pembelajaran terbimbing melalui teknik *sliding window* [8]. Dengan panjang jendela w , setiap sampel pelatihan terdiri atas masukan $[y_{t-w+1}, \dots, y_t]$ dan target y_{t+1} . Jumlah sampel yang terbentuk adalah $N - w$, dengan N sebagai jumlah pengamatan. Konsekuensinya, semakin panjang jendela yang digunakan, semakin sedikit sampel pelatihan yang tersedia, yaitu pertimbangan yang menjadi kritis pada *dataset* berukuran terbatas seperti pada penelitian ini.

c. Pembagian Data

Berbeda dengan data yang tidak berurutan, pembagian data deret waktu tidak boleh dilakukan secara acak karena akan menimbulkan kebocoran informasi masa depan (*data leakage*). Pembagian dilakukan secara kronologis, dengan data terawal sebagai data latih dan data terakhir sebagai data uji [16].

2.2.8 Metrik Evaluasi

Evaluasi akurasi model peramalan dalam penelitian ini menggunakan metrik berikut, yang mengacu pada tinjauan Hyndman dan Koehler mengenai ukuran akurasi peramalan [18], dengan y_i sebagai nilai aktual, $\hat{y}_i$ sebagai nilai prediksi, dan n sebagai jumlah pengamatan.

a. Mean Absolute Error (MAE)

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (2.11)$$

b. Root Mean Squared Error (RMSE)

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (2.12)$$

c. Mean Absolute Percentage Error (MAPE)

$$\text{MAPE} = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \quad (2.13)$$

MAPE memudahkan interpretasi karena dinyatakan dalam persentase, namun tidak terdefinisi ketika terdapat nilai aktual sama dengan nol dan bersifat asimetris terhadap galat berlebih maupun kurang [18]. Keterbatasan ini relevan bagi penelitian ini mengingat *dataset* memuat hari-hari tanpa transaksi.

d. symmetric Mean Absolute Percentage Error (sMAPE)

Untuk mengatasi keterbatasan MAPE tersebut digunakan varian simetrisnya, yaitu sMAPE, yang membagi galat absolut terhadap rata-rata nilai aktual dan nilai prediksi sehingga tidak meledak ketika nilai aktual mendekati nol dan memiliki batas atas galat sebesar 200% [18].

$$\text{sMAPE} = \frac{100\%}{n} \sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{(|y_i| + |\hat{y}_i|)/2} \quad (2.14)$$

Sebagai konvensi implementasi, apabila penyebut bernilai nol karena nilai aktual dan nilai prediksi sama-sama nol, penyebut diganti dengan nilai 1 agar tidak terjadi galat pembagian dengan nol (*division by zero*).

e. Mean Absolute Scaled Error (MASE)

Berbeda dengan ketiga metrik sebelumnya yang berdiri sendiri, MASE memungkinkan perbandingan langsung terhadap *baseline* karena galat model dinormalisasi terhadap galat metode naif. Metrik ini diusulkan Hyndman dan Koehler [18] dan dirumuskan sebagai berikut:

$$\text{MASE} = \frac{\frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|}{\frac{1}{N-m} \sum_{t=m+1}^N |y_t - y_{t-m}|} \quad (2.15)$$

dengan penyebut dihitung khusus dari data latih, yaitu N menyatakan jumlah pengamatan pada data latih dan m panjang periode musiman, agar nilai MASE sebanding dengan yang dilaporkan pada literatur. Nilai MASE kurang dari 1 menunjukkan bahwa model berkinerja lebih baik daripada *baseline seasonal-naive*, sedangkan nilai lebih dari 1 menunjukkan sebaliknya. Metrik ini menjadikan perbandingan terhadap *baseline* bersifat eksplisit dan terukur.

2.2.9 Flutter

Flutter adalah *framework* pengembangan aplikasi lintas platform yang dikembangkan Google, menggunakan bahasa pemrograman Dart dan menerapkan pendekatan berbasis *widget* dengan mesin perenderan tersendiri [20]. Pemilihan Flutter dalam penelitian ini didasarkan pada kemampuannya menghasilkan

aplikasi dengan basis kode tunggal, performa mendekati aplikasi asli (*native*), serta dukungan ekosistem pustaka yang memadai untuk integrasi dengan layanan basis data dan antarmuka pemrograman aplikasi (API).

2.2.10 Pengujian *Black Box*

Pengujian *black box*, atau disebut juga *behavioral testing*, adalah metode pengujian yang berfokus pada kesesuaian antara masukan dan keluaran sistem berdasarkan spesifikasi fungsional, tanpa memperhatikan struktur kode maupun logika internal program [21]. Pengujian ini diarahkan untuk menemukan kesalahan berupa fungsi yang tidak benar atau tidak tersedia, kesalahan antarmuka, kesalahan akses basis data, serta kesalahan perilaku dan kinerja sistem [21], dengan teknik perancangan kasus uji yang lazim digunakan meliputi *equivalence partitioning* dan *boundary value analysis* [22], [23]. Dalam penelitian ini, pengujian *black box* diterapkan untuk memverifikasi fungsionalitas aplikasi *Point of Sale* yang dibangun, meliputi modul autentikasi pengguna, manajemen produk, transaksi penjualan, pengelolaan persediaan, pelaporan, serta modul prediksi penjualan harian, dengan setiap kasus uji mencantumkan skenario pengujian, masukan, hasil yang diharapkan, hasil yang diperoleh, dan simpulan berupa “berhasil” atau “gagal”. Metode ini dipilih karena tujuan pengujian adalah memastikan seluruh fungsi aplikasi berperilaku sesuai spesifikasi kebutuhan dari sudut pandang pengguna akhir, sehingga penilaian akurasi model prediksi tidak termasuk dalam cakupan pengujian ini melainkan dilakukan secara terpisah menggunakan metrik yang telah diuraikan pada Subbab 2.2.8.

BAB III

METODOLOGI PENELITIAN

3.1 Data dan Pengumpulan Data

Penelitian ini menggunakan data sekunder yang bersumber dari basis data transaksi platform katalog menu digital **EatsTEDI** pada Departemen Teknik Elektro dan Informatika (DTEDI), Universitas Gadjah Mada. Data diperoleh dalam bentuk *dump* basis data relasional berformat SQL (`eatstedi-20260621-010820.sql`) berukuran 32,15 MB dengan total sekitar 395.090 baris, mencakup rentang transaksi 24 Agustus 2024 sampai dengan 20 Juni 2026 atau 666 hari kalender secara inklusif. Data tersebut merupakan riwayat transaksi riil yang telah terhimpun jauh sebelum penelitian ini dimulai, bukan data yang dihasilkan oleh aplikasi yang dibangun dalam penelitian ini.

Penggunaan data EatsTEDI dipilih karena merepresentasikan karakteristik usaha kuliner berskala kecil pada lingkungan institusional yang menjadi fokus penelitian. Rentang 22 bulan tersebut mencakup empat semester berturut-turut, yakni semester gasal dan genap tahun akademik 2024/2025 serta 2025/2026, sehingga pola musiman berbasis kalender akademik teramati secara berulang. Di sisi lain, jumlah pengamatannya tetap tergolong terbatas, sehingga sesuai untuk menguji kelayakan penerapan model *Long Short-Term Memory* pada kondisi data yang tidak melimpah.

Data tidak digunakan dalam bentuk mentah, melainkan melalui penyaringan dan agregasi terlebih dahulu. Transaksi dibatasi pada nota berstatus lunas

(*is_paid* = 1) dari tabel *invoices*, lalu diagregasi menurut tanggal untuk membentuk deret waktu pendapatan harian. Rentang efektif yang diperoleh adalah 26 Agustus 2024 sampai 20 Juni 2026, menghasilkan 313 hari dengan transaksi tercatat. Sesuai batasan penelitian, pemodelan bersifat univariat dengan total penjualan harian sebagai satu-satunya variabel target. Adapun struktur data penelitian ditunjukkan pada Tabel 3.1.

Tabel 3.1 Struktur Data *Dataset* Final Penelitian

No	Nama Data	Sumber	Keterangan
1	<i>invoice_id</i>	Basis data EatsTEDI	Identitas unik setiap nota transaksi
2	<i>created_at</i>	Basis data EatsTEDI	Waktu pencatatan transaksi pada sistem
3	<i>is_paid</i>	Basis data EatsTEDI	Penanda status pelunasan, digunakan untuk menyaring transaksi sah
4	<i>total</i>	Basis data EatsTEDI	Nilai nominal penjualan pada setiap nota transaksi
5	<i>date</i>	Hasil praproses	Tanggal transaksi (format YYYY-MM-DD) hasil normalisasi <i>created_at</i> , berfungsi sebagai penanda urutan deret waktu
6	<i>revenue</i>	Hasil praproses	Total nilai penjualan harian dalam Rupiah hasil agregasi seluruh nota lunas pada tanggal yang sama; menjadi variabel target pemodelan

Berdasarkan Tabel 3.1, kolom *invoice_id*, *created_at*, *is_paid*, dan *total* merupakan atribut asli basis data EatsTEDI yang menjadi bahan penyaringan dan agregasi, sedangkan kolom *date* dan *revenue* dihasilkan pada tahap praproses. Kolom *revenue* menjadi satu-satunya variabel yang dimodelkan, sehingga *dataset*

final berbentuk deret waktu univariat dengan 313 titik pengamatan. Pembagian data latih dan uji dilakukan secara kronologis, bukan acak, guna menghindari kebocoran informasi masa depan sebagaimana dijelaskan pada Subbab 2.2.7.

Metode pengumpulan data dalam penelitian ini dilakukan melalui tahapan berikut:

a. Studi Literatur

Studi literatur dilakukan untuk mengkaji penelitian terdahulu yang berkaitan dengan peramalan penjualan ritel berbasis *Long Short-Term Memory*, augmentasi data sintetis menggunakan TimeGAN, serta penggunaan *baseline* sederhana sebagai kontrol metodologis. Hasil studi ini menjadi dasar dalam perancangan metode penelitian dan penetapan metrik evaluasi.

b. Observasi dan Wawancara

Observasi dan wawancara dilakukan terhadap pengelola divisi kewirausahaan mahasiswa platform EatsTEDI di DTEDI Universitas Gadjah Mada. Kegiatan ini bertujuan memahami alur operasional kasir, pencatatan menu harian, pengelolaan stok, serta kendala dalam mengantisipasi sisa produk, sehingga kebutuhan fitur prediksi pada aplikasi dapat dirumuskan sesuai kondisi lapangan.

c. Akuisisi Data

Data transaksi diperoleh langsung dari pengelola platform EatsTEDI dalam bentuk berkas *dump SQL*. Berkas tersebut memuat tabel *invoices* yang menjadi sumber utama nilai transaksi, beserta tabel pendukung

product_sold, *products*, dan *categories*. Data digunakan sebagai data utama penelitian karena merupakan catatan transaksi riil yang berkesinambungan selama dua tahun akademik penuh.

d. **Praproses Data**

Tahap praproses dilakukan untuk menyesuaikan data dengan kebutuhan pemodelan deret waktu, yang meliputi:

- 1) Penyaringan transaksi berdasarkan status pelunasan;
- 2) Agregasi nilai transaksi menurut tanggal menjadi pendapatan harian;
- 3) Normalisasi nilai menggunakan *Min-Max Scaling*;
- 4) Pembentukan sampel pembelajaran terbimbing melalui teknik *sliding window*.

Hasil dari tahap ini adalah *dataset* final berupa deret waktu univariat yang digunakan sebagai masukan dalam proses pelatihan dan evaluasi model.

3.2 Analisis Kebutuhan Sistem

Analisis kebutuhan sistem merupakan tahap identifikasi terhadap fungsi-fungsi yang harus disediakan oleh sistem serta sumber daya pendukung yang diperlukan agar sistem dapat berjalan sebagaimana mestinya. Analisis ini dibagi menjadi kebutuhan fungsional dan kebutuhan non-fungsional.

3.2.1 Analisis Kebutuhan Fungsional

Kebutuhan fungsional menggambarkan fungsi utama yang harus dimiliki oleh aplikasi *Point of Sale* dengan fitur prediksi penjualan harian.

1. Sistem dapat melakukan registrasi toko dan pendaftaran akun pengguna baru.
2. Sistem dapat melakukan autentikasi pengguna menggunakan email dan kata sandi, serta membedakan hak akses berdasarkan peran Pemilik (*Owner*) dan Kasir.
3. Sistem dapat mengelola data produk dan kategori produk, meliputi penambahan, pengubahan, dan penghapusan data.
4. Sistem dapat mencatat transaksi penjualan melalui alur *checkout* kasir.
5. Sistem dapat mencatat dan menampilkan riwayat mutasi stok produk.
6. Sistem dapat menampilkan dasbor ringkasan yang memuat omzet, jumlah transaksi, dan status persediaan produk.
7. Sistem dapat menampilkan hasil prediksi penjualan harian yang dihasilkan model *Long Short-Term Memory* melalui layanan *REST API*.
8. Sistem dapat menyimpan dan menampilkan riwayat analisis prediksi yang telah dijalankan.
9. Sistem dapat menyinkronkan data transaksi pada perangkat dengan basis data *cloud*.
10. Sistem dapat mengirimkan notifikasi kepada staf toko.
11. Sistem dapat mengelola data staf karyawan dan pengaturan profil toko.
12. Sistem dapat menghitung performa model prediksi menggunakan metrik evaluasi MAE, RMSE, sMAPE, dan MASE.

3.2.2 Analisis Kebutuhan Non-Fungsional

Kebutuhan non-fungsional merupakan kebutuhan pendukung yang berkaitan dengan spesifikasi perangkat keras (*hardware*) dan perangkat lunak (*software*) yang digunakan agar sistem dapat berjalan dengan optimal. Kebutuhan ini tidak berhubungan langsung dengan fungsi utama sistem, namun berperan penting dalam mendukung performa, stabilitas, dan keandalan sistem.

a. Perangkat Keras (*Hardware*)

Perangkat keras yang digunakan dalam penelitian ini dapat dilihat pada Tabel 3.2 berikut.

Tabel 3.2 Spesifikasi Perangkat Keras

No	Nama	Spesifikasi	Keterangan
1	Laptop	Acer Nitro 5, Intel Core i5 Gen 12, RAM 16 GB, SSD 512 GB, NVIDIA GeForce RTX 3050	Perangkat pengembangan aplikasi dan pelatihan model prediksi
2	<i>Smartphone</i>	Android 16	Perangkat pengujian aplikasi <i>mobile</i>

b. Perangkat Lunak (*Software*)

Perangkat lunak yang digunakan dalam pengembangan dan pengujian sistem ini dapat dilihat pada Tabel 3.3 berikut.

Tabel 3.3 Spesifikasi Perangkat Lunak

No	Nama	Spesifikasi	Keterangan
1	Sistem Operasi	Windows 11 <i>Home Single Language</i>	Sistem operasi perangkat pengembangan
2	<i>Code Editor</i>	Antigravity	Lingkungan penulisan kode program

No	Nama	Spesifikasi	Keterangan
3	<i>Emulator</i>	LDPlayer 9	Menjalankan dan menguji aplikasi Android pada perangkat pengembangan
4	<i>Framework Mobile</i>	Flutter SDK (bahasa Dart)	Membangun aplikasi <i>Point of Sale</i> lintas platform
5	Bahasa Pemrograman	Python 3.10	Melatih model LSTM, membangun modul augmentasi TimeGAN, dan menyusun layanan <i>REST API</i> prediksi
6	Pustaka <i>Machine Learning</i>	TensorFlow, Keras, PyTorch, Pandas, NumPy, Scikit-Learn	Pemrosesan data dan pembangunan model prediksi
7	<i>Framework API</i>	Flask	Menyajikan hasil prediksi kepada aplikasi <i>mobile</i>
8	Basis Data <i>Cloud</i>	Supabase (PostgreSQL)	Penyimpanan terpusat data transaksi
9	Basis Data Lokal	Isar Database	Penyimpanan data pada perangkat
10	Layanan Notifikasi	Firebase	Pengiriman notifikasi dan pencatatan telemetri aplikasi
11	Lingkungan Analisis	Jupyter Notebook	Eksplorasi data dan pelatihan model prediksi
12	Platform <i>Hosting</i>	Hugging Face	Tempat layanan API prediksi di- <i>deploy</i>
13	Alat Pemodelan	Draw.io dan Mermaid.js	Pembuatan diagram UML dan arsitektur sistem


3.3 Perancangan Sistem

Perancangan sistem merupakan tahap yang bertujuan memberikan gambaran mengenai bagaimana aplikasi *Point of Sale* dengan fitur prediksi penjualan harian akan dibangun dan dioperasikan. Tahap perancangan ini mencakup penyusunan

arsitektur sistem, pemodelan menggunakan *Unified Modeling Language* (UML), serta perancangan antarmuka pengguna (*user interface*). Adapun rincian perancangan sistem dalam penelitian ini dijelaskan sebagai berikut.

3.3.1 Arsitektur Sistem

Sistem Parzello POS Mobile dirancang menggunakan pendekatan arsitektur *hybrid-cloud* yang membagi pemrosesan antara perangkat lokal dan infrastruktur *cloud*. Secara keseluruhan, sistem terdiri dari empat komponen utama yang saling terintegrasi, yaitu *Flutter Mobile App*, *Supabase Cloud*, *Firebase*, dan *Layanan Inferensi Model LSTM* (Hugging Face). Rancangan arsitektur sistem diilustrasikan pada Gambar 3.1.



Gambar 3.1 Arsitektur Sistem POS

Penjelasan mengenai empat komponen utama dalam arsitektur sistem adalah sebagai berikut:

1. **Sisi Klien (*Client-Side*):** Aplikasi dibangun menggunakan *framework* Flutter

dengan manajemen *state* Riverpod dan navigasi GoRouter. Isar DB berperan sebagai basis data lokal agar kasir tetap dapat bertransaksi meskipun koneksi terputus, sedangkan *sync engine* menyinkronkan data ke *cloud* menggunakan penanda *isSynced* untuk menghindari duplikasi.

2. **Infrastruktur Cloud (Supabase):** Supabase menjadi tulang punggung infrastruktur *cloud* melalui empat layanan. Supabase Auth menangani autentikasi pengguna, sedangkan Supabase PostgreSQL berperan sebagai basis data relasional terpusat yang dilengkapi kebijakan *Row Level Security* untuk mengisolasi data antartoko serta prosedur tersimpan (*RPC*) untuk memproses transaksi secara aman. Supabase Storage menyimpan aset media, dan *Edge Functions* memproses *webhook* basis data seperti pemicu notifikasi stok menipis.
3. **Telemetri dan Notifikasi (Firebase):** Sistem terintegrasi dengan Firebase untuk telemetri dan notifikasi. *Firebase Cloud Messaging* menyampaikan *push notification* kepada staf toko, misalnya peringatan stok menipis, sedangkan *Firebase Analytics* mencatat perilaku penggunaan aplikasi seperti volume transaksi harian dan frekuensi pemakaian fitur prediksi.
4. **Layanan Inferensi Model LSTM (Hugging Face):** Model *Long Short-Term Memory* dikemas sebagai layanan *REST API* berbasis Flask yang di-deploy pada platform Hugging Face, sehingga dapat diakses tanpa infrastruktur *server* tersendiri. Aplikasi memanggil *endpoint* tersebut melalui HTTPS dengan *payload* berupa data agregat penjualan, lalu


menerima hasil prediksi dalam format JSON yang disimpan sebagai *snapshot* pada Supabase.

3.3.2 Pemodelan Sistem *Unified Modeling Language* (UML)

Pemodelan sistem merupakan tahapan dalam perancangan yang digunakan untuk menggambarkan interaksi antara pengguna dan sistem serta alur proses yang terjadi di dalam aplikasi *Point of Sale*. Pemodelan dilakukan menggunakan pendekatan *Unified Modeling Language* (UML) agar rancangan sistem dapat direpresentasikan secara visual dan terstruktur. Pada penelitian ini, pemodelan sistem meliputi *use case diagram* dan *activity diagram*.

a. *Use Case Diagram*

Sistem melibatkan dua aktor, yaitu Owner (Pemilik Toko) dan Kasir (Karyawan). Pembatasan hak akses berbasis peran ditegakkan pada lapisan navigasi aplikasi, di mana hanya Manajemen Karyawan, Pengaturan Profil Toko, dan Registrasi Toko yang eksklusif bagi Owner, sedangkan fungsi operasional lainnya dapat diakses seluruh staf. Hubungan tersebut digambarkan melalui relasi generalisasi aktor, yaitu Owner mewarisi seluruh *use case* Kasir. Adapun keharusan pengguna terautentikasi dinyatakan sebagai prasyarat pada setiap *use case*, bukan relasi *include*, agar tidak terjadi duplikasi. Rancangan *use case* diilustrasikan pada Gambar 3.2.



Gambar 3.2 Use Case Diagram Sistem POS

Gambar 3.2 menggambarkan interaksi antara kedua aktor dengan fungsi-fungsi yang tersedia pada sistem. Adapun penjelasan mengenai masing-masing *use case* diuraikan pada bagian berikut.

1) *Use Case* Registrasi Toko Baru

Rancangan *use case* registrasi toko baru digunakan untuk mendaftarkan identitas toko beserta akun pemilik pada saat sistem pertama kali digunakan. Melalui *use case* ini, data toko terbentuk sebagai wadah bagi seluruh data produk, transaksi, dan staf yang dikelola selanjutnya. Rancangan *use case* ini dapat dilihat pada Tabel 3.4.

Tabel 3.4 *Use Case* Registrasi Toko Baru

<i>Use Case</i>	Registrasi Toko Baru
Deskripsi	Proses pendaftaran akun toko baru pada saat inisialisasi awal sistem
<i>Actor</i>	Owner
<i>Precondition</i>	1. Pengguna berada pada halaman registrasi 2. Pengguna mengisi data toko dan data akun pemilik
<i>Postcondition</i>	Akun toko dan akun Owner berhasil terbentuk pada sistem

Tabel 3.4 menunjukkan bahwa sistem menyediakan mekanisme pendaftaran toko baru sehingga aplikasi dapat langsung digunakan tanpa konfigurasi manual pada basis data.

2) *Use Case* Login Akun

Rancangan *use case login* akun digunakan untuk memverifikasi identitas pengguna sebelum mengakses fungsi-fungsi sistem. Proses autentikasi sekaligus menentukan hak akses yang diberikan sesuai peran pengguna. Rancangan *use case*

ini dapat dilihat pada Tabel 3.5.

Tabel 3.5 *Use Case Login Akun*

<i>Use Case</i>	Login Akun
Deskripsi	Proses autentikasi pengguna menggunakan email dan kata sandi
<i>Actor</i>	Owner dan Kasir
<i>Precondition</i>	1. Pengguna telah memiliki akun terdaftar 2. Pengguna memasukkan email dan kata sandi pada halaman <i>login</i>
<i>Postcondition</i>	Pengguna masuk ke dasbor sesuai hak akses perannya

Tabel 3.5 menunjukkan bahwa sistem membedakan hak akses Owner dan Kasir sejak tahap autentikasi.

3) *Use Case* Mengelola Katalog Produk

Rancangan *use case* mengelola katalog produk digunakan untuk memelihara data produk yang dijual beserta jumlah persediaannya. Rancangan *use case* ini dapat dilihat pada Tabel 3.6.

Tabel 3.6 *Use Case* Mengelola Katalog Produk

<i>Use Case</i>	Mengelola Katalog Produk
Deskripsi	Proses penambahan, penyuntingan, dan penghapusan data produk serta stok
<i>Actor</i>	Owner dan Kasir
<i>Precondition</i>	1. Pengguna telah masuk ke dalam sistem 2. Pengguna membuka halaman katalog produk
<i>Postcondition</i>	Data produk dan stok tersimpan sesuai perubahan yang dilakukan

Tabel 3.6 menunjukkan bahwa katalog produk dapat dipelihara secara mandiri oleh pengelola toko.

4) *Use Case* Mengelola Kategori

Rancangan *use case* mengelola kategori digunakan untuk mengatur pengelompokan produk agar katalog lebih mudah ditelusuri. Rancangan *use case* ini dapat dilihat pada Tabel 3.7.

Tabel 3.7 *Use Case* Mengelola Kategori

<i>Use Case</i>	Mengelola Kategori
Deskripsi	Proses pengaturan pengelompokan produk pada katalog toko
<i>Actor</i>	Owner dan Kasir
<i>Precondition</i>	1. Pengguna telah masuk ke dalam sistem 2. Pengguna membuka halaman kategori produk
<i>Postcondition</i>	Data kategori tersimpan dan produk terkelompokkan sesuai kategorinya

Tabel 3.7 menunjukkan bahwa produk dapat dikelompokkan sehingga memudahkan pencarian saat transaksi.

5) *Use Case* Melakukan *Checkout*

Rancangan *use case* melakukan *checkout* merupakan fungsi inti aplikasi kasir yang digunakan untuk memproses transaksi penjualan. Data yang dihasilkan dari *use case* ini menjadi sumber utama bagi pencatatan omzet sekaligus bahan masukan fitur prediksi penjualan. Rancangan *use case* ini dapat dilihat pada Tabel 3.8.

Tabel 3.8 *Use Case* Melakukan *Checkout*

<i>Use Case</i>	Melakukan <i>Checkout</i>
Deskripsi	Proses pemilihan produk ke dalam keranjang hingga penyelesaian pembayaran
<i>Actor</i>	Owner dan Kasir
<i>Precondition</i>	1. Pengguna telah masuk ke dalam sistem 2. Terdapat produk aktif pada katalog toko
<i>Postcondition</i>	Transaksi tersimpan dan stok produk terbaru secara otomatis

Tabel 3.8 menunjukkan bahwa transaksi penjualan tercatat beserta pembaruan stok produk yang terkait.

6) *Use Case* Mengaudit Riwayat Stok

Rancangan *use case* mengaudit riwayat stok digunakan untuk menelusuri catatan mutasi persediaan sebagai bahan pemeriksaan inventaris. Rancangan *use case* ini dapat dilihat pada Tabel 3.9.

Tabel 3.9 *Use Case* Mengaudit Riwayat Stok

<i>Use Case</i>	Mengaudit Riwayat Stok
Deskripsi	Proses penelusuran <i>log</i> mutasi stok produk
<i>Actor</i>	Owner dan Kasir
<i>Precondition</i>	1. Pengguna telah masuk ke dalam sistem 2. Terdapat riwayat perubahan stok yang tercatat
<i>Postcondition</i>	Riwayat mutasi stok tersaji beserta waktu dan penyebab perubahannya

Tabel 3.9 menunjukkan bahwa setiap perubahan stok dapat ditelusuri untuk keperluan audit persediaan.

7) *Use Case* Melihat *Dashboard*

Rancangan *use case* melihat *dashboard* digunakan untuk menyajikan

ringkasan performa penjualan toko dalam satu tampilan. Rancangan *use case* ini dapat dilihat pada Tabel 3.10.

Tabel 3.10 *Use Case* Melihat *Dashboard*

<i>Use Case</i>	Melihat <i>Dashboard</i>
Deskripsi	Proses penyajian ringkasan omzet, jumlah transaksi, dan status persediaan
<i>Actor</i>	Owner dan Kasir
<i>Precondition</i>	1. Pengguna telah masuk ke dalam sistem 2. Terdapat data transaksi yang tercatat
<i>Postcondition</i>	Ringkasan performa penjualan tersaji dalam bentuk kartu dan grafik

Tabel 3.10 menunjukkan bahwa pengelola memperoleh gambaran menyeluruh kondisi toko tanpa menelusuri data satu per satu.

8) *Use Case* Melihat Prediksi Penjualan Harian

Rancangan *use case* melihat prediksi penjualan harian merupakan fungsi yang menjadi inti penelitian ini. Melalui *use case* ini, hasil peramalan yang dihasilkan model *Long Short-Term Memory* disajikan langsung kepada pengelola di dalam alur kerja aplikasi *Point of Sale*. Rancangan *use case* ini dapat dilihat pada Tabel 3.11.

Tabel 3.11 *Use Case* Melihat Prediksi Penjualan Harian

<i>Use Case</i>	Melihat Prediksi Penjualan Harian
Deskripsi	Proses permintaan dan penyajian hasil prediksi penjualan harian dari layanan <i>REST API</i>
<i>Actor</i>	Owner dan Kasir
<i>Precondition</i>	1. Pengguna telah masuk ke dalam sistem 2. Riwayat transaksi telah memenuhi panjang sekuens minimum yang disyaratkan model
<i>Postcondition</i>	Hasil prediksi penjualan harian tersaji dalam bentuk kartu estimasi dan grafik peramalan

Tabel 3.11 menunjukkan bahwa hasil peramalan dapat langsung dimanfaatkan pengelola sebagai bahan pertimbangan penentuan volume produksi harian.

9) *Use Case* Melihat Riwayat Analisis

Rancangan *use case* melihat riwayat analisis digunakan untuk menelusuri kembali hasil prediksi yang pernah dijalankan beserta sumber komputasinya.

Rancangan *use case* ini dapat dilihat pada Tabel 3.12.

Tabel 3.12 *Use Case* Melihat Riwayat Analisis

<i>Use Case</i>	Melihat Riwayat Analisis
Deskripsi	Proses penyajian daftar analisis prediksi yang telah dijalankan sebelumnya
<i>Actor</i>	Owner dan Kasir
<i>Precondition</i>	1. Pengguna telah masuk ke dalam sistem 2. Terdapat analisis prediksi yang pernah dijalankan
<i>Postcondition</i>	Riwayat analisis tersaji beserta waktu pelaksanaan dan estimasi yang dihasilkan

Tabel 3.12 menunjukkan bahwa pengelola dapat membandingkan hasil peramalan antarwaktu tanpa menjalankan ulang analisis.

10) *Use Case* Sinkronisasi Data

Rancangan *use case* sinkronisasi data digunakan untuk menyelaraskan data transaksi pada perangkat dengan basis data *cloud*. Rancangan *use case* ini dapat dilihat pada Tabel 3.13.

Tabel 3.13 *Use Case* Sinkronisasi Data

<i>Use Case</i>	Sinkronisasi Data
Deskripsi	Proses penyelarasan data transaksi perangkat dengan basis data <i>cloud</i>
<i>Actor</i>	Owner dan Kasir
<i>Precondition</i>	1. Terdapat data transaksi yang belum tersinkronkan 2. Perangkat terhubung ke jaringan internet
<i>Postcondition</i>	Data transaksi pada perangkat dan basis data <i>cloud</i> menjadi selaras

Tabel 3.13 menunjukkan bahwa pencatatan transaksi tetap utuh meskipun koneksi sempat terputus.

11) *Use Case* Kirim *Broadcast* Notifikasi

Rancangan *use case* kirim *broadcast* notifikasi digunakan untuk menyampaikan pemberitahuan kepada seluruh staf toko secara serentak. Rancangan *use case* ini dapat dilihat pada Tabel 3.14.

Tabel 3.14 *Use Case* Kirim *Broadcast* Notifikasi

<i>Use Case</i>	Kirim <i>Broadcast</i> Notifikasi
Deskripsi	Proses pengiriman pemberitahuan kepada staf toko
<i>Actor</i>	Owner dan Kasir
<i>Precondition</i>	1. Pengguna telah masuk ke dalam sistem 2. Pengguna menyusun isi pesan yang akan dikirimkan
<i>Postcondition</i>	Notifikasi diterima oleh perangkat staf toko yang dituju

Tabel 3.14 menunjukkan bahwa informasi operasional dapat disebarkan tanpa memerlukan saluran komunikasi terpisah.

12) *Use Case* Mengelola Karyawan

Rancangan *use case* mengelola karyawan digunakan untuk mendaftarkan staf

kasir serta mengatur peran yang diberikan kepada masing-masing staf. Rancangan *use case* ini dapat dilihat pada Tabel 3.15.

Tabel 3.15 *Use Case* Mengelola Karyawan

<i>Use Case</i>	Mengelola Karyawan
Deskripsi	Proses pendaftaran dan pengaturan peran staf toko
<i>Actor</i>	Owner
<i>Precondition</i>	1. Owner telah masuk ke dalam sistem 2. Owner membuka halaman manajemen karyawan
<i>Postcondition</i>	Data staf beserta perannya tersimpan pada sistem

Tabel 3.15 menunjukkan bahwa pengaturan hak akses staf sepenuhnya berada pada kewenangan Owner.

13) *Use Case* Mengatur Profil Toko

Rancangan *use case* mengatur profil toko digunakan untuk memperbarui identitas toko yang ditampilkan pada aplikasi dan bukti transaksi. Rancangan *use case* ini dapat dilihat pada Tabel 3.16.

Tabel 3.16 *Use Case* Mengatur Profil Toko

<i>Use Case</i>	Mengatur Profil Toko
Deskripsi	Proses pengubahan nama, alamat, dan logo toko
<i>Actor</i>	Owner
<i>Precondition</i>	1. Owner telah masuk ke dalam sistem 2. Owner membuka halaman pengaturan profil toko
<i>Postcondition</i>	Identitas toko terbaru pada seluruh tampilan aplikasi


Tabel 3.16 menunjukkan bahwa identitas toko dapat disesuaikan sewaktu-waktu oleh Owner.

b. *Activity Diagram*

Activity Diagram merupakan gambaran visual yang digunakan untuk menggambarkan serangkaian aktivitas atau proses yang terjadi di dalam sistem. Diagram ini memudahkan penjelasan mengenai logika prosedural, alur kerja, serta titik percabangan keputusan pada aplikasi *Point of Sale* yang dilengkapi fitur prediksi penjualan harian. Pada penelitian ini disusun satu *activity diagram* untuk setiap *use case* yang telah dirancang sebelumnya, sehingga seluruh fungsi sistem memiliki gambaran alur kerja yang lengkap. Adapun rincian masing-masing *activity diagram* diuraikan sebagai berikut.

1) *Activity Diagram* Registrasi Toko Baru

Registrasi toko baru digunakan untuk mendaftarkan identitas toko beserta akun pemilik pada saat sistem pertama kali digunakan. *Activity diagram* tersebut dapat dilihat pada Gambar 3.3.




Gambar 3.3 Activity Diagram Registrasi Toko Baru

Gambar 3.3 menunjukkan proses calon pemilik dalam mendaftarkan toko baru pada sistem. Calon pemilik membuka halaman registrasi dan sistem menampilkan formulir registrasi. Calon pemilik kemudian mengisi data toko beserta data akun pemilik. Sistem memeriksa apakah data yang dimasukkan telah valid. Apabila belum valid, calon pemilik melihat pesan kesalahan dan memperbaiki data masukan. Apabila telah valid, sistem menyimpan data toko dan akun Owner, lalu menampilkan konfirmasi pendaftaran, sehingga calon pemilik dapat mulai menggunakan aplikasi.

2) Activity Diagram Login Akun

Login akun digunakan untuk memverifikasi identitas pengguna sekaligus menentukan hak akses yang diberikan sesuai perannya. *Activity diagram* tersebut dapat dilihat pada Gambar 3.4.



Gambar 3.4 Activity Diagram Login Akun


Gambar 3.4 menunjukkan proses pengguna dalam melakukan autentikasi pada sistem. Pengguna membuka halaman *login* dan sistem menampilkan formulir *login*. Pengguna kemudian memasukkan email dan kata sandi. Sistem memeriksa apakah kredensial yang dimasukkan sesuai. Apabila tidak sesuai, pengguna melihat pesan kesalahan autentikasi dan memasukkan kembali kredensialnya. Apabila sesuai, sistem memuat data toko beserta hak akses peran, lalu

menampilkan dasbor sesuai peran, sehingga pengguna dapat mengakses fungsi yang menjadi kewenangannya.

3) *Activity Diagram* Mengelola Katalog Produk

Pengelolaan katalog produk digunakan untuk memelihara data produk dan persediaan yang menjadi sumber masukan bagi pencatatan transaksi penjualan.

Activity diagram tersebut dapat dilihat pada Gambar 3.5.




Gambar 3.5 *Activity Diagram* Mengelola Katalog Produk

Gambar 3.5 menunjukkan proses staf toko dalam mengelola katalog produk pada sistem. Staf toko membuka halaman katalog produk dan sistem menampilkan daftar produk. Staf toko kemudian memilih aksi tambah, ubah, atau hapus.

Apabila aksi yang dipilih bukan penghapusan, staf toko mengisi data produk pada formulir yang disediakan. Apabila aksi yang dipilih adalah penghapusan, sistem menandai produk tersebut sebagai terhapus melalui skema *soft delete*. Sistem kemudian menyimpan perubahan ke basis data lokal Isar DB dan mencatat mutasi stok, lalu menyinkronkan data ke Supabase ketika koneksi tersedia, sehingga staf toko dapat melihat katalog produk yang telah diperbarui.

4) *Activity Diagram* Mengelola Kategori

Pengelolaan kategori digunakan untuk mengatur pengelompokan produk agar katalog toko lebih mudah ditelusuri saat transaksi berlangsung. *Activity diagram* tersebut dapat dilihat pada Gambar 3.6.




Gambar 3.6 *Activity Diagram* Mengelola Kategori

Gambar 3.6 menunjukkan proses staf toko dalam mengelola kategori produk pada sistem. Staf toko membuka halaman kategori produk dan sistem menampilkan daftar kategori. Staf toko kemudian memilih aksi tambah, ubah, atau hapus, lalu mengisi nama kategori yang dikehendaki. Sistem menyimpan kategori tersebut ke basis data lokal Isar DB dan mengelompokkan produk sesuai kategorinya. Setelah penyimpanan selesai, sistem menyinkronkan data kategori ke Supabase ketika koneksi tersedia, sehingga staf toko dapat melihat katalog produk yang telah terkelompok.

5) *Activity Diagram* Melakukan *Checkout*

Transaksi *checkout* digunakan untuk memproses penjualan di kasir sekaligus menghasilkan data deret waktu yang menjadi masukan model prediksi. *Activity diagram* tersebut dapat dilihat pada Gambar 3.7.




Gambar 3.7 Activity Diagram Melakukan Checkout

Gambar 3.7 menunjukkan proses kasir dalam melayani transaksi penjualan pada sistem. Kasir membuka layar kasir dan sistem menampilkan katalog produk. Kasir kemudian memilih produk yang dibeli ke dalam keranjang, lalu sistem menghitung subtotal keranjang. Sistem memeriksa apakah keranjang telah selesai disusun. Apabila belum selesai, kasir mengulang pemilihan produk hingga seluruh pesanan pelanggan tercatat. Setelah keranjang dinyatakan selesai, kasir memilih metode pembayaran dan memasukkan nominal yang diterima, lalu sistem menghitung kembalian. Sistem kemudian menyimpan transaksi ke basis data lokal Isar DB, memotong stok produk yang terjual, dan menampilkan konfirmasi, sehingga kasir dapat melihat transaksi yang telah berhasil disimpan.

6) Activity Diagram Mengaudit Riwayat Stok

Audit riwayat stok digunakan untuk menelusuri catatan mutasi persediaan sebagai bahan pemeriksaan inventaris toko. *Activity diagram* tersebut dapat dilihat pada Gambar 3.8.




Gambar 3.8 Activity Diagram Mengaudit Riwayat Stok

Gambar 3.8 menunjukkan proses staf toko dalam mengaudit riwayat stok pada sistem. Staf toko membuka halaman riwayat stok dan sistem mengambil *log* mutasi stok dari basis data. Staf toko kemudian memilih rentang waktu dan produk yang ingin ditelusuri, lalu sistem menyaring data sesuai kriteria tersebut. Sistem menampilkan daftar mutasi stok beserta waktu dan penyebab perubahannya, sehingga staf toko dapat menelaah setiap perubahan persediaan yang pernah terjadi.

7) Activity Diagram Melihat Dashboard

Dasbor digunakan untuk menyajikan ringkasan performa penjualan toko dalam satu tampilan yang mudah dipantau. *Activity diagram* tersebut dapat dilihat pada Gambar 3.9.



Gambar 3.9 Activity Diagram Melihat Dashboard


Gambar 3.9 menunjukkan proses pengguna dalam memantau ringkasan performa toko pada sistem. Pengguna membuka halaman dasbor dan sistem mengagregasi data transaksi beserta persediaan. Pengguna kemudian memilih rentang waktu laporan, lalu sistem menghitung omzet, jumlah transaksi, dan jumlah produk berstok rendah. Sistem menampilkan hasil perhitungan tersebut dalam bentuk kartu statistik dan grafik penjualan, sehingga pengguna dapat memantau kondisi toko tanpa menelusuri data transaksi satu per satu.

8) Activity Diagram Melihat Prediksi Penjualan Harian

Penyajian prediksi penjualan harian digunakan untuk menampilkan hasil

peramalan model *Long Short-Term Memory* kepada pengelola di dalam aplikasi.

Activity diagram tersebut dapat dilihat pada Gambar 3.10.




Gambar 3.10 *Activity Diagram* Melihat Prediksi Penjualan Harian

Gambar 3.10 menunjukkan proses pengguna dalam memperoleh hasil prediksi penjualan harian pada sistem. Pengguna membuka halaman prediksi penjualan dan sistem mengagregasi riwayat transaksi harian. Sistem kemudian memeriksa apakah panjang sekuens data telah mencukupi syarat minimum model. Apabila belum mencukupi, sistem menampilkan peringatan *cold start* beserta estimasi berbasis pola umum. Apabila telah mencukupi, layanan prediksi memuat model LSTM, menerima data yang dikirimkan, lalu menghasilkan prediksi penjualan harian. Sistem kemudian menyajikan kartu estimasi dan grafik peramalan serta menyimpan *snapshot* riwayat analisis, sehingga pengguna dapat melihat hasil peramalan beserta riwayatnya.

9) Activity Diagram Melihat Riwayat Analisis

Riwayat analisis digunakan untuk menelusuri kembali hasil prediksi yang pernah dijalankan beserta sumber komputasinya. *Activity diagram* tersebut dapat dilihat pada Gambar 3.11.




Gambar 3.11 Activity Diagram Melihat Riwayat Analisis

Gambar 3.11 menunjukkan proses pengguna dalam menelusuri riwayat analisis pada sistem. Pengguna membuka halaman riwayat analisis dan sistem mengambil *snapshot* analisis yang telah tersimpan. Sistem kemudian memeriksa apakah riwayat analisis tersedia. Apabila belum tersedia, pengguna melihat keterangan bahwa riwayat masih kosong. Apabila tersedia, sistem menampilkan daftar riwayat beserta waktu pelaksanaan, estimasi yang dihasilkan, dan sumber komputasinya, sehingga pengguna dapat menelaah hasil analisis sebelumnya tanpa menjalankan ulang prediksi.

10) Activity Diagram Sinkronisasi Data

Sinkronisasi data digunakan untuk menjaga keutuhan pencatatan transaksi ketika perangkat sempat kehilangan koneksi internet. *Activity diagram* tersebut dapat dilihat pada Gambar 3.12.




Gambar 3.12 Activity Diagram Sinkronisasi Data

Gambar 3.12 menunjukkan proses sinkronisasi data dari aplikasi klien ke basis data *cloud* pada sistem. Aplikasi klien mendeteksi perubahan status konektivitas, kemudian memeriksa apakah koneksi internet telah tersedia. Apabila belum tersedia, aplikasi klien menunggu hingga koneksi kembali terdeteksi. Setelah koneksi tersedia, aplikasi klien menjalankan sinkronisasi di latar belakang

dan menyeleksi data yang belum tersinkron. Aplikasi klien mengunggah data kategori dan produk, lalu basis data *cloud* menyimpannya. Aplikasi klien kemudian memanggil prosedur RPC *create_transaction_v4* dan basis data *cloud* mencatat nota beserta pemotongan stok dalam satu transaksi. Setelah pengunggahan selesai, aplikasi klien menandai data lokal telah tersinkron, sehingga data pada perangkat dan *cloud* menjadi selaras.

11) Activity Diagram Kirim Broadcast Notifikasi

Pengiriman *broadcast* notifikasi digunakan untuk menyampaikan pemberitahuan kepada seluruh staf toko secara serentak. Activity diagram tersebut dapat dilihat pada Gambar 3.13.




Gambar 3.13 Activity Diagram Kirim Broadcast Notifikasi

Gambar 3.13 menunjukkan proses staf toko dalam mengirimkan notifikasi

pada sistem. Staf toko membuka halaman notifikasi dan sistem menampilkan formulir pesan. Staf toko kemudian menyusun isi pesan yang akan disampaikan, lalu sistem mengirimkan pesan tersebut melalui layanan *Firebase Cloud Messaging*. Setelah pengiriman selesai, sistem menampilkan status pengiriman, sehingga staf toko dapat melihat konfirmasi bahwa pesan telah diterima perangkat staf lain.

12) Activity Diagram Mengelola Karyawan

Pengelolaan karyawan digunakan untuk mendaftarkan staf kasir serta mengatur peran yang diberikan kepada masing-masing staf. *Activity diagram* tersebut dapat dilihat pada Gambar 3.14.




Gambar 3.14 Activity Diagram Mengelola Karyawan

Gambar 3.14 menunjukkan proses Owner dalam mengelola data staf toko pada sistem. Owner membuka halaman manajemen karyawan dan sistem menampilkan daftar staf toko. Owner kemudian menambah staf baru atau mengubah peran staf yang sudah ada. Sistem memeriksa apakah data staf yang dimasukkan telah valid. Apabila belum valid, Owner melihat pesan kesalahan dan memperbaiki masukannya. Apabila telah valid, sistem menyimpan data staf beserta perannya, lalu menyinkronkan data tersebut ke Supabase, sehingga Owner dapat melihat daftar staf yang telah diperbarui.

13) *Activity Diagram* Mengatur Profil Toko

Pengaturan profil toko digunakan untuk memperbarui identitas toko yang ditampilkan pada aplikasi dan bukti transaksi. *Activity diagram* tersebut dapat dilihat pada Gambar 3.15.



Gambar 3.15 Activity Diagram Mengatur Profil Toko

Gambar 3.15 menunjukkan proses Owner dalam memperbarui identitas toko pada sistem. Owner membuka halaman profil toko dan sistem menampilkan data identitas toko yang berlaku. Owner kemudian mengubah nama, alamat, atau logo toko sesuai kebutuhan, lalu sistem menyimpan perubahan tersebut. Setelah penyimpanan selesai, sistem memperbarui tampilan aplikasi dan format bukti transaksi, sehingga Owner dapat melihat identitas toko yang telah diperbarui pada seluruh halaman aplikasi.

3.3.3 Perancangan Antarmuka Pengguna (*User Interface*)

Perancangan antarmuka pengguna (*user interface*) dilakukan untuk memberikan gambaran tampilan serta interaksi pengguna dengan sistem dalam

proses pencatatan transaksi dan penyajian prediksi penjualan harian. Perancangan ini bertujuan menghasilkan antarmuka yang mudah digunakan, terstruktur, dan sesuai dengan kebutuhan fungsional sistem.

Antarmuka sistem dirancang dengan tata letak yang rapi, navigasi yang mudah dipahami, serta penyajian informasi yang mendukung alur penggunaan sistem mulai dari registrasi toko, autentikasi pengguna, pengelolaan katalog produk, transaksi kasir, hingga penyajian prediksi penjualan harian. Rancangan halaman disusun mengikuti *use case* yang telah dimodelkan pada Subbab sebelumnya, sehingga setiap fungsi sistem memiliki rancangan antarmukanya masing-masing. Adapun rancangan halaman pada aplikasi *Point of Sale* adalah sebagai berikut:

a. Perancangan Halaman Registrasi Toko Baru

Halaman registrasi toko baru dirancang sebagai titik masuk awal sistem, yaitu tempat calon pemilik mendaftarkan identitas toko sekaligus akun pemiliknya. Desain halaman tersebut dapat dilihat pada Gambar 3.16.

Gambar 3.16 Desain Halaman Registrasi Toko Baru

Gambar 3.16 menunjukkan formulir pendaftaran yang memuat kolom nama lengkap, email, kata sandi, dan konfirmasi kata sandi, disertai kolom identitas toko. Bagian bawah halaman menyediakan tautan menuju halaman *login* bagi pengguna yang telah memiliki akun.

b. Perancangan Halaman *Login* dan Pemilihan Toko

1) Perancangan Halaman *Login*

Halaman *login* dirancang untuk memverifikasi identitas pengguna sebelum mengakses fungsi sistem, sekaligus menentukan hak akses sesuai perannya. Desain halaman tersebut dapat dilihat pada Gambar 3.17.

Selamat Datang Kembali
Masukkan email dan password untuk masuk ke dashboard POS.

Email

Masukkan email Anda

Password

Masukkan kata sandi Anda

☐ Ingat saya [Lupa password?](#)

Masuk

ATAU


 Lanjutkan dengan Google

Gambar 3.17 Desain Halaman *Login*

Gambar 3.17 menunjukkan kolom email dan kata sandi beserta tombol masuk. Halaman ini juga menyediakan tautan lupa kata sandi serta tautan menuju halaman registrasi bagi pengguna baru.

2) Perancangan Halaman Pemilihan Toko

Halaman pemilihan toko dirancang sebagai kelanjutan proses *login* bagi pengguna yang terdaftar pada lebih dari satu toko. Desain halaman tersebut dapat dilihat pada Gambar 3.18.



Gambar 3.18 Desain Halaman Pemilihan Toko

Gambar 3.18 menunjukkan daftar toko yang dapat dioperasikan pengguna beserta peran yang dimilikinya pada masing-masing toko. Pengguna memilih satu toko aktif sebelum masuk ke dasbor.

c. Perancangan Halaman Kelola Katalog Produk

Halaman kelola katalog produk dirancang untuk memelihara data produk dan persediaan yang menjadi sumber masukan bagi pencatatan transaksi penjualan. Desain halaman tersebut dapat dilihat pada Gambar 3.19.

← Tambah Produk

Tambah Foto

Maksimal ukuran foto 5MB. Format JPG, PNG.

Nama Produk

Masukkan nama produk

Kategori

Pilih kategori

SKU / Barcode

Contoh: PRD-001

Harga Modal

Rp 0

Harga Jual

Rp 0

Stok Awal

0


Simpan Produk

Gambar 3.19 Desain Halaman Kelola Katalog Produk

Gambar 3.19 menunjukkan formulir data produk yang memuat nama, harga, jumlah stok, SKU atau *barcode*, kategori, dan gambar produk. Halaman ini digunakan untuk menambah maupun menyunting data produk, sedangkan penghapusan produk diterapkan melalui skema *soft delete*.

d. Perancangan Halaman Kelola Kategori

Halaman kelola kategori dirancang untuk mengatur pengelompokan produk agar katalog toko lebih mudah ditelusuri saat transaksi berlangsung. Desain halaman tersebut dapat dilihat pada Gambar 3.20.




Gambar 3.20 Desain Halaman Kelola Kategori

Gambar 3.20 menunjukkan daftar kategori yang telah dibuat beserta jumlah produk pada masing-masing kategori. Halaman ini menyediakan aksi tambah, ubah, dan hapus kategori.

e. Perancangan Halaman Kasir dan Pembayaran

1) Perancangan Halaman Kasir

Halaman kasir dirancang sebagai layar utama pelayanan transaksi, yaitu tempat kasir menyusun keranjang belanja pelanggan. Desain halaman tersebut dapat dilihat pada Gambar 3.21.



Gambar 3.21 Desain Halaman Kasir

Gambar 3.21 menunjukkan katalog produk yang dikelompokkan menurut kategori, kolom pencarian produk, serta lencana keranjang yang menampilkan jumlah item dan subtotal belanja.

2) Perancangan Halaman Pembayaran

Halaman pembayaran dirancang untuk menyelesaikan transaksi setelah keranjang belanja dinyatakan selesai disusun. Desain halaman tersebut dapat dilihat pada Gambar 3.22.

The image shows a mobile application interface for a payment screen. At the top, there is a back arrow and the title "Pembayaran". Below this, a grey box displays "TOTAL TAGIHAN" and "Rp 25.000". Underneath, the section "Metode Pembayaran" offers two options: "Tunai" (Cash) with a cash icon and "QRIS" with a QR code icon. The "Uang Tunai Diterima" (Cash Received) section shows a text input field with "Rp 25000" and three radio button options: "Rp 25", "Rp 50", and "Rp 100", each followed by "rb". At the bottom of this section, a grey box shows "KEMBALIAN" (Change) as "Rp 0" with a checkmark icon. A large black button at the very bottom is labeled "Konfirmasi & Simpan Transaksi".

Gambar 3.22 Desain Halaman Pembayaran

Gambar 3.22 menunjukkan rincian item belanja beserta total tagihan, pilihan metode pembayaran, dan kolom nominal uang yang diterima. Sistem menghitung kembalian sebelum transaksi disimpan ke basis data lokal.

f. Perancangan Halaman Riwayat Stok

Halaman riwayat stok dirancang untuk menelusuri catatan mutasi persediaan sebagai bahan pemeriksaan inventaris toko. Desain halaman tersebut dapat dilihat pada Gambar 3.23.

The wireframe shows a mobile application screen for 'Riwayat Stok'. It features a title bar at the top. Below the title bar are five filter boxes stacked vertically: 'Filter: rentang tanggal', 'Filter: produk', 'Mutasi masuk / keluar', 'Waktu, jumlah, penyebab', and 'Saldo stok berjalan'. In the center of the screen is a large rectangular area labeled 'PLACEHOLDER'. At the bottom of the screen is a navigation bar containing four small circles.


Gambar 3.23 Desain Halaman Riwayat Stok

Gambar 3.23 menunjukkan penyaring rentang waktu dan produk, serta daftar mutasi stok yang memuat waktu perubahan, jumlah yang berubah, penyebab perubahan, dan saldo stok berjalan.

g. Perancangan Halaman Dasbor dan Laporan

1) Perancangan Halaman Dasbor

Halaman dasbor dirancang sebagai halaman utama yang ditampilkan setelah pengguna berhasil masuk ke dalam sistem. Desain halaman tersebut dapat dilihat pada Gambar 3.24.




Gambar 3.24 Desain Halaman Dasbor

Gambar 3.24 menunjukkan kartu statistik omzet, jumlah transaksi, jumlah produk berstok rendah, dan jumlah produk aktif, disertai grafik tren penjualan serta pintasan menuju modul utama aplikasi.

2) Perancangan Halaman Laporan

Halaman laporan dirancang untuk menyajikan rekapitulasi penjualan pada rentang waktu yang dipilih pengguna. Desain halaman tersebut dapat dilihat pada Gambar 3.25.




Gambar 3.25 Desain Halaman Laporan

Gambar 3.25 menunjukkan penyaring rentang waktu beserta ringkasan penjualan dalam bentuk tabel dan grafik, sehingga pengguna dapat menelaah performa toko secara lebih rinci daripada tampilan dasbor.

h. Perancangan Halaman Prediksi Penjualan Harian

Halaman prediksi penjualan harian dirancang sebagai antarmuka fitur inti penelitian, yaitu tempat hasil peramalan model *Long Short-Term Memory* disajikan kepada pengelola. Desain halaman tersebut dapat dilihat pada Gambar 3.26.



Gambar 3.26 Desain Halaman Prediksi Penjualan Harian

Gambar 3.26 menunjukkan kartu estimasi omzet dan estimasi jumlah transaksi untuk hari berikutnya, grafik peramalan yang membedakan data aktual dengan hasil prediksi, serta area peringatan *cold start* yang muncul ketika panjang sekuens data belum memenuhi syarat minimum model.

i. Perancangan Halaman Riwayat Analisis

Halaman riwayat analisis dirancang untuk menelusuri kembali hasil prediksi yang pernah dijalankan beserta sumber komputasinya. Desain halaman tersebut dapat dilihat pada Gambar 3.27.

The wireframe shows a mobile application screen for 'Riwayat Analisis'. It features a title bar at the top. Below the title bar, there are five rectangular boxes, each containing a label: 'Daftar analisis tersimpan', 'Waktu pelaksanaan', 'Estimasi yang dihasilkan', 'Sumber komputasi', and 'Detail tiap snapshot'. These boxes are stacked vertically. Below the last box is a larger rectangular box labeled 'PLACEHOLDER'. At the bottom of the screen is a navigation bar with four circular icons.

Gambar 3.27 Desain Halaman Riwayat Analisis

Gambar 3.27 menunjukkan daftar analisis yang telah tersimpan beserta waktu pelaksanaan, estimasi omzet yang dihasilkan, dan keterangan sumber komputasi, sehingga hasil peramalan antarwaktu dapat dibandingkan.

j. **Perancangan Halaman Manajemen Karyawan**

Halaman manajemen karyawan dirancang sebagai halaman eksklusif Owner untuk mendaftarkan staf kasir dan mengatur peran yang diberikan. Desain halaman tersebut dapat dilihat pada Gambar 3.28.

Manajemen Karyawan

Daftar staf toko

Nama dan peran

Tambah staf baru

Ubah peran staf

Tombol simpan

PLACEHOLDER

Gambar 3.28 Desain Halaman Manajemen Karyawan

Gambar 3.28 menunjukkan daftar staf toko beserta nama dan perannya, formulir penambahan staf baru, serta pilihan pengubahan peran staf yang telah terdaftar.

k. Perancangan Halaman Profil Toko dan Pengaturan

1) Perancangan Halaman Profil Toko

Halaman profil toko dirancang sebagai halaman eksklusif Owner untuk memperbarui identitas toko yang ditampilkan pada aplikasi dan bukti transaksi.

Desain halaman tersebut dapat dilihat pada Gambar 3.29.


The image shows a mobile application interface for setting up a shop profile. At the top, there is a back arrow icon and a shop icon. Below these, a welcome message reads 'Selamat Datang!' followed by 'Satu langkah lagi untuk memulai bisnis Anda. Mari buat toko pertama Anda.' The main section is titled '< Informasi Toko' and contains two input fields: 'NAMA TOKO / OUTLET' with the example text 'Contoh: Kopi Kenangan Jaya' and 'ALAMAT LENGKAP' with the example text 'Jl. Merdeka No. 123'. A large black button labeled 'Konfirmasi & Mulai' is positioned below the fields. At the bottom, a small disclaimer states: 'Dengan klik Konfirmasi, fitur **RESTAURANT** akan langsung diaktifkan untuk anda.'

Gambar 3.29 Desain Halaman Profil Toko

Gambar 3.29 menunjukkan kolom nama toko, alamat, logo *outlet*, dan informasi operasional lainnya yang ditampilkan kepada pelanggan.

2) Perancangan Halaman Pengaturan

Halaman pengaturan dirancang sebagai pusat konfigurasi aplikasi yang menghimpun menu-menu pendukung dalam satu tempat. Desain halaman tersebut dapat dilihat pada Gambar 3.30.



Gambar 3.30 Desain Halaman Pengaturan

Gambar 3.30 menunjukkan daftar menu konfigurasi aplikasi dan toko, dengan sebagian menu hanya tersedia bagi Owner, yaitu manajemen karyawan dan pengaturan profil toko.


3.4 Perancangan Metode Penelitian

Bagian ini menjelaskan tahapan perancangan metode yang digunakan dalam penelitian ini. Penelitian dilaksanakan sebagai penelitian pengembangan (*Research and Development*) dengan pendekatan kuantitatif untuk pengujian model prediksi, sedangkan pengembangan aplikasi dilakukan secara iteratif dan bertahap dengan

memprioritaskan fitur inti kasir sebelum fitur analitik prediktif ditambahkan. Perancangan metode diuraikan menjadi empat bagian, yaitu perancangan alur penelitian, *flowchart* penerapan metode *Long Short-Term Memory* (LSTM), *flowchart* perhitungan sel LSTM, serta perhitungan metrik evaluasi pengujian.

3.4.1 Perancangan Alur Penelitian

Alur penelitian dirancang secara sistematis untuk membangun aplikasi *Point of Sale* yang dilengkapi fitur prediksi penjualan harian. Alur penelitian tersebut dapat dilihat pada Gambar 3.31.



Gambar 3.31 Alur Penelitian

Gambar 3.31 menunjukkan tahapan penelitian yang terbagi menjadi dua fase yang saling berkaitan, yaitu pengembangan sistem *Point of Sale* dan pengembangan model prediksi penjualan. Adapun rincian kedua fase tersebut dijelaskan sebagai berikut.

a. Fase Pengembangan Sistem *Point of Sale*


Fase ini diawali dengan analisis kebutuhan melalui observasi pada mitra EatsTEDI, dilanjutkan perancangan sistem dan antarmuka. Aplikasi dikembangkan menggunakan Flutter dengan Supabase dan Isar DB, sedangkan layanan prediksi dibangun menggunakan Python pada Hugging Face, lalu diujicobakan secara fungsional pada mitra.

b. Fase Pengembangan Model Prediksi Penjualan

Fase ini menggunakan data sekunder berupa riwayat transaksi platform EatsTEDI yang telah beroperasi sebelum penelitian dimulai, bukan data dari aplikasi yang baru dibangun. Data tersebut melalui pra-pemrosesan, pembentukan deret waktu, dan pembagian data latih serta uji. Model LSTM kemudian dilatih, dievaluasi, lalu diintegrasikan ke aplikasi melalui *REST API*.

3.4.2 *Flowchart Penerapan Metode Long Short-Term Memory*

Flowchart penerapan metode LSTM ditunjukkan pada Gambar 3.32. *Flowchart* ini menggambarkan alur implementasi metode LSTM dalam sistem prediksi penjualan harian, mulai dari penarikan data transaksi hingga penyajian hasil prakiraan kepada pengguna.



Gambar 3.32 Alur Kerja Algoritma *Long Short-Term Memory* (LSTM)

Gambar 3.32 menunjukkan proses penerapan metode yang dimulai dari penarikan data transaksi harian pada basis data Supabase sebagai masukan sistem. Adapun tahapan proses tersebut dijelaskan sebagai berikut.

- a. Input Data Transaksi Harian: Sistem menarik riwayat transaksi harian mitra EatsTEDi dari basis data *cloud* Supabase sebagai masukan proses pemodelan.

- b. *Filtering* Hari Non-Aktif: Sistem menghapus hari Sabtu, Minggu, serta bulan Januari dan Juli agar model dilatih murni pada indeks hari kerja aktif tanpa distorsi *gap* panjang.
- c. Transformasi Logaritma: Nominal pendapatan Y_t ditransformasikan ke skala logaritma menggunakan $Y'_t = \log(Y_t + 1)$ untuk menstabilkan variansi.
- d. Transformasi Target *Log-Return*: Target prediksi diubah dari nilai pendapatan menjadi perubahan relatif (*log-return*) r_t agar model mewarisi autokorelasi jangka pendek data penjualan, sebagaimana Persamaan 3.1.

$$r_t = Y'_t - Y'_{t-1} = \log(Y_t + 1) - \log(Y_{t-1} + 1) \quad (3.1)$$

- e. Pengodean Siklik dan Normalisasi: Fitur waktu diubah menjadi nilai sinus dan kosinus, lalu seluruh fitur dinormalisasi dengan *Min-Max Scaling* ke rentang $[0, 1]$. Parameter *scaler* dipasang hanya pada data latih untuk mencegah *data leakage*.
- f. Pembentukan *Sequence*: Deret waktu diubah menjadi pasangan urutan melalui *sliding window* sepanjang 7 hari aktif untuk memprediksi 1 hari aktif berikutnya (*one-step-ahead*).
- g. Pembagian *Dataset* Kronologis: *Dataset* dibagi secara *time-based split*, yaitu 70% data latih, 15% data validasi untuk *early stopping*, dan 15% data uji.
- h. Pembangunan Arsitektur LSTM: Arsitektur dirancang minimalis untuk menghindari *overfitting*, terdiri atas *input layer* 7×8 , satu *LSTM layer* 24 *hidden units*, *dropout* 0,1, *dense layer* 16 neuron ReLU, dan *output layer* satu neuron linear, dengan total 3.585 parameter terlatih.

- i. Pelatihan Model: Model dilatih menggunakan optimasi Adam (*learning rate* 5×10^{-4}), fungsi kerugian MSE, *batch* 16, dan maksimum 200 *epoch*, disertai *Early Stopping* 20 *epoch* dan *Reduce Learning Rate on Plateau* faktor 0,5.
- j. Evaluasi Model: Sistem menghitung MAE, RMSE, sMAPE, dan MASE pada data uji sebagaimana dijabarkan pada Subbab 3.4.4.
- k. Pemeriksaan Kriteria Kelayakan: Model dinyatakan layak apabila MASE-nya lebih kecil daripada MASE *baseline Naive*. Apabila belum, dilakukan *hyperparameter tuning* dan pelatihan diulang.
- l. Rekonstruksi ke Skala Nominal: *Output* berupa *log-return* $\hat{r}_t$ dikembalikan ke skala Rupiah $\hat{Y}_t$ menggunakan nilai penjualan hari sebelumnya, sesuai Persamaan 3.2.

$$\hat{Y}_t = \exp(\log(Y_{t-1} + 1) + \hat{r}_t) - 1 \quad (3.2)$$


- m. Prakiraan Rekursif Multi-Langkah: Proyeksi 7 hari aktif ke depan dihasilkan secara rekursif dengan tiga pengaman, yaitu *clipping log-return* pada persentil 10–90, *damping factor* ϕ^h dengan $\phi = 0,7$, dan *safety rail* pada rentang pendapatan historis.
- n. Integrasi dan Penyajian Hasil: Model yang layak diintegrasikan ke sistem POS melalui *REST API* berbasis Flask pada Hugging Face, sehingga hasil prediksi dapat ditampilkan pada halaman prediksi penjualan harian.

Proses tersebut diulang hingga model memenuhi kriteria kelayakan. *Flowchart* ini menunjukkan bahwa LSTM diterapkan sebagai model prediksi deret

waktu bertarget *log-return*, yang hasilnya direkonstruksi ke skala nominal sebelum disajikan pada aplikasi *Point of Sale*.

3.4.3 Flowchart Perhitungan Sel Long Short-Term Memory

Flowchart perhitungan sel LSTM ditunjukkan pada Gambar 3.33. Flowchart ini menggambarkan komputasi di dalam satu sel LSTM pada setiap langkah waktu, mulai dari penerimaan masukan hingga penghasilan prediksi.



Gambar 3.33 Flowchart Perhitungan Sel Long Short-Term Memory

Gambar 3.33 menunjukkan proses pembaruan *cell state* dan *hidden state* yang diulang sebanyak panjang *sequence* masukan, yaitu 7 langkah waktu. Adapun tahapan proses tersebut dijelaskan sebagai berikut.

- a. Input Vektor Fitur dan *State* Sebelumnya: Sel menerima vektor fitur x_t , *hidden state* h_{t-1} , dan *cell state* C_{t-1} .
- b. Inisialisasi *State* Awal: Pada langkah waktu pertama, h_0 dan C_0 diinisialisasi sebagai vektor nol berdimensi 24 sesuai jumlah *hidden units*.
- c. Penggabungan Vektor Masukan: Vektor h_{t-1} dan x_t digabungkan menjadi satu vektor yang digunakan bersama oleh seluruh gerbang.
- d. Perhitungan *Forget Gate*: Nilai f_t dihitung dengan Persamaan 2.3 untuk menentukan proporsi informasi *cell state* sebelumnya yang dipertahankan.
- e. Perhitungan *Input Gate*: Nilai i_t dihitung dengan Persamaan 2.4 untuk menentukan besar informasi baru yang masuk ke *cell state*.
- f. Perhitungan Kandidat *Cell State*: Kandidat $\tilde{C}_t$ dihitung dengan Persamaan 2.5 menggunakan fungsi aktivasi tanh.
- g. Pembaruan *Cell State*: *Cell state* diperbarui dengan Persamaan 2.6, yaitu penjumlahan $f_t \odot C_{t-1}$ dan $i_t \odot \tilde{C}_t$.
- h. Perhitungan *Output Gate*: Nilai o_t dihitung dengan Persamaan 2.7 untuk menentukan bagian *cell state* yang dikeluarkan.
- i. Perhitungan *Hidden State*: *Hidden state* h_t dihitung dengan Persamaan 2.8 melalui perkalian elemen o_t dan $\tanh(C_t)$.
- j. Pemeriksaan Langkah Waktu: Apabila masih terdapat langkah waktu tersisa, nilai h_t dan C_t diteruskan ke langkah berikutnya dan proses kembali ke tahap penggabungan.
- k. Pengambilan *Hidden State* Akhir: Setelah seluruh langkah waktu selesai, *hidden*

state terakhir h_T diambil sebagai representasi ringkas *sequence* masukan.

- l. Regularisasi *Dropout*: Nilai h_T dilewatkan melalui *dropout layer* berlaju 0,1 untuk mencegah ketergantungan berlebih antar-node.
- m. Pemrosesan *Dense Layer*: Hasil *dropout* diproses *dense layer* 16 neuron beraktivasi ReLU untuk mempelajari kombinasi non-linear representasi *sequence*.
- n. Penghasilan Prediksi *Log-Return*: *Output layer* satu neuron beraktivasi linear menghasilkan prediksi $\hat{r}_t$, yang selanjutnya direkonstruksi ke skala nominal Rupiah.

Flowchart ini menunjukkan bahwa sel LSTM bekerja melalui tiga gerbang dalam mengatur aliran informasi antar-langkah waktu, sehingga model mampu mempelajari pola autokorelasi jangka pendek pada deret waktu penjualan harian.

3.4.4 Perhitungan Metrik Evaluasi Pengujian

Proses evaluasi menghasilkan nilai kesalahan prediksi untuk setiap data uji berdasarkan perbandingan antara nilai aktual Y_t dan nilai prediksi $\hat{Y}_t$ pada skala nominal Rupiah. Penelitian ini menggunakan empat metrik evaluasi, yaitu *Mean Absolute Error* (MAE), *Root Mean Squared Error* (RMSE), *symmetric Mean Absolute Percentage Error* (sMAPE), dan *Mean Absolute Scaled Error* (MASE), yang landasan teorinya telah dijabarkan pada Subbab 2.2.8. Perhitungan keempat metrik tersebut dirumuskan sebagai berikut.

$$\text{MAE} = \frac{1}{N} \sum_{t=1}^N |Y_t - \hat{Y}_t| \quad (3.3)$$

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{t=1}^N (Y_t - \hat{Y}_t)^2} \quad (3.4)$$

$$\text{sMAPE} = \frac{100\%}{N} \sum_{t=1}^N \frac{|Y_t - \hat{Y}_t|}{(|Y_t| + |\hat{Y}_t|) / 2} \quad (3.5)$$

$$\text{MASE} = \frac{\frac{1}{N} \sum_{t=1}^N |Y_t - \hat{Y}_t|}{\frac{1}{N-1} \sum_{t=2}^N |Y_t - Y_{t-1}|} \quad (3.6)$$

Keterangan:

1. Y_t merupakan nilai penjualan aktual pada hari aktif ke- t .
2. $\hat{Y}_t$ merupakan nilai penjualan hasil prediksi model pada hari aktif ke- t .
3. N merupakan jumlah seluruh data pengujian.
4. Penyebut pada persamaan MASE merupakan MAE dari *baseline Naive*, yaitu prediksi yang menyamakan nilai hari ini dengan nilai hari aktif sebelumnya.

Nilai MAE dan RMSE dinyatakan dalam satuan Rupiah dan menunjukkan besaran kesalahan absolut prediksi, dengan RMSE memberikan penalti lebih besar terhadap kesalahan berskala ekstrem. Nilai sMAPE dinyatakan dalam persen sehingga memudahkan interpretasi kesalahan secara relatif. Sebagai konvensi implementasi metrik sMAPE, apabila penyebut bernilai nol (nilai aktual dan prediksi sama-sama nol), penyebut diganti dengan nilai 1 agar tidak terjadi galat pembagian dengan nol (*division by zero*). Konvensi inilah yang diverifikasi pada pengujian *white box*.

Nilai MASE digunakan sebagai metrik utama penentuan kelayakan model

karena bersifat bebas skala dan membandingkan kinerja model secara langsung terhadap *baseline Naive*. Model dinyatakan layak apabila nilai MASE model lebih kecil daripada MASE *baseline Naive* pada data uji yang sama, yang berarti kesalahan prediksi model lebih kecil daripada kesalahan metode pembanding sederhana tersebut.

3.5 Skenario Pengujian Model

Penelitian ini melakukan pengujian terhadap model *Long Short-Term Memory* untuk mengevaluasi akurasi prediksi penjualan harian yang dihasilkan. Pengujian menggunakan data historis transaksi mitra EatsTEDI sebanyak 313 hari kerja aktif, dengan hasil prediksi dibandingkan terhadap nilai aktual menggunakan metrik MAE, RMSE, sMAPE, dan MASE. Skenario pengujian dirancang untuk menganalisis kinerja model terhadap metode pembanding, mengamati stabilitasnya terhadap inisialisasi bobot acak, mengukur pengaruh augmentasi data sintetis, serta menguji konsistensi kinerja pada horizon prakiraan yang berbeda.

3.5.1 Skenario 1: Pengujian Model LSTM terhadap *Baseline*

Skenario pertama bertujuan mengetahui kinerja model LSTM dibandingkan empat metode pembanding. Pengujian dilakukan pada data uji yang sama untuk seluruh metode, dengan tiga *baseline* dievaluasi pada skema satu langkah ke depan dan *Seasonal-Naive* pada skema multi-langkah. Parameter k pada *Seasonal-Naive* menyatakan jumlah kemunculan terakhir hari sejenis yang dirata-ratakan. Adapun skenario pengujian tersebut dapat dilihat pada Tabel 3.17.

Tabel 3.17 Skenario 1: Pengujian Model LSTM terhadap *Baseline*

No	Metode	Skema Prediksi	Keterangan
1	LSTM	<i>one-step-ahead</i>	Model usulan penelitian
2	<i>Naive</i>	<i>one-step-ahead</i>	Nilai hari aktif sebelumnya
3	<i>Mean-7</i>	<i>one-step-ahead</i>	Rata-rata 7 hari aktif terakhir
4	SARIMA	<i>one-step-ahead</i>	Model statistik klasik deret waktu
5	<i>Seasonal-Naive</i>	<i>multi-step</i>	Rata-rata k kemunculan terakhir hari sejenis

3.5.2 Skenario 2: Pengujian Stabilitas *Multi-Seed*

Skenario kedua bertujuan mengukur stabilitas kinerja model, mengingat inisialisasi bobot awal jaringan saraf bersifat acak dan berpengaruh besar pada *dataset* berukuran kecil. Model dilatih sebanyak 10 kali menggunakan *seed* acak yang berbeda, kemudian hasil evaluasi dilaporkan sebagai rata-rata beserta standar deviasinya. Adapun skenario pengujian tersebut dapat dilihat pada Tabel 3.18.

Tabel 3.18 Skenario 2: Pengujian Stabilitas *Multi-Seed*

No	Metode	Jumlah Pengulangan	Bentuk Pelaporan
1	LSTM	10 <i>seed</i> acak	Rata-rata $\pm$ standar deviasi MAE, RMSE, sMAPE, dan MASE

3.5.3 Skenario 3: Pengujian Augmentasi Data Sintetis TimeGAN

Skenario ketiga bertujuan mengukur pengaruh augmentasi data sintetis terhadap akurasi prediksi pada kondisi data latih terbatas. TimeGAN dilatih pada jendela deret waktu sepanjang 24 hari aktif dengan tiga fitur numerik, yaitu omzet, jumlah transaksi, dan kuantitas terjual. Data sintetis yang dihasilkan digabungkan dengan data riil untuk melatih ulang model LSTM, lalu kinerjanya dibandingkan

terhadap model tanpa augmentasi. Adapun skenario pengujian tersebut dapat dilihat pada Tabel 3.19.

Tabel 3.19 Skenario 3: Pengujian Augmentasi Data Sintetis TimeGAN

No	Skenario Data Latih	Sekuens Riil	Sekuens Sintetis	Rasio Augmentasi
1	Tanpa augmentasi	199	0	–
2	Dengan augmentasi TimeGAN	199	298	1,5

3.5.4 Skenario 4: Pengujian Horizon Prakiraan Rekursif

Skenario keempat bertujuan mengamati konsistensi kinerja model pada horizon prakiraan yang berbeda, mengingat metode *recursive forecasting* berpotensi mengalami akumulasi bias pada langkah yang semakin jauh. Pengujian dilakukan pada empat horizon, yaitu 1, 3, 5, dan 7 hari aktif ke depan, dengan model LSTM dibandingkan terhadap *baseline Seasonal-Naive*. Adapun skenario pengujian tersebut dapat dilihat pada Tabel 3.20.

Tabel 3.20 Skenario 4: Pengujian Horizon Prakiraan Rekursif

No	Horizon Prakiraan	Metode Dibandingkan
1	1 hari aktif	LSTM dan <i>Seasonal-Naive</i>
2	3 hari aktif	LSTM dan <i>Seasonal-Naive</i>
3	5 hari aktif	LSTM dan <i>Seasonal-Naive</i>
4	7 hari aktif	LSTM dan <i>Seasonal-Naive</i>

Keempat skenario tersebut berfokus pada prediksi harian sebagai lingkup evaluasi ilmiah penelitian ini. Adapun proyeksi mingguan dan bulanan yang turut

disajikan layanan API produksi menggunakan metode rata-rata sederhana dan berada di luar lingkup evaluasi, sejalan dengan Batasan Masalah yang memfokuskan prediksi pada rentang harian.

3.6 Perancangan Pengujian Sistem

Pengujian sistem dilakukan untuk memastikan kualitas fungsional aplikasi yang dibangun. Penelitian ini menggunakan dua pendekatan, yaitu *black box testing* untuk memverifikasi kesesuaian perilaku fitur terhadap spesifikasi kebutuhan, dan *white box testing* secara terbatas untuk memverifikasi kebenaran logika pada fungsi kritis layanan prediksi.

3.6.1 Perancangan Pengujian *Black Box*

Pengujian *black box* bertujuan menguji fungsi-fungsi sistem berdasarkan masukan dan keluaran yang dihasilkan, tanpa memeriksa struktur kode program. Pengujian diterapkan pada empat belas fungsi utama aplikasi *Point of Sale*, mulai dari registrasi toko hingga penyajian prediksi penjualan harian, untuk memastikan seluruhnya berjalan sesuai kebutuhan pengguna. Adapun skenario pengujian *black box* dapat dilihat pada Tabel 3.21.

Tabel 3.21 Skenario Pengujian *Black Box*

No.	Fitur / Fungsi	Skenario Pengujian	Hasil yang Diharapkan
1	Registrasi Toko Baru	Mengisi <i>form</i> registrasi dengan email baru, kata sandi, nama toko, alamat, dan nomor HP.	Akun Owner berhasil dibuat, data toko tersimpan di <i>database</i> Supabase <i>cloud</i> , dan beralih ke halaman utama.

No.	Fitur / Fungsi	Skenario Pengujian	Hasil yang Diharapkan
2	Login Akun	Memasukkan email dan kata sandi yang <i>valid/invalid</i> pada layar <i>login</i> .	Jika <i>valid</i> , pengguna masuk ke dasbor sesuai hak akses peran. Jika <i>invalid</i> , sistem menampilkan pesan <i>error</i> autentikasi.
3	Checkout Transaksi	Memasukkan produk ke keranjang, memilih metode bayar, dan mengonfirmasi nominal bayar.	Transaksi berhasil disimpan di <i>database</i> lokal Isar DB, jumlah stok produk berkurang otomatis, dan dialihkan ke struk sukses.
4	Terapkan Diskon	Memasukkan kode <i>voucher</i> /nilai diskon pada keranjang belanja sebelum pembayaran.	Total belanja terpotong sesuai nilai nominal diskon/ <i>voucher</i> dan tercatat pada rincian nota.
5	Mencetak Struk	Menghubungkan printer Bluetooth <i>thermal</i> dan menekan tombol cetak struk dari riwayat transaksi.	Printer <i>thermal</i> mencetak struk fisik transaksi secara lengkap (nama produk, total, tanggal, metode bayar).
6	Kelola Produk	Menambah produk baru dengan nama, harga, stok, foto, dan kategori serta mengubah/menghapus produk.	Data produk baru tersimpan di <i>database</i> lokal Isar DB, terdaftar pada <i>list</i> produk, dan dapat diubah/dihapus.
7	Kelola Kategori	Menambahkan kategori baru, menyunting nama kategori, atau menghapus kategori produk.	Kategori berhasil dibuat, muncul sebagai opsi <i>filter</i> menu, dan diperbarui secara <i>real-time</i> .
8	Audit Mutasi Stok	Melakukan transaksi/penyesuaian stok, lalu membuka halaman riwayat mutasi stok.	Riwayat keluar-masuk barang tercatat pada <i>log stock_history</i> dengan jenis mutasi yang sesuai.

No.	Fitur / Fungsi	Skenario Pengujian	Hasil yang Diharapkan
9	Dasbor Ringkasan	Membuka dasbor laporan penjualan harian, mingguan, dan grafik visualisasi omzet.	Menampilkan statistik ringkasan omzet, total transaksi harian, dan grafik visualisasi garis yang akurat.
10	<i>Smart Analytics</i>	Membuka layar <i>Smart Analytics</i> dengan koneksi internet aktif.	Grafik prediksi penjualan 7 hari ke depan dari layanan API prediksi berhasil ditampilkan dan tersimpan sebagai <i>snapshot</i> .
11	<i>Broadcast Notifikasi</i>	Owner mengirim pesan <i>broadcast</i> kepada staf toko melalui menu notifikasi.	Notifikasi <i>broadcast</i> diterima dan muncul di perangkat kasir secara <i>real-time</i> .
12	Sinkronisasi <i>Offline</i>	Mematikan koneksi internet (luring), membuat transaksi lokal, lalu mengaktifkan internet kembali (daring).	Transaksi disimpan secara lokal di Isar DB (<i>offline-first</i>), lalu terunggah otomatis ke Supabase <i>cloud</i> saat internet aktif kembali.
13	Kelola Staf Karyawan	Owner menambahkan akun staf kasir baru dan mengubah peran staf.	Akun staf berhasil terdaftar pada toko dengan peran yang sesuai. Menu ini tidak dapat diakses oleh Kasir.
14	Atur Profil Toko	Owner mengubah nama, alamat, dan logo toko pada menu pengaturan.	Informasi profil toko berhasil diperbarui dan tampil pada struk serta katalog. Menu ini eksklusif untuk Owner.

3.6.2 Perancangan Pengujian *White Box*

Pengujian *white box* bertujuan memverifikasi kebenaran logika internal dan jalur eksekusi kode pada fungsi kritis layanan API prediksi. Pengujian dilakukan dengan menelusuri jalur logika secara manual menggunakan masukan yang

keluarannya telah dihitung lebih dahulu sebagai acuan kebenaran. Tiga fungsi yang diuji adalah sebagai berikut.

1. Fungsi perhitungan *Seasonal-Naive (by_dow)*, untuk memverifikasi jalur percabangan logika ketika jumlah data historis per hari kerja mencukupi ($\geq k$), tidak mencukupi ($< k$), maupun tidak tersedia sama sekali (*fallback*).
2. Fungsi metrik evaluasi sMAPE dan MASE, untuk memverifikasi jalur penanganan kasus pembagian dengan nilai penyebut nol atau mendekati nol agar tidak menghasilkan galat pembagian (*division by zero*).
3. Fungsi prediksi rekursif (*forecast_hybrid_stable*), untuk memverifikasi jalur eksekusi tiga mekanisme pengaman secara berurutan, yaitu *clipping log-return*, *damping factor*, dan *safety rail* nominal omzet.

3.6.3 Indikator Keberhasilan Penelitian

Keberhasilan penelitian diukur melalui tiga indikator berikut, yang pencapaiannya dijawab pada Bab IV dan Bab V.

1. Aplikasi *Point of Sale* berfungsi mengelola transaksi penjualan, katalog produk, dan pelaporan penjualan, yang divalidasi melalui pengujian *black box*.
2. Model *Long Short-Term Memory* terimplementasi pada sistem dan kinerjanya terukur secara objektif menggunakan metrik MAE, RMSE, sMAPE, dan MASE terhadap *baseline*.
3. Sistem menyajikan hasil prediksi dan laporan penjualan dalam bentuk visualisasi yang mudah dipahami pengguna.

BAB IV

HASIL DAN PEMBAHASAN

Bab ini menyajikan hasil rancang bangun dan pembahasan sistem Point of Sale (POS) dengan fitur prediksi penjualan harian menggunakan metode Long Short-Term Memory (LSTM). Pembahasan dibagi menjadi tujuh bagian utama, yaitu hasil implementasi sistem, hasil implementasi praproses data, hasil implementasi mekanisme prediksi, hasil pengujian model terhadap skenario pengujian, hasil pengujian sistem, pembahasan hasil penelitian, serta keterbatasan sistem dan penelitian. Perlu ditegaskan bahwa bab ini memaparkan dua objek yang berbeda namun saling terkait, yaitu sistem POS sebagai artefak rancang bangun dan model LSTM sebagai objek kajian metode prediksi.

4.1 Hasil Implementasi Sistem

Bagian ini memaparkan realisasi fisik dari rancangan sistem yang telah disusun pada Bab III, yang mencakup implementasi antarmuka aplikasi mobile (kasir dan owner), implementasi backend dan basis data cloud (Supabase), serta implementasi layanan prediksi (API) di sisi server.

4.1.1 Implementasi Antarmuka Aplikasi Mobile

Aplikasi *mobile* dikembangkan menggunakan *framework* Flutter dengan bahasa pemrograman Dart, mengacu pada rancangan *wireframe* pada Subbab 3.3.3. Cuplikan hasil implementasi antarmuka diambil langsung dari

aplikasi yang berjalan pada data toko mitra EatsTEDi, disusun berurutan mengikuti alur penggunaan aplikasi mulai dari registrasi akun, manajemen toko dan produk, transaksi kasir, hingga laporan analitik.

1. Halaman Registrasi

Halaman *Buat Akun* merupakan titik masuk awal bagi pengguna baru. Form registrasi memuat kolom Nama Lengkap, Email, *Password*, dan Konfirmasi *Password*, dilengkapi opsi pendaftaran cepat *Lanjutkan dengan Google* serta tautan menuju halaman Login bagi pengguna yang telah memiliki akun.

Gambar 4.1 Implementasi Halaman Registrasi

2. Halaman *Login*

Halaman *Selamat Datang Kembali* menyediakan autentikasi menggunakan Email dan *Password*, opsi *Ingat saya* dan *Lupa password*, serta tombol masuk melalui akun Google. Tombol *Masuk sebagai Pelanggan* disediakan sebagai jalur akses terpisah bagi pelanggan yang hendak memindai QR katalog mandiri tanpa memerlukan akun staf toko.

Gambar 4.2 Implementasi Halaman *Login*

3. Halaman Informasi Toko


Setelah registrasi, pengguna diarahkan ke halaman *Informasi Toko* untuk membuat outlet pertamanya, memuat kolom Nama Toko/*Outlet*, Provinsi dan Kota/Kabupaten (*dropdown* berjenjang), serta Alamat Lengkap, yang

kemudian dikonfirmasi melalui tombol *Konfirmasi & Mulai*.

Gambar 4.3 Implementasi Halaman Informasi Toko

4. Halaman Pilih Toko


Menampilkan daftar seluruh *outlet* yang terasosiasi dengan akun pengguna beserta peran pada masing-masing *outlet* (Owner atau Karyawan). Pengguna dapat bergabung ke *outlet* lain melalui *Kode Undangan* atau mendaftarkan *outlet* baru sebelum memilih toko aktif yang ingin dioperasikan.



Gambar 4.4 Implementasi Halaman Pilih Toko

5. Halaman Dasbor Owner


Menyajikan *Ringkasan Performa* toko dengan *filter* rentang waktu (Hari Ini, Minggu Ini, Bulan Ini), empat kartu statistik *real-time* (Omzet, Transaksi, Stok Rendah, dan Produk Aktif), serta grafik *Performa Penjualan* yang memvisualisasikan tren omzet tujuh hari terakhir. Navigasi bawah aplikasi (Dasbor, Kasir, Riwayat, Laporan, dan menu lainnya) juga tampak pada halaman ini.




Gambar 4.5 Implementasi Halaman Dasbor Owner

6. Halaman Kelola Produk dan Tambah Produk

Halaman *Katalog Produk* menampilkan daftar inventaris beserta foto, kategori, status stok, harga, dan kode SKU, dilengkapi kolom pencarian dan *filter* kategori (Semua, Minuman, Makanan). Formulir *Tambah Produk* memuat unggah foto produk, nama, kategori, SKU/*Barcode* (dapat dipindai atau digenerasi otomatis), harga modal, harga jual, dan stok awal.



(a) Katalog Produk




(b) Tambah Produk

Gambar 4.6 Implementasi Halaman Kelola Produk dan Tambah Produk

7. Halaman Kelola Kategori


Menyediakan pengelompokan produk melalui kategori yang dapat ditambah, disunting, dan dihapus, dilengkapi pencarian kategori dan penghitung jumlah produk pada setiap kategori (misalnya Minuman dan Makanan).




Gambar 4.7 Implementasi Halaman Kelola Kategori

8. Halaman Kelola Stok dan Ubah Stok Produk

Halaman *Kelola Stok* menampilkan daftar produk beserta harga dan jumlah stok terkini, dengan tombol *Ubah* pada setiap baris. Menekan tombol tersebut memunculkan modal *Ubah Stok Produk* berisi *stepper* penambahan/pengurangan stok manual serta pilihan pintasan (-10, -5, +5, +10) sebelum disimpan.



(a) Kelola Stok



(b) Modal Ubah Stok Produk

Gambar 4.8 Implementasi Halaman Kelola Stok dan Ubah Stok Produk

9. Halaman Riwayat Stok


Berfungsi sebagai log audit mutasi stok, menampilkan jenis mutasi (Penjualan atau Penyesuaian Manual), perubahan jumlah stok sebelum dan sesudah (misalnya dari 41 menjadi 40 *pcs*), staf yang melakukan perubahan, serta waktu kejadian, dilengkapi *filter* berdasarkan jenis mutasi.




Gambar 4.9 Implementasi Halaman Riwayat Stok

10. Halaman Kasir (POS) dan Detail Pesanan

Merupakan layar operasional utama kasir, menampilkan katalog produk dalam bentuk *grid* dengan pencarian dan pemindaian *barcode*. Memilih produk memunculkan modal *Detail Pesanan* yang merinci nama item, harga satuan, kuantitas melalui *stepper*, subtotal, dan total bayar sebelum dilanjutkan ke pembayaran.



(a) Kasir (POS)




(b) Detail Pesanan

Gambar 4.10 Implementasi Halaman Kasir (POS) dan Detail Pesanan

11. Halaman Pembayaran


Menampilkan total tagihan, pilihan metode pembayaran (Tunai atau QRIS), kolom *Uang Tunai Diterima* beserta pintasan nominal pecahan umum (Rp25rb, Rp50rb, Rp100rb), dan kalkulasi kembalian otomatis sebelum transaksi dikonfirmasi dan disimpan.



Gambar 4.11 Implementasi Halaman Pembayaran

12. Halaman Riwayat Transaksi


Menampilkan ringkasan kumulatif Omzet dan jumlah Transaksi, *filter* periode (Semua, Hari Ini, Kemarin, Pilih Tanggal) serta status (Berhasil, *Pending*, Batal), dan daftar transaksi yang dikelompokkan per tanggal lengkap dengan nomor invoice, jam, metode bayar, dan nominal.



Gambar 4.12 Implementasi Halaman Riwayat Transaksi

13. Halaman Struk Digital


Menampilkan rincian nomor transaksi, tanggal, metode pembayaran, nama kasir, total belanja, dan kembalian, dilengkapi kode QR yang dapat dipindai pelanggan untuk melihat struk secara *online*, serta tombol *Bagikan* dan *Set Printer* untuk mencetak struk fisik.



Gambar 4.13 Implementasi Halaman Struk Digital

14. Halaman Laporan Analitik

Menyajikan ringkasan Omzet dan Transaksi Keseluruhan, jumlah Stok Rendah dan Produk Aktif, serta grafik *Tren Penjualan* bulanan yang memvisualisasikan riwayat omzet toko EatsTEDI sejak Agustus 2024 hingga Juni 2026, sejalan dengan rentang data penelitian pada Subbab 3.4. Kartu *Smart Analitik* pada bagian atas halaman menjadi pintu masuk menuju fitur prediksi berbasis AI.




Gambar 4.14 Implementasi Halaman Laporan Analitik


15. Halaman *Smart Analitik* dan Riwayat Analisis

Halaman *Smart Analitik* memanggil layanan prediksi yang di-deploy pada *HuggingFace Space (Cloud)* dengan estimasi lokal *on-device* sebagai jalur cadangan apabila layanan *cloud* tidak dapat dijangkau, konsisten dengan strategi *offline-first* yang dibahas pada Subbab 3.2.1. Ketika riwayat transaksi toko masih kurang dari batas minimum sekuens LOOK_BACK yang disyaratkan model (lihat Subbab 3.3.2), sistem menampilkan peringatan *cold start* dan menyajikan estimasi berbasis pola bisnis retail/kafe

umum sebagai gantinya. Halaman ini menampilkan kartu Estimasi Omzet dan Estimasi *Traffic*, grafik *Forecasting* yang membedakan data riil dengan hasil prediksi AI, serta proyeksi menu terlaris untuk hari berikutnya. Setiap analisis yang dijalankan turut dicatat pada halaman *Riwayat Analisis* beserta sumber komputasi (*Cloud* atau Lokal) dan estimasi omzet yang dihasilkan.



Gambar 4.15 Implementasi Halaman *Smart Analitik*



Gambar 4.16 Implementasi Halaman Riwayat Analisis

4.1.2 Implementasi Backend dan Basis Data Cloud

Infrastruktur backend cloud diimplementasikan menggunakan platform Supabase BaaS dengan database PostgreSQL. Struktur relasional database diwujudkan melalui sembilan tabel utama yang saling terhubung:

1. *stores*: Menyimpan data identitas outlet merchant (id, nama, alamat, nomor HP, URL logo, created_at).
2. *store_members*: Mengatur relasi hak akses pengguna dengan peran Owner atau Karyawan di masing-masing outlet.

3. *categories*: Mengelola daftar kategori pengelompokan produk.
4. *products*: Menyimpan katalog inventaris barang (id, nama, harga, stok, barcode, URL foto, is_synced, is_deleted).
5. *transactions*: Menyimpan data nota induk transaksi penjualan (id, total belanja, metode pembayaran, kasir_id, created_at).
6. *transaction_items*: Menyimpan rincian item produk yang terjual pada setiap transaksi penjualan (id, transaksi_id, produk_id, jumlah, harga).
7. *stock_history*: Mencatat log audit mutasi perubahan stok produk (stok masuk, keluar, penjualan, audit manual).
8. *notifications*: Mengelola pesan notifikasi sistem dan info siaran antar staf toko secara real-time.
9. *smart_analytics_snapshots*: Menyimpan riwayat *snapshot* hasil analitik prediksi LSTM setiap kali fitur *Smart Analytics* dijalankan, sehingga hasil analisis sebelumnya dapat ditinjau kembali tanpa memanggil ulang model.

Keamanan akses data antar-outlet dijamin melalui penerapan kebijakan Row Level Security (RLS) di database PostgreSQL. Kebijakan ini memastikan bahwa pengguna (kasir/owner) hanya dapat membaca dan menulis data yang memiliki *store_id* yang sesuai dengan toko tempat mereka terdaftar.

4.1.3 Implementasi Layanan Prediksi (API)

Modul kecerdasan buatan untuk kalkulasi prediksi penjualan harian dikembangkan menggunakan Python dan terdiri atas dua bagian yang saling melengkapi. Bagian pertama adalah *pipeline* riset berbasis Jupyter Notebook yang

melatih model prediksi LSTM (TensorFlow/Keras) pada tiga granularitas waktu (harian, mingguan, dan bulanan) beserta eksperimen augmentasi data sintetis TimeGAN (PyTorch). Bagian kedua adalah layanan API produksi berbasis *framework* Flask yang di-*deploy* pada platform Hugging Face dan diintegrasikan langsung dengan aplikasi POS, sehingga beban komputasi prediksi terpisah dari beban kerja transaksional kasir.

Layanan API produksi menyediakan tujuh *endpoint* REST dengan fungsi sebagai berikut:

1. **Endpoint Prediksi Penjualan** (*/api/predict/daily*, */api/predict/weekly*, */api/predict/monthly*): Meramalkan omzet ke depan dengan tanggal prediksi yang otomatis melewati hari tutup (akhir pekan serta libur semester Januari/Juli). Berdasarkan hasil evaluasi komparatif pada penelitian ini (Subbab 4.4), metode penyaji yang dipilih pada *endpoint* produksi adalah metode statistik paling stabil, yaitu *Seasonal-Naive* ($k = 4$, rata-rata empat kemunculan terakhir hari yang sama, kompromi antara responsivitas terhadap tren terbaru dan peredaman fluktuasi acak, setara dengan rentang sekitar satu bulan hari sejenis) untuk harian, *Mean-4* untuk mingguan, dan *Mean-3* untuk bulanan, dengan prediksi *Naive* disertakan sebagai pembanding, sedangkan model LSTM hasil pelatihan didokumentasikan sebagai artefak riset (*.keras*).
2. **Endpoint Rekomendasi Operasional** (*/api/recommendations/stock* dan */api/recommendations/target*): Menghasilkan rekomendasi alokasi anggaran

belanja per kategori produk dan kuantitas stok produk teratas berdasarkan proyeksi omzet (dilengkapi *safety buffer* 15% dan peringatan khusus produk mudah basi), serta tiga tingkatan target omzet harian (konservatif, moderat, dan agresif) berbasis statistik 15 hari aktif terakhir.

3. **Endpoint Pencatatan dan Status** (*/api/sales/record* dan */api/status*):

Menerima rekap penjualan harian dari aplikasi POS dan memperbaruinya ke dataset historis (*upsert* per tanggal) agar dasar prediksi selalu mengikuti data terkini, serta memeriksa kesehatan layanan dan ketersediaan berkas data.

Aplikasi Flutter memanggil *endpoint* tersebut secara langsung melalui HTTPS dengan *payload* agregat penjualan tanpa informasi identitas pelanggan, kemudian menyimpan hasil analisis sebagai *snapshot* pada tabel *smart_analytics_snapshots* di Supabase.

Inti implementasi *endpoint* prediksi harian pada berkas *app.py* disajikan pada Kode Program IV.1 (dipersingkat). Metode *Seasonal-Naive* dihitung dengan merata-ratakan *k* kemunculan terakhir dari setiap hari kerja yang sama, dan tanggal prediksi dihasilkan dengan melewati hari tutup.

```

1 @app.route('/api/predict/daily', methods=['GET', 'POST'])
2 def predict_daily():
3     data = request.get_json(silent=True) or {}
4     n_days = int(data.get("n_days", 7))
5     k = int(data.get("k", 4))
6     dfa = get_daily_dataframe(data.get("history", None))
7     last_date = dfa['date'].max()

```



```

8
9     # Seasonal-Naive: rata-rata k kemunculan terakhir
10    # dari hari kerja yang sama (0=Senin ... 4=Jumat)
11    by_dow = {}
12    for dow in range(5):
13        dow_data = dfa[dfa['day_of_week'] == dow]['revenue']
14        if len(dow_data) >= k:
15            by_dow[dow] = dow_data.tail(k).mean()
16        elif len(dow_data) > 0:
17            by_dow[dow] = dow_data.mean()
18        else:
19            by_dow[dow] = dfa['revenue'].tail(10).mean()
20
21    # Naive: prediksi = omzet hari kerja terakhir
22    naive_value = float(dfa['revenue'].iloc[-1])
23
24    # Tanggal prediksi otomatis melewati hari tutup
25    future_dates = generate_future_business_days(last_date,
26                                                    n_days)
27    predictions = []
28    for dt in future_dates:
29        pred_sn = int(round(by_dow.get(dt.weekday(),
30                                     naive_value)))
31        predictions.append({
32            "date": dt.strftime('%Y-%m-%d'),
33            "predicted_revenue_seasonal_naive": pred_sn,
34            "predicted_revenue_naive":

```

```

        int(round(naive_value)))
33     return jsonify({"predictions": predictions}), 200

```

Kode Program IV.1: Implementasi Endpoint Prediksi Harian Seasonal-Naive (*app.py*)

4.2 Hasil Implementasi Praproses Data

Bagian ini menjelaskan tahapan pengolahan data sebelum digunakan untuk melatih model prediksi, mencakup deskripsi dan eksplorasi awal dataset, serta prapemrosesan dan pembentukan sequence data latih.

4.2.1 Deskripsi dan Eksplorasi Awal Dataset EatsTEDi

Data yang digunakan dalam pengujian model prediksi ini merupakan rekapitulasi transaksi penjualan harian kantin EatsTEDi UGM pada periode 26 Agustus 2024 hingga 20 Juni 2026. Setelah dilakukan agregasi nilai transaksi per hari dan penyaringan terhadap hari-hari non-aktif (di mana kantin tutup), diperoleh total sebanyak 313 hari aktif bisnis. Statistik ringkas mengenai dataset pendapatan harian ini disajikan pada Tabel 4.1.

Tabel 4.1 Statistik Ringkas Dataset Pendapatan Harian

Karakteristik	Nilai
Jumlah hari aktif	313 hari
Rentang waktu	26 Agu 2024 – 20 Jun 2026
Total revenue (omzet)	Rp 471.200.494,00
Rata-rata revenue per hari aktif	Rp 1.505.433,00
Revenue tertinggi	Rp 3.738.500,00 (6 Mei 2026)

Hasil eksplorasi awal menunjukkan bahwa deret data pendapatan harian

kantin EatsTEDI bersifat sangat fluktuatif dan dipengaruhi secara kuat oleh kalender akademis universitas. Terdapat pola penurunan tajam hingga bernilai Rp 0 pada masa libur semester mahasiswa (sepanjang bulan Januari dan Juli) serta pola musiman mingguan di mana penjualan menurun secara bertahap menjelang akhir pekan. Pola musiman tahunan tidak dapat teramati secara penuh karena rentang waktu data yang tersedia kurang dari dua tahun, sehingga deret waktu ini tergolong pendek (*short time-series*) untuk standar pemodelan berbasis *deep learning* yang membutuhkan volume data historis yang besar.

4.2.2 Penyaringan Hari Aktif dan Transformasi Target Log-Return

Pemodelan prediksi pada penelitian ini difokuskan pada granularitas harian dengan strategi prediksi satu langkah ke depan (*one-step-ahead prediction*). Untuk mengatasi variansi data yang ekstrem akibat fluktuasi harian yang sangat tajam, target prediksi tidak diprediksi menggunakan bentuk nilai nominal mentah, melainkan menggunakan bentuk *log-return* (selisih logaritmik) pendapatan antar hari aktif yang berurutan. Pendekatan residual ini dirancang agar model cukup mempelajari koreksi atau deviasi nilai pendapatan dari hari aktif sebelumnya, sehingga model secara tidak langsung mewarisi sifat autokorelasi jangka pendek yang kuat pada deret waktu transaksi.

Variabel masukan (*features*) terdiri atas nilai log-return pendapatan target dan enam fitur kalender yang dikodekan secara siklik (*cyclical encoding* sinus-kosinus untuk nomor minggu dalam setahun, bulan, dan hari kerja aktif) serta variabel biner Ramadan. Variabel jumlah transaksi harian dan kuantitas

produk terjual secara sengaja dikeluarkan dari variabel masukan model prediksi untuk menghindari kebocoran data (*data leakage*), karena kedua nilai tersebut belum tersedia saat modul prediksi dijalankan untuk memprediksi hari berikutnya. Proses penskalaan data dilakukan menggunakan metode *Min-Max Scaling* yang dipasang (*fit*) hanya pada data latih untuk mencegah terjadinya kebocoran informasi dari data uji.

4.2.3 Pembentukan Sequence dan Pembagian Dataset

Pembagian dataset dilakukan secara kronologis (*chronological split*) dengan rasio 70% untuk data latih (*train set*), 15% untuk data validasi (*validation set*), dan 15% untuk data uji (*test set*). Pembentukan urutan temporal (*sequence*) dilakukan menggunakan panjang *look-back* sebesar 7 hari aktif terakhir. Rincian pembagian data serta dimensi sequence disajikan pada Tabel 4.2.

Tabel 4.2 Pembagian Dataset dan Dimensi Sequence

Subset Data	Jumlah Hari	Jumlah Sequence	Dimensi Masukan
Latih (<i>train</i>)	219	212	(212, 7, 8)
Validasi (<i>val</i>)	46	39	(39, 7, 8)
Uji (<i>test</i>)	48	41	(41, 7, 8)

Implementasi pra-pemrosesan data, meliputi penyaringan hari aktif, transformasi target *log-return*, dan pengodean siklik fitur kalender, disajikan pada Kode Program IV.2.

```

1 df = pd.read_csv(DAILY_CSV, parse_dates=['date'])
2 # Hanya hari aktif (revenue > 0) yang dilatih ke model
3 dfa = df[df['revenue'] > 0].copy() \

```

```

4         .sort_values('date').reset_index(drop=True)
5
6     dfa['rev_log'] = np.log1p(dfa['revenue'])
7     # TARGET: log-return (perubahan pendapatan harian)
8     dfa['logret'] = dfa['rev_log'].diff().fillna(0.0)
9     # Pengodean siklik sinus-kosinus fitur kalender
10    dfa['week_sin'] = np.sin(2*np.pi*dfa['week_of_year']/52)
11    dfa['week_cos'] = np.cos(2*np.pi*dfa['week_of_year']/52)
12    dfa['month_sin'] = np.sin(2*np.pi*dfa['month']/12)
13    dfa['month_cos'] = np.cos(2*np.pi*dfa['month']/12)
14    dfa['dow_sin'] = np.sin(2*np.pi*dfa['day_of_week']/5)
15    dfa['dow_cos'] = np.cos(2*np.pi*dfa['day_of_week']/5)
16
17    # 'logret' wajib kolom pertama (kolom target)
18    FEATURES = ['logret', 'week_sin', 'week_cos', 'month_sin',
19                'month_cos', 'dow_sin', 'dow_cos', 'is_ramadan']
20
21    # Pembagian kronologis 70/15/15 (tanpa pengacakan)
22    n = len(dfa); n_tr = int(n*0.70); n_va = int(n*0.15)
23    df_tr = dfa.iloc[:n_tr]
24    df_va = dfa.iloc[n_tr:n_tr+n_va]
25    df_te = dfa.iloc[n_tr+n_va:]

```

Kode Program IV.2: Pra-pemrosesan Data: Filter Hari Aktif, Log-Return, dan Fitur Siklik

4.3 Hasil Implementasi Mekanisme Prediksi

Bagian ini memaparkan implementasi arsitektur model LSTM beserta skenario eksperimen, hasil pelatihan model, implementasi augmentasi data sintetis TimeGAN, dan implementasi mekanisme prediksi rekursif untuk kebutuhan visualisasi jangka pendek pada aplikasi.

4.3.1 Implementasi Arsitektur Model LSTM

Arsitektur model prediksi yang diimplementasikan adalah LSTM satu lapis (*single-layer LSTM*) dengan 24 *hidden units*, diikuti oleh lapisan *Dropout* dengan laju 0,1 untuk regularisasi, satu lapisan *Dense* dengan 16 neuron beraktivasi *Rectified Linear Unit* (ReLU), dan diakhiri oleh satu lapisan keluaran (*output layer*) tunggal beraktivasi linear. Model ini dirancang secara minimalis dengan total parameter terlatih hanya sebanyak 3.585 parameter. Pemilihan model berkapasitas rendah ini didasarkan pada jumlah data latih yang sangat terbatas (212 sampel sequence), sehingga penggunaan model LSTM berkapasitas besar (*stacked layers*) akan berisiko tinggi memicu kegagalan konvergensi pelatihan atau bias *overfitting*. Proses optimasi menggunakan metode Adam dengan *learning rate* awal sebesar 5×10^{-4} , fungsi kerugian (*loss function*) MSE, serta didukung *callbacks* *EarlyStopping* dan *ReduceLROnPlateau*. Konstruksi arsitektur model beserta konfigurasi pelatihannya disajikan pada Kode Program IV.3.

```
1 LOOK_BACK = 7    # jendela masukan: 7 hari aktif
2 HORIZON    = 1    # prediksi 1 langkah ke depan
3 UNITS      = 24
```

```

4 DROPOUT    = 0.1

5

6 def build_lstm():
7     m = Sequential([
8         LSTM(UNITS, input_shape=(LOOK_BACK, len(FEATURES))),
9         Dropout(DROPOUT),
10        Dense(16, activation='relu'),
11        Dense(HORIZON)
12    ], name='lstm_hybrid_residual')
13    m.compile(optimizer=Adam(5e-4), loss='mse',
14              metrics=['mae'])
15
16    return m
17
18 cb = [EarlyStopping('val_loss', patience=20,
19                    restore_best_weights=True),
20       ReduceLROnPlateau('val_loss', factor=0.5,
21                          patience=8, min_lr=1e-6)]
22
23 model = build_lstm()
24 hist = model.fit(X_tr, y_tr, validation_data=(X_va, y_va),
25                 epochs=200, batch_size=16, callbacks=cb)

```


Kode Program IV.3: Konstruksi Arsitektur LSTM Tersederhanakan dan Konfigurasi

Pelatihan

4.3.2 Hasil Pelatihan Model

Pada konfigurasi akhir model tersederhanakan, proses pelatihan berjalan secara stabil di mana galat validasi menunjukkan tren penurunan yang konsisten melampaui *epoch* pertama. Mekanisme *EarlyStopping* berhasil menghentikan proses pelatihan dan mengembalikan bobot terbaik model sebelum terjadi gejala *overfitting*. Hal ini berbanding terbalik dengan uji coba pada konfigurasi awal penelitian yang menggunakan arsitektur jaringan saraf berskala besar dan target berupa nilai nominal mentah, di mana model mengalami kolaps (*model collapse*) dengan galat validasi terbaik yang dicapai langsung pada *epoch* pertama (model tidak melakukan pembelajaran) dan menghasilkan prediksi bernilai rendah yang konstan secara sistematis. Penyederhanaan arsitektur, pemilihan target *log-return*, serta pembatasan horizon menjadi satu langkah ke depan terbukti mampu memperbaiki performa pelatihan secara signifikan, di mana nilai MAE uji terbaik model LSTM mengalami penurunan drastis dari sekitar Rp 1.805.196,00 pada konfigurasi awal menjadi berkisar antara Rp 500.000,00 hingga Rp 600.000,00 pada konfigurasi akhir. Iterasi dari konfigurasi awal (arsitektur besar, target nominal) menuju konfigurasi akhir tersederhanakan inilah yang merupakan realisasi dari *loop hyperparameter tuning* dengan kriteria akurasi ($MASE < 1$) pada diagram alur Gambar 3.32. Meskipun kriteria $MASE < 1$ pada akhirnya tidak tercapai oleh konfigurasi manapun, iterasi dihentikan pada konfigurasi terbaik dan keputusan produksi dialihkan ke metode *baseline* sebagaimana dibahas pada Subbab 4.4. Grafik kurva kerugian pelatihan model ditunjukkan pada Gambar

4.17.

Gambar 4.17 Kurva Kerugian Pelatihan (*Training Loss Curve*) Model LSTM

4.3.3 Implementasi Augmentasi Data Sintetis TimeGAN

Sebagai upaya mitigasi terhadap keterbatasan ukuran dataset yang menjadi akar penyebab ketidakstabilan model LSTM, dilakukan eksperimen augmentasi data sintetis menggunakan **TimeGAN** (Yoon et al., 2019). Model TimeGAN yang diimplementasikan dengan PyTorch dilatih pada jendela deret waktu sepanjang 24 hari aktif dengan tiga fitur numerik (omzet, jumlah transaksi, dan kuantitas terjual) melalui tiga fase pelatihan (*autoencoder*, *supervised*, dan *joint adversarial training*) masing-masing sebanyak 600 *epoch*, kemudian menghasilkan 298 sekuens data harian sintetis dari 199 sekuens data riil (rasio augmentasi 1,5). Pada skenario ini, model LSTM multi-langkah (*look-back* 14 hari aktif, horizon 7 hari) selanjutnya dilatih dalam dua kondisi: hanya menggunakan 199 sekuens data riil (*baseline real-only*), dan menggunakan gabungan data riil dengan 298 sekuens sintetis (rasio augmentasi 1,5). Hasil evaluasi perbandingan kedua kondisi tersebut disajikan pada Subbab 4.4.3.

Cuplikan implementasi dua dari lima jaringan penyusun TimeGAN pada berkas *TimeGAN.py*, yaitu jaringan *embedder* yang memetakan data riil ke ruang laten dan *generator* yang memetakan derau acak menjadi representasi laten

sintetis, disajikan pada Kode Program IV.4.

```

1  class EmbedderNet(nn.Module):
2
3      """Memetakan data nyata X -> representasi laten H."""
4
5      def __init__(self):
6
7          super().__init__()
8
9          self.rnn = nn.GRU(NUM_FEAT, HIDDEN_DIM,
10
11                             NUM_LAYERS, batch_first=True)
12
13          self.proj = nn.Sequential(
14
15              nn.Linear(HIDDEN_DIM, HIDDEN_DIM), nn.Sigmoid())
16
17
18      def forward(self, x):
19
20          h, _ = self.rnn(x)
21
22          return self.proj(h)
23
24
25  class GeneratorNet(nn.Module):
26
27      """Memetakan noise Z -> laten sintetis E."""
28
29      def __init__(self):
30
31          super().__init__()
32
33          self.rnn = nn.GRU(NUM_FEAT, HIDDEN_DIM,
34
35                             NUM_LAYERS, batch_first=True)
36
37          self.proj = nn.Sequential(
38
39              nn.Linear(HIDDEN_DIM, HIDDEN_DIM), nn.Sigmoid())
40
41
42      def forward(self, z):
43
44          h, _ = self.rnn(z)
45
46          return self.proj(h)

```

```

27 # Tiga fase pelatihan (masing-masing 600 epoch):
28 # 1) train_embedder : autoencoder embedder-recovery
29 # 2) train_supervisor: dinamika temporal ruang laten
30 # 3) train_joint      : pelatihan gabungan adversarial

```

Kode Program IV.4: Implementasi Jaringan *Embedder* dan *Generator* TimeGAN

(PyTorch)

4.3.4 Implementasi Prediksi Rekursif Multi-Langkah

Untuk kebutuhan penyajian visualisasi ramalan penjualan harian selama 7 hari aktif ke depan secara rekursif (*recursive forecasting*), model LSTM residual yang melakukan iterasi mandiri mengalami kerentanan berupa penumpukan kesalahan (*error propagation*) di mana nilai prediksi meluruh secara eksponensial hingga bernilai sangat kecil dan tidak realistis. Setelah ditambahkan mekanisme pengaman berupa *clipping* pada *log-return* (dijepit antara persentil 10–90 data latih), *damping factor* ($\phi = 0.7$) untuk meredam perubahan pada horizon yang jauh, serta *safety rail* penahan nominal omzet harian aktif, grafik prediksi yang dihasilkan menjadi lebih stabil dan realistis. Implementasi inti dari fungsi prediksi rekursif beserta ketiga mekanisme pengaman tersebut disajikan pada Kode Program IV.5.

```

1 # Batas clip dari persentil 10-90 log-return data latih
2 LR_LO, LR_HI = np.percentile(_train_logret, [10, 90])
3 REV_FLOOR = np.percentile(_act_rev, 2)      # rail bawah
4 REV_CEIL   = _act_rev.max()                 # rail atas

```



```

29         prev_rev = rev
30         rows.append({'tanggal': d.date(),
31                     'prediksi_revenue': int(round(rev))})
32     return pd.DataFrame(rows)

```

Kode Program IV.5: Prediksi Rekursif dengan *Clipping*, *Damping*, dan *Safety Rail*

Secara statistik, prediksi rekursif jangka panjang berbasis LSTM pada data terbatas ini akan dengan cepat meredam menuju nilai rata-rata historis (sifat *mean-reverting*) dan menyerupai prediksi naif. Untuk diintegrasikan ke dalam fitur aplikasi riil kasir, metode prediksi statistik *SARIMA* dan *Seasonal-Naive* (rata-rata hari sejenis pada minggu sebelumnya) lebih direkomendasikan karena memberikan hasil prediksi multi-langkah yang jauh lebih stabil dan konsisten. Rekomendasi ini diwujudkan pada layanan API produksi, di mana *endpoint* prediksi menyajikan metode *Seasonal-Naive* ($k = 4$) sebagai metode penyaji utama prediksi harian kepada aplikasi POS. Dalam penelitian skripsi ini, hasil evaluasi akurasi ilmiah tetap didasarkan pada pengujian satu langkah ke depan (*one-step-ahead*), sedangkan visualisasi prediksi multi-langkah diposisikan murni sebagai ilustrasi fungsionalitas sistem.

4.3.5 Implementasi Fungsi Metrik Evaluasi

Pengukuran akurasi model dilakukan menggunakan empat metrik evaluasi secara simultan, yaitu MAE, RMSE, sMAPE, dan MASE. Penggunaan MAPE konvensional dihindari karena karakteristik dataset transaksi memiliki beberapa

hari aktif dengan nilai nominal pendapatan yang sangat rendah (mendekati nol), sehingga pembagian terhadap nilai aktual tersebut akan menyebabkan pembagian dengan nol atau nilai persentase galat yang sangat besar (*exploding MAPE*) yang tidak representatif. Metrik MASE dipilih sebagai acuan performa utama karena ternormalisasi terhadap galat prediksi naif secara *in-sample*, di mana nilai MASE kurang dari satu menandakan bahwa kinerja model prediksi lebih baik dibandingkan model naif sederhana. Sebagai model pembanding (*baselines*) pada skema satu langkah ke depan, digunakan tiga metode pembanding statistik sederhana: (1) *Naive* (kemarin) di mana prediksi hari ini disamakan dengan realisasi hari kemarin, (2) *Mean-7* berupa rata-rata bergerak dari 7 hari aktif terakhir, dan (3) model statistik *SARIMA* dengan skema prediksi *rolling one-step*. Implementasi fungsi metrik evaluasi sMAPE dan MASE yang digunakan pada seluruh pengujian disajikan pada Kode Program IV.6.

```

1  def smape(y, yhat):
2      # sMAPE: galat dibagi rata-rata |aktual| dan |prediksi|
3      d = (np.abs(y) + np.abs(yhat)) / 2
4      return np.mean(np.abs(y - yhat)
5                      / np.where(d == 0, 1, d)) * 100
6
7  def mase(y, yhat, naive_mae):
8      # MASE: galat dinormalisasi thd galat naif in-sample
9      return mean_absolute_error(y, yhat) / naive_mae
10
11 def report(y, yhat, naive_mae, label):

```

```

12     rmse = np.sqrt(mean_squared_error(y, yhat))
13     mae = mean_absolute_error(y, yhat)
14     return {'rmse': rmse, 'mae': mae,
15           'smape': smape(y, yhat),
16           'mase': mase(y, yhat, naive_mae)}

```

Kode Program IV.6: Implementasi Fungsi Metrik Evaluasi sMAPE dan MASE

4.4 Hasil Pengujian Model terhadap Skenario Pengujian

Subbab ini melaporkan hasil pengujian model prediksi terhadap empat skenario pengujian yang telah dirancang pada Subbab 3.5. Seluruh pengukuran menggunakan metrik MAE, RMSE, sMAPE, dan MASE sebagaimana diimplementasikan pada Subbab 4.3.5.

4.4.1 Skenario 1: Pengujian Model LSTM terhadap Baseline Statistik


Setelah pelatihan diselesaikan, dilakukan evaluasi performa model prediksi pada dataset uji (*testing data*). Hasil evaluasi performa model LSTM Hybrid dibandingkan dengan ketiga metode pembandingan (*baselines*) disajikan pada Tabel 4.3. Nilai performa LSTM Hybrid yang disajikan pada tabel merupakan nilai rata-rata dari sepuluh kali percobaan dengan inisialisasi bobot acak yang berbeda (*multi-seed*).

Tabel 4.3 Perbandingan Performa pada Data Uji (*One-Step-Ahead*)

Model	MAE (Rp)	RMSE (Rp)	sMAPE	MASE
Naive (kemarin)	519.841	697.253	30,77%	1,432
SARIMA	586.083	751.408	33,80%	1,615
Mean-7	647.263	791.746	36,25%	1,784
LSTM Hybrid (Rata-rata)	667.718	897.563	38,06%	1,840
Seasonal-Naive ($k = 4$)	775.451	975.701	44,97%	2,137

Berdasarkan hasil perbandingan pada Tabel 4.3, secara rata-rata metode *Naive* sederhana memberikan kesalahan prediksi terkecil dengan MAE sebesar Rp 519.841,00, disusul oleh model statistik *SARIMA* dan *Mean-7*. Model LSTM Hybrid berada di posisi keempat dengan MAE rata-rata sebesar Rp 667.718,00 dan MASE sebesar 1,840, sedangkan *Seasonal-Naive* ($k = 4$) menempati posisi terakhir dengan MAE sebesar Rp 775.451,00 dan MASE sebesar 2,137. Metode *Seasonal-Naive* ($k = 4$) turut disertakan pada pengujian ini karena metode tersebutlah yang disajikan oleh layanan API produksi, sehingga performanya perlu diukur pada skema yang sama dengan metode lainnya. Hasilnya menunjukkan bahwa pada skema satu langkah ke depan, asumsi musiman mingguan lima hari kerja justru kurang tepat dibandingkan asumsi persistensi harian. Temuan ini mengindikasikan karakteristik data pendapatan kantin EatsTEDI UGM yang didominasi oleh persistensi jangka pendek yang kuat (omzet hari ini sangat dekat dengan omzet kemarin). Karakteristik persistensi ini dapat ditangkap secara sangat efisien oleh model naif, sementara model LSTM Hybrid yang dilatih menggunakan ukuran data yang relatif kecil mengalami *over-smoothing* (penghalusan berlebih) sehingga kurang mampu menangkap lonjakan-lonjakan

pendapatan harian secara presisi. Perlu dicatat bahwa seluruh metode pada Tabel 4.3 – termasuk *Naive* itu sendiri – memiliki nilai MASE lebih besar dari satu (1,432 hingga 1,840). Hal ini terjadi karena MASE dinormalisasi terhadap galat naif satu langkah *in-sample* yang dihitung pada data latih, sehingga nilai $MASE > 1$ pada data uji semata menandakan bahwa periode uji secara umum lebih bergejolak (memiliki variansi/perubahan harian yang lebih besar) dibandingkan periode latih yang menjadi acuan normalisasi, bukan berarti seluruh metode gagal secara mutlak. Oleh karena itu, perbandingan performa yang bermakna secara metodologis pada penelitian ini adalah perbandingan MASE antar metode pada data uji yang identik (lihat kriteria kelayakan relatif pada Subbab 3.6), bukan ambang mutlak $MASE < 1$. Visualisasi perbandingan nominal pendapatan aktual terhadap nilai prediksi dari model LSTM Hybrid disajikan pada Gambar 4.18.



Gambar 4.18 Grafik Pendapatan Aktual vs. Prediksi Model LSTM Hybrid

4.4.2 Skenario 2: Pengujian Stabilitas Model melalui Multi-Seed

Meningkatnya sensitivitas performa model LSTM terhadap inisialisasi bobot acak awal pada data kecil mengharuskan pengujian dilakukan menggunakan pendekatan *multi-seed evaluation* dengan melatih model sebanyak sepuluh kali menggunakan nilai *seed* acak yang berbeda. Prosedur pengujian

diimplementasikan sebagai perulangan pelatihan dengan pengaturan *seed* eksplisit pada seluruh sumber keacakan (Python, NumPy, dan TensorFlow) sebagaimana disajikan pada Kode Program IV.7. Ringkasan statistik hasil pengujian sepuluh *seeds* tersebut disajikan pada Tabel 4.4.

```

1  def set_seed(s):
2      os.environ['PYTHONHASHSEED'] = str(s)
3      random.seed(s); np.random.seed(s); tf.random.set_seed(s)
4
5  rows = []
6  for s in range(N_SEEDS):    # N_SEEDS = 10
7      set_seed(s)
8      cb = [EarlyStopping('val_loss', patience=20,
9                          restore_best_weights=True, verbose=0),
10           ReduceLROnPlateau('val_loss', factor=0.5,
11                              patience=8, min_lr=1e-6,
12                              verbose=0)]
13
14     mdl = build()
15     mdl.fit(X_tr, y_tr, validation_data=(X_va, y_va),
16            epochs=200, batch_size=16, callbacks=cb, verbose=0)
17     # Rekonstruksi log-return prediksi ke nominal Rupiah
18     logret_hat = inv_logret(
19         mdl.predict(X_te, verbose=0).flatten())
20     y_lstm = np.expml(np.loglp(rev_prev) + logret_hat)
21     r = metrics(rev_true, y_lstm); r['seed'] = s
22     rows.append(r)
23

```


```
22 res = pd.DataFrame(rows)    # rata-rata +- deviasi per metrik
```

Kode Program IV.7: Prosedur Evaluasi *Multi-Seed* (10 Kali Pelatihan Ulang)

Tabel 4.4 Statistik Performa LSTM Hybrid pada 10 Seed

Metrik	Rata-rata $\pm$ Simpangan baku	Rentang (min – maks)
MAE (Rp)	667.718 $\pm$ 145.024	495.527 – 1.048.967
RMSE (Rp)	897.563 $\pm$ 165.804	703.721 – 1.320.587
sMAPE	38,06% $\pm$ 3,96%	29,16% – 44,63%
MASE	1,840 $\pm$ 0,400	1,365 – 2,891

Hasil pada Tabel 4.4 menunjukkan nilai simpangan baku (*standard deviation*) yang cukup signifikan (MAE $\pm$ Rp 145.024,00 dan MASE $\pm$ 0,400). Hal ini membuktikan adanya ketidakstabilan performa model LSTM yang disebabkan oleh ukuran data yang terbatas, performa model sangat bergantung pada keberuntungan inisialisasi parameter awal. Selain itu, sebaran data menunjukkan bahwa hanya terdapat 1 dari 10 percobaan (10%) yang berhasil mengungguli performa model pembanding *Naive* dan *SARIMA*, yaitu pada *seed* ke-7 dengan MAE sebesar Rp 495.527,00. Oleh karena itu, pelaporan kinerja model LSTM berdasarkan uji coba tunggal (*single run*) berisiko memberikan kesimpulan yang kurang valid atau menyesatkan. Distribusi nilai MAE dari sepuluh *seeds* tersebut divisualisasikan dalam bentuk *boxplot* pada Gambar 4.19.



Gambar 4.19 Boxplot Distribusi MAE Hasil Pengujian *Multi-Seed*

4.4.3 Skenario 3: Pengujian Augmentasi Data Sintetis TimeGAN

Sebagai upaya mitigasi terhadap keterbatasan ukuran dataset yang menjadi akar penyebab ketidakstabilan model LSTM, hasil implementasi augmentasi data sintetis TimeGAN (lihat Subbab 4.3.3) dievaluasi dengan membandingkan performa model LSTM multi-langkah (*look-back* 14 hari aktif, horizon 7 hari) yang dilatih dalam dua kondisi: hanya menggunakan 199 sekuens data riil (*baseline real-only*), dan menggunakan gabungan data riil dengan 298 sekuens sintetis (rasio augmentasi 1,5). Hasil perbandingan pada data uji disajikan pada Tabel 4.5.

Tabel 4.5 Perbandingan Performa Eksperimen Augmentasi TimeGAN (*Multi-Step*, Horizon 7)

Model	MAE (Rp)	RMSE (Rp)	sMAPE	MASE
Seasonal-Naive ($k = 5$)	755.403	975.130	37,58%	2,082
Seasonal-Naive ($k = 7$)	783.179	985.180	38,24%	2,158
LSTM + Augmentasi TimeGAN	860.695	1.047.842	41,49%	2,372
LSTM Tanpa Augmentasi	1.750.355	1.935.119	115,40%	4,823

Perlu dicatat bahwa nilai galat pada Tabel 4.5 tidak dapat dibandingkan secara langsung dengan Tabel 4.3, karena eksperimen augmentasi ini menggunakan skema prediksi multi-langkah langsung (*direct multi-step*, horizon 7 hari sekaligus) yang secara inheren lebih sulit daripada skema satu langkah ke depan (*one-step-ahead*).

Hasil eksperimen menunjukkan dua temuan penting. Pertama, augmentasi TimeGAN terbukti efektif memperbaiki kualitas pelatihan LSTM pada data terbatas: nilai MAE model turun drastis dari Rp 1.750.355,00 menjadi Rp 860.695,00 (perbaikan sekitar 50,8%), dan nilai MASE membaik dari 4,823 menjadi 2,372. Kedua, meskipun mengalami perbaikan signifikan, model LSTM teraugmentasi tetap belum mampu mengungguli *baseline Seasonal-Naive* ($k = 5$, MAE Rp 755.403,00) yang memanfaatkan pola musiman mingguan secara sederhana. Perlu dicatat bahwa evaluasi multi-langkah ini menguji *Seasonal-Naive* pada konfigurasi $k = 5$ dan $k = 7$, sedangkan layanan produksi memakai $k = 4$ sebagai kompromi responsivitas–stabilitas. Ketiganya menunjukkan karakteristik performa yang serupa karena sama-sama merata-ratakan beberapa kemunculan terakhir hari sejenis. Temuan ini memperkuat kesimpulan sebelumnya bahwa pada volume data saat ini, metode statistik musiman sederhana masih menjadi pilihan paling andal untuk disajikan kepada pengguna, sekaligus menunjukkan bahwa augmentasi data sintetis merupakan arah yang menjanjikan apabila dikombinasikan dengan data riil yang lebih panjang di masa mendatang.

4.4.4 Skenario 4: Pengujian Horizon Prakiraan Rekursif

Skenario keempat menguji perilaku galat prediksi rekursif seiring bertambahnya horizon prakiraan, sekaligus mengukur kontribusi tiga mekanisme pengaman yang telah diimplementasikan pada Subbab 4.3.4, yaitu pembatasan nilai (*clipping*), peredaman (*damping*) dengan $\phi = 0,7$, dan *safety rail*. Pengujian dilakukan dengan membandingkan galat model LSTM rekursif terhadap *baseline Seasonal-Naive* pada horizon $h = 1, 3, 5$, dan 7 hari aktif. Pelaporan difokuskan pada MAE, sMAPE, dan MASE karena ketiganya cukup untuk memperlihatkan pola degradasi galat antarhorizon. Hasil pengukuran disajikan pada Tabel 4.6.

Tabel 4.6 Galat Prediksi Rekursif per Horizon Prakiraan

Horizon	LSTM + TimeGAN			MASE Pembanding		
	MAE (Rp)	sMAPE	MASE	S-Naive $k = 5$	S-Naive $k = 7$	LSTM tanpa aug.
$h = 1$	909.176	41,33%	2,505	2,140	2,274	3,928
$h = 3$	840.691	38,79%	2,317	2,082	2,153	5,017
$h = 5$	890.125	42,49%	2,453	2,041	2,132	5,304
$h = 7$	770.693	41,77%	2,124	2,012	2,033	3,534

Berdasarkan Tabel 4.6, galat model LSTM teraugmentasi tidak menunjukkan degradasi yang tajam seiring bertambahnya horizon. Nilai MASE bergerak pada rentang sempit 2,124 sampai 2,505 tanpa kecenderungan menaik, bahkan galat terendah justru tercatat pada horizon terjauh ($h = 7$) dengan MAE sebesar Rp770.693,00. Pola ini merupakan bukti kuantitatif bekerjanya mekanisme pengaman pada Subbab 4.3.4: peredaman dengan $\phi = 0,7$ menarik prediksi menuju nilai rata-rata seiring bertambahnya langkah, sehingga galat tidak menumpuk secara eksponensial sebagaimana lazim terjadi pada prediksi rekursif

tanpa pengaman.

Efek tersebut terlihat jelas ketika dibandingkan dengan model LSTM tanpa augmentasi pada kolom terakhir. Model tersebut mengalami penurunan kualitas yang nyata di horizon menengah, yaitu MASE meningkat dari 3,928 pada $h = 1$ menjadi 5,304 pada $h = 5$, sebelum kembali turun ke 3,534 pada $h = 7$. Perbandingan ini menegaskan bahwa kestabilan prediksi multi-langkah pada penelitian ini bersumber dari kombinasi augmentasi data dan mekanisme pengaman, bukan dari kemampuan model menangkap dinamika jangka panjang.

Meskipun demikian, kedua *baseline Seasonal-Naive* tetap mencatat MASE lebih rendah pada seluruh horizon, yaitu 2,012 sampai 2,140 untuk $k = 5$ dan 2,033 sampai 2,274 untuk $k = 7$. Dengan kata lain, kestabilan yang dicapai model LSTM belum diikuti keunggulan akurasi. Perlu dicatat pula bahwa peredaman yang menstabilkan galat juga menyebabkan prediksi bersifat *mean-reverting*, sehingga simpangan baku nilai prediksi menyempit pada horizon jauh dan model menjadi kurang responsif terhadap lonjakan pendapatan mendadak.

4.4.5 Rekapitulasi Hasil Keempat Skenario

Rangkuman capaian keempat skenario pengujian model disajikan pada Tabel 4.7. Rekapitulasi ini menunjukkan bahwa pada volume data penelitian, tidak satu pun skenario menghasilkan konfigurasi LSTM yang mengungguli metode pembandingan sederhana, meskipun Skenario 3 membuktikan bahwa penambahan data sintesis memberikan perbaikan galat yang substansial.

Tabel 4.7 Rekapitulasi Hasil Pengujian Keempat Skenario

Skenario	Tujuan Pengujian	Metode Terbaik	Temuan Utama
1	Membandingkan LSTM terhadap <i>baseline</i> statistik pada skema satu langkah ke depan	<i>Naive</i> (kemarin)	<i>Naive</i> mencatat MAE Rp519.841 dan MASE 1,432, lebih baik daripada LSTM Hybrid (MAE Rp667.718; MASE 1,840) maupun <i>Seasonal-Naive</i> $k = 4$ (MAE Rp775.451; MASE 2,137).
2	Menguji kestabilan LSTM melalui sepuluh kali pelatihan dengan <i>seed</i> berbeda	—	Sebaran MAE sangat lebar (Rp495.527–Rp1.048.967; simpangan baku Rp145.024), menandakan model belum stabil pada ukuran data ini.
3	Menguji efektivitas augmentasi data sintetis TimeGAN pada skema multi-langkah	<i>Seasonal-Naive</i> ($k = 5$)	Augmentasi menurunkan MAE LSTM dari Rp1.750.355 menjadi Rp860.695, namun tetap di bawah <i>Seasonal-Naive</i> (MAE Rp755.403).
4	Menguji degradasi galat prediksi rekursif terhadap horizon prakiraan	<i>Seasonal-Naive</i> ($k = 5$)	MASE LSTM teraugmentasi stabil pada 2,124–2,505 tanpa degradasi seiring horizon, namun tetap di atas <i>Seasonal-Naive</i> (2,012–2,140).

4.5 Hasil Pengujian Sistem

Pengujian sistem dilakukan untuk memvalidasi fungsionalitas aplikasi dan memeriksa kebenaran logika internal komponen kritis pada layanan API prediksi yang telah diintegrasikan. Pengujian mengikuti rancangan skenario pada Subbab 3.6, yang mencakup uji fungsional *black box* terhadap kasus penggunaan utama, pengujian mekanisme sinkronisasi *offline-first*, serta uji telusur logika kode *white box* terhadap fungsi kritis pada layanan API prediksi.

4.5.1 Hasil Pengujian Black Box

Pengujian fungsionalitas sistem menggunakan metode Black Box diterapkan pada 14 skenario kasus penggunaan utama yang melibatkan peran Owner dan Kasir. Hasil pengujian diringkas pada Tabel 4.8.

Tabel 4.8 Hasil Pengujian Black Box

No.	Fitur / Skenario	Hasil yang Diharapkan	Hasil Riil	Status
1	Registrasi Toko	Akun owner baru dan data toko berhasil didaftarkan di cloud database.	Sesuai Harapan	Berhasil
2	Login Pengguna	Masuk ke dasbor utama sesuai hak akses peran (Owner/Kasir).	Sesuai Harapan	Berhasil
3	Checkout Belanja	Transaksi tersimpan, stok barang berkurang otomatis di lokal.	Sesuai Harapan	Berhasil
4	Terapkan Diskon	Total belanja terpotong sesuai nilai nominal diskon/voucher.	Sesuai Harapan	Berhasil
5	Cetak Struk Fisik	Printer thermal mencetak detail nota transaksi via Bluetooth.	Sesuai Harapan	Berhasil

No.	Fitur / Skenario	Hasil yang Diharapkan	Hasil Riil	Status
6	Kelola Produk	Menambah, mengedit, dan menghapus katalog produk di basis data.	Sesuai Harapan	Berhasil
7	Kelola Kategori	Mengatur kategori produk untuk pengelompokan menu kasir.	Sesuai Harapan	Berhasil
8	Audit Mutasi Stok	Riwayat keluar masuk barang tercatat di log stock_history.	Sesuai Harapan	Berhasil
9	Dasbor Ringkasan	Menampilkan ringkasan omzet dan grafik penjualan aktual.	Sesuai Harapan	Berhasil
10	Smart Analytics	Grafik prediksi LSTM untuk 7 hari ke depan dapat ditampilkan.	Sesuai Harapan	Berhasil
11	Broadcast Notif	Pengiriman notifikasi broadcast dari owner muncul di layar kasir.	Sesuai Harapan	Berhasil
12	Sinkronisasi Data	Data transaksi offline terunggah otomatis ke cloud saat online.	Sesuai Harapan	Berhasil
13	Kelola Staf Karyawan	Owner dapat menambah dan mengatur peran staf kasir.	Sesuai Harapan	Berhasil
14	Atur Profil Toko	Informasi nama, alamat, dan logo toko berhasil diubah.	Sesuai Harapan	Berhasil

Berdasarkan hasil uji coba pada Tabel 4.8, seluruh fungsi utama aplikasi POS mobile dan server-side API berjalan dengan status sukses ("Berhasil"), membuktikan kelayakan operasional sistem untuk penggunaan harian.

4.5.2 Hasil Pengujian Mekanisme Sinkronisasi Offline-First

Sebagai bagian dari skenario #12 (Sinkronisasi Data), pengujian fitur *offline-first* dilakukan lebih rinci untuk memastikan keandalan penyimpanan lokal menggunakan Isar DB ketika koneksi internet terputus dan proses sinkronisasi otomatis ketika koneksi terhubung kembali. Rincian skenario pengujian sinkronisasi tersebut dijabarkan pada Tabel 4.9.

Tabel 4.9 Hasil Pengujian Mekanisme Sinkronisasi

No	Skenario Pengujian	Hasil Pengujian	Status
1	Melakukan transaksi checkout saat jaringan terputus (Luring).	Transaksi tersimpan di Isar DB lokal dengan status <i>is_synced = false</i> (penanda yang sama dinamai <i>isSynced</i> pada lapisan kode Dart, mengikuti konvensi penamaan masing-masing platform). Stok produk berkurang di lokal.	Berhasil
2	Membuka riwayat transaksi kasir saat luring.	Menampilkan daftar transaksi lokal secara instan tanpa memicu error atau halaman kosong.	Berhasil
3	Menghubungkan perangkat kembali ke internet (Daring).	Mesin <i>SyncNotifier</i> mendeteksi koneksi dan mengunggah data transaksi ke Supabase.	Berhasil
4	Memeriksa status database cloud setelah sinkronisasi.	Data transaksi masuk ke Supabase, dan status di lokal berubah menjadi <i>is_synced = true</i> .	Berhasil

Hasil uji coba membuktikan bahwa arsitektur offline-first menjamin

operasional POS kasir tetap berjalan tanpa kendala saat konektivitas internet tidak stabil, serta menjaga konsistensi data transaksi saat online kembali.

4.5.3 Hasil Pengujian White Box

Pengujian *white box* dilakukan dengan menelusuri jalur logika (*code path*) dari tiga fungsi kritis pada layanan API prediksi menggunakan data masukan yang telah diketahui nilai keluarannya secara manual, kemudian membandingkan hasil eksekusi aktual terhadap hasil kalkulasi *ground truth*. Ringkasan hasil penelusuran jalur logika disajikan pada Tabel 4.10.

Tabel 4.10 Hasil Pengujian White Box

No	Fungsi / Jalur Logika	Kondisi Uji	Hasil yang Diharapkan	Status
1	<i>by_dow</i> (Seasonal-Naive)	Data historis hari kerja tersedia $\geq k$ (jalur utama)	Nilai prediksi merupakan rata-rata k kemunculan terakhir hari kerja yang sama	Berhasil
2	<i>by_dow</i> (Seasonal-Naive)	Data historis hari kerja tersedia $< k$ (jalur cabang <i>partial</i>)	Nilai prediksi merupakan rata-rata dari seluruh data hari kerja yang tersedia	Berhasil
3	<i>by_dow</i> (Seasonal-Naive)	Data historis hari kerja tidak tersedia sama sekali (jalur <i>fallback</i>)	Nilai prediksi menggunakan rata-rata 10 hari aktif terakhir keseluruhan	Berhasil
4	<i>smape</i>	Nilai aktual dan prediksi sama-sama bernilai 0 (jalur penyebut nol)	Fungsi tidak menghasilkan galat pembagian dengan nol (<i>division by zero</i>)	Berhasil
5	<i>mase</i>	Galat naif <i>in-sample</i> bernilai positif normal (jalur utama)	Nilai MASE terhitung sesuai rasio MAE model terhadap MAE naif	Berhasil
6	<i>forecast_hybrid_stable</i>	Nilai <i>log-return</i> mentah melebihi persentil 90 data latih (jalur <i>clipping</i>)	Nilai <i>log-return</i> dipotong tepat pada batas atas persentil 90	Berhasil
7	<i>forecast_hybrid_stable</i>	Iterasi horizon ke- n dengan $n > 1$ (jalur <i>damping</i>)	Besaran perubahan <i>log-return</i> teredam sesuai faktor $\phi^{(n-1)}$	Berhasil
8	<i>forecast_hybrid_stable</i>	Nilai omzet hasil rekonstruksi melampaui nilai maksimum historis (jalur <i>safety rail</i>)	Nilai omzet dipotong tepat pada batas <i>REV_CEIL</i>	Berhasil

Berdasarkan hasil pada Tabel 4.10, seluruh jalur logika kritis pada ketiga fungsi yang diuji, yaitu perhitungan *Seasonal-Naive*, metrik evaluasi sMAPE/MASE, dan prediksi rekursif, telah tervalidasi menghasilkan keluaran yang sesuai dengan perhitungan manual, sehingga tidak ditemukan kesalahan logika (*logic error*) pada percabangan kode yang diuji.

4.6 Pembahasan Hasil Penelitian

Bagian ini membahas temuan hasil implementasi, kontribusi fitur offline-first terhadap kelancaran operasional kasir, serta kemampuan analitik prediksi LSTM dalam meminimalkan masalah persediaan barang.

4.6.1 Analisis Dominasi Persistensi Jangka Pendek pada Data Kantin Institusional

Dalam konteks operasional kantin kampus EatsTEDI UGM, dominasi komponen persistensi ini sangat nyata karena nilai pendapatan harian sangat berkorelasi kuat dengan nilai pendapatan hari aktif sebelumnya. Pola ketergantungan jangka pendek ini ditangkap dengan sangat presisi oleh model *Naive* (kemarin) yang memiliki kesalahan MAE terendah sebesar Rp 519.841,00.

4.6.2 Analisis Kegagalan LSTM Mengungguli Baseline: Over-Smoothing pada Data Pendek

Secara keseluruhan, hasil pengujian menunjukkan bahwa pada dataset transaksi penjualan kantin EatsTEDI UGM dengan 313 hari aktif, model LSTM,

termasuk varian hybrid residual yang merupakan konfigurasi terbaik, tidak mengungguli metode pembandingan sederhana (*Naive* dan *Mean-7*) maupun model statistik *SARIMA* secara rata-rata, dan hanya mampu kompetitif pada kasus terbaiknya (1 dari 10 percobaan *multi-seed*). Hasil evaluasi ini bukan merupakan suatu kegagalan atau anomali sistem, melainkan sejalan dengan temuan luas dalam berbagai literatur prediksi deret waktu komersial ritel (seperti pada kompetisi prediksi global M3 dan M4). Literatur tersebut membuktikan bahwa metode statistik klasik dan naif kerap mengungguli pendekatan pembelajaran mendalam (*deep learning*) ketika data historis yang tersedia relatif terbatas dan deret waktu didominasi secara kuat oleh komponen persistensi jangka pendek.

Di sisi lain, model LSTM Hybrid yang memiliki kapasitas parameter lebih besar cenderung melakukan penghalusan nilai prediksi secara berlebihan (*over-smoothing*) pada data latih yang pendek, sehingga tidak mampu menangkap lonjakan-lonjakan ekstrem omzet harian yang dipicu oleh dinamika aktivitas mahasiswa di lapangan.

4.6.3 Analisis Ketidakstabilan Model akibat Keterbatasan Volume Data

Pengujian multi-seed pada Skenario 2 memperlihatkan bahwa ketidakunggulan LSTM tidak hanya bersifat rata-rata, tetapi juga disertai ketidakstabilan yang tinggi. Nilai MAE dari sepuluh kali pelatihan tersebar pada rentang Rp495.527 sampai Rp1.048.967 dengan simpangan baku Rp145.024, sehingga galat percobaan terburuk lebih dari dua kali lipat galat percobaan terbaik. Sebaran yang lebar ini merupakan gejala khas pelatihan jaringan saraf pada data

berukuran kecil, yaitu proses optimasi sangat peka terhadap inisialisasi bobot acak karena jumlah sekuens latih tidak cukup untuk menuntun model menuju solusi yang konsisten. Implikasinya, pelaporan performa berdasarkan satu kali pelatihan saja berpotensi menyesatkan, baik karena kebetulan memperoleh hasil terbaik maupun terburuk. Hal inilah yang mendasari penggunaan sebaran nilai, bukan nilai tunggal, sebagai dasar penarikan kesimpulan pada penelitian ini.

4.6.4 Analisis Kontribusi dan Batas Efektivitas Augmentasi TimeGAN

Sebagai upaya mengatasi akar permasalahan keterbatasan data tersebut, penelitian ini turut menguji peran augmentasi data sintetis menggunakan TimeGAN. Hasil eksperimen menunjukkan bahwa penambahan sekuens sintetis mampu memperbaiki kualitas pembelajaran model LSTM secara substansial (penurunan MAE sekitar 50,8% dibandingkan model tanpa augmentasi pada skema multi-langkah), yang menandakan bahwa kegagalan LSTM pada penelitian ini memang bersumber dari kelangkaan data, bukan dari kesalahan arsitektur semata. Namun demikian, model LSTM teraugmentasi tetap belum melampaui *baseline Seasonal-Naive*, sehingga augmentasi sintetis diposisikan sebagai pelengkap yang menjanjikan, bukan pengganti, dari akumulasi data transaksi riil jangka panjang.

4.6.5 Analisis Interpretasi Nilai MASE Lebih dari Satu

Seluruh metode yang diuji pada Skenario 1 menghasilkan nilai MASE lebih besar dari satu, berkisar antara 1,432 untuk *Naive* sampai 1,840 untuk LSTM

Hybrid. Secara harfiah, nilai tersebut berarti galat seluruh metode pada data uji lebih besar daripada galat prediksi naif *in-sample* yang menjadi penyebutnya. Kondisi ini tidak menandakan kesalahan perhitungan, melainkan mencerminkan bahwa periode data uji memiliki fluktuasi pendapatan harian yang lebih tinggi dibandingkan periode data latih, sehingga acuan normalisasi yang dihitung dari data latih menjadi relatif rendah. Oleh karena itu, MASE pada penelitian ini lebih tepat dibaca sebagai ukuran pembandingan relatif antarmetode daripada sebagai ambang kelayakan absolut. Dibaca dengan cara tersebut, urutan MASE tetap konsisten dengan urutan MAE dan RMSE, yaitu *Naive* paling baik dan LSTM Hybrid paling lemah, sehingga kesimpulan perbandingan antarmetode tidak berubah.

4.6.6 Analisis Keputusan Metode Penyaji pada Layanan Produksi

Kerangka evaluasi ini menghasilkan kesimpulan analisis yang jujur, objektif, dan dapat dipertanggungjawabkan secara akademik, sekaligus memberikan rekomendasi praktis bagi pengelola bisnis: untuk skala volume data transaksi harian UMKM saat ini, metode *Naive*, *Seasonal-Naive*, atau *SARIMA* lebih direkomendasikan untuk diintegrasikan sebagai fitur visualisasi dasbor prediksi penjualan harian pada aplikasi POS, sedangkan penerapan algoritma LSTM baru relevan untuk ditinjau kembali di masa depan apabila volume data transaksi historis telah bertambah secara signifikan (mencakup minimal 3–5 tahun operasional). Rekomendasi tersebut telah diimplementasikan secara nyata pada penelitian ini: layanan API prediksi produksi yang terhubung ke aplikasi POS

menyajikan metode *Seasonal-Naive* ($k = 4$) untuk prediksi harian, *Mean-4* untuk mingguan, dan *Mean-3* untuk bulanan, sementara model LSTM beserta hasil eksperimen augmentasi TimeGAN didokumentasikan sebagai artefak riset yang siap diaktifkan kembali ketika data telah memadai. Perlu dicatat secara terbuka bahwa hasil pengujian pada Tabel 4.3 menunjukkan *Seasonal-Naive* ($k = 4$) belum merupakan pilihan optimal untuk prediksi satu hari ke depan, karena metode *Naive* mencatat galat yang lebih rendah. Pemilihan *Seasonal-Naive* pada layanan produksi didasari pertimbangan keterbacaan pola mingguan bagi pengguna, sehingga penyesuaian metode penyaji menjadi *Naive* merupakan perbaikan yang dapat dilakukan secara langsung tanpa mengubah arsitektur layanan yang bersifat *model-agnostic*.

Perlu ditegaskan di awal bahwa bab ini memaparkan dua hal yang berbeda namun saling terkait: (1) hasil eksperimen dan evaluasi metode LSTM sebagai objek kajian utama penelitian (Subbab 4.2 s.d. 4.4), dan (2) metode yang benar-benar disajikan oleh layanan API produksi (*endpoint* `/api/predict/daily`) yang dipanggil aplikasi *mobile* (Subbab 4.1.3 dan 4.5). Berdasarkan hasil evaluasi komparatif pada Subbab 4.4, LSTM belum terbukti unggul dibandingkan *baseline* statistik pada volume data penelitian ini, sehingga layanan produksi menerapkan *fallback* berbasis bukti berupa metode *Seasonal-Naive* ($k = 4$), sedangkan model LSTM (`.keras`) tetap didokumentasikan sebagai artefak riset. Arsitektur layanan prediksi bersifat *model-agnostic* sehingga dapat langsung menyajikan model LSTM begitu data

mencukupi untuk mengungguli *baseline*. Selain itu, granularitas mingguan dan bulanan yang disebutkan pada Subbab 4.1.3 merupakan fitur pelengkap visualisasi pada antarmuka *Smart Analytics* dan berada di luar lingkup evaluasi ilmiah pada bab ini, yang berfokus pada granularitas harian sesuai Batasan Masalah.

4.6.7 Pembahasan Kelayakan Fungsional dan Kontribusi Arsitektur Offline-First

Hasil pengujian Black Box pada 14 skenario menunjukkan tingkat kesuksesan 100% ("Berhasil"). Integrasi antara basis data lokal Isar DB dan basis data cloud Supabase terbukti sangat andal. Melalui skema sinkronisasi yang dirancang, kasir tidak perlu bergantung pada koneksi internet saat menginput transaksi. Hal ini menghilangkan risiko terhambatnya antrean kasir akibat koneksi internet yang lambat atau terputus secara tiba-tiba.

Penggunaan local database Isar DB juga memberikan performa loading data yang sangat cepat. Secara observasi, operasi baca-tulis produk dan transaksi lokal terasa hampir seketika (*near-instant*) dan jauh lebih responsif dibandingkan operasi yang bergantung pada pemanggilan REST API database cloud secara langsung, yang turut dipengaruhi oleh kondisi dan latensi jaringan. Hal ini meningkatkan efisiensi kerja kasir secara signifikan. Perlu dicatat bahwa perbandingan ini bersifat observasi kualitatif, bukan hasil pengukuran latensi terstruktur (mis. jumlah sampel, alat ukur, dan kondisi jaringan yang terkendali), sehingga angka waktu tempuh kuantitatif belum dapat dilaporkan pada penelitian ini.

4.6.8 Posisi Temuan terhadap Penelitian Terdahulu

Sebagian besar penelitian terdahulu yang ditinjau pada Subbab 2.1 melaporkan keunggulan LSTM atau variannya dibandingkan metode pembanding. Perbedaan hasil dengan penelitian ini tidak terletak pada implementasi arsitektur, melainkan pada karakteristik data yang dimodelkan. Penelitian-penelitian tersebut umumnya menggunakan deret waktu dengan cakupan historis bertahun-tahun serta pola musiman yang telah berulang beberapa siklus penuh, sehingga jaringan saraf memperoleh cukup contoh untuk mempelajari struktur temporal yang berulang. Sebaliknya, data penelitian ini hanya mencakup 313 hari aktif, belum genap dua siklus tahun akademik, dan didominasi komponen persistensi jangka pendek yang justru paling efisien ditangkap oleh metode naif.

Dengan demikian, temuan bahwa LSTM belum mengungguli *baseline* pada penelitian ini tidak bertentangan dengan literatur, melainkan melengkapinya dengan menandai batas bawah volume data yang diperlukan agar pendekatan pembelajaran mendalam memberikan nilai tambah pada konteks UMKM. Kontribusi tersebut ditopang oleh ketelitian metodologis evaluasi yang diterapkan, yaitu:

1. **Penggunaan Model Pembanding (*Baselines*) yang Tepat:** Menyandingkan model LSTM dengan metode naif, rata-rata bergerak, dan SARIMA untuk memvalidasi apakah penambahan kompleksitas komputasi model AI memberikan nilai tambah akurasi prediksi yang sepadan.
2. **Pemilihan Metrik Evaluasi yang Valid:** Menggunakan sMAPE dan MASE

yang tahan terhadap pembagian bernilai nol atau sangat kecil pada hari-hari libur, menghindari kesalahan *exploding MAPE* yang menyesatkan.

3. **Pengujian Kestabilan melalui Multi-Seed:** Melaporkan sebaran nilai performa model dari sepuluh kali pelatihan secara acak, sehingga mengungkap ketidakstabilan model LSTM pada ukuran data yang kecil secara transparan.
4. **Eksplorasi Augmentasi Data Sintetis:** Menguji efektivitas TimeGAN sebagai strategi mitigasi keterbatasan data pada prediksi penjualan UMKM, lengkap dengan kuantifikasi perbaikan galat terhadap model tanpa augmentasi dan posisinya relatif terhadap *baseline* musiman.

4.7 Keterbatasan Sistem dan Penelitian

Meskipun sistem POS mobile dengan fitur prediksi penjualan harian ini telah berhasil diimplementasikan dan diuji, terdapat beberapa keterbatasan operasional maupun metodologi penelitian yang harus diperhatikan.

4.7.1 Keterbatasan Sistem POS

Beberapa keterbatasan operasional dari sistem POS mobile yang dikembangkan meliputi:

1. **Keterbatasan Cold Start pada Toko Baru:** Model prediksi LSTM memerlukan data transaksi historis runtun waktu yang kontinu. Sebagaimana dijelaskan pada Subbab 3.1.6, model secara teknis membutuhkan minimal 7 hari aktif transaksi (panjang *sequence LOOK_BACK*) agar dapat dijalankan

sama sekali, namun hasil proyeksi baru dianggap cukup andal untuk ditampilkan tanpa peringatan *cold start* setelah data transaksi terkumpul minimal selama 30 hari sebagai periode pemanasan awal (*warm-up period*).

2. **Ketergantungan Data Terkini:** Meskipun operasional transaksi kasir dapat berjalan tanpa internet (offline), kualitas proyeksi modul prediksi LSTM bergantung pada kelengkapan data transaksi aktual yang menjadi *payload* permintaan analisis. Jika data transaksi terbaru belum tercatat atau tersinkronkan, akurasi hasil proyeksi prediksi untuk hari berikutnya dapat menurun karena tidak menangkap tren transaksi paling akhir.
3. **Ketergantungan Akses Server untuk Hasil Prediksi:** Karena keterbatasan sumber daya komputasi dan konsumsi baterai perangkat mobile, proses kalkulasi prediksi model LSTM yang berat dialihkan sepenuhnya ke layanan inferensi Python yang di-*hosting* pada platform Hugging Face. Akibatnya, meskipun kasir dapat bertransaksi secara offline, pengguna tetap memerlukan koneksi internet aktif untuk memperbarui visualisasi prediksi analitik terbaru dari API inferensi ke dasbor aplikasi. Selain itu, layanan inferensi gratis pada Hugging Face dapat mengalami kondisi *cold start* (jeda pemuatan saat *server* baru aktif kembali dari *idle*) yang memperlambat respons analisis pertama.

4.7.2 Keterbatasan Penelitian Model Prediksi

Keterbatasan utama dalam pemodelan prediksi pada penelitian ini meliputi:

1. **Keterbatasan Volume Dataset:** Jumlah data transaksi aktif riil dari

platform EatsTEDI UGM relatif sedikit untuk standar pemodelan pembelajaran mendalam (*deep learning*), yakni hanya 313 hari aktif yang menyusut menjadi sekitar 212 sampel latih setelah pembentukan sequence. Keterbatasan ini berdampak langsung pada tingginya sensitivitas model terhadap inisialisasi bobot acak awal (*seed variance*) yang memicu ketidakstabilan akurasi model.

2. **Keterbatasan Pengamatan Pola Musiman Jangka Panjang:** Rentang waktu transaksi yang kurang dari dua tahun belum memungkinkan model LSTM untuk mempelajari pola musiman tahunan (*annual seasonality*) secara utuh dan komprehensif.
3. **Deret Waktu yang Terputus-putus:** Banyaknya hari non-aktif transaksi akibat libur kalender akademik kampus (seperti sepanjang bulan Januari dan Juli) serta akhir pekan menyebabkan deret waktu menjadi patah dan terputus-putus, yang menyulitkan jaringan saraf dalam mempelajari dependensi keterkaitan temporal jangka panjang secara kontinu.
4. **Bias Penyaringan Hari Aktif ($\text{revenue} > 0$):** Penyaringan data pada tahap *preprocessing* hanya mempertahankan hari kerja yang memiliki pendapatan positif ($\text{revenue} > 0$), sebagaimana dijelaskan pada Subbab 3.1.7. Konsekuensinya, hari kerja aktif dengan penjualan nol yang sebenarnya nyata turut terbuang dari dataset, bukan hanya akhir pekan atau libur kalender akademik. Akibat lanjutannya, deret *log-return* r_t yang menjadi target model dihitung antar hari aktif berurutan yang jarak kalender

riilnya tidak seragam – dapat berupa 1 hari, namun juga dapat mencapai lebih dari 10 hari setelah masa libur panjang. Ketidakseragaman interval waktu ini melanggar sebagian asumsi keteraturan deret waktu (*regular time-series*) yang mendasari arsitektur LSTM, dan diduga turut menjadi salah satu faktor yang memperberat kesulitan model dalam mempelajari pola dependensi temporal secara konsisten.

BAB V

PENUTUP

Bab ini menyajikan kesimpulan dari hasil perancangan, implementasi, dan pengujian sistem Point of Sale (POS) mobile dengan fitur prediksi penjualan harian menggunakan metode Long Short-Term Memory (LSTM) dan arsitektur offline-first, serta saran-saran untuk pengembangan sistem lebih lanjut di masa mendatang.

5.1 Kesimpulan

Berdasarkan hasil analisis, perancangan, implementasi, dan pengujian yang telah dilakukan pada penelitian ini, maka dapat ditarik beberapa kesimpulan sebagai berikut:

1. Penelitian ini telah berhasil membangun aplikasi *Point of Sale (POS) mobile* berbasis Flutter yang terintegrasi dengan basis data cloud Supabase PostgreSQL dan layanan API prediksi penjualan harian berbasis Python dan Flask. Modul riset LSTM berbasis TensorFlow/Keras dikembangkan dan didokumentasikan secara lengkap sebagai artefak penelitian, sedangkan layanan API produksi yang benar-benar dipanggil aplikasi menyajikan metode *Seasonal-Naive* berdasarkan hasil evaluasi komparatif, melalui arsitektur *prediction service* yang bersifat *model-agnostic* dan siap menyajikan model `.keras` begitu data mencukupi.
2. Penerapan arsitektur *offline-first* menggunakan basis data lokal Isar DB terbukti handal dalam menjaga keberlangsungan transaksi kasir tanpa

ketergantungan penuh pada koneksi internet. Secara observasi, operasi baca-tulis lokal terasa jauh lebih responsif dibandingkan operasi yang bergantung pada jaringan (belum diukur secara kuantitatif dan terstruktur), dan sinkronisasi otomatis menggunakan modul *SyncNotifier* berhasil mengunggah data transaksi lokal ke database cloud saat perangkat terhubung kembali ke internet.

3. Implementasi metode prediksi *Long Short-Term Memory* (LSTM) dengan pendekatan *hybrid residual* (memprediksi *log-return*) pada dataset harian aktif menghasilkan rata-rata kesalahan prediksi (*multi-seed evaluation*) berupa MAE sebesar Rp 667.718,00 $\pm$ Rp 145.024,00, RMSE sebesar Rp 897.563,00 $\pm$ Rp 165.804,00, sMAPE sebesar 38,06% $\pm$ 3,96%, dan MASE sebesar 1,840 $\pm$ 0,400. Hasil ini menunjukkan bahwa model LSTM Hybrid yang dikembangkan belum mampu mengungguli metode pembandingan *Naive* (MAE Rp 519.841,00, MASE 1,432) dan *SARIMA* secara rata-rata, dikarenakan deret pendapatan yang pendek serta tingginya persistensi jangka pendek pada data penjualan kantin EatsTEDI UGM. Upaya augmentasi data sintetis menggunakan TimeGAN terbukti menurunkan galat model LSTM multi-langkah secara signifikan (MAE membaik dari Rp 1.750.355,00 menjadi Rp 860.695,00), namun tetap belum mengungguli *baseline Seasonal-Naive*, sehingga layanan API prediksi produksi menyajikan metode *Seasonal-Naive* sebagai metode penyaji utama.
4. Hasil pengujian fungsionalitas menggunakan metode *Black Box Testing*

terhadap 14 skenario kasus penggunaan utama yang melibatkan peran Owner dan Kasir berjalan dengan sukses tanpa kegagalan (tingkat keberhasilan 100%), menunjukkan sistem layak dioperasikan secara penuh pada unit usaha UMKM.

5.2 Saran

Berdasarkan keterbatasan sistem yang diidentifikasi selama proses pengembangan dan pengujian, berikut adalah beberapa saran konstruktif untuk pengembangan sistem lebih lanjut:

1. **Penerapan Metode Prediksi Hybrid:** Untuk meningkatkan akurasi proyeksi penjualan pada data yang memiliki volatilitas tinggi atau tren musiman yang sangat dinamis, disarankan untuk menggabungkan model LSTM dengan model *Gated Recurrent Unit* (GRU) atau model statistik klasik ARIMA menjadi model *hybrid* (seperti ARIMA-LSTM atau LSTM-GRU).
2. **Mengatasi Masalah Cold Start:** Untuk memfasilitasi toko baru yang belum memiliki riwayat transaksi selama 30 hari, disarankan mengimplementasikan teknik *transfer learning* atau melatih model *global* awal menggunakan data transaksi historis dari toko sejenis sebelum melatih model secara spesifik menggunakan data toko tersebut.
3. **Penguatan Keamanan Data Lokal:** Guna melindungi data transaksi sensitif pelaku UMKM yang disimpan secara lokal pada perangkat fisik,

disarankan untuk mengaktifkan fitur enkripsi basis data lokal pada Isar DB dengan menggunakan kunci enkripsi dinamis yang dikelola secara aman oleh perangkat.

4. **Penyediaan Skalabilitas Tinggi (High Availability):** Untuk menghadapi potensi ekspansi multi-outlet dengan ribuan kasir aktif, arsitektur modul AI berbasis Flask disarankan dimigrasikan ke infrastruktur cloud dengan konfigurasi *load balancer*, *Docker container clusters*, dan replikasi basis data Supabase PostgreSQL untuk meminimalisasi *single point of failure*.
5. **Notifikasi Multi-Kanal Otomatis:** Mengembangkan fitur integrasi notifikasi dengan layanan pihak ketiga seperti WhatsApp API atau SMS Gateway untuk mengirimkan laporan ringkasan omzet harian secara langsung ke nomor WhatsApp Owner, serta memberikan peringatan dini jika terdapat stok produk tertentu yang berada di bawah ambang batas minimum (*safety stock*).
6. **Integrasi Sistem Pembayaran Digital (E-Wallet & QRIS Dynamic):** Menambahkan integrasi langsung dengan penyedia gerbang pembayaran (*payment gateway*) lokal untuk menghasilkan kode QRIS dinamis secara real-time pada layar transaksi kasir, sehingga mempermudah pembukuan dan meminimalkan kesalahan input nominal transaksi nontunai oleh kasir.
7. **Penambahan Fitur `gap_days` pada Variabel Masukan Model:** Untuk mengurangi dampak ketidakseragaman interval waktu antar hari aktif akibat penyaringan `revenue > 0` (lihat Subbab 4.7.2), disarankan menyertakan

fitur `gap_days` (jarak hari kalender terhadap hari aktif sebelumnya) sebagai variabel masukan tambahan pada model prediksi, sehingga model dapat mempelajari secara eksplisit pengaruh jeda waktu antar observasi terhadap besaran perubahan pendapatan.

DAFTAR PUSTAKA

- [1] S. Mansur, K. Sattar, S. E. Hosseini, S. Pervez, I. Ahmad, K. Saleem, and A. Z. Elhendi, "Sales Forecasting for Retail Stores Using Hybrid Neural Networks and Sales-Affecting Variables," *PeerJ Computer Science*, vol. 11, e3058, 2025, doi: 10.7717/peerj-cs.3058.
- [2] S. Hochreiter and J. Schmidhuber, "Long Short-Term Memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.
- [3] M. Mitra, S. Roy, S. De, S. Bhattacharyya, J. Platos, and V. Snasel, "Harnessing LSTM Neural Networks and Hyperparameter Optimization for Precise Sales Forecasting in Retail," in *Proc. 10th International Conference on Advanced Intelligent Systems and Informatics (AISIS 2024)*, Lecture Notes on Data Engineering and Communications Technologies, vol. 220. Cham, Switzerland: Springer, 2024, doi: 10.1007/978-3-031-71619-5_11.
- [4] T. de Castro Moraes, X.-M. Yuan, and E. P. Chew, "Hybrid Convolutional Long Short-Term Memory Models for Sales Forecasting in Retail," *Journal of Forecasting*, vol. 43, no. 5, pp. 1278–1293, 2024, doi: 10.1002/for.3073.
- [5] "Financial Time Series Augmentation Using Transformer Based GAN Architecture," *arXiv preprint arXiv:2602.17865*, 2026. [*Preprint*, belum melalui *peer-review*].
- [6] J. Yoon, D. Jarrett, and M. van der Schaar, "Time-series Generative Adversarial Networks," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 32, pp. 5508–5518, 2019.
- [7] P. Tang, Z. Li, X. Wang, X. Liu, and P. Mou, "Time Series Data Augmentation for Energy Consumption Data Based on Improved TimeGAN," *Sensors*, vol. 25, no. 2, 2025, doi: 10.3390/s25020493.
- [8] A.-A. Semenoglou, E. Spiliotis, and V. Assimakopoulos, "Data Augmentation for Univariate Time Series Forecasting with Neural Networks," *Pattern Recognition*, vol. 134, art. no. 109132, 2023, doi: 10.1016/j.patcog.2022.109132.
- [9] S. Makridakis, E. Spiliotis, and V. Assimakopoulos, "The M5 Competition: Background, Organization, and Implementation," *International Journal of Forecasting*, vol. 38, no. 4, pp. 1325–1336, 2022, doi: 10.1016/j.ijforecast.2021.07.007.
- [10] P. Yadav and C. R. Barde, "Retail Real-Time Sales Prediction System Using LSTM and XGBoost," *International Journal of Advanced Research in Computer and Communication Engineering (IJARCCE)*, vol. 14, no. 4, 2025.

- [11] R. A. Sembiring and Y. Sary, “Analisa dan Implementasi *Long Short-Term Memory* (LSTM) dalam Kebutuhan Persediaan Barang di PT. Gunung Sari Indonesia,” *Jurnal Ilmiah Teknik Mesin, Elektro dan Komputer*, 2025.
- [12] U. M. Jannah dkk., “Analisis Prediksi Penjualan Isi Ulang Air Galon Menggunakan Metode LSTM dan SARIMA,” *Jurnal Teknologi Informasi dan Multimedia*, 2025.
- [13] R. Verdiyanto, D. Hartanti, and E. Purwanto, “Pengembangan Aplikasi *Point of Sales* untuk Prediksi Penjualan Harian Usaha Minuman Menggunakan Algoritma *Random Forest Regression*,” *Infotek: Jurnal Informatika dan Teknologi*, vol. 8, no. 2, 2025.
- [14] E. M. Sipayung, C. Fiarni, and Wawan, “Evaluasi Penggunaan Aplikasi *Point of Sale* Menggunakan *Technology Acceptance Model* pada UMKM,” *Jurnal Nasional Teknik Elektro dan Teknologi Informasi (JNTETI)*, vol. 9, no. 1, pp. 18–24, 2020, doi: 10.22146/jnteti.v9i1.116.
- [15] M. Siddik and S. Samsir, “Rancang Bangun Sistem Informasi POS (*Point of Sale*) untuk Kasir Menggunakan Konsep Bahasa Pemrograman Orientasi Objek,” *JOISIE (Journal of Information Systems and Informatics Engineering)*, vol. 4, no. 1, p. 43, 2020, doi: 10.35145/joisie.v4i1.607.
- [16] R. J. Hyndman and G. Athanasopoulos, *Forecasting: Principles and Practice*, 3rd ed. Melbourne, Australia: OTexts, 2021.
- [17] G. E. P. Box, G. M. Jenkins, G. C. Reinsel, and G. M. Ljung, *Time Series Analysis: Forecasting and Control*, 5th ed. Hoboken, NJ, USA: John Wiley & Sons, 2015.
- [18] R. J. Hyndman and A. B. Koehler, “Another Look at Measures of Forecast Accuracy,” *International Journal of Forecasting*, vol. 22, no. 4, pp. 679–688, 2006.
- [19] I. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, and Y. Bengio, “Generative Adversarial Nets,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 27, pp. 2672–2680, 2014.
- [20] Google LLC, “Flutter Documentation,” 2026. [Daring]. Tersedia: <https://docs.flutter.dev/> [Diakses: 29 Juli 2026].
- [21] R. S. Pressman and B. R. Maxim, *Software Engineering: A Practitioner’s Approach*, 9th ed. New York, NY, USA: McGraw-Hill Education, 2020.
- [22] G. J. Myers, C. Sandler, and T. Badgett, *The Art of Software Testing*, 3rd ed. Hoboken, NJ, USA: John Wiley & Sons, 2011.
- [23] ISO/IEC/IEEE 29119-4:2021, *Software and Systems Engineering — Software*

Testing — Part 4: Test Techniques, International Organization for Standardization, Geneva, Switzerland, 2021.

LAMPIRAN

LEMBAR KONSULTASI PEMBIMBING I
LEMBAR KONSULTASI SKRIPSI
JURUSAN TEKNOLOGI INFORMASI DAN KOMPUTER
PROGRAM STUDI TEKNIK INFORMATIKA

Nama : Muhammad Kholis
NIM : 2022573010098
Judul TA : Rancang Bangun Aplikasi *Point of Sale* dengan
Fitur Prediksi Penjualan Harian Menggunakan
Metode *Long Short-Term Memory* (LSTM)
Pembimbing I : Zulfan Khairil Simbolon, S.T., M.Eng.
NIP : 196909021993031004

No.	Tanggal	Hasil Konsultasi	Paraf Pembimbing

LEMBAR KONSULTASI PEMBIMBING II
LEMBAR KONSULTASI SKRIPSI
JURUSAN TEKNOLOGI INFORMASI DAN KOMPUTER
PROGRAM STUDI TEKNIK INFORMATIKA

Nama : Muhammad Kholis
NIM : 2022573010098
Judul TA : Rancang Bangun Aplikasi *Point of Sale* dengan
Fitur Prediksi Penjualan Harian Menggunakan
Metode *Long Short-Term Memory* (LSTM)
Pembimbing II : Azhar, S.T., M.T.
NIP : 196408301990031005

No.	Tanggal	Hasil Konsultasi	Paraf Pembimbing